

重庆理工大学学报(自然科学)

Journal of Chongqing University of Technology(Natural Science)

ISSN 1674-8425,CN 50-1205/T

《重庆理工大学学报(自然科学)》网络首发论文

题目: 面向异构数据的多粒度动态聚类联邦学习模型
作者: 何帅为, 何兵, 乔少杰, 蒋宇河, 郑代涌, 郑康
收稿日期: 2025-12-18
网络首发日期: 2026-04-14
引用格式: 何帅为, 何兵, 乔少杰, 蒋宇河, 郑代涌, 郑康. 面向异构数据的多粒度动态聚类联邦学习模型[J/OL]. 重庆理工大学学报(自然科学).
<https://link.cnki.net/urlid/50.1205.T.20260414.1337.004>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

面向异构数据的多粒度动态聚类联邦学习模型

何帅为, 何兵, 乔少杰, 蒋宇河, 郑代涌, 郑康

(成都信息工程大学 软件工程学院, 成都 610225)

摘要: 联邦学习在保护数据隐私的同时实现分布式深度学习, 但面临 Non-IID(Non-Independent and Identically Distributed)数据导致的性能退化以及现有聚类方法难以适应动态数据分布等挑战。针对上述问题, 提出多粒度动态聚类联邦学习模型 MG-DCFL(Multi-Granularity Dynamic Clustering Federated Learning)。针对粒球计算局限于欧氏空间的问题, 采用语义相似度构建参数空间粒球模型, 扩展粒球理论至高维参数空间; 针对缺乏聚类质量评估机制的问题, 设计纯度与收敛性双重指标量化聚类质量; 针对聚类结构静态固化的问题, 提出分裂、合并、重分配三策略协同演化机制, 实现聚类结构的自适应调整。实验结果表明: MG-DCFL 在异构场景下能准确识别数据特征并完成有效聚类, 性能优于现有方法; 在动态数据场景下通过演化机制调整聚类结构, 准确率达 67.4%, 较静态聚类方法提升 14.6%。

关键词: 异构数据; 联邦学习; 聚类; 粒球计算; 动态演化

中图分类号: TP311

Multi-granularity dynamic clustering federated learning model for heterogeneous data

HE Shuaiwei, HE Bing, QIAO Shaojie, JIANG Yuhe, ZHENG Daiyong, ZHENG Kang

(School of Software Engineering, Chengdu University of Information Technology, Chengdu 610225, China)

Abstract: Federated learning enables distributed deep learning while preserving data privacy, yet faces challenges including performance degradation caused by Non-IID (Non-Independent and Identically Distributed) data and the inability of clustering methods to adapt to dynamic data distributions. This paper proposes MG-DCFL (Multi-Granularity Dynamic Clustering Federated Learning) to address these issues. To overcome the limitation of granular ball computing in Euclidean space, MG-DCFL constructs a parameter-space granular ball model using semantic similarity, extending granular ball theory to high-dimensional parameter space. To address the lack of clustering quality evaluation, MG-DCFL employs dual metrics of purity and convergence to quantify clustering quality. To solve the static clustering structure problem, MG-DCFL introduces a collaborative evolution mechanism integrating splitting, merging, and reassignment strategies, achieving adaptive adjustment of clustering structures. Experimental results demonstrate that MG-DCFL accurately identifies data features and achieves effective clustering in heterogeneous scenarios, outperforming existing methods. In dynamic data scenarios, the evolution mechanism adjusts clustering structures and achieves an accuracy of 67.4%, representing a 14.6% improvement over static clustering methods.

Keywords: heterogeneous data; federated learning; clustering; granular ball computing; dynamic evolution

0 引言

联邦学习作为新型分布式机器学习范式, 允许多个参与者在保持数据本地化的同时协同训练

全局模型, 有效解决数据孤岛和隐私保护问题^[1]。然而, 实际应用中不同客户端的数据存在显著差异, 非独立同分布(Non-IID)特性导致算法收敛缓慢, 全局模型性能严重退化^[2]。

聚类联邦学习通过识别具有相似数据分布的客户端群体并训练个性化模型, 缓解这一问题^[3]。然而, 现有聚类方法普遍采用静态配置, 难以适应数据分布的动态变化, 且聚类决策缺乏可解释性。粒球计算理论作为新兴的多粒度认知计算方法, 其多粒度表示能力和自适应粒度调整机制为动态聚类提供了理论支撑^[4]。但现有研究主要面

收稿日期: 2025-12-18

基金项目: 国家自然科学基金项目(62272066, 62572078); 四川省科技计划资助项目(2025ZNSFSC0044, 2025YFHZ0194, 2025YFRG0013); 网络空间大数据智能安全教育部重点实验室开放基金课题(CBDIS202404); 成都市重点研发计划基础研究项目(2025-YF12-00019-RC, 2025-YF12-00012-RC, 2025-YF12-00015-RC); 成都重点研发支撑计划产业链协同创新项目(2025-XT00-00005-GX); 成都重点研发支撑计划成果转化示范项目(2026-YF09-00044-SN); 成都市区域科技创新合作项(2025-YF11-00050-HZ, 2026-YF11-00061-HZ)

作者简介: 何帅为, 男, 硕士研究生, 主要从事联邦学习研究, E-mail: 1123123818@qq.com; **通信作者** 何兵, 男, 博士, 主要从事人工智能研究, E-mail: bingh@cuit.edu.cn。

向欧氏空间的集中式场景，如何将其扩展到高维参数空间的分布式环境是一个具有挑战性的问题。

基于上述问题，提出多粒度动态聚类联邦学习框架 MG-DCFL(Multi-Granularity Dynamic Clustering Federated Learning)，通过将粒球计算理论与聚类联邦学习深度融合，实现训练数据的特征识别与聚类划分。主要贡献包括：

(1) 突破传统粒球理论的欧氏空间限制，建立参数空间粒球理论体系。现有粒球计算研究局限于欧氏空间，MG-DCFL 将粒球计算扩展至高维参数空间，采用语义相似度替代几何距离作为聚类度量构建粒球模型，实现有效聚类并提升计算效率；设计纯度-收敛性双重指标量化聚类质量，使聚类决策从依赖训练特征转变为基于聚类状态的自适应判断，提升决策的准确性和可解释性。

(2) 突破现有聚类方法的静态局限，设计自适应演化机制。现有聚类联邦学习采用静态聚类方法，聚类一旦确定便难以调整。MG-DCFL 提出分裂、合并、重分配三策略协同的演化机制，使聚类联邦学习具备对数据分布变化的动态响应能力，实现聚类结构的持续优化。

(3) 在标准数据集上进行对比实验和消融实验，验证 MG-DCFL 在异构数据场景和动态数据场景下的有效性及性能优势。

1 相关工作

1.1 聚类联邦学习

McMahan 等人^[5]提出 FedAvg(Federated Averaging)算法实现协同训练，但其基于数据独立同分布假设，与实际场景存在显著差异。Li 等人^[6]提出 FedProx 算法，通过引入近端项限制本地模型与全局模型的偏离程度，缓解了数据异构性的影响。

Sattler 等人^[3]提出聚类联邦学习框架 CFL(Clustering Federated Learning)，通过梯度相似度识别相似客户端并训练个性化模型，但聚类结构固定且复杂度高达 $O(n^3)$ 。后续，IFCA(Iterative Federated Clustering Algorithm)算法采用交替优化策略同时学习聚类分配和模型参数^[7]；FLACC(Federated Learning via Agglomerative Client Clustering)框架通过贪婪聚合策略和系统记忆机制实现自适应聚类^[8]；FedUC(Unified Clustering Algorithm for Hierarchical Federated Learning)算法通过最优时分调度提升聚类效率^[9]；

FLSC(FL with Soft Clustering)方法通过引入重叠软聚类与局部模型融合机制，提高了异构数据场景下局部信息利用效率与模型学习性能^[10]。

现有聚类策略的不足在于：聚类结构一旦确定便难以重构，无法适应数据分布的动态变化；聚类决策依赖更新特征而非系统状态，缺乏鲁棒性和可解释性。

1.2 粒球计算理论

Xia 等人^[4]提出粒球计算理论体系，使用球形几何结构作为基本计算单元，表示数据空间的子区域，具有高效性、鲁棒性、可解释性和自适应性等优势。粒球计算基本思想如图 1 所示^[11]。




图 1 粒球计算基本思想

基于粒球理论，Ball k-means 算法通过自适应粒球半径调整解决了传统 k-means 对初始化敏感的问题，在大规模数据集上实现数量级的加速^[12]；GBCT(Granular-ball Clustering)算法采用密度感知策略识别任意形状的聚类结构，通过自适应粒度调节实现精度和效率的平衡^[13]。在深度学习领域，GRIG(Graph-based Representation for Image based on Granular-ball)方法使用粒球计算将图像转换为图结构，提升模型的可解释性^[14]。GBSC(Spectral Clustering Algorithm Based on Granular-ball)算法将粒球应用于谱聚类，使其能够处理百万级数据集^[15]，GrBFL(Granular-Ball Federated Learning)框架将粒球理论引入联邦学习，但仅应用于数据预处理步骤，未融入训练核心过程^[16]。

现有研究聚焦于欧氏几何度量，但神经网络参数空间的语义信息体现在梯度方向而非绝对位置，传统度量方式难以直接适用。

2 多粒度动态聚类联邦学习模型

2.1 聚类联邦学习模型架构及训练

MG-DCFL 采用两阶段渐进式训练策略，避免过早聚类导致信息损失和长期全局训练带来性能退化。初始阶段，全部客户端置于初始粒球

GB_0 中基于统一全局模型协同训练，建立全局知识基础。训练轮次达到 T_i 后系统评估粒球状态，当数据异构性显著且模型趋于稳定时，触发首次分裂并转入聚类阶段。聚类阶段，各粒球独立维护个性化模型，服务器按粒球归属关系分组聚合，并依据动态演化机制调整聚类结构。

系统架构如图 2 所示，采用服务器-客户端分层架构。服务器承担核心协调职责：1) 参数验证，

基于 L2 范数过滤幅度异常项，基于所属粒球中心的方向相似度过滤偏离项初始阶段以初始粒球中心为基准，聚类阶段以各粒球中心为基准；2) 模型聚合，对合法参数执行数据量加权聚合；3) 聚类管理，根据粒球状态触发演化操作；4) 参数分发。客户端仅负责本地训练与参数上传，无需感知聚类结构变化。




图 2 MG-DCFL 系统架构

2.2 面向参数空间的粒球模型

基于 Sattler 等人^[3]揭示的梯度相似性与数据分布相似性之间的映射关系，本文提出面向参数空间的粒球模型，以语义相似度替代几何距离作为聚类准则，兼顾高维聚类的有效性、计算高效性与决策可解释性。

定义 1 (参数空间粒球) 在参数空间，粒球 GB 定义为：

$$GB = \{C, \mu, r, \rho, \sigma, \omega\} \quad (1)$$

式中， $C = \{c_1, c_2, \dots, c_n\}$ 表示粒球包含的客户端集合； μ 表示粒球中心，表示粒球的整体优化趋势； r 表示归属半径，建立粒球成员的归属边界； ρ 表示粒球纯度，量化粒球的内部同质性； σ 表示收敛指标，量化粒球的模型收敛趋势； ω 表示粒球的模型参数。参数空间的粒球模型如图 3 所示：




图 3 参数空间粒球模型

其中，不同颜色区域表示系统内不同粒球的归属范围； $\Delta\omega$ 表示客户端的参数更新，实线表示已分配客户端更新，虚线表示未分配客户端更新。

定义 2 (粒球中心) 粒球 GB 的中心 μ 采用数据量加权平均计算：

$$\mu = \sum_{c_i \in GB} \frac{|c_i.D|}{\sum_{c_j \in GB} |c_j.D|} \cdot c_i.\Delta\omega \quad (2)$$

式中, $|c_i.D|$ 表示客户端 c_i 的本地数据集大小; $c_i.\Delta\omega$ 表示客户端 c_i 的参数更新。

定义 3 (相似度度量) 客户端 c_i 与粒球 GB 的数据相似度通过客户端更新与粒球中心的余弦相似度实现评估:

$$\text{sim}(c_i, GB) = \frac{c_i.\Delta\omega \cdot GB.\mu}{\|c_i.\Delta\omega\| \|GB.\mu\|} \quad (3)$$

式中, $c_i.\Delta\omega$ 表示客户端 c_i 的更新向量; $GB.\mu$ 表示粒球 GB 的中心; $\|\cdot\|$ 表示 L2 范数。

此外, 粒球间相似性也通过粒球中心的余弦相似度实现度量。

定义 4 (粒球纯度) 粒球 GB 的纯度 ρ 采用粒球内部相似度的均值量化内部同质性:

$$\rho = \frac{1}{|GB.C|} \sum_{c_i \in GB} \text{sim}(c_i, GB) \quad (4)$$

式中, $|GB.C|$ 表示粒球 GB 包含的客户端数量, $\text{sim}(c_i, GB)$ 表示客户端 c_i 与粒球 GB 的相似度。高纯度表示粒球内部优化方向一致; 低纯度表明存在显著异质性。

定义 5 (粒球收敛指标) 粒球 GB 的收敛指标 σ 通过滑动窗口分析中心变化以评估模型稳定性:

$$\sigma = \frac{\|GB.\mu^t - GB.\mu^{t-1}\|}{\frac{1}{n} \sum_{k \in [t-n, t]} \|GB.\mu^k - GB.\mu^{k-1}\|} \quad (5)$$

式中, $GB.\mu^t$ 表示第 t 轮粒球 GB 的中心向量; n 表示滑动窗口大小。较大 σ 值表示模型趋于稳定状态。

定义 6 (粒球归属条件) 若存在粒球满足 $\text{sim}(c_i, GB) \geq GB.r$, 则客户端 c_i 归属于其中相似度最高的粒球; 否则记录为未分配状态, 避免强制归属破坏粒球同质性。

2.3 粒球动态演化机制

联邦学习环境的动态性和异构性要求聚类结构具备自适应调整能力。本文基于粒球纯度和收敛指标设计分裂、合并、重分配三策略协同的动态演化机制分裂细化异构粒球并产生未分配客户端, 合并整合碎片化粒球并创造吸纳空间, 重分配完成资源再配置, 三者协同实现聚类结构对数据变化的自适应响应。表 1 列出了后续的主要符号及其含义。

表 1 主要符号说明

符号	详细描述
GB	粒球对象
$GB.C$	粒球包含的客户端集合
$GB.\mu$	粒球中心向量
$GB.\rho$	粒球纯度
$GB.\sigma$	粒球收敛指标
$GB.\omega$	粒球模型参数
$GB.cd$	粒球冷却期剩余轮次
$ GB.D $	粒球包含的总数据量
B	系统粒球集合
U	未分配客户端集合
$\setminus$	集合差运算
τ_{pur}	粒球纯度阈值
τ_{conv}	粒化收敛阈值
τ_{size}	粒球规模阈值
τ_{dir}	粒球方向一致性阈值
τ_{data}	粒球数据相似度阈值

2.3.1 粒球分裂策略

粒球分裂策略针对内部多模态分布导致的梯度抵消问题, 通过识别并划分异质性显著的粒球实现聚类粒度优化。图 4 展示了粒球分裂过程:




图 4 粒球分裂过程示例

其中, 粒球 GB 内部异构性显著且趋于稳定后触发粒球分裂, 分裂为两个高纯度子粒球 GB_1 和 GB_2 , 不满足归属条件的客户端转入未分配状态。具体而言, 分裂策略按以下流程执行:

(1) 分裂判定。系统对非冷却期粒球进行状态评估, 同时满足三项约束时触发分裂: 1) 规模约束 $|GB.C| \geq \tau_{size}$, 确保子粒球具有统计意义; 2) 纯度条件 $GB.\rho < \tau_{pur}$, 确保粒球内部存在显著异构特征; 3) 收敛判定 $GB.\sigma \geq \tau_{conv}$, 确保模型已趋于稳定。

(2) 种子选取。满足分裂条件后, 按照客户端与粒球的相似度降序排序, 选取 85%分位点 (高相似度) 和 15%分位点 (低相似度) 的客户端作为种子节点, 分别初始化子粒球并继承父粒球参数。高相似度种子代表粒球"核心模式", 低相似度种子代表"边缘模式", 两端选取以最大化子聚类区分度并代表异构粒球内不同更新趋势; 采用分位点而非极值以避免离群点干扰。

(3) 客户端分配。子粒球初始化后, 遍历剩余

客户端，计算其与子粒球的相似度。若满足归属条件则分配至相似度更高的子粒球并更新粒球中心，否则标记为未分配状态。

(4) 有效性验证。客户端分配结束后，验证子粒球客户端数量是否满足规模阈值 τ_{size} 。若均满足则分裂成功，子粒球进入冷却期；若仅一个满足则保留该子粒球，另一子粒球成员转入未分配状态；若均不满足约束则撤销分裂，维持原粒球结构。

算法 1 为分裂策略的形式化描述，时间复杂度为 $O(n \log n)$ ， n 为客户端总数。

算法 1：粒球分裂算法

输入：粒球集合 B ，未分配客户端集合 U 。

输出：更新后的粒球集合 B ，更新后的未分配客户端集合 U 。

```

1. for each  $GB \in B$  do
2.   if FilterByState( $GB$ ) then
3.      $sd_1, sd_2 \leftarrow \text{SelectSeeds}(GB)$ ;
4.      $GB_1, GB_2 \leftarrow \text{CreateBall}(sd_1, sd_2, GB)$ ;
5.     for each  $c \in (GB.C \setminus \{sd_1, sd_2\})$  do
6.        $GB' \leftarrow \text{GetNearestBall}(c, GB_1, GB_2)$ ;
7.       if  $\text{sim}(c, GB') \geq r$  then
8.          $GB'.C \leftarrow GB'.C \cup \{c\}$ ;
9.       else
10.         $U \leftarrow U \cup \{c\}$ ;
11.     end if
12.   end for
13.    $B_{valid} \leftarrow \text{FilterBySize}(GB_1, GB_2)$ ;
14.   if  $|B_{valid}| > 0$  then
15.      $B \leftarrow (B \setminus \{GB\}) \cup B_{valid}$ ;
16.      $U \leftarrow U \cup \text{GetClients}(\{GB_1, GB_2\} \setminus B_{valid})$ ;
17.   end if
18. end if
19. end for
20. return  $B, U$ ;
```

该策略仅计算客户端与粒球中心的相似度并采用启发式划分，相比传统方法构建完整相似度矩阵选取种子节点的 $O(n^2)$ 和采用最优二分算法寻求全局最优划分的 $O(n^3)$ 显著降低。该策略的可行性源于后续演化过程可持续优化聚类结构。

2.3.2 粒球合并策略

合并策略针对聚类演化产生的碎片化问题，通过识别并整合相似粒球优化系统规模并促进知识共享。图 5 展示了粒球合并过程：




图 5 粒球合并过程示例

其中，相似粒球对 GB_i 和 GB_j 通过三阶段筛选后合并为粒球 GB_m 。

算法 2：粒球合并算法

输入：粒球集合 B 。

输出：更新后的粒球集合 B 。

```

1.  $B_{cand} \leftarrow \text{FilterByQuality}(B)$ ;
2.  $Pairs \leftarrow \emptyset$ ;
3. for each  $(GB_i, GB_j) \in \text{GetPair}(B_{cand})$  do
4.   if FilterByDirection( $GB_i, GB_j$ ) then
5.     if FilterByData( $GB_i, GB_j$ ) then
6.        $Pairs \leftarrow Pairs \cup \{(GB_i, GB_j)\}$ ;
7.     end if
8.   end if
9. end for
10.  $\text{SortBySim}(Pairs)$ ;
11. for each  $(GB_i, GB_j) \in Pairs$  do
12.   if  $\{GB_i, GB_j\} \subseteq B$  then
13.      $GB_m \leftarrow \text{MergeBall}(GB_i, GB_j)$ ;
14.      $B \leftarrow (B \setminus \{GB_i, GB_j\}) \cup \{GB_m\}$ ;
15.   end if
16. end for
17. return  $B$ ;
```

算法 2 为合并策略的形式化描述，时间复杂度为 $O(k^2)$ ，其中 k 为粒球数量。

具体而言，合并策略按以下流程进行：

(1) 粒球质量筛选。基于粒球状态快速筛选候选粒球，粒球需满足冷却期约束 $GB.cd = 0$ 、纯度约束 $GB.\rho \geq \tau_{pur}$ 、收敛约束 $GB.\sigma \geq \tau_{conv}$ ，确保只有高质量且状态稳定的非冷却期粒球参与合并。

(2) 方向一致性验证。计算候选粒球对 (GB_i, GB_j) 的粒球间相似度，当 $\text{sim}(GB_i, GB_j) \geq \tau_{dir}$ ，表明粒球对具有相近的优化趋势，满足方向一致性条件。

(3) 数据相似度验证。引入基于锚点模型的数据特征机制确保候选粒球对的数据相似性。系统保存初始阶段的最终全局模型作为锚点模型 ω_a ，客户端 c_i 基于锚点模型在本地数据上执行 E 轮训练取得训练后模型 $\omega_i^{(E)}$ ，数据特征 γ_i 为训练前后的参数差值展平向量，即 $\gamma_i = \text{Flatten}(\omega_i^{(E)} - \omega_a)$ ，独立于当前训练状态，反映客户端数据对模型的影响模式，体现客户端数据的本质信息。粒球数据特征 γ_{GB} 通过成员的数据特征按数据量加权聚合得出。当候选粒球对的数据特征余弦相似度 $\text{sim}(\gamma_{GB_i}, \gamma_{GB_j}) \geq \tau_{data}$ ，满足数据相似度条件。

(4) 合并执行。满足条件的粒球对按数据特征相似度降序合并。新粒球继承全部客户端并进入冷却期，其模型参数 ω_m 通过数据量加权融合生成，如式(6)所示：

$$\omega_m = \frac{|GB_i.D| \cdot GB_i.\omega_i + |GB_j.D| \cdot GB_j.\omega_j}{|GB_i.D| + |GB_j.D|} \quad (6)$$

2.3.3 客户端重分配策略

演化过程中部分客户端因不满足归属条件转入未分配状态，该策略评估未分配客户端与粒球匹配度以实现重分配，在保持粒球同质性的同时最大化数据利用率。




图 6 客户端重分配过程示例

图 6 展示客户端重分配过程，其中未分配客户端 c 计算与各粒球的相似度，满足条件后纳入相似度最高的粒球 GB_2 并同步模型参数。具体而言，重分配策略按以下流程执行：

(1) 重分配判定。每轮演化后评估未分配客户端与各非冷却期粒球的相似度。满足归属条件时，客户端纳入最相似粒球并同步模型参数。

(2) 未分配状态管理。不满足归属条件的客户端保持未分配状态并冻结参数，避免独立优化导致与粒球体系差异扩大。后续，系统持续进行相

似度评估，一旦满足条件便触发重分配操作。

算法 3 为重分配策略的形式化描述，时间复杂度为 $O(m \times k)$ ，其中 m 为未分配客户端数量， k 为粒球数量。

算法 3：客户端重分配算法

输入：粒球集合 B ，未分配客户端集合 U ，粒球半径 r 。
输出：更新后的粒球集合 B ，更新后的重分配客户端集合 U 。

```

1. for each  $c \in U$  do
2.    $GB' \leftarrow \text{FindNearestBall}(c, B)$ ;
3.   if  $sim(c, GB') \geq r$  then
4.      $GB'.C \leftarrow GB'.C \cup \{c\}$ ;
5.      $\text{SyncModel}(c, GB')$ ;
6.      $U \leftarrow U \setminus \{c\}$ ;
7.   end if
8. end for
9. return  $B, U$ ;
```

3 实验与分析

3.1 实验设置

实验基于 PyTorch 2.1.2 实现，在 NVIDIA RTX 4070 GPU 上运行。数据集选择 MNIST、EMNIST-ByClass 和 CIFAR-10，分别验证基础性能、多类别分类和复杂视觉识别能力，数据异构性通过 Dirichlet 分布 $\text{Dir}(\alpha)$ 控制。

网络架构方面，MNIST 采用两层卷积和单层全连接的轻量级 CNN，EMNIST 和 CIFAR-10 采用三个卷积块和两层全连接的标准 CNN，学习率 $\eta=0.01$ ，本地训练轮次 $E=3$ 。

表 2 参数取值及其设置依据

参数名称	符号	取值	设置依据
初始训练轮次	T_{init}	20	全局模型稳定后启动聚类评估
滑动窗口大小	n	3	平衡收敛判定的可靠性与响应速度
粒球冷却期	cd	3	防止连续演化导致聚类结构震荡
粒球归属半径	r	0	接纳正相似度客户端
粒球收敛阈值	τ_{conv}	0.98	确保模型参数趋于稳定
粒球规模阈值	τ_{size}	2	防止子粒球退化为单客户端
粒球方向一致性阈值	τ_{dir}	0	合并时要求优化方向非负相关
粒球数据相似度阈值	τ_{data}	0.5	合并时要求数据特征中等以上相似

性能评估采用分布式验证策略，客户端在本地验证集上独立计算准确率后算术平均，以准确反映 Non-IID 环境下的模型性能。对比方法选择 FedAvg^[5]作为经典联邦学习基准，CFL^[3]作为静态聚类联邦学习基准。

参数配置方面，纯度阈值 τ_{pur} 随训练场景调

整，其取值与数据复杂度和异构程度正相关。其余参数取值及其设置依据如表 2 所示。

3.2 异构数据场景下性能验证

实验在 MNIST、EMNIST 和 CIFAR-10 数据集构建具有聚类特征的场景。总通信轮次 80 轮，

20 个客户端均分为 4 组，分别施加 0° 、 90° 、 180° 、 270° 旋转变换，结合 Dir(1.0)分布构建特征和标签双重异构环境。

图 7 展示了三个数据集上的性能表现。MG-DCFL 在 MNIST 上达到 98.4%准确率，相比 FedAvg 和 CFL 分别提升 9.6%和 1.1%；在 EMNIST 上达到 86.8%，相比 FedAvg 和 CFL 分别提升 28.3%和 2.3%；在 CIFAR-10 上达到 71.2%，相比 FedAvg 和 CFL 分布提升 9.4%和 2.3%。随着任务复杂度增加，MG-DCFL 的性能

优势更为明显，验证了系统在特征识别与聚类划分方面的有效性。

训练曲线显示 MG-DCFL 在聚类阶段存在暂时的准确率波动，源于系统排除低相似度客户端以维持簇内同质性，后续客户端重分配至粒球时，模型难以适应新成员特征导致准确率短暂下降，随训练推进准确率逐渐回升。该机制以短期波动换取异常节点隔离与聚类动态重构能力，使其影响可接受。




图 7 异构数据场景下性能对比

3.3 动态数据场景下性能验证

实验在 MNIST、EMNIST 和 CIFAR-10 数据集上构建动态数据场景。总通信轮次 120 轮，40 个客户端均分为 4 组，分别施加 0° 、 90° 、 180° 、 270° 旋转变换。第 50 轮引入数据变化，对每个旋转组随机选择 50%客户端施加额外 180° 旋转以破坏原有聚类结构。

图 8 展示了三个数据集上的性能表现。MG-DCFL 在 MNIST 上达到 97.2%准确率，相比 FedAvg 和 CFL 分别提升 12.1%和 3.3%；在 EMNIST 上达到 86.5%，相比 FedAvg 和 CFL 分

别提升 24.1%和 4.6%；在 CIFAR-10 上达到 67.4%，相比 FedAvg 和 CFL 分别提升 11.2%和 14.6%，验证了演化机制的动态响应能力。

训练曲线显示第 50 轮数据变化后各方法均出现准确率下降。FedAvg 无聚类机制，受数据变化冲击较小但缺乏针对性优化。CFL 维持原聚类结构导致特征冲突，簇外客户端无法协同训练，部分场景性能低于 FedAvg，揭示了静态聚类的局限性。MG-DCFL 则通过演化机制成功重构聚类结构，准确率快速恢复并持续提升。




图 8 动态数据场景下性能对比

3.4 消融实验

为验证演化机制中各策略的有效性，本节在 CIFAR-10 数据集的动态数据场景下分别测试完整

系统及禁用单一策略的性能表现。






图 9 MG-DCFL 框架的聚类演化过程


图 9 展示了 MG-DCFL 框架的完整聚类演化过程。初始阶段(0~23 轮)建立全局模型基础,第 23 轮后进入聚类阶段,通过迭代分裂(第 34、45 轮)形成 4 个子粒球,对应不同的数据特征。第



(a) 未使用分裂策略



(b) 未使用合并策略



(c) 未使用重分配策略

图 10 消融实验结果对比

4 结论

针对联邦学习中数据异构导致的性能退化及聚类方法难以适应动态分布等问题,本文提出多粒度动态聚类联邦学习框架 MG-DCFL,其优势在于:1) 通过语义相似度构建参数空间粒球模型,纯度-收敛性双重指标为聚类决策提供可量化依据,聚类判定更具可靠性与可解释性;2) 分裂-合并-重分配三策略协同演化机制赋予聚类结构动态调整能力,能够适应数据分布变化。未来研究将探索自适应阈值机制减少先验知识依赖,研究软聚类策略支持客户端的多粒球归属,结合差分隐私等技术增强隐私保护能力。

参考文献

[1] LI T, SAHU A K, TALWALKAR A, et al. Federated learning: challenges, methods, and future directions[J]. IEEE Signal Processing Magazine, 2020, 37(3): 50-60.
[2] WANG J, LIU Q, LIANG H, et al. Tackling the objective inconsistency problem in heterogeneous federated

50 轮数据分布变化后,系统通过合并操作(第 58、59、82 轮)整合相似聚类,通过分裂操作(第 61、68、78 轮)隔离异构客户端,并持续进行客户端重分配,成功适应分布,准确率达 67.4%。

图 10 展示了消融实验结果。未使用分裂策略时,系统无法细化聚类结构,准确率降至 57.3%;未使用合并策略时,聚类碎片化限制知识共享,准确率降至 60.9%;未使用重分配策略时,边界客户端被排除导致数据利用率低,准确率降至 54.4%。实验验证了三种策略在细化聚类、优化共享和数据利用方面的协同作用。

optimization[J]. Advances in Neural Information Processing Systems, 2020, 33: 7611-7623.

[3] SATTTLER F, MÜLLER K R, SAMEK W. Clustered federated learning: model-agnostic distributed multitask optimization under privacy constraints[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(8): 3710-3722.
[4] XIA S, LIU Y, DING X, et al. Granular ball computing classifiers for efficient, scalable and robust learning[J]. Information Sciences, 2019, 483: 136-152.
[5] MCMAHAN B, MOORE E, RAMAGE D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial Intelligence and Statistics. PMLR, 2017: 1273-1282.
[6] LI T, SAHU A K, ZAHEER M, et al. Federated optimization in heterogeneous networks[J]. Proceedings of Machine Learning and Systems, 2020, 2: 429-450.
[7] GHOSH A, CHUNG J, YIN D, et al. An efficient framework for clustered federated learning[J]. IEEE Transactions on Information Theory, 2022, 68(12): 8076-8091.

- [8] MEHTA M, SHAO C. A greedy agglomerative framework for clustered federated learning[J]. IEEE Transactions on Industrial Informatics, 2023, 19(12): 11856-11867.
- [9] Ma Q, Xu Y, Xu H, et al. FedUC: A unified clustering approach for hierarchical federated learning[J]. IEEE Transactions on Mobile Computing, 2024, 23(4): 3456-3470.
- [10] LI C, LI G, VARSHNEY P K. Federated learning with soft clustering[J]. IEEE Internet of Things Journal, 2021, 9(10): 7773-7782.
- [11] XIA S, WANG G, GAO X, et al. Granular-ball computing: an efficient, robust, and interpretable adaptive multi-granularity representation and computation method[J]. arXiv preprint arXiv:2304.11171, 2023.
- [12] XIA S, PENG D, MENG D, et al. Ball k-means: fast adaptive clustering with no bounds[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 44(1): 87-99.
- [13] XIA S, SHI B, WANG Y, et al. GBCT: efficient and adaptive clustering via granular-ball computing for complex data[J]. IEEE Transactions on Neural Networks and Learning Systems, 2025, 36(1): 234-248.
- [14] XIA S, WANG G, Chen Z, et al. Graph-based representation for image based on granular-ball[J]. arXiv preprint arXiv:2303.02388, 2023.
- [15] XIE J, KONG W, XIA S, et al. An efficient spectral clustering algorithm based on granular-ball[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(9): 9743-9753.
- [16] LAI G, FENG Y, YANG X, et al. A new perspective on privacy protection in federated learning with granular-ball computing[J/OL]. arXiv preprint arXiv:2501.04940, 2025.