



山东大学学报(工学版)

Journal of Shandong University(Engineering Science)

ISSN 1672-3961,CN 37-1391/T

《山东大学学报(工学版)》网络首发论文

题目: 面向工业物联网基于区块链的高效安全联邦学习框架
作者: 何腾远, 王基书, 王敏, 唐明靖
收稿日期: 2025-07-04
网络首发日期: 2026-04-16
引用格式: 何腾远, 王基书, 王敏, 唐明靖. 面向工业物联网基于区块链的高效安全联邦学习框架[J/OL]. 山东大学学报(工学版).
<https://link.cnki.net/urlid/37.1391.T.20260415.1523.002>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

面向工业物联网基于区块链的高效安全联邦学习框架

何腾远¹, 王基书², 王敏¹, 唐明靖^{1,3*}

(1. 云南师范大学信息学院, 云南 昆明 650500; 2. 云南大学信息学院, 云南 昆明 650500; 3. 云南省马铃薯生物学重点实验室 (云南师范大学), 云南 昆明 650500)

摘要: 针对工业物联网设备计算性能异质性导致的联邦学习训练效率显著下降问题, 提出基于区块链的高效安全联邦学习框架。设计动态客户端选择算法和信誉管理机制, 筛选出可靠的高性能设备参与每轮训练; 设计基于主副链的区块链架构, 提高区块链交易验证效率, 降低区块链交易存储开销; 为了平衡区块链在联邦学习不同阶段的性能, 使用基于深度学习的方法动态调整区块大小, 使区块链运行更稳定、更高效。在公开数据集上的试验表明, 客户端选择算法性能接近理论最优, 区块链存储开销优化至传统方案的 66% 以下, 延迟预测性能优于现有工作。试验评估与结果分析证明所提框架的有效性和可行性, 同样适用于其他设备计算性能异质性的应用场景。

关键词: 工业物联网; 联邦学习; 区块链系统; 客户端选择; 主副链架构; 区块链性能优化

中图分类号: TP181

文献标志码: A

Efficient and secure blockchain-based federated learning framework for industrial Internet of Things

HE Tengyuan¹, WANG Jishu², WANG Min¹, TANG Mingjing^{1,3*}

(1. School of Information Science and Technology, Yunnan Normal University, Kunming 650500, Yunnan, China; 2. School of Information Science and Engineering, Yunnan University, Kunming 650500, Yunnan, China; 3. Yunnan Provincial Key Laboratory of Potato Biology, Yunnan Normal University, Kunming 650500, Yunnan, China)

Abstract: To address the significant decline in federated learning training efficiency caused by computational heterogeneity among industrial Internet of Things devices, an efficient and secure blockchain-based federated learning framework was proposed. The dynamic client selection algorithm and reputation management mechanism were designed to screen out reliable and high-performance devices to participate in each round of training. The main-subchain blockchain architecture was introduced to enhance transaction verification efficiency while reducing storage costs. A deep learning-based method was utilized to dynamically adjust the block size to balance blockchain performance across different federated learning phases, thereby enabling more stable and efficient blockchain operations. Experiments on public datasets demonstrated that the client selection algorithm achieved near-optimal performance, blockchain storage costs were optimized to less than 66% of conventional approaches, and latency prediction performance outperformed existing solutions. Experimental evaluations and result analyses demonstrated the effectiveness and feasibility of the proposed framework, which was equally applicable to other application scenarios characterized by device computational heterogeneity.

Keywords: industrial Internet of Things; federated learning; blockchain system; client selection; main-subchain architecture; blockchain performance optimization

0 引言

人工智能 (artificial intelligence, AI) 与工业物联网 (industrial Internet of Things, IIoT) 的结合引起学

术界和工业界的广泛关注^[1-2]。开发面向 IIoT 的 AI 产品通常需要大规模数据, 对训练高性能的机器学习 (machine learning, ML) 模型至关重要。在传统的 ML 模式中, 各个物联网设备需要将收集的原始数据共享

收稿日期: 2025-07-04

基金项目: 国家自然科学基金资助项目 (61862067); 云南省基础研究专项重点资助项目 (202501AS070007)

第一作者简介: 何腾远 (2002—), 男, 河南平顶山人, 硕士研究生, 主要研究方向为人工智能安全。E-mail: hetengyuan@ynnu.edu.cn

*通信作者简介: 唐明靖 (1978—), 男, 湖南沅陵人, 教授, 硕士生导师, 博士, 主要研究方向为深度学习、图神经网络和生物信息。E-mail: tmj@ynnu.edu.cn

到中央服务器进行集中训练。这些原始数据中往往包含大量的用户隐私信息（如地理位置），存在安全合规与隐私保护等问题^[3]。

为解决上述问题，联邦学习（federated learning, FL）作为一种分布式的 ML 框架应运而生^[4]。FL 不需要收集原始训练数据到中央服务器，数据拥有者只需在本地训练模型后上传模型参数，因此它能够满足数据使用的合规性，解决训练数据隐私保护、数据孤岛等问题^[5-8]。FL 已应用于医疗保健^[9]、自动驾驶^[10]等重要的 IIoT 场景中，但仍然存在一些不足，限制了进一步应用。一方面，经典 FL 范式仍然需要一个集中式的参数服务器，不可靠的参数服务器会导致数据隐私泄露^[11]；另一方面，不可靠的客户端可能会有意或无意地执行恶意攻击或消极训练等行为，影响全局模型的训练进程^[12]。

区块链作为一种分布式账本技术，具有去中心化、可追溯等特性及共识机制等组件，可以有效缓解 FL 中存在的上述问题。使用区块链网络代替 FL 中的参数服务器，实现 FL 架构的去中心化，解决中心参数服务器的可靠性问题。利用区块链的可追溯性，结合信誉机制可以快速发现恶意客户端并进行惩罚，降低恶意客户端毒化全局模型的风险^[13-14]。

在 IIoT 场景下，不同设备之间存在异质性，即设备的计算性能、存储空间均可能存在差异。现有基于区块链的 FL 模式使用随机选择方法确定每轮训练的客户端，保证客户端选择的公平性^[15]。但是在 IIoT 设备异质性的情况下，选择存在的低性能设备可能会延长 FL 的模型训练时间，使高性能设备处于长期等待状态，降低 FL 的整体训练效率^[16]。

常见的解决方法是在 FL 任务发布时添加对客户端设备的性能要求，使低性能设备不参与模型训练^[17]。但 IIoT 的设备往往需要进行包括 FL 在内的多个任务，设备的实时可用计算资源会由于其他任务的影响而出现变动。因此，即便在任务发布时筛选出符合性能要求的设备，仍然可能随机选择到实时可用计算资源较低的客户端。

针对上述问题，本研究提出一种动态客户端选择方法，在 FL 每轮训练开始前，根据设备当前的计算性能选择本轮客户端，使选出的设备性能差异较小，平均训练时间最短；考虑客户端可能存在恶意攻击和消极训练等问题，提出一种基于信誉机制的客户端管理机制，遏制此类行为发生；在客户端选择阶段同时考虑设备当前的计算性能和信誉，实现所选择的客户端在本轮训练阶段的实际计算性能和诚实度最优。

在基于区块链的 FL 系统中，对新区块内容的验证往往花费较长时间。因此，本研究设计一种基于主

副链的双区块链结构。主链负责存储 FL 过程中的所有相关数据，在完成 FL 任务的同时实现训练数据可追溯；副链记录 FL 客户端的动作信息，负责对主链的交易内容进行快速验证。基于主副链架构能够有效提升主链交易验证效率，减少交易存储总开销。然而，区块链的交易处理性能也会影响 FL 效率。在 FL 不同阶段中，由于提交到区块链的交易规模不同，区块链会有不同的延迟和吞吐量。区块大小和交易到达率（本研究中交易到达率指客户端竞选时的交易规模和模型更新时的交易规模）会显著影响区块链性能。因此，本研究使用深度学习（deep learning, DL）方法动态调整区块大小，平衡区块链在 FL 不同阶段交易规模下的性能，加快整体训练效率。

1 相关工作

1.1 联邦学习客户端选择

为了保证客户端被选中概率的平等性，传统 FL 常常使用随机选择的方法^[15]。但是在客户端异质性环境下，随机选择的方法会严重降低联邦学习的训练效率和全局模型性能^[16]。文献[18]通过信誉机制对客户端模型更新进行管理，有效选择出无恶意行为的客户端，保证全局模型的安全性；文献[19]通过评估模型更新的贡献，自适应选择贡献较大的客户端，有效筛选掉低质量数据的客户端。上述研究没有考虑设备可用计算资源不规则变化的问题，因此，在 IIoT 环境下，模型训练效率仍然过低。基于此，文献[16]根据客户端计算性能为每轮训练指定截止时间，在截止时间内尽可能多地接收客户端的更新，虽然保证每轮训练时间的可控性，但是不能保证每轮客户端数量的可控性。

本研究设计一种基于计算性能和信誉的客户端选择和管理机制，改善现有工作中存在的不足，使 FL 更适用于 IIoT 场景。

1.2 基于区块链的 FL 框架

区块链与 FL 的结合是热门研究方向。研究人员已经使用区块链技术解决 FL 中的许多挑战。文献[18]使用联盟区块链存储管理客户端的信誉，结合激励机制鼓励客户端参与训练，有效抵抗 FL 中的模型中毒攻击；文献[20]使用完全去中心化、受隐私保护的区块链作为 FL 系统的中央数据库，保护本地隐私数据免受恶意客户端攻击。上述研究中的区块链通过解耦方式辅助 FL，但分离式的架构增加了技术部署成本及引入区块链所致的额外性能开销。文献[21]设计一种共识机制，基于有向无环图构建区块链加权的 FL 框架，有效解决 FL 中存在的设备异步和资源消耗问题；文献[22]提出一种基于区块链的 FL 系统，用于

IIoT 中的故障检测,实现客户端数据的完整性验证;文献[23]提出一种异步全局聚合方法,加快 FL 的收敛速度。

受上述工作的启发,本研究设计一种基于主副链的区块链结构,对交易验证和交易存储进行优化,提高 FL 框架的整体训练效率及潜在的训练溯源效率。

1.3 区块链性能优化

随着区块链在多个领域的应用,其性能问题也逐渐受到关注。文献[24]提出一种基于区块链的 IIoT 分布式数据系统,使用分段散列图共识算法优化区块链的吞吐量和延迟;文献[25]提出一种具有事务去重功能的区块链,通过自适应扩展实现更高的吞吐量;文献[26]使用区块链分片技术提高吞吐量,动态平衡不同分片上的交易负载;文献[27]结合 DL 选择合适的矿工和交易,最大限度减少区块链延迟;文献[28]使用 DL 方法动态调整区块参数,通过训练区块链性能预测模型预测区块链在不同交易到达率和区块大小下的性能表现,选择适合当前交易到达率的区块大小参数,有效提高区块链的性能。

现有工作已实现有效的区块链性能优化,但基于共识机制和分片的方法往往具有较高的复杂性,不适用于设备性能受限的 IIoT 场景。基于 DL 的区块链性能优化方法在模型预测精度和性能优化效果上仍有进一步提升的空间。

2 基于区块链的高效安全 FL 框架

本研究设计一个基于区块链的高效安全 FL 框架,可以在 IIoT 设备存在计算性能异质性的情况下完成高效的 FL。该框架由网络层、区块链层和应用层 3 层架构组成。网络层是由任务发布者和客户端组成的一个分散的对等网络,其中任务发布者负责发布一个 FL 任务,客户端负责 FL 任务的执行。区块链层由主链和副链 2 条区块链组成,主链负责记录与 FL 相关的所有数据,副链只记录客户端的动作信息。应用层由智能合约和 FL 协同控制整个 FL 相关事件的执行。

2.1 工作流程

基于区块链的高效安全 FL 框架工作流程如图 1 所示,具体步骤如下。




图 1 基于区块链的高效安全 FL 框架工作流程

Fig.1 Workflow of efficient and secure blockchain-based FL framework

(1)任务发布与节点筛选。任务发布者广播一个 FL 任务,包含训练要求(模型的目标精度、聚合规则等)和客户端要求(本地数据量、硬件资源等)。符合要求的节点成为本次 FL 任务的客户端并初始化本地模型和信誉。

(2)副链性能优化。在新一轮训练开始前,执行区块链优化算法,根据本次 FL 任务的客户端数量调整副链的区块大小。

(3)本轮客户端选择。客户端根据当前计算性能

预估本地训练时间,将本地训练时间广播并记录在副链区块中。智能合约执行客户端选择算法,根据客户端的预估时间和信誉选出本轮客户端。

(4)主副链性能优化。在选出本轮训练的客户端后,再次执行区块链优化算法,根据本轮训练的客户端数量调整主链和副链的区块大小。

(5)本地模型训练。本轮训练客户端使用本地数据对模型进行训练,将本地训练结果(模型更新和实际训练时间)广播并记录在副链区块中。

(6)模型聚合与信誉计算。本轮客户端中信誉最高的客户端成为领导者节点,执行模型聚合算法和信誉更新算法,根据其他客户端广播的本地训练结果更新全局模型和客户端信誉。

(7)区块生成及共识验证。领导者节点将更新后的全局模型和客户端信誉打包到新区块中并广播给其他客户端,其他客户端通过副链中记录的客户端行为信息验证新区块中的内容。

(8)新区块添加到主链。如果新生成的区块通过大多数客户端的验证,该区块将添加到主链上,被整个网络接受。

2.2 客户端选择设计

客户端选择机制用于从本次 FL 任务的所有客户端集合中选出参与本轮训练的一个客户端子集。在 IIoT 中,FL 的客户端选择结果往往决定总体训练效率。一方面,客户端设备可能在网络延迟和计算能力上存在差异性,导致它们不能同步完成训练;另一方面,不同设备的训练数据存在分布差异,造成全局模型收敛缓慢。假设客户端设备的网络延迟等通信资源差异性较小可忽略,且不同设备的训练数据独立同分布,则本研究在客户端选择算法研究中重点关注 IIoT 设备的计算性能异质性问题。设计基于客户端当前计算性能的选择算法,使选出的客户端在本轮训练时间最短。算法选出训练时间最短的 k 个客户端子集

$$S_k^* = \arg \min t_{\text{sum}}(S_k), S_k \in C_n, \quad (1)$$

式中, S_k 为 k 个客户端子集, C_n 为本次 FL 所有 n 个客户端总集, $t_{\text{sum}}(\cdot)$ 为客户端集合中的训练时间总和。

在竞选阶段存在客户端诚实性问题,即不诚实的客户端会通过上传虚假预估时间提高被选中参与本轮训练的概率。为此,设计信誉机制管理客户端竞选行为。此时算法选出的训练时间最短的 k 个客户端子集

$$S_k^* = \arg \min t_{\text{sum}}(S_k), S_k \in C_n, R_{\min}(S_k) \geq r, \quad (2)$$

式中: $R_{\min}(\cdot)$ 为客户端集合中的最低信誉; r 为信誉阈值, $r = (R_{\text{ini}} + d) / a$, 其中 R_{ini} 为初始信誉, d 为信誉增长步幅, a 为信誉下降指数。基于预估时间和信誉共同选择客户端,使本轮实际训练时间最短。具体过程如算法 1 所示。

算法 1 基于预估训练时间和信誉的客户端选择算法

输入: k 、 C_n 、 r 、客户端预估训练时间集合 T 、客户端信誉集合 R 。

输出: S_k^* 。

(1) 初始化 S_k^* ;

(2) 遍历集合 C_n 中的客户端,从集合 R 中获取当前客户端的信誉,将信誉小于 r 的客户端从 C_n 中删除;

(3) 根据集合 T 中的预估训练时间,将 C_n 中剩余的客户端按各自的预估训练时间从小到大排序;

(4) 从 C_n 的客户端排序中截取前 k 个客户端添加到 S_k^* 中。

在 FL 每轮训练结束后,根据客户端竞选时的诚实性更新信誉。当客户端诚实时,信誉呈线性增长;当客户端不诚实时,信誉呈指数性下降。经典信誉评估模型(如贝叶斯信誉系统)通过分析客户端的长期行为数据实现信誉的动态精确估计。相比之下,本研究设计的信誉更新机制重点关注客户端信誉与预设信誉阈值之间的相对关系,核心目标在于高效筛选出不诚实客户端,为诚实客户端留有容错空间。

本研究设计的信誉机制采用归一化数值范围 $[0,1]$,其中所有参与设备的初始信誉均设置为中间值 0.5,以实现双向信誉更新能力。单次线性增长步幅取值区间为 $[0.05,0.10]$,不同取值控制客户端获得容错能力的难易程度。信誉下降指数一般固定设置为 2,保证高效筛选出不诚实客户端。此外,设定信誉上限 R_{max} 为 a 和 R_{ini} 的乘积,客户端一旦表现出不诚实的行为,则客户端信誉立刻小于或等于 R_{ini} 。此设定使客户端在初始训练轮次保持诚实后获得一次容错。信誉更新的具体过程如算法 2 所示。

算法 2 客户端信誉更新算法

输入: 客户端 i 当前信誉 R_i 、客户端 i 预估训练时间 t_i^e 、客户端 i 实际训练时间 t_i 、 R_{max} 、 d 、 a 。

输出: 客户端 i 更新后的信誉 R_i' 。

- (1) 初始化 $R_i' = R_i$;
- (2) if $t_i^e < t_i$ then;
- (3) $R_i' = R_i / a$;
- (4) else if $t_i^e \geq t_i, R_i + d < R_{\text{max}}$ then;
- (5) $R_i' = R_i + d$;
- (6) else;
- (7) $R_i' = R_{\text{max}}$;
- (8) end if。

2.3 主副链架构设计

本研究选用联盟链减少区块链在块生成阶段对计算资源的需求,选择信誉最高的客户端作为本轮领导者节点,负责计算全局模型更新和客户端信誉更新,将结果打包到新区块中。设计基于主副链的架构优化主链交易的验证过程。主副链架构如图 2 所示。




图2 主副链架构

Fig.2 Main-subchain architecture

在主副链架构中，主链负责保存与 FL 训练相关的完整数据，副链只记录每轮训练时客户端的行为数据。当客户端将行为数据提交到区块链时，副链节点进行验证并存储，每轮训练结束后，领导者节点将副链区块中记录的本轮客户端行为数据打包到主链的新区块中，实现主副链数据同步。由于副链中记录的数据较少，在对主链新区块内容验证时可以快速从副链中查询到所需数据，具体验证过程如算法 3 所示。

算法 3 基于主副链架构的模型更新和信誉更新结果验证过程

输入： 新生成区块中的全局模型更新 M' 、客户端更新信誉集合 R' 、当前全局模型 M 、客户端信誉集合 R 。

输出： 客户端 j 对新区块的验证结果 V_j 。

- (1) 初始化 $V_j = \text{false}$ ；
- (2) 向副链请求本轮训练客户端提交的本地模型更新集合 M_k ；
- (3) 根据 M_k 中的本地模型更新和 M 对 M' 进行验证，若验证错误，直接输出 $V_j = \text{false}$ ；
- (4) 遍历 R' 中的 R'_i ，向副链请求 t_i^e 和 t_i ，在 R 中获取 R_i ，根据 t_i^e 、 t_i 和 R_i 验证 R'_i ，若验证错误，输出 $V_j = \text{false}$ ；
- (5) 若对 M' 和 R' 均验证正确，输出验证结果 $V_j = \text{true}$ 。

在存储设计上，选用约 1/3 总节点数量的奇数个节点存储主链交易数据，剩余节点存储副链交易数据。在这种设计下，主副链架构的交易存储在本质上是用副链节点替换部分主链节点，有效降低所有节点在交易存储上的总开销。

2.4 区块链参数优化设计

区块链的延迟性能受多种因素影响，如网络拓扑与传播延迟、区块大小与生成间隔、网络负载与突发流量等。在基于区块链的 FL 系统中，不同 FL 阶段客户端提交到区块链的交易量存在显著差异，交易量的动态变化与固定区块大小机制之间的不匹配导致区块链网络延迟严重波动。因此，在忽略其他影响区块链延迟性能因素的前提下，本研究使用基于 DL 的

方法动态调整区块大小，降低区块链在 FL 各阶段的平均延迟。此方法的关键点在于使用高性能 DL 模型完成区块链性能预测任务。

文献[28]选用多层感知机(multilayer perceptron, MLP)网络训练性能预测模型；文献[29]提出的 Kolmogorov-Arnold 网络(Kolmogorov-Arnold networks, KAN)在线性回归任务上表现出优越性，将多变量函数分解为单变量函数的叠加，理论上能以更少的参数精确表示某些函数。本研究设计使用 KAN 训练区块链性能预测模型。KAN 结构如图 3 所示。输入层由交易到达率和区块大小 2 个特征组成。这些特征经过多个隐藏层后映射到输出层。输出层代表区块链的交易延迟。




图3 KAN 结构

Fig.3 Structure of KAN

在区块链参数优化时，将 FL 下一阶段的活跃客户端数量作为交易到达率，与不同区块大小一起馈送到上述训练的 KAN 模型中，使用预测延迟最低的区块大小进行调整，具体过程如算法 4 所示。

算法 4 基于 DL 的区块大小动态调整算法

输入： FL 下一阶段的活跃客户端数量 P 、可选择的区块大小集合 $B = \{B_1, B_2, \dots, B_n\}$ 、已训练的区块链延迟预测模型 KAN。

输出： 最佳区块大小 B_{best} 。

- (1) 初始化 $B_{\text{best}} = 0$ 、最佳延迟 $L_{\text{best}} = 0$ ；
- (2) for B_i in B ；
- (3) 预测延迟 $L_i = \text{KAN}(P, B_i)$ ；
- (4) if $L_{\text{best}} = 0$ or $L_{\text{best}} > L_i$ then；
- (5) $L_{\text{best}} = L_i$, $B_{\text{best}} = B_i$ ；
- (6) end if；
- (7) end。

3 试验评估与结果分析

本研究使用 64 位 Intel Core i7-8750H 2.20 GHz CPU、NVIDIA Geforce GTX 1050 GPU、16 GB 内存并搭载 Windows 操作系统的工作站进行试验。PyCharm 为集成开发环境，编程语言选用 Python 3.8，

PyTorch 2.4.1 作为 DL 框架。

3.1 基于预估训练时间和信誉机制的客户端选择算法的有效性

为了验证所提基于预估训练时间和信誉机制的客户端选择算法的有效性,本研究对算法 1、2 进行仿真试验。

使用一个标准卷积神经网络作为联邦学习任务的全局模型。该卷积神经网络具有 6 个卷积层(卷积核大小为 3×3 , 通道数分别为 32、32、64、64、128、128, 每个通道均由 ReLU 激活并批量归一化, 每 2 个通道后有 1 个 2×2 的最大池化)和 3 个全连接层(前两层中 382 和 192 个神经元由 ReLU 激活, 最后一层 10 个神经元由 Softmax 激活)。本研究使用贴近实际应用场景的 Fashion-MNIST 数据集^[30], 包含 60 000 个训练样本和 10 000 个测试样本。

设置 20 个客户端, 进行 10 轮训练, 每轮训练选出 10 个客户端。每个客户端在每轮训练时随机截取不同大小的数据集作为本轮训练的训练集, 得到 20 个客户端在 10 轮训练中不规则变化的实际训练时间, 如图 4 所示。




图 4 客户端实际训练时间分布

Fig.4 The actual training time distribution of each client

当所有客户端都诚实时, 使用实际训练时间竞选本轮客户端, 每个训练轮次 G 的实际训练时间 t_G 如图 5(a)所示。相较于随机选择算法每轮过长的训练时间, 本研究基于预估训练时间的客户端选择算法可以做出每轮的最佳选择, 使每轮训练时间最短。此外, 设置 3 个不诚实的客户端, 它们会在实际训练时间较长的轮次谎报训练时间竞选成为参与者。设置每个客户端的 $R_{ini} = 0.5$, $d = 0.1$, $a = 2$, $R_{max} = 1.0$, 每轮实际训练时间如图 5(b)所示, 客户端的信誉变化如图 5(c)所示。




图 5 实际训练时间对比和信誉变化趋势

Fig.5 Comparison of actual training time and change trend of reputation

基于预估训练时间的客户端选择算法在没有信誉机制时的每轮训练时间与随机选择算法接近, 但是有信誉机制时可以在大部分轮次接近或达到最佳选择。从客户端的信誉变化可以看出, 诚实客户端的信誉稳步增长但不超出信誉上限, 不诚实客户端的信誉在每个不诚实的训练轮次大幅减少, 当客户端信誉小于信誉阈值后将不能再参与训练。

3.2 主副链架构在交易存储优化上的性能

使用一个开源的以太坊交易数据集 Ethereum^[31]验证本研究设计的主副链架构在交易存储上的优化性能。Ethereum 是某以太坊用户在某天 12 h 内的连续交易记录, 共包含 8 个参数和 5 000 条记录。

基于上述试验中的 20 个客户端节点, 选择 7 个客户端作为主链节点, 存储每次交易的全部参数, 剩

余 13 个客户端作为副链节点, 只存储交易的 4 个关键参数(交易时间戳、转出的以太币数量、收到的以太币数量、交易以太币所需的费用)。设置 10 个交易数量(500~5 000, 步长为 500), 将不同交易数量在节点上的存储文件大小作为存储开销。对照试验设置 20 个客户端均作为单链架构的节点。不同交易数量下的存储开销对比如表 1 所示。由表 1 可以看出, 在不同的交易数量下, 副链节点的存储开销仅占主链节点的 47%以下, 主副链架构在总存储开销上占单链架构的 66%以下。由此说明, 为了提高交易验证效率设计的主副链架构并不是用存储空间换取查询时间。在部署主副链架构时, 合理选择存储节点可以实现验证效率和存储开销的共同优化。

表 1 不同交易数量下的存储开销对比
Table 1 Comparison of storage costs under different transaction volumes

交易数量	主链单节点存储开销/MB	副链单节点存储开销/MB	副链单节点存储开销占比/%	单链架构总存储开销/MB	主副链架构总存储开销/MB	主副链架构总存储开销占比/%
500	0.048	0.022	45.83	0.960	0.626	65.21
1 000	0.096	0.045	46.88	1.914	1.247	65.15
1 500	0.143	0.067	46.85	2.868	1.873	65.31
2 000	0.191	0.089	46.60	3.837	2.503	65.23
2 500	0.239	0.111	46.44	4.792	3.127	65.25
3 000	0.287	0.133	46.34	5.733	3.740	65.24
3 500	0.335	0.156	46.57	6.688	4.361	65.21
4 000	0.383	0.178	46.48	7.650	4.990	65.23
4 500	0.430	0.200	46.51	8.606	5.614	65.23
5 000	0.478	0.222	46.44	9.560	6.235	65.22

3.3 基于 DL 方法的区块大小优化算法的性能

本研究使用区块链性能基准数据集 BPD^[28]验证基于 DL 方法的区块大小优化算法的性能。BPD 包含 4 个子数据集 (BPD-1、BPD-2、BPD-3、BPD-4)，共 4 320 个样本，每个数据集包含 4 个参数：交易到达率 V_R 、区块大小 B_S 、延迟 L_A 和吞吐量 H 。使用 KAN 训练区块链性能预测模型，在针对区块链交易延迟的预测任务中，设置 2 个隐藏层（输出维度分别为 64 和 8），使用 Adam 优化器，学习率设置为 0.001，训练数据批大小为 32。使用均方误差作为模型训练的损失函数，将训练轮次设置为 200 轮。为了说明基于 KAN 训练的模型在区块链性能预测任务上的优势和性能，除了文献[28]中基于 MLP 的模型外，还与线性回归 (linear regression, LR)、决策树回归 (decision tree regression, DTR)、贝叶斯岭回归 (Bayes ridge regression, BR) 和随机森林回归 (random forest regression, RFR) 4 种传统机器学习模型进行对比。使用平均绝对误差 E_{MA} 、均方根误差 E_{RMS} 、平均绝对

对百分比误差 E_{MAP} 作为评价指标，计算式分别为

$$E_{MA} = \frac{1}{x} \sum_{i=1}^x |y_i - \hat{y}_i|,$$

$$E_{RMS} = \sqrt{\frac{1}{x} \sum_{i=1}^x (y_i - \hat{y}_i)^2}, \quad (4)$$

$$E_{MAP} = \frac{1}{x} \sum_{i=1}^x \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\%, \quad (5)$$

式中： x 为样本总数； y_i 为第 i 个样本的真实值； $\hat{y}_i$ 为第 i 个样本的预测值。

5 折交叉验证的试验结果如表 2 所示。由表 2 可以看出，在 BPD 数据集上，本研究模型预测误差均优于现有模型，说明本研究使用的区块链性能预测模型可以准确地预测区块链延迟，提高动态优化区块大小的有效性和可行性。

表 2 不同模型在 BPD 数据集上的延迟预测性能
Table 2 The latency prediction performance of different models on BPD dataset

模型	BPD-1			BPD-2			BPD-3			BPD-4		
	E_{MA}	E_{RMS}	E_{MAP}	E_{MA}	E_{RMS}	E_{MAP}	E_{MA}	E_{RMS}	E_{MAP}	E_{MA}	E_{RMS}	E_{MAP}
LR	0.499	0.654	56.55	0.532	0.795	64.53	0.627	0.952	69.73	0.589	0.857	76.35
DTR	0.132	0.214	12.16	0.178	0.276	31.58	0.246	0.385	37.66	0.187	0.346	28.15
BR	0.115	0.247	8.62	0.161	0.312	19.46	0.182	0.388	17.70	0.213	0.326	34.02
RFR	0.152	0.225	15.48	0.179	0.292	31.42	0.252	0.420	39.31	0.204	0.336	33.47
文献[28]模型	0.112	0.199	9.04	0.136	0.256	16.63	0.150	0.289	15.31	0.150	0.278	17.26
本研究模型	0.100	0.188	7.89	0.126	0.246	16.28	0.147	0.279	14.88	0.148	0.276	14.91

设置 20 个交易到达率 (10~200，步长为 10)，通过训练好的延迟预测模型结合区块大小优化算法为每个交易到达率选择最佳区块大小。在 BPD 数据集上，获取每一对交易到达率和优化后的区块大小对应的实际区块链延迟。设置 4 个固定区块大小 (50、100、150、200) 作为对照试验，试验结果如图 6 所示。




图 6 不同区块大小的延迟
Fig.6 The latency of different block sizes

由图 6 可以看出,在同一交易到达率下,区块链经过区块大小优化算法优化后可以达到最低延迟。不同块大小和交易到达率会带来不同的区块链延迟。当 $V_R < 150$ 时, $B_s = 50$ 的区块链延迟比其他固定区块大小的延迟低,但随着 V_R 继续增长, $B_s = 50$ 的区块链延迟又会升高。这说明不会有一个固定的区块大小可以永远保持低延迟。基于 DL 方法的区块大小优化算法可以动态为不同交易到达率匹配最合适的区块大小,使区块链一直保持较低的延迟性能。

4 结论

为了加快 IIoT 设备计算性能异质环境下 FL 的训练效率,本研究提出基于区块链的高效安全 FL 框架。使用基于预估训练时间和信誉的动态客户端选择算法,降低 FL 的每轮训练时间;通过设计基于主副链的区块链架构加快交易验证效率,优化交易存储;设计基于 DL 方法的区块大小动态优化算法,通过使用预测性能更好的模型选择最佳区块大小,有效降低区块链在不同交易到达率下的延迟。试验评估及结果分析证明所提方法的有效性和可行性。本研究方法不仅适用于 IIoT,也适用于其他设备计算性能异质性的应用场景。

本研究工作仍有一些不足之处,例如在客户端竞选时存在通信开销、不同客户端在响应时间及上线时间的异质性问题等。未来将更加深入研究区块链与 FL 的结合,进一步解决现实应用中存在的问题。

参考文献:

- [1] Rahman M A, Hossain M S, Showail A J, et al. AI-enabled IIoT for live smart city event monitoring[J]. IEEE Internet of Things Journal, 2023, 10(4): 2872-2880.
- [2] 曹宇慧, 黄昱泽, 冯北鹏, 等. 基于深度强化学习的物联网服务协同卸载方法[J]. 山东大学学报(工学版), 2024, 54(1): 83-90.
Cao Yuhui, Huang Yuze, Feng Beipeng, et al. A collaborative service offloading approach for Internet of Things based on deep reinforcement learning[J]. Journal of Shandong University (Engineering Science), 2024, 54(1): 83-90.
- [3] Chen B T, Wan J F, Lan Y T, et al. Improving cognitive ability of edge intelligent IIoT through machine learning[J]. IEEE Network, 2019, 33(5): 61-67.
- [4] Yang Q, Liu Y, Chen T J, et al. Federated machine learning: concept and applications[J]. ACM Transactions on Intelligent Systems and Technology, 2019, 10(2): 12.
- [5] 乐俊青, 谭州勇, 张迪, 等. 面向车联网数据持续共享的安全高效联邦学习[J]. 计算机研究与发展, 2024, 61(9): 2199-2212.
Le Junqing, Tan Zhouyong, Zhang Di, et al. Secure and efficient federated learning for continuous IoV data sharing[J]. Journal of Computer Research and Development, 2024, 61(9): 2199-2212.
- [6] 唐晓岚, 梁煜婷, 陈文龙. 面向非独立同分布数据的车联网多阶段联邦学习机制[J]. 计算机研究与发展, 2024, 61(9): 2170-2184.
Tang Xiaolan, Liang Yuting, Chen Wenlong. Multi-stage federated learning mechanism with non-IID data in Internet of Vehicles[J]. Journal of Computer Research and Development, 2024, 61(9): 2170-2184.
- [7] Zhang W, Li X, Ma H, et al. Federated learning for machinery fault diagnosis with dynamic validation and self-supervision[J]. Knowledge-Based Systems, 2021, 213: 106679.
- [8] Liu Y, Yu J J Q, Kang J W, et al. Privacy-preserving traffic flow prediction: a federated learning approach[J]. IEEE Internet of Things Journal, 2020, 7(8): 7751-7763.
- [9] Adnan M, Kalra S, Cresswell J C, et al. Federated learning and differential privacy for medical image analysis[J]. Scientific Reports, 2022, 12(1): 1953.
- [10] Fantauzzo L, Fani E, Caldarola D, et al. FedDrive: generalizing federated learning to semantic segmentation in autonomous driving[C]//2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Kyoto, Japan: IEEE, 2022: 11504-11511.
- [11] Tabassum N, Chow K H, Wang X Y, et al. On the efficiency of privacy attacks in federated learning[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, USA: IEEE, 2024: 4226-4235.
- [12] Sun G, Cong Y, Dong J H, et al. Data poisoning attacks on federated machine learning[J]. IEEE Internet of Things Journal, 2021, 9(13): 11365-11375.
- [13] 张宝晨, 黄月, 孔兰菊, 等. 一种支持自适应联邦学习任务的可信公平区块链框架[J]. 计算机研究与发展, 2023, 60(11): 2504-2519.
Zhang Baochen, Huang Yue, Kong Lanju, et al. A trustworthy and fair blockchain framework supporting adaptive federated learning task[J]. Journal of Computer Research and Development, 2023, 60(11): 2504-2519.
- [14] 施宏建, 马汝辉, 张卫山, 等. 基于区块链辅助的半中心化联邦学习框架[J]. 计算机研究与发展, 2023, 60(11): 2567-2582.
Shi Hongjian, Ma Ruhui, Zhang Weishan, et al. Blockchain-assisted semi-centralized federated learning framework[J]. Journal of Computer Research and Development, 2023, 60(11): 2567-2582.
- [15] Yang Z P, Shi Y M, Zhou Y, et al. Trustworthy federated learning via blockchain[J]. IEEE Internet of Things Journal,

- 2023, 10(1): 92-109.
- [16] Nishio T, Yonetani R. Client selection for federated learning with heterogeneous resources in mobile edge[C]//ICC 2019-2019 IEEE International Conference on Communications (ICC). Shanghai, China: IEEE, 2019: 8761315.
- [17] Ma C, Li J, Shi L, et al. When federated learning meets blockchain: a new distributed learning paradigm[J]. IEEE Computational Intelligence Magazine, 2022, 17(3): 26-33.
- [18] Kang J W, Xiong Z H, Niyato D, et al. Incentive mechanism for reliable federated learning: a joint optimization approach to combining reputation and contract theory[J]. IEEE Internet of Things Journal, 2019, 6(6): 10700-10714.
- [19] Abdulrahman S, Tout H, Mourad A, et al. FedMCCS: multicriteria client selection model for optimal IoT federated learning[J]. IEEE Internet of Things Journal, 2021, 8(6): 4723-4735.
- [20] Wang W L, Wang Y J, Huang Y, et al. Privacy protection federated learning system based on blockchain and edge computing in mobile crowdsourcing[J]. Computer Networks, 2022, 215: 109206.
- [21] Lu Y L, Huang X H, Dai Y Y, et al. Blockchain and federated learning for privacy-preserved data sharing in industrial IoT[J]. IEEE Transactions on Industrial Informatics, 2020, 16(6): 4177-4186.
- [22] Jin X J, Ma C, Luo S, et al. Distributed IIoT anomaly detection scheme based on blockchain and federated learning[J]. Journal of Communications and Networks, 2024, 26(2): 252-262.
- [23] Feng L, Zhao Y Q, Guo S Y, et al. BAFL: a blockchain-based asynchronous federated learning framework[J]. IEEE Transactions on Computers, 2022, 71(5): 1092-1103.
- [24] Gao N J, Huo R, Wang S, et al. Sharding-Hashgraph: a high-performance blockchain-based framework for industrial Internet of Things with Hashgraph mechanism[J]. IEEE Internet of Things Journal, 2022, 9(18): 17070-17079.
- [25] Xu J, Xie Q Y, Peng S, et al. AdaptChain: adaptive scaling blockchain with transaction deduplication[J]. IEEE Transactions on Parallel and Distributed Systems, 2023, 34(6): 1909-1922.
- [26] Li M Z, Wang W, Zhang J. LB-Chain: load-balanced and low-latency blockchain sharding via account migration[J]. IEEE Transactions on Parallel and Distributed Systems, 2023, 34(10): 2797-2810.
- [27] Wang S P, Sun S M, Wang X J, et al. Secure crowdsensing in 5G Internet of Vehicles: when deep reinforcement learning meets blockchain[J]. IEEE Consumer Electronics Magazine, 2021, 10(5): 72-81.
- [28] Wang J S, Zhu C, Miao C, et al. BPR: blockchain-enabled efficient and secure parking reservation framework with block size dynamic adjustment method[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(3): 3555-3570.
- [29] Liu Z M, Wang Y X, Vaidya S, et al. KAN: Kolmogorov-Arnold networks[PP/OL]. V5. (2025-02-09)[2025-06-25]. <https://arxiv.org/abs/2404.19756>
- [30] Xiao H, Rasul K, Vollgraf R. Fashion-MNIST: a novel image dataset for benchmarking machine learning algorithms[PP/OL]. V2. (2017-09-15)[2025-02-20]. <https://arxiv.org/abs/1708.07747>
- [31] Singh I. Ethereum transaction dataset (Raw)[DS/OL]. V2. Kaggle (2024-04-18)[2025-03-10]. <https://www.kaggle.com/datasets/ikjotsingh221/ethereum-transaction-dataset-raw>.