



计算机应用研究
Application Research of Computers
ISSN 1001-3695, CN 51-1196/TP

《计算机应用研究》网络首发论文

题目：异构数据的差分隐私个性化联邦学习方案
作者：侯俊康，郭瑞，张应辉，刘光军
DOI：10.19734/j.issn.1001-3695.2025.09.0411
收稿日期：2025-09-09
网络首发日期：2026-02-26
引用格式：侯俊康，郭瑞，张应辉，刘光军. 异构数据的差分隐私个性化联邦学习方案[J/OL]. 计算机应用研究. <https://doi.org/10.19734/j.issn.1001-3695.2025.09.0411>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

异构数据的差分隐私个性化联邦学习方案*

侯俊康^{1,2†}, 郭瑞^{1,2}, 张应辉^{1,2}, 刘光军³

(1. 西安邮电大学 网络空间安全学院, 西安 710121; 2. 西安邮电大学无线网络安全技术国家工程研究中心, 西安 710121; 3. 西安文理学院 信息工程学院, 西安 710065)

摘要: 针对联邦学习中数据异构性导致性能退化和隐私泄露风险并存的问题, 旨在设计一种既能保护隐私又能适应异构数据的个性化联邦学习方案。提出差分隐私个性化联邦学习框架 DP-PFL, 主要包括: 1) 自适应差分隐私梯度扰动机制, 根据训练进度动态衰减噪声强度, 并按梯度分量重要性差异化分配噪声; 2) 基于元学习的个性化训练策略, 通过优化全局初始化参数和自适应模型混合实现快速本地适应; 3) 多层级隐私防御体系, 结合了贝叶斯不确定性增强、温度缩放和输出噪声注入。理论证明 DP-PFL 满足 (ϵ, δ) -差分隐私约束且保持 $O(1/\sqrt{T})$ 收敛速率。在 MNIST、CIFAR-10 数据集上的实验表明, DP-PFL 在 $\alpha=0.1$ 的高异构场景下分别达到 85.5% 和 74.2% 的准确率; 对成员推断、属性推断和梯度反演攻击的防御成功率分别为 54.6%、51.5% 和 PSNR=6.8dB, 对比基线平均提升 10.2%。DP-PFL 在严格隐私保护约束下实现了异构数据的有效个性化学习, 为联邦学习的安全部署提供了理论支撑和实践指导。

关键词: 差分隐私; 联邦学习; 数据异构性; 成员推断攻击; 个性化学习

中图分类号: TP309 doi: 10.19734/j.issn.1001-3695.2025.09.0411

Differential privacy-based personalized federated learning for heterogeneous data

Hou Junkang^{1,2†}, Guo Rui^{1,2}, Zhang Yinghui^{1,2}, Liu Guangjun³

(1. School of Cyberspace Security, Xi'an University of Posts & Telecommunications, Xi'an 710121, China; 2. National Engineering Research Center for Secured Wireless, Xi'an University of Posts and Telecommunications, Xi'an 710121, China; 3. School of Information Engineering, Xi'an University, Xi'an 710065, China)

Abstract: This study addresses the coexistence of performance degradation and privacy leakage risks caused by data heterogeneity in federated learning, and aims to design a personalized federated learning scheme that both protects privacy and adapts to heterogeneous data. It proposes a differential privacy-based personalized federated learning framework (DP-PFL), which mainly includes three components: 1) An adaptive differential privacy gradient perturbation mechanism that dynamically attenuated noise intensity according to training progress and allocated noise differentially based on the importance of gradient components; 2) A meta-learning-based personalized training strategy that achieved rapid local adaptation by optimizing global initialization parameters and adaptive model mixing; 3) A multi-level privacy defense system that combined Bayesian uncertainty enhancement, temperature scaling, and output noise injection. Theoretical analysis confirms that DP-PFL satisfies the (ϵ, δ) -differential privacy constraint and maintains an $O(1/\sqrt{T})$ convergence rate. Experiments on MNIST and CIFAR-10 datasets show that DP-PFL achieved accuracy rates of 85.5% and 74.2% respectively in the highly heterogeneous scenario with $\alpha=0.1$; its defense success rates against membership inference, attribute inference, and gradient inversion attacks reached 54.6%, 51.5%, and PSNR=6.8dB respectively, representing an average improvement of 10.2% over baselines. DP-PFL realizes effective personalized learning for heterogeneous data under strict privacy protection constraints and provides theoretical support and practical guidance for the secure deployment of federated learning.

Key words: differential privacy; federated learning; data heterogeneity; membership inference attack; personalized learning

0 引言

近年来, 人工智能技术快速发展并广泛赋能各个行业, 显著提升了生产与生活效率。在医疗领域, 人工智能可用于临床诊疗的医学图像分析, 通过可解释的病灶分析为医护人员提供决策支持, 有效助力精准诊疗^[1]。在自然语言处理领

域, 智能语音助手与机器翻译等应用打破语言障碍, 提升了信息传播效率^[2]。在网络安全领域中, 基于人工智能模型的网络入侵检测系统能够实现精准的入侵检测^[3]。自动驾驶领域则通过融合道路、车辆与行人等多源数据推动智能出行^[4]。与此同时, 《通用数据保护条例》(General Data Protection Regulation, GDPR)^[5]等隐私法规的实施与用户隐私意识的提

收稿日期: 2025-09-09; 修回日期: 2025-11-17 基金项目: 国家密码科学基金资助项目(2025NCSF02037); 国家自然科学基金资助项目(62072369); 陕西省重点研发计划基金资助项目(2020ZDLGY08-04); 陕西省创新能力的支持计划基金资助项目(2020KJXX-052); 陕西省自然科学基金一般项目(2024JC-YBMS-545, 2024JC-YBMS-557); 陕西省高校青年创新团队(23JP160); 西安市科技计划项目(23KGDW0018-2023)

作者简介: 侯俊康(2001—), 男(通信作者), 陕西西安人, 硕士研究生, 主要研究方向为联邦学习、差分隐私; 郭瑞(1984—), 男, 河南洛阳人, 副教授, 硕士, 主要研究方向为隐私保护、区块链等; 张应辉(1985—), 男, 陕西西安人, 教授, 博导, 博士, 主要研究方向为云计算安全、区块链和机器学习中的安全与隐私等; 刘光军(1980—), 男, 安徽六安人, 教授, 博士, 主要研究方向为密码学与编码理论、人工智能安全等。

升, 使传统集中式数据训练模式面临日益严峻的合规与安全挑战。

联邦学习(Federated Learning, FL)作为一种分布式学习范式, 允许多方在数据不出本地的条件下协同训练模型, 仅共享模型更新或梯度, 从而在一定程度上缓解数据孤岛与隐私泄露问题^[6]。开创性的 FedAvg 算法^[7]通过迭代聚合客户端本地更新以构建全局模型, 验证了该方法的可行性。然而, 实际部署中仍面临两类核心挑战: 1) 数据异质性导致的性能退化。现实场景下, 客户端数据普遍呈现非独立同分布(Non-Identically and Independently Distributed, Non-IID)特性^[8], 具体表现为特征分布偏移与标签分布不均衡, 易引发客户端漂移与聚合过程中的权重发散, 进而削弱全局模型性能; 2) 隐私推断带来的安全风险。尽管原始数据不被共享, 但是模型更新仍可能泄露敏感信息^[9,10]。

为了应对上述挑战, 已有工作主要从两条路径推进: 其一, 通过个性化联邦学习(Personalized Federated Learning, PFL)为不同客户端构建定制化模型, 有效缓解 Non-IID 带来的适配问题。其二, 差分隐私(Differential Privacy, DP)^[11]在更新中注入经校准的噪声提供形式化隐私保证。然而, 现有研究成果多聚焦于单一维度, 兼顾异质性适配与严格隐私的方案较少。更关键的是, 差分隐私与模型效能间存在固有权衡, 该矛盾在异质分布下尤为突出: 噪声过强会抑制个性化能力, 噪声过弱则难以满足隐私预算约束。

针对以上问题, 文章提出差分隐私个性化联邦学习框架(Differential Privacy Personalized Federated Learning, DP-PFL), 在异质数据场景下实现隐私保护与模型效能的协同优化。主要贡献如下:

- a) 提出了自适应差分隐私机制, 根据本地数据特征与训练进度动态分配隐私预算并调整噪声强度, 在既定隐私预算下最小化效用损失, 相较固定噪声策略更具灵活性与稳定性。
- b) 使用了元学习驱动的个性化策略, 基于模型无关元学习思想优化本地初始化与动态参数, 并结合自适应模型混合, 兼顾全局协作与本地快速适配, 提升对 Non-IID 分布的鲁棒性。
- c) 采用了多层级隐私防御, 将差分隐私与贝叶斯不确定性量化、温度缩放等输出扰动技术结合, 形成针对成员推断、属性推断与梯度反演攻击的综合防线。
- d) 针对 MNIST、CIFAR-10 基准数据集的多种 Non-IID 划分下, DP-PFL 在保持隐私预算可控的前提下取得较高的准确率, 并对成员推断、属性推断与梯度反演攻击展现较强鲁棒性。

1 相关工作

FL^[7]自 2017 年由 McMahan 等人提出以来, 迅速成为解决数据孤岛与隐私保护问题的重要范式。FedAvg 算法通过本地训练与全局聚合的迭代机制, 在不共享原始数据的前提下实现多客户端协同建模, 奠定了联邦学习的基础框架。然而, 随着联邦学习在医疗、金融等高隐私场景中的广泛应用, 其面临的数据异构性和隐私保护等问题日益凸显, 催生了一系列改进方案。

1.1 数据异构性问题

数据异构性是联邦学习面临的核心挑战之一。针对该挑战, 研究者提出了多类改进方案, 具体可分为以下四类:

- a) 算法改进方法。Li 等人^[8]提出的 FedProx 算法通过在本地图标函数中引入近端项, 有效限制了本地模型参数与全局模型的偏离程度, 从而缓解了客户端漂移现象。

Karimireddy 等人^[12]设计的 SCAFFOLD 算法则采用更精细的控制变量机制, 校正了客户端与服务器间的梯度估计偏差, 提升了非独立同分布数据场景下的收敛性能。Wang 等人^[13]提出的 FedNova 算法则聚焦于客户端本地更新步数不一致导致的目标函数错位问题, 通过标准化与重新加权机制保障了聚合过程的公平性。

- b) 数据增强方法。Lin 等人^[14]提出的 FedDF 方法借助知识蒸馏技术, 在服务器端生成合成数据以协调客户端间的知识差异, 通过数据增强手段缓解异构性影响。Yang 等人^[15]提出个性化数据转换机制, 针对不同客户端的数据分布差异, 设计了客户端级别的个性化转换策略。在本地对数据进行预处理, 既保留数据的有效信息以维持模型精度, 又为后续的隐私保护提供基础。

- c) 模型聚合改进方法。Wang 等人^[16]的 FedMA 方法通过在参数空间中进行匹配聚合, 对齐不同客户端模型的神经元以优化聚合效果, 而 Ma 等人^[17]提出的 pFedLA, 服务器端为每个客户端使用专用超级网络, 在层粒度上识别相互贡献因素, 引入参数化机制更新分层聚合权重, 实现模型的精确个性化。该方法可有效利用非 IID 数据客户端的用户间相似性, 对不同层进行差异化聚合, 提升模型在异构数据上的训练性能。

- d) 个性化联邦学习方法。Fallah 等人^[18]提出的 Per-FedAvg 算法基于模型无关元学习(MAML)原理, 通过学习全局最优初始化参数支持快速本地适应, 并在理论上为个性化联邦学习提供了收敛性保证。Dinh 等人^[19]的 pFedMe 算法采用双层优化框架, 分离全局参数与个性化参数, 借助 Moreau 包络技术实现精细化的个性化控制。Collins 等人^[20]提出的 FedRep 算法则从表示学习视角出发, 将模型拆分为共享表示层与个性化分类层, 利用架构设计平衡全局知识共享与本地适应需求。个性化联邦学习的核心思想是为每个客户端定制适配其本地数据分布的模型, 以更好地适应本地数据分布。该方法从根本上解决了单一全局模型无法适配多样化本地分布的异构性瓶颈。

1.2 隐私保护问题

隐私保护问题是联邦学习面临的另一个重要挑战, 隐私攻击与防御机制的研究是联邦学习安全性保障的核心内容。Shokri 等人^[21]首次系统性提出成员推断攻击(MIA), 通过分析模型对特定样本的置信度推断其是否参与训练, 揭示了机器学习模型的隐私泄露风险。Nasr 等人^[22]将该攻击扩展至联邦学习场景, 证实攻击者可通过分析模型更新获取敏感信息。更严峻的是, Zhu^[23]与 Geiping 等人^[24]相继提出的梯度反演攻击, 能够从共享梯度中重构训练数据的近似版本, 这些攻击的成功实施, 凸显了联邦学习对更严格隐私保护技术的迫切需求。

差分隐私技术为联邦学习提供严格的隐私保障, 并在联邦学习领域的应用已得到深入探索。Abadi 等人^[25]提出的 DP-FedAvg 将差分隐私机制引入联邦学习, 通过在梯度中添加校准噪声防止隐私泄露, 为联邦学习的隐私保护奠定了理论基础。Geyer 等人^[26]进一步探索集中式差分隐私在联邦学习中的应用, 提出了 CDP-FL 方法。随着研究深入, 学者们发现固定隐私参数并非最优选择, Andrew 等人^[27]提出的 AdaClip 算法通过自适应调整梯度裁剪阈值优化隐私效用权衡, 可根据梯度实际分布动态调整参数。Kairouz 等人^[28]则使差分隐私与 SCAFFOLD 算法结合, 提出 DP-SCAFFOLD 方法, 在保障隐私的同时提升了收敛性能。

除差分隐私外, 研究者们还探索了其他隐私保护技术。Bonawitz 等人^[29]提出的安全聚合协议通过密码学技术确保服务器仅能获取聚合后的模型更新, 无法访问单个客户端的参数, 在协议层面提供隐私保护。Aono 等人^[30]将同态加密技术应用于联邦学习, 支持在加密状态下进行模型聚合计算, 虽然能提供强隐私保证, 但是存在计算开销较大的问题。

文章方案相对于已有工作的优势主要如下:

a) 自适应隐私机制的创新性: 对比固定噪声策略, DP-PFL 可以根据客户端数据分布特征和训练进度动态调整裁剪阈值和噪声水平, 在相同隐私预算下准确率提升。

b) 个性化与隐私保护的协同优化: 现有较多个性化方法缺乏隐私保护, 而隐私保护方法忽略个性化需求。DP-PFL 将元学习驱动的个性化策略与自适应差分隐私深度融合, 通过 MAML 优化全局初始化参数, 结合自适应模型混合, 在保障差分隐私的同时实现快速本地适应, 相比单一策略方法收敛速度提升。

c) 多层级防御体系的全面性: 单一攻击面的防御, 会缺乏系统性保护。DP-PFL 构建“梯度扰动-输出模糊-不确定性增强”的多层防御体系, 针对梯度反演、成员推断、属性推断等不同攻击面部署差异化防御机制, 相比单点防御方法攻击成功率降低。

d) 理论保证的完备性: DP-PFL 不仅满足差分隐私保证, 还在 Non-IID 条件下进行了收敛性分析, 为方案的理论可靠性提供了严格支撑。

2 基础知识

2.1 联邦学习设置与挑战

考虑由 K 个客户端构成的联邦学习系统, 其中每个客户端 k 持有本地数据集 $D_k = \{(x_i, y_i)\}_{i=1}^{n_k}$ 。传统联邦学习的核心目标是最小化全局经验风险, 其表达式如下:

$$F(\theta) = \sum_{k=1}^K \left(\frac{n_k}{n} \right) F_k(\theta), \quad (1)$$

其中, n_k 表示客户端 k 持有的本地数据集样本数量。

$n = \sum_{k=1}^K n_k$, $F_k(\theta) = \frac{1}{n_k} \sum_{i=1}^{n_k} l(\theta; x_i, y_i)$ 代表客户端 k 的本地损失函数。然而, 该方法在实际应用中面临两个关键挑战。

挑战 1: 数据异构性问题。不同客户端数据集分布存在显著差异, 导致单一全局模型难以良好适配所有客户端的本地数据特征。文中采用 Dirichlet 分布参数对异构性程度进行量化^[31], 其中异构值 α_k 越小, 表明数据异构性越高。

挑战 2: 隐私泄露风险。即便不直接共享原始数据, 联邦学习依然面临多种隐私攻击。比如: 成员推断攻击 (Membership Inference Attack, MIA) 通过分析模型输出推断特定样本是否参与训练。属性推断攻击 (Attribute Inference Attack, AIA) 可以从模型更新中提取敏感属性信息。梯度反演攻击 (Gradient Inversion Attack, GIA) 可以重构训练样本。

2.2 个性化联邦学习

为解决数据异质性问题, 个性化联邦学习可以为每个客户端学习适配其本地数据分布的定制化模型。主流的个性化策略包括:

a) 模型混合策略: 通过融合全局知识与本地特征实现个性化, 其数学表达式如下:

$$\theta_k^{\text{pers}} = \lambda_k \theta^{\text{global}} + (1 - \lambda_k) \theta_k^{\text{local}}, \quad (2)$$

其中, θ_k^{pers} 是客户端 k 的个性化模型参数, θ^{global} 是全局模型参数, θ_k^{local} 为客户端 k 的本地模型参数, λ_k 为自适应混合系

数, 用于平衡模型的全局一致性与本地适应性。

b) 元学习策略: 通过学习优质的全局初始化参数, 使每个客户端能够快速完成本地适配, 其优化目标为

$$\min_{\theta} \sum_{k=1}^K E_{D_k} [F_k(\theta - \alpha_{\text{meta}} \nabla F_k(\theta))], \quad (3)$$

F_k 为客户端 k 的本地损失函数, α_{meta} 为元学习率, $(\theta - \alpha_{\text{meta}} \nabla F_k(\theta))$ 表示客户端 k 基于全局参数 θ 的一步本地更新。该策略基于模型无关元学习 (Model-Agnostic Meta-Learning, MAML) 思想, 可通过少量本地更新步骤快速实现模型个性化。

2.3 差分隐私保护

定义 1 (ϵ, δ)-差分隐私。对于随机算法 M , 若对任意相邻数据集 D 和 D' , 以及任意输出集合 S , 均满足:

$$\Pr[M(D) \in S] \leq e^{\epsilon} \cdot \Pr[M(D') \in S] + \delta, \quad (4)$$

则称算法 M 满足 (ϵ, δ)-差分隐私。其中, ϵ 为隐私预算, 用于控制隐私保护强度, δ 表示隐私保护失败的概率。

在联邦学习中, 差分隐私通常通过梯度扰动方式实现, 具体如下:

$$\tilde{g}_k = \text{Clip}(g_k, C) + N(0, \sigma^2 \mathbf{I}), \quad (5)$$

其中, $\tilde{g}_k$ 表示添加差分隐私噪声后的梯度,

$\text{Clip}(g_k, C) = g_k \cdot \min(1, \frac{C}{\|g_k\|_2})$ 是裁剪梯度, 用于保证梯度敏感度的有界性, $N(0, \sigma^2 \mathbf{I})$ 是均值为 0、方差为 σ^2 的高斯噪声,

σ^2 的值根据隐私预算确定 $\sigma^2 = \frac{2C^2 \ln(\frac{1.25}{\delta})}{\epsilon^2}$ 。

2.4 安全威胁模型

文章采用“诚实但好奇” (Honest-but-Curious) 威胁模型, 以模拟联邦学习实际部署中的隐私风险。该模型假设服务器作为聚合中心严格遵守训练协议, 但可能通过分析中间参数 (如梯度更新或模型输出) 推断客户端敏感信息。攻击者知悉 DP-PFL 算法逻辑、超参数, 但无法直接访问原始本地数据。攻击目标包括窃取训练数据成员关系、敏感属性或重构原始样本。主要攻击面涵盖三类:

a) 成员推断攻击 (MIA): 攻击者通过分析模型对特定样本的输出置信度, 推断该样本是否参与训练。

b) 属性推断攻击 (AIA): 攻击者从模型更新中提取训练数据的敏感属性, 即使属性未直接暴露于标签中。

c) 梯度反演攻击 (GIA): 攻击者通过共享的梯度信息, 利用优化算法重构训练样本的近似版本, 导致原始数据泄露。

防御目标是确保个体样本信息不泄露, 同时满足 (ϵ, δ)-差分隐私约束。

3 DP-PFL 方案设计

为解决联邦学习中数据异构性导致的性能退化与隐私泄露风险问题, 本节提出差分隐私个性化联邦学习框架 (DP-PFL)。该框架通过自适应隐私控制、元学习驱动的个性化与多层防御机制的协同, 在保障严格隐私约束的同时, 实现异构数据下的模型性能优化。以下从系统框架、核心机制与算法流程三个层面阐述方案设计。

3.1 DP-PFL 框架

DP-PFL 框架旨在解决联邦学习中的两个核心挑战: 数据异构性导致的性能退化和隐私泄露风险。DP-PFL 框架从系统设计的角度出发, 通过四个核心组件协同实现对隐私保护、个性化适应和模型效用的优化。

如图 1 所示, DP-PFL 框架的整体架构主要包括四个关键组件, 每个组件承担特定功能, 同时通过信息交互与参数协调实现协同。




图 1 DP-PFL 模型框架

Fig. 1 The framework of DP-PFL model

自适应差分隐私模块: 作为隐私保护的核心, 该模块根据客户端数据分布特性动态调整梯度裁剪阈值与噪声注入策略, 解决固定隐私参数在异构场景下过度牺牲性能或隐私保护不足的问题。

元学习个性化模块: 针对异构数据导致全局模型适配性差的问题, 利用模型无关元学习优化全局初始化参数, 并结合自适应模型混合技术, 使每个客户端能快速生成适配本地数据的个性化模型。

输出扰动防御模块: 为抵御成员推断、梯度反演等多维度隐私攻击, 在梯度层、输出层分别部署差异化防御机制, 形成噪声扰动与不确定性增强的协同防御体系。

隐私预算管理模块: 负责在时间维度与客户端维度动态分配总隐私预算, 确保全局训练过程满足预设的隐私约束, 同时最大化模型效用。

3.1.1 自适应差分隐私机制

传统差分隐私采用固定梯度裁剪阈值与噪声水平实现隐私保护, 但在数据异构场景下存在显著局限性。对高异构性客户端, 固定裁剪易过度丢失关键梯度, 导致模型性能下降; 对低异构性客户端, 固定噪声会引入不必要的扰动, 进而浪费隐私预算。通过分析该问题, 文章设计异构性感知的自适应隐私机制, 可以动态调整裁剪阈值、噪声水平与噪声分配策略, 实现隐私与效用的精准平衡。

梯度裁剪的核心目的是控制梯度敏感度, 为差分隐私提供基础。DP-PFL 根据客户端数据异构性动态调整裁剪阈值, 公式如下:

$$C_k^i = \max(C_{\min}, C_{\text{base}} \cdot (1 + \beta(1 - \alpha_k))), \quad (6)$$

其中, C_{base} 为基础裁剪阈值, β 为适应因子, α_k 为客户端 k

的异构性度量, $C_{\min}$ 为裁剪阈值下界, 防止因 α_k 过大导致裁剪阈值为负数。当客户端 k 的数据分布异构性较高时, α_k 较小, 系统会增大裁剪阈值, 从而保留更多的梯度信息来支持个性化学习。相反, 对于数据分布相对均匀的客户端, 系统会采用较小的裁剪阈值来增强隐私保护。自适应裁剪阈值仅依赖客户端标签分布的统计量, 该统计量通过安全聚合协议^[29]上传, 不暴露原始样本信息, 因此裁剪调整过程满足差分隐私的后处理不变性。参数 β 的引入使调整具备可控性, 避免参数变化过度激进。

在联邦学习的不同阶段, 模型对噪声的敏感性不同。训练初期, 模型参数变化较大, 适量的噪声不会显著影响收敛方向; 而在训练后期, 模型趋于稳定, 过多的噪声可能会破坏已经形成的良好参数配置。基于此, 本节设计了考虑训练进度和数据规模的动态噪声调整策略:

噪声水平根据训练进度和数据规模进行自适应调整, 公式如下:

$$\sigma_k^t = \sigma_{\text{base}} \cdot \sqrt{\frac{n_{\text{total}}}{n_k}} \cdot \exp(-\gamma \frac{t}{T}), \quad (7)$$

其中, σ_{base} 是基础噪声水平, n_k 为客户端 k 的样本量, n_{total} 为总样本数, γ 为衰减率, 控制噪声随训练的衰减速度。 t 为当前轮次, T 为总轮次。第一个调整因子 $\sqrt{\frac{n_{\text{total}}}{n_k}}$ 是对数据规模模差的补偿, 确保数据量较小的客户端获得更强的隐私保护。第二个调整因子 $\exp(-\gamma \frac{t}{T})$ 实现对噪声水平的时序衰减, 使得系统能够在训练后期减少噪声干扰, 提高模型的最终性能。

对所有梯度分量添加相同噪声, 可能破坏关键特征的梯度信息。不同于对所有梯度分量添加相同噪声的方式, 文章根据梯度分量的重要性进行加权注入。梯度向量 $\mathbf{g}_k = [\mathbf{g}_{k,1}, \mathbf{g}_{k,2}, \dots, \mathbf{g}_{k,m}]$, 对于梯度第 j 个分量 $\mathbf{g}_{k,j}$, 其重要性分数定义为

$$I_j = \frac{|\mathbf{g}_{k,j}|}{\max_i |\mathbf{g}_{k,i}|}. \quad (8)$$

根据重要性分数动态调整噪声标准差, 调整后的噪声标准差为

$$\sigma_{k,j}^t = \sigma_k^t (1 - \tau \cdot \min(I_j, \tau_{\max})), \quad (9)$$

其中, τ 为重要性调整强度, $\tau_{\max}$ 为重要性上界。对重要的梯度分量添加较少噪声, 以保护关键信息免受过度干扰。例如: 取 $\tau = 0.3$, $\tau_{\max} = 0.8$, 那么 $\sigma_{k,j}^t = \sigma_k^t \times (1 - 0.3 \times 0.7) \approx 0.79 \sigma_k^t$, 重要梯度 ($I_j \geq 0.7$) 的噪声水平降低 21%, 次要梯度 ($0.3 \leq I_j < 0.7$), 噪声基本不变。不重要梯度 ($I_j < 0.3$) 噪声增加, 实现了对关键梯度的精准噪声控制。

3.1.2 MAML 初始化与自适应模型混合

联邦学习通常采用简单的参数平均来更新全局模型, 在数据异构性较高时易导致全局模型偏离各个客户端的最优解。文章先利用模型无关元学习方法^[18]对全局模型初始化参数进行优化, 按照式(3)寻找一个全局参数 θ , 使得每个客户端都能够通过少量的梯度更新步骤 ($\theta - \alpha_{\text{meta}} \nabla F_k(\theta)$) 快速适应其本地数据分布。与传统的参数平均不同, 该优化目标考虑了本地适应的效果, 故能够产生个性化效果更好的全局初始化。

客户端在 MAML 初始化基础上完成本地训练后, 需进一步融合全局模型与本地模型的优势(全局模型保证协同性,

本地模型保证适配性)。DP-PFL 通过动态混合系数 λ_k 实现这一目标, 每个客户端维护个性化模型, 该模型通过融合全局模型与本地模型得到 $\theta_k^{pers} = \lambda_k \theta_k^{global} + (1 - \lambda_k) \theta_k^{local}$, 混合系数 λ_k 根据本地模型性能进行自适应调整:

$$\lambda_k = \lambda_{base} + (1 - \alpha_k) \cdot \lambda_{max} \cdot \text{sigmoid}(\Delta \mathcal{L}_k), \quad (10)$$

其中, λ_{base} 为基础混合系数, λ_{max} 为最大调整幅度, $\Delta \mathcal{L}_k$ 为客户端 k 本地模型相对于全局模型的性能改进量。sigmoid 激活函数用于将 $\Delta \mathcal{L}_k$ 映射为性能改进权重。异构性较高的客户端更依赖本地模型, 本地模型性能更优的客户端, 其本地模型在混合中的权重相应增加。

文章提出“元学习初始化+自适应混合”的联邦学习策略。在全局阶段, 服务器端采用 MAML 目标优化全局模型初始化, 使其具备良好的快速适应能力。在本地阶段, 各客户端以全局初始化为起点, 本地微调获得个性化参数。最终输出采用自适应混合策略, 根据客户端异构性和本地性能反馈动态确定混合系数, 实现最优个性化模型输出。

3.1.3 多层防御系统

如 3.1.1 节所述, 在梯度层防御使用自适应裁剪与噪声注入, 理论上可以降低梯度反演攻击的成功率。然而, 仅在梯度层面施加差分隐私保护通常难以抵御复杂的隐私攻击, 尤其是当攻击者能够观察到模型的多轮输出时。DP-PFL 构建“梯度扰动-输出模糊-不确定性增强”的多层防御体系 (Multi-Layer Defense, MLD), 针对不同攻击面部署差异化防御机制。

成员推断攻击能够分析模型对样本的输出置信度来推断成员关系。DP-PFL 采用以下机制模糊差异:

a) 贝叶斯不确定性增强。将确定性模型转换为贝叶斯模型, 以增加输出的不确定性。采用变分参数替换最后一层权重, 即 $\mathbf{W} \sim \mathcal{N}(\mu_{\mathbf{W}}, \sigma_{\mathbf{W}}^2 \mathbf{I})$, 推理过程中进行蒙特卡罗采样生成输出分布, 即 $p(y|x) = \frac{1}{S} \sum_{s=1}^S p(y|x, \mathbf{W}^{(s)})$ 。引入贝叶斯神经网络的设计思想, 能够为模型的输出增加内在的不确定性。具体而言, 在模型的关键层中引入可学习的不确定性参数, 使得模型的输出不再是确定性的点估计, 而是带有不确定性的分布估计。通过增加输出的随机性, 使攻击者难以区分样本是否为训练成员, 从而增加了攻击者从模型输出中提取确定信息的难度。

b) 温度缩放。对模型输出的 logits 施加温度缩放, 平滑置信度分布:

$$p_i = \frac{\exp(\frac{z_i}{\tau_t})}{\sum_j \exp(\frac{z_j}{\tau_t})}, \quad (11)$$

其中 τ_t 为温度参数, 仅用于输出层置信度平滑, 与 3.2.3 节的重要性调整强度 τ 无关, $\tau_t = 1 + \frac{\max(\mathbf{z}) - \min(\mathbf{z})}{10}$, 可以动态调整。例如, $\tau_t = 2$ 时, 输出分布的方差从 2.5 降至 1.2, 减少过拟合导致的“置信度峰值”。

c) 输出噪声注入。在最终预测结果中添加校准噪声 $\hat{\mathbf{y}} = \mathbf{y} + \mathbf{N}(0, \sigma_{output}^2 \mathbf{I})$, 噪声水平 σ_{output} 根据剩余隐私预算动态调整, 当预算充足时增大, 确保防御强度。

为了更直观地展示 MLD 的防御体系, 表 1 列出了多层防御系统的攻击面与防御机制对应关系。

该表按“攻击面、攻击方式、暴露信息、单防御缺陷、MLD 对策”五列分类。针对“梯度、输出、logits”三个关键

攻击面, 分别部署差异化防御机制, 通过梯度层隐私增强与输出层不确定性提升的协同策略, 形成多方位隐私保护, 有效抵御梯度反演、成员推断等典型攻击。

表 1 多层防御对不同攻击的对策

攻击面	攻击方式	暴露信息	单防御缺陷	MLD 对策
梯度	梯度反演	敏感标签	噪声太大 精度下降	差分隐私与 重要性加权
输出	成员推断	置信度峰值	单点平滑 仍可利用	贝叶斯与 温度缩放
Logits	黑盒 MIA	最大 logit 间距	加噪太小 防御无效	输出校准噪声

3.1.4 隐私预算模块

差分隐私的核心是通过隐私预算 (ϵ, δ) 量化保护强度, 预算分配直接影响隐私-效用权衡。DP-PFL 设计时间-客户端二维动态分配策略, 确保总预算高效利用。

a) 时间维度分配。训练初期模型参数波动大, 需要更多预算支出梯度探索; 后期模型趋于稳定, 可以减少隐私预算。采用二次递减策略分配各轮次预算:

$$\epsilon_t = \epsilon_{total} \cdot \frac{2t-1}{T^2}. \quad (12)$$

第 1 轮分配 $\epsilon_1 = \frac{\epsilon_{total}}{T^2}$, 第 T 轮分配 $\epsilon_T = \epsilon_{total} \cdot \frac{2T-1}{T^2}$, 累

计预算总和为 ϵ_{total} 。

b) 客户端维度分配。依据数据量和异构性, 不同客户端的隐私风险与模型贡献差异显著, 预算需向数据量小且异构性高的客户端倾斜, 这类客户端更易泄露隐私且需要更多梯度信息。具体分配公式如下:

$$\epsilon_k^t = \epsilon_t \cdot \frac{n_k}{\sum_{j \in S_t} n_j} \cdot \frac{2 - \alpha_k}{\sum_{j \in S_t} (2 - \alpha_j)}, \quad (13)$$

其中, S_t 为轮次 t 中参与训练的客户端集合。异构性较高的客户端需要更多隐私预算以保障数据安全。数据量占比

$(\frac{n_k}{\sum_{j \in S_t} n_j})$ 中样本量小的客户端获得更高比例。异构性补偿

$(\frac{2 - \alpha_k}{\sum_{j \in S_t} (2 - \alpha_j)})$ 可以确保 α_k 小的高异构客户端获得更多预算。

3.2 算法流程

DP-PFL 算法采用“服务器全局协同-客户端本地优化”的分布式架构, 通过差分隐私机制实现隐私保护, 同时引入元学习与自适应策略提升模型个性化能力。算法核心在于将全局训练任务拆解为服务器端的全局模型聚合与隐私预算管控, 以及客户端的本地训练与个性化优化两大模块, 通过闭环交互实现隐私保护、模型性能和个性化需求的平衡。本节将详细阐述服务器端与客户端的具体算法流程。

3.2.1 服务器端算法

服务器端算法主要负责全局模型的迭代更新、隐私预算的动态分配以及客户端训练过程的协同管控。其核心功能是在满足总隐私预算约束的前提下, 通过加权聚合客户端上传的模型更新, 生成兼顾全局一致性与隐私安全性的全局模型。具体流程如下:

算法 1 DP-PFL 服务器端全局协同算法

输入: 客户端总集合 $\{1, 2, \dots, K\}$; 总隐私预算 $(\epsilon_{total}, \delta_{total})$; 最大通信轮

次 T ; 客户端本地迭代次数 E ; 基础裁剪阈值 C_{base} ; 基础噪声水平 σ_{base} ; 元学习率 α_{meta} 。

输出: 最终全局模型参数 θ^T ; 剩余隐私预算 ε_{remain} ; 各轮次隐私预算消耗记录。

1) 初始化阶段 ($t=0$):

- (a) 随机初始化全局模型参数 θ^0 , 通过安全传输分发至所有客户端;
- (b) 初始化剩余隐私预算 $\varepsilon_{remain} = \varepsilon_{total}$, 剩余隐私失败概率 $\delta_{remain} = \delta_{total}$;
- (c) 初始化客户端数据量记录表, 存储各客户端历史样本量 n_k // 初始为 0, 首轮训练后更新。

2) 迭代训练阶段 ($t=1, 2, \dots, T$):

(a) 客户端选择与预算分配:

① 从 K 个客户端中随机选取 30% 组成参与集合 $S_t \subseteq \{1, 2, \dots, K\}$;

② 按时间维度二次递减策略计算本轮预算: $\varepsilon_t = \varepsilon_{total} \cdot \frac{2t-1}{T^2}$

③ 向 S_t 中所有客户端分发 θ^{t-1} 与 ε_t , 同步元学习参数 α_{meta} 。

(b) 模型更新接收与聚合:

① 接收客户端 $k \in S_t$ 上传的模型更新 $\Delta\theta_k^t = \theta_k^{pers,t} - \theta^{t-1}$;

② 按客户端数据量加权聚合全局模型:

$$\theta^t = \theta^{t-1} + \sum_{k \in S_t} \left(\frac{n_k}{\sum_{j \in S_t} n_j} \right) \cdot \Delta\theta_k^t$$

(c) 隐私预算与终止判断:

① 更新剩余预算: $\varepsilon_{remain} = \varepsilon_{remain} - \varepsilon_t$, $\delta_{remain} = \delta_{remain} - \frac{\delta_{total}}{T}$;

② 若 $\varepsilon_{remain} \leq 0$ 或 $t=T$, 输出 θ^T 并终止; 否则进入 $t+1$ 轮迭代。

3.2.2 客户端本地训练算法

客户端算法聚焦于本地数据的隐私保护与个性化模型训练, 通过自适应隐私参数调整、梯度扰动以及元学习优化, 在满足本地隐私约束的同时, 生成既能适配本地数据特性又能与全局模型协同的个性化模型。具体算法如下:

算法 2 DP-PFL 客户端本地训练算法

输入: 客户端 k 的本地数据集 $D_k = \{(x_i, y_i)\}_{i=1}^{n_k}$; 服务器分发的 θ^{t-1} 与 ε_t ; 学习率 η ; 裁剪阈值下界 C_{min} ; 噪声衰减率 γ ; 个性化混合系数基础值 λ_{base} 。

输出: 客户端 k 的模型更新 $\Delta\theta_k^t$; 本地数据异构性度量 α_k 。// 用于服务器下一轮预算分配。

1) 本地预处理阶段:

(a) 计算异构性: 基于 D_k 标签分布拟合 Dirichlet 分布, 得到 α_k ; // α_k 越小, 异构性越高;

(b) 分配本地预算:

$$\varepsilon_k^t = \varepsilon_t \cdot \left(\frac{n_k}{\sum_{j \in S_t} n_j} \right) \cdot \left(\frac{2 - \alpha_k}{\sum_{j \in S_t} (2 - \alpha_j)} \right)$$

(c) 自适应设置隐私参数:

① 裁剪阈值: $C_k^t = \max(C_{min}, C_{base} \cdot (1 + \beta(1 - \alpha_k)))$;

② 噪声水平: $\sigma_k^t = \sigma_{base} \cdot \sqrt{\frac{n_{total}}{n_k}} \cdot \exp\left(-\gamma \cdot \frac{t}{T}\right)$;

2) 本地训练与个性化阶段 ($e=1, 2, \dots, E$):

(a) 初始化本地模型: $\theta_{k,0}^e = \theta^{t-1}$;

(b) 批量训练与梯度处理:

① 采样批量数据 $B \subseteq D_k$, 计算梯度: $g = \nabla_{\theta} L(\theta_{k,e-1}^e, B)$;

② 梯度裁剪: $g' = g \cdot \min\left(1, \frac{C_k^t}{\|g\|_2}\right)$;

③ 重要性加权噪声注入:

- 计算梯度分量重要性: $I_j = \frac{|g_{k,j}|}{\max_i |g_{k,i}|}$;

- 调整噪声标准差: $\sigma_{k,j}^t = \sigma_k^t \cdot (1 - \tau \cdot \min(I_j, \tau_{max}))$;

- 添加高斯噪声: $g'' = g' + \sum_j \mathcal{N}(0, (\sigma_{k,j}^t)^2)$;

④ 更新本地模型: $\theta_{k,e}^t = \theta_{k,e-1}^t - \eta \cdot g''$

(c) 元学习个性化优化:

① 元更新: $\theta_{k,meta}^t = \theta_{k,E}^t - \alpha_{meta} \cdot \nabla F_k(\theta_{k,E}^t)$;

② 自适应混合生成个性化模型:

$$\lambda_k = \lambda_{base} + (1 - \alpha_k) \cdot \lambda_{max} \cdot \text{sigmoid}(\Delta L_k);$$

$$\theta_k^{pers,t} = \lambda_k \cdot \theta^{t-1} + (1 - \lambda_k) \cdot \theta_{k,meta}^t;$$

3) 输出层防御与更新上传:

(a) 输出层处理: 对 $\theta_k^{pers,t}$ 的 logits 施加温度缩放

$$\tau_t = 1 + \frac{\max(z) - \min(z)}{10} \text{ 与噪声注入 } \hat{y} = y + \mathcal{N}(0, \sigma_{output}^2 I);$$

(b) 计算并上传 $\Delta\theta_k^t = \theta_k^{pers,t} - \theta^{t-1}$, 同步 α_k 至服务器。

3.3 算法性能分析

3.3.1 算法复杂度分析

针对文章 DP-PFL 的算法复杂度按服务器端与客户端双层架构拆解, 核心操作时间复杂度如下:

服务器端每轮迭代核心为客户端选择与模型聚合。客户端选择从 K 个客户端中随机选取 30% ($|S_t| = 0.3K$), 复杂度 $O(K)$; 模型聚合对 $|S_t|$ 个客户端的 d 维模型更新加权求和, 复杂度 $O(|S_t| \cdot d)$ 。 T 轮总复杂度为 $O(T \cdot (K + |S_t| \cdot d))$, 因 $K \ll |S_t| \cdot d$, 实际可简化为 $O(T \cdot |S_t| \cdot d)$, 支持大规模客户端场景。

客户端的本地训练为主要时间开销, 每轮本地迭代(共 E 轮)包括: 批量梯度计算(复杂度 $O(b \cdot d)$, b 为批量大小 16)、梯度裁剪与噪声注入 ($O(d)$)、模型更新 ($O(d)$), 单客户端 E 轮本地训练复杂度为 $O(E \cdot b \cdot d)$; 元学习个性化与输出防御操作复杂度均为 $O(d)$ 。单客户端总复杂度为 $O(n_k + E \cdot b \cdot d)$, n_k 为本地样本量, 多客户端并行时整体复杂度无额外增加, 适合边缘终端设备部署。

3.3.2 隐私分析

定理 1 单轮 $(\varepsilon_t, \delta_t)$ -差分隐私。DP-PFL 算法的单轮训练满足 $(\varepsilon_t, \delta_t)$ -差分隐私, 其中隐私参数为

$$\varepsilon_t = \sqrt{2 \ln\left(\frac{1.25}{\delta_t}\right)} \cdot \frac{\sigma_k^t}{C_k^t} + \frac{\sigma_k^t}{(C_k^t)^2} \cdot \ln\left(\frac{1}{\delta_t}\right). \quad (14)$$

证明 1) 客户端 k 的梯度裁剪操作定义为:

$\text{Clip}(g_k, C_k^t) = g_k \cdot \min\left(1, \frac{C_k^t}{\|g_k\|_2}\right)$, 根据裁剪规则, 裁剪后梯度的 L_2 范数满足: $\|\text{Clip}(g_k, C_k^t)\|_2 \leq C_k^t$ 。因此, 对于任意两个相邻数据集 D_k 和 D'_k , 仅相差一个样本。梯度的敏感度为:

$$\Delta g = \|\text{Clip}(g_k, C_k^t) - \text{Clip}(g_{k'}, C_k^t)\|_2 \leq C_k^t.$$

2) 本框架采用高斯机制实现 (ε, δ) -差分隐私。裁剪后的梯度添加高斯噪声: $g_{k'} = \text{Clip}(g_k, C_k^t) + \mathcal{N}(0, (\sigma_k^t \cdot C_k^t)^2 I)$ 。根据高斯机制的差分隐私理论, 若噪声标准差 σ 满足:

$$\sigma \geq \frac{\Delta g \cdot \sqrt{2 \ln(1.25/\delta)}}{\varepsilon}, \text{ 则该机制满足 } (\varepsilon, \delta)\text{-差分隐私}.$$

3) 将 $\Delta g = C_k^t$ 和 $\sigma = \sigma_k^t \cdot C_k^t$ 代入上述不等式, 整理得:

$$\varepsilon_t = \sqrt{2 \ln\left(\frac{1.25}{\delta_t}\right)} \cdot \frac{\sigma_k^t}{C_k^t} + \frac{\sigma_k^t}{(C_k^t)^2} \cdot \ln\left(\frac{1}{\delta_t}\right), \text{ 因此, 单轮训练满足 } (\varepsilon_t, \delta_t)\text{-差分隐私, 证毕}.$$

定理 2 T 轮 $(\varepsilon_{total}, \delta_{total})$ -差分隐私。 T 轮训练后, DP-PFL 满足 $(\varepsilon_{total}, \delta_{total})$ -差分隐私, 其中:

$$\varepsilon_{total} = \sqrt{2T \ln\left(\frac{1}{\delta_{total}}\right) \cdot \max_t \frac{\sigma_k^t}{\min_t C_k^t}} + T \cdot \max_t \frac{\sigma_k^t}{(\min_t C_k^t)^2} \cdot \ln\left(\frac{1}{\delta_{total}}\right) \quad (15)$$

证明 a) 对于 T 个独立的 $(\varepsilon_t, \delta_t)$ -差分隐私机制, 高级组合定理指出总隐私满足: $\varepsilon_{total} \leq \sum_{t=1}^T \varepsilon_t + \sqrt{2 \sum_{t=1}^T \varepsilon_t^2 \cdot \ln\left(\frac{1}{\delta_{total}}\right)}$, 其中

$$\delta_{total} \geq \sum_{t=1}^T \delta_t.$$

b) 代入单轮 ε_t 表达式, 总隐私预算的线性项为:

$$\sum_{t=1}^T \varepsilon_t \leq T \cdot \max_t \left[\sqrt{2 \ln\left(\frac{1.25}{\delta_t}\right) \cdot \frac{\sigma_k^t}{C_k^t}} + \frac{\sigma_k^t}{(C_k^t)^2} \cdot \ln\left(\frac{1}{\delta_t}\right) \right]. \text{ 取 } \delta_t = \frac{\delta_{total}}{T},$$

$$\text{简化得: } \sum_{t=1}^T \varepsilon_t \leq T \cdot \max_t \frac{\sigma_k^t}{(C_k^t)^2} \cdot \ln\left(\frac{\delta_{total}}{T}\right).$$

c) 二次项部分满足: $\sum_{t=1}^T \varepsilon_t^2 \leq T \cdot \max_t \left(\frac{\sigma_k^t}{C_k^t} \right)^2 \cdot 2 \ln\left(\frac{1.25}{\delta_t}\right)$, 代

$$\text{入平方根项并化简: } \sqrt{2 \sum_{t=1}^T \varepsilon_t^2 \cdot \ln\left(\frac{1}{\delta_{total}}\right)} \leq \sqrt{2T \ln\left(\frac{1}{\delta_{total}}\right) \cdot \max_t \frac{\sigma_k^t}{C_k^t}}.$$

d) 合并线性项和二次项, 得到训练的总隐私参数:

$$\varepsilon_{total} = \sqrt{2T \ln\left(\frac{1}{\delta_{total}}\right) \cdot \max_t \frac{\sigma_k^t}{\min_t C_k^t}} + T \cdot \max_t \frac{\sigma_k^t}{(\min_t C_k^t)^2} \cdot \ln\left(\frac{1}{\delta_{total}}\right),$$

证毕。

定理 3 自适应隐私保证。DP-PFL 中的自适应参数调整 (C_k, σ_k) 不违反差分隐私保证。

证明 a) 在 DP-PFL 方案设计中, 自适应参数 C_k^t 和 σ_k^t 仅依赖公开的全局参数 $(C_{base}, \sigma_{base}, T)$ 与客户端数据的统计特征 $(\alpha_k$ 基于标签分布, 与具体样本无关), 调整过程为确定性操作, 不引入额外随机性。

b) 通过 C_{min} 设置确保裁剪阈值始终为正, 且噪声水平 $\sigma_k^t \geq \sigma_{base} \cdot \exp(-\gamma)$ (因 $t \leq T$), 满足隐私保护的最低要求。

c) 差分隐私机制对后处理操作具有不变性, 而自适应参数调整可视为基于公开信息的后处理, 因此不改变原机制的隐私保证。

综上, 该自适应机制兼容差分隐私, 证毕。

3.4 收敛性分析

3.4.1 数学假设与符号定义

为了进行严格的收敛性分析, 首先建立必要的数学假设和符号定义, 符号定义如下表 2。

基础假设:

假设 A1 L -平滑性。对所有客户端 k 和参数 θ, θ' , 损失函数 F_k 满足:

$$\|\nabla F_k(\theta) - \nabla F_k(\theta')\|_2 \leq L \|\theta - \theta'\|_2. \quad (16)$$

假设 A2 μ -强凸性。全局损失函数 F 满足:

$$F(\theta') \geq F(\theta) + \nabla F(\theta)^T (\theta' - \theta) + \frac{\mu}{2} \|\theta' - \theta\|_2^2. \quad (17)$$

假设 A3 有界梯度。存在常数 G 使得对所有客户端 k 和任意参数 θ , 本地梯度的二阶范数有界:

$$\mathbb{E}[\|\nabla F_k(\theta)\|_2^2] \leq G^2. \quad (18)$$

假设 A4 有界异构性。存在常数 σ_{local} 使得客户端本地

梯度与全局梯度的偏差有界:

$$\mathbb{E}[\|\nabla F_k(\theta) - \nabla F(\theta)\|_2^2] \leq \sigma_{local}^2. \quad (19)$$

假设 A5 有界噪声。差分隐私注入的高斯噪声二阶范数有界:

$$\mathbb{E}[\|\xi_k^t\|_2^2] \leq (\sigma_k^t C_k^t)^2 d. \quad (20)$$

CNN 的损失函数通常不满足严格强凸性, 但在实际训练中, 可通过以下方式使假设 A2 在一定条件下近似成立: 参数正则化, 加入正则项后, 损失函数可具备带正则的强凸性, 此时 μ 可对应正则化系数, 满足假设 A2 的数学形式。在最优解附近的局部参数空间中, CNN 的损失函数可近似为强凸函数, 使得收敛性分析中的推导逻辑依然有效。假设 A2 可作为 CNN 模型收敛性分析的合理简化假设, 既用于推理论证收敛速率的上界, 也可反映算法的收敛趋势。

表 2 相关符号定义

Tab. 2 Symbol definitions

符号	含义
θ^t	第 t 轮全局模型参数
θ_k^t	客户端 k 第 t 轮本地模型参数
σ_{local}	本地梯度与全局梯度的偏差上限
g_k^t	客户端 k 在第 t 轮本地更新的梯度
$\hat{g}_k^t$	添加差分隐私噪声后的梯度
ξ_k^t	添加到梯度的隐私噪声
$\lambda_{avg} = \frac{1}{K} \sum_k \lambda_k$	全局平均混合系数
$\theta^* = \arg \min_{\theta} F(\theta)$	全局最优解
$\theta_k^* = \arg \min_{\theta} F_k(\theta)$	客户端 k 的本地最优解
$F(\theta) = \sum_k \left(\frac{n_k}{n}\right) F_k(\theta)$	全局损失函数
$F_k(\theta) = \frac{1}{n_k} \sum_{(x,y) \in D_k} \ell(\theta; x, y)$	客户端 k 本地损失

3.4.2 主要收敛定理

定理 4 DP-PFL 主收敛定理。在假设 A1-A5 下, DP-PFL 算法的期望收敛误差满足:

$$\mathbb{E}[F(\theta^T) - F(\theta^*)] \leq \frac{\sigma_{avg}^2 d}{2\mu T} + \frac{(1 - \lambda_{avg})^2 \sigma_{local}^2}{2\mu} + \frac{LG^2}{2\mu\sqrt{T}}. \quad (21)$$

证明 1) 单轮更新误差分析

考虑 DP-PFL 的更新过程。在第 t 轮, 客户端 k 本地模型更新为: $\theta_k^t = \theta^{t-1} - \eta \cdot \hat{g}_k^t$, 其中 η 为学习率, $\hat{g}_k^t = \text{Clip}(g_k^t, C_k^t) + \xi_k^t$ 为加噪裁剪梯度。对两边取期望并减去全局最优解 θ^* 得到 $E[\theta_k^t - \theta^*] = E[\theta^{t-1} - \theta^*] - \eta \cdot E[\hat{g}_k^t]$ 。整理得本地更新的误差传递关系:

$$E[\|\theta_k^t - \theta^*\|_2^2] \leq (1 - \mu\eta) E[\|\theta^{t-1} - \theta^*\|_2^2] + \eta^2 E[\|\hat{g}_k^t\|_2^2]$$

服务器通过加权平均聚合全局模型:

$$\theta^t = \theta^{t-1} + \sum_{k \in S_t} \frac{n_k}{n} (\theta_k^t - \theta^{t-1}), \text{ 代入本地更新公式, 全局模型误差}$$

满足: $E[\|\theta^t - \theta^*\|_2^2] \leq \sum_{k \in S_t} \frac{n_k}{n} E[\|\theta_k^t - \theta^*\|_2^2]$, 单轮全局误差可表示为:

$$E[\|\theta^t - \theta^*\|_2^2] \leq (1 - \mu\eta) E[\|\theta^{t-1} - \theta^*\|_2^2] + \eta^2 \cdot \text{Err}_t, \text{ 其中}$$

$$\text{Err}_t = \sum_{k \in S_t} \frac{n_k}{n} E[\|\hat{g}_k^t\|_2^2] \text{ 为单轮总误差项。}$$

2) 误差项分解

隐私噪声误差: 由假设 A5, 噪声 ξ_k^t 的贡献为: $E[\|\xi_k^t\|_2^2] \leq (\sigma_k^t C_k^t)^2 \cdot d$ 。取 $\sigma_{avg} = \max_t \sigma_k^t$, 则单轮噪声误差为: $\text{Err}_{noise} \leq \sigma_{avg}^2 \cdot d$ 。

异构性误差: 由假设 A4 本地梯度与全局梯度的偏差结

合个性化混合系数 λ_k ($\theta_k^{pers,t} = \lambda_k \theta^{t-1} + (1-\lambda_k) \theta_k^t$), 误差降低为 $Err_{hetero} \leq (1-\lambda_{avg})^2 \cdot \sigma_{local}^2$ 。

随机优化误差: 由假设 A3, 梯度本身的随机性贡献, 单轮优化误差为: $Err_{opt} \leq L \cdot G^2$ 。

3) 总收敛误差推导

将单轮全局误差从 $t=1$ 到 $t=T$ 累加, 结合误差分解, 总误差满足:

$$E[\|\theta^T - \theta^*\|_2^2] \leq (1-\mu\eta)^T E[\|\theta^0 - \theta^*\|_2^2] + \eta \sum_{t=1}^T (1-\mu\eta)^{T-t} \cdot Err_t$$

当 T 足够大时, $(1-\mu\eta)^T \approx 0$, 且 $\sum_{t=1}^T (1-\mu\eta)^{T-t} \approx \frac{1}{\mu\eta}$ 。代入误差项得

$$E[\|\theta^T - \theta^*\|_2^2] \leq \frac{\sigma_{avg}^2 \cdot d}{\mu T} + \frac{(1-\lambda_{avg})^2 \cdot \sigma_{local}^2}{\mu} + \frac{L \cdot G^2}{\mu \sqrt{T}}$$

由假设 A2, 损失函数误差与参数误差满足:

$$F(\theta^T) - F(\theta^*) \leq \frac{1}{2} \|\theta^T - \theta^*\|_2^2, \text{ 最终得收敛速率}$$

$$E[F(\theta^T) - F(\theta^*)] \leq \frac{\sigma_{avg}^2 d}{2\mu T} + \frac{(1-\lambda_{avg})^2 \sigma_{local}^2}{2\mu} + \frac{LG^2}{2\mu \sqrt{T}}。$$

推论 1 个性化改进。相比无个性化的 DP-FedAvg, DP-PFL 的收敛误差降低:

$$\Delta_{gain} = \frac{[1 - (1-\lambda_{avg})^2] \sigma_{local}^2}{2\mu}。 \quad (22)$$

当无个性化时 $\lambda_k = 1$, 误差项为 $\frac{\sigma_{local}^2}{2\mu}$, DP-PFL 中误差项

为 $(1-\lambda_{avg})^2 \cdot \frac{\sigma_{local}^2}{2\mu}$, 因此相比 DP-FedAvg 方法其改进量为

$$\Delta_{gain} = \frac{\sigma_{local}^2}{2\mu} - \frac{(1-\lambda_{avg})^2 \sigma_{local}^2}{2\mu} = \frac{[1 - (1-\lambda_{avg})^2] \sigma_{local}^2}{2\mu}$$

4 实验与结果分析

4.1 数据集与异构性设置

实验选用两种广泛使用的基准图像分类数据集, 涵盖不同复杂度与应用场景, 具体信息如下。

a) MNIST. 手写数字识别数据集, 包含 70,000 个 28×28 像素的灰度图像, 分为 10 个类别(0-9), 其中 60,000 个为训练样本, 10,000 个为测试样本。该数据集数据分布相对简单, 常用于验证算法基础性能。

b) CIFAR-10. 自然图像分类数据集, 包含 60,000 个 32×32 像素的 RGB 图像, 涵盖 10 个类别(如飞机、汽车、鸟类等), 训练集 50,000 个样本, 测试集 10,000 个样本。其数据复杂度高于 MNIST, 更能反映实际场景中的异构性挑战。

为模拟联邦学习场景中客户端数据的非独立同分布特性, 采用 Dirichlet 分布 ($Dir(\alpha)$) 对数据集进行划分, 通过调整参数 α 控制异构性程度。 α 值越小, 客户端间数据分布差异越大, 即异构性越高; α 值越大, 数据分布越接近独立同分布。具体划分策略为: 对每个客户端, 基于 Dirichlet 分布生成类别概率分布, 再根据该分布从全局数据集中抽取样本, 确保客户端数据的类别偏好与 α 值匹配。

实验设置 5 种典型异构性场景异构性度量如图 2 所示。其中 $\alpha=0.01$ 表示极端异构, 每个客户端主要包含 1-2 个类别。 $\alpha=0.1$ 是高度异构, 类别分布严重不平衡。 $\alpha=0.5$ 表示中等异构, 存在明显的类别偏好。 $\alpha=1.0$ 为轻度异构, 接近但不完全均匀。 $\alpha=10.0$ 比较接近独立同分布, 类别分布相对均匀。




图 2 异构性度量对比

Fig. 2 Heterogeneity metric comparison

4.2 基线方法与实验环境

选取以下具有代表性的联邦学习方法作为基线, 以对比 DP-PFL 的性能:

a) 标准联邦学习方法。FedAvg^[7]是经典联邦平均算法, 通过客户端本地训练与服务器参数平均实现协同训练。FedProx^[8]在本地目标函数中引入近端项, 限制本地模型与全局模型的偏离。SCAFFOLD^[12]采用控制变量机制校正客户端与服务器的梯度估计偏差, 提升 Non-IID 场景下的收敛性。

b) 差分隐私联邦学习方法。DP-FedAvg^[25]是标准差分隐私联邦学习, 在 FedAvg 基础上添加固定噪声的差分隐私版本, 提供 (ϵ, δ) - 隐私保证。AdaClip^[27]是通过自适应调整梯度裁剪阈值优化隐私与效用权衡的方法。DP-SCAFFOLD^[28]方法结合了 SCAFFOLD 与差分隐私的方法, 平衡隐私与收敛性能。FedBDP 方法是 2024 年由张少波等提出的差分隐私个性化联邦学习方法^[33]。该方法通过 Bregman 散度衡量本地与全局模型差异, 解决高异构下欧氏距离不敏感问题, 并采用指数衰减系数动态调整差分隐私噪声。

c) 个性化联邦学习方法。Per-FedAvg^[18]基于模型无关学习的个性化方法, 学习全局初始化参数以支持快速本地适应。pFedMe^[19]采用双层优化框架与 Moreau 包络技术, 分离全局与个性化参数。FedRep^[20]将模型拆分为共享表示层与个性化分类层, 平衡全局知识共享与本地适应。

实验的硬件环境包括配备 NVIDIA 4060TI GPU、32GB DDR4 内存和 win11 操作系统。软件环境则采用 PyTorch 1.12 作为深度学习框架, 使用 Opacus 1.3 作为差分隐私库, CUDA 版本为 11.8, 代码采用 Python 实现。模型采用卷积神经网络 (Convolutional Neural Network, CNN) 作为基准架构, 包含 2 个卷积层(卷积核大小 3×3), 2 个全连接层, 使用 ReLU 激活函数和 Dropout 正则化, 取 Dropout 率为 0.5。实验中的超参数设置如下: 客户端配置为总客户端数量 $K=100$, 每轮随机选取 30% 个客户端参与训练。训练参数方面, 本地迭代次数设为 5, 批量大小设置为 16, 初始学习率为 0.01 并采用余弦退火调度进行衰减。隐私参数方面, 隐私参数设定默认隐私预算 $\epsilon=1.0$, $\delta=10^{-5}$ 。基础裁剪阈值设置为 1.0, 梯度裁剪按照方案动态调整。个性化参数包括元学习率 $\alpha_{meta}=0.001$, 个性化混合系数初始化设置为 $\lambda_k=0.5$, 随客户端异构性 α_k 进行动态调整, 最大调整幅度为 0.3。噪声系数初始值为 1.4, 随训练轮次衰减, 噪声衰减率 $\gamma=0.8$ 。最大通信轮次 $T=200$ 或隐私预算耗尽时提前终止, 这些参数均通过网格搜索优化确定。所有 DP 方法在相同预算条件下比较, DP-PFL 通过时间与客户端维度的自适应分

配动态调整噪声系数, 但不突破总隐私约束。

4.3 攻击设置与评估指标

采用“诚实但好奇”威胁模型, 服务器遵守协议但试图从可见信息推断隐私, 攻击者知悉 DP-PFL 算法逻辑与超参数, 无法访问原始数据, 为验证 DP-PFL 方案的抗攻击能力, 围绕联邦学习场景下三类典型隐私攻击展开, 表 3 为 DP-PFL 框架攻击设置表。

表 3 攻击设置
Tab. 3 Attack setup

攻击类型	场景	数据参数	模型/计算参数
成员推断黑盒查询		样本 5000 个 (2500 成员/2500 非成员)	10 次蒙特卡罗采样, 逻辑回归(轮次 100)
属性推断灰盒梯度		100 个客户端, 二值敏感属性	轻量级 CNN(2 卷积层, 轮次 80, 学习率 0.001)
梯度反演白盒梯度		前 20 轮梯度, 100 样本/客户端	GAN 框架, PSNR 计算进行像素归一化

在评估指标方面, 主要从效用, 隐私与系统三个角度设计评估指标, 全面衡量算法性能:

a) 效用指标。a.测试准确率: 表示模型在本地测试集上的分类准确率。b.通信轮次: 训练达到稳定性能所需的通信轮次, 衡量算法的训练效率。c.计算开销: 总训练时间与峰值内存占用, 用于评估算法的计算成本。

b) 隐私指标。a.成员推断攻击成功率: 攻击者正确判断样本是否为训练成员的比例, MIA 攻击的成功率越低越好。b.属性推断攻击成功率: 攻击者推断训练数据敏感属性的准确率。c.梯度反演攻击 PSNR: 重构图像与原始图像的峰值信噪比, 值越低表明隐私保护效果越好。

c) 系统指标。a.可扩展性: 支持的最大客户端数量, 衡量算法在大规模场景下的适用性。b.通信效率: 每轮通信的数据传输量与总通信轮次, 评估分布式训练的通信成本。

4.4 Non-IID 场景下的性能对比


本研究重点关注高异构性场景($\alpha = 0.1$), 即联邦学习部署中最具挑战性的情况。图 3 展示了 DP-PFL 在不同 Non-IID 场景下与基线方法的性能对比。实验结果验证了 DP-PFL 的有效性, 具体如下:

a) MNIST 数据集分析。在高 Non-IID 场景下, DP-PFL 达到 85.5% 的准确率, 相比最佳个性化基线 Per-FedAvg 虽略有差距, 但相比同样具有隐私保护的 DP-FedAvg, DP-PFL 准确率提升了 5.3 个百分点, 同时比 FedBDP 方案的 85.2% 准确率略高, 证明文中方法在隐私保护约束下的仍然具有较好的性能优势。


b) CIFAR-10 数据集分析。在更复杂的自然图像分类任务中, DP-PFL 在 $\alpha = 0.1$ 情况下达到 74.2% 准确率, 与 FedBDP 方法的准确率 74.3% 相似, 对比 FedAvg 方案也有较大的优势。DP-PFL 与个性化联邦学习方法相比, 与 FedRep 准确率接近, 比 pFedMe 和 Per-FedAvg 略差一些。在具有隐私保护效果的方案中, DP-PFL 比 DP-FedAvg 和 DP-SCAFFOLD 提升了 6.0 和 4.1 个百分点。

c) 异构性鲁棒性分析。图 3(c)在 MNIST 数据集下, 对比了 FedAvg, DP-FedAvg, Per-FedAvg 与 DP-PFL 在不同异构水平下的性能表现。随着异构性值 α 的逐渐增大, 数据分布越来越接近独立同分布, DP-PFL 的优势逐渐变小, 这是由于 DP-PFL 主要优化了数据异构导致的性能下降问题。在 $\alpha = 10$ 的场景下, 数据分布异构性低, 对其他方案的准确率影响较低, 而 DP-PFL 和 DP-FedAvg 方案由于应用了差分隐私技术加噪, 导致模型准确率


弱于未加噪方案。但是总体上, DP-PFL 在所有异构性级别下都保持较好性能, 特别是在极端 Non-IID 场景($\alpha = 0.01$)下, 达到 76.3% 左右的准确率, 相比 DP-FedAvg(65.5%)提升显著, 证明了本方案对数据异构性的强鲁棒性。




(a) MNIST 数据集下不同方法的对比



(b) CIFAR-10 数据集下不同方法的对比



(c) MNIST 数据集下 α 的影响



(d) CIFAR-10 数据集下对 DP-FedAvg 的提升

图 3 Non-IID 场景性能对比


Fig. 3 Non-iid scenario performance comparison

d) 隐私-效用权衡分析。图 3(d)展示了 DP-PFL 相比 DP-FedAvg


在不同隐私预算下的性能提升。在强隐私场景, DP-PFL 与 DP-FedAvg 的对比有明显优势。随着隐私预算增加, 两者差距逐渐缩小但 DP-PFL 始终保持领先, 证明了自适应机制在各种隐私级别下的有效性。

4.5 隐私防御效果分析


本节评估了三种主要的隐私攻击: 成员推断攻击、属性推断攻击和梯度反演攻击。图 4 展示了 DP-PFL 多层防御系统对各种隐私攻击的防御效果。柱状图中红色表示抵抗隐私攻击较弱, 黄色部分代表隐私保护效果一般, 绿色方案防御效果最好。




(a) 成员推断攻击



(b) 属性推断攻击



(c) 梯度反演攻击



(d) 多层防御效果

图 4 隐私防御效果对比

Fig. 4 Privacy defense effect comparison

a) 成员推断攻击防御分析。如图 4(a) 所示, DP-PFL 将

MIA 攻击成功率降低至 54.6%, 相比 DP-FedAvg(61.4%)降低了 6.8 个百分点, 相对改进 11.1%。更重要的是, 相比无隐私保护的方法, DP-PFL 的防御效果显著, 攻击成功率接近随机猜测水平。

b) 属性推断攻击防御分析。图 4(b) 显示 DP-PFL 在 PIA 攻击防御方面同样表现出色, 攻击成功率为 51.5%, 较 DP-FedAvg 的 57.7% 降低了 6.2 个百分点, 相对改进 10.7%。这一结果表明文中的多层防御机制能够有效保护训练数据的敏感属性信息。

c) 梯度反演攻击防御分析。图 4(c) 展示了梯度反演攻击的 PSNR 值对比。DP-PFL 达到 6.8dB 的 PSNR 值, 比 DP-FedAvg 降低了 1.4dB, 表明重构图像质量进一步下降, 隐私保护效果更佳。这得益于自适应噪声调整机制对关键梯度分量减少噪声注入以保留模型性能, 对次要分量增加噪声以强化隐私保护, 实现了隐私与效用的精准平衡。

d) 多层防御消融分析。图 4(d) 展示了各防御组件的贡献。从基础的差分隐私(MIA 成功率 61.4%)开始, 逐步添加贝叶斯不确定性、温度缩放和输出噪声, 每个组件都对最终的隐私保护效果有积极贡献。同时, 准确率从 80.2% 逐步提升至 85.2%, 证明了多层防御系统的协同效应。既通过差异化噪声注入增强隐私保护, 又通过不确定性量化技术减少性能损失。

4.6 个性化效果分析

本节评估了 DP-PFL 个性化机制的有效性, 包括与传统个性化方法的对比、收敛速度分析和通信效率评估。如图 5 所示。

a) 全局模型与个性化模型对比。图 5(a) 展示了 10 个客户端上全局模型与个性化模型的性能对比。个性化模型在所有客户端上均显著优于全局模型, 平均提升 5.8 个百分点。其中, 高异构性客户端的性能提升最为明显, 提升了 7.2 个百分点, 也验证了元学习驱动的个性化策略在处理客户端数据异构性方面的有效性。

b) 个性化方法对比。图 5(b) 比较了 DP-PFL 与其他个性化方法以及基线 FedAvg 的准确率。在 MNIST 数据集上, DP-PFL 相比 FedAvg 提升 1.6 个百分点, 相比 pFedMe 提升了 2.3 个百分点; 在 CIFAR-10 数据集上, DP-PFL 相比 FedAvg 提升 1.4 个百分点。结果表明, 结合自适应差分隐私的元学习策略, 在保持隐私保护的同时实现了更好的本地适应效果。

c) 收敛速度分析。图 5(c) 展示了 FedAvg, DP-Fedavg, Per-FedAvg 与 DP-PFL 方法在同一数据集下, $\alpha=0.1$ 的收敛曲线。DP-PFL 展现出较快的收敛速度, 在约 125 轮通信后达到稳定性能(85.2%), 相比 FedAvg 的 150 轮减少了约 16.7% 的通信轮次, 相比 DP-FedAvg 减少了 21.9%。这得益于元学习初始化提供的更好起点和自适应混合策略的快速本地适应能力, 通过动态调整混合系数, 使模型更快适配本地数据分布。

d) 通信效率分析。图 5(d) 的散点图展示了通信效率与最终准确率的权衡。DP-PFL 位于左上角, 以较少的通信轮次(125 轮)达到了较高的准确率(85.2%), 证明了方法的整体效率优势。其通信成本降低主要源于两方面: 一是收敛速度加快减少了总轮次, 二是自适应隐私预算分配减少了无效通信开销。

4.7 自适应机制分析

图 6 详细分析了 DP-PFL 自适应差分隐私机制的各个组件, 结果验证了动态参数调整策略的有效性。




Fig. 6 Adaptive mechanism analysis

a) 自适应与固定参数对比。图 6(a)展示了自适应噪声策略相比固定噪声的优势。自适应策略初始噪声水平为 1.4, 随训练轮次衰减至 0.63, 最终准确率达到 85.2%; 而固定噪声策略($\sigma=1.2$)准确率为 79.6%, 两者差距 5.6 个百分点。这证明了根据训练进度调整隐私参数的重要性——初期高噪声

Fig. 5 Personalization effect comparison

可以保障隐私, 后期低噪声可以提升性能。

b) 异构性感知参数调整。图 6(b)显示了不同异构性水平下的参数调整策略。在高异构性场景($\alpha=0.01$)下, 系统自动将裁剪阈值提高至 1.25 并将噪声水平设为 0.85; 随着异构性降低($\alpha=0.1$), 裁剪阈值降至 0.9, 噪声水平降至 0.45。这种调整使高异构客户端保留更多梯度信息, 低异构客户端强化隐私保护, 实现了异构场景下的动态平衡。

c) 隐私预算分配策略。图 6(c)比较了不同预算分配策略的效率。DP-PFL 的自适应分配策略消耗 82%的预算即可达到 85.2% 的准确率, 相比均匀分配(100% 预算, 79.6%准确率)实现了更好的隐私效用权衡。通过将更多预算倾斜给训练初期(占总预算的 38%)和高异构客户端(占比 42%), 显著提升了预算利用效率。

d) 重要性加权噪声注入。图 6(d)展示了梯度分量重要性与噪声分配的关系。重要的梯度分量(前 3 个组件)获得较高的重要性分数(0.92-0.74), 噪声水平降低约 21%; 不重要的分量(后 3 个组件)噪声水平增加约 15%。这种精细化策略在保护关键特征梯度的同时, 通过冗余分量强化隐私, 使模型在加噪情况下仍保持较高性能。

4.8 可扩展性分析

为验证 DP-PFL 方案的可扩展性, 表 4 评估了 DP-PFL 在 MNIST 数据集上不同规模客户端下的性能表现, 验证其在实际部署中的可行性。

表 4 系统可扩展性评估

Tab. 4 Comparison of human evaluation scores

客户端数量	通信轮次	每轮通信时间/s	总训练时间/h	峰值内存/GB	最终准确率/%
10	120	1.8	0.6	3.2	85.2±0.6
50	123	6.2	2.1	8.7	85.3±0.8
100	125	12.3	4.2	16.4	85.4±0.5
200	132	23.7	8.4	31.6	85.3±0.5

通过表格可以直观看到 DP-PFL 有以下优势:

- 1)性能稳定性: 随着客户端数量从 10 增加到 200, 准确率保持稳定在 85%左右, 证明算法对客户端规模变化具有强鲁棒性。
- 2)通信效率: 通信轮次随客户端数量增加缓慢增长从 120-132 轮, 远低于线性增长比例, 表明算法能有效处理大规模协作场景。
- 3)资源消耗: 每轮通信时间与客户端数量近似线性相关, 峰值内存增长较缓, 适合中等硬件环境部署。

5 结束语

本研究围绕异构数据下联邦学习的隐私保护、个性化适配与系统性能协同优化问题, 设计并验证了 DP-PFL 方案。该方案主要包含三大关键部分: 自适应差分隐私梯度扰动机制, 依据训练迭代动态衰减噪声, 并按模型梯度分量重要性差异化分配噪声, 在相同隐私预算下实现隐私与效能的平衡; 基于元学习的个性化训练策略, 通过优化本地初始化与动态参数, 增强对异质分布的适应性; 结合隐私保护输出层与不确定性增强的多层级成员推断防御体系。理论证明 DP-PFL 满足差分隐私约束, 且在非独立同分布条件下能保持可证明的 $O(1/\sqrt{T})$ 收敛速率。在 MNIST、CIFAR-10 等基准数据集上的测试显示, DP-PFL 在非 IID 划分场景下不仅取得更高准确率, 还对成员推断、属性推断与梯度反演攻击展现出更强鲁棒性, 同时在客户端数量增至 200 时实现 $\leq 0.5\%$ 的准确率

波动, 兼顾了效用、隐私与可扩展性。

未来工作将探索针对客户端频繁加入退出的动态场景, 设计基于联邦元学习的在线更新机制, 提升框架对系统异构性的容忍度, 进一步降低通信与计算开销。

参考文献:

[1] Jin Weina, Li Xiaoxiao, Fatehi M, *et al.* Guidelines and evaluation of clinical explainable AI in medical image analysis [J]. Medical Image Analysis, 2023, 84: 102684.

[2] 何泽平, 许建, 戴华, 等. 联邦学习应用技术研究综述 [J]. 信息安全, 2024, 24 (12): 1831-1844. (He Zeping, Xu Jian, Dai Hua, *et al.* Research review on federated learning application technologies [J]. Netinfo Security, 2024, 24 (12): 1831-1844.)

[3] 何俊鹏, 罗蕾, 肖堃, 等. 基于特征值分布和人工智能的网络入侵检测系统的研究与实现 [J]. 计算机应用研究, 2021, 38 (9): 2746-2751. (He Junpeng, Luo Lei, Xiao Kun, *et al.* Research and implementation of network intrusion detection system based on eigenvalue distribution and artificial intelligence [J]. Application Research of Computers, 2021, 38 (9): 2746-2751.)

[4] Lima I R, Nagai Y, Santos-Victor J. AI-Driven Anticipation of Vehicle Drift Dynamics [C]// Proc of the 2025 IEEE International Conference on Omni-layer Intelligent Systems (COINS) . Madison, WI, USA: IEEE Press, 2025: 1-7.

[5] Voigt P, Von Dem Bussche A. The EU General Data Protection Regulation (GDPR) [M]. Cham: Springer International Publishing, 2017.

[6] Li T, Sahu A K, Talwalkar A, *et al.* Federated learning: Challenges, methods, and future directions [J]. IEEE Signal Processing Magazine, 2020, 37 (3): 50-60.

[7] McMahan B, Moore E, Ramage D, *et al.* Communication-efficient learning of deep networks from decentralized data [C]// Proc of the 20th International Conference on Artificial Intelligence and Statistics. PMLR, 2017: 1273-1282.

[8] Duan Jianhui, Li Wenzhong, Zou Derun, *et al.* Federated learning with data-agnostic distribution fusion [C]// Proc of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE, 2023: 8074-8083.

[9] Hu Hongsheng, Salcic Z, Sun Lichao, *et al.* Membership inference attacks on machine learning: A survey [J]. ACM Computing Surveys (CSUR) , 2022, 54 (11s): 1-37.

[10] Rao Bosen, Zhang Jiale, Wu Di, *et al.* Privacy inference attack and defense in centralized and federated learning: A comprehensive survey [J]. IEEE Trans on Artificial Intelligence, 2025, 6 (2): 333-353.

[11] Jiang Zhifeng, Wang Wei, Chen Ruichuan. Dordis. Efficient federated learning with dropout-resilient differential privacy [C]// Proc of the 19th European Conference on Computer Systems. New York: ACM Press, 2024: 472-488.

[12] Karimireddy S P, Kale S, Mohri M, *et al.* SCAFFOLD: Stochastic controlled averaging for federated learning [C]// Proc of the 37th International Conference on Machine Learning. Cambridge, MA: MIT Press, 2020: 5132-5143.

[13] Wang Jianyu, Liu Qinghua, Liang Hao, *et al.* Tackling the objective inconsistency problem in heterogeneous federated optimization [J]. Advances in Neural Information Processing Systems, 2020, 33: 7611-7623.

[14] Lin Tao, Kong Lingjing, Stich S U, *et al.* Ensemble distillation for robust

- model fusion in federated learning [J]. *Advances In Neural Information Processing Systems*, 2020, 33: 2351-2363.
- [15] Yang Yuchen, Hui Bo, Yuan Haolin, *et al.* PrivateFL: Accurate, differentially private federated learning via personalized data transformation [C]// 32nd USENIX Security Symposium (USENIX Security 23). Anaheim, CA: USENIX Association, 2023: 1595-1612.
- [16] Wang Hongyi, Yurochkin M, Sun Yuekai, *et al.* Federated learning with matched averaging [C]// Proc of the 8th International Conference on Learning Representations (ICLR). Addis Ababa, Ethiopia: ICLR, 2020: 1-16.
- [17] Ma Xiaosong, Zhang Jie, Guo Song, *et al.* Layer-wised model aggregation for personalized federated learning [C]// Proc of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE, 2022: 10092-10101.
- [18] Fallah A, Mokhtari A, Ozdaglar A. Personalized federated learning with theoretical guarantees: A model-agnostic meta-learning approach [J]. *Advances in Neural Information Processing Systems*, 2020, 33: 3557-3568.
- [19] T Dinh C, Tran N, Nguyen J. Personalized federated learning with moreau envelopes [J]. *Advances in Neural Information Processing Systems*, 2020, 33: 21394-21405.
- [20] Yang Yirui, Wang Kun, Li Wujun. FedREP: A Byzantine-robust, communication-efficient and privacy-preserving framework for federated learning [J]. *arXiv preprint arXiv: 2303.05206*, 2023.
- [21] Shokri R, Stronati M, Song Congzheng, *et al.* Membership inference attacks against machine learning models [C]// Proc of the 2017 IEEE Symposium on Security and Privacy (SP). Piscataway, NJ: IEEE Press, 2017: 3-18.
- [22] Nasr M, Shokri R, Houmansadr A. Comprehensive privacy analysis of deep learning: Passive and active white-box inference attacks against centralized and federated learning [C]// Proc of the 2019 IEEE Symposium on Security and Privacy (SP). IEEE, 2019: 739-753.
- [23] Zhu Ligeng, Liu Zhijian, Han Song. Deep leakage from gradients [J]. *Advances in Neural Information Processing Systems*, 2019, 32.
- [24] Geiping J, Bauermeister H, Dröge H, *et al.* Inverting gradients-how easy is it to break privacy in federated learning? [J]. *Advances in Neural Information Processing Systems*, 2020, 33: 16937-16947.
- [25] Abadi M, Chu A, Goodfellow I, *et al.* Deep learning with differential privacy [C]// Proc of the 2016 ACM SIGSAC Conference on Computer and Communications Security. New York: ACM Press, 2016: 308-318.
- [26] Geyer R C, Klein T, Nabi M. Differentially private federated learning: A client level perspective [J]. *arXiv preprint arXiv: 1712.07557*, 2017.
- [27] Andrew G, Thakkar O, McMahan B, *et al.* Differentially private learning with adaptive clipping [J]. *Advances in Neural Information Processing Systems*, 2021, 34: 17455-17466.
- [28] Kairouz P, McMahan H B, Avenet B, *et al.* Advances and open problems in federated learning [J]. *Foundations and Trends in Machine Learning*, 2021, 14 (1-2): 1-210.
- [29] Bonawitz K, Ivanov V, Kreuter B, *et al.* Practical secure aggregation for privacy-preserving machine learning [C]// Proc of the 2017 ACM SIGSAC Conference on Computer and Communications Security. New York: ACM Press, 2017: 1175-1191.
- [30] Phong L T, Aono Y, Hayashi T, *et al.* Privacy-preserving deep learning via additively homomorphic encryption [J]. *IEEE Trans on Information Forensics and Security*, 2017, 13 (5): 1333-1345.
- [31] Guo Songyue, Yang Xu, Feng Jiyuan, *et al.* FedGR: Federated learning with gravitation regulation for double imbalance distribution [C]// Proc of the International Conference on Database Systems for Advanced Applications. Cham: Springer Nature Switzerland, 2023: 703-718.
- [32] Dwork C, Roth A. The algorithmic foundations of differential privacy [J]. *Foundations and Trends in Theoretical Computer Science*, 2014, 9 (3-4): 211-407.
- [33] 张少波, 张激勇, 朱更明, 等. 基于 Bregman 散度和差分隐私的个性化联邦学习方法 [J]. *软件学报*, 2023, 35 (11): 5249-5262. (Zhang Shaobo, Zhang Jiyong, Zhu Gengming, *et al.* A personalized federated learning method based on Bregman divergence and differential privacy [J]. *Journal of Software*, 2024, 35 (11): 5249-5262.)