



计算机工程
Computer Engineering
ISSN 1000-3428,CN 31-1289/TP

《计算机工程》网络首发论文

题目：联邦学习中一种动态恶意节点识别机制
作者：刘佳琦，程晓娜
DOI：10.19678/j.issn.1000-3428.0253438
网络首发日期：2026-04-15
引用格式：刘佳琦，程晓娜. 联邦学习中一种动态恶意节点识别机制[J/OL]. 计算机工程.
<https://doi.org/10.19678/j.issn.1000-3428.0253438>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

联邦学习中一种动态恶意节点识别机制

刘佳琦¹, 程晓娜^{2*}

(中南大学计算机学院, 湖南 长沙 410083)

摘要: 联邦学习通过“数据不动模型动”的分布式范式实现了隐私保护与协同建模, 但现有方案在客户端选择效率、恶意节点防御及激励分配公平性上存在明显不足。为此, 本研究提出一种动态恶意节点识别机制 (GIFL), 实现恶意节点精准识别、高效客户端选择与动态激励分配的协同优化。GIFL 通过轻量型贪心筛选策略过滤低贡献高成本节点, 基于模型参数偏差的影响因子动态更新机制识别并剔除恶意节点, 结合历史与实时贡献设计动态报酬支付策略。基于 Fashion-MNIST 和 CIFAR-10 及 Tiny-ImageNet 数据集的实验表明, 在恶意节点比例为 5%-30% 的跨设备联邦学习场景下, 与 FedAvg、IAFL 等五种基准方法相比, GIFL 的恶意节点识别精度提升 5.4%~23.9%, 前置筛选耗时较 QAIM 平均降低 86.1%, 模型收敛稳定性与社会福利显著改善, 在模型精度不低于 92% (Fashion-MNIST、CIFAR-10) 和 88% (Tiny-ImageNet) 的前提下, 服务器平均成本降低 16.94%, 为移动边缘网络中联邦学习的高效可靠运行提供了新方案。

关键词: 轻量贪心策略; 影响因子; 联邦学习; 激励机制; 恶意节点识别

中图分类号: TP391

文献标志码: A

DOI: 10.19678/j.issn.1000-3428.0253438

A Dynamic Malicious Node Identification Mechanism for Federated Learning

LIU Jiaqi¹, CHENG Xiaona^{2*}

(School of Computer Science and Engineering, Central South University, Changsha 410083, Hunan, China)

【Abstract】 Federated learning achieves privacy preservation and collaborative modeling through the distributed paradigm of “data staying local and model being shared.” However, existing schemes show clear limitations in client selection efficiency, malicious node defense, and fairness of incentive allocation. This paper proposes a dynamic malicious node identification mechanism, named GIFL, to jointly optimize malicious node detection, efficient client selection, and dynamic incentive allocation. GIFL adopts a lightweight greedy screening strategy to filter low-contribution and high-cost clients. An influence factor dynamic updating mechanism based on model parameter deviation is used to accurately identify and remove malicious nodes. A dynamic reward payment strategy is designed by jointly considering historical and real-time contributions. Experiments on the Fashion-MNIST, CIFAR-10 and Tiny-ImageNet datasets demonstrate that in cross-device federated learning scenarios where the proportion of malicious nodes is 5%-30%, GIFL significantly outperforms five benchmark methods, including FedAvg and IAFL. The malicious node identification accuracy is improved by 5.4% to 23.9%. Compared with QAIM, the pre-selection time is reduced by an average of 86.1%. Model convergence stability and social welfare are significantly enhanced. Under the condition that model accuracy is not lower than 92% (Fashion-MNIST, CIFAR-10) and 88% (Tiny-ImageNet), the average server cost is reduced by 16.94%. The results indicate that GIFL provides an effective and reliable solution for federated learning in mobile edge networks.

【Key words】 lightweight greedy strategy; influence factor; federated learning; incentive mechanism; malicious node identification

0 引言

联邦学习 (Federated Learning, FL) 通过“数据不动模型动”的分布式训练范式, 在保护隐私的同时实现多点协同建模, 已经成为移动边缘智能的核心技术^[1-2]。随着大规模异构终端的广泛部署, 联邦学习在系统可扩展性、节点异质性管理以及安全性等方

面面临新的挑战^[3-4]。特别是在跨设备联邦学习场景中, 客户端数量庞大且参与行为高度不稳定, 使得高效客户端选择与安全防御成为系统设计的关键问题^[5]。受网络通信稳定性、设备在线时长以及非独立同分布数据特性等因素制约^[6], 聚合服务器在每一轮训练中仅能选取少量客户端参与联合训练。因此, “客户端选择”已成为联邦学习中的核心流程,

即每轮训练启动前筛选出最优参与客户端集合。

近年来,学界围绕客户端选择算法展开了大量研究^[7-9],旨在同步优化联邦学习的资源消耗(包括通信与计算成本)与联合模型性能(涵盖模型精度与训练速度)。根据节点效用函数建模所依赖的特征信息差异,现有研究中节点选择算法基本划分为四类:随机选择算法^[10-11]、基于数据效用的选择算法^[9]、基于资源效用的选择算法^[7]、以及基于数据与资源联合效用的选择算法^[12]。这些研究虽在一定程度上优化了客户端选择效果,但仍存在明显不足:其一,随机选择算法完全忽视节点异质性,导致训练效率低下;其二,单维度效用(数据或资源)导向的选择算法易造成指标失衡,如侧重数据质量可能导致通信成本激增,侧重资源优势可能牺牲模型精度;其三,现有机制普遍缺乏对恶意节点的有效识别与抑制能力,恶意节点通过投毒攻击等行为上传虚假模型参数,严重影响全局模型性能;其四,激励分配多采用静态策略,无法根据节点实时贡献动态调整,难以激发节点持续参与的积极性。近期研究开始关注恶意节点在多轮训练过程中的行为特征,例如 Ding 等人^[14]通过模型更新轨迹异常检测实现对交替式投毒的在线识别,但该类方法主要侧重检测阶段,尚未考虑与客户端选择及激励机制的协同设计。从研究目标与机制设计角度看,现有联邦学习方法可大致划分为三类:

1) 单目标优化方法:主要围绕模型精度或通信效率进行优化,如 FedAvg^[10]、FedProx^[11]等,其设计重点在于缓解数据异构性或系统延迟问题,但普遍缺乏针对恶意节点攻击与激励公平性的系统建模^{[15][16]}。

2) 双目标协同优化方法:在模型性能优化的同时引入客户端选择或激励机制,例如 QAIM^[17]、IAFL^[18]等,通过数据质量评估或静态激励提升训练可靠性,但往往将恶意节点防御与客户端选择、激励分配进行统一建模,相关机制^[17-19]多以独立或弱耦合方式设计。

3) 多目标联合建模方法:尝试在安全防御、资源利用与激励公平性之间进行综合权衡,但现有研究^[20-21]多集中于博弈建模或声誉机制,计算复杂度较高且缺乏面向跨设备大规模场景的轻量化设计。

综上,如何在保证计算复杂度可控的前提下,实现恶意节点识别、客户端选择与激励分配的协同优化,仍是联邦学习中的一项关键挑战。针对上述问题,本研究提出一种基于轻量贪心策略的动态联

邦恶意节点识别激励机制 (Greedy Incentive Federated Learning, GIFL),核心目标是实现“高效客户端选择-恶意节点精准识别-合理动态激励分配”的协同优化。与现有将客户端选择、恶意节点防御和激励机制作为相互独立模块分别设计的方法不同,GIFL 从系统运行流程角度出发,将客户端选择显式设计为恶意节点识别的前置轻量筛选步骤,并通过影响因子在识别与激励两个阶段之间建立统一状态变量,实现“筛选—识别—激励”的闭环协同。该设计避免了多目标联合建模带来的高复杂度问题,同时保证了恶意节点识别精度、系统效率与激励公平性的协同提升。本文通过 Fashion-MNIST 基础图像任务、CIFAR-10 中等复杂度图像任务及 Tiny-ImageNet 中高复杂度实景图像任务的多维实验验证,全面验证 GIFL 机制在不同数据复杂度下的有效性与通用性。

1 相关工作

1.1 联邦学习客户端选择算法研究

客户端选择是提升联邦学习效率的关键前置环节,现有研究主要围绕不同效用维度展开优化。基于数据效用的选择算法聚焦节点数据质量与分布特性,Hu 等人^[17]提出的 QAIM 机制通过评估节点训练损失和历史记录筛选高质量客户端,有效提升了模型精度,但未考虑通信与计算资源约束。基于资源效用的选择算法则侧重节点硬件性能与网络状态,Nishio 等人^[7]提出的客户端选择策略综合考量设备计算能力与通信带宽,降低了训练延迟,但忽视了数据异质性对模型性能的影响。联合数据与资源效用的选择算法试图实现多目标平衡,Li 等人^[12]提出 PyramidFL 框架通过细粒度评估节点数据价值与资源开销,筛选出效用最优的客户端集合,但未涉及恶意节点防御机制。此外,部分研究引入贪心想优化选择过程,Zeng 等人^[22]设计的多维度拍卖激励机制通过贪心策略选择出价合理且贡献潜力大的节点,但在大规模节点场景下计算复杂度较高。

近期研究开始系统性地分析客户端选择问题的公平性与效率权衡。Liu 等人^[15]对联邦学习客户端选择算法进行了系统综述,指出现有方法在异构性建模与计算复杂度控制方面仍存在不足。Li 等^[23]进一步从公平性角度出发,提出兼顾训练效率与节点参与公平的客户端选择策略,但未考虑恶意节点的干扰问题。总体而言,现有客户端选择算法多作为独立优化目标设计,未能与恶意节点识别形成有效

协调，且普遍存在计算复杂度偏高的问题。

1.2 联邦学习激励机制研究

联邦学习激励机制的核心是通过合理的报酬分配激发节点参与积极性，现有方案主要分为三类：基于数据贡献的激励机制、基于声誉的激励机制和基于资源的激励机制。基于数据贡献的激励机制通过评估节点数据对模型训练的贡献度分配奖励，Cai 等人^[24]提出的 QuoTa 机制采用反向拍卖模式，激励数据质量高、成本低的节点参与训练，但未考虑节点贡献的动态变化。Fei 等人^[19]提出了一种基于动态客户端选择的优化方法，在一定程度上缓解了数据质量退化对模型性能的影响，但其方法未考虑恶意节点行为对选择结果的干扰。基于声誉的激励机制通过构建节点声誉评价体系优化激励分配，Xiong 等人^[25]将声誉机制与反向拍卖相结合，通过多重声誉评估筛选可靠节点，但声誉更新存在滞后性，难以快速响应节点行为变化。基于资源的激励机制聚焦节点计算与通信资源的消耗补偿，Wang 等人^[26]通过 Stackelberg 博弈为节点分配训练与挖矿奖励，激励节点合理配置算力，但未充分考虑模型性能提升与资源消耗的匹配关系。

针对联邦学习中的激励问题，已有研究从博弈论与机制设计角度进行了深入探索^[27-28]。然而，多数激励机制仍采用静态或半静态策略，难以应对节点行为的动态变化。

1.3 联邦学习恶意节点防御研究

恶意节点攻击（如投毒攻击）是联邦学习面临的主要安全威胁，现有防御机制主要包括基于声誉的防御、基于模型验证的防御和基于异常检测的防御。基于声誉的防御机制通过积累节点历史行为评价识别恶意节点，Ahmed 等人^[29]提出的 FRIMFL 机制结合声誉与反向拍卖，有效筛选可靠节点，但对首次参与的恶意节点缺乏识别能力。Rashid 等人^[20]通过构建节点声誉共识与激励支付框架促进节点参与与公平性，但其机制主要依赖历史声誉信息，未显式将声誉评估与动态选择策略的协同优化纳入整体训练过程。基于模型验证的防御机制通过评估节点上传模型参数的有效性识别异常，Wu 等人^[18]提出的 IAFL 机制引入训练时模型奖励，鼓励节点上传真实模型参数，但未设计针对性的惩罚机制。基于异常检测的防御机制通过分析模型参数分布识别恶意更新，Penalva 等人^[21]提出的 RepuNet 系统通过声誉网络检测恶意节点，但在数据异构场景下误检率较高。此外，Parsa 等人^[30]提出的 FedLAW 通过

在训练过程中学习可解释的聚合权重，在存在拜占庭（投毒）客户端时自适应下调异常更新影响，从而提升鲁棒聚合效果，但该方法主要聚焦聚合鲁棒性，未将前置客户端筛选与激励分配纳入统一闭环。

所以，现有防御机制多独立于客户端选择流程，未能通过前置筛选降低识别成本，且识别精度与实时性难以兼顾。

2 GIFL 机制设计

2.1 系统架构

GIFL 机制面向移动边缘网络中的跨设备联邦学习场景，系统由基站（BS）和海量异构节点组成，整体流程如图 1 所示。



图 1 GIFL 机制系统架构

Fig.1 GIFL Mechanism System Architecture
系统工作流程如下：

1) 任务发布阶段：BS 发布联邦学习任务需求（包括模型结构、训练精度目标、预算约束等），初始化全局模型并广播给所有节点，同时设定初始影响因子阈值 $\kappa_{\text{threshold}}$ 、偏差阈值 δ 等核心参数；

2) 前置筛选阶段：节点根据自身资源状态（计算能力、通信带宽）与数据情况（数据量、数据质量）提交参与意愿，BS 通过轻量型贪心算法初步筛选出具有基本参与价值的节点集合 W_{init} ，减少后续计算开销；

3) 本地训练与模型上传阶段：初步筛选节点集合 W_{init} 中的节点下载全局模型，利用本地数据完成训练并上传模型参数，并将训练后的模型参数 w_n 上

传至 BS;

4) 恶意识别与模型聚合阶段: BS 首先计算各节点的更新偏差 χ_n , 通过影响因子动态更新机制识别并剔除恶意节点, 得到最终参与集合 W_{final} ; 随后采用精度加权聚合策略对最终参与集合 W_{final} 中的节点模型参数进行聚合, 生成新的全局模型 w^{t+1} 。

5) 报酬支付阶段: BS 根据节点历史与实时影响因子分配动态报酬, 完成一轮循环;

6) 迭代训练: 重复步骤 2-5, 直至全局模型精度达到预设目标或训练轮数达到上限。

2.2 轻量型贪心客户端选择策略

在本文中, 客户端选择并非作为独立的性能优化目标, 而是被设计为恶意节点识别的前置筛选步骤, 其核心目标是快速过滤掉资源消耗过高或贡献潜力极低的节点, 降低后续恶意识别的计算复杂度, 不追求最优选择效果, 重点保证筛选的轻量化与实时性。

2.2.1 简化效用评估

为避免引入复杂的多维效用建模, 本文采用简化的效用评估指标, 仅综合考虑节点的潜在参与价值与预估训练成本, 定义节点 n 的筛选评分为:

$$Score_n = \frac{\kappa_n^0 \cdot q_n}{C_n} \quad (1)$$

其中, κ_n^0 为节点 n 的初始影响因子, 用于刻画其在训练初期的潜在参与价值。 q_n 为节点 n 的本地数据量 (单位: 样本数); C_n 为节点 n 的预估训练成本。

1) 初始影响因子 κ_n^0 的计算

考虑到训练初期尚未积累节点的历史行为信息, 本文基于节点的可观测静态状态对其潜在参与价值进行估计, 包括本地数据量 q_n 、可用计算能力 f_n 以及可用通信带宽 r_n 。为消除量纲差异, 先对上述指标进行 Min-Max 归一化处理:

$$\tilde{x}_n = \frac{x_n - \min_{i \in H} x_i}{\max_{i \in H} x_i - \min_{i \in H} x_i + \varepsilon}, \quad (2)$$

$x \in \{q, f, r\}$

其中, H 表示候选节点集合, $\varepsilon = 1e-6$ 为防止分母为零的微小常数。在此基础上, 定义节点 n 的潜在价值得分:

$$u_n = \omega_q q_n + \omega_f f_n + \omega_r r_n, \quad (3)$$

$$\omega_q + \omega_f + \omega_r = 1$$

其中, $\omega_q, \omega_f, \omega_r$ 分别表示数据规模、计算能力与通信能力在初始价值评估中的权重。与本文的轻量化设计保持一致, 并避免对节点产生过强的先验偏置, 将 $u_n \in [0,1]$ 线性映射至区间 $[0.5,1.0]$, 从而得到初始影响因子 $\kappa_n^0 = 0.5 + 0.5 \cdot u_n$ 。

2) 预估训练成本 C_n 及成本系数的计算

为保证前置筛选阶段的轻量化与低复杂度实现, 本文采用由计算开销与通信开销构成的简化成本模型对节点训练成本进行估计:

$$C_n = \alpha \cdot q_n + \beta \cdot \frac{s}{r_n} \quad (4)$$

其中, α 为单位样本的计算成本系数, 用于刻画节点执行本地训练时的平均计算资源消耗; β 为单位通信时间成本系数; s 为模型参数规模; r_n 表示节点 n 的可用通信带宽。

未保证不同成本项之间的尺度可比性, 本文通过离线 profiling 的方式对成本系数进行标定。具体而言, 在系统部署环境中选取部分节点进行短时测试, 统计其平均计算时延 $\bar{T}_{cmp}$ 与平均通信时延 $\bar{T}_{com}$, 并据此设置:

$$\alpha = \frac{1}{\bar{T}_{cmp} + \varepsilon}, \quad \beta = \frac{1}{\bar{T}_{com} + \varepsilon} \quad (5)$$

该标定方式能够有效避免人为系数带来的尺度不一致问题。需要指出的是, 在前置筛选阶段, 预估训练成本主要用于节点的比较和排序, 其绝对取值不会影响算法整体决策逻辑。

综合上述评估流程, 节点筛选阶段的初始影响因子与预估训练成本均由服务器端统一计算。客户端仅上报必要的可观测状态信息, 不参与评分计算, 从而避免造假风险。初始影响因子仅用于前置轻量筛选的粗粒度评估, 不直接参与模型聚合或激励分配, 其主要作用是快速剔除明显低效节点, 对后续恶意节点识别与动态激励机制的影响有限。

2.2.2 快速筛选算法

算法流程以轻量化为核心, 避免复杂的边际效用计算, 直接根据筛选评分选择 Top-M 节点, 算法描述如下:

算法 1 轻量型贪心节点筛选算法

输入 候选节点集合 H 、初始影响因子 $\{\kappa_n^0\}$ 、数据量集合 $\{q_n\}$ 、预估成本集合 $\{C_n\}$ 、信道约束 M

输出 初步筛选节点集合 W_{init}

1. 初始化 $W_{init} = \emptyset$;
2. 对每个节点 $n \in H$ ，根据公式(1)计算筛选评分 $Score_n$;
3. 按 $Score_n$ 降序排列候选节点集合 H ，得到排序后的集合 H_{sorted} ;
4. 从 H_{sorted} 中选择前 M 个节点加入 W_{init} (若 $|H| < M$ ，则选择全部节点);
5. 返回 W_{init} 。

该算法计算复杂度为 $O(N \log N)$ (N 为候选节点数)，远低于传统贪心选择算法 (通常为 $O(N^2)$)，能快速完成前置筛选，为后续恶意节点识别节省计算资源。通过筛选评分的设计，可初步过滤掉“数据量少、成本高、初始信誉差”的节点，减少后续恶意识别的处理规模。

2.3 影响因子动态更新机制

2.3.1 更新偏差计算

影响因子更新的核心是识别节点模型参数的真实性与有效性，通过计算节点本地模型与全局模型的参数偏差实现。定义节点 n 的更新偏差 χ_n 为：

$$\chi_n = \frac{\|w_n - w^t\|_2}{\|w^t\|_2 + \varepsilon} \quad (6)$$

其中， w_n 为节点 n 上传的本地模型参数， w^t 为第 t 轮训练的全局模型参数， $\|\cdot\|_2$ 表示欧式范数， $\varepsilon = 1e-6$ 为防止分母为零的微小常数。采用归一化处理 (除以全局模型参数的欧式范数)，可避免因模型参数规模差异导致的偏差评估不准确问题。更新偏差 χ_n 越大，说明节点模型参数与全局方向偏差越显著，存在恶意攻击的概率越高。

2.3.2 影响因子更新规则

影响因子 k_n 综合反映节点的可靠性与贡献度，采用动态更新策略，实时追踪节点行为变化，计算公式为：

$$\kappa_n^{t+1} = \max(0, \kappa_n^t + \zeta \Phi(\chi_n^t)) \quad (7)$$

其中， κ_n^t 为节点 n 第 t 轮的影响因子， ζ 为更

新权重系数 (控制影响因子变化幅度，取值 0.05，通过敏感性实验确定)， $\Phi(\cdot)$ 为更新偏差转换函数，用于将参数偏差映射为影响因子的奖惩值；若 $\kappa_n^{t+1} < \kappa_{threshold}$ ，则剔除节点， $\kappa_{threshold}$ 为影响因子阈值。

转换函数 $\Phi(\chi)$ 根据更新偏差的不同区间设置差异化奖惩规则，实现恶意节点的精准识别与正常节点的正向激励：

$$\Phi(\chi) = \begin{cases} \frac{1}{a}, & 0 \leq \chi < \delta \\ 0, & \delta \leq \chi < 2\delta \\ -\frac{1}{2a}, & 2\delta \leq \chi < 3\delta \\ -\frac{1}{a}, & \chi \geq 3\delta \end{cases} \quad (8)$$

其中， δ 为预设偏差阈值 (根据数据集与模型类型自适应调整，Fashion-MNIST 数据集上取值 0.5，CIFAR-10 数据集上取值 0.6)； a 为归一化系数 (取值 5，确保影响因子在 $[0.3, 1.5]$ 区间内)。

各区间的物理意义如下：

- 1) 当 $0 \leq \chi < \delta$ 时，节点模型参数与全局方向高度一致，判定为正常节点，给予正向奖励，鼓励其持续参与；
- 2) 当 $\delta \leq \chi < 2\delta$ 时，节点模型参数存在轻微偏差，判定为可疑节点，暂不奖惩，持续观察其后续行为；
- 3) 当 $2\delta \leq \chi < 3\delta$ 时，节点模型参数偏差较大，判定为高风险节点，给予适度惩罚，降低其后续参与权重；
- 4) 当 $\chi \geq 3\delta$ 时，节点模型参数严重偏离全局方向，判定为恶意节点，给予重度惩罚，若影响因子低于 $\kappa_{threshold}$ ，则将节点从后续多轮训练中剔除。

2.4 动态报酬支付机制

为激励节点上传真实模型并持续参与训练，本文在影响因子评估结果的基础上设计了动态报酬支付策略，报酬分配与节点可靠性直接关联，通过动态调整节点收益，形成“可靠节点高报酬、恶意节点零报酬”的激励导向。节点 n 的第 t 轮的报酬 p_n^t 计算如公式(9)：

$$p_n^t = \frac{\kappa_n^t + \kappa_n^{t+1}}{2 \cdot \sum_{i \in W_{final}} (\kappa_i^t + \kappa_i^{t+1})} \cdot B \quad (9)$$

其中, B 为 BS 每轮训练的总预算, W_{final} 为剔除恶意节点后的最终参与集合, κ_n^t 和 κ_n^{t+1} 分别为节点 n 第 t 轮训练前后的影响因子, 取平均值可平衡节点历史可靠性与当前轮次表现, 避免单轮表现波动导致的报酬大幅变化。

2.4.1 个体理性与帕累托有效性证明

1) **个体理性**: 节点参与训练的报酬需覆盖其训练成本。对于正常节点, 其更新偏差 $\chi_n < \delta$, 根据公式(7)和(8), 影响因子非递减 ($\kappa_n^{t+1} > \kappa_n^t$), 因此 $\kappa_n^{t+1} + \kappa_n^t > 2\kappa_n^t$ 。由于总预算 B 满足 $B \geq \sum_{i \in W_{final}} C_i$

(BS 根据预估总成本设定预算), 且正常节点的影响因子占比不低于其成本占比

$$\left(\frac{\kappa_n^t + \kappa_n^{t+1}}{\sum_{i \in W_{final}} (\kappa_i^t + \kappa_i^{t+1})} \geq \frac{C_n}{\sum_{i \in W_{final}} C_i} \right), \text{ 可得 } p_n^t \geq C_n,$$

确保节点参与的净收益非负, 激发参与积极性。

2) **帕累托有效性**: 假设存在其他报酬分配方案 $\{p_n^i\}$, 使得部分节点效用提升而其他节点效用不降低。对于方案 $\{p_n^i\}$, 若存在节点 n^* 满足 $p_{n^*}^i > p_{n^*}^t$, 则需减少其他至少一个节点的报酬 (因总预算 B 固定), 导致该节点效用降低, 与帕累托最优定义矛盾。因此, 该支付策略满足帕累托有效性, 实现资源最优分配。

3 实验验证与分析

3.1 实验设置

实验采用 Fashion-MNIST^[31]、CIFAR-10^[32] 和 Tiny-ImageNet^[33] 三个公开数据集 (如图 2), 覆盖不同复杂度的图像分类任务, 确保实验结果的通用性:

1) **Fashion-MNIST**: 包含 10 类服装图像 (T 恤、裤子、外套等), 共 60000 张训练图和 10000 张测试图, 图像尺寸为 28×28 , 单通道灰度图, 数据分布相对均衡;

2) **CIFAR-10**: 包含 10 类自然图像 (飞机、汽车、鸟类等), 共 50000 张训练图和 10000 张测试图, 图像尺寸为 32×32 , 三通道彩色图。

3) **Tiny-ImageNet**: 包含 200 个类别、12 万张 64×64 三通道实景彩色图像 (动物、植物、日常物品、交通工具等), 共 100000 张训练图像, 10000

张验证图像和 10000 张测试图像, 单类别样本数量分布不均, 呈非独立同分布 (Non-IID) 特性。




图 2 图像数据集部分样本: 来自 CIFAR-10 (彩色图像)、Fashion-MNIST (灰度图像) 和 Tiny-ImageNet (实景图像)
Fig.2 Sample images from the datasets: CIFAR-10 (color images), Fashion-MNIST (grayscale images), and Tiny-ImageNet (real-scene images).

为模拟跨设备联邦学习中的非独立同分布 (Non-IID) 数据场景, 采用 Dirichlet 分布 ($\alpha = 0.5$) 将数据划分至 50 个客户端, 在 Fashion-MNIST 与 CIFAR-10 上, 每个客户端的数据量约为 800–1600 样本; 在 Tiny-ImageNet 上, 每个客户端的数据量约为 1600–2500 样本, 以匹配其更大的数据规模。恶意节点通过添加高斯噪声 ($\sigma^2 = 0.5$)、生成反向梯度更新或注入随机扰动模拟投毒攻击。模型结构方面, 在 Fashion-MNIST 上采用 AlexNet, 在 CIFAR-10 和 Tiny-ImageNet 上采用 ResNet-18。训练超参数在所有对比方法中保持一致: 优化器为 Adam, 初始学习率 0.001, 权重衰减 1×10^{-4} , 本地训练 5 个 epoch, batch size 设为 64, 总联邦训练轮数为 100, 且在全局更新后采用 $\gamma = 0.96$ 的学习率衰减策略。

联邦学习系统由 1 个基站 (BS) 与 50 个客户端组成, 恶意节点比例设置为 5%–30%, 步长为 5%。每轮训练的参与客户端数由 GIFL 的贪心前置筛选模块动态确定。对比方法包括 FedAvg^[10]、FedProx^[11]、QAIM^[17]、IAFL^[18]、FedLAW^[30]。其中, FedAvg(2017, AISTATS) 和 FedProx(2020, MLSys) 作为经典联邦学习基线方法, 用于验证算法在标准设置下的收敛性能; IAFL(2024, ICLR) 与 QAIM(2024, IEEE Internet Things J.) 分别代表近年来在联邦学习激励机制与质

量感知客户端选择方向上的代表性研究；FedLAW(2026, ICLR)则通过引入可学习的聚合权重，在存在恶意或异常客户端的情况下自适应抑制

模型更新对全局聚合结果的影响，体现了近年来联邦学习中面向拜占庭鲁棒聚合方向的研究进展。相关性能对比结果如表 1 所示。

表 1 各研究方法相关性能对比

方法	年份	期刊/会议	客户端选择策略	是否具有恶意防御	是否激励机制
FedAvg ^[10]	2017	AISTATS	随机选择	×	×
FedProx ^[11]	2020	MLSys	随机选择	×	×
QAIM ^[17]	2024	IEEE IOT-J	基于质量筛选	√	√
IAFL ^[18]	2024	ICLR	随机选择	×	√
FedLAW ^[30]	2026	ICLR	无显式选择	√	×
GIFL	This work	—	前置轻量筛选	√	√

GIFL 机制中的关键参数设置如下：节点初始影响因子范围为[0.5,1.0]，偏差阈值 δ 根据数据集复杂度自适应调整，在 Fashion-MNIST 上设为 0.5、在 CIFAR-10 上设为 0.6、在 Tiny-ImageNet 上设为 0.65；影响因子剔除阈值 $\kappa_{threshold}$ 统一设为 0.3；模拟通信带宽范围为 5–20Mbps；所有实验在相同的数据划分与随机种子条件下重复运行 10 次，实验结果取平均值。




图 3 影响因子更新权重分析

Fig.3 Analysis of updated weight of impact factors

为验证影响因子更新权重 ζ 的合理性，本文进一步开展参数敏感性实验，分析不同 ζ 取值对恶意节点抑制效果与正常节点误惩罚风险的影响。具体而言，在固定其余参数不变的条件下，逐步调整 $\zeta \in [0.01, 0.15]$ ，分别统计系统对恶意节点的抑制率以及正常节点被误惩罚的比例，实验结果如图 3 所示。

可以观察到，随着 ζ 的增大，恶意节点抑制率逐步提升，表明较大的更新权重有助于加快异常节点的识别与抑制；但同时，正常节点误惩罚率亦随之上升，说明过大的 ζ 会放大短期模型偏差对影响

因子更新的影响。综合权衡恶意节点抑制效果与系统稳定性，当 $\zeta = 0.05$ ，两者取得较为合理的折中，因此本文在后续实验中统一采用 $\zeta = 0.05$ 作为影响因子更新权重。




图 4 客户端选择阶段平均耗时对比

Fig.4 Comparison of average time consumption during client selection stage

3.2 实验结果与分析

3.2.1 前置筛选轻量化效果分析

客户端选择阶段的平均耗时对比如图 4 所示，所有数据均为 10 次独立重复实验的平均值，误差棒表示标准差。

各方法的筛选耗时随数据集复杂度提升呈合理梯度变化，综合三类数据集的平均结果，GIFL 的前置筛选平均耗时仅为 0.021s，远低于 QAIM(0.153s)，较 FedAvg(0.012s)仅增加 0.009s，实现了轻量化目标。GIFL 的筛选耗时较 QAIM 降低了 86.1%，这是得益于其简化的效用评估指标和快速排序策略，计算复杂度仅为 $O(N \log N)$ ，而 QAIM 需要计算节点的多维效用与边际贡献，计算复杂度为 $O(N^2)$ 。

从分数数据集表现来看, GIFL 在 Tiny-ImageNet 上的耗时为 0.024s, 较 Fashion-MNIST (0.019s) 仅增加 0.005s, 增幅远小于 IAFL 和 QAIM, 且标准差始终稳定在 0.003, 表现出良好的可扩展性与稳定性。FedLAW 的平均耗时为 0.023s, 介于随机选择与质量感知筛选方法之间, 但稳定性弱于 GIFL。

实验结果表明, GIFL 的轻量型贪心筛选算法在完成有效筛选的同时, 未引入显著计算开销, 且在中高复杂度实景场景下仍能保持低延迟与高稳定性, 有效提升了联邦学习系统的整体运行效率。

3.2.2 恶意节点识别精度对比




图 5 不同恶意节点比例下的识别精度对比

Fig.5 Comparison of recognition accuracy under different proportions of malicious nodes

不同恶意节点比例下的识别精度如图 5 所示。所有实验结果均为 10 次独立重复实验的平均值, 且覆盖 Fashion-MNIST、CIFAR-10 及 Tiny-ImageNet 三类数据集, 确保结果可靠且通用性。随着恶意节点比例增加, 各方法识别精度均呈下降趋势, 但 GIFL 始终保持最高精度。综合三类数据集平均结果, 在恶意节点比例为 5% 时, GIFL 的识别精度达到 94.5%, 较 FedAvg(70.6%)、IAFL(76.1%)、QAIM(83.6%) 和 FedLAW(87.5%) 分别提升约 23.9%、18.4%、10.9% 和 7.0%; 当比例升至 30% 时, GIFL 平均精度仍保持 84.3% 的识别精度, 而上述方法分别下降至 62.4%、67.6%、74.6% 和 78.9%, 对应提升 21.9%、16.7%、9.7% 和 5.4%。

进一步对比可知, FedLAW 通过鲁棒聚合在一定程度上抑制了异常更新, 其整体性能优于 QAIM 与 IAFL, 但受限于聚合阶段的被动防御, 其识别能力仍不及 GIFL。相比之下, GIFL 通过前置筛选与

影响因子动态更新机制, 对客户端更新偏差进行细粒度建模, 从而在高比例恶意节点场景下表现出更好的稳定性与鲁棒性。

3.2.3 模型收敛性能分析




图 6 模型收敛性能对比 (恶意节点比例 20%)

Fig.6 Comparison of model convergence performance (malicious ratio = 20%)

收敛性能对比如图 6 所示, 所有结果均为 10 次独立重复实验在 Fashion-MNIST、CIFAR-10 和 Tiny-ImageNet 三类数据集上的平均值。随着全局迭代轮次的增加, 各方法的模型精度整体提升、损失逐步下降, 但在收敛速度与稳定性方面差异显著。

FedAvg 与 FedProx 由于缺乏恶意节点防御机制, 在投毒场景下收敛波动较大, 最终精度分别为 68.9% 与 70.4%, 且损失在训练后期仍存在振荡。IAFL 通过静态激励机制提升了整体性能, 最终精度达到 80.5%, 但在训练中后期 (70 轮) 出现精度短暂回落、损失小幅回升的不稳定性。QAIM 基于历史损失进行客户端筛选, 提高了训练可靠性, 最终精度为 83.1%, 但收敛速度相对较慢, 模型性能需在约 80 轮后趋于稳定。FedLAW 通过引入可学习聚合权重增强了对异常更新的鲁棒性, 其收敛曲线较 QAIM 与 IAFL 更为平滑, 最终精度达到 85.3%, 但由于缺乏前置筛选与显式恶意节点剔除, 其整体性能仍略低于 GIFL。




图 7 GIFL 机制的消融实验结果对比（恶意节点比例为 20%）
Fig. 7 Ablation study results of the GIFL mechanism (malicious ratio = 20%)

相比之下，GIFL 在精度与损失两个指标上均表现出最优的收敛特性。GIFL 在第 50 轮迭代时精度已达到 65.7%，最终在第 100 轮取得 85.5% 的最高测试精度，较 FedAvg、FedProx、IAFL、QAIM 与 FedLAW 分别提升 16.6%、15.1%、5.0%、2.4% 和 0.2%，验证了其在投毒场景下的收敛效率与训练鲁棒性优势。

3.2.4 消融实验分析

为验证 GIFL 机制中前置轻量筛选、动态影响因子更新、动态报酬支付三大核心模块的必要性与协同效应，本文在保持实验设置、数据划分及超参数完全一致的条件下，设计模块移除变体（w/o 系列）与模块独立变体（only 系列），并以完整机制 GIFL-full 为基准，从模型测试精度、恶意节点识别准确率、归一化社会福利（由客户端训练报酬与服务器计算和通信成本共同决定，用于衡量系统激励效果与资源开销之间的综合性能）三方面展开消融实验。

从模块移除变体的收敛曲线（图 7(a-1) - (a-3)）与数据可见，GIFL-full 在全维度均保持最优表现：第 100 轮测试精度达 90.46%，恶意节点识别准确率为 0.968，归一化社会福利为 0.912，且收敛过程平稳。对比各消融变体，w/o dynamic IF 的性能退化最为显著：测试精度降至 86.77%（降幅 3.69%），识别准确率跌至 0.898（降幅 0.07），社会福利仅为 0.782，说明静态影响因子无法区分恶意节点投毒偏

差与正常节点非 IID 数据偏差，是模型性能衰减的核心瓶颈。w/o pre-screen 因缺少前置降噪，测试精度与识别准确率分别降至 87.95%、0.945，服务器成本上升导致社会福利降至 0.82；w/o dynamic pay 因静态报酬无法激励高质量节点参与，社会福利降幅最大（0.181），最终仅为 0.731。

进一步观察模块独立变体的结果（图 7(b-1) - (b-3)），单一模块的功能局限性被充分暴露：only dynamic IF 作为核心识别模块，最终测试精度 85.93%、识别准确率 0.903，虽优于 only pre-screen（80.21%、0.697）与 only dynamic pay（71.25%、0.651），但仍与 GIFL-full 存在 4.53% 的精度差距，且社会福利仅为 0.835；only pre-screen 仅能过滤低质节点，无法识别恶意攻击，模型收敛后精度停滞；only dynamic pay 无筛选与识别能力，激励机制基本失效，是性能最差的变体。

综上，GIFL 的优异性能源于三大模块的闭环协同：pre-screen 作为前置轻量化降噪环节，为 dynamic IF 降低计算成本与噪声干扰；dynamic IF 作为核心恶意识别模块，实时追踪节点偏差以保障模型聚合可靠性；dynamic pay 作为激励增益环节，动态分配收益以提升系统福利。任一模块的缺失或独立运行都会破坏这一协同机制，导致模型性能、防御能力或资源效率的显著退化，从实验层面验证了本机制设计的必要性与有效性。

3.2.5 社会福利与服务器成本分析

如图 8 所示。在恶意节点比例为 20% 的场景下，不同方法在社会福利与服务器成本两项指标上呈现出显著差异性。在社会福利方面，GIFL 的平均社会福利值达到 2405.3，显著高于 FedAvg(1676.1)、FedProx(1814.1)、IAFL(2113.4)和 QAIM(2212.7)，对应提升幅度分别为 43.5%、32.6%、13.8%和 8.7%。与引入鲁棒聚合的 FedLAW 相比，GIFL 仍保持约 4.5%的优势(2405.3 vs. 2301.1)。该结果表明，GIFL 通过前置筛选与动态激励的协同设计，能够在抑制恶意行为的同时，更有效地引导客户端进行高质量参与，从而提升整体效用。在服务器成本方面，GIFL 的平均服务器开销为 399.8，为所有方法中最低。相较 FedAvg、FedProx、IAFL、QAIM 和 FedLAW，服务器成本分别降低 27.0%、22.9%、16.4%、11.9%和 6.5%。其中，FedLAW 通过鲁棒聚合在一定程度上降低了无效更新带来的计算浪费，但由于缺乏前置筛选与显式恶意节点剔除，其成本控制能力仍不及 GIFL。




图 8 社会福利演化与服务器成本对比
Fig.8 Evolution of Social Welfare and Comparison of Server Costs

综合来看，GIFL 在实现最高社会福利的同时显著降低了服务器成本，体现出在个体收益激励与系统资源约束之间的良好权衡。该结果进一步验证了 GIFL 在存在恶意节点的移动边缘联邦学习场景中，具备更优的整体效率与实用价值。

3.2.6 实验结论

综合上述实验分析，可得出以下结论：1) GIFL 的恶意节点识别机制具有较高的精度，在不同恶意节点比例下均优于基准方法，能够有效抵御投毒攻击；2) 前置筛选步骤实现了轻量化设计，在快速过滤无效节点的同时，未引入显著计算开销，反而提升了整体系统效率；3) GIFL 在模型收敛速度、最终精度、社会福利和服务器成本等方面均表现优异，

实现了“恶意节点精准识别-高效资源利用-合理激励分配”的协同优化。从机制设计角度看，实验结果进一步验证了将客户端选择、恶意节点识别与激励分配进行协同建模，相比独立优化单一模块，更有利于提升联邦学习系统的整体鲁棒性与资源利用效率。

4 结束语

针对传统联邦学习在恶意节点防御能力不足和激励分配公平性有限的问题，本文提出了一种动态恶意节点识别的激励机制 GIFL。该机制通过前置轻量筛选、影响因子动态更新的恶意节点识别以及动态报酬支付策略，实现了模型性能、安全性与系统效率的协同优化。实验结果表明，GIFL 在识别精度、模型收敛、社会福利和服务器成本等方面均优于现有方法，验证了其在移动边缘网络场景下的有效性。

需要指出的是，本文所提出的动态奖惩机制主要基于模型更新一致性进行决策，在数据近似同构或弱异构场景下表现良好；在高度数据异构条件下，部分正常节点可能因数据分布差异而受到不利影响。未来工作将面向复杂异构环境，进一步研究异构感知的一致性度量与更具鲁棒性的激励机制设计，以提升方法的适用性与公平性。

参考文献

- [1] MCMAHAN H B, MOORE E, RAMAGE D, et al. Federated learning of deep networks using model averaging[J]. arXiv preprint arXiv:1602.05629, 2016, 2(2).
- [2] YANG Q, LIU Y, CHEN T, et al. Federated machine learning: Concept and applications[J]. ACM Transactions on Intelligent Systems and Technology (TIST), 2019, 10(2): 1-19.
- [3] LI Q, WEN Z, WU Z, et al. A survey on federated learning systems: Vision, hype and reality for data privacy and protection[J]. IEEE Transactions on Knowledge and Data Engineering, 2021, 35(4): 3347-3366.
- [4] 李少波, 杨磊, 李传江, 等. 联邦学习概述: 技术、应用及未来[J]. 计算机集成制造系统, 2022, 28(7): 2119-2138.
- [5] LI S B, YANG L, LI C J, et al. An Overview of Federated Learning: Techniques, Applications, and Future Directions[J]. Computer Integrated Manufacturing Systems, 2022, 28(7): 2119-2138. (in Chinese)
- [6] BONAWITZ K, EICHNER H, GRIESKAMP W, et al. Towards federated learning at scale: System design[J]. Proceedings of machine learning and systems, 2019, 1: 374-388.
- [7] LI X, HUANG K, YANG W, et al. On the convergence of fedavg on non-iid data[J]. arXiv preprint arXiv:1907.02189, 2019.
- [8] NISHIO T, YONETANI R. Client selection for federated learning with heterogeneous resources in mobile edge[C]//ICC 2019-2019 IEEE international conference

- on communications (ICC). IEEE, 2019: 1-7.
- [8] MACIEL F, DE SOUZA A M, BITTENCOURT L F, et al. Resource aware client selection for federated learning in iot scenarios[C]//2023 19th International Conference on Distributed Computing in Smart Systems and the Internet of Things (DCOSS-IoT). IEEE, 2023: 1-8.
 - [9] CHO Y J, WANG J, JOSHI G. Towards understanding biased client selection in federated learning[C]//International Conference on Artificial Intelligence and Statistics. PMLR, 2022: 10351-10375.
 - [10] MCMAHAN B, MOORE E, RAMAGE D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial intelligence and statistics. PMLR, 2017: 1273-1282.
 - [11] LI T, SAHU A K, ZAHEER M, et al. Federated optimization in heterogeneous networks[J]. Proceedings of Machine learning and systems, 2020, 2: 429-450.
 - [12] LI C, ZENG X, ZHANG M, et al. PyramidFL: A fine-grained client selection framework for efficient federated learning[C]//Proceedings of the 28th annual international conference on mobile computing and networking. 2022: 158-171.
 - [13] 张宇, 江海峰, 杨浩文, 等. 移动群智感知中基于联邦学习的参与者选择机制[J]. Application Research of Computers/Jisuanji Yingyong Yanjiu, 2023, 40(4).
ZHANG Y, JIANG H F, YANG H W, et al. Participant Selection Mechanism Based on Federated Learning in Mobile Crowd Sensing[J]. Application Research of Computers, 2023, 40(4). (in Chinese)
 - [14] DING Z, WANG W, LI X, et al. Identifying alternately poisoning attacks in federated learning online using trajectory anomaly detection method[J]. Scientific Reports, 2024, 14(1): 20269.
 - [15] SHANMUGARASA Y, PAIK H, KANHERE S S, et al. A systematic review of federated learning from clients' perspective: challenges and solutions[J]. Artificial Intelligence Review, 2023, 56(Suppl 2): 1773-1827.
 - [16] TAN J, LIU Z, GUO K, et al. Long-Term Client Selection for Federated Learning With Non-IID Data: A Truthful Auction Approach[J]. IEEE Internet of Things Journal, 2024.
 - [17] HU G, HAN J, LU J, et al. Game-Theoretic Design of Quality-Aware Incentive Mechanisms for Hierarchical Federated Learning[J]. IEEE Internet of Things Journal, 2024, 11(15): 26033-26045.
 - [18] WU Z, AMIRI M M, RASKAR R, et al. Incentive-aware federated learning with training-time model rewards[C]//The Twelfth International Conference on Learning Representations. 2024.
 - [19] FEI Q, RODRÍGUEZ-BARROSO N, LUZÓN M V, et al. Addressing Data Quality Decompensation in Federated Learning via Dynamic Client Selection[J]. arXiv preprint arXiv:2505.21219, 2025.
 - [20] RASHID M M, XIANG Y, UDDIN M P, et al. Trustworthy and fair federated learning via reputation-based consensus and adaptive incentives[J]. IEEE Transactions on Information Forensics and Security, 2025.
 - [21] PENALVA I M, BELTRÁN E T M, PÉREZ M G, et al. RepuNet: A Reputation System for Mitigating Malicious Clients in DFL[J]. arXiv preprint arXiv:2506.19892, 2025.
 - [22] ZENG R, ZHANG S, WANG J, et al. FMore: An incentive scheme of multi-dimensional auction for federated learning in MEC[C]//2020 IEEE 40th international conference on distributed computing systems (ICDCS). IEEE, 2020: 278-288.
 - [23] LI Q, MIAO J, ZHAO P, et al. Emulating full client participation: A long-term client selection strategy for federated learning[J]. arXiv e-prints, 2024: arXiv:2405.13584.
 - [24] CAI H, BIAN C, SHENG B, et al. QuoTa: An Online Quality-Aware Incentive Mechanism for Fast Federated Learning[J]. Applied Sciences, 2024, 14(2): 833.
 - [25] XIONG A, CHEN Y, CHEN H, et al. A truthful and reliable incentive mechanism for federated learning based on reputation mechanism and reverse auction[J]. Electronics, 2023, 12(3): 517.
 - [26] WANG Z, HU Q, LI R, et al. Incentive mechanism design for joint resource allocation in blockchain-based federated learning[J]. IEEE Transactions on Parallel and Distributed Systems, 2023, 34(5): 1536-1547.
 - [27] 贾云健, 黄宇, 梁靛, 等. 基于主从博弈的分层联邦学习激励机制研究[J]. 电子与信息学报, 2023, 45: 4.
JIA Y J, HUANG Y, LIANG L, et al. Research on a Hierarchical Federated Learning Incentive Mechanism Based on a Leader-Follower Game[J]. Journal of Electronics & Information Technology, 2023, 45(4). (in Chinese)
 - [28] LIM W Y B, LUONG N C, HOANG D T, et al. Federated learning in mobile edge networks: A comprehensive survey[J]. IEEE communications surveys & tutorials, 2020, 22(3): 2031-2063.
 - [29] AHMED A, CHOI B J. FRIMFL: A Fair and Reliable Incentive Mechanism in Federated Learning[J]. Electronics, 2023, 12(15): 3259.
 - [30] PARSA J, DAGHESTANI A H, TEIXEIRA A M H, et al. Byzantine-Robust Federated Learning with Learnable Aggregation Weights[J]//The Twelfth International Conference on Learning Representations. 2026.
 - [31] XIAO H, RASUL K, VOLLGRAF R. Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms[J]. arXiv preprint arXiv:1708.07747, 2017.
 - [32] KRIZHEVSKY A, HINTON G. Learning multiple layers of features from tiny images[J]. 2009.
 - [33] LE Y, YANG X. Tiny imagenet visual recognition challenge[J]. CS 231N, 2015, 7(7): 3.