



计算机应用  
*Journal of Computer Applications*  
ISSN 1001-9081, CN 51-1307/TP

## 《计算机应用》网络首发论文

题目：基于聚类评估的联邦学习投毒攻击防御算法  
作者：夏彬杰，缪祥华，刘义良，吕艳  
收稿日期：2025-11-19  
网络首发日期：2026-04-24  
引用格式：夏彬杰，缪祥华，刘义良，吕艳. 基于聚类评估的联邦学习投毒攻击防御算法[J/OL]. 计算机应用. <https://link.cnki.net/urlid/51.1307.TP.20260423.1920.004>



**网络首发：**在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认：**纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

# 基于聚类评估的联邦学习投毒攻击防御算法

夏彬杰<sup>1</sup>, 缪祥华<sup>1,2\*</sup>, 刘义良<sup>3</sup>, 吕艳<sup>1</sup>

(1.昆明理工大学 信息工程与自动化学院, 昆明 650500; 2.云南省计算机应用重点实验室 (昆明理工大学), 昆明 650500;

3.红河烟草(集团)有限责任公司 红河卷烟厂, 云南 弥勒 652300)

(\*通信作者电子邮箱 [xianghuamiao@126.com](mailto:xianghuamiao@126.com))

**摘要:** 为解决联邦学习中当存在不同数量以及较多恶意客户端时, 特别是非独立同分布(Non-IID)场景下, 全局模型性能损失严重的问题, 本文提出一种基于聚类评估的联邦学习投毒攻击防御算法 FedCE。首先利用余弦距离和曼哈顿距离剔除混合距离和最小的簇, 最大限度保留客户端信息; 随后结合上轮全局模型聚合参数和聚合客户端进行历史聚合信息评估筛选最优聚类结果; 最后通过四分位距法(IQR)统计各客户端异常梯度占比动态调整聚合权重, 提升全局模型的鲁棒性。实验结果表明, 在数据为非独立同分布(Non-IID)和恶意客户端比例为 40%时, 相较于 LASA 算法, FedCE 在 MNIST 数据集上对于 MinMax、Mimic、LabelFlipping、Neurotoxin 四种投毒攻击的模型准确率分别提升了 1.64、0.67、0.03 和 0.54 个百分点, 在 CIFAR10 数据集上模型准确率分别提升了 1.28、9.45、1.46 和 4.67 个百分点。在 2 个数据集的独立同分布和非独立同分布数据划分下, 面对不同比例的恶意客户端和类型的投毒攻击, FedCE 的模型准确率相比 5 个主流的防御算法都有明显的优势。

**关键词:** 联邦学习; 投毒攻击; 异常检测; 四分位距; 聚类评估**中图分类号:** TP309.2**文献标志码:** A

## Defense algorithm against poisoning attacks in federated learning based on clustering evaluation

XIA Binjie<sup>1</sup>, MIAO Xianghua<sup>1,2\*</sup>, LIU Yiliang<sup>3</sup>, LÜ Yan<sup>1</sup>

(1.Faculty of Information Engineering and Automation, Kunming University of Science and Technology, Kunming Yunnan 650500, China;

2.Yunnan Key Laboratory of Computer Technology Application(Kunming University of Technology), Kunming Yunnan 650500, China

3.Hongyun Honghe Tobacco(GROUP) Company Limited, Honghe Cigarettes Factory, Mile Yunnan 652300, China)

**Abstract:** In order to solve the problem of serious performance loss of global model when there are different numbers and more malicious clients in federated learning, especially in the scenario of Non-Independent and Identically Distributed (Non-IID) distributed data, a federated learning poisoning attack defense algorithm FedCE based on clustering evaluation is proposed. Firstly, the cosine distance and Manhattan distance are used to eliminate the cluster with the smallest sum of mixed distances, and the client information is retained to the greatest extent. Then, the historical aggregation information is evaluated and screened by combining the aggregation parameters of the last round of global model and the aggregation clients to select the optimal clustering results. Finally, the proportion of abnormal gradients of each client is calculated by the Interquartile Range (IQR) method, and the aggregation weight is dynamically adjusted to improve the robustness of the global model. The experimental results show that when the data is Non-Independent and Identically Distributed (Non-IID) and the proportion of malicious clients is high, compared with the LASA algorithm, the model accuracy of FedCE for MinMax, Mimic, LabelFlipping and Neurotoxin on the MNIST dataset is improved by 1.64, 0.67, 0.03 and 0.54 percentage points respectively, and the model accuracy on the CIFAR10 dataset is improved by 1.28, 9.45, 1.46 and 4.67 percentage points respectively. Under the independent identically distributed and non-independent identically distributed data partition of the two data sets, in the face of different proportions of malicious clients and types of poisoning attacks, the model accuracy of FedCE has obvious advantages over the five mainstream defense algorithms.

**Keywords:** federated learning; poisoning attack; anomaly detection; interquartile range; clustering evaluation

## 0 引言

随着人工智能和大数据的不断发展, 其相关技术已经在制造、医疗、交通等领域得以应用并产生了十分积极的影响,

收稿日期: 2025-11-19; 修回日期: 2026-03-29; 录用日期: 2026-04-08。

基金项目: 云南省重大专项计划项目(202302AD080002)。

**作者简介:** 夏彬杰(2001—), 男, 四川内江人, 硕士研究生, CCF 会员, 主要研究方向: 信息安全、联邦学习; 缪祥华(1972—), 男, 贵州盘县人, 副教授, 博士, 主要研究方向: 信息安全、网络安全、移动通信安全; 刘义良(1994—), 男, 云南石屏人, 助理工程师, 本科, 主要研究方向: 信息安全; 吕艳(1999—), 女, 四川南充人, 硕士研究生, 主要研究方向: 信息安全、联邦学习。

这背后少不了海量数据的驱动。但传统的集中式机器学习方式需要将不同设备的数据上传至中央服务器进行训练,这面临着通信效率低下、数据泄露以及数据孤岛等一系列问题<sup>[1]</sup>。为了解决这些问题,谷歌提出了联邦学习框架<sup>[2]</sup>,联邦学习作为一种分布式机器学习范式,允许多个设备或组织在不共享私有数据的情况下在本地训练数据,然后将训练参数上传至服务器协同训练机器学习模型<sup>[3]</sup>。该技术能有效利用不同用户间的分布式数据,同时保障隐私安全,被广泛应用于金融、智能驾驶、医疗健康等领域<sup>[4]</sup>。

当前联邦学习相关的研究指出,由于联邦学习的分布式特性,会存在恶意客户端干扰或破坏模型的正常训练过程<sup>[5]</sup>。投毒攻击就是联邦学习中比较常见的攻击方法,其可分为数据投毒<sup>[6-7]</sup>和模型投毒<sup>[8-9]</sup>。数据投毒大多为定向攻击,攻击者可通过向训练数据植入后门或者翻转训练数据标签的方式降低全局模型在部分任务的性能;模型投毒大多为非定向攻击,攻击者可通过篡改上传至中央服务器的模型参数或梯度的方式致使全局模型性能下降甚至无法收敛。因此,针对联邦学习中的投毒攻击进行防御,提高联邦学习系统的有效性和可靠性具有重要意义。

目前,为了缓解和消除投毒攻击对全局模型的影响,研究者已经提出了多种防御算法,其中针对客户端上传参数展开分析而设计防御算法的最为常见,这些防御算法出发点不乏有基于客户端参数贡献度找出异常参数<sup>[10]</sup>或基于客户端参数的几何中值,能在一定程度上缓解中毒攻击影响,但面对一些隐蔽攻击会被绕过规则导致训练不稳定;基于客户端整体或局部参数间的一致性<sup>[11]</sup>或差异制定一些鲁棒聚合规则,在面对较多恶意客户端时防御效果不佳;服务器维护着一小部分无污染的验证数据集<sup>[12]</sup>,这在实际场景中难以实现。针对联邦学习中常见投毒攻击特点以及目前防御算法的局限性,本文从客户端参数的多个角度为切入点,提出了一种基于聚类评估的投毒攻击防御算法 FedCE,该防御算法兼具异常检测和鲁棒聚合的特点,通过聚类评估优先剔除恶意客户端,消除其带来的影响,若评估失效仍然能够利用聚类交集客户端梯度作为基准,利用四分位距法(Interquartile Range, IQR)计算各客户端异常梯度占比动态调整聚合权重实现鲁棒聚合,极大程度减小投毒攻击影响。

本文的主要工作如下:

1) 利用多维空间特征协同的恶意客户端筛选方法,该方法基于 HDBSCAN(Hierarchical Density-Based Spatial Clustering of Applications with Noise)聚类使用曼哈顿距离捕捉客户端参数的空间差异,随后通过各个簇中客户端间的曼哈顿距离以及输出层的余弦距离的和,从客户端参数大小和方向角度准确有效地筛选恶意客户端,保留更多的客户端参数信息。

2) 根据历史聚合信息评估与决策机制,在利用历史聚合信息进行 K-means 聚类的基础上,基于聚类结果计算信任评分并与信任阈值进行比较,选择最优聚类簇的同时评估

并决策进行异常客户端剔除还是鲁棒聚合,提高模型训练的稳定性。

3) 利用动态权重调整策略,该策略以高置信度良性客户端梯度为基准,引入四分位距法计算客户端异常梯度数量占比调整聚合权重,自适应地施加权重惩罚与归一化调整,实现全局鲁棒聚合,增强系统的鲁棒性。

## 1 相关工作

### 1.1 联邦学习中的投毒攻击现状

投毒攻击按照目标的实现方式可分为数据投毒和模型投毒。数据投毒的实现可以是篡改数据标签和植入后门等<sup>[13-15]</sup>方式。模型投毒则更为直接,可以注入虚假客户端、修改参数符号和模拟正常客户端并扩大影响等<sup>[16-18]</sup>。

早期的投毒攻击实现较为单一,攻击特征容易被检测。例如 Tolpegin 等<sup>[19]</sup>提出的标签翻转攻击 LabelFlipping,通过直接的标签篡改诱导模型学习错误的判别边界。Shejwalkar 等<sup>[20]</sup>提出 MinMax 优化攻击,通过计算一个恶意梯度其他良性梯度更新的最大距离小于任何两个良性梯度更新之间的最大距离,并对其进行扰动来破坏模型性能;Sai 等<sup>[21]</sup>提出了 Mimic 攻击,攻击者复制一个特定的良性客户端更新,在弱化其他客户端更新的同时放大其影响力。

随着日益完善的检测机制和鲁棒聚合规则,投毒攻击也逐渐增强其隐蔽性和持久性。Zhang 等<sup>[22]</sup>提出的神经毒素攻击 Neurotoxin,该策略利用梯度掩码将恶意更新投射到全局模型中更新频率较低的坐标参数上,结合梯度范数裁剪机制防止模型被过度更新,有效维持后门攻击的持久性。Xie 等<sup>[23]</sup>提出了多轮一致性的模型投毒攻击 PoisonedFL,其直觉为随机方向被大幅度更新,模型准确率会急剧下降。攻击者会根据本轮参数与是上一轮全局参数的差异以及上轮提交的恶意参数,估算良性客户端更新的典型模式,进而调整恶意更新的幅度,使其在统计特性上接近良性更新,从而绕过基于异常检测的防御算法。这些恶意更新与良性客户端的更新进行聚合,从而使得全局模型在攻击者预设的随机方向上被逐步破坏。在提升后门隐蔽性上,Yang 等<sup>[24]</sup>提出了 FeatureTrojan 攻击。利用扩散生成模型,在干净输入的隐空间特征中嵌入动态触发器,并通过微调注入后门。这种特征级投毒使得恶意样本在视觉和特征空间上均与干净样本高度耦合,极大提升了攻击在各类现有防御检测下的生存率。

### 1.2 联邦学习中的投毒攻击防御现状

面对联邦学习系统所面临的中毒威胁,研究者已经从参数相似度、统计异质性、参数距离变化、基于历史纪录、参数裁剪以及贡献度等多个维度和视角提出了一系列防御策略,其大体可分为鲁棒聚合和异常检测两大类。

鲁棒聚合旨在减轻中毒攻击带来的影响。Yin 等<sup>[25]</sup>提出



的 Trimmed-Mean, 通过在每个参数维度上剔除极值将剩下的参数进行平均后作为该维度的聚合参数, 实现坐标级参数的稳健性。Cao 等<sup>[26]</sup>提出的 FLTrust 利用根数据集训练结果与客户端提交的梯度计算余弦相似度生成信任分数, 最后进行加权聚合得到最终的全局模型。Pillutla 等<sup>[27]</sup>提出的 RFA(Robust Federated Aggregation)算法, 服务器使用平滑 Weiszfeld 算法对客户端上传参数进行几轮迭代逐渐逼近到几何中值作为全局模型的聚合参数, 旨在构建一个稳健且更贴近多数更新的聚合向量, 从而增强对异常值的抗干扰能力。Nguyen 等<sup>[28]</sup>提出的 FLAME 方法进一步结合余弦距离聚类区别良性与恶意客户端, 并通过自适应噪声注入来净化全局模型。针对传统鲁棒聚合直接剔除异常参数导致中毒转移效应的致命缺陷, Liu 等<sup>[29]</sup>提出了 Produgal 防御框架。该方案通过 Top-K 梯度共识保留被投毒的离群参数并反向分发给攻击者, 从而有效阻断了恶意特征向良性坐标的转移渗透。

异常检测旨在分析客户端参数或梯度特征进而剔除恶意客户端。Huang 等<sup>[30]</sup>提出的 Multi-Metrics 算法结合余弦距离、曼哈顿距离以及欧氏距离作为指标计算客户端评分, 选取评分较高的一部分进行聚合, 过滤掉异常值的影响。Xu 等<sup>[31]</sup>提出了分层自适应稀疏化模型聚合方案 LASA(Layer-Adaptive Sparsified Model Aggregation), 在聚合前对每个客户端的更新进行稀疏化处理, 降低恶意参数的影响, 并最小化次要参数对后续过滤过程的干扰。基于稀疏化更新, 分层自适应过滤器会通过综合所有客户端的幅度和方向指标, 自适应选择良性网络层进行聚合。通过预聚合稀疏化与分层自适应聚合相结合以提升鲁棒性。Huang 等<sup>[32]</sup>提出的 Scope 算法通过维度归一化和差异化缩放来突出隐藏的后门特征, 主导梯度聚类算法利用余弦距离指标, 将恶意客户端的梯度从正常客户端的梯度中分离出来, 从而有效地检测和消除后门梯度。针对高级投毒攻击的隐蔽性与适应性, Chen 等<sup>[33]</sup>提出了 FLSDA 算法, 该方案不仅引入了梯度自适应稀疏化进行防御, 更结合了 HDBSCAN 聚类与动态权重调整, 实现了从冗余信息过滤到权重优化的协同防御。

上述这些方法能在一定程度上缓解投毒攻击的影响, 但存在大量恶意客户端时防御性能会大大降低, 并且在非独立同分布的数据分布下难以检测出恶意参数以及剔除恶意客户端。本文提出的 FedCE 方法对恶意客户端的检测以及缓解中毒带来的影响更加稳定和鲁棒, 同时相比于上述的防御算法更能实现安全性和时间开销的平衡。

## 2 预备知识

### 2.1 联邦学习

联邦学习是一种隐私保护下的分布式机器学习范式。假设系统中存在 1 个中央服务器和  $N$  个参与训练的客户端, 集合记为  $i = \{1, 2, \dots, N\}$ 。每个客户端  $i$  拥有本地私有数据集

$D_i$ , 其样本数量为  $n_i = |D_i|$ , 所有客户端本地数据量和为  $n$ 。联邦学习的核心目标是在数据不出本地的前提下, 联合所有客户端最小化全局损失函数  $F(w)$ :

$$\min_w F(w) = \sum_{i=1}^N \frac{n_i}{n} F_i(w) \quad (1)$$

其中  $w$  是模型参数,  $F_i(w)$  为客户端  $i$  在本地数据集  $D_i$  上的经验风险。在第  $t$  轮通信中 FL 的主要流程为: 服务器广播本轮全局模型参数  $w^t$  至选中客户端; 每个客户端利用  $D_i$  通过随机梯度下降(Stochastic Gradient Descent, SGD)等优化算法进行本地训练, 以最小化本地损失  $F_i(w)$ ; 客户端将训练更新后的本地模型参数  $w^{t+1}$  发送到中央服务器; 服务器聚合上传的全局模型参数并将聚合后的全局模型广播至参与训练的客户端。重复上述流程, 直至模型达到收敛条件。

服务器的核心是聚合算法, 会对全局模型的性能产生至关重要的影响。目前最为常见的聚合算法是联邦平均(Federated Averaging, FedAvg), 核心思想是根据各客户端参训的数据量对本地模型参数进行加权, 该算法聚合规则单一, 容易遭受攻击致使模型性能下降或模型无法正常收敛。联邦平均算法公式为:

$$w^{t+1} = \sum_{i=1}^N \frac{n_i}{n} w_i^{t+1} \quad (2)$$

### 2.2 聚类算法

K-means 算法是一种经典的基于划分的无监督学习方法, 旨在依据数据间的距离将数据划分为  $k$  个互不相交的簇, 使得每个簇内部的样本尽可能紧密, 而簇间的距离尽可能大。该算法通过迭代优化过程, 最小化簇内平方误差和, 核心公式为:

$$C = \sum_{j=1}^k \sum_{x_i \in c_j} \|x_i - \mu_j\|^2 \quad (3)$$

算法首先会随机初始化  $k$  个数据点作为质心, 随后计算每个数据点  $x_i$  到各个质心  $\mu_j$  的距离并将其划分到距离最近的簇, 然后根据新划分的数据集合, 重新计算每个簇的质心位置。算法重复上述步骤直至质心不再发生显著变化或达到预设的迭代次数。

HDBSCAN 是一种基于密度的聚类算法。该算法利用互达距离构建一个新的度量空间, 以增强对稀疏噪声的鲁棒性。互达距离定义为:

$$d_{\text{reach}}(a, b) = \max\{\text{core}_k(a), \text{core}_k(b), d(a, b)\} \quad (4)$$

其中,  $d(a, b)$  表示原始空间中的距离,  $\text{core}_k(a)$  表示数据点  $a$  到第  $k$  个最近邻的距离。通过这种度量变换, 低密度的噪声点被推离高密度区域。在聚类构建阶段, HDBSCAN 基于互达距离构建最小生成树, 并将其转化为层级聚类树,

其次还采用了一种基于簇稳定性的压缩策略，最后选择稳定性总和最大的簇，同时将稳定性低于阈值的点标记为噪声。

### 2.3 四分位距

四分位距是一种基于次序统计量的鲁棒离群点检测方法。该方法首先将数据按数值大小升序排列，四分位距  $IQR$  为第三四分位数  $Q_3$  减去第一四分位数  $Q_1$ ，其中  $IQR$  反映了数据主体部分的散布宽度，进一步可计算四分位数的下限  $lb = Q_1 - 1.5 * IQR$  以及上限  $up = Q_3 + 1.5 * IQR$ 。最后四分位距法将数据位于  $[lb, up]$  之间的被视为正常数据，位于  $[lb, up]$  之外的被视为异常数据。

## 3 方案设计

为有效解决联邦学习系统中不同数量以及较多恶意客户端影响全局模型准确率的问题，本文结合曼哈顿距离、余弦距离以及历史聚合信息利用聚类方法进行分析检测，确保训练的有效性和稳定性，即使在非独立同分布情况下面对复杂投毒攻击，统计客户端异常梯度占比调整聚合权重也能有效缓解投毒攻击影响，提升系统的鲁棒性。主要符号说明如表 1 所示。

表1 主要符号  
Tab. 1 Main symbols

| 参数                | 含义                              |
|-------------------|---------------------------------|
| $N$               | 客户端总数                           |
| $t$               | 第 $t$ 轮训练                       |
| $w_i^t$           | 客户端 $i$ 的模型参数                   |
| $w_{i,ol}^t$      | 客户端 $i$ 的输出层的模型参数               |
| $w_{agg}^{t-1}$   | 第 $t-1$ 轮的全局模型聚合参数              |
| $w_{diff}^t$      | 所有客户端参数与 $w_{agg}^{t-1}$ 的绝对偏移量 |
| $d_{mht}^{i,j}$   | 客户端 $i$ 与客户端 $j$ 模型参数的曼哈顿距离     |
| $d_{olcos}^{i,j}$ | 客户端 $i$ 与客户端 $j$ 模型输出层的余弦距离     |
| $M_{mht}$         | 由 $d_{mht}^{i,j}$ 构成的曼哈顿距离矩阵    |
| $M_{olcos}$       | 由 $d_{olcos}^{i,j}$ 构成的余弦距离矩阵   |
| $p$               | 距离权重                            |
| $d_{clu}$         | 混和距离                            |
| $C_h^t$           | HDBSCAN 聚类选取的客户集合               |
| $C_k^t$           | K-means 聚类选取的客户集合               |
| $C_{agg}^{t-1}$   | 第 $t-1$ 轮进行聚合的客户端集合             |
| $s_h^t$           | HDBSCAN 聚类结果的当前信任评分             |

|              |                     |
|--------------|---------------------|
| $s_k^t$      | K-means 聚类结果的当前信任评分 |
| $s_{hagg}^t$ | HDBSCAN 聚类结果的历史信任评分 |
| $s_{kagg}^t$ | K-means 聚类结果的历史信任评分 |
| $s_{th}$     | 信任阈值                |
| $g_i^t$      | 客户端 $i$ 的梯度         |
| $f$          | 异常梯度数量基准            |

### 3.1 威胁模型

在本文讨论的联邦学习系统中包含一个诚实可信的中央服务器，参与训练的客户端按照预先约定协议进行训练。客户端分为诚实可信的良性客户端和恶意客户端，良性客户端提交正常的客户端参数协助训练全局模型，恶意客户端意图提交恶意参数破坏全局模型的性能或阻止模型收敛，恶意客户端的数量不超过参与训练的客户端数量的一半。

攻击者目标：攻击者毒化联邦学习的训练过程，被毒化的全局模型具有较高的测试错误率或无法收敛。

攻击者能力：攻击者通过操控联邦学习中的多个客户端来干扰数据聚合过程。在每次迭代中，攻击者操控着被控制恶意客户端的完整训练数据和客户端梯度更新。

攻击者知识：攻击者知晓每轮服务器下发的全局模型参数，了解被控制恶意客户端的完整训练数据和客户端梯度更新，但对于服务器聚合算法和防御机制是不了解的。对于 Mimic 和 MinMax 攻击，攻击者需要知晓良性客户端的模型参数。

### 3.2 系统架构

本文提出的 FedCE 防御算法部署于联邦学习的中央服务器端，该算法摒弃了单一的距离度量与静态聚合规则，构建了一个多维度、包含历史聚合信息的鲁棒聚合架构。如图 1 所示，该系统架构主要由以下三个模块构成：

多维特征聚类与初筛模块。针对恶意攻击可能存在的量级放大与方向偏移，该模块同时提取模型参数的曼哈顿距离与输出层的余弦距离。在多维距离矩阵的基础上，利用 HDBSCAN 算法进行密度聚类。通过参照数量最小的簇，计算每个簇中各客户端间的混合距离和，实现从大小和方向的角度过滤有显著恶意特征的恶意客户端。

历史聚合信息评估与决策模块。针对非独立同分布(Non-Independent and Identically Distributed, Non-IID)数据的干扰，该模块首先计算客户端参数与上一轮全局聚合参数的绝对偏移量，并据此进行 K-means 状态划分。随后，针对两聚类结果进行评估，以两者交集为基准，计算当轮聚类信任评分以及上轮参与聚合的客户端交集计算历史聚类信任评分，最后信任评分求和与信任阈值比较决策是否开启动态权重调整策略。多维度确保系统高效用。




图1 FedCE 防御算法执行框架

Fig. 1 The execution framework of FedCE defense algorithm

动态权重调整模块。当触发调整策略时，该模块根据客户端异常梯度数量实施动态权重调整。以两聚类结果的交集作为高置信度的良性客户端集合，并引入四分位距法计算异常梯度的上下阈值，根据各客户端异常梯度数量占比调整聚合权重，从统计的角度极大降低恶意客户端的影响。

### 3.3 多维特征聚类与初筛

在联邦学习系统中，各客户端拥有的数据分布并不完全相同，特别是在 Non-IID 条件下，各类数据量不平衡，这使得存在恶意客户端通过缩放参数等方式进行伪装，服务器难以区分异常和正常参数。但是由于恶意客户端对参数的模仿、范数限制、距离优化等操作，使得恶意客户端具有一定共性，在客户端参数表现出较为相似的特点，因此利用曼哈顿距离能够很好捕捉高维变化信息这一特点进行聚类可以较好适配不同数量的恶意客户端。

在每一轮服务器在接收到客户端的参数信息后，首先计算参数间的空间变化矩阵：

$$\mathbf{M}_{\text{mht}} = \begin{bmatrix} 0 & d_{\text{mht}}^{1,2} & \cdots & d_{\text{mht}}^{1,n} \\ d_{\text{mht}}^{2,1} & 0 & \cdots & d_{\text{mht}}^{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ d_{\text{mht}}^{n,1} & d_{\text{mht}}^{n,2} & \cdots & 0 \end{bmatrix} \quad (5)$$

通过计算客户端输出层的余弦距离  $d_{\text{olcos}}^{i,j}$  可以得到一个余弦距离矩阵  $\mathbf{M}_{\text{olcos}}$ 。其中余弦距离计算公式如下：

$$d_{\text{olcos}}^{i,j} = 1 - \frac{\mathbf{w}_{i,\text{ol}}^t \cdot \mathbf{w}_{j,\text{ol}}^t}{\|\mathbf{w}_{i,\text{ol}}^t\| \|\mathbf{w}_{j,\text{ol}}^t\|} \quad (6)$$

对于式(6)中  $\|\cdot\|$  是计算参数的 L2 范数。输出层参数综合了输入层和所有神经网络的全部信息，包含丰富的类别信

息。所以可以通过输出层差异，发现良性与恶意客户端存在的方向特征。

恶意客户端在空间和方向上的较高的相似性使其更易成簇，并且相比于其余簇在大小和方向上更加紧密，单一距离度量难以检测。结合 HDBSCAN 对噪声和异常值鲁棒、可以发现不同密度实现自适应聚类等特点，利用曼哈顿距离进行聚类生成不同的簇  $clu$ 。以最小数量簇为基准计算各个簇的混合距离，混合距离的计算公式为：

$$d_{clu} = p * \sum_{i,j}^{i,j \in clu} d_{\text{mht}}^{i,j} + (1-p) * \sum_{i,j}^{i,j \in clu} d_{\text{olcos}}^{i,j} \quad (7)$$

式(7)中，对于每一个簇都会对簇内客户端间的曼哈顿距离以及输出层余弦距离求和，考虑到两类距离计算特点，对两类距离进行归一化并给予一定的权重，实现从大小和方向维度上平衡。由于恶意客户端较高的相似性，会将混合距离最小的簇去除，剩余客户端作为良性客户端进行下一步骤的评估。算法1详细描述了该筛选算法的流程。

算法1 多维特征聚类与初筛算法

输入：客户端模型参数  $w_i$ ，距离权重参数  $p$ 。

输出：良性客户端集合  $C_b$ 。

- 1)  $clusters \leftarrow \text{HDBSCAN}(\mathbf{M}_{\text{mht}})$  // 聚类得到簇
- 2)  $\text{minnum} \leftarrow \min(\text{len}(clusters))$  // 最小数量簇为基准
- 3) for  $cluster[\text{minnum}]$  in  $clusters$
- 4) 使用式(7)得到每个簇的混合距离
- 5) end for
- 6)  $C_b \leftarrow \text{del}(clusters[\min(d_{clu})])$  // 剔除混合距离最小的簇
- 7) return  $C_b$



在算法1中行1)利用曼哈顿距离矩阵进行HDBSCAN聚类,行2)得到簇最小数量作为基准统一各个簇计算数量,行3)~5)主要是利用每个簇的最小数量索引在矩阵中找到对应的值并进行加权得到各簇混合距离,行6)~7)在所有客户端索引中剔除最小混合距离的索引得到良性客户端索引并返回。

### 3.4 历史聚合信息评估与决策

对于单独使用HDBSCAN结合方向和大小的筛选方式在Non-IID以及面对复杂攻击时可能存在聚类不稳定的情况。可以利用历史聚合信息对该筛选机制可信度进行评估以及增强整体防御算法的泛化性。在质量评估机制中使用客户端参数与上一轮全局聚合参数的绝对偏移量进行K-means聚类将客户端分为两类,由于多数客户端为良性客户端,恶意客户端的目标是让整体模型偏离,由此可以选择多数客户端类作为良性客户端。绝对偏移量的计算公式为:

$$w_{diff}^t = |w^t - w_{agg}^{t-1}| \quad (8)$$

$w_{diff}^t$  包含了各客户端参数与全局聚合参数的偏离程度,进行聚类选取多数客户端得到  $C_k^t$ , 以进行后续的评估。

聚类结果的正交集可以得到高置信度客户端集合  $C_{b1}^t = C_h^t \cap C_k^t$ , 由此可以计算2个聚类结果的聚类信任评分,该信任评分用以评估此轮聚类结果的优劣,计算公式为:

$$s_h^t = \frac{|C_h^t \cap C_k^t|}{|C_h^t|}, s_k^t = \frac{|C_h^t \cap C_k^t|}{|C_k^t|} \quad (9)$$

但是仅使用当轮评分在两聚类结果有较大差别时二者的信任分会极大地偏向其中一方,无法达到平衡评估的效果,于是提出根据上一轮选取的良性客户端给予各聚类一定的历史聚类信任评分。各聚类良性客户端集合与上一轮聚合的客户端交集  $C_{hagg}^t = C_h^t \cap C_{agg}^{t-1}$ ,  $C_{kagg}^t = C_k^t \cap C_{agg}^{t-1}$ 。

通过式(9)的计算方式可以计算信任评分  $s_{hagg}^t$  以及  $s_{kagg}^t$  实现历史聚合学习维度评估。聚类质量评分  $s$  则是由上述的聚类信任评分等权重求和。

利用信任评分进行决策,选取聚类信任评分较高的聚类结果作为良性客户端,如果  $s$  达到设定的  $s_{th}$ , 则选取的良性客户端参数进行聚合训练;如果未达到评估阈值,则选取  $C_{b1}^t$  进行下一步的动态权重调整,由其实现坐标级参数与全局参数维度的平衡以及全局模型的效用。

#### 算法2 历史聚合信息评估与决策算法

输入: 客户端模型参数  $w_i$ , 信任阈值  $s_{th}$ , 上一轮全局聚合参数  $w_{agg}^{t-1}$ , 上一轮选取的聚合客户端  $C_{agg}^{t-1}$ , 算法1聚类结果  $C_h^t$ , K-means 聚类结果  $C_k^t$ 。

输出: 良性客户端集合  $C_f^t$ , 评估结果标志  $flag$ 。

- 1)  $C_k^t = \text{Kmeans}(w_{diff}^t, num\_cluster = 2)$
- 2) 通过式(9)计算各个聚类的信任评分  $s_h^t, s_k^t, s_{hagg}^t, s_{kagg}^t$
- 3) if  $s_h^t + s_{hagg}^t > s_k^t + s_{kagg}^t$  then
- 4)  $C_f^t = C_h^t$
- 5) else
- 6)  $C_f^t = C_k^t$
- 7) end if
- 8) if  $s \geq s_{th}$  then
- 9)  $flag = 1$
- 10) else
- 11)  $flag = 0, C_f^t = C_{b1}^t$
- 12) end if
- 13) return  $flag, C_f^t$

算法2主要利用历史聚合信息对不同角度的两种聚类方法结果进行评估,利用不同聚类的良性客户端集合取交集等方式求得当轮信任评分等进行评估,最后根据信任评分评估是否要执行算法3。

### 3.5 动态权重调整

动态权重调整算法以  $C_f^t$  集中客户端梯度为基准,使用四分位距法计算异常梯度的阈值,统计客户端异常梯度的数量动态调整聚合权重,缓解参数变化小等潜伏在良性集合中的客户端投毒带来的影响。

第  $t$  轮经过历史信息评估后,提取  $C_f^t$  中所有客户端的梯度参数,将其展平并拼接成一个一维的全局基准梯度向量  $V^t$ 。该基准向量  $V^t = \text{Concat}(\{g_i^t | i \in C_f^t\})$  包含了良性梯度的微观统计分布信息。为剥离极端异常值并确定鲁棒的参数边界,引入非参数化的四分位距法,根据IQR的统计学定义,可自适应地计算出异常梯度的容忍下界  $T_{lower}^t$  与上界  $T_{upper}^t$ , 若某个梯度坐标的值超出  $[T_{lower}^t, T_{upper}^t]$  这一安全区间,则该坐标被判定为异常梯度。

良性和恶意客户端的异常梯度数量有较为明显差异,因此高置信度客户端的梯度统计量可以作为调整权重的基准,其计算公式为:

$$f = \frac{1}{|C_f^t|} \sum_{i \in C_f^t} \sum_{j=1}^d \mathbb{I}_{i,j}^t \quad (10)$$

上式(10)中  $d$  表示模型梯度的维度,  $\mathbb{I}_{i,j}^t$  表示第  $t$  轮客户端  $i$  的第  $j$  个梯度为异常。

差异数量计算公式为:

$$b_i^t = \left| \left( \sum_{j=1}^d \mathbb{I}_{i,j}^t \right) - f \right| \quad (11)$$

上式(11)中 $|\cdot|$ 保证数量差为正,便于后续的归一化。

从统计的角度调整客户端聚合权重并进行归一化,异常梯度数量越多的客户端将获得更小的聚合权重,权重分配计算方式为:

$$Weight_i^t = \max \left( 0, \frac{2}{|C^t|} - \frac{b_i^t}{\sum_{j \in C^t} b_j^t} \right) \quad (12)$$

上式(12)中 $|C^t|$ 表示集合的基础即客户端总数, $\sum_{j \in C^t} b_j^t$ 表示所有参与聚合的客户端梯度绝对差异和并实现归一化, $2/|C^t|$ 是基础权重修正因子,确保数量差异越大所得的权重越小。本小节提出的动态权重调整如算法3所示。

算法3 动态权重调整算法

输入: 良性客户端集合  $C_{\text{f}}$ , 评估结果标志  $flag$ , 客户端梯度参数  $g_i$ , 所有客户端集合  $C^t$ 。

输出: 聚合权重  $Weight$ 。

1) if  $flag = 1$  then //执行动态参数裁剪策略

2)  $T_{\text{lower}}^t = Q_1 - 1.5 \times IQR$ ,  $T_{\text{upper}}^t = Q_1 + 1.5 \times IQR$

3) 通过式(10)(11)计算各客户端异常梯度数量

4)  $Weight_i^t = \max \left( 0, \frac{2}{|C^t|} - \frac{b_i^t}{\sum_{j \in C^t} b_j^t} \right)$  //调整聚合

权重

5)  $Weight.APPEND(weight_i^t)$

6) end if

7) return  $Weight$

算法3 实现在 Non-IID 数据分布以及复杂攻击环境下聚合效果差时仍具鲁棒性,以高置信度客户端梯度为基准,通过统计的视角根据客户端异常梯度的差异数量归一化计算差异占比调整聚合权重,降低中毒攻击的影响,提升整体模型性能。

## 4 实验及结果分析

### 4.1 实验设置

1) 实验环境。本实验所采用的实验设备为: Intel Core i5-12490F 处理器, 32 GB 内存, GPU 为 RTX4060, 操作系统为 Windows 10 64 位, 实验配置环境采用基于 Python 3.8 的 PyTorch 框架, Torch 版本为 2.0.1+cu118。

2) 数据集。实验使用了联邦学习中广泛应用的数据集: MNIST 和 CIFAR10。其中: MNIST 包含 0~9 的手写数字共 10 个类别的灰度图像的数据集, 图片尺寸大小为  $28 \times 28$ , 60000 张图像的作用训练集以及 10000 张图像用作测试集。对该数据集, 实验选择 LeNet-5 模型, 该模型由两层卷积层和三层全连接层组成, 包含池化层和 ReLU 激活层。

CIFAR10 包含了交通工具和动物共 10 个不同类别的彩色图像数据集, 图片尺寸为  $32 \times 32$ , 共有 50000 个训练集和 10000 个测试集。对于该数据集, 实验选择 resnet18 深度卷积模型, 该模型包含 1 个  $3 \times 3$  卷积核以及步长为 1 的卷积层(原结构是  $7 \times 7$  以及步长为 2 的卷积层)、16 个  $3 \times 3$  卷积层以及 1 个全连接层, 同时包含了最大池化以及平均池化层。数据集分别在独立同分布(Independent and Identically Distributed, IID)和 Non-IID 两种数据划分模式下进行实验。在 IID 设置下, 每个客户端的样本数量类别均匀分配; 而在 Non-IID 设置下, 采用基于迪利克雷分布的划分方法, 其超参数  $\alpha$  默认设置为 0.5。

3) 联邦学习设置。MNIST 数据集训练包含 50 个客户端, 每个客户端本地迭代 5 次, 全局迭代 200 轮, 初始学习率 0.01, 批量大小 64。CIFAR10 数据集包含 20 个客户端, 每个客户端本地迭代 3 次, 全局迭代 300 轮初始学习率 0.02, 批量大小 64。都使用随机梯度下降作为优化算法, 交叉熵损失作为损失函数, 学习率调整方式为 MultiStepLR, 分别在训练轮数的 0.5 和 0.8 阶段执行,  $\gamma$  值为 0.1。包含 1 个服务器, 采用 FedAvg 进行模型聚合, 所有攻击防御都会在 IID 和 Non-IID 设置下实验, 以评估各防御算法在不同环境设置下的防御性能。

4) 攻击设置与对比方法。本实验评估了四种投毒攻击。LabelFlipping 攻击, 攻击者将其本地数据集中的源标签 3 恶意篡改为目标标签 7, 旨在诱导全局模型产生后门误分类; Neurotoxin 攻击, 将梯度掩码比例设为 0.1, 结合范数裁剪阈值为 0.2 逃避常规检测; MinMax 攻击, 攻击者在最大化全局模型测试误差的同时, 约束恶意梯度与良性梯度的距离阈值设置为  $1e-5$ , 绕过基于距离的传统聚合规则; Mimic 攻击, 攻击者精确模仿特定良性节点客户端 0 的统计特征, 潜伏于良性簇中破坏模型收敛。

实验选取了五种常用的对比防御算法。RFA 算法利用平滑 Weiszfeld 算法计算近似几何中位数, 替代脆弱的算术平均; FLAME 算法利用 HDBSCAN 聚类与自适应噪声注入进行防御; Multi-Metrics 通过融合曼哈顿、欧氏与余弦三种距离动态识别异常梯度并选取良性客户端的防御方法; LASA 通过梯度稀疏化与层级自适应 MZ-score 的高维聚合防御方案; Scope 利用特征归一化与主导特征聚类检测客户端。实验设置在不同恶意客户端比例以及无攻击环境下综合评估防御性能。

5) 评价指标。为多维度衡量联邦学习系统在遭受不



同类型投毒攻击时的效用与安全性，本实验采用以下两项核心评价指标：模型准确率(Model Accuracy, MA)，是全局模型在干净、未受污染的测试集上正确分类样本的比例，投毒攻击的最终目的是破坏模型的收敛与泛化能力。因此，在受攻击环境下，防御算法所维持的 MA 越高，说明其保护全局模型效用的防御性能越好。攻击成功率 (Attack Success Rate, ASR)，为全局模型将带有恶意特征的样本，错误分类为攻击者指定的目标标签的比例。攻击者试图在不显著降低 MA 的前提下最大化 ASR。因此，在后门防御评估中，更低的 ASR

直接反映了防御算法有效阻断了恶意后门特征的植入。

4.2 实验结果与分析

4.2.1 无恶意客户端环境

为了检验各个防御算法在无恶意客户端环境的模型性能，本小节选择了 MNIST 和 CIFAR10 数据集的 IID 以及 Non-IID 环境下进行实验。




图2 无攻击环境下各方法在不同数据上的全局模型准确率曲线

Fig. 2 Global model accuracy curve of each method on different dataset in an attack-free environment

表2 无攻击环境下各方法在不同数据上的全局模型准确率 单位：%

| Tab. 2 Global model accuracy of each method on different dataset in an attack-free environment |         | unit: %      |       |       |               |       |       |       |
|------------------------------------------------------------------------------------------------|---------|--------------|-------|-------|---------------|-------|-------|-------|
| 数据集                                                                                            | 数据分布    | FedAvg       | RFA   | FLAME | Multi-Metrics | LASA  | Scope | FedCE |
| MNIST                                                                                          | IID     | <b>98.74</b> | 98.73 | 98.53 | 98.56         | 98.72 | 96.86 | 98.72 |
|                                                                                                | Non-IID | <b>98.54</b> | 98.50 | 98.12 | 97.88         | 98.41 | 96.24 | 98.49 |
| CIFAR10                                                                                        | IID     | 79.01        | 79.03 | 78.41 | <b>80.25</b>  | 79.18 | 77.85 | 79.26 |
|                                                                                                | Non-IID | <b>76.15</b> | 75.75 | 74.42 | 75.48         | 76.01 | 74.47 | 76.03 |

图 2(a)~图 2(d)展示了全局模型准确率变化曲线，从 MA 曲线可以看出，在无恶意客户端的情况下，本文算法与其余防御算法的变化趋势几乎一致且都能收敛。从表 2 展示的各算法在不同数据集和不同数据分布训练最后 20 轮的平均全局准确率可以看出，本文算法与基准 FedAvg 聚合方法的准确率基本一致。结果表明本文算法没有因筛选剔除客户端和

聚合权重动态调整对模型性能造成很大影响，有较好的效果。

4.2.2 恶意客户端环境

在本小节评估了 FedCE 在不同攻击下的防御效果。为了凸显各个防御算法在大量攻击者环境下的性能，在两个数据集下选取了更加符合真实环境的 Non-IID 数据分布情况以及四种投毒攻击都存在 40%恶意客户端的环境进行实验。结果

表明, FedCE 在两数据集下相较于其余防御算法具有相似甚至较高的 MA, 并且曲线变化较为稳定有较好的防御性能。

图 3(a)~图 3(d)展示了 MNIST 数据集在四种投毒攻击下各防御算法的全局模型准确率的变化情况。RFA 在多种投毒攻击下都具有较好的性能, 但在 MinMax 的优化攻击下, 多数恶意客户端的参数导致几何中心偏移, 部分恶意参数参与聚合导致收敛能力下降, MA 仅有 78.36%, 下降明显。FLAME 最初以余弦距离进行 HDBSCAN 聚类采用多数量的簇作为良性客户端, 在 Non-IID 以及较多恶意客户端环境下, 该方法在 MinMax 攻击下选取客户端中包含几乎所有的恶意客户端致使无法收敛, 后续的裁剪和加噪虽然缓解了 Mimic 以及 Neurotoxin 攻击的影响, 但这使得训练曲线波动以及收敛变慢且 MA 也有部分损失。Multi-Metrics 结合多个距离作为指标评分, 选取较小 topk 比例客户端聚合, 无法完美检测进行模仿操作的 Mimic 客户端, 并且过多的客户端过滤使得 MA 有所下降, 在 CIFAR10 数据集上 MA 下降明显。LASA 的分层权重聚合缓解中毒攻击的影响, 但较多的恶意客户端在 LabelFlipping 以及 Mimic 攻击下曲线较为波动, 从表 3 中可以看出 FedCE 在 MinMax、Mimic、LabelFlipping、Neurotoxin 四种投毒攻击下的 MA 分别比 LASA 高 1.64、0.67、0.03 和 0.54 个百分点, 虽然两防御算法的 MA 值相差不大, 但从曲线可以看出 LASA 防御算法遭受的中毒攻击影响明显。Scope

在数据不平衡环境下, 主导梯度聚类时选取客户端不稳定, 这造成训练过程波动较大, 收敛能力变差, 在 CIFAR10 数据集上的 Neurotoxin 攻击下甚至无法收敛。

图 4(a)~图 4(d)展示了 CIFAR10 数据集在四种投毒攻击下各防御算法的全局模型准确率的变化情况。CIFAR10 数据集上模型更加复杂, 异构数据集以及大量恶意客户端环境使得防御算法的检测和鲁棒聚合更加困难。RFA 仍然具有很好的防御性能, 甚至在 MinMax 攻击下的 MA 比 FedCE 高 1.39%。FLAME 由于初始聚类的不准确以及后续的裁剪以及加噪收敛性下降明显。LASA 具有较好的异常检测和分层鲁棒聚合能力, 但在幅度和符号过滤时由于 Mimic 攻击的相似性, 选取了较多恶意客户端聚合, 在检测 Neurotoxin 攻击时符号和幅度的不一致性导致剔除了较多的良性客户端使得收敛能力降低, 但分层聚合能够在一定程度上缓解中毒的影响。FedCE 在有 40% 恶意客户端时仍能有效地检测, 即使在参数扰动较小的 LabelFlipping 投毒攻击下也能通过聚合权重的调整进行鲁棒聚合, 降低其带来的影响。从表 3 中的展示中, 相较于 LASA 算法, FedCE 在 CIFAR10 数据集上在对应的四中投毒攻击下模型准确率分别提升了 1.28、9.45、1.46 和 4.67 个百分点, 并且 FedCE 在所设置的环境条件下与其余防御算法相比, MA 基本上都较高且曲线相对平稳, 能够保持模型具有较高的性能。




图3 各方法在 MNIST 数据集 Non-IID 分布下各攻击全局模型准确率曲线

Fig. 3 Accuracy curves of each method for each attack under the Non-IID distribution of the MNIST dataset




图4 各方法在 CIFAR10 数据集 Non-IID 分布下各攻击全局模型准确率曲线

Fig. 4 Accuracy curves of each method for each attack under the Non-IID distribution of the CIFAR10 dataset

表3 各方法在不同数据集 Non-IID 分布下各攻击 40% 恶意客户端的全局模型准确率 单位: %

Tab. 3 Global model accuracy of each method attacking 40% of malicious clients on different datasets with Non-IID distributions unit: %

| 防御算法          | MNIST        |              |               |              | CIFAR10      |              |               |              |
|---------------|--------------|--------------|---------------|--------------|--------------|--------------|---------------|--------------|
|               | MinMax       | Mimic        | LabelFlipping | Neurotoxin   | MinMax       | Mimic        | LabelFlipping | Neurotoxin   |
| RFA           | 78.36        | 97.16        | 98.04         | 97.73        | <b>73.01</b> | 68.04        | 73.72         | 68.87        |
| FLAME         | 11.35        | 95.42        | 98.21         | 96.63        | 65.91        | 55.80        | 59.76         | 57.39        |
| Multi-Metrics | 97.75        | 90.40        | 97.87         | 96.18        | 65.41        | 35.09        | 69.37         | 67.17        |
| LASA          | 96.71        | 97.70        | 98.22         | 97.82        | 70.34        | 61.66        | 74.38         | 66.36        |
| Scope         | 81.42        | 95.90        | 96.55         | 86.05        | 69.08        | 46.30        | 45.82         | 10.00        |
| FedCE         | <b>98.35</b> | <b>98.37</b> | <b>98.25</b>  | <b>98.36</b> | 71.62        | <b>71.11</b> | <b>75.84</b>  | <b>71.03</b> |

为了更加全面的评估本文算法的防御性能。在两个数据集的 IID 和 Non-IID 数据分布以及不同恶意客户端比例环境下对各个攻击和防御算法的模型性能(训练最后 20 轮平均全局准确率)进行实验比较。

图 5~图 8 展示了 IID、Non-IID 环境上各防御算法在面对各投毒攻击不同恶意客户端比例下的全局模型精度变化,从图中可以看出除 FedCE 外,其余防御算法随着恶意客户端比例的增加 MA 下降较为明显。由于 LabelFlipping 相比其余投毒攻击对模型参数影响较小,且 IID 环境下参数差异较小,在 MNIST 和 CIFAR10 数据集上 FedCE 分别相比于 RFA 和 LASA 的 MA 略低。RFA 随着恶意客户端比例的增加其平滑方向逐渐偏向于恶意参数从而 MA 逐渐降低。FLAME 首先

会进行 HDBSCAN 聚类将客户端分为两类,随着恶意客户端比例的增加聚类结果包含的恶意客户端也在增加,并且丢弃了部分良性客户端参数,即使在 Neurotoxin 攻击下检测出恶意客户端但是对于良性客户端参数的裁剪和加噪也使得 MA 有所降低。Multi-Metrics 是基于客户端参数间多种距离指标进行检测的,由于 Mimic 的攻击特性,随着恶意客户端比例的增加,该防御算法更加偏向于选取执行 Mimic 攻击的客户端,因此 MA 下降较为明显,并且由于选取参与聚合的客户端比例固定,即使检测出恶意客户端也因选取的客户端较少相比其余防御算法 MA 降低更多。LASA 对客户端每层参数的方向和大小进行检测选取客户端进行自适应层间聚合,随着恶意客户端比例的增加,基于方向和大小选取的交集客户端



变少会丢失部分包含重要信息的参数层,这也会造成训练过程的波动和不稳定。**Scope** 会根据距离指标较小的客户端梯度进行主导梯度聚类作为选取的良性客户端,随着恶意客户端比例的增加,当最初选取进行主导梯度聚类的客户端会恶意客户端时,选取的恶意客户端也会增加,最终 MA 下降甚

至在 **Neurotoxin** 攻击下出现无法收敛的情况。图 6 和图 8 展示了 **Non-IID** 数据分布下不同恶意客户端比例下的模型精度变化曲线,在参数差异较大的情况下, **RFA** 和 **LASA** 仍具有一定的鲁棒性,但 **FALME**、**Multi-Metrics** 和 **Scope** 则因此防御性能明显下降,MA 曲线变化明显。




图5 MNIST 数据集 IID 分布上不同攻击下恶意客户端比例对防御算法性能的影响

Fig. 5 Impact of the proportion of malicious clients under different attacks on the performance of defense algorithms on the IID distribution of the MNIST dataset




图6 MNIST 数据集 Non-IID 分布上不同攻击下恶意客户端比例对防御算法性能的影响

Fig. 6 Impact of the proportion of malicious clients under different attacks on the performance of defense algorithms on the Non-IID distribution of the MNIST dataset




图7 CIFAR10 数据集 IID 分布上不同攻击下恶意客户端比例对防御算法性能的影响

Fig. 7 Impact of the proportion of malicious clients under different attacks on the performance of defense algorithms on the IID distribution of the CIFAR10 dataset




图8 CIFAR10 数据集 Non-IID 分布上不同攻击下恶意客户端比例对防御算法性能的影响

Fig. 8 Impact of the proportion of malicious clients under different attacks on the performance of defense algorithms on the Non-IID distribution of the CIFAR10 dataset

以 LabelFlipping 攻击为例, 表 4 展示了各算法在不同比例恶意客户端攻击下的 ASR (最后 20 轮取平均)。从表中可以看出在 MNIST 数据集上各算法都有很低的 ASR, 即使存在 40% 恶意客户端 ASR 最高仅为 2.72%, 但从图 3(c) 中曲线可以看出 LASA 算法到训练末期曲线才趋于稳定, 其训练过程受攻击影响较大。对于更为复杂的 CIFAR10 数据集, 当恶意客户端未达到 40% 时, ASR 仅 FLAME 方法的 11.81% 和 Scope 方法的 17.53%、12.01% 超过 10%, 相较其余防御方法受 LabelFlipping 攻击影响造成一定程度的分类错误。当恶意

客户端达到 40% 时, 仅 RFA 未超过 10%, 但其余算法 ASR 保持在较低水平, 攻击未能主导模型。

FedCE 通过根据簇间的余弦距离和曼哈顿距离和剔除最小簇, 保留更多参数信息, 结合历史聚合信息评估确保聚类结果的稳定性, 即使一致性相差较大, 也能通过多类信息指标的聚类交集客户端作为基准动态调整聚合权重缓解中毒影响以及增加聚合信息, 基于恶意客户端参数的高度相似性比其余防御算法更能适应不同比例恶意客户端以及数据分布差异的场景。

表4 2 个数据集 Non-IID 分布上不同 LabelFlipping 恶意客户端比例下各防御算法 ASR 对比 单位: %

Tab. 4 Comparison of ASR for different defense algorithms on two datasets under Non-IID distributions with varying ratios of

LabelFlipping malicious clients unit: %

| 防御算法          | MNIST       |             |             |             | CIFAR10     |             |             |             |
|---------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|
|               | 10%         | 20%         | 30%         | 40%         | 10%         | 20%         | 30%         | 40%         |
| RFA           | 0.65        | 0.88        | 1.00        | 2.72        | <b>2.94</b> | <b>3.06</b> | <b>6.83</b> | <b>9.84</b> |
| FLAME         | 0.38        | 0.41        | 0.37        | 0.43        | 6.95        | 8.08        | 11.81       | 15.89       |
| Multi-Metrics | 0.37        | 0.32        | <b>0.25</b> | <b>0.29</b> | 4.79        | 7.71        | 7.53        | 16.28       |
| LASA          | 0.50        | 0.79        | 1.12        | 2.03        | 3.22        | 4.99        | 8.49        | 16.57       |
| Scope         | <b>0.15</b> | <b>0.20</b> | 0.36        | 0.52        | 9.20        | 17.53       | 12.01       | 10.81       |
| FedCE         | 0.45        | 0.67        | 0.71        | 1.83        | 3.66        | 4.01        | 7.00        | 14.94       |

#### 4.2.3 效率分析

本小节中对本文算法和其他防御算法进行效率实验。为验证客户端数量对各防御训练开销的影响, MNIST 数据集客户端数量分别 50、100, CIFAR10 数据集客户端数量分别。训练开销包含客户端本地训练时间和服务器传递参数的时间。FLAME、Multi-Metrics、Scope 和 FedCE 都需要计算成对距离, 计算复杂度为  $O(n^2d)$ , RFA 和 LASA 的计算复杂度为  $O(nd)$ , 其中  $n$  为客户端数量,  $d$  为参数维度。

在 CIFAR10 数据集上的时间开销则更为明显, 因为模型和数据集更加复杂, 参数量更多。从整体来看, RFA 和 FLAME 的单轮平均时间都较低, LASA 需要进行参数的大小和方向过滤后逐层聚合, 在模型层数较多时频繁的内存交换影响训练时间, 在客户端数量为 10 和 20 时相比 FedCE 分别高 0.07s/t

和 0.73s/t。FedCE 相比 Multi-Metrics 只计算了输出层的余弦距离, 且 Multi-Metrics 和 Scope 使用循环次数较多, 分别比 FedCE 高 25.61s/t 和 6.46s/t。本文方案时间开销相较于其余防御算法适中, 但具有更稳定的防御性能, 在一定程度上降低了时间开销。

表5 2 个数据集上不同客户端下各个算法的平均计算开销

Tab. 5 Average computational cost of each algorithm under different clients on two datasets

| 防御算法          | MNIST         |               | CIFAR10       |                |
|---------------|---------------|---------------|---------------|----------------|
|               | 50            | 100           | 10            | 20             |
| RFA           | 5.07 s        | <b>7.75 s</b> | <b>7.87 s</b> | <b>12.50 s</b> |
| FLAME         | <b>5.03 s</b> | 7.91 s        | 8.89 s        | 14.23 s        |
| Multi-Metrics | 5.18 s        | 8.76 s        | 14.08 s       | 43.65 s        |
| LASA          | 5.19 s        | 8.45 s        | 9.62 s        | 18.77 s        |
| Scope         | 5.27 s        | 8.27 s        | 13.02 s       | 24.50 s        |

|       |        |        |        |         |
|-------|--------|--------|--------|---------|
| FedCE | 5.14 s | 8.19 s | 9.55 s | 18.04 s |
|-------|--------|--------|--------|---------|

#### 4.2.4 消融实验

FedCE 算法包含多维特征聚类与初筛与历史聚合信息评估与决策, 根据评估结果决定是否进行动态调整聚合权重以减轻中毒影响。在本小节中将分析各个模块是如何影响算法性能的, 因此作出以下实验设置, A: 未应用 FedCE 的联邦学习; B: 只具备多维特征聚类与初筛模块; C: 只进行历史聚合信息评估; D: 只具备动态调整聚合权重; E: 在 B 基础上添加历史聚合信息评估与决策模块; F: 在 B 基础上添加动态调整聚合权重方法; G: 完整应用 FedCE 算法。以 Mimic 和 LabelFipping 作为攻击条件在两个数据集的全局准确率 (最后 20 轮取平均) 作为评估标准。

表6 消融实验结果

Tab. 6 Results of ablation experiments

| 消融方案 | MNIST(Non-IID) |              | CIFAR10(IID) |              |
|------|----------------|--------------|--------------|--------------|
|      | Mimic          | LabelFipping | Mimic        | LabelFipping |
| A    | 91.20          | 91.13        | 67.54        | 72.83        |
| B    | 98.35          | 97.29        | 75.48        | 76.34        |
| C    | 97.95          | 97.41        | 75.37        | 76.19        |
| D    | 97.38          | 97.84        | 73.94        | 76.95        |
| E    | 98.36          | 97.10        | 75.01        | 76.08        |
| F    | 98.24          | 97.85        | 74.67        | 77.03        |
| G    | <b>98.37</b>   | <b>98.25</b> | <b>75.86</b> | <b>77.44</b> |

通过表 6 的结果可以看到每一项方法相较方案 A 都有着一定的防御效果, 对于 Mimic 攻击, 检测方案基本优于鲁棒聚合方案, 但方案 E 评估不通过时会以少量客户端进行聚合损失精度, 相较方案 C, 方案 B 则是保留了更多的参数信息, 方案 F 相较方案 D 有基准而更有效。LabelFipping 攻击参数影响较小, 动态调整聚合权重相比于检测能够学习更多的信息, 方案 D 和 F 的 MA 相较方案 B、C 和 E 更高一些。方案 E 完整应用 FedCE 时获得了最佳的效果, 在 MNIST 以及 CIFAR10 数据集上都有着最高的 MA。

#### 4.2.5 参数分析

本小节探究多维特征聚类与初筛方法中的权重参数  $p$  以及基于历史聚类信息评估与决策的阈值参数  $s_{th}$  对 FedCE 防御算法整体性能的影响。较大的权重参数  $p$  和阈值参数  $s_{th}$  意味着方向上的余弦距离占比更小以及聚类过滤的一致性变强。为平衡模型的稳定性和鲁棒性, 能够防御不同的投毒攻击, 选取  $p$  的取值为  $\{0.3, 0.4, 0.5\}$  以及  $s_{th}$  的取值为  $\{0.6, 0.75, 0.9\}$ , 在 Mimic 攻击下不同数据集 Non-IID 数据分布环境下全局模型的准确率变化。

表7 不同参数组合下 MA 对比

Tab. 7 Comparison of MA under different parameters

| $p$ | $s_{th}$ | MNIST | CIFAR10 |
|-----|----------|-------|---------|
|-----|----------|-------|---------|

|     |      |               |               |
|-----|------|---------------|---------------|
| 0.3 | 0.6  | <b>98.373</b> | <b>71.106</b> |
| 0.3 | 0.75 | 98.170        | 66.711        |
| 0.3 | 0.9  | 97.965        | 68.048        |
| 0.4 | 0.6  | 98.274        | 69.859        |
| 0.4 | 0.75 | 98.061        | 68.460        |
| 0.4 | 0.9  | 97.855        | 68.558        |
| 0.5 | 0.6  | 98.269        | 70.335        |
| 0.5 | 0.75 | 98.067        | 69.177        |
| 0.5 | 0.9  | 97.866        | 67.421        |

表 7 展示了不同参数组合下全局模型的全局准确率。  $p$  的取值变化时, 阈值参数  $s_{th}$  为 0.6 时都具有较高的 MA, 随着  $s_{th}$  参数的变大, 检测一致性要求变高, FedCE 会执行聚合权重调整进行鲁棒性聚合, 在参数组合  $\{0.3, 0.75\}$  时初期能够剔除恶意客户端进行聚合, 但后续又执行鲁棒聚合导致聚合的不稳定, MA 较低。数据的异质性会使得良性和恶意客户端间的异常参数量减少, 缓解 Mimic 攻击影响相比于 IID 下会有所降低。权重参数  $p$  的增大会使曼哈顿距离占比增加, 这会让聚类结果保留部分恶意客户端或剔除部分良性客户端, 破坏历史信息评估的稳定性, 对全局模型的收敛能力造成不同程度的影响。综上分析, 参数  $p$  和  $s_{th}$  的取值不宜太大, 在  $p = 0.3$  和  $s_{th} = 0.6$  时表现最好。

## 5 结语

针对防御联邦学习中投毒攻击问题, 本文提出了一种基于聚类评估的投毒攻击防御算法 FedCE。本算法通过大小和方向指标剔除恶意客户端最大程度保留有效参数, 结合历史聚合信息进行评估确保训练过程的稳定性, 即使面对隐蔽性强的投毒攻击也能由动态聚合权重调整策略缓解影响。在 MNIST 和 CIFAR10 数据集的 IID 和 Non-IID 数据分布下的实验结果表明, 本文方法在不同比例恶意客户端的多种典型投毒攻击场景下均具备良好的防御能力, 保护和维持全局模型的性能。然而, 本文采用聚类的方法在大规模的客户端和高维模型下训练开销大, 未来需要进一步优化算法效率, 随着攻击角度和场景的演化, 未来将考虑改进本文方案以适应复杂和新型投毒攻击场景, 确保联邦学习系统的高效性和鲁棒性。

## 参考文献 (References)

- [1] Stripelis D, Ambite J L. Federated learning over harmonized data silos[C]//International Workshop on Health Intelligence. Cham: Springer Nature Switzerland, 2023: 27-41.
- [2] Konečný J, McMahan H B, Yu F X, et al. Federated learning: Strategies for improving communication efficiency [EB/OL]. (2016-10-18)[2026-03-25]. <https://arxiv.org/abs/1610.05492>.
- [3] Chen H, Zhu T, Zhang T, et al. Privacy and fairness in federated learning: On the perspective of tradeoff[J]. ACM Computing Surveys, 2023, 56(2): 1-37.

- [4] Mahon P, Chatzitheofilou I, Dekker A, et al. A federated learning system for precision oncology in Europe: DigiONE[J]. *nature medicine*, 2024, 30(2): 334-337.
- [5] Dong C, Weng J, Li M, et al. Privacy-preserving and Byzantine-robust federated learning[J]. *IEEE Transactions on Dependable and Secure Computing*, 2023, 21(2): 889-904.
- [6] 钟琪,张淑芬,张镇博,等.基于梯度特征的联邦学习后门防御算法[J/OL]. *计算机应用*, 1-14[2025-11-12].(Zhong Qi, Zhang Shufen, Zhang Zhenbo, et al. Federal learning backdoor defense algorithm based on gradient feature [J/OL]. *Journal of computer applications*, 1-14 [2025-11-12].).
- [7] Li Z, Lan J, Yan Z, et al. Backdoor attacks and defense mechanisms in federated learning: a survey[J]. *Information Fusion*, 2025, 123: 103248.
- [8] Zhang H, Liu Y, He X, et al. Sok: Benchmarking poisoning attacks and defenses in federated learning [EB/OL].(2025-02-06)[2026-03-25]. <https://arxiv.org/abs/2502.03801>.
- [9] 钟琪,张淑芬,张镇博,等.面向联邦学习的投毒攻击检测与防御机制[J]. *计算机应用*, 2026, 46(02): 445-457.(Zhong Qi, Zhang Shufen, Zhang Zhenbo, et al. Federal Learning-oriented Poisoning Attack Detection and Defense Mechanism [J]. *Journal of computer applications*, 2026, 46(02): 445-457.).
- [10] 蒋伟进,杨璇,李碧霞.基于可解释贡献异常检测与动态裁剪的联邦学习投毒攻击防御方法[J]. *计算机学报*, 2025, 48(12): 2855-2874.(Jiang Weijin, Yang Xuan, Li Bixia. Federal Learning Poisoning Attack Defense Method Based on Explainable Contribution Anomaly Detection and Dynamic Clipping [J]. *Journal of Computer Science*, 2025, 48(12): 2855-2874.).
- [11] Wang N, Zhang C, Xiao Y, et al. FLARE: Defending Federated Learning Against Model Poisoning Attacks Via Latent Space Representations[J]. *IEEE Transactions on Dependable and Secure Computing*, 2025, 22(3): 2607-2623.
- [12] Ali Y, Han K H, Majeed A, et al. An Optimal Two-Step Approach for Defense Against Poisoning Attacks in Federated Learning[J]. *IEEE Access*, 2025.
- [13] Hao L, Hao K, Wei B, et al. Multi-target federated backdoor attack based on feature aggregation[J]. *Pattern Recognition*, 2025: 112333.
- [14] 陈学斌,任志强,张宏扬.联邦学习中的安全威胁与防御措施综述[J]. *计算机应用*, 2024, 44(6): 1663-1672.(CHEN XB, REN Z Q, ZHANG H Y. Review on security threats and defense measures in federated learning[J]. *Journal of computer applications*, 2024, 44(6): 1663-1672.).
- [15] Zhang C, Sun S, Tu J, et al. Clean-label backdoor attack via sample-customized feature alignment[J]. *Expert Systems with Applications*, 2025: 129481.
- [16] Feng Y, Guo Y, Hou Y, et al. A survey of security threats in federated learning[J]. *Complex & Intelligent Systems*, 2025, 11(2): 165.
- [17] Yang H, Gu D, He J. A robust and efficient federated learning algorithm against adaptive model poisoning attacks[J]. *IEEE Internet of Things Journal*, 2024, 11(9): 16289-16302.
- [18] 乐紫莹,陈珂,寿黎但,等.基于梯度放大的联邦学习激励欺诈攻击与防御[J]. *软件学报*, 2025, 36(05): 2254-2269.(Le Ziying, Chen Ke, Shou Lidan, etc. Federated Learning Encourage Fraud Attack and Defense Based on Gradient Amplification [J]. *Journal of Software*, 2025, 36(05): 2254-2269.).
- [19] Tolpegin V, Truex S, Gursoy M E, et al. Data poisoning attacks against federated learning systems[C]//European symposium on research in computer security. Cham: Springer International Publishing, 2020: 480-501.
- [20] Shejwalkar V, Houmansadr A. Manipulating the byzantine: Optimizing model poisoning attacks and defenses for federated learning[C]//NDSS. 2021.
- [21] Karimireddy S P, He L, Jaggi M. Byzantine-Robust Learning on Heterogeneous Datasets via Bucketing[C]//International Conference on Learning Representations. 2022.
- [22] Zhang Z, Panda A, Song L, et al. Neurotoxin: Durable backdoors in federated learning[C]//International conference on machine learning. PMLR, 2022: 26429-26446.
- [23] Xie Y, Fang M, Gong N Z. Model poisoning attacks to federated learning via multi-round consistency[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 15454-15463.
- [24] Yang R, Sun Q, Cao H, et al. FeatureTrojan: Boosting stealthy and steady backdoor attacks with feature poisoning and fine-tuning injection[J]. *Neural Networks*, 2026: 108717.
- [25] Yin D, Chen Y, Kannan R, et al. Byzantine-robust distributed learning: Towards optimal statistical rates[C]//International conference on machine learning. Pmlr, 2018: 5650-5659.
- [26] Cao X, Fang M, Liu J, et al. FLTrust: Byzantine-robust Federated Learning via Trust Bootstrapping[C]//Proceedings of NDSS. 2021.
- [27] Pillutla K, Kakade S M, Harchaoui Z. Robust aggregation for federated learning[J]. *IEEE Transactions on Signal Processing*, 2022, 70: 1142-1154.
- [28] Nguyen T D, Rieger P, Chen H, et al. {FLAME}: Taming backdoors in federated learning[C]//31st USENIX Security Symposium (USENIX Security 22). 2022: 1415-1432.
- [29] Liu G, Lin W, Huang T, et al. Prodigal: Backdoor Defense for Federated Learning beyond Robust Aggregation[J]. *Knowledge-Based Systems*, 2025: 114903.
- [30] Huang S, Li Y, Chen C, et al. Multi-metrics adaptively identifies backdoors in federated learning[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 4652-4662.
- [31] Xu J, Zhang Z, Hu R. Achieving byzantine-resilient federated learning via layer-adaptive sparsified model aggregation[C]//2025 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). IEEE, 2025: 1508-1517.
- [32] Huang S, Li Y, Yan X, et al. Scope: On Detecting Constrained Backdoor Attacks in Federated Learning[J]. *IEEE Transactions on Information Forensics and Security*, 2025, 20: 3302-3315.
- [33] Chen Y, Gao H, Wang H, et al. FLSDA: A synergistic defense against backdoor attacks in federated learning[J]. *Information Sciences*, 2025: 122974.
- [34] McMahan B, Moore E, Ramage D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial intelligence and statistics. PMLR, 2017: 1273-1282.

**This work is partially supported by the Yunnan Province Major Special Project (202302AD080002).**

**XIA Binjie**, born in 2001, M. S. candidate. His research interests include information security, federated learning.

**MIAO Xianghua**, born in 1972, Ph. D., associate professor. His research interests include information security, network security, mobile communication security.

**LIU Yiliang**, born in 1994, B. S., assistant engineer. His research interests include information security.

**LV Yan**, born in 1999, M. S. candidate. Her research interests include information security, federated learning.