

引用格式: 孙恩昌, 杨一凡. 基于增量梯度相似度更新的联邦学习多样化客户端选择方法 [J]. 北京工业大学学报, 2026, 52(5): 561-568.
SUN E C, YANG Y F. Diverse client selection method for federated learning based on incremental gradient similarity update [J]. Journal of Beijing University of Technology, 2026, 52(5): 561-568. (in Chinese)

基于增量梯度相似度更新的联邦学习多样化客户端选择方法

孙恩昌^{1,2}, 杨一凡¹

(1. 北京工业大学信息科学技术学院, 北京 100124; 2. 北京工业大学北京-都柏林国际学院, 北京 100124)

摘 要: 为降低联邦学习多样化客户端选择方法 (diverse client selection method for federated learning, DivFL) 在大规模联邦学习中维护梯度相似度矩阵的计算开销, 提出一种基于增量梯度相似度更新的联邦学习多样化客户端选择方法 IS-DivFL, 通过为每个客户端构建梯度摘要, 并仅对梯度变化量超过阈值的客户端所对应的相似度矩阵进行更新, 有效降低了相似度矩阵维护阶段的复杂度。实验结果表明: IS-DivFL 能够保持与 DivFL 相当的测试精度与方差水平, 同时在 100 ~ 1 000 个客户端规模下, IS-DivFL 在相似度维护阶段的平均运行时间相较于 DivFL 减少 50% ~ 70%。综上, IS-DivFL 为大规模联邦学习中的多样化客户端选择提供了一种兼顾模型性能与降低计算开销的方法。

关键词: 联邦学习; 客户端选择; 计算开销; 梯度相似度; 梯度摘要; 相似度矩阵更新

中图分类号: TP 181

文献标志码: A

文章编号: 0254-0037(2026)05-0561-08

doi: 10.11936/bjutxb2025110023

Diverse Client Selection Method for Federated Learning Based on Incremental Gradient Similarity Update

SUN Enchang^{1,2}, YANG Yifan¹

(1. School of Information Science and Technology, Beijing University of Technology, Beijing 100124, China;

2. Beijing-Dublin International College, Beijing University of Technology, Beijing 100124, China)

Abstract: To reduce the computational overhead of maintaining the gradient-similarity matrix in the diverse client selection method for federated learning (DivFL) in large-scale federated learning, an incremental gradient similarity update-based diverse client selection method, termed IS-DivFL, is proposed. Specifically, IS-DivFL constructs a gradient summary for each client and updates the similarity matrix only for clients whose gradient changes exceed a predefined threshold, thereby reducing the complexity of the similarity-maintenance stage. Experimental results show that IS-DivFL achieves test accuracy and variance comparable to those of DivFL, while reducing the average running time of similarity maintenance by 50% - 70% relative to DivFL when the number of clients ranges from 100 to 1 000. Overall, IS-DivFL offers an effective solution for diverse client selection in large-scale federated learning, balancing model performance with reduced computational overhead.

收稿日期: 2025-11-26; **修回日期:** 2025-12-28

基金项目: 国家自然科学基金资助项目 (62371014; 62371012)

作者简介: 孙恩昌 (1977—), 男, 副教授, 主要从事无线通信与网络、区块链、联邦学习、深度学习方面的研究, E-mail: ecsun@bjut.edu.cn

Key words: federated learning; client selection; computational overhead; gradient similarity; gradient summary; similarity matrix update

联邦学习^[1]通过在终端侧本地训练并交换模型参数或梯度,实现跨设备数据协同建模,在隐私保护与通信开销控制之间取得了良好的平衡。然而,在真实部署场景中,终端设备数量往往巨大,终端算力与网络条件高度异构,并且各客户端持有的数据分布之间的差异具有统计学意义^[2]。如果每一轮都让全部客户端参与训练,不仅会造成巨大的通信与计算负担,还可能引入更多无效或冗余更新,甚至由于低质量连接或噪声数据的反复参与而降低训练稳定性与最终模型泛化能力。因此,在每一轮训练过程中,从大量可用客户端中智能选择一个合适的子集,使其能够兼顾效率、稳定性与模型性能,已成为联邦学习系统设计中的关键环节之一。

现有客户端选择方法可大致分为 3 类:均匀随机采样、基于性能指标的启发式选择及基于子模优化的多样性驱动选择^[3-5]。均匀随机采样实现简单、易于工程部署,并在客户端分布相对均匀时能够提供较稳健的基线性能,但在统计异质性较强时往往难以保证所选子集能够覆盖多样的数据分布,从而可能带来收敛变慢或不同客户端表现差异增大的问题^[6-7]。基于损失、时延等指标的方法可以在一定程度上优先选择困难样本更多或训练效率更高的客户端^[8],但其选择准则通常是局部的、单指标驱动的,容易在效率优先与信息多样性之间失衡,忽略全局多样性结构。近期提出的联邦学习多样化客户端选择方法(diverse client selection method for federated learning, DivFL)^[9]通过构造基于梯度相似度的子模函数^[10],将所有客户端两两之间的梯度距离构造一个相似度矩阵,并以该矩阵为输入优化多样性目标函数,从而在保证全局模型精度的同时提升所选客户端子集的多样性^[11-12]。然而,这类方法需要频繁维护梯度相似度矩阵,在每个更新周期重新计算所有客户端间的成对距离,计算开销较大,在客户端规模增大时成为系统瓶颈。

针对上述问题,本文在 DivFL 的基础上提出一种基于增量梯度相似度更新的联邦学习多样化客户端选择方法 IS-DivFL。该方法在保留子模优化框架的前提下,通过在每个更新周期仅对梯度变化量超过阈值的客户端进行相似度更新,其余客户端沿用历史相似度,降低了相似度维护阶段的

复杂度,并通过实验验证了在所述任务上的有效性与可扩展性。

1 系统模型与问题描述

本文提出的联邦学习系统模型如图 1 所示。




图 1 联邦学习系统模型

Fig. 1 Federated learning system model

系统包含 N 个客户端,第 i 个客户端持有本地数据集 D_i 。在聚合阶段,服务器采用经典的联邦平均(federated averaging, FedAvg)策略更新全局模型参数。记第 t 轮的全局模型参数为 $w^{(t)}$,本轮被选中的客户端集合为 S_t ,客户端 i 的本地样本数为 n_i ,其在完成本地训练后的模型参数为 $w_i^{(t+1)}$,则 FedAvg 的聚合规则可写为

$$w^{(t+1)} = \sum_{i \in S_t} \frac{n_i}{\sum_{i \in S_t} n_i} w_i^{(t+1)} \quad (1)$$

式中 $w^{(t+1)}$ 即为新的全局模型。在此基础上,本文在服务器侧引入客户端选择模块,通过维护每个客户端的梯度摘要衡量相邻轮次之间的梯度变化量,并对相似度矩阵进行增量更新来构造子模目标函数,从而在每一轮选择具有代表性的客户端子集 S_t 参与训练。客户端侧仅负责本地数据上的

梯度计算与模型更新,整体通信流程与标准联邦学习框架保持一致。

1.1 联邦学习与客户端选择问题

考虑典型的联邦学习场景,记客户端集合为 $C = \{1, 2, \dots, N\}$, 样本数量为 $|D_i|$ 。联邦学习的目标是最小化全局经验风险,公式为

$$\min_w F(w) = \sum_{i=1}^N p_i F_i(w) p_i = \frac{\sum_{i=1}^N |D_i|}{\sum_{j=1}^N |D_j|} \quad (2)$$

式中: $F_i(w)$ 为客户端 i 在本地数据上的损失函数; p_i 为客户端权重,通常按样本占比确定权重。由于通信与计算资源受限,每一轮仅从 C 中选择一个子集 $S \subseteq C$ 参与训练,并采用 FedAvg 聚合策略更新全局模型。本文将每轮允许参与训练的客户端最大数量称为客户端选择预算,记为 B 。在给定 B 的前提下,如何设计合理的选择策略生成 S ,是本文关注的核心问题。

1.2 基于梯度相似度的子模客户端选择框架 DivFL

在联邦学习中,每一轮训练需要从大量候选客户端中选出一个子集,既要保证全局模型的收敛效率,又希望兼顾数据多样性与训练公平性。DivFL 的核心思想是:将客户端两两之间的梯度相似度构成一个 $N \times N$ 的相似度矩阵 D ,然后构造一个子模目标函数,在给定预算约束 $|S| \leq B$ 下,通过贪心算法选出更具代表性的客户端集合。

具体地,记本轮共有 N 个候选客户端,每个客户端 i 在当前轮的梯度向量记为 g_i 。通过欧氏距离可以得到客户端之间的梯度相似度,公式为

$$d(i, j) = \|g_i - g_j\|_2, i, j = 1, 2, \dots, N \quad (3)$$

在服务器端构造一个 $N \times N$ 的梯度相似度矩阵 D ,公式为

$$D = [d(i, j)]_{N \times N} \quad (4)$$

进一步,DivFL 将客户端选择问题抽象为子模最大化问题,可以表示为

$$F(S) = \sum_{i \in C} \max_{j \in S} d(i, j), \text{ s. t. } |S| \leq B \quad (5)$$

式中: $F(S)$ 为定义在客户端子集 S 上的子模目标函数,其函数值用来刻画所选客户端集合 S 对候选客户端集合 C 的多样性覆盖能力; $d(i, j)$ 可以理解为客户端 i 与客户端 j 之间的差异度,对每一个(未必被选中的)客户端 i ,只关心它与集合 S 中最不相似的那个客户端的距离 $\max_{j \in S} d(i, j)$,再对所有客户端求和。若集合 S 中的客户端彼此过于相似,则很多

客户端都会被同一个代表覆盖,整体目标函数 $F(S)$ 较小;若 S 中的客户端分布各异,则每个客户端都能在 S 中找到一个与自己差异较大的代表,使得 $\max_{j \in S} d(i, j)$ 的和更大。

从数学性质上看,上述目标函数 F 是定义在客户端子集上的子模函数。设 V 为所有候选客户端组成的集合,则 $F: 2^V \rightarrow \mathbb{R}$ 表示函数 F 的定义域为 V 的幂集,即对 V 的任意子集 $S \subseteq V$,都对应一个实数函数值 $F(S)$ 。对于任意满足 $A \subseteq E \subseteq V$ 及 $e \in V$ 且 $e \notin E$ 的集合 A, E 及元素 e ,若有

$$F(A \cup \{e\}) - F(A) \geq F(E \cup \{e\}) - F(E) \quad (6)$$

则称 F 具有子模性,即随着集合从 A 扩展到 E ,同一元素 e 带来的边际收益呈递减趋势,正是由于这种子模结构,带预算约束的最大化问题 $\max_{|S| \leq B} F(S)$ 可以采用贪心算法获得具有近似比 $(1 - 1/e)$ 的解,从空集开始,在每一步选择当前能够带来最大边际增益的客户端加入 S ,直至达到预算约束。该结论最早可追溯至 Nemhauser 等^[3]关于子模最大化的研究,后续 Conforti 等^[4]以及 Fujishige^[5]也对这一结果进行了系统论述。DivFL 及本文提出的 IS-DivFL 均利用这一性质,在保证多样性的同时获得较好的理论与实践性,但是,DivFL 运用上述子模选择框架的前提是:服务器在每个相似度更新周期维护了一个完整的梯度相似度矩阵 D ,其中包含所有 N 个客户端之间的两两距离。设每个梯度向量的维度为 d ,则任意一对客户端的距离计算复杂度为 $O(d)$,而不同客户端共有 $N(N-1)/2$ 对。因此,单次完整更新该矩阵所需的计算复杂度为

$$O(N(N-1)d/2) = O(N^2d) \quad (7)$$

当客户端规模从几十扩展到数百甚至上千时,该阶段将成为整体系统的主要计算瓶颈。

2 IS-DivFL

为了降低相似度维护阶段的复杂度,本文提出 IS-DivFL,在保持 DivFL 原有子模目标函数和贪心选择策略不变的前提下,重构了服务器端相似度矩阵的维护方式。

IS-DivFL 的核心思想是:不再每次更新都重新计算所有客户端之间的相似度,而是为每个客户端定义一个平滑的梯度代表量,称为梯度摘要,并基于连续 2 轮梯度摘要之间的变化定义梯度变化量,只对梯度变化量超过设定阈值 τ 的少数客户端所对应的相似度矩阵的行/列进行更新,其余客户端之间的

相似度则沿用上一轮的计算结果。

2.1 梯度摘要的定义与作用

在 DivFL 中,每次相似度更新周期都直接使用当前轮梯度 $g_i^{(t)}$ 计算客户端之间的相似度,历史轮次的梯度信息不会保留。这样做虽然简单,但是一方面容易受到单轮噪声梯度的影响,另一方面也难以利用多轮梯度信息得到稳定可靠的梯度统计量。

为此,本文定义每个客户端 i 在第 t 轮的梯度摘要为 $\hat{g}_i^{(t)}$,通过指数滑动平均累计历轮梯度,公式为

$$\hat{g}_i^{(t)} = \alpha \hat{g}_i^{(t-1)} + (1 - \alpha) g_i^{(t)} \quad (8)$$

式中: $g_i^{(t)}$ 为第 t 轮本地训练得到的原始梯度向量; $\hat{g}_i^{(t-1)}$ 为上一轮梯度摘要; $\alpha \in (0, 1)$ 为指数滑动平均(exponential moving average, EMA)因子,用于控制历史梯度与当前梯度的相对权重。在实践中, α 通常取接近 1 的较大值,如 0.70、0.90、0.99 等。当 α 较大时, $\hat{g}_i^{(t)}$ 更接近多轮梯度的加权平均,有助于削弱单轮随机波动的影响;当 α 较小时, $\hat{g}_i^{(t)}$ 更接近当前轮梯度,对轮次间的局部变化更加敏感。具体数值依赖于任务噪声水平和模型规模,本文在实验部分将给出具体设定(见 3.2 节)。

将式(8)展开可以得到

$$\hat{g}_i^{(t)} = (1 - \alpha) (g_i^{(1)} + \alpha g_i^{(2)} + \cdots + \alpha^{t-1} g_i^{(t)}) + \alpha^t \hat{g}_i^{(0)} \quad (9)$$

初始化令 $\hat{g}_i^{(0)} = 0$,将式(9)写成求和形式,公式为

$$\hat{g}_i^{(t)} = (1 - \alpha) \sum_{k=0}^{t-1} \alpha^k g_i^{(t-k)} \quad (10)$$

由式(10)可以看出, $\hat{g}_i^{(t)}$ 等价于对历次梯度按指数权重进行加权求和,因此, $\hat{g}_i^{(t)}$ 可以被视为客户端 i 在历史多轮训练过程中的代表性梯度,比仅使用单轮梯度更稳健,噪声更小。IS-DivFL 在相似度计算阶段不再直接使用原始梯度,而是用梯度摘要替代,公式为

$$d^{(t)}(i, j) = \|\hat{g}_i^{(t)} - \hat{g}_j^{(t)}\|_2 \quad (11)$$

因此,梯度摘要能够平滑单轮噪声,提高相似度计算的稳定,并为后续基于梯度变化量的筛选机制提供较为平滑的参考基准。

2.2 梯度变化量

IS-DivFL 的关键在于:每个更新周期仅对梯度变化量超过预设阈值 τ 的客户端进行相似度更新。

为此,本文基于梯度摘要定义客户端 i 在第 t 轮的梯度变化量为

$$\Delta_i^{(t)} = \|\hat{g}_i^{(t)} - \hat{g}_i^{(t-1)}\|_2 \quad (12)$$

式中 $\Delta_i^{(t)}$ 为客户端 i 的梯度变化量,即相邻 2 轮梯度摘要之间的欧氏距离。若 $\Delta_i^{(t)}$ 较大,说明其梯度摘要在相邻 2 轮之间发生了显著变化,相应地,其与其他客户端的梯度相似度也更可能发生明显变化,因此,在相似度矩阵增量维护阶段优先更新这部分行/列。基于梯度变化量,构造在当前更新周期内需要进行相似度更新的候选客户端集合 $C^{(t)}$,公式为

$$C^{(t)} = \{i \in S^{(t)} \mid \Delta_i^{(t)} > \tau\} \quad (13)$$

式中: $S^{(t)}$ 为第 t 轮真正参与训练的客户端集合; $\tau > 0$ 为梯度变化量阈值。服务器在随后的相似度维护阶段仅对集合 $C^{(t)}$ 中的客户端重新计算其与其他客户端之间的相似度,并更新相似度矩阵对应的行/列,其余客户端的相似度沿用上一轮的结果,由此将相似度维护开销集中在变化较大的客户端子集上。

2.3 与子模选择框架的结合

在定义了梯度摘要与梯度变化量之后,IS-DivFL 需要在不改变 DivFL 原有子模目标函数与贪心选择策略的前提下,重构相似度矩阵维护阶段的具体流程。在第 t 轮训练中,IS-DivFL 在服务器端执行以下步骤。

1) 梯度摘要更新:服务器收集各客户端上传的原始梯度 $g_i^{(t)}$,并利用式(10)对所有客户端的梯度摘要进行更新。

2) 梯度变化量与候选集合构造:服务器对每个客户端计算梯度变化量 $\Delta_i^{(t)} = \|\hat{g}_i^{(t)} - \hat{g}_i^{(t-1)}\|_2$,并根据阈值 τ 构造候选客户端集合 $C^{(t)}$ 。

3) 相似度矩阵的增量更新:记上一轮的相似度矩阵为 $D^{(t-1)}$,在本轮更新时,IS-DivFL 仅对 $C^{(t)}$ 中的客户端所对应的相似度矩阵进行更新,对任意的 $i \in C^{(t)}$,令

$$D_{ij}^{(t)} = \|\hat{g}_i^{(t)} - \hat{g}_j^{(t)}\|_2, j = 1, 2, \cdots, N \quad (14)$$

并同步更新第 i 行与第 j 列;对于不在 $C^{(t)}$ 中的客户端对 (p, q) ,则直接沿用上一轮结果,公式为

$$D_{pq}^{(t)} = D_{pq}^{(t-1)}, p \notin C^{(t)}, q \notin C^{(t)} \quad (15)$$

这样得到的 $D^{(t)}$ 就是一个增量维护的相似度矩阵,即在梯度变化量较小的客户端上,服务器保留上一轮得到的相似度矩阵,对于梯度变化量超过阈值的客户端,则利用当前轮的梯度摘要更新其在相似度矩阵中对应的行/列。

4) 基于子模目标函数进行贪心选择: 在获得最新的相似度矩阵 $D^{(t)}$ 后, IS-DivFL 在客户端选择阶段沿用 DivFL 的子模目标函数和贪心算法, 即仍以 $F(S) = \sum_{i \in C} \max_{j \in S} d(i, j)$ 作为优化目标, 在预算约束 $|S| \leq B$ 下, 从空集开始迭代选择边际增益最大的客户端加入 S , 直至选出 B 个客户端。

2.4 相似度维护阶段的复杂度分析

在 DivFL 中, 服务器在每个相似度更新周期都需要基于所有客户端的梯度向量更新完整的 $N \times N$ 相似度矩阵, DivFL 单次更新相似度矩阵的时间复杂度为 $O(N^2 d)$, d 为维护梯度。

在 IS-DivFL 中, 服务器首先根据梯度变化量筛选出候选客户端集合 $C^{(t)}$, 记其规模为 $M_t = |C^{(t)}|$ 。由于只有本轮实际参与训练的客户端才会上传新的梯度向量, 因此, $C^{(t)}$ 始终是参与训练集合 $S^{(t)}$ 的子集, 即

$$M_t \leq |S^{(t)}| \leq B \quad (16)$$

在每个相似度更新周期内, 服务器仅对 $i \in C^{(t)}$ 的客户端重新计算其与所有 N 个客户端之间的距离, 并更新相似度矩阵对应的行/列, 因此, 第 t 次相似度更新的时间复杂度为 $O(M_t N d)$, 客户端选择阶段的预算为 B , 故 IS-DivFL 在相似度维护阶段的时间复杂度上界可写为

$$O(M_t N d) \leq O(B N d) \quad (17)$$

因此, IS-DivFL 相较于 DivFL 在相似度维护阶段的时间复杂度由 $O(N^2 d)$ 降低为 $O(B N d)$ 。当 $B \ll N$ 时, 可以减少服务器在该阶段的运行时间。

3 实验结果与分析

为了更直观体现 IS-DivFL 的优势, 本文在 LEAF 联邦学习基准提供的 FEMNIST 数据集^[4]上开展实验, 给出 IS-DivFL 与多种客户端选择策略的对比结果, 最后, 通过基于合成梯度的相似度维护模块的开销评估实验直接量化相似度维护阶段的运行时间。

3.1 实验环境与数据集

在 FEMNIST 数据集上, 客户端以书写者为单位进行天然划分(每个书写者对应一个客户端), 因此, 具有更强的统计异质性与客户端数据规模差异, 更贴近真实的联邦学习场景。实验中, 本文从 FEMNIST 中随机抽取 100 个客户端, 在 62 类手写字符(10 个数字 + 52 个字母)识别任务上训练全局模型。模型采用轻量级卷积神经网络(convolutional neural network, CNN)的 62 类分类器: 输入为 784 维

展平灰度图像(重塑为 $28 \times 28 \times 1$), 包含 2 层 3×3 卷积层(通道数分别为 32、64), 每层卷积后接一层 2×2 最大池化(步幅 2), 随后为 128 个单元的全连接层, 最终接 62 维输出层。优化器采用 Adam, 学习率为 0.001, 本地批大小为 32, 本地训练轮数设为 1, 总通信轮数为 300; 客户端选择预算固定为 $B = 15$, 即每轮从 100 个客户端中选出 15 个参与训练, 并按轮评估全局模型性能, 这也与复杂度分析中 $B \ll N$ 的假设相一致。

3.2 对比方法与参数设置

对比方法与参数设置如下。

1) Uniform: 每轮从所有客户端中均匀随机采样 B 个客户端参与训练。

2) Loss-based: 首先在所有客户端上计算当前轮的训练损失, 然后在候选集合中优先选择损失较大的客户端, 属于典型的多候选优选策略。

3) DivFL(原始子模客户端选择方法): 记相似度更新周期为 m , DivFL 每隔 5 轮重新计算所有客户端间的成对距离。

4) IS-DivFL(本文提出的增量式子模客户端选择方法): $m = 5$ 。在本文所有实验中, 指数滑动平均的系数固定为 $\alpha = 0.7$ 。在初始实验中考察了 $\alpha \in \{0.5, 0.7, 0.9\}$ 的情况, 在 $\alpha = 0.7$ 时, 在收敛速度与测试精度方差之间取得了较为平衡的表现, 因此, 在后续实验中不再对该参数进行额外调整。

为了评估 IS-DivFL 中梯度变化量阈值 τ 对性能的影响, 本文在保持其余参数与训练配置不变的条件, 对 τ 进行敏感性分析。选取 $\tau \in \{0.01, 0.05, 0.10\}$ 作为代表性取值, 统计 3 次随机划分下各个指标的均值, 其中 $\tau = 0.01$ 对应更激进的更新策略(更多客户端触发更新), $\tau = 0.10$ 对应更保守的更新策略(更少客户端触发更新), $\tau = 0.05$ 位于二者之间。本文中的测试准确率指各客户端本地测试准确率的均值; 测试准确率方差指各客户端本地测试准确率在客户端维度上的方差。最终结果如表 1 所示。

表 1 IS-DivFL 中梯度变化量阈值 τ 的敏感性分析
Table 1 Sensitivity analysis of the gradient-change threshold τ in IS-DivFL

τ	最终测试 准确率	最佳测试 准确率	最终测试 准确率方差
0.01	0.884 5	0.913 5	0.004 7
0.05	0.899 8	0.915 4	0.003 5
0.10	0.893 9	0.916 5	0.003 3

可以看出: 当 $\tau=0.05$ 时, 在最终测试准确率上取得最高值, 说明在训练结束时具有更好的收敛效果; 当 $\tau=0.10$ 时, 在最佳测试准确率与最终测试准确率方差上略优, 表明更保守的更新触发策略可以带来轻微的稳定收益。综合考虑 3 项指标且差异整体较小, 因此, 后续实验默认采用 $\tau=0.05$ 。

在下面所有方法中, 均通过 FedAvg 策略更新全局模型, 并评估 3 项指标: 测试准确率、训练损失及各客户端测试准确率的方差。

3.3 FEMNIST 数据集上联邦学习结果

图 2~4 给出了在 FEMNIST 数据集上非独立同分布(independent and identically distributed, IID) 场景下 4 种客户端选择策略的对比结果。




图2 FEMNIST 数据集上不同客户端选择策略的测试准确率
Fig.2 Test accuracy of different client selection strategies on FEMNIST dataset




图3 FEMNIST 数据集上不同客户端选择策略的测试准确率方差
Fig.3 Variance of test accuracy under dataset different selection strategies on FEMNIST dataset

图 2 给出了 FEMNIST 数据集上 4 种客户端选择策略的测试准确率随通信轮数的变化。可以看到, IS-DivFL 与 DivFL 的准确率曲线整体接近, 说明在引入增量梯度相似度更新后, IS-DivFL 能够在更




图4 FEMNIST 数据集上不同客户端选择策略的训练损失
Fig.4 Training loss comparison of different client selection strategies on FEMNIST dataset

强异质性的 FEMNIST 数据集场景下保持与原始 DivFL 相当的收敛性能与最终精度。

图 3 给出了各轮次客户端本地测试准确率的方差变化。总体上, 方差随训练推进呈下降趋势, 反映出全局模型逐步缩小了不同客户端之间的性能差异。IS-DivFL 与 DivFL 在方差曲线上保持相近水平, 表明在总体测试精度不受影响的前提下, IS-DivFL 能够获得与 DivFL 相当的性能分布特征与训练稳定性。

由图 4 可知, 4 种策略的训练损失都随通信轮数增加而快速下降并逐步收敛。与 Uniform 与 Loss-based 相比, DivFL 与 IS-DivFL 在中后期整体保持更低的训练损失, 说明其客户端选择更有利于全局目标优化, 收敛更充分。两者曲线基本重合, 表明 IS-DivFL 在采用增量相似度更新的情况下, 仍能获得与 DivFL 相近的优化效果。

为便于对不同方法进行更直观的横向比较, 进一步将图 2~4 中的关键指标汇于表 2。

表2 FEMNIST 数据集上不同客户端选择策略的量化对比
Table 2 Quantitative comparison of different client selection strategies on FEMNIST dataset

方法	最终测试准确率	最佳测试准确率	最终测试准确率方差	最终训练损失
Uniform	0.781 3	0.791 1	0.012 1	0.697 1
Loss-based	0.792 8	0.792 8	0.011 2	0.686 4
DivFL	0.804 8	0.810 5	0.009 6	0.500 3
IS-DivFL	0.808 9	0.817 6	0.009 7	0.499 6

由表 2 可以看出: IS-DivFL 在测试准确率上与

DivFL 接近,甚至略有优势,并且明显高于 Uniform 和 Loss-based,这说明在保持 DivFL 多样性选择优势的同时,IS-DivFL 的增量相似度维护并未削弱模型性能;从最终测试准确率方差来看,DivFL 和 IS-DivFL 均显著低于其他 2 种方法,这与图 3 中方差曲线整体趋势一致,表明基于多样性的选择策略能有效降低不同客户端之间的性能差异,提升训练稳定性与公平性;在训练损失方面,IS-DivFL 和 DivFL 明显低于 Uniform 与 Loss-based,并且 IS-DivFL 的最终训练损失与 DivFL 接近,说明多样性驱动的候选客户端集合更有利于优化目标的持续下降,并且本文方法并不会破坏 DivFL 的优化优势。

综上,IS-DivFL 在 FEMNIST 数据集上能够保持与 DivFL 相当的测试精度、方差水平和收敛性能,说明在统计异质性强与样本量不均衡条件下,增量式相似度更新并未削弱子模选择策略的有效性。

进一步地,本文的侧重点在于相似度矩阵维护过程的计算方式,因此,有必要对该模块的计算开销进行更直接、可控的量化评估。

3.4 相似度维护模块的开销评估实验

本文之所以不直接以 FEMNIST 数据集的端到端训练总耗时作为对比依据,是因为总耗时会同时叠加本地训练、评估、数据读取与系统调度等开销,并且受每轮参与客户端的样本量差异与掉线机制影响,时间波动较大,这些因素会掩盖相似度维护特定模块的时间差异,使得端到端耗时对比难以准确反映增量更新机制带来的收益。相比之下,相似度维护模块的开销评估实验通过固定梯度维度与客户端规模、隔离本地训练与评估等环节,能够更清晰地刻画相似度维护阶段的时间消耗及其随 N 变化的趋势,从而为本文的复杂度分析提供更有说服力的证据。

具体地,本文在梯度维度 $d=8\,000$ 、客户端数量 $N \in \{100, 200, 500, 1\,000\}$ 条件下随机生成归一化梯度向量,并分别测量全量更新和增量更新这 2 种策略在一个相似度更新周期中的耗时。全量更新是计算所有客户端之间的欧氏距离,模拟原始 DivFL 的全量相似度矩阵更新。增量更新是按 IS-DivFL 的方式,仅对候选客户端集合 $C^{(t)}$ 中客户端所对应的相似度矩阵进行更新。

表 3 给出了在不同客户端规模下全量更新与增量更新的平均耗时,并列出了增量更新相较于全量更新的时间减少量和时间减少的比例。可以看出,当客户端数量 N 从 100 增加到 1 000 时,全量更新

的耗时近似呈二次增长,而增量更新的耗时则保持在相对温和的增长水平。

表 3 不同客户端规模下全量更新与增量更新的平均耗时对比

Table 3 Comparison of average time consumption between full update and incremental update under different clients

N	平均耗时/ms		时间减少量	时间减少比例/
	全量更新	增量更新	$\Delta T/\text{ms}$	%
100	9.09	4.46	4.63	50.9
200	22.12	9.65	12.47	56.4
500	99.62	31.83	67.79	68.1
1 000	245.18	91.91	153.27	62.5

不同客户端规模下 IS-DivFL 与 DivFL 在相似度维护阶段的平均耗时对比如图 5 所示。可以看出,IS-DivFL 在相似度维护阶段平均耗时相较于 DivFL 减少 50%~70%,并且当客户端数量达到 500 左右时,时间减少的比例最为显著。这表明增量式相似度维护机制能够有效缓解子模客户端选择在大规模场景中的计算瓶颈。




图 5 不同客户端规模下 IS-DivFL 与 DivFL 在相似度维护阶段的平均耗时对比

Fig. 5 Comparison of the average time consumption of IS-DivFL and DivFL in the similarity maintenance phase under different client scales

4 结论

1) 本文提出一种增量式子模客户端选择方法——IS-DivFL,通过在相似度维护阶段采用基于梯度摘要和梯度变化量的增量更新,降低了相似度维护阶段的计算复杂度。

2) 在 FEMNIST 数据集上的联邦学习训练任务中,IS-DivFL 在测试精度上与 DivFL 保持相当水平,

并整体优于均匀随机采样与基于损失的多候选优选策略;同时,在测试准确率方差指标上,IS-DivFL 与 DivFL 表现接近且保持较低方差,说明其在不同数据集与不同异质性来源下均能兼顾模型性能与训练过程的稳定性。

3) 相似度维护模块的开销评估实验表明,在客户端数量为 100 ~ 1 000 时,IS-DivFL 在相似度维护阶段的平均运行时间相较于 DivFL 减少 50% ~ 70%。

参考文献:

- [1] LI T, SAHU A K, TALWALKAR A, et al. Federated learning: challenges, methods, and future directions [J]. IEEE Signal Processing Magazine, 2020, 37(3): 50-60.
- [2] WANG G, LIU R Y, LIU S H. ALFL: a federated learning client selection algorithm for heterogeneous data [C] // 2024 5th International Conference on Big Data & Artificial Intelligence & Software Engineering. Piscataway, NJ: IEEE, 2024: 410-413.
- [3] 刘海洋. 基于自适应剪枝和客户端选择的联邦学习通信优化研究与实现 [D]. 济南: 山东大学, 2024.
- [4] LIU H Y. Research and implementation of federated learning communication optimization based on adaptive pruning and client selection [D]. Jinan: Shandong University, 2024. (in Chinese)
- [5] MOHRI M, SIVEK G, SURESH A T. Agnostic federated learning [C] // Proceedings of the 36th International Conference on Machine Learning. Cambridge, MA: PMLR, 2019: 4615-4625.
- [6] KIM J, SONG C, PAEK J, et al. A review on research trends of optimization for client selection in federated learning [C] // 2024 International Conference on Information Networking. Piscataway, NJ: IEEE, 2024: 287-289.
- [7] 孙洪波, 王国成, 张林, 等. 基于深度强化学习的联邦学习客户端自适应选择策略 [J/OL]. 南京邮电大学学报(自然科学版) [2025-10-25]. <https://link.cnki.net/urlid/32.1772.tn.20250811.1047.009>.
- [8] SUN H B, WANG G C, ZHANG L, et al. Adaptive selection for clients in federated learning based on deep reinforcement learning [J/OL]. Journal of Nanjing University of Posts and Telecommunications (Natural Science Edition) [2025-10-25]. <https://link.cnki.net/urlid/32.1772.tn.20250811.1047.009>. (in Chinese)
- [9] CHO Y J, WANG J Y, JOSHI G. Client selection in federated learning: convergence analysis and power-of-choice selection strategies [EB/OL]. [2025-11-11]. <https://arxiv.org/abs/2010.01243>.
- [10] BALAKRISHNAN R, AKDENIZ M, DHAKAL S, et al. Resource management and fairness for federated learning over wireless edge networks [C] // 2020 IEEE 21st International Workshop on Signal Processing Advances in Wireless Communications. Piscataway, NJ: IEEE, 2020: 1-5.
- [11] BALAKRISHNAN R, LI T, ZHOU T Y, et al. Diverse client selection for federated learning via submodular maximization [C/OL] // International Conference on Learning Representations, 2022 [2025-10-20]. <https://openreview.net/pdf?id=nwKXyFvaUm>.
- [12] WEI K, IYER R, BILMES J. Fast multi-stage submodular maximization [C] // Proceedings of the 31st International Conference on Machine Learning. Cambridge, MA: PMLR, 2014: 1494-1502.
- [13] YIN D, PANANJADY A, LAM M, et al. Gradient diversity: a key ingredient for scalable distributed learning [C] // International Conference on Artificial Intelligence and Statistics. Cambridge, MA: PMLR, 2018: 1998-2007.
- [14] IYER R, JEGELKA S, BILMES J. Fast semidifferential-based submodular function optimization [C] // Proceedings of the 30th International Conference on Machine Learning. Cambridge, MA: PMLR, 2013: 855-863.
- [15] NEMHAUSER G L, WOLSEY L A, FISHER M L. An analysis of approximations for maximizing submodular set functions: I [J]. Mathematical Programming, 1978, 14(1): 265-294.
- [16] CONFORTI M, CORNUÉJOLS G. Submodular set functions, matroids and the greedy algorithm: tight worst-case bounds and some generalizations of the Rado-Edmonds theorem [J]. Discrete Applied Mathematics, 1984, 7(3): 251-274.
- [17] FUJISHIGE S. Submodular functions and optimization [M]. Amsterdam: Elsevier, 2005: 55-65.
- [18] CALDAS S, DUDDU S M K, WU P, et al. LEAF: a benchmark for federated settings [EB/OL]. [2025-11-11]. <https://arxiv.org/abs/1812.01097>.

(责任编辑 梁 洁)