



中国管理科学
Chinese Journal of Management Science
ISSN 1003-207X,CN 11-2835/G3

《中国管理科学》网络首发论文

题目：基于联邦学习的信用风险评估中的数据交易定价研究
作者：张云鹏，王帆，韦立坚
DOI：10.16381/j.cnki.issn1003-207x.2024.2004
网络首发日期：2026-03-02
引用格式：张云鹏，王帆，韦立坚. 基于联邦学习的信用风险评估中的数据交易定价研究[J/OL]. 中国管理科学.
<https://doi.org/10.16381/j.cnki.issn1003-207x.2024.2004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

DOI:10.16381/j.cnki.issn1003-207x.2024.2004

基于联邦学习的信用风险评估中的数据交易定价研究

张云鹏¹, 王帆¹, 韦立坚¹

(1. 中山大学管理学院, 广东 广州 510275)

摘要: 通过数据提供方与信贷机构方的联邦学习建模可以在隐私保护的条件下丰富借款人的特征维度, 从而缓解信用风险评估中的信息不对称, 实现数据赋能普惠金融大文章。而要实现数据交易和联邦学习建模, 关键是设定合理的价格机制激励信贷方和数据方的共同参与。本文通过理论模型和数值模拟探究了面向金融信贷场景的数据交易定价机制, 并用互联网小贷公司的借贷数据和联邦学习建模对定价机制进行检验。研究发现(1)存在最优的数据定价区间, 该区间内, 整体社会福利达到最大化, 数据价格起到对数据赋能带来经济价值的收益分配作用, 需要根据信用风险评估中各数据参与方的贡献度进行收益分配。当定价较低时, 不满足数据方参与约束条件; 定价较高时, 则会出现社会福利损失, 数据资源配置效率下降。(2)按照信用评估模型贡献度分配原则, 我们构建了反映模型价值贡献度的经济增加值和利润增加值指标, 实证检验发现这两个指标能够度量联邦学习模型的经济价值, 因此可以采用这两个指标作为数据收益分配的基准。(3)数值模拟和实证检验均表明当信贷机构方客户达到一定规模, 市场质量较差时, 通过联邦学习建模进行数据交易才具备可行性, 数据提供方可以根据客户规模和市场质量分别对不同类型的金融机构制定差异化定价策略, 包括低定价策略、精益求精策略、薄利多销策略和高定价策略等。

关键词: 联邦学习; 信用风险评估; 数据定价; 信息不对称

1 引言

随着大数据时代的到来, 数据量和数据维度都呈现爆发式的增长^[1-2], 仅仅通过传统的信用评价指标已经很难满足大数据环境下多变的融资需求, 需要利用海量大数据中丰富的数据维度, 对客户进行全方位的精准画像, 从而全面提升对客户的信用风险评估能力^[3-4]。然而现行数据资源集中于政府和国有企业、通信运营商和互联网公司中, 单单依靠金融机构的数据量和数据维度很难满足大量用户的个性化需求。因此要破解信息不对称难题, 一个可行的解决办法是金融机构向其他数据方购买数据, 但是随着数据赋能研究的不断深入, 隐私保护和数据泄露问题日益突出^[5]。过去采用传统机器学习等大数据方法正面临数据割裂的严峻挑战, 呈现出“信息壁垒”和“数据孤岛”的特征^[6]。

数据要素的广泛参与会促进经济增长^[7-8], 但其中面临数据安全和数据流通之间的困境^[9]。为了促进数据交易, 发挥数据经济价值, 党中央成立国家数据总局, 并在多地市成立数据交易所^[10]。然而从2014-2022年成立的40多家数据交易所, 超过半数已处于停止运营状态, 数据交易场内市场出现了“有数无市”“有市无数”的现象, “进场企业少、交易数据

作者简介: 张云鹏(1997—), 男(汉族), 河南安阳人, 中山大学管理学院博士研究生, 研究方向: 金融科技与监管科技, Email: zhangyp36@mail2.sysu.edu.cn; 王帆(1974—), 男(白族), 云南昆明人, 中山大学管理学院教授, 博士, 研究方向: 金融科技与供应链金融, Email: fanwang@gmail.com; 通讯作者: 韦立坚(1981—), 男(汉族), 广西岑溪人, 中山大学管理学院教授, 博士, 研究方向: 金融科技、智能投资与风险管理, Email: weilj5@mail.sysu.edu.cn。

基金项目: 国家自然科学基金面上项目(72171239); 广东省自然科学基金杰出青年项目

(2021B1515020073); 本文系中山大学大数据管理行为与决策教育部哲学社会科学实验室的研究成果。

少、成交金额少”。一方面，从数据的提供方来说数据存在较大隐私保护风险，由于数据的虚拟性和可复制性^[11]，数据流通过程中存在泄露隐私和转售问题，数据的提供方难以从交易中获得持续的收益流从而缺乏动力提供数据^[12-13]。另一方面，从数据的购买方来说数据的价格机制尚未形成，由于数据购买双方存在信息不对称，数据带来的经济价值存在不确定性，因此在数据交易的定价和收益分配存在巨大分歧，这导致数据购买方没有动力购买数据^[14]。

鉴于此，如何在隐私保护的条件下实现信用风险评估中的数据交易定价，发挥数据要素价格机制的资源有效配置作用是数字金融领域中亟待解决的问题。

联邦学习恰好能够完美的解决数据隐私安全问题。它通过结合隐私计算和加密算法等技术，使得在金融机构与其他数据优势方在自身数据不泄露的前提下进行联合建模，从而做到不获取实际数据而拼凑出小微企业的全息画像，提高仅使用金融机构数据对客户的违约预测准确率。2021 年 12 月，中国人民银行印发的《金融科技发展规划（2022-2025 年）》明确提出“积极应用多方安全计算、联邦学习、差分隐私、联盟链等技术，探索建立跨主体数据安全共享隐私计算平台，在保障原始数据不出域前提下规范开展数据共享应用”。而在国务院发布《“十四五”数字经济发展规划》也指出，“要充分发挥数据要素作用，鼓励重点行业创新数据开发利用模式，在确保数据安全、保障用户隐私的前提下，调动多方参与数据价值开发”。联邦学习可以实现数据的可用不可见，基于联邦学习的信用风险评估数据交易模式使得从原始的“数据所有权交易”转变为“数据使用权交易”^[9]，这对破解信息不对称难题，创新数据开发利用模式，实现数据赋能信贷产业升级具有重要理论和实践意义。

纵向联邦学习在信贷领域有着最为广泛的应用前景。在联邦学习的类型中，纵向联邦学习是指各个数据参与方拥有相同的样本空间和相同的 ID，但是它们的特征空间是不同的联邦建模方法^[15]。信贷方可以通过与其他数据优势方进行纵向联邦建模丰富借款人的数字足迹，从而达到缓解信贷方与借款者信息不对称的目的。金融机构和政府进行合作，共享借款企业的司法数据、纳税数据、水电费数据等；金融机构和通信运营商进行合作，共享借款人的手机相关数据，如贷款金融类 APP 使用情况、银行通话次数、地理位置等等；金融机构和大数据企业进行合作，共享借款客户的支付宝信息如芝麻信用评分、淘宝信息如购物消费、微信信息如微信好友数等。研究表明这些“数字足迹”类的风险特征信息在信用风险评估中发挥的重要作用^[16-17]，采用纵向联邦建模的构建信贷模型确实能够提高对借款人的风险评估能力^[18-19]。

本文基于纵向联邦学习的隐私计算方法，给出了信贷方和数据方在信用风险评估领域的数据交易定价的解决方案。有学者结合金融机构和移动通信运营商数据进行纵向联邦建模^[20]，还有学者将公开的信贷数据拆成两部分模拟信贷方和数据参与方^[21-22]，并没有考虑信贷方和数据方参与合作条件与定价策略。还有一类研究从理论上分析数据要素和隐私保护对经济增长带来的影响^[23]，如强制共享数据和自主交易数据两种不同数据要素配置方法对信贷市场竞争以及借款者福利的影响^[24-25]，数据的强制共享要求数据格式的统一标准，在现阶段巨有较大阻碍，而数据的自主交易共享则需要在“场景专用性”上探索更加具体的合作模式和激励机制设计，这样才能实现数据要素的市场建设^[9]。

本文不仅在理论上探究了数据交易中信贷方和数据方的参与条件和定价策略，并且在实践上，构建了衡量数据带来经济价值的具体指标以及收益贡献分配方式，并采用实际数据进行实证检验。数据带来的经济价值可以分为数据所有权和数据用益权两类^[26]，信贷方通过纵向联邦建模提高了自身的筛选能力从而实现了数据的用益权，信贷方向数据合作方支付一定数据使用报酬以实现数据的所有权。因此纵向联邦学习的引入对信贷方期望利润有两方面影响，一个是通过提高筛选能力来提升期望利润的正面作用，一个是通过支付数据使用费用增大成本的负面作用。本文构建了信贷方和数据合作方在进行纵向联邦合作前和合作后的期望利润模型，在此基础上根据利润最大化求解模型，并通过数值算例考察数据价格、信贷方

规模、市场质量等因素对利润函数的影响。进一步构建模型带来的经济增加值和利润增加值指标,并采用实际借贷数据根据构建指标设计激励机制合同,对数据带来的经济价值进行合理的收益贡献分配。

研究发现:(1)存在最优的数据定价区间,该区间内,整体社会福利达到最大化,数据价格机制起到对数据赋能带来经济价值的收益分配作用,需要根据参与贡献度进行合理的收益分配。当定价较低时,不满足数据方参与约束条件,定价较高时,则会出现社会福利损失,资源配置效率下降。(2)我们构建了反应模型价值贡献度的经济增加值和利润增加值指标,实证检验发现该指标更能突显出联邦模型的经济价值,据此作为数据带来收益贡献度分配的基准,并指导设定数据价格。(3)当信贷方客户达到一定规模,市场质量较差时,通过联邦建模进行数据交易才具备合作空间,数据方可以根据客户规模和市场质量分别对不同类型的金融机构制定低定价策略、精益求精策略、薄利多销策略和高定价策略。

本文的边际贡献在于:在理论层面,不同于谢丹夏等^[24]提出的数据要素市场自主交易的数据要素配置方法,也不同于He等^[27]中的开放银行数据共享的概念,本文首次构建了一个融合数据定价的信贷竞争模型,清晰地刻画了数据交易的合作条件与动态定价区间,并阐明了信贷方规模与市场质量如何共同决定了其最优数据采购策略,为联邦学习在金融领域的商业化实践提供了亟需的理论基础。在方法层面,提出了适用于联邦学习环境的经济增加值与利润增加值指标,该指标体系克服了传统模型评价指标与经济价值脱节的局限,为实现基于价值贡献的收益分配提供了可量化、可操作的基准。在实践层面,基于理论与实证发现,为数据方针对不同类型的金融机构(如大型商业银行、金融科技公司、传统小贷机构等)制定了高定价、薄利多销、精益求精与低定价的差异化策略,为数据要素参与信贷行业收入分配提供了具体的现实指导。

本文接下来在第2节进行理论模型构建和分析,第3节进行实证检验,第4给出结论和政策建议。

2 理论模型

为探究数据交易中的定价机制与合作条件,本节通过构建理论模型展开分析。首先,基于信贷市场特征设定基础假设,并分别建立信贷方在联邦合作前与合作后的利润函数,明晰数据方的定价行为及其参与约束。其次,通过求解信贷方利润最大化问题,推导出最优数据购买策略与定价区间。最后,通过数值模拟与敏感性分析,深入考察数据价格、信贷方规模及市场质量等关键参数对模型均衡结果的影响,从而为后文的实证检验与策略制定提供理论依据。

2.1 模型构建

2.1.1 基础假设

本文构建一个包含借款人、信贷方和数据方三方的纵向联邦合作理论框架。模型基础借鉴了信贷竞争的相关研究^[27-29],本文的核心创新在于引入了数据方的定价行为与数据交易价格。信贷方通过向数据方支付费用以获取更多数据维度,从而提升风控能力并实现利润最大化。

(1) 借款人描述

假设信贷市场上存在 N 个风险中性的借款人,每个借款人申请一笔价值为1的贷款。 $b \in \{h, l\}$ 表示借款人的真实信用质量,属于私人信息。其中, $b = h$ 代表借款人高信用会正常履约, $b = l$ 代表借款人为低信用违约。设人群中高信用借款人比例为 q ,反应市场质量,则可得公式(1)。

$$P(b = h) = q, P(b = l) = 1 - q \quad (1)$$

(2) 信贷方描述

当借款人申请借款时, 信贷机构会利用自身数据训练的风控模型来判断借款人的信用风险水平, $s \in \{h, l\}$ 代表信贷机构对借款人的评估结果。其中, $s = h$ 代表信贷机构判断借款人为高信用, $s = l$ 代表信贷机构判断借款人为低信用。对于真实信用为 $b(i)$ 的借款人, 信贷方通过大数据方法构建的风控筛选能力 φ 对借款人进行信贷评估结果为 $s(i)$ 的概率为 $P(s(i)|b(i))$, 当 $s(i) = b(i)$ 时, 表明信贷方的信用评估结果是正确的, 所以 φ 可表示信贷方筛选能力的准确率。因此信贷机构的筛选能力可以用公式 (2) 表示:

$$\begin{aligned} P(s = h|b = h) &= P(s = l|b = l) = \varphi \\ P(s = h|b = l) &= P(s = l|b = h) = 1 - \varphi \end{aligned} \quad (2)$$

仅当信贷机构的风控筛选准确率超过 50% 时, 进行详细的信贷评估才具有实际意义。若风控准确率低于 50%, 直接假设所有借款人的信用状态处于平均水平, 反而能实现更高的整体预测准确率并带来更大的经济效益。

王煜心等^[30]探究了数据质量和数据容量对数据定价的影响, 在基于联邦学习的信用风险评估中可以将其对应于数据样本量 (n) 和数据维度 (d), 这也可以反应出信贷放的风控能力。数据维度越多, 样本数越多, 通过数据训练的风控模型的准确率越高, 且数据维度和样本量同样呈替代关系, 因此可假设信贷方的筛选能力为公式 (3)。

$$\varphi = (1 + nd)/2, \quad d \in [0, 1], \quad n \in [0, 1] \quad (3)$$

若要收集所有借款人的所有数据特征, 其代价是高昂的, 因此对于信贷方构建筛选能力的成本 c 应该满足边际成本递增的原则, 即公式 (4):

$$\begin{aligned} \frac{\partial c}{\partial d} &> 0, & \frac{\partial^2 c}{\partial d^2} &> 0 \\ \frac{\partial c}{\partial n} &> 0, & \frac{\partial^2 c}{\partial n^2} &> 0 \end{aligned} \quad (4)$$

当信贷方不通过大数据手段进行违约风险评估时, 此时不需要任何数据, 因此对应成本为 0, 即 $c(nd = 0) = 0$ 。考虑到信贷方无法穷尽所有借款人的相关数据, 所以有 $\lim_{nd \rightarrow 1} c(n, d) = +\infty$, 参考龚强等^[9]的做法, 记 $c = \tau_1(\frac{1}{1-nd} - 1)$, 其中 τ_1 是采集数据和建立风控能力所需的成本系数。

2.1.2 联邦合作前的信贷方利润

由借款人真实信用情况和信贷机构的信用评估情况, 可得公式 (5):

$$\begin{aligned} P(s = h, b = h) &= P(s = h|b = h)P(b = h) = \varphi q \\ P(s = h, b = l) &= P(s = h|b = l)P(b = l) = (1 - \varphi)(1 - q) \end{aligned} \quad (5)$$

基于贝叶斯公式, 当信贷方评估借款人为高信用时, 借款人偿还的概率可以通过公式 (6) 计算:

$$\begin{aligned} P(b = h|s = h) &= \frac{P(s = h, b = h)}{P(s = h, b = h) + P(s = h, b = l)} \\ &= \frac{\varphi q}{\varphi q + (1 - \varphi)(1 - q)} \end{aligned} \quad (6)$$

同理可得公式 (7):

$$P(b = l|s = h) = \frac{(1 - \varphi)(1 - q)}{\varphi q + (1 - \varphi)(1 - q)} \quad (7)$$

对于信贷方来说, 若对借款人评估为高信用, 则进行放贷, 若评估为低信用, 则不会对其进行放贷, 那么期望利润可以用公式 (8) 表达:

$$\pi = rP(b = h|s = h) - P(b = l|s = h) - c \quad (8)$$

其中, $rP(b = h|s = h)$ 为信贷方评估为高信用且借款人真为高信用按时还款利息收入, $P(b = l|s = h)$ 为信贷方评估为高信用但借款人实际违约的损失, c 为信贷方构建自身筛选能力的成本。

信贷方利用大数据和金融科技手段构建自身风控筛选能力的前提条件是, 当不进行任何筛选时, 无法获得正利润^[24], 即 r 需要满足公式 (9) :

$$qr - (1 - q) < 0 \quad (9)$$

将 $P(b = h|s = h)$ 、 $P(b = l|s = h)$ 、 $\varphi = (1 + nd)/2$ 、 $c = \tau_1(\frac{1}{1 - nd} - 1)$ 代入公式 (8) 中, 可得在纵向联邦合作前的信贷方利润, 即公式 (10) :

$$\begin{aligned} \pi &= r \cdot \frac{\varphi \cdot q}{\varphi \cdot q + (1 - q)(1 - \varphi)} - \frac{(1 - q)(1 - \varphi)}{\varphi \cdot q + (1 - q)(1 - \varphi)} - \tau_1(\frac{1}{1 - d \cdot n} - 1) \\ &= r \cdot \frac{q + dnq}{1 + 2dnq - dn} - \frac{1 - dn - q + dnq}{1 - dn + 2dnq} - \tau_1(\frac{1}{1 - dn} - 1) \end{aligned} \quad (10)$$

2.1.3 联邦合作后的信贷方利润

在纵向联邦合作建模时, 信贷方向数据方购买更多数据维度的使用权, 使得借款人的特征维度更加丰富, 此时信贷方的数据量并不发生变化, 而数据的特征维度会变得更加。假设从数据合作企业方得到的数据维度为 Δd , 则信贷方的筛选能力也相应提高为 $\varphi' = \frac{1 + (d + \Delta d)n}{2}$ 。由于信贷方本身已经具有关于借款人的特征维度 d , 前文我们将所有跟借款人有关的特征维度抽象为一个 0-1 之间的数, 因此 $0 \leq \Delta d \leq 1 - d$ 。构建纵向联邦模型时需要信贷方和数据合作方付出一定的时间成本、人力成本、研发成本, 这里将其记为固定费用 f 。由于信贷方通过获得合作企业的数据提高了筛选能力, 因此需要根据使用的数据量支付给合作方报酬。数据合作方对数据维度量的定价为 τ_2 , 因此信贷机构在纵向联邦学习之后的期望利润为公式 (11) :

$$\begin{aligned} \pi' &= r \cdot \frac{\frac{1 + (d + \Delta d)n}{2} \cdot q}{\frac{1 + (d + \Delta d)n}{2} \cdot q + \frac{1 - (d + \Delta d)n}{2} (1 - q)} - \frac{(1 - q) \frac{1 - (d + \Delta d)n}{2}}{\frac{1 + (d + \Delta d)n}{2} \cdot q + \frac{1 - (d + \Delta d)n}{2} (1 - q)} - \tau_1(\frac{1}{1 - d \cdot n} - 1) \\ &\quad - 1) - f - \tau_2 \Delta d \\ &= (r + 1) \cdot \frac{q + dnq + \Delta d nq}{1 + 2dnq - dn + \Delta d (2nq - n)} - 1 - \tau_1(\frac{1}{1 - d \cdot n} - 1) - f - \tau_2 \Delta d \end{aligned} \quad (11)$$

2.1.4 参与主体决策

对于数据合作企业来说, 决策变量是对借款人数据维度的定价 τ_2 , 目标函数是通过合理设定数据维度价格实现自身的利润最大化, $\tau_2 \Delta d$ 为参与联邦合作的收益, f 为其参加联邦合作的固定支出, 因此数据合作方加入到纵向联邦合作的目标函数为公式 (12) :

$$\begin{aligned} \max_{\tau_2} \pi_p &= \tau_2 \Delta d - f \\ \text{s.t. } 0 &\leq \Delta d \leq 1 - d \end{aligned} \quad (12)$$

对于信贷方来说, 决策变量是要向数据合作企业购买的数据维度, 目标函数是通过纵向联邦合作实现自身利润的最大化, 在追求自身利润的同时也要满足一些限制条件。首先, 若数据合作企业参与纵向联邦合作, 其利润应该满足 $\tau_2 \Delta d - f > 0$ 的参与约束条件。其次,

信贷方需要满足公式（9）才会利用数据分析手段构建自身筛选能力。综上所述，信贷方在进行纵向联邦合作之后的目标函数为公式（13）：

$$\begin{aligned} \max_{\Delta d} \pi' = & (r+1) \cdot \frac{q + dnq + \Delta dnq}{1 + 2dnq - dn + \Delta d(2nq - n)} - 1 \\ & - \tau_1 \left(\frac{1}{1 - d \cdot n} - 1 \right) - f - \tau_2 \Delta d \end{aligned} \quad (13)$$

$$s.t. \begin{cases} \tau_2 \Delta d - f > 0 \\ qr - (1 - q) < 0 \\ 0 \leq \Delta d \leq 1 - d \end{cases}$$

公式中包含的所有参数符号及其含义如下表 1 所示。

表 1 变量符号及其含义

变量名称	变量解释
q	借款人群中高信用借款人比例
d	信贷方所拥有的评估借款人违约的特征维度
n	信贷方所拥有的评估借款人违约的数据样本量
Δd	信贷方向数据合作企业购买的借款人的特征维度
τ_1	信贷方采集构建自身借款人筛选系统的成本系数
τ_2	数据合作企业的数据价格
r	借款人利率
f	建立联邦学习模型的固定费用
π	进行纵向联邦合作前信贷方期望利润
π'	进行纵向联邦合作后信贷方期望利润
$\Delta \pi$	进行联邦合作后相对合作前的利润增加值
π_p	数据合作方的期望利润

2.2 模型求解

在当前的数据交易市场下，由于数据带来的经济价值具有不确定性，追求利润最大化并不是数据供方最迫切的需求^[14]，因此我们将数据方的期望利润大于零作为信贷方的参与约束条件，主要考虑信贷方的目标函数最大化，讨论 τ_2 在不同条件下的最优决策，结果如下命题所示：

命题 1 （1）信贷方的最优购买数据维度为：

$$\Delta d = \begin{cases} 0, \tau_2 \geq \frac{2nq(1-q)(r+1)}{[1 + (2q-1)nd]^2} \\ \Delta d^*, \frac{2nq(1-q)(r+1)}{[1 + (2q-1)n]^2} < \tau_2 < \frac{2nq(1-q)(r+1)}{[1 + (2q-1)nd]^2} \\ 1 - d, \frac{2nq(1-q)(r+1)}{[1 + (2q-1)n]^2} \geq \tau_2 \end{cases} \quad (14)$$

（2）信贷方的最优利润为：

π'

$$= \begin{cases} \frac{q + dnq}{1 + 2dnq - dn} (1+r) - 1 - \tau_1 \left(\frac{1}{1 - d \cdot n} - 1 \right) - f, \tau_2 \geq \frac{2nq(1-q)(r+1)}{[1 + (2q-1)nd]^2} \\ \frac{q + dnq + \Delta d^* nq}{1 + 2dnq - dn + \Delta d^* (2nq - n)} (1+r) - 1 - \tau_1 \left(\frac{1}{1 - d \cdot n} - 1 \right) - f - \tau_2 \Delta d^*, \frac{2nq(1-q)(r+1)}{[1 + (2q-1)n]^2} < \tau_2 < \frac{2nq(1-q)(r+1)}{[1 + (2q-1)nd]^2} \\ \frac{q + nq}{1 + 2nq - n} (1+r) - 1 - \tau_1 \left(\frac{1}{1 - d \cdot n} - 1 \right) - f - \tau_2 (1 - d), \frac{2nq(1-q)(r+1)}{[1 + (2q-1)n]^2} \geq \tau_2 \end{cases}$$

$$\text{其中 } \Delta d^* = \sqrt{\frac{2nq(1-q)(r+1)}{\tau_2}} - 1 - d$$

(3) 数据合作企业的最优利润为:

$$\begin{aligned} \pi_p &= \tau_2 \Delta d - f \\ &= \begin{cases} \tau_2(1-d) - f, \tau_2 \leq \frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2} \\ \tau_2 \sqrt{\frac{2nq(1-q)(r+1)}{\tau_2}} - [d + \frac{1}{(2q-1)n}] \tau_2 - f, \frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2} < \tau_2 < \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2} \\ -f, \tau_2 \geq \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2} \end{cases} \end{aligned} \quad (16)$$

具体证明见附录 A, 将 $\frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2} \geq \tau_2$, $\frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2} < \tau_2 < \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2}$, $\tau_2 \geq$

$\frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2}$ 分别记为情形 1, 情形 2 和情形 3。

公式 (14) 描述了信贷方进行纵向联邦合作最优数据维度的购买量受数据价格的影响, 也反应出不同数据质量和定价策略对数据购买量的影响^[34]。对于情形 1, 当数据合作企业对自身的数据定价较低时, 信贷方最优决策的数据购买量为 $1-d$, 即表明信贷方愿意将市场上所有跟借款人数字足迹有关的风险特征都进行联邦建模, 此时通过丰富对借款人的全息画像提高筛选能力得到的利润增益要大于数据购买带来的成本。在现实中, 由于一个数据合作企业不可能拥有所有的数据维度, 因此通常其给信贷方通过纵向联邦带来的数据维度增量并不能达到 $1-d$ 。而对于数据维度特征较多但信息质量较低的数据合作企业可以采用此种薄利多销的数据定价方法, 通过降低数据资产价格提高信贷方的数据购买量, 从而达到自身的利润最大化。如通信运营商掌握大量借款客户的手机相关数据, 这些数据量十分丰富但是真正对判断借款人违约有关的数据字段并不多, 则可以采取此种定价策略。对于情形 2, 当数据合作企业对自身数据定价适中时, 信贷方的最优数据购买量为 Δd^* , 注意到此时的临界情况为 $\tau_2 = \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2}$, 当信贷方的数据维度越多时, 数据合作企业若想通过联邦合作的可

定价范围越小。由于此时 $\Delta d^* < 1-d$, 这表明信贷方只是有选择的购买数据维度, 在现实中, 对于具有高信息质量的数据合作企业, 可以采用这种数据加工精益求精的策略, 通过提高数据价格的方式来获得更高的利润, 如支付宝微信等互联网企业, 包含可以评价借款人日常消费和社交网络的关键核心数据, 则可以采用此种定价策略。对于情形 3, 当数据合作企业对自身的数据定价过高时处于市场失衡阶段, 信贷方的数据购买量为 0, 此时信贷方的最优策略是不进行纵向联邦建模, 因为通过联邦建模购买的数据成本大于增加数据维度提高筛选能力带来的收益。

公式 (15) 和公式 (16) 给出了在最优数据购买维度下的信贷方和数据合作方的期望利润, 公式表明信贷方的期望利润随着数据合作企业的数据价格的增高而下降, 而数据合作方的期望利润先升高后下降, 在后文的敏感性分析中进行更详细的阐述。

2.3 敏感性分析

本节对上述建立的模型进行敏感性分析, 并通过数值仿真的方式直观展示了理论分析的结果。我们从三个角度考察合作方数据价格、信贷方规模和市场质量的影响, 包括信贷方最

优购买维度、信贷方合作前和合作后期望利润，以及合作方期望利润。

2.3.1 合作方数据价格对最优购买维度和期望利润的影响

通过命题 1 我们发现数据合作方对数据资产的定价是影响信贷方决策的关键，不仅会影响合作方的期望利润，也会影响信贷方的最优决策和期望利润，本小节通过敏感性分析具体考察数据合作方数据价格对最优购买维度和期望利润的影响，具体可将结论归纳为如下命题：

命题 2 信贷方的最优购买维度和期望利润随数据合作方的数据价格的增大而减小，数据合作方的期望利润随其数据价格先增大后减小。即公式 (17)：

$$\begin{aligned} \frac{\partial \Delta d}{\partial \tau_2} &= \begin{cases} = 0, \tau_2 \in [0, \tau'] \\ < 0, \tau_2 \in (\tau', \tau''] \\ = 0, \tau_2 \in (\tau'', \infty) \end{cases} \\ \frac{\partial \pi'}{\partial \tau_2} &= \begin{cases} < 0, \tau_2 \in [0, \tau'] \\ < 0, \tau_2 \in (\tau', \tau''] \\ = 0, \tau_2 \in (\tau'', \infty) \end{cases} \\ \frac{\partial \pi_p}{\partial \tau_2} &= \begin{cases} > 0, \tau_2 \in [0, \tau^*] \\ < 0, \tau_2 \in (\tau^*, \tau''] \\ = 0, \tau_2 \in (\tau'', \infty) \end{cases} \end{aligned} \quad (17)$$

证明及 τ' 、 τ'' 、 τ^* 的数学表达式详见附录 B。

总体而言，数据合作企业的数据价格显著影响了信贷方的最优决策，同时决定了信贷方和数据合作方的期望利润，给定其他参数（ $q = 0.8$ ， $r = 0.15$ ， $n = 0.8$ ， $d = 0.7$ ， $\tau_1 = 0.05$ ， $f = 0.005$ ），图 1 和图 2 描述了数据价格的影响。当数据价格较低时（ $0 < \tau_2 < 0.132$ ）对应情形 1 薄利多销阶段，根据命题 1 可知，此时信贷方的最优购买维度为 $1 - d$ ，即愿意尽最大可能购买所有与借款人风险特征相关的数字足迹。随着数据价格的不断提升，由于数据购买量不变，因此数据合作方利润逐渐增大（对应图 2 中倒三角标记线），信贷方利润不断减小（对应图 2 中五角星标记线）。当数据价格较高时（ $0.132 < \tau_2 < 0.166$ ）对应情形 2 精益求精阶段，在该情形下，信贷方的最优购买量逐渐下降，由于数据价格提高带来的收益无法弥补购买量下降带来的损失，因此数据合作企业的期望利润从最高点不断下跌，由于数据购买量下降使得信贷方筛选能力下降，从而导致信贷业务利润的下跌无法由支付给合作方数据报酬减小带来的盈余弥补，因此信贷方的总体期望利润也进一步下降，此时社会总体福利下降。当数据价格过高时（ $\tau_2 > 0.166$ ）对应情形 3 市场失衡阶段，此时信贷方的最优决策是不购买任何数据，但是由于联邦建模存在固定成本，因此信贷方在进行联邦合作之后的利润低于联邦合作之前本身的利润（对应图 2 中圆形标记线），在该数据价格下，信贷方不应该进行联邦合作。

综上所述，对于信贷方来说，只有当联邦学习合作建模带来的期望利润比合作前更高时，才有动力推动联邦合作，对于数据合作方来说，在合作后的期望利润大于 0，才会进行数据交易。当双方均满足参与约束条件时，对应图 2 中即 $\tau_2 \in [0.016, 0.132)$ ，此时才处于最优的数据定价区间。

在最优数据定价区间内，进行联邦合作后，数据方和信贷方的利润进行同等程度的上升和下降，这说明数据方和信贷方的利润总和保持不变，因此数据价格起到对数据赋能带来经济价值的分配作用，数据价格越高，数据方分配得到的数据增效越多。可以根据信贷方和合作方的数据对模型的贡献度来衡量不同参与方的数据价值，实现对联邦合作带来超额收益的合理分配，从而达到各个参与方不断提高自身数据质量、提升模型筛选能力的良性循环的目的。




图1 数据价格对信贷方最优购买维度的影响




图2 数据价格对利润的影响

2.3.2 其他因素对最优购买维度和期望利润的影响

除了合作方的数据价格外，信贷联邦合作的最优策略还受到信贷方规模、市场质量等因素的影响，分析这些因素对最优数据维度购买量以及信贷方和数据合作方利润的影响，可以为数据优势方选择合适的信贷合作伙伴提供实践指导。这些因素的具体影响可总结为以下命题：

命题3 信贷方的最优购买维度与合作方利润随信贷方自身规模的增大而增大，进行联邦合作后的信贷方的期望利润与其数据获取成本有关，对于数据成本低的信贷方利润随自身规模的增大而增大，数据成本高的信贷方利润则先增大后减小。即公式（18）：

$$\frac{\partial \Delta d}{\partial n} = \begin{cases} = 0, n \in [0, n'] \\ > 0, n \in (n', n''] \\ = 0, n \in (n'', 1] \end{cases}$$

$$\frac{\partial \pi_p}{\partial n} = \begin{cases} = 0, n \in [0, n'] \\ > 0, n \in (n', n''] \\ = 0, n \in (n'', 1] \end{cases} \quad (18)$$

$$0 < \tau_1 \leq \tau_1^* \text{ 时, } \frac{\partial \pi'}{\partial n} > 0, n \in [0, 1]$$

$$\tau_1^{**} > \tau_1 > \tau_1^* \text{ 时, } \frac{\partial \pi'}{\partial n} = \begin{cases} > 0, n \in [0, n^*] \\ < 0, n \in (n^*, 1] \end{cases}$$

命题 4 信贷方联邦合作后对比合作前的利润增益随信贷方规模的增大而增大，当信贷方达到一定规模后，进行联邦合作的信贷方才能通过联邦建模获得超额利润。即公式 (19)：

$$\frac{\partial y}{\partial n} > 0, \quad y = \pi' - \pi \quad (19)$$

命题 3 和命题 4 证明详见附录 C 和附录 D。

命题 3 和命题 4 给出了信贷方规模即数据样本量对最优购买维度和利润的影响。给定其他参数 ($q=0.8, r=0.15, d=0.7, \tau_2=0.1, f=0.005$)，图 3、图 4 和图 5 通过数值算例模拟了数据样本量的影响。其中图 3 为数据样本量对信贷方最优购买维度的影响，图 4 为数据获取成本较小时 ($\tau_1=0.0001$) 信贷方数据样本量对利润的影响，图 5 为数据获取成本较大时 ($\tau_1=0.05$) 信贷方数据样本量对利润的影响。当信贷方规模较小即数据样本量较少时 ($0 < n < 0.36$)，对应情形 1，由于数据样本量较小使得在固定 τ_2 的情景下满足 $\tau_2 > \tau''$ ，此时最佳的数据购买量为 0，因此不进行联邦合作反而信贷方能够获得更大的利润。当信贷方数据样本量适中时 ($0.36 < n < 0.44$)，对应情形 2，在固定 τ_2 的情景下满足 $\tau' < \tau_2 < \tau''$ ，此时最优购买维度逐渐增高，而参与联邦合作后的信贷方期望利润的增速高于不进行联邦合作的信贷方期望利润，双方的利润差距逐渐减小，在附录 D 中我们给出具体证明。当数据样本量较高时 ($0.44 < n < 1.0$)，对应情形 3，在固定 τ_2 的情景下满足 $\tau_2 > \tau''$ ，由于数据样本量越高涉及到的数据搜集成本越高，因此根据数据获取成本的大小 (τ_1) 分为两种情况，当数据获取成本较小时对应图 4，此时联邦合作后和合作前的信贷方利润都随数据样本量的增大而增大；当数据获取成本较大时对应图 5，此时存在最优的信贷方规模使得信贷方的期望利润达到最大值。但是不论信贷方数据获取成本如何，当信贷方达到一定规模时，参与联邦合作的期望利润（图 4/图 5 中的五角星标记线）总是高于基准利润（图 4/图 5 中的圆形标记线），这一段构成了数据交易的合作空间。




图 3 数据样本量对信贷方最优购买维度的影响




图 4 数据获取成本较小时信贷方规模对利润的影响




图 5 数据获取成本较大时信贷方规模对利润的影响

命题 5 信贷方的最优购买维度与合作方利润随市场质量的增大而减小，联邦合作后的信贷方期望利润随市场质量的增大而增大。即可用公式 (20) 表示：

$$\frac{\partial \Delta d}{\partial q} = \begin{cases} = 0, q \in [0.5, q'] \\ < 0, q \in (q', q'') \\ = 0, q \in (q'', 1] \end{cases}$$

$$\frac{\partial \pi_p}{\partial n} = \begin{cases} = 0, q \in [0.5, q'] \\ > 0, q \in (q', q'') \\ = 0, q \in (q'', 1] \end{cases} \quad (20)$$

$$\frac{\partial \pi'}{\partial n} > 0, q \in [0.5, 1]$$

命题 6 信贷方联邦合作后对比合作前的超额利润随市场质量的增大而减小，在借款人违约风险较高的市场上进行纵向联邦合作更有助于提升利润。即公式 (21)：

$$\frac{\partial y}{\partial q} < 0, \quad y = \pi' - \pi \quad (21)$$

证明详见附录 E 和附录 F。

命题 5 和命题 6 描述了市场质量的影响，控制其他参数不变 ($q=0.8, r=0.15, n=0.9, d=0.7, \tau_1=0.05, \tau_2=0.1, f=0.005$)，图 6 和图 7 仿真模拟出市场质量对最优购买维度和参与方利润的影响。由图 7 可知，在市场质量较差借款人违约风险较高的市场中 ($0.5 < q < 0.84$)，信贷方才有动力进行联邦合作建模，并且违约风险越高的市场通过联邦建模获得的利润增益更大，但是考虑到信贷方需要满足生存的基本条件，因此进行联邦建模的最佳市场质量为 $0.7 < q < 0.84$ ，这一段构成了数据交易的合作空间。

以上命题表明，对于规模较大服务于较低市场质量的信贷方更适合建立联邦模型。此外，信贷方的数据获取成本也是最优利润的影响因素，通常数据获取成本较小的信贷方是通过规模效应获得更大的数据样本量，其通过联邦合作能够实现的期望利润更大；而数据获取成本较大的信贷方则需要较高的获客成本，其需要合理评估是否能够通过联邦合作获得利润增益。




图 6 市场质量对最优购买维度的影响




图 7 市场质量对利润的影响

3 实证检验

本节采用某互联网小贷公司的借贷数据，通过构建纵向联邦学习模型，对前述理论分析进行实证检验。首先，我们构建了可用于实践的量化数据经济价值的评价指标；其次，介绍了实证数据来源并进行描述性统计；最后，对比分析了联邦模型的效果，并基于平台类型讨论了数据交易定价策略。本实证采用的联邦逻辑回归模型具体实现算法详见附录 G。

3.1 指标构建

本节构建了用于评价模型经济价值的两个指标，经济增加值（Value-added）和利润增加值（Profit-added），该指标在 Khandani [32] 提出指标的基础上进行改进，使其能够较好的反应模型带来的经济利益。根据前文的分析，可以计算出应用模型预测前和预测后的利润。

$$\pi_{no\ forecast} = \sum_{i \in \{TP+FN\}} M_i * r_i - \sum_{i \in \{FP+TN\}} M_i \quad (22)$$

$$\pi_{forecast} = \sum_{i \in \{TP\}} M_i * r_i - \sum_{i \in \{FP\}} M_i \quad (23)$$

$\pi_{no\ forecast}$ 为没有模型预测时的利润，由正常还款的客户利息收入减去违约的本金损失构成。 $\pi_{forecast}$ 为有模型预测时的利润，信贷机构对预测违约的客户均不进行贷款，因此只需考虑预测为正常的客户中的实际正常客户带来的利润和实际违约客户的本金损失。

$$\Delta\pi = \pi_{forecast} - \pi_{no\ forecast} = \sum_{i \in \{TN\}} M_i - \sum_{i \in \{FN\}} M_i * r_i \quad (24)$$

我们用公式 (22) 减去公式 (23) 得到带来的利润增加值，同样分为两部分，包括判断正确违约客户节约的本金损失和判断错误正常客户少赚到的钱。

接下来计算经济增加值（Value-added），首先与上文中一样我们考虑当模型预测效果最

好时，将所有坏客户都拒绝掉时最多能够带来的利润的增加额为 $\sum_{i \in \{TP+FN\}} M_i * r_i + \sum_{i \in \{TN+FP\}} M_i$ ，令 $\Delta\pi$ 比上最大利润即可得到经济增加值。

$$\begin{aligned} Value - added &= \frac{\Delta\pi}{\sum_{i \in \{TP+FN\}} M_i * r_i + \sum_{i \in \{TN+FP\}} M_i} \\ &= \frac{\sum_{i \in \{TN\}} M_i - \sum_{i \in \{FN\}} M_i * r_i}{\sum_{i \in \{TP+FN\}} M_i * r_i + \sum_{i \in \{TN+FP\}} M_i} \end{aligned} \quad (25)$$

另外一个指标利润增加值（Profit-added）。由于当采用模型预测时实际的贷款金额少于没有用模型预测的情况，而对于节省的贷款金额还可以继续进行放贷获得利润，因此我们可以对比在有模型和无模型下的利润率增加值。

$$\begin{aligned} Profit - added &= \frac{\pi_{no \text{ forecast}}}{\sum_{i \in \{TP+FP+TN+FN\}} M_i} - \frac{\pi_{forecast}}{\sum_{i \in \{TP+FP\}} M_i} \\ &= \frac{\sum_{i \in \{TP+FN\}} M_i * r_i - \sum_{i \in \{FP+TN\}} M_i}{\sum_{i \in \{TP+FP+TN+FN\}} M_i} \\ &\quad - \frac{\sum_{i \in \{TP\}} M_i * r_i - \sum_{i \in \{FP\}} M_i}{\sum_{i \in \{TP+FP\}} M_i} \end{aligned} \quad (26)$$

3.2 数据描述

实证的数据来自于某市地方金融风险防控平台的非现场监管系统，该系统包含了某市 60 家互联网小贷平台的小额贷款借贷数据。这些互联网小贷公司需要定期将贷款数据报送给监管平台，同时监管方也会在会接入其他各个维度的数据以防范信用违约风险，附录 H 给出具体数据指标。我们对违约的定义采用《新巴塞尔协议》的认定标准，将贷款合同到期后 90 天内未足额清偿视作违约。表 2 展示了 2017-2019 三年期间的针对借款企业的样本描述性统计，可以发现坏账率并不高，大概在 3.05%，平均借款金额为 84,120 元，借款利率为 11.98%，这些指标为评价模型经济价值提供基础。

表 2 数据样本的描述性统计

	数据描述
平均借款金额	84,120
平均借款利率	11.98%
好样本量	35,485
坏样本量	1,118
总样本量	36,613
坏账率	3.05%

3.3 实证结果

3.3.1 联邦建模效果对比

首先我们对比联邦模型与本地模型、全局模型的建模效果。本地模型包含指标为信贷方在接到借款申请的信息，包括本次贷款信息、历史贷款信息、企业工商信息，采用逻辑回归模型训练模型。全局模型包含指标除了本地模型的指标外，还包括接入的司法信息和税务信息，也直接采用了逻辑回归训练模型，此时没有考虑数据的隐私属性，而是将所有数据放到一起训练模型。联邦模型也采用了和全局模型中一样的指标，但考虑数据的隐私和敏感性采用附录 G 中联邦逻辑回归模型^[33]，三个模型的指标如表 3 所示。

表 3 本地模型、全局模型、联邦模型指标构成

	模型 1 本地模型	模型 2 全局模型	模型 3 联邦模型
本次贷款信息指标	√	√	√

历史贷款信息指标	✓	✓	✓
工商信息指标	✓	✓	✓
司法信息指标		✓	✓
税务信息指标		✓	✓
是否采用联邦建模			✓
包含指标数目	19	25	25

我们用 AUC 指标来评价模型预测效果,用上一小节构建的经济增加值和利润增加值来评价模型的经济效果。图 8 展示了三个模型的 ROC 曲线,表 4 展示了三个模型的评价效果。从 ROC 曲线来看,本地模型效果表现较差,而联邦模型和全局模型要明显高于本地模型。联邦模型略逊于全局模型,在假阳性较高时,全局模型具有更高的真阳率,但是整体上两者差距很小,AUC 值也证明了这点,这表明联邦建模可以在隐私保护条件下达到几乎等同于全局模型的效果。从模型带来经济效果来看,同样联邦模型带来的经济价值与全局模型较为接近,且显著高于本地模型。

表 4 本地模型、全局模型、联邦模型建模效果对比

	模型 1 本地模型	模型 2 全局模型	模型 3 联邦模型
$\pi_{no\ forecast}$	167,472,404	167,472,404	167,472,404
$\pi_{forecast}$	249,512,728	271,032,250	268,704,306
<i>Profit – added</i>	2.63%	3.37%	3.26%
<i>Value – added</i>	13.16%	16.40%	16.24%
<i>AUC</i>	0.938	0.970	0.966




图 8 本地模型、全局模型、联邦模型 ROC 曲线

表 5 根据联邦模型相对于本地模型的经济价值,尝试根据贡献度分配收益。第一类是基于模型预测效果的贡献度,即通过 AUC 的提升度来计算分配到数据方的比例,在没有任何预测时 AUC 最小为 0.5,因此引入司法税务数据的数据方分配比例为 $(0.966-0.938)/(0.966-0.5)=6.01\%$ 。第二类是基于模型经济价值的贡献度,联邦模型带来的模型的利润提升度为 19,191,578,利润提升度占联邦模型带来的利润比值即应该分配给数据方的收益比例,经计算为 7.14%。上述两种方法计算得到的比例只考虑了模型预测效果,并没有考虑节约贷款占用带来的机会成本,而经济增加值和利润增加值可以很好的解决这个问题,通过经济增加值和利润增加值计算得到的数据方分配比例要高于 AUC 和模型利润,分别为 18.97%和 19.33%。

在四种收益分配比例中,基于经济增加值和利润增加值指标构建的收益分配方案考虑更加全面,对数据方分配比例较高,同时兼顾了模型带来的收益和成本,更有利于激励数据方参与合作。

表 5 收益分配比例计算

	联邦模型	本地模型	提升度	数据方比例	信贷方比例
$\pi_{forecast}$	268,704,306	249,512,728	19,191,578	7.14%	92.86%
Value – added	16.24%	13.16%	3.08%	18.97%	81.03%
Profit – added	3.26%	2.63%	0.63%	19.33%	80.67%
AUC	0.966	0.938	0.28	6.01%	93.99%

3.3.2 基于理论模型的定价策略量化分析

为强化理论模型与实证检验的关联,本小节将实证中的四个平台置于统一框架下进行参数化分析,以验证理论推导出的定价情形与策略的有效性。四个平台的基本特征描述如表 6 所示。平台 1 和平台 3 客户违约率较小,因此不采用模型预测时就可以获得正利润,平台 2 和平台 4 则违约率较高,利润较差。

表 6 不同平台类型指标统计

	平台 1	平台 2	平台 3	平台 4
总样本量	710	149	23,803	1,364
坏样本量	10	61	66	708
违约率	1.41%	40.94%	0.28%	51.90%
信贷规模	小	小	大	大
市场质量	好	差	好	差
$\pi_{no\ forecast}$	20,666,301	-1,423,696	129,532,554	-4,683,091

接下来将实际数据进行参数化,并推导它们各自所处的理论情形。对于规模代理变量(n),需要将其归一化到[0,1]区间,将每个平台的样本量取对数后按照比例进行给值,平台 1 和平台 2 规模较小,分别取 0.5 和 0.4,平台 3 和平台 4 则取 0.9 和 0.8。对于市场质量,按照 1 减去违约率进行计算。由于平台 4 违约率为 51.90%,按照理论模型,市场质量需要大于 0.5,因此这里设置为 0.5 以代表其较差的市场质量。的其他模型参数统一设置如下:信贷方自身数据维度(d)为 0.6,贷款利率(r)为 0.15,联邦建模固定成本(f)为 0.002。参数化结果及据此计算的理论价格阈值(τ' 和 τ'')、联邦合作前利润(π)如下表 6 所示。在此基础上,我们为每个平台模拟了三种数据定价策略(低、中、高),并计算了相应最优数据购买量(Δd)、联邦合作后信贷方利润(π')、利润增加值($\Delta \pi = \pi' - \pi$)及数据方利润(π_p)。根据表 7 的模拟计算结果,可以为每个平台得出兼具理论依据和实证支持的定价策略。

平台 1 (规模小、质量高): 其理论价格阈值 τ' 与 τ'' 极低 (分别为 0.007 和 0.010)。模拟显示,仅在数据价格 $\tau_2=0.006$ (情形 1) 时,合作双方能获得非负利润,但利润增加值近乎为零。一旦价格升高至情形 2 或情形 3,信贷方利润即受损。这表明,对于此类平台,数据交易带来的经济价值空间非常有限。因此,数据方应采取低定价策略,且需谨慎评估是否与之开展联邦合作,因为微小的成本或价格波动都可能导致合作无法产生正收益。

平台 2 (规模小、质量差): 该平台联邦合作前利润为负,凸显其提升风控能力的迫切性。其理论价格阈值 τ' 与 τ'' 较高 (0.194, 0.204)。在 $\tau_2=0.100$ (情形 1) 时,信贷方能实现利润显著提升 ($\Delta \pi=0.039$),同时数据方也能获得可观利润 ($\pi_p=0.039$)。由于市场质量差,引入越多数据维度对风控准确率的边际提升效果显著。因此,对这类平台最有效的策略是薄利多销,通过较低的价格促使信贷方购买尽可能多的数据维度,从而实现双方利润最大化。

表 7 不同平台类型的理论参数量化

	n	q	τ'	τ''	π	情形	τ_2	Δd	π'	$\Delta \pi$	π_p
平台 1	0.5	0.986	0.007	0.010	0.120	情形 1	0.006	0.400	0.120	0.000	0.001
						情形 2	0.008	0.241	0.119	-0.001	0.001
						情形 3	0.010	0.000	0.119	-0.001	-0.001
平台 2	0.4	0.591	0.194	0.204	-0.209	情形 1	0.100	0.400	-0.171	0.039	0.039
						情形 2	0.200	0.162	-0.210	-0.001	0.031
						情形 3	0.300	0.000	-0.210	-0.001	-0.001
平台 3	0.9	0.995	0.003	0.004	0.090	情形 1	0.001	0.400	0.090	0.000	-0.000
						情形 2	0.003	0.357	0.089	0.000	0.000
						情形 3	0.005	0.000	0.089	-0.001	-0.001
平台 4	0.7	0.500	0.403	0.403	-0.220	情形 1	0.300	0.400	-0.180	0.040	0.119
						情形 3	0.500	0.000	-0.221	-0.001	-0.001

平台 3 (规模大、质量好)：虽然其规模优势明显 ($n=0.9$)，但极高的市场质量 ($q=0.995$) 导致其理论价格阈值极低 ($\tau'=0.003$, $\tau''=0.004$)。模拟结果显示，即使在情形 1 下，由于数据开支摊薄了收益，利润增加值和数据方利润均接近零甚至为负。因此，盲目采取低定价、全维度购买的“薄利多销”策略并不可行。相反，数据方应为其提供精益求精的策略，即聚焦于提供那些能关键性提升风控能力的少数高价值维度，依靠其自身庞大的样本量优势来实现风控模型的精进与利润增长。

平台 4 (规模大、质量差)：此类平台同时具备规模大和风控能力提升需求迫切两大特征。其理论价格阈值 ($\tau'=\tau''=0.403$) 远高于其他平台。在 $\tau_2=0.300$ (情形 1) 时，信贷方利润得到大幅改善 ($\Delta \pi=0.040$)，而数据方也能获得极高的回报 ($\pi_p=0.119$)。这表明，数据方对此类金融机构具备很强的定价权。因此，对平台 4 最适合采用高定价策略，在保证合作能够达成 (信贷方利润提升) 的前提下，最大限度地数据赋能带来的经济价值转化为数据方自身的收益。

3.3.3 实证结果的对照分析

前述基于理论模型的量化模拟，为差异化定价策略提供了数理逻辑上的支持。接下来，我们通过对比真实数据下的联邦建模效果，对理论分析结果进行交叉验证。

表 8 给出了采用本地模型和联邦模型下的利润、利润增加值和经济增加值，以及联邦模型相对于本地模型的指标提升比例。平台 1 的实证结果显示，引入联邦学习后，其利润增加值与经济增加值均出现负增长 ($\Delta \pi_{forecast}=-3.73\%$, $\Delta Value-added=-100\%$)。这一现象印证了理论模型的预测：对于此类规模较小、市场质量极高的信贷方，数据赋能带来的边际收益非常有限。这类机构在实践中通常类似于大型集团旗下的消费金融公司，其依托主业场景展业，客群优质、风险可控，自身风控模型已接近饱和。

平台 2 的实证效果较为显著，联邦学习使其利润率提升了 14.16%。这与理论模拟中其能在“薄利多销”策略下实现可观利润增加值 ($\Delta \pi=0.039$) 的结论也相对应。该平台代表了现实中那些服务于当地中小微企业的传统小额贷款机构。它们面临信息不透明、抵押物不足的困境，风控成本高、违约风险大。对于此类机构，通过联邦学习引入外部数据是破解其风控难题、实现利润扭转的关键路径。

平台 3 在联邦学习后获得了正向但相对有限的利润提升 ($\Delta \pi_{forecast}=0.13\%$)，这与理论模拟中其利润增益微薄 ($\Delta \pi \approx 0$) 的结论相符。但是通过其超大的数据样本量实现规模收益，因此利润增加值显著提高 ($\Delta Value-added=46.67\%$)。此类平台对应大型商业银行，其客户经过严格筛选，资质优良，内部数据体系完善，导致外部数据的边际贡献相对

较低。实证结果验证了理论模型的推断：尽管其规模巨大，但由于极高的原生市场质量，数据交易能创造的整体经济价值空间确实受限，若要引入数据，则需要精益求精策略，提供高价值维度的数据，依靠规模优势获得利润空间。

平台 4 在实证中展现了最强烈的合作价值，利润提升幅度高达 66.82%。这完美地印证了理论模型将其定位为最具合作价值类型的判断。此类机构对应于现实中的金融科技类互联网金融公司或网络小贷，它们服务的是被传统银行体系所忽略的长尾客群，市场规模大但信用风险高。其实证结果验证了理论模型的核心预测：对于这类机构，数据要素是其风控能力的刚需，通过联邦合作能够释放巨大的经济价值。

综上所述，基于真实数据的实证结果与基于理论模型的量化模拟形成了强有力的相互印证。这种交叉验证不仅表明本文的理论模型具备良好的现实解释力和预测能力，更重要的是，它从数理逻辑与实证效果两个维度，共同系统性地证实了数据交易定价策略的有效性与科学性。

表 8 不同类型平台模型效果

		平台 1	平台 2	平台 3	平台 4
本地模型下	$\pi_{forecast}$	21,466,301	843,091	129,938,154	-113,787
	$Profit - added$	0.46%	18.15%	0.05%	52.31%
	$Value - added$	2.99%	54.01%	0.30%	93.36%
联邦模型下	$\pi_{forecast}$	20,666,301	962,511	130,112,705	-37,758
	$Profit - added$	0	19.44%	0.07%	66.94%
	$Value - added$	0	56.85%	0.44%	94.91%
联邦模型对比	$\Delta\pi_{forecast}$	-3.73%	14.16%	0.13%	66.82%
本地模型提升	$\Delta Profit - added$	-100.00%	7.11%	40.00%	27.97%
度	$\Delta Value - added$	-100.00%	5.26%	46.67%	1.66%

4 结语

中小微企业和个体工商户是国民经济的生力军，如何解决其生产经营中面临的融资问题关乎实体经济的活力。通过信贷方与数据方纵向联邦合作的信用风险评估联合建模，可以增加对借款人的风险特征维度，从而提高对违约风险的精准识别和预测，增加中小微企业的贷款获得性，提高金融机构的经济效益，实现数据的使用价值和经济价值。鉴于此，本文构建并求解了信贷方与数据企业的期望利润模型与合作数据维度的定价策略，通过数值算例分析了数据价格等因素对信贷方和数据合作企业期望利润的影响，进一步在实证上构建了反应模型价值贡献度的经济增加值（Value-added）和利润增加值（Profit-added）指标，并通过实际数据的理论量化模拟和实证效果检验，证明了联邦学习带来经济效果，更从实践层面揭示了在不同类型金融机构中的数据交易定价策略。

根据上述研究发现，我们给出以下三点管理启示与政策建议：

（1）对于政府部门来说，要健全信用信息共享协调机制，特别要推动掌握大量具有隐私的公共数据的政府部门，在保护公民隐私的前提下加强与金融机构开展采用联邦学习建模，推动公共数据赋能普惠金融。

（2）对于进行信贷业务的金融机构来说，我们发现具有一定规模和数据样本量，以及服务于高风险市场的信贷方更容易通过纵向联邦合作获得更高的期望利润，因此对于此类金融机构，如众多具有互联网平台资源的金融科技公司，可以与政府、通信运营商和互联网公司掌握大量数据资源的数据优势方开展联邦学习建模合作，运用多维度大数据完善信用评级模型，实现对中小微企业的精准画像。

(3) 对于具有数据优势的合作方来说, 数据使用价格起到对数据赋能带来经济价值的分配作用, 应该在保证自身和信贷方期望利润大于零的前提下根据经济价值采用个性化的合理定价策略, 例如可以根据各参与方的模型贡献度指标来调整数据价格, 从而最大限度激励数据交易, 释放数据的经济价值。

本研究亦存在一些局限性, 可为未来研究提供方向。实证分析所采用的数据来源于 2017-2019 年, 未能覆盖 2020 年后互联网金融监管政策深度调整及新冠疫情等外部冲击时期。尽管本文的核心目的在于揭示联邦学习下数据交易定价的内在机理与普遍规律, 其理论框架与差异化策略逻辑具有跨周期的参考价值, 但需要指出, 实证中的具体数值(如利润水平)可能随市场环境的波动而变化。因此, 本研究的主要结论更适用于理解数据要素在信贷风控中的价值创造与分配机制, 并为在常态化监管环境下开展数据合作提供理论依据与实践指引, 而非用于精确预测特定时间点的市场绝对表现。未来研究在数据可得的情况下, 可对本研究的结论进行跨时间窗口的稳健性检验。

参考文献

- [1] 刘业政, 孙见山, 姜元春, 等. 大数据的价值发现:4C 模型[J]. 管理世界, 2020, 36(2): 129-138.
Liu Y Z, Sun J S, Jiang Y C, et al. Value discovery of big data: 4C model[J]. Journal of Management World, 2020, 36(2): 129-138.
- [2] Hao J, Deng Z, Li J, et al. How to price a dataset: a deep learning framework for data monetization with alternative data[J]. Humanities and Social Sciences Communications, 2025, 12(1): 1736.
- [3] 巴曙松, 侯畅, 唐时达. 大数据风控的现状、问题及优化路径[J]. 金融理论与实践, 2016, 439(2): 23-26.
Ba S S, Hou C, Tang S D. Status, problems and optimization paths of big data risk control[J]. Financial Theory & Practice, 2016, 439(2): 23-26.
- [4] 马玥, 郭晔. 公共数据开放与商业银行普惠贷款——基于商业银行小微企业贷款的实证分析[J]. 中国管理科学, 2025, DOI: 10.16381/j.cnki.issn1003-207x.2024.1804.
Ma Y, Guo Y. Public Data Opening and Commercial Banks' Inclusive Loans—An Empirical Analysis Based on Small and Micro Enterprises Loans[J]. Chinese Management Science, 2025, DOI: 10.16381/j.cnki.issn1003-207x.2024.1804.
- [5] 綦勇, 侯泽敏, 曹金霞. 差异化隐私数据保护政策下的厂商数据利用策略研究[J]. 中国管理科学, 2025, 33(3), 151-161.
Qi Y, Hou Z M, Cao J X. Research on enterprise data utilization strategies under differential privacy protection policies[J]. Chinese Management Science, 2025, 33(3), 151-161.
- [6] 杨强等. 联邦学习[M]. 北京: 电子工业出版社, 2020.
Yang Q, et al. Federated Learning[M]. Beijing: Publishing House of Electronics Industry, 2020.
- [7] 席轩, 张玉林. 考虑数据优势的在线平台数据投资和定价决策[J]. 中国管理科学, 2025, 33(12), 87-99.
Xi X, Zhang Y L. Data investment and pricing decisions of online platforms considering data advantages[J]. Chinese Management Science, 2025, 33(12), 87-99.
- [8] 蔡继明, 刘媛, 高宏, 等. 数据要素参与价值创造的途径——基于广义价值论的一般均衡分析[J]. 管理世界, 2022, 38(07): 108-121.
Cai J M, Liu Y, Gao H, et al. Approaches to value creation through data elements—General equilibrium analysis based on generalized value theory[J]. Journal of Management World, 2022, 38(07): 108-121.
- [9] 龚强, 班铭媛, 刘冲. 数据交易之悖论与突破: 不完全契约视角[J]. 经济研究, 2022, 57(07): 172-188.
Gong Q, Ban M Y, Liu C. Paradox and breakthrough in data trading: An incomplete contract perspective[J]. Economic Research Journal, 2022, 57(07): 172-188.
- [10] 陈荣达, 王宸, 潘陈新, 等. 数据要素市场化对企业绩效的影响: 来自中国上市公司的经验证据[J]. 中国

管理科学, 2025, 33(10): 1-11.

Chen R D, Wang C, Pan C X, et al. The Impact of Data Factor Marketization on Firm Performance: Empirical Evidence from Chinese Listed Companies[J]. Chinese Management Science, 2025, 33(10): 1-11.

[11]樊必武, 高峰, 赵越, 等. 基于拓展 CAPM-BS 模型的企业数据资产估值定价研究[J]. 中国管理科学, 2025, DOI: 10.16381/j.cnki.issn1003-207x.2024.0059.

Fan B W, Gao F, Zhao Y, et al. Valuation and Pricing of Enterprise Data Assets Based on an Extended CAPM-BS Model[J]. Chinese Management Science, 2025, DOI: 10.16381/j.cnki.issn1003-207x.2024.0059.

[12]Cong L W, Xie D, Zhang L. Knowledge accumulation, privacy, and growth in a data economy[J]. Management Science, 2021, 67(10): 6480-6492.

[13]Jones C I, Tonetti C. Nonrivalry and the economics of data[J]. American Economic Review, 2020, 110(9): 2819-2858.

[14]王今朝, 窦一凡, 黄丽华, 等. 数据产品交易的定价研究: 进展评述与方法比较[J]. 价格理论与实践, 2023, (4): 22-27.

Wang J C, Dou Y F, Huang L H, et al. Pricing research on data product transactions: review and comparison of methods[J]. Price:Theory & Practice, 2023, (4): 22-27.

[15]Yang Q, Liu Y, Chen T, et al. Federated machine learning: concept and applications[J]. ACM Transactions On Intelligent Systems and Technology, 2019, 10(2): 1-19.

[16]黄益平, 邱晗. 大科技信贷: 一个新的信用风险管理框架[J]. 管理世界, 2021, 37(02): 12-21.

Huang Y P, Qiu H. Big tech lending: a new credit risk management framework[J]. Journal of Management World, 2021, 37(02): 12-21.

[17]王正位, 周从意, 廖理, 等. 消费行为在个人信用风险识别中的信息含量研究[J]. 经济研究, 2020, 55(01): 149-163.

Wang Z W, Zhou C Y, Liao L, et al. Research on the information content of consumer behavior in personal credit risk identification[J]. Economic Research Journal, 2020, 55(01): 149-163.

[18]Ou W, Zeng J, Guo Z, et al. A homomorphic-encryption-based vertical federated learning scheme for risk management[J]. Computer Science and Information Systems, 2020, 17(3): 819-834.

[19]郭艳卿, 王鑫磊, 付海燕, 等. 面向隐私安全的联邦决策树算法[J]. 计算机学报, 2021, 44(10): 2090-2103.

Guo Y Q, Wang X L, Fu H Y, et al. Privacy-preserving federated decision tree algorithm[J]. Chinese Journal of Computers, 2021, 44(10): 2090-2103.

[20]Liang Y, Liu Z, Song Y, et al. A methodology of trusted data sharing across telecom and finance sector under china's data security policy[C]//2021 IEEE International Conference on Big Data, Orlando, USA, December15-18, IEEE, 2021:5406-5412.

[21]Cheng K, T. F, Y. J, et al. Secureboost: a lossless federated learning framework[J]. IEEE Intelligent Systems, 2021, 36(6): 87-98.

[22]Chen X, S. Z, B. G, et al. Fed-eini: an efficient and interpretable inference framework for decision tree ensembles in vertical federated learning[J].ArXiv, 2021, DOI: arXiv:2105.09540.

[23]Cong L W, Wei W, Xie D, et al. Endogenous growth under multiple uses of data[J]. Journal of Economic Dynamics and Control, 2022, 141: 104395.

[24]谢丹晔, 魏文石, 李尧, 等. 数据要素配置、信贷市场竞争与福利分析[J]. 中国工业经济, 2022, (08): 25-43.

Xie D X, Wei W S, Li Y, et al. Allocation of data elements, credit market competition, and welfare analysis[J]. China Industrial Economics, 2022, (08): 25-43.

[25]李三希, 王泰茗, 刘小鲁. 数据投资、数据共享与数据产权分配[J]. 经济研究, 2023, 58(07): 139-155.

-
- Li S X, Wang T M, Liu X L. Data investment, data sharing, and data property rights distribution[J]. *Economic Research Journal*, 2023, 58(07): 139-155.
- [26]申卫星. 论数据用益权[J]. *中国社会科学*, 2020, No.299(11): 110-131.
- Shen W X. On the right to use data[J]. *Social Sciences in China*, 2020, No.299(11): 110-131.
- [27]He Z, Huang J, Zhou J. Open banking: credit market competition when borrowers own the data[J]. *Journal of Financial Economics*, 2023, 147(2): 449-474.
- [28]Broecker T. Credit-worthiness tests and interbank competition[J]. *Econometrica*, 1990, 58: 429-452.
- [29]Hauswald R, Marquez R. Information technology and financial services competition[J]. *The Review of Financial Studies*, 2003, 16(3): 921-948.
- [30]王煜心, 李建平, 郝俊. 集成效用与数据产品最优定价[J]. *中国科学: 信息科学*, 2024, 54(11): 2533-2553.
- Wang Yuxin, Li Jianping, Hao Jun. Aggregated Utility and Optimal Pricing of Data Products [J]. *Scientia Sinica(Informationis)*, 2024, 54(11): 2533-2553.
- [31]林娟娟, 黄志刚, 唐勇. 数据质量、数量与数据资产定价: 基于消费者异质性视角[J]. *中国管理科学*, 2025, 33(05): 88-98.
- Lin J J, Huang Z G, Tang Y. Data Quality, Quantity, and Data Asset Pricing: From the Perspective of Consumer Heterogeneity[J]. *Chinese Management Science*, 2025, 33(05): 88-98.
- [32]Khandani A E, Kim A J, Lo A W. Consumer credit-risk models via machine-learning algorithms[J]. *Journal of Banking & Finance*, 2010, 34(11): 2767-2787.
- [33]Zheng F, Li K, Tian J, et al. A vertical federated learning method for interpretable scorecard and its application in credit scoring[J]. *ArXiv*, 2020, DOI: arXiv:2009.06218.

Data transaction pricing in credit risk Evaluation based on Federated learning

ZHANG Yun-peng¹ WANG Fan¹ WEI Li-jian¹

(1. School of Business, Sun Yat-sen University, Guangzhou 510275, China)

Abstract: Through federated learning modeling between data providers and credit institutions, the feature dimensions of borrowers can be enriched under privacy protection conditions, thereby alleviating information asymmetry in credit risk assessment and enabling data empowerment for inclusive finance. To achieve data transactions and federated learning modeling, it is crucial to establish a reasonable pricing mechanism that incentivizes the participation of both credit institutions and data providers. This paper investigates the pricing mechanism for data transactions in financial credit scenarios through theoretical models and numerical simulations, and tests the pricing mechanism using loan data from online micro-lending companies and federated learning modeling. The study finds that: (1) There exists an optimal data pricing interval within which overall social welfare is maximized. Data pricing serves to distribute the economic value generated by data empowerment, and revenue should be allocated based on the contribution of each data participant in credit risk assessment. When pricing is too low, it fails to meet the participation constraints of data providers; when pricing is too high, it leads to social welfare loss and reduced efficiency in data resource allocation. (2) Following the principle of contribution-based allocation in credit

assessment models, we constructed indicators for Economic Value Added and Profit Value Added that reflect the value contribution of the model. Empirical tests show that these two indicators can measure the economic value of federated learning models, making them suitable benchmarks for data revenue distribution. (3) Both numerical simulations and empirical tests indicate that data transactions through federated learning modeling are feasible only when credit institutions have a certain scale of customers and market quality is poor. Data providers can adopt differentiated pricing strategies for different types of financial institutions based on customer scale and market quality, including low pricing strategies, refinement strategies, small profits but quick returns strategies, and high pricing strategies.

Key words: federated learning; credit risk assessment; data pricing; information asymmetry

附录

A 命题 1 证明

首先令目标函数对 Δd 求导可得：

$$\begin{aligned} & \frac{\partial \pi'}{\partial \Delta d} \\ &= \frac{rnq[1 + 2dnq - dn + \Delta d(2nq - n)] - (2nq - n) \cdot r \cdot (q + dnq + \Delta dnq)}{[1 + 2dnq - dn + \Delta d(2nq - n)]^2} \\ & - \frac{(nq - n)[1 - dn + 2dnq + \Delta d(2nq - n)] - (2nq - n)[1 - dn - q + dnq + \Delta d(nq - n)]}{[1 + 2dnq - dn + \Delta d(2nq - n)]^2} \\ & - \tau_2 = \frac{2nq(1 - q)(r + 1)}{[1 + (2q - 1)n(d + \Delta d)]^2} - \tau_2 \end{aligned}$$

通常我们认为市场上的高信用的借款人应该多于低信用的借款人，因此假设 $q > \frac{1}{2}$ ，所以 $(2q - 1)n > 0$ 。

$\frac{\partial \pi'^2}{\partial \Delta d^2} = \frac{-4n^2q(1-q)(r+1)(2q-1)}{[1+(2q-1)n(d+\Delta d)]^3}$ ，由于 $0 \leq \Delta d \leq 1 - d$ ，所以 $\frac{\partial \pi'^2}{\partial \Delta d^2} \leq 0$ ，因此 $\frac{\partial \pi'}{\partial \Delta d}$ 在定义域内是恒减的，因此可以分以下几种情况：

(1) 当 $\Delta d = 0$ 时， $\frac{\partial \pi'}{\partial \Delta d} \Big|_{\Delta d=0} \leq 0$ ，由于 $\frac{\partial \pi'}{\partial \Delta d}$ 在定义域内是恒减的，因此有 $\frac{\partial \pi'}{\partial \Delta d} \leq 0$ ，因此 $\Delta d = 0$ 为目标函数的最优解，因此求解 $\frac{\partial \pi'}{\partial \Delta d} \Big|_{\Delta d=0} \leq 0$ 可得：

$$\frac{\partial \pi'}{\partial \Delta d} \Big|_{\Delta d=0} = \frac{2nq(1 - q)(r + 1)}{[1 + (2q - 1)nd]^2} - \tau_2 \leq 0$$

即 $\tau_2 \geq \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2}$ 时，该信贷机构不应从外部购入任何维度，其对应的现实意义为当合作数据方的数据价格定价过高时，最佳决策是不进行联邦合作建模。

(2) 若当 $\Delta d = 0$ 时， $\frac{\partial \pi'}{\partial \Delta d} \Big|_{\Delta d=0} > 0$ ，且 $\Delta d = 1 - d$ 时， $\frac{\partial \pi'}{\partial \Delta d} \Big|_{\Delta d=1-d} < 0$ ，则在 $\Delta d \in (0, 1 - d)$ 上存在一个 Δd^* ，使得 $\frac{\partial \pi'}{\partial \Delta d} \Big|_{\Delta d=\Delta d^*} = 0$ ，此时 π' 取得最大值 π'_{max} 。其对应的现实意义是该信贷机构此时能够找到一个最优的购入数据量，实现自己的利润最大化。接下来探究满足该条件下的数据价格：

$$\begin{cases} \left. \frac{\partial \pi'}{\partial \Delta d} \right|_{\Delta d=0} = \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2} - \tau_2 > 0 \\ \left. \frac{\partial \pi'}{\partial \Delta d} \right|_{\Delta d=1-d} = \frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2} - \tau_2 < 0 \end{cases}$$

解得 $\frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2} < \tau_2 < \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2}$, 即只有当 τ_2 满足 $\frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2} < \tau_2 < \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2}$ 时才存在最优购买维度, 使得期望利润达到最大化。下面探究最优购买维度 Δd^* , 最优购买维度需要满足 $\frac{\partial \pi'}{\partial \Delta d} = 0$, 解得:

$$\Delta d^* = \frac{\sqrt{\frac{2nq(1-q)(r+1)}{\tau_2}} - 1}{(2q-1)n} - d$$

(3) 若当 $\Delta d = 0$ 时, $\left. \frac{\partial \pi'}{\partial \Delta d} \right|_{\Delta d=0} \geq 0$, 且 $\Delta d = 1-d$ 时, $\left. \frac{\partial \pi'}{\partial \Delta d} \right|_{\Delta d=1-d} \geq 0$, 那么在 $\Delta d \in (0, 1-d)$ 上, $\frac{\partial \pi'}{\partial \Delta d} \geq 0$, 即 π' 随 Δd 增加而递增, 在 $\Delta d = 1-d$ 时 π' 取得最大值 π'_{max} , 此时对应的数据价格条件为: $\frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2} \leq \tau_2$, 其对应的现实情况为当数据合作方的数据维度价格较低时, 信贷机构倾向于最大化的购买数据合作企业拥有的数据维度。

综上, 可得最优的数据购买维度为:

$$\Delta d = \begin{cases} 0, \tau_2 \geq \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2} \\ \Delta d^*, \frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2} < \tau_2 < \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2} \\ 1-d, \frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2} \geq \tau_2 \end{cases}$$

将最优数据购买维度的公式带入利润目标函数中, 即可得到最优的利润函数: $\pi' =$

$$\begin{cases} \frac{q+dnq}{1+2dnq-dn} (1+r) - 1 - \tau_1 \left(\frac{1}{1-d \cdot n} - 1 \right) - f, \tau_2 \geq \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2} \\ \frac{q+dnq+\Delta d^*nq}{1+2dnq-dn+\Delta d^*(2nq-n)} (1+r) - 1 - \tau_1 \left(\frac{1}{1-dn} - 1 \right) - f - \tau_2 \Delta d^*, \frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2} < \tau_2 < \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2} \\ \frac{q+nq}{1+2nq-n} (1+r) - 1 - \tau_1 \left(\frac{1}{1-dn} - 1 \right) - f - \tau_2 (1-d), \frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2} \geq \tau_2 \end{cases}$$

其中 $\Delta d^* = \frac{\sqrt{\frac{2nq(1-q)(r+1)}{\tau_2}} - 1}{(2q-1)n} - d$, 因此命题 1 得证。

B 命题 2 证明

根据命题 1 可得到 Δd 与 τ_2 之间的关系, 我们记 $\tau' = \frac{2nq(1-q)(r+1)}{[1+(2q-1)n]^2}$, $\tau'' = \frac{2nq(1-q)(r+1)}{[1+(2q-1)nd]^2}$,

由于当 $\tau_2 \in [0, \tau']$ 以及 $\tau_2 \in (\tau'', \infty)$ 时, Δd 的取值与 τ_2 无关, 所以 $\frac{\partial \Delta d}{\partial \tau_2} = 0$, 当 $\tau_2 \in (\tau', \tau'')$

时, $\Delta d = \frac{\sqrt{\frac{2nq(1-q)(r+1)}{\tau_2}} - 1}{(2q-1)n} - d$, 因此 $\frac{\partial \Delta d}{\partial \tau_2} = -\frac{\sqrt{2nq(1-q)(r+1)}}{2(2q-1)n\tau_2\sqrt{\tau_2}}$, 根据前文所述, 我们假设

$(2q-1) > 0$, 因此 $\frac{\partial \Delta d}{\partial \tau_2} < 0$, 所以下式得证:

$$\frac{\partial \Delta d}{\partial \tau_2} = \begin{cases} = 0, \tau_2 \in [0, \tau'] \\ < 0, \tau_2 \in (\tau', \tau'') \\ = 0, \tau_2 \in (\tau'', \infty) \end{cases}$$

根据命题 1 可得到 π_p 与 τ_2 之间的关系, 当 $\tau_2 \in (\tau'', \infty)$ 时, 信贷方的最优购买维度为 0, 因此 $\frac{\partial \pi_p}{\partial \tau_2} = 0$ 。当 $\tau_2 \in [0, \tau']$ 时, 信贷方的最优购买维度为 $1-d$, 因此 $\pi_p = \tau_2(1-d) - f$, 所以有 $\frac{\partial \pi_p}{\partial \tau_2} > 0$ 。当 $\tau_2 \in (\tau', \tau'')$ 时, $\Delta d = \frac{\sqrt{\frac{2nq(1-q)(r+1)}{\tau_2}} - 1}{(2q-1)n} - d$ 带入 π_p 中, 计算 $\frac{\partial \pi_p}{\partial \tau_2}$ 可得:

$$\frac{\partial \pi_p}{\partial \tau_2} = \frac{\sqrt{2qn(1-q)(1+r)}}{(2q-1)n} \sqrt{\tau_2} - (d + \frac{1}{(2q-1)n})\tau_2 - f$$

$$\text{令 } y = \frac{\sqrt{2qn(1-q)(1+r)}}{(2q-1)n} \sqrt{\tau_2} - (d + \frac{1}{(2q-1)n})\tau_2 - f, \text{ 则对其求导可得 } y' = \frac{\sqrt{2qn(1-q)(1+r)}}{(2q-1)n} \cdot \frac{1}{2\sqrt{\tau_2}} - (d + \frac{1}{(2q-1)n}), \text{ 继续求导可得, } y'' = -\frac{\sqrt{2qn(1-q)(1+r)}}{4(2q-1)n} \cdot \frac{1}{\tau_2\sqrt{\tau_2}} < 0, \text{ 这说明 } y' \text{ 在 } \tau_2 \in$$

(τ', τ'') 的定义域内是单调递减的。将 $\tau_2 = \tau'$ 代入得 $y'|_{\tau_2=\tau'} = \frac{1}{2} - \frac{1}{2(2q-1)n} - d$; 将 $\tau_2 = \tau''$ 代入得 $y'|_{\tau_2=\tau''} = -\frac{d}{2} - \frac{1}{2(2q-1)n} < 0$ 。因此, 若 $y'|_{\tau_2=\tau'} > 0$, 则存在 $\tau''' \in (\tau', \tau'')$ 上存在使得 $y' = 0$, 此时当 $\tau_2 \in (\tau', \tau''')$ 时, $y' > 0$, $\tau_2 \in (\tau''', \tau'')$ 时 $y' < 0$, 其中 $\tau''' = \frac{qn^2(1-q)(1+r)(2q-1)}{[1+(2q-1)n]^2}$ 。若 $y'|_{\tau_2=\tau'} < 0$, 则在 $\tau_2 \in (\tau', \tau'')$ 上 $y' < 0$ 。综上可知:

$$\frac{\partial \pi_p}{\partial \tau_2} = \begin{cases} > 0, \tau_2 \in [0, \tau^*] \\ < 0, \tau_2 \in (\tau^*, \tau'') \\ = 0, \tau_2 \in (\tau'', \infty) \end{cases}$$

此时, 使得合作方期望利润 π_p 最大的定价 τ^* 的取值涉及 τ' 与 τ''' 的决策, 即 $\frac{1}{2} - \frac{1}{2(2q-1)n} - d > 0$ 时, $\tau^* = \tau'''; \frac{1}{2} - \frac{1}{2(2q-1)n} - d < 0$ 时, $\tau^* = \tau'$ 。

根据命题 1 可得到 π' 与 τ_2 之间的关系, 当 $\tau_2 \in [0, \tau']$ 时, $\frac{\partial \pi'}{\partial \tau_2} = -(1-d) < 0$ 。当 $\tau_2 \in (\tau'', \infty)$ 时, 此时的最优购买维度为 0, 因此 $\frac{\partial \pi'}{\partial \tau_2} = 0$, 当 $\tau_2 \in (\tau', \tau'')$ 时, $\Delta d = \frac{\sqrt{\frac{2nq(1-q)(r+1)}{\tau_2}} - 1}{(2q-1)n} - d$, 将其代入 π' 中, 计算 $\frac{\partial \pi'}{\partial \tau_2}$ 可得:

$$\frac{\partial \pi'}{\partial \tau_2} = d + \frac{1}{(2q-1)n} - (\frac{2q(1-q)(r+1)}{(2q-1)} \cdot \frac{1}{\tau_2} + \frac{\sqrt{2qn(1-q)(1+r)}}{(2q-1)} \cdot \frac{1}{\sqrt{\tau_2}})$$

记 $z = \frac{2q(1-q)(r+1)}{(2q-1)} \cdot \frac{1}{\tau_2} + \frac{\sqrt{2qn(1-q)(1+r)}}{(2q-1)} \cdot \frac{1}{\sqrt{\tau_2}}$, 因为 $\tau_2 \in (\tau', \tau'')$ 时, $z' < 0$, 所以其最小值在 $\tau_2 = \tau''$ 时取得, 将其代入可得 $z_{min} = z|_{\tau_2=\tau''} = \frac{[1+(2q-1)nd]^2}{nq(2q-1)} + d + \frac{1}{(2q-1)n}$, 所以 $\frac{\partial \pi'}{\partial \tau_2}$ 的最大值为 $\frac{\partial \pi'}{\partial \tau_2} = \frac{\partial \pi'}{\partial \tau_2}|_{\tau_2=\tau''} = -\frac{[1+(2q-1)nd]^2}{nq(2q-1)} < 0$, 综上所述可得:

$$\frac{\partial \pi'}{\partial \tau_2} = \begin{cases} < 0, \tau_2 \in [0, \tau'] \\ < 0, \tau_2 \in (\tau', \tau''] \\ = 0, \tau_2 \in (\tau'', \infty) \end{cases}$$

C 命题 3 证明

为了证明命题 3，需要先证明如下引理：

引理 1：当 $\tau_1 < 2q(1-q)(r+1)$ 时，信贷方才会采用数据分析的方法构建自身的筛选力。

证明：记 $x = nd$ ，则可将未进行联邦合作的信贷方利润表示为， $\pi = \frac{q(1+x)}{1+(2q-1)x}(1+r) -$

$1 - \tau_1(\frac{1}{1-x} - 1)$ ，对其关于 x 求导可得：

$$\frac{\partial \pi}{\partial x} = \frac{2q(1-q)}{[1+(2q-1)x]^2}(1+r) - \frac{\tau_1}{(1-x)^2}$$

由上式可知， $\frac{\partial^2 \pi}{\partial x^2} < 0$ ， $\frac{\partial \pi}{\partial x}$ 随 x 增大而减小。当 $x = 1$ 时， $\frac{\partial \pi}{\partial x}|_{x=1}$ 趋向于负无穷；当 $x = 0$ 时，

$\frac{\partial \pi}{\partial x} = 2q(1-q)(1+r) - \tau_1$ 。若 $\frac{\partial \pi}{\partial x}|_{x=0} < 0$ ，则 $x = 0$ 时信贷方达到最大利润，其经济意义是如果获取数据的成本 τ_1 过高，此时信贷机构不愿利用大数据分析建立筛选能力；如果信贷机构需要利用数据和维度进行筛选，则要求 $\frac{\partial \pi}{\partial x}|_{x=0} > 0$ ，即 $\tau_1 < 2q(1-q)(r+1)$ ，因此引理得证。

首先我们考虑 n 对 Δd 的影响，根据命题 1 可知，由于当 $\tau_2 \leq \tau'$ 时， $\Delta d = 1 - d$ ，当 $\tau_2 > \tau''$ 时， $\Delta d = 0$ ，因此在 $\tau_2 \leq \tau'$ 和 $\tau_2 > \tau''$ 时， $\frac{\partial \Delta d}{\partial n} = 0$ 。由于在考虑 n 对 Δd 的影响时， τ_2 是固定的，因此求解 $\tau_2 = \tau'$ 和 $\tau_2 = \tau''$ 可以得到对应的 n' 和 n'' 。下面重点考虑当 $\tau' < \tau_2 \leq \tau''$ ，即 $n \in (n', n'']$ 时的情况，对 $\Delta d = \Delta d^*$ 求导数可得：

$$\frac{\partial \Delta d}{\partial n} = \frac{1}{(2q-1)n^2} \cdot (1 - \frac{\sqrt{n}}{2} \cdot \sqrt{\frac{2q(1-q)(1+r)}{\tau_2}})$$

由于 $\tau' < \tau_2 \leq \tau''$ ，因此代入可得

$$\frac{1}{2}(1 - (2q-1)n) < 1 - \frac{\sqrt{n}}{2} \cdot \sqrt{\frac{2q(1-q)(1+r)}{\tau_2}} < \frac{1}{2}(1 - (2q-1)nd)$$

由于 $0 < 2q-1 < 1$ ，所以可得 $\frac{\partial \Delta d}{\partial n} > 0$ ，综上所述可得：

$$\frac{\partial \Delta d}{\partial n} = \begin{cases} = 0, n \in [0, n'] \\ > 0, n \in (n', n''] \\ = 0, n \in (n'', 1] \end{cases}$$

下面考虑 n 对 π_p 的影响，由于 $\pi_p = \tau_2 \Delta d - f$ ， τ_2 与 f 取值均与 n 无关，因此 n 对 π_p 的影响与对 Δd 的影响相同，所以可得：

$$\frac{\partial \pi_p}{\partial n} = \begin{cases} = 0, n \in [0, n'] \\ > 0, n \in (n', n''] \\ = 0, n \in (n'', 1] \end{cases}$$

下面考虑 n 对 π' 的影响, 由于我们的目标是要尽力促成联邦合作, 因此主要考虑 $\Delta d = 1 - d$ 时, 即 $\tau_2 \leq \tau'$ 时的情况。将 $\Delta d = 1 - d$ 代入 π' 可得:

$$\pi' = \frac{q + nq}{1 + n(2q - 1)}(1 + r) - 1 - \tau_1\left(\frac{1}{1 - dn} - 1\right) - f - \tau_2(1 - d)$$

$$\frac{\partial \pi'}{\partial n} = \frac{2q(1 - q)(1 + r)}{[1 + n(2q - 1)]^2} - \frac{\tau_1 d}{(1 - nd)^2}$$

由上式可知, $\frac{\partial^2 \pi'}{\partial n^2} < 0$, 即 $\frac{\partial \pi'}{\partial n}$ 随 n 增加而减少。 $\frac{\partial \pi'}{\partial n}\Big|_{n=0} = 2q(1 - q)(1 + r) - \tau_1 d$, 根据引理 1 可知, $\tau_1 < 2q(1 - q)(r + 1)$, $d < 1$, 因此 $\frac{\partial \pi'}{\partial n}\Big|_{n=0} > 2q(1 - q)(1 + r)(1 - d) > 0$ 。 $\frac{\partial \pi'}{\partial n}\Big|_{n=1} = (1 - q)(1 + r) - \frac{\tau_1 d}{(1 - d)^2}$, 若 $\frac{\partial \pi'}{\partial n}\Big|_{n=1} > 0$, 则 $\frac{\partial \pi'}{\partial n}$ 在 $n \in [0, 1]$ 上均大于 0, 则 $n = 1$ 时 π' 达到最大值, 此时对应的条件为 $\tau_1 < \frac{(1 - q)(1 + r)(1 - d)^2}{d}$; 若 $\frac{\partial \pi'}{\partial n}\Big|_{n=1} < 0$, 则 $\frac{\partial \pi'}{\partial n}$ 在 $n \in [0, n^*]$ 时大于 0, 在 $n \in (n^*, 1]$ 时小于 0, 其中 n^* 满足的条件为 $\frac{\partial \pi'}{\partial n}\Big|_{n=n^*} = 0$, 此时 $\frac{\partial \pi'}{\partial n}\Big|_{n=1} < 0$ 对应的条件为 $(1 - q)(1 + r) - \tau_1 \frac{d}{(1 - d)^2} < 0$, 即 $\frac{(1 - q)(1 + r)(1 - d)^2}{d} < \tau_1 < 2q(1 - q)(r + 1)$, 综上所述可得:

$$0 < \tau_1 \leq \tau_1^* \text{ 时, } \frac{\partial \pi'}{\partial n} > 0, n \in [0, 1]$$

$$\tau_1^{**} > \tau_1 > \tau_1^* \text{ 时, } \frac{\partial \pi'}{\partial n} = \begin{cases} > 0, n \in [0, n^*] \\ < 0, n \in (n^*, 1] \end{cases}$$

$$\text{其中 } \tau_1^* = \frac{(1 - q)(1 + r)(1 - d)^2}{d}, \tau_1^{**} = 2q(1 - q)(r + 1), n^* = \frac{1 - \sqrt{\frac{\tau_1 d}{2q(1 - q)(1 + r)}}}{(2q - 1)\sqrt{\frac{\tau_1 d}{2q(1 - q)(1 + r)} + d}}.$$

D 命题 4 证明

记 $y = \pi' - \pi$, 根据命题 1 可知, 当 $n = 0$ 时, $\Delta d = 0$, $y = -f < 0$, 当 $\Delta d \neq 0$ 时,

$$y = (r + 1) \left(\frac{q + dnq + \Delta d^* nq}{1 + 2dnq - dn + \Delta d^* (2nq - n)} - \frac{q + dnq}{1 + 2dnq - dn} \right) - \tau_2 \Delta d - f$$

$$\frac{\partial y}{\partial n} = (r + 1)q(2 - 2q) \left(\frac{(d + \Delta d)}{[1 + (d + \Delta d)(2q - 1)n]^2} - \frac{d}{[1 + d(2q - 1)n]^2} \right)$$

$$\text{其中 } \frac{(d + \Delta d)}{[1 + (d + \Delta d)(2q - 1)n]^2} = \frac{1}{\frac{1}{d + \Delta d} + 2(2q - 1)n + (d + \Delta d)(2q - 1)n}, \frac{d}{[1 + d(2q - 1)n]^2} = \frac{1}{\frac{1}{d} + 2(2q - 1)n + d(2q - 1)n}$$

对于函数 $f(x) = \frac{1}{x} + (2q - 1)nx$ 可知, $f'(x) = \frac{(2q - 1)nx^2 - 1}{x^2}$, $f(x)$ 在 $x \in [0, \frac{1}{\sqrt{(2q - 1)n}}]$ 上递减, 在 $x \in [\frac{1}{\sqrt{(2q - 1)n}}, +\infty)$ 上递增。由于 $\frac{1}{\sqrt{(2q - 1)n}} > 1 > d + \Delta d > d$, 所以有 $f(d) > f(d + \Delta d) > 0$, 因此 $\frac{1}{\frac{1}{d + \Delta d} + 2(2q - 1)n + (d + \Delta d)(2q - 1)n} > \frac{1}{\frac{1}{d} + 2(2q - 1)n + d(2q - 1)n}$, 所以 $\frac{\partial y}{\partial n} > 0$ 。

由于 $y|_{n=0} < 0$, 且 $\frac{\partial y}{\partial n} > 0$, 所以当 n 足够大且 f 较小时, 存在 $y|_{n=n^*} > 0$, 因此命题得证。

E 命题 5 证明

首先我们考虑 q 对 Δd 的影响, 根据命题 1 可知, 由于当 $\tau_2 \leq \tau'$ 时, $\Delta d = 1 - d$, 当 $\tau_2 >$

τ'' 时, $\Delta d = 0$, 因此在 $\tau_2 \leq \tau'$ 和 $\tau_2 > \tau''$ 时, $\frac{\partial \Delta d}{\partial q} = 0$ 。由于在考虑 q 对 Δd 的影响时, τ_2 是固定的, 因此求解 $\tau_2 = \tau'$ 和 $\tau_2 = \tau''$ 可以得到对应的 q' 和 q'' 。下面重点考虑当 $\tau' < \tau_2 \leq \tau''$, 即 $q \in (q', q'']$ 时的情况, 对 $\Delta d = \Delta d^*$ 求导数可得:

$$\frac{\partial \Delta d}{\partial q} = -\sqrt{\frac{(1+r)}{2n\tau_2 q(1-q)}} - 2\sqrt{\frac{2(1+r)q(1-q)}{n\tau_2}} \cdot \frac{1}{(2q-1)^2} < 0$$

所以可得:

$$\frac{\partial \Delta d}{\partial q} = \begin{cases} = 0, q \in [0.5, q'] \\ < 0, q \in (q', q''] \\ = 0, q \in (q'', 1] \end{cases}$$

下面考虑 q 对 π_p 的影响, 由于 $\pi_p = \tau_2 \Delta d - f$, τ_2 与 f 取值均与 n 无关, 因此 q 对 π_p 的影响与对 Δd 的影响相同, 所以可得:

$$\frac{\partial \pi_p}{\partial n} = \begin{cases} = 0, q \in [0.5, q'] \\ > 0, q \in (q', q''] \\ = 0, q \in (q'', 1] \end{cases}$$

下面考虑 q 对 π' 的影响, 由于我们的目标是要尽力促成联邦合作, 因此主要考虑 $\Delta d = 1 - d$ 时, 即 $\tau_2 \leq \tau'$ 时的情况。将 $\Delta d = 1 - d$ 代入 π' 可得

$$\pi' = \frac{q + nq}{1 + n(2q-1)}(1+r) - 1 - \tau_1\left(\frac{1}{1-dn} - 1\right) - f - \tau_2(1-d)$$

$$\frac{\partial \pi'}{\partial q} = \frac{(1-n^2)(1+r)}{[1 + n(2q-1)]^2} > 0$$

所以可得:

$$\frac{\partial \pi'}{\partial n} > 0, q \in [0.5, 1]$$

F 命题 6 证明

记 $y = \pi' - \pi$, 根据命题 1 可知, 当 $q = 1$ 时, $\Delta d = 0$, $y = -f < 0$, 由于我们的目标是要尽力促成联邦合作, 下面主要考虑当 $\Delta d = 1 - d$ 时的情景:

$$y = (r+1)\left(\frac{q + nq}{1 + 2nq - n} - \frac{q + dnq}{1 + 2dnq - dn}\right) - \tau_2(1-d) - f$$

$$\frac{\partial y}{\partial q} = (r+1)\left(\frac{1-n^2}{[1 + (2q-1)n]^2} - \frac{1-(dn)^2}{[1 + d(2q-1)n]^2}\right)$$

由于 $[1 + (2q-1)n]^2 > [1 + d(2q-1)n]^2 > 0$, 且 $0 < 1 - n^2 < 1 - (dn)^2$, 因此 $\frac{1-n^2}{[1+(2q-1)n]^2} - \frac{1-(dn)^2}{[1+d(2q-1)n]^2} < 0$, 所以 $\frac{\partial y}{\partial q} < 0$, 这说明信贷方联邦合作后对比合作前的利润增益随市场质量的增大而减小, 因此命题得证。

G 联邦逻辑回归实现算法

在实践当中, 逻辑回归因其可解释性、稳定性而成为最常见的用于信用风险评估的模型。由于逻辑回归中涉及到 $\log$ 运算无法通过加密实现, 因此需要对其中的损失函数进行泰勒展开, 使其能够进行加法和乘法同态加密运算。在二分类问题中, $\log$ 函数的取值在 0-1 之间, 因此 $\log$ 函数可以近似为二阶泰勒展开 (公式 (27))。对于逻辑回归模型, z 可以代替为 $y_i \theta^T x_i$, 其中 y_i 表示是否违约, 因此逻辑回归的损失函数可以用公式 (28) 表示。对损失函数中 θ 求导, 可以计算对应的梯度, 如公式 (29) 所示, 并采用梯度下降法来优化参数 (公式 (30)), 最终使其收敛到我们想得到的结果。

$$\lg(1 + e^{-z}) \approx \lg 2 - \frac{1}{2}z + \frac{1}{8}z^2 \quad (27)$$

$$Loss = \frac{1}{|S|} \sum_{i \in S} \lg(1 + e^{-y_i \theta^T x_i}) \approx \frac{1}{|S|} \sum_{i \in S} [\lg 2 - \frac{1}{2} y_i \theta^T x_i + \frac{1}{8} (\theta^T x_i)^2] \quad (28)$$

$$y_i = \begin{cases} 1, & \text{正常} \\ -1, & \text{违约} \end{cases}$$

$$g = \frac{1}{|S|} \sum_{i \in S} (\frac{1}{4} \theta^T x_i^2 - \frac{1}{2} y_i x_i) = \frac{1}{|S|} \sum_{i \in S} (\frac{1}{4} \theta^T x_i - \frac{1}{2} y_i) x_i \quad (29)$$

$$\theta_{k+1} = \theta - \alpha * g \quad (30)$$

在联邦模型当中，需要三个参与方，参与方 A 为提供更多数据维度的数据方 (x_A)，参与方 B 为拥有违约数据的信贷方 (x_B)，参与方 C 为可信任的中间方（通常也可由参与方 A/B 担任）。我们采用 Paillier^[33]同态加密方法来完成参与方之间的参数传递，该方法允许任何一方使用公钥对其数据进行加密，而用于解密的私钥由第三方拥有。加法同态加密可以计算两个加密数的加法，也可以计算未加密数与加密数的乘积，用 $[[\cdot]]$ 作为加密运算，表示为 $[[u]] + [[v]] = [[u + v]]$ ， $v[[u]] = [[vu]]$ 。对于数据方 A，我们记 $u_A = \theta^T_A x_A$ ， $u_B = \theta^T_B x_B$ ，记 $d = \frac{1}{4} \theta^T x - \frac{1}{2} y = \frac{1}{4} ([u_A] + [u_B] - \frac{1}{2} [y])$ 。因此损失函数和梯度可以用公式 (31) 和公式 (32) 表示。

$$[[Loss]] = \frac{1}{|S|} \sum_{i \in S} [\lg 2 - \frac{1}{2} y_i ([u_A] + [u_B])] + \frac{1}{8} ([u_A^2] + [u_B^2] + 2u_B [u_A]) \quad (31)$$

$$[[g]] = ([g_A], [g_B]) = \frac{1}{|S|} \sum_{i \in S} [[d]] x = \left(\frac{1}{|S|} \sum_{i \in S} [[d]] x_A, \frac{1}{|S|} \sum_{i \in S} [[d]] x_B \right) \quad (32)$$

$$\text{其中 } d = \frac{1}{4} ([u_A] + [u_B]) - \frac{1}{2} [y]$$

在得到加密之后的各个参与方的损失函数和梯度计算公式后，就可以在各参与方之间进行加密传输，从而在保证数据隐私的前提下联合训练出联邦逻辑回归模型。具体步骤如下所示：

- (1) 参与方 C 生成公钥和私钥，并将公钥发送给数据方 A 和信贷方 B，数据方 A 和信贷方 B 生成初始参数 θ_A 和 θ_B 。
- (2) 数据方 A 根据自身的参数 θ_A 计算加密后的 $[[u_A]]$ 和 $[[u_A^2]]$ ，并将其发送给信贷方 B。
- (3) 信贷方 B 计算自身的 u_B 和 u_B^2 ，并对其加密得到 $[[u_B]]$ 和 $[[u_B^2]]$ ，根据发送的 $[[u_A]]$ 和 $[[u_A^2]]$ 计算加密的 $[[Loss]]$ 函数和 $[[d]]$ ，并将加密的 $[[d]]$ 发送给数据方 A，将加密的 $[[Loss]]$ 发送给中间方 C。
- (4) 数据方 A 根据 $[[d]]$ 计算对应的数据的梯度 $[[g_A]]$ ，并将其发送给中间方 C，信贷方 B 也计算对应的数据的梯度 $[[g_B]]$ ，将其发送给中间方 C。
- (5) 中间方 C 通过自己手中的私钥对 $[[g_A]]$ 和 $[[g_B]]$ 进行解密，则将解密后的 g_A 和 g_B 发送回数据方和信贷方。中间方用私钥对信贷方 B 发送来的 $[[Loss]]$ 值进行解密，判断损失函数值 $Loss$ 是否达到最小值，若相比上一轮迭代的损失函数值变大，则停止迭代。
- (6) 数据方 A 和数据方 B 根据解密的 g_A 和 g_B 更新自身的参数 θ_A 和 θ_B ，若根据步骤 3 判断是否停止迭代，若没有停止迭代，则返回步骤 1。

在上述三个参与方中，数据方 A、信贷方 B 以及中间方 C 之间只传递加密的中间参数，任意一方并不知道其他参与者的数据具体长什么样，因此保证了数据的隐私安全，训练得到

的逻辑回归模型综合了数据方和信贷方的所有数据维度，实现了数据的可用不可见。

H 数据指标描述

企业本次贷款信息风险指标	
还款方式	本次贷款金额的自然对数
资金用途	本次贷款年化利率
贷款方式	是否受托支付
是否省内贷款	
企业历史贷款信息风险指标	
上次贷款金额的自然对数	上次贷款与本次贷款间隔天数
上次贷款年化利率	本次贷款金额占历史金额均值之比
上次贷款是否违约	历史借款次数
上次贷款是否逾期	首次贷款至本次贷款间隔天数
企业工商信息风险指标	
借款企业类型	借款企业产业类型
借款企业类型是否缺失	借款企业所属行业
企业税务司法风险指标	
企业主体是否是纳税非正常户	企业主体是否是老赖
企业主体是否欠税	企业主体是否被公开执行
企业主体是否被限制高消费	本次借款金额与企业主体被执行总金额之比