



计算机应用
Journal of Computer Applications
ISSN 1001-9081, CN 51-1307/TP

《计算机应用》网络首发论文

题目： 满足差分隐私的纵向联邦子空间聚类方法
作者： 张嘉怡，霍峥，王素贞
收稿日期： 2026-02-13
网络首发日期： 2026-04-23
引用格式： 张嘉怡，霍峥，王素贞. 满足差分隐私的纵向联邦子空间聚类方法[J/OL]. 计算机应用. <https://link.cnki.net/urlid/51.1307.TP.20260422.1602.010>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

满足差分隐私的纵向联邦子空间聚类方法

张嘉怡¹, 霍 峥¹, 王素贞^{2*}

(1. 河北经贸大学 管理科学与信息工程学院, 石家庄 050061; 2. 河北工程技术学院 科研与产教融合处, 石家庄 050091)

(* 通信作者电子邮箱: wsuz@163.com)

摘要:随着数据隐私保护法规的日趋严格,传统基于密度的聚类算法面临数据孤岛与隐私泄露的双重挑战。针对纵向联邦学习中样本重叠、特征异构的场景,提出了一种满足差分隐私的纵向联邦聚类算法PP-VFCLIQUE。首先,设计基于分位点的全局网格划分策略,确保各参与方在特征空间划分上的一致性;其次,设计了一种高效的协同挖掘流程,客户端通过计算并上传加密的二值支持度掩码完成安全验证;最后,引入密度阈值衰减机制,使稠密单元格筛选阈值随子空间维度动态调整,有效平衡隐私保护与聚类效用。与VFDPC、FKDC、AFCL、FedSC算法相比,在Wine、Iris、Seeds、Ecoli、Pima五个数据集上,ACC分别最高提升了27.08、6.27、16.42、22.32和46.88个百分点,个别数据集性能与对比方法基本持平,验证了该方法在纵向特征割裂场景下恢复联合子空间结构的有效性,为跨机构协同分析提供了安全有效的解决方案。

关键词:纵向联邦学习;CLIQUE聚类;隐私保护;阈值衰减;差分隐私

中图分类号:TP311.5 **文献标志码:**A

Vertical federated subspace clustering method under differential privacy

ZHANG Jiayi¹, HUO Zheng¹, WANG Suzhen^{2*}

(1. School of Management Science and Information Technology, Hebei University of Economics and Business, Shijiazhuang Hebei 050061, China;

2. Research and Industry Education Integration Department, Hebei University of Engineering Science, Shijiazhuang Hebei 050091, China)

Abstract: With the increasingly stringent data privacy protection regulations, traditional density-based clustering algorithms were confronted with the dual challenges of data silos and privacy leakage. For scenarios with overlapping samples and heterogeneous features in vertical federated learning, a differential privacy-preserving vertical federated clustering algorithm named PP-VFCLIQUE was proposed. First, a global grid partitioning strategy based on quantiles was designed to ensure consistency in feature space partitioning across all participants. Second, an efficient collaborative mining process was designed, in which encrypted binary support masks were computed and uploaded by clients to complete secure validation. Finally, a density threshold decay mechanism was introduced, so that the screening threshold for dense units was dynamically adjusted with subspace dimensions, thereby effectively balancing privacy protection and clustering utility. Compared with the VFDPC, FKDC, AFCL, and FedSC algorithms, ACC was improved by up to 27.08, 6.27, 16.42, 22.32, and 46.88 percentage points on the Wine, Iris, Seeds, Ecoli, and Pima datasets, respectively, while the performance on a few datasets was basically comparable to that of the comparison methods. The effectiveness of the algorithm in restoring the joint subspace structure under scenarios with vertically fragmented features was validated, and a secure and effective solution was provided for cross-institutional collaborative analysis.

Key words: vertical federated learning; CLIQUE clustering; privacy preservation; threshold decay; differential privacy

0 引言

作为经典的高维子空间聚类方法,CLIQUE算法能够挖掘高维数据中内嵌的低维密集子空间,有效缓解“维度灾难”问题,在高维数据处理场景中具有广泛应用价值^[1]。然而,传统CLIQUE算法依赖集中式数据存储,要求所有参与方将原始特征数据汇总至集中式平台进行聚类,这一模式在当前数据隐私保护法规逐步完善的背景下,面临严峻的“数据孤岛”与隐私泄露双重挑战。在实际业务场景中,多机构间常存在“样本重叠、特征异构”的数据分布特征^[2]。例如,医疗机

构拥有患者的诊断记录特征,体检机构掌握同一批患者的生理指标特征,二者若需联合开展患者健康风险聚类分析,直接共享原始数据会违反隐私保护要求,而各自独立进行CLIQUE聚类又会因特征不完整导致聚类精度大幅下降。联邦学习(Federated Learning, FL)^[3]的出现为解决这一矛盾提供了新思路,通过“数据不动模型动”的分布式协作模式,允许参与方在本地保留原始数据的同时协同构建全局模型,从根本上减少数据泄露风险^[4]。根据数据分布形式的不同,联邦学习根据数据分布差异可分为横向联邦学习、纵向联邦学习与联邦迁移学习^[5]。其中,纵向联邦学习(Vertical Federated Learning,

收稿日期:2026-02-13;修回日期:2026-04-01;录用日期:2026-04-09。

基金项目:河北省自然科学基金项目(F2025207001);中央引导地方科技发展资金计划项目(246Z0703G)

作者简介:霍峥,主要工作:文章第1、5章撰写,文章投稿与修改;王素贞,主要工作:数据整理、方法及论文审阅;张嘉怡(2001—),女,河北邢台人,硕士研究生,主要研究方向:联邦聚类、隐私保护;霍峥(1982—),女,河北邯郸人,教授,博士,CCF会员,主要研究方向:隐私保护技术、联邦学习;王素贞(1964—),女,河北邯郸人,教授,博士,CCF会员,主要研究方向:移动云计算。

VFL)专门针对样本空间一致、特征空间互补的场景,通过联合多方特征维度,实现模型性能提升,特别适用于多机构间的跨特征协同聚类任务。现有联邦聚类方法多基于全空间距离或中心点聚合构建全局模型,其核心假设是:尽管每个客户端仅拥有部分特征信息,但通过聚合局部统计量,可以近似恢复全局特征结构^[6]。然而,当聚类结构仅存在于特定跨客户端子空间时,该假设可能不成立,从而导致结构信息丢失。而在高维数据场景下,真实聚类结构往往仅存在于部分低维子空间中,而非整个特征空间。当直接在全空间进行联邦密度估计或中心聚合时,易受到无关特征干扰,导致密度稀释和簇结构模糊。因此,在纵向联邦环境下,“子空间发现”不仅是一种降维手段,更是一种结构恢复机制。通过在分布式特征上协同挖掘高密度子空间,可以在不暴露原始数据的前提下重构跨特征的局部关联结构,从而弥补单方特征信息不足的问题。

综上所述,将 CLIQUE 算法与纵向联邦学习结合,构建一个支持高维数据分析的隐私保护子空间聚类框架,成为突破“数据孤岛”困境与保障数据安全的关键方向。然而,将传统 CLIQUE 算法迁移至纵向联邦环境仍面临三大核心挑战:第一,如何在非共享原始特征的前提下实现一致的网格划分;第二,如何高效地在分布式特征上进行高维稠密单元格的挖掘;第三,如何在保证聚类精度的同时,防止多轮通信过程中间统计结果被恶意推断,从而造成隐私泄露。针对上述挑战,本文提出了一种满足差分隐私的纵向联邦聚类算 PP-VFCLIQUE,本文的主要贡献如下:

第一,提出了一种满足差分隐私的纵向联邦 CLIQUE 聚类算法 PP-VFCLIQUE,将基于密度的子空间聚类方法扩展至纵向联邦学习架构,在非共享原始特征数据的前提下实现多方协同聚类。

第二,设计了基于分位点的全局网格划分策略与阈值衰减机制,使稠密单元筛选阈值随子空间维度动态调整;构建了局部稠密识别-全局候选合并-支持度掩码验证的分布式挖掘流程,通过加密掩码与噪声注入防止原始特征泄露。

第三,在 10 个公开数据集上的实验表明,PP-VFCLIQUE 在多项聚类指标上优于传统 CLIQUE 聚类及现有联邦聚类方法,验证了其在保证隐私约束的同时能够维持较优的聚类性能。

1 相关工作

联邦学习框架下的隐私保护聚类算法,根据其核心机制与目标,主要可分为基于模型或参数聚类的联邦学习方法、传统聚类算法的联邦化实现和联邦聚类中的隐私增强技术。

1.1 基于模型或参数聚类的联邦学习方法

该类方法主要是对联邦学习过程中产生的中间产物,如模型参数、更新向量、推理结果进行聚类,旨在将数据分布相似的客户端分组,以训练个性化的模型,提升联邦学习在非独立同分布数据下的性能。在模型更新聚类方面,Briggs 等^[7]提出了一种基于层次聚类的联邦学习方法。该方法通过在联邦训练过程中引入层次聚类步骤,根据客户端对全局模型的本地更新向量之间的相似性对客户端进行聚类,从而为不同数据分布的客户端群体训练专用的个性化模型。Souza 等^[8]提出了一种基于测试模型最后一层权重的客户端聚类系统。该方法在水平联邦学习场景下,通过将客户端分组以形成内部数据分布更接近独立同分布的簇,可为每个簇训练个性化的模型。在推理结果聚类方面,Morafah 等^[9]提出基于推理相似性的集群联邦学习算。该方法突破传统联邦聚类依赖模型权重或损失曲面几何特性的局限,通过计算推理结果矩阵间的相似度,在非共享原始数据的前提下,精准识别数据分布相似的客户端,避免无关数据客户端对集群训练的干扰,同时保障数据隐私。在模型参数聚类方面,鲁晨阳等^[10]针对联邦学习中数据非独立同分导致模型性能下降的问题,提出了一种基于 DBSCAN (Density-Based Spatial Clustering of Applications with Noise, DBSCAN)聚类的集群联邦学习方法。该方法首先在各客户端本地训练模型,随后由服务器对客户端上传的模型参数进行 DBSCAN 聚类,将客户端划分为多个簇,每个簇内进行联邦学习以训练适用于该簇的全局模型。该类方法主要服务于优化监督

学习模型,并非直接执行无监督聚类任务,其聚类对象是客户端而非原始数据样本。Miao 等^[11]提出了 FedDec 算法,通过一种密度极值聚类方法对客户端的模型超参数进行分组,以提升水平联邦学习在非独立同分布(Non-Independent and Identically Distributed, Non-IID)数据下的模型训练效率。在此基础上,研究者进一步从自适应聚类与动态分组角度改进联邦学习框架。Zhang 等^[12]提出 FedAC 框架,通过自适应客户端聚类策略,根据模型更新的相似性动态划分客户端组,从而在异构数据环境下提高模型收敛速度与训练稳定性。Du 等人^[13]提出一种动态自适应迭代聚类联邦学习方法,通过在训练过程中不断更新客户端聚类结构,使模型能够更好地适应数据分布变化。

1.2 传统聚类算法的联邦化实现

对于传统聚类算法的联邦化研究致力于将经典的集中式聚类算法,如 K-Means、模糊 C 均值(Federated Fuzzy C-Means, FFCM)、密度峰值(Density Peak Clustering, DPC)聚类 etc 适配到联邦环境中,其目标是在数据不离开本地的前提下,协作完成对所有样本的全局聚类^[14]。在基于划分的方法上,Wang 等^[15]提出了一种基于密度核的一次性安全联邦 K-Means 聚类框架,各客户端首先通过本地 K-Means 生成代表点来捕捉局部数据特征,并利用差分隐私对代表点进行加密后上传;服务器端基于共享最近邻重新定义局部密度与相对距离,从中筛选出更具代表性的密度核作为全局聚类中心。该方法通过“代表点”间接构建全局相似性度量,在仅需一轮通信的同时,可提升在非独立同分布和非凸数据上的聚类性能。Stallmann 等^[16]提出了联邦模糊 C 均值算法,将经典的模糊 C 均值聚类扩展至联邦学习中,在数据不离开本地的前提下实现全局聚类。该算法通过客户端本地迭代更新聚类中心,并由服务器聚合这些中心来形成全局聚类。文中提出了两种聚合策略:一是基于加权平均的 avg_1 ,二是引入 K-means 对本地中心进行再聚类的 avg_2 。实验表明,在数据分布不均或存在隐藏聚类情况下, avg_2 表现更优,能更准确地识别全局聚类结构。尽管 FFCM 未引入差分隐私机制,其对于非独立同分布数据的处理能力以及对聚类中心聚合方式的探索,为联邦环境下的聚类方法提供了重要参考。Alfawaz 等^[17]提出 VFCKM 框架,通过在纵向数据划分场景下构建基于 K-means 的联邦聚类方法,实现具有共享属性的数据协同聚类。然而,该方法仍依赖于传统 K-means 聚类模型,难以有效发现高维数据中的潜在子空间结构。

1.3 联邦聚类中的隐私增强技术

为确保分布式计算过程中的数据安全,多种隐私保护技术被集成到联邦聚类框架中。

徐等^[18]针对横向联邦学习场景,提出了一种本地均分扰动联邦 K-means 算法。该算法通过各站点联合协商随机种子,以较低的通信代价生成相同的拉普拉斯噪声,并将其均分后添加到本地的簇内数据和与数据数目上,使服务器聚合后得到的全局噪声与中心化差分隐私 K-means 所加噪声相同,从而在保护本地数据隐私的同时保证了聚类效用。Balkus 等^[19]提出联邦增强模糊 C 均值聚类算法。该算法设计去中心化并行通信架构,仅需两轮通信即可完成全局聚类;同时,客户端仅上传经过主成分分析(Principal Component Analysis, PCA)处理的聚类中心,且在初始中心生成时添加噪声以掩盖原始样本特征,从而实现隐私保护。在基于密度的方法上,Ding 等人^[20]提出了横向联邦密度峰值聚类算法,以解决传统 DPC 算法在分布式环境下存在的隐私泄露与“多米诺”效应问题,其核心是通过将各客户端数据映射为网格点并在服务器端聚合,从而在不暴露原始数据的前提下执行聚类。为提升聚类质量,HFDPC 引入了相似密度链以缓解流形数据中因局部密度峰值引起的误分问题。Li 等^[21]提出了一种基于非线性映射的纵向联邦密度峰值聚类方法。该方法针对垂直划分数据的隐私保护问题,设计了一种混合加密机制,用于在客户端之间安全地合并距离矩阵,而无需暴露原始数据。Bozdemir 等人^[22]提出了首个基于安全两方计算的全隐私保护的 DBSCAN 密度聚类方案,有效解决了传统聚类方法在多方协作或外包计算场景下的隐私泄露问题。

FKDC (Federated K-Means Clustering Based on Density Cores)^[15]

和ELFedKmeans^[18]利用拉普拉斯机制对上传的中间添加噪声,提供可证明的隐私保障。VFDPC (Vertical Federated Density Peaks Clustering)^[21]和Bozdemir的方案^[22]采用混合加密或安全多方计算来保护中间计算结,避免其明文暴露。He等^[23]提出一种结合自适应局部差分隐私的聚类联邦学习方法,通过对客户端上传的模型信息进行局部差分隐私扰动,在保护隐私的同时实现客户端动态聚类。Luo等^[24]提出了一种隐私保护的聚类联邦学习方法,该方法采用随机响应机制对客户端的标签分布进行扰动,仅上传二值化的标签存在性向量,在保护数据分布隐私的同时显著降低通信开销。服务器基于扰动后的标签向量计算客户端间的Jaccard相似度,构建加权无向图,并引入COPRA (Community Overlap PPropagation Algorithm)社区发现算法实现动态、重叠的客户端聚类,无需预设聚类数目。

综上所述,现有联邦聚类研究主要沿两条技术路径展开:一类通过聚合模型参数或客户端更新向量,对客户端进行分组,其聚类对象为“客户端”;另一类通过联邦化改造传统K-Means、FFCM或DPC算法,在全特征空间上进行全局距离或密度估计,其聚类对象为“样本”。这两类方法普遍依赖全空间结构假设,未考虑高维数据中真实簇结构可能仅存在于局部子空间的问题。且部分方法的隐私保护机制依赖于特定加密技术,而非可证明的差分隐私。隐私技术的选择往往与算法流程紧耦合,如何在子空间聚类这类多轮迭代、中间结果复杂的任务中,系统化地集成差分隐私并平衡其效用损失,仍是一个挑战。在纵向联邦场景中,由于特征分散存储,各参与方仅观测到全局特征空间的一部分,单方无法识别完整的全空间密度结构。若直接采用全空间距离或中心聚合策略,不仅会受到无关维度干扰,还会放大高维稀疏性问题。因此,将“子空间发现机制”引入纵向联邦聚类框架,成为解决高维特征割裂与密度稀释问题的关键路径。与现有联邦聚类方法相比,本文聚焦于纵向联邦学习场景下的子空间聚类问题,提出一种保护隐私的CLIQUE聚类算法。将CLIQUE算法联邦化,通过全局网格划分、分布式稠密单元格挖掘与阈值衰减策略,实现高维数据的隐私保护子空间发现。

2 预备知识

本节主要介绍论文的预备知识,包括纵向联邦学习和差分隐私技术。

2.1 纵向联邦聚类

纵向联邦聚类 (Vertical Federated Clustering, VFC) 是一类在特征纵向划分、样本对齐且无需数据共享的场景下,实现无监督聚类的联邦学习方法。该问题广泛存在于跨机构数据协同分析中,例如多部门联合用户画像构建与隐私保护数据挖掘等应用场景^[25]。

纵向联邦聚类系统中共有 m 个参与方 $\mathcal{P} = \{P_1, P_2, \dots, P_m\}$, 第 i 个参与方持有局部数据集: $D_i = \{X_i, y_i\}$, $X_i \in \mathbb{R}^{n \times d_i}$, 其中, n 表示样本数量, d_i 表示第 i 个参与方持有的特征维度数。各参与方拥有相同的样本标识集, 即 $ID_1 = ID_2 = \dots = ID_m$, 但其特征集合互不重叠: $F_i \cap F_j = \emptyset, \forall i \neq j$ 。纵向联邦聚类的目标是在不泄露各参与方原始特征数据的前提下, 对样本集合进行无监督划分。

与集中式聚类相比, 纵向联邦聚类在不集中原始数据的前提下, 实现了对多方互补特征信息的联合建模, 有效降低了隐私泄露与合规的风险。同时, 通过利用距离、密度或其他统计量的纵向可分解性, 纵向联邦聚类在聚类性能上能够逼近集中式方法, 具备更好的现实部署性, 尤其适用于跨机构、隐私敏感的数据分析场景。

2.2 攻击模型

在传统的纵向联邦CLIQUE聚类中, 若是各参与方只交换“坐标索引”和“二进制掩码”, 看似没有交换原始数据。但本质上, 攻击者可以通过收集多轮迭代中的掩码信息, 利用区间求交的原理, 逐步缩小样本的取值范围, 最终以极高的精度重构出客户端的私有数据。例如, 假设恶意服务端, 能够动态调整下发的网格分位数, 在攻击开始前攻击者仅知晓数据的定义域在第 t 轮迭代中, 服务端下发针对特征的 f 的查询网格区间, 客户端返回针对此区间的掩码0或1, 攻击者利用二分查找思想构造陷阱网格。若掩码为1, 则锁定此区域, 若掩

码为0, 则在另一区域, 在锁定的半区域内继续二分下发, 直至重构出精确的客户端数据。因此, 需对掩码进行隐私保护处理。

2.3 差分隐私

在本研究中, 为了保护参与方的数据隐私, 本文采用差分隐私技术来保证各客户端上传的局部统计信息不会泄露个体样本的隐私。

定义1 ϵ -差分隐私^[26]。对于两个相邻的数据集 D_1 和 D_2 , 满足条件 $\|D_1 - D_2\| \leq 1, \forall S \subseteq \text{Range}(\mathcal{A})$, 若算法满足:

$$\Pr[\mathcal{A}(D_1) \in S] \leq e^\epsilon \Pr[\mathcal{A}(D_2) \in S] \quad (1)$$

则称算法 $\mathcal{A}$ 满足 ϵ -差分隐私保护。其中, ϵ 是隐私预算, S 是算法输出的一个子集。公式表明, 差分隐私要求算法的输出对相邻数据之间的变化不敏感。 ϵ 值越小, 隐私保护程度越高。

定义2 全局敏感度^[27]。在差分隐私中, 给定一个函数 $f: D \rightarrow \mathbb{R}^d$, 其全局敏感度定义为:

$$\Delta f = \max_{D_1, D_2} \|f(D_1) - f(D_2)\|_1 \quad (2)$$

全局敏感度表示当数据集中任意一个样本被修改、加入或删除时, 函数输出可能发生的最大变化量。在本研究中, 由于每个客户端和服务端只统计本地计数, 因此全局敏感度 Δf 为1.0。

定义3. Laplace 机制^[28]。假设有一个敏感函数 $f(D)$, 拉普拉斯机制将向 $f(D)$ 的输出添加一个拉普拉斯分布的噪声, 噪声的尺度参数 b 与全局敏感度和隐私预算 ϵ 相关, 公式如下:

$$\mathcal{A}(D) = f(D) + \text{Lap}(0, \Delta f/\epsilon) \quad (3)$$

其中, $\text{Lap}(0, b)$ 表示均值为0, 尺度为 b 的拉普拉斯分布。噪声的大小由隐私预算 ϵ 控制, 较小的 ϵ 会导致更大的噪声, 从而提高隐私保护的强度。

定理1 序列组性^[29]。若算法由多个依次执行的差分隐私机制组成, 每个机制分别消耗隐私预算 $\epsilon_1, \epsilon_2, \dots, \epsilon_k$, 则整体算法的隐私消耗为各子机制的预算之和。设:

$$\mathcal{A}_i: D \rightarrow R_i; i = 1, 2, \dots, k \quad (4)$$

每个 $\mathcal{A}_i$ 均满足 ϵ_i -差分隐私, 则联合算法 $\mathcal{A}(D) = (\mathcal{A}_1(D), \mathcal{A}_2(D), \dots, \mathcal{A}_k(D))$ 满足 $(\sum_{i=1}^k \epsilon_i)$ -差分隐私。

定理2. 并行组性^[29]。若有若干个算法 $\mathcal{A}_1, \mathcal{A}_2, \dots, \mathcal{A}_k$ 分别作用在互不重叠的数据子集 $D_1, D_2, \dots, D_k$ 上, 且每个 $\mathcal{A}_i$ 满足 ϵ_i -差分隐私, 则组合算法 $\mathcal{A}(D) = (\mathcal{A}_1(D_1), \mathcal{A}_2(D_2), \dots, \mathcal{A}_k(D_k))$ 满足 $(\max_i \epsilon_i)$ -差分隐私。

3 PP-VFCLIQUE 聚类算法

3.1 问题定义

假设全局数据 $X \in \mathbb{R}^{n \times d}$ 在特征维度上分散存储在 N 个客户端 $P_1, P_2, \dots, P_N$ 上, 每个客户端 P_i 持有部分特征 $X_i \in \mathbb{R}^{n \times d_i}$, 其中 $d = \sum_{i=1}^N d_i$, n 为样本总数。 N 个客户端持有的数据集在特征维度上互不重叠, N 个客户端联合一个中央服务器 S 进行全局聚类。假设所有客户端均为诚实节点, 服务器为诚实但好奇节点, 各参与方之间不存在串通行为, 并严格遵循协议执行计算。最终, 服务器获得全局聚类簇, 客户端获得增强的聚类结果, 同时支持对聚类后的数据进行安全发布与分析。本文所使用的符号定义如表1所示。

3.2 算法结构

PP-VFCLIQUE 聚类算法在不共享原始数据的前提下, 实现全局稠密单元格的发现与基于密度的聚类, 算法架构如图1所示, 算法流程如下。

第一, 基于分位点的全局网格划分。各客户端在本地计算自己拥有的特征的分位数, 将结果发送给服务端。服务端聚合所有客户端的分位数, 形成统一的全局分位数标准, 并下发给所有客户端。所有客户端都使用相同的分位数标准进行网格划分, 确保全局一致性。

表1 符号及其含义

Tab. 1 Symbols and Their Meanings

符号	含义
N	客户端总数
n	全局样本总数
d	全局特征维度总数
X	全局数据集, $X \in \mathbb{R}^{n \times d}$
X_i	第 i 个客户端持有的本地数据集
d_i	第 i 个客户端持有的特征维度数目
ξ	网格划分参数, 每个维度的划分单元数
τ	密度阈值参数
δ	簇合并距离阈值
k	聚类维度, 当前处理的子空间维度
g	网格单元
u	稠密单元格, 表示为特征-网格索引的字典
U_k	k 维稠密单元格集合
C	聚类簇, 包含稠密单元格、维度集合和数据点索引
D	所有稠密单元格的集合
S	稠密单元格到数据点索引的映射关系
Q	分位点矩阵




图1 PP-VFCLIQUE算法架构

Fig. 1 PP-VFCLIQUE Algorithm Architecture

第二, 客户端挖掘本地稠密单元格。客户端依据全局分位数对本地数据进行处理, 统计每个单元格内的样本数量, 并对真实计数值进行扰动, 生成噪声计数值。如果某个网格的噪声密度达到或超过预设阈值, 则该网格被标记为一个一维稠密单元格。客户端仅将通过筛选的一维稠密单元格的坐标索引发送给服务端, 不传输具体的计数值。

第三, 全局稠密单元格筛选。服务端汇聚所有一维坐标索引后进行多轮迭代。生成 $k+1$ 维候选单元并下发至客户端。客户端本地计算二值掩码, 并对掩码及独立噪声进行同态加密后上传。服务器在密文域完成聚合, 解密获得加噪计数值, 并依据阈值衰减策略判定稠密单元格。该过程持续迭代, 直至无新稠密单元格生成或达到最大维度 $k_{\max}$ 。

最后, 服务端构建聚类簇。通过广度优先搜索发现图中的连通分量, 每个连通分量形成一个初始簇。服务端估算各簇的样本集合, 并计算近似质心。对质心距离小于设定阈值的簇进行合并, 最后将未分配的样本分配到最近的簇质心, 完成整个聚类过程, 如算法1所示。

算法1 PP-VFCLIQUE算法。

输入: 客户端 $\{P_i\}_{i=1}^N$, 本地数据 X_i , 网格划分参数 ξ , 初始密度阈

值 τ , 每轮迭代的单步隐私预算 ε , 公钥 pk , 最大聚类维度 $k_{\max}$; 输出: 聚类结果 C^* 。

- 1) 客户端 P_i 计算本地特征的分位数并发送给服务器;
- 2) 服务器构建 s 分位点矩阵 Q 并广播;
- 3) for 每个客户端 P_i do
- 4) P_i 对本地特征 X_i 进行量化, 得到 Z_i ;
- 5) for 每个网格单元 g do
- 6) 计算本地一维单元的噪声计数 $\tilde{C}_{j,g}^{(i)}$
- 7) 计算噪声计数密度 $\tilde{\rho}_{j,g}^{(i)} = \frac{\tilde{C}_{j,g}^{(i)}}{n}$;
- 8) if $\tilde{\rho}_{j,g}^{(i)} \geq \tau_1$ then
- 9) 将 g 加入集合 $U_1^{(i)}$;
- 10) end if
- 11) end for
- 12) 将 $U_1^{(i)}$ 坐标索引发送给服务器;
- 13) end for
- 14) 服务端构建全局一维稠密单元集合 U_1 ; 令 $k \leftarrow 1$;
- 15) while $U_k \neq \emptyset$ and $k < k_{\max}$ do
- 16) 服务端生成 $k+1$ 维候选集 U_{k+1}^{cand} 并广播;
- 17) for 每个候选单元 $u \in U_{k+1}^{cand}$ do
- 18) for 每个客户端 P_i do
- 19) 计算掩码向量 $M_i(u)$;
- 20) 采样噪声 $\eta_i \sim \text{Lap}(1/\varepsilon)$;
- 21) 使用公钥 pk 加密并上传 $\text{Enc}(M_i)$ 和 $\text{Enc}(\eta_i)$;
- 22) end for
- 23) 服务端聚合解密, 得到 $\tilde{C}(u)$;
- 24) 计算 $\text{density}(u)$;
- 25) 更新阈值 τ_{k+1} ;
- 26) if $\text{density}(u) \geq \tau_{k+1}$ then
- 27) $U_{k+1} \leftarrow U_{k+1} \cup \{u\}$;
- 28) end if
- 29) end for
- 30) $k \leftarrow k+1$
- 31) end while
- 32) 构建连通图并提取聚类簇 C^* ;
- 33) return C^*

3.3 算法实现

在服务器端的协作下, PP-VFCLIQUE算法通过多轮联邦迭代完成跨客户端的高维稠密单元格发现, 本节主要介绍算法的实现细节。

3.3.1 全局网格划分

各客户端在本地计算所持有数据的特征的 ξ 分位数, 将结果发送给服务端。服务器基于所有客户端提供的本地分位数, 计算每个特征的全局分位数。所有客户端使用相同的分位数定义来编码本地持有的特征, 但对于本地不持有的特征, 须知其定义而不实际使用。

服务器端计算全局分位数矩阵 $Q \in \mathbb{R}^{(\xi+1) \times d}$, 根据全局数据分布计算每个特征的 $\xi+1$ 个分位点, 每个特征被划分为 ξ 个等频区间, 每个区间表示为:

$$I_g^j = [q_g^{(j)}, q_{g+1}^{(j)}], g = 0, 1, \dots, \xi - 1$$

其中: I_g^j 为第 j 个特征的第 g 个网格区间, $q_g^{(j)}$ 表示第 j 个特征的第 g 个分位点, 为了确保覆盖所有样本, 最后一个区间 $I_{\xi-1}^j$ 设为闭区间。随后, 服务端将分位矩阵 Q 广播至各客户端, 确保所有特征空间划分一致。

3.3.2 本地稠密单元格挖掘

客户端 P_i 接收到分位矩阵 Q 后, 依据其持有的本地数据矩阵 $X_i \in \mathbb{R}^{n \times d}$ 进行量化编码。设 x_k^j 为第 k 个样本在第 j 个特征上的原始数据, 客户端通过映射函数将连续的 X_i 转换为离散的网格索引矩阵 $Z_i \in \mathbb{Z}^{n \times d}$ 。矩阵 Z_i 中的元素 z_k^j 表示样本 k 的第 j 个特征, 若其落在单元 g 中, 则记为: $z_k^j = g$, 当 $q_g^{(j)} \leq x_k^j < q_{g+1}^{(j)}$ (对于最后一个区间, 规

则为 $q_{\xi-1}^{(j)} \leq x_k^{(j)} \leq q_{\xi}^{(j)}$ 。这些步骤为所有客户端将原始数值统一映射为网格坐标索引,为后续保护隐私的稠密单元格挖掘提供基础。所谓稠密单元格,指给定密度阈值 τ ,单元格 g 的密度 $\tilde{C}_{j,g}^{(i)} \geq \tau$ 。稠密单元格表示在该子空间区域内数据点具有较高的局部密度,是后续子空间扩展和聚类生成的基本单元。

纵向联邦环境下,对 CLIQUE 算法中每一维单元格进行计数是实现密度判定的关键。然而,单元格计数值反映了某一特征取值范围内该参与方的样本的数量分布,一旦在参与方之间直接交换或聚合计数值,可能导致潜在的隐私泄露风险。首先,由于纵向场景中各参与方掌握的是同一批样本的不同特征,若某单元格计数值呈现异常稀疏或接近唯一,其他参与方可能据此推断出特定的样本是否落入该特征区间,实施成员推断攻击^[30]。其次,在跨参与方对多个单元格计数值进行联合分析时,可能进一步泄露目标样本在不同维度上的取值模式,导致特征推断攻击^[31]。更为重要的是,当单元格划分较细时,计数结果与原始特征分布近似等价,传递未经扰动的计数信息会暴露参与方的局部数据分布。基于上述原因,单元格计数过程必须引入隐私保护机制,以防止在联邦聚类过程中通过计数值反向恢复个体或其特征信息。因此,算法首先计算每个一维单元的噪声计数值,用下面的公式表示:

$$\tilde{C}_{j,g}^{(i)} = \left| \left\{ x \in X_i \mid g_j(x^{(j)}) = g \right\} \right| + \text{Lap}(1/\varepsilon) \quad (5)$$

其中: $\tilde{C}_{j,g}^{(i)}$ 为客户端 i 在特征 j 的网格 g 上的噪声计数值, ε 为每轮迭代的单步隐私预算,由上述公式可计算出噪声密度 $\tilde{\rho}_{j,g}^{(i)} = \frac{\tilde{C}_{j,g}^{(i)}}{n}$,若 $\tilde{\rho}_{j,g}^{(i)} \geq \tau_1$,则将该单元标记为一维稠密单元格,放入集合 $U_k^{(i)}$ 中。

在传统 CLIQUE 算法中,固定的密度阈值对所有维度均相同。然而,随着子空间维 k 的增加,数据在高维空间中的稀疏性迅速上升,若仍使用固定阈值将导致高维稠密单元格被大量剪枝,聚类结果出现碎片化。为解决该问题,本文提出了阈值衰减策略,密度阈值随维度增加动态衰减,调整公式如(6)所示。

$$\tau_k = \max(\tau \times \alpha^{(k-1)}, \beta \times (1/\xi)^k) \quad (6)$$

其中, τ_k 表示第 k 维的密度阈值, τ 表示初始密度阈值, α 为主衰减系数, β 为下界保护系数。随着聚类维度的增加, $\tau \times \alpha^{(k-1)}$ 描述阈值随子空间维度增加逐渐衰减的趋势。 $\beta \times (1/\xi)^k$ 提供与网格粒度相关的下界约束,防止阈值过快衰减引入大量噪声单元。在近似均匀背景假设下,随机背景单元的期望密度随维度增加按 ξ^{-k} 衰减,因此下界项 $\beta \times (1/\xi)^k$ 保证阈值与背景密度衰减保持同阶,从而抑制高维伪稠密单元大量进入,真实簇对应的稠密单元虽然也会因维度扩展出现局部密度下降,但其下降速度通常慢于随机背景单元。因此,主衰减系数 α 并非简单降低阈值,而是在保留真实高维稠密结构与抑制高维噪声扩张之间取得平衡。该机制在高维场景下有效缓解了过度剪枝问题,提高了高维稠密结构的保留率。

为了最大限度地保护数据隐私,客户端在初始阶段仅上传筛选过的一维稠密单元格的坐标索引,服务端汇聚所有客户端上传的坐标索引,构建全局一维稠密单元格集合 U_1 ,服务端汇聚所有一维单元后,采用 Apriori 原理逐层生成高维候选集合。具体而言,服务端基于已确认的 k 维稠密单元格集合 U_k ,通过连接步生成 $k+1$ 维候选单元集合 U_{k+1}^{cand} ,方法如下:

$$U_{k+1}^{cand} = \left\{ u_a \cup u_b \mid u_a, u_b \in U_k, u_a \neq u_b, |u_a \cap u_b| = k-1 \right\} \quad (7)$$

其中, u_a, u_b 表示属于集合 U_k 的两个 k 维稠密单元格。服务端将生成的 $k+1$ 维候选单元集合 U_{k+1}^{cand} 广播给客户端。对于每一个候选单元 $u \in U_{k+1}^{cand}$,持有对应特征的客户端 P_i 在本地计算局部二值掩码 $M_i(u) \in \{0, 1\}^n$,其中 n 为全局样本总数,掩码即为一个长度为 n 的二值向量:若第 j 个样本在 P_i 所持有的特征落在候选单元 u 内,则 $M_i(u)[j] = 1$,否则为 0。

定义 4 单元格全局支持度。对于一个给定的 k 维候选单元 u ,其加噪后的全局支持度计数记作 $\tilde{C}(u)$,公式如下:

$$\tilde{C}(u) = \text{Dec}(C_{\text{final}}) = \|S(u)\|_1 + \sum \eta_i \quad (8)$$

其中, $\|S(u)\|_1$ 为真实支持度计数,即 $S(u)$ 的 L_1 范数, $\sum \eta_i$ 为聚合后的总噪声,满足 $\text{Lap}(1/\varepsilon)$ 。

将局部掩码进行按位与操作,即可得到全局支持度向量: $S(u) = M_1(u) \wedge M_2(u) \wedge \dots \wedge M_N(u)$ 。 $S(u)$ 中取值为 1 的位置代表该样本同时满足候选单元 u 的所有特征条件。

定义 5 独立噪声。独立噪声是指各参与方在本地为实现差分隐私保护而独立生成并注入的随机扰动项。对于客户端 P_i ,其生成的噪声记为 η_i ,满足拉普拉斯分布: $\eta_i \sim \text{Lap}(1/\varepsilon)$,各客户端生成的噪声 $\{\eta_i\}_{i=1}^N$ 相互独立,并在密文域参与安全聚合。

在计算全局支持度时,仅使用单一保护机制存在安全隐患。若仅使用差分隐私而不加密,传输的明文掩码将直接泄露样本位置信息;若仅使用加密而不加噪,解密后的精确计数值可能遭遇成员推断攻击。为了防止直接传输原始掩码泄露样本的位置信息,服务器端需联合客户端利用安全聚合协议,在密文域协作计算单元格的全局支持度。

在计算过程中,不能将向量 $S(u)$ 的明文直接发送给服务器。采用分布式噪声注入机制,各客户端 P_i 独立采样拉普拉斯噪声 η_i 。此处注入的噪声与一维稠密单元格挖掘阶段保持一致,均服从差分隐私机制的要求。为了实现密文计算,各客户端利用同态加密算法^[32]对局部掩码向量 M_i 和独立噪声 η_i 进行加密。以 $pk = (n, g)$ 为公钥,对于掩码向量中的单个元素值 x 进行加密: $\text{Enc}(x) = g^x \cdot r^n \bmod n^2$ 。其中, r 为客户端在每次加密时独立选取的随机盲化因子,确保即使对相同的明文进行多次加密,生成的密文也完全不同,防止字典攻击。客户端将加密后的掩码向量 $\text{Enc}(M_i)$ 与加密噪声 $\text{Enc}(\eta_i)$ 上传给服务端。

3.3.3 阈值衰减策略分析

为进一步说明式(6)中阈值衰减策略的合理性,下面从算法终止性、噪声扰动下的判定稳定性以及高维条件下的聚类一致性三个方面进行分析。

在算法终止性方面,对于任意维度 k ,第 k 维稠密单元格集合 U_k 的大小至多为 $|U_k| \leq \binom{d}{k} \xi^k$,在 d 维特征空间中,任选 k 维共有 $\binom{d}{k}$ 种方式,而每个维度被划分为 ξ 个网格区间,因此一个 k 维子空间中最多包含 ξ^k 个网格单元。故各层候选或稠密单元格集合的规模均有限,算法按照由低维到高维的方式逐层扩展候选单元格,当候选集为空或达到预设的最大搜索维度时终止,因此算法必然在有限步内结束。

在噪声稳定性方面,设候选单元格 u 的真实密度为 $\rho(u)$,根据式(8),加噪后的全局支持度计数满足 $\tilde{C}(u) = \|S(u)\|_1 + \sum \eta_i$,故加噪后的密度估计可表示为 $\tilde{\rho}(u) = \frac{\tilde{C}(u)}{n} = \rho(u) + \frac{\sum \eta_i}{n}$,其中, $\sum \eta_i$ 为服务端解密后得到的聚合总噪声,单元格被误判,仅当噪声扰动足以使其加噪后的密度估计跨越判定阈值 τ_k 时才会发生,记 $\gamma_k(u) = |\rho(u) - \tau_k|$ 为单元格真实密度与阈值之间的间隔, $\gamma_k(u)$ 为该单元格不被误判的安全边界,只有当噪声造成的密度偏移至少达到这一间隔时,才可能发生误判。由于拉普拉斯噪声的尾概率呈指数衰减,可得 $\Pr(|\tilde{\rho}(u) - \rho(u)| \geq \gamma_k(u)) \leq e^{-n\varepsilon\gamma_k(u)}$,当隐私预算固定且单元格真实密度与判定阈值之间保持正的间隔时,样本规模越大,单元格被误判的概率越小,因此稠密单元格的判定在统计上是稳定的。

在聚类一致性方面,在各客户端基于统一全局分位点矩阵划分网格,真实稠密单元格与非稠密单元格之间存在正的密度间隔,不同真实簇之间至少由一层非稠密单元格隔开,以及簇合并过程不造成跨簇误合并的条件下,由概率并交界可知,多个候选单元格中“至少一个被误判”的概率不超过各单元格误判概率之和。因此,随着样本规模增加,各层候选单元集合中的单元格均可被正确判定,所得稠密单元格集合的连通结构与真实簇保持一致,最终聚类结果在上述条件下依概率收敛于真实聚类划分。

3.3.4 全局稠密单元格筛选

服务端利用交互式安全乘法协议,在密文域计算各方加密掩码

的乘积,得到全局支持度向量 $S(u)$ 的密文形式,利用同态加法特性将交集密文向量中的所有元素相乘,并将收集到的所有客户端的加密噪声 $Enc(\eta_i)$ 乘入该结果中。最终,服务端对聚合后的密文进行解密,由于噪声已在密文状态下混入,服务端解密后直接获得加噪后的全局支持度计数 $\tilde{C}(u) = Dec(C_{final}) = \|S(u)\|_1 + \sum \eta_i$ 。其中, $\|S(u)\|_1$ 为真实支持度计数,即 $S(u)$ 的 L_1 范数, $\sum \eta_i$ 为聚合后的总独立噪声,且符合 $Lap(1/\epsilon)$ 分布,与一维阶段公式(5)中的噪声机制原理一致。通过此过程,服务端在统计全局密度的同时,无法获知任何样本的具体位置信息。

服务端基于噪声计数值计算全局密度 $density(u) = \frac{\tilde{C}(u)}{n}$ 。并根据前文阈值衰减策略公式(6)确定此维度的稠密单元格,保留满足 $density(u) \geq \tau_{k+1}$ 的候选单元,构成 $k+1$ 维全局稠密单元格集合 U_{k+1} : $U_{k+1} = \{u \in U_k^{cand} | density(u) \geq \tau_{k+1}\}$ 。算法依次进行以上操作,继续不断迭代,逐层递增维度,当 $U_{k+1} = \emptyset$ 或 $k = k_{max}$ 时,联邦迭代过程终止。最终,所有层级的稠密单元格构成集合 $\mathcal{D}$:

$$\mathcal{D} = \bigcup_{k=1}^{k_{max}} U_k \quad (9)$$

服务端基于集合 $\mathcal{D}$ 构建稠密单元格连通图并提取聚类簇。

3.3.5 构建聚类簇

获得所有稠密单元格集合 $\mathcal{D}$ 后,算法通过构建稠密单元格连通图实现聚类簇提取。每个稠密单元格被视作图节点,若两个单元在相同子空间且对应维度的网格索引差不超过1,则建立边连接,形成稠密单元格图:

$$G = (\mathcal{D}, E), E = \{(u_i, u_j) | \|u_i - u_j\|_1 \leq 1\} \quad (10)$$

服务端采用广度优先搜索(BFS)提取每个连通分量作为初始聚类簇:

$$\mathcal{C} = \{C_1, C_2, \dots, C_m\}, C_p = BFS(G, u_{start}) \quad (11)$$

然而,在联邦聚类场景下,由于不同客户端特征空间的局部性差异,初始簇可能存在碎片化问题。为进一步提升聚类完整性,在聚类生成阶段引入基于质心距离的簇合并机制。设聚类簇 C_p 由若干稠密单元格组成,每个稠密单元格在其所涉及的特征维度上由对应的网格索引表示。定义簇 C_p 在第 j 个特征维度上的质心分量为 $\mu_p^{(j)}$:

$$\mu_p^{(j)} = \frac{1}{|C_p^{(j)}|} \sum_{u_i \in C_p^{(j)}} g_{i,j}, |C_p^{(j)}| > 0 \quad (12)$$

其中, $C_p^{(j)}$ 表示在第 j 个特征维度上包含网格索引的稠密单元格集合, $g_{i,j}$ 为稠密单元格 u_i 在该维度上的网格索引。由此,定义聚类簇 C_p 的质心向量为 μ_p :

$$\mu_p = (\mu_p^{(1)}, \mu_p^{(2)}, \dots, \mu_p^{(d)}) \quad (13)$$

任意两个聚类簇 C_p 与 C_q 之间的距离定义为其质心向量在网格索引空间中的欧氏距离。当其距离小于给定阈值 δ 时,对两个簇执行合并操作:

$$\|\mu_p - \mu_q\|_2 < \delta \Rightarrow C_p \leftarrow C_p \cup C_q \quad (14)$$

此外为了确保样本的全覆盖,对于未落入任何稠密单元格的孤立样本,算法将其分配至最近的簇质心,规则如下:

$$label(x) = \arg \min_p \|\mu_p - x\|_2 \quad (15)$$

经簇合并与再分配后,服务端输出最终聚类结果的集合 $\mathcal{C}^*$ 。本文提出的方法有效缓解了稠密单元格碎片化带来的聚类不稳定问题,提升了聚类结果的整体连贯性与解释性。

3.4 隐私分析

本节从隐私预算累积与安全性两个方面对算法进行分析。

3.4.1 隐私预算组合分析

算法的联邦迭代过程由多轮差分隐私机制组成,整体隐私损失由定理1序列组合性计算。设算法共执行 R 轮迭代,每轮消耗隐私预算 ϵ ,则总隐私损失为: $\epsilon_{total} = R \cdot \epsilon$ 。具体而言,在一维稠密单元格挖

掘阶段,各客户端对本地计数值添加 $Lap(1/\epsilon)$ 噪声,消耗隐私预算 ϵ ;在后续高维候选单元阶段,每一轮迭代中客户端上传加密掩码并注入独立噪声,每轮消耗预算 ϵ ,由于各维度的候选单元作用于互不重叠的数据子集,根据定理2并行组合性,同一轮内各维度的隐私损失取最大值而非累加,因此总预算仍为 $R \cdot \epsilon$ 。由前文阈值衰减策略分析可知,迭代轮数 R 有限,故总隐私预算 ϵ_{total} 有界,其中 R 为实际迭代轮数,随数据集特征维度和网格参数变化,实验中多数数据集在达到最大维度前因候选集为空而提前终止,实际消耗的总预算通常低于 $d \cdot \epsilon$,其中 d 为数据集特征维度数。

3.4.2 安全性分析

算法针对诚实但好奇的服务器及恶意成员推断、特征推断攻击提供以下保护。

成员推断攻击试图通过观察上传的中间结果判断某一样本是否属于特定单元格。在一维阶段,客户端上传的是加噪后的计数值而非原始计数,噪声的引入使得服务器无法从计数值精确还原样本归属。在高维阶段,客户端上传的是经同态加密的二值掩码,服务器仅能在密文域完成聚合并解密得到加噪后的全局支持度计数,无法获知任何单个样本的位置信息。因此,无论是一维阶段还是高维阶段,攻击者均无法通过观察算法输出判断某一特定样本是否属于某个单元格,从而抵御成员推断攻击。特征推断攻击试图通过多轮迭代中的掩码信息逐步重构客户端的私有特征值,即前文所述的二分查找攻击,算法通过两层机制抵御此类攻击:第一,同态加密保证服务器在密文域完成计算,无法观测明文掩码;第二,每轮注入的独立拉普拉斯噪声使得即便攻击者截获密文并尝试暴力解密,解密后的结果也因噪声干扰而无法精确定位样本的特征区间。攻击者无法通过有限轮迭代将特征值精确定位,从而从根本上破坏了2.2节所述二分查找攻击的前提条件。

4 实验结果与分析

4.1 实验设置与实验数据

本实验的环境为:16核Intel(R) Xeon(R) Gold 6430 CPU; Ubuntu 22.04 64位操作系统;NVIDIA RTX 4090(24GB显存)显卡。为验证本文所提方法的有效性,本文选取10个公开聚类数据集进行实验,涵盖不同样本规模、特征维度和类别分布,数据集的具体信息如表2所示。

表2 实验数据集信息

Tab. 2 Information on the Experimental Dataset

数据集	样本数	属性数	簇数	类别规模
Wine	178	13	3	59,71,48
Iris	150	4	3	50,50,50
Seeds	210	7	3	70,70,70
Breast	569	30	2	212,357
Waveform	5000	21	3	1657,1647,1696
Dermatology (Derma)	366	33	6	112,61,72,49,52,20
Zoo	101	17	7	41,20,5,13,4,8,10
Satellite (Sat)	6435	34	6	1533,703,1358,626,707,1508
Ecoli	336	7	8	143,77,52,35,20,5,2,2
Pima	768	8	2	500,268

为全面评估模型性能,本文建立了多维度的评估指标体系,从准确率、聚类质量、完整性等角度进行综合评估。为全面评估模型的聚类性能,本文构建了多维度评价指标体系,从准确率(Accuracy, ACC)、归一化互信息(Normalized Mutual Information, NMI)、调整兰德指数(Adjusted Rand Index, AR)、同质性(Homogeneity)、完整性(Completeness)以及统一指标V-measure等多个角度对模型性能进行综合评估^[33, 34]。

4.2 实验数据划分方式

为构建纵向联邦学习实验环境,本文在保证样本ID对齐的前提下,对特征维度进行划分。具体而言,设原始数据集包含 n 个样本和 d 维特征,设置 N 个客户端。各客户端拥有相同的样本ID集合,但仅持有对应样本的部分特征,从而形成“样本对齐、特征分散”的纵向联邦数据结构。特征划分采用轮转均匀分配策略,按照特征索引顺序,将第 i 个特征分配至编号为 $i \bmod N$ 的客户端。保证各客户端获得的特征数量差异不超过1,从而实现近似均衡划分,同时避免随机划分带来的实验波动问题,提高实验结果的可复现性。例如,在 $N=3$ 的实验设置下,wine数据集包含 $d=13$ 维特征,按照上述轮转规则进行划分后,三个客户端分别持有5维、4维和4维特征。在该设定下,任一客户端仅能观测其本地特征子空间中的密度结构,无法获得完整

特征空间中的联合分布信息。

4.3 实验结果分析

本实验从三个方面对PP-VFCLIQUE算法进行评估:阈值衰减策略的有效性、隐私保护对聚类精度的影响,以及与其他相关算法的对比实验分析。

4.3.1 阈值衰减策略评估

在基于密度的聚类过程中,稠密单元格判定阈值的设置对聚类结果具有重要影响。本文在PP-VFCLIQUE算法中引入阈值衰减策略。本实验对CLIQUE算法、纵向联邦环境下固定阈值的CLIQUE算法(表示为:联邦-固定阈值)及阈值衰减的联邦CLIQUE算法(表示为:联邦-阈值衰减)在8个公开数据集上进行了对比分析,实验结果如表3所示。

表3 对比实验结果

Tab. 3 Comparison of Experimental Results

方法	ACC			NMI			ARI		
	CLIQUE	联邦-固定阈值	联邦-阈值衰减	CLIQUE	联邦-固定阈值	联邦-阈值衰减	CLIQUE	联邦-固定阈值	联邦-阈值衰减
Wine	0.7135	0.9101	0.9663	0.6256	0.7290	0.8662	0.5664	0.7468	0.8975
Iris	0.7684	0.9133	0.9400	0.6620	0.7342	0.8192	0.6292	0.7588	0.8341
Seeds	0.9667	0.8762	0.9286	0.8875	0.6684	0.7524	0.9036	0.6770	0.7992
Breast	0.6381	0.8172	0.9438	0.5747	0.5808	0.7007	0.5545	0.6821	0.7857
Waveform	0.5060	1	0.9993	0.4400	1	0.9956	0.3512	1	0.9980
Dermatology	0.7131	0.6967	0.8251	0.7771	0.5099	0.8395	0.6482	0.4209	0.7992
Zoo	0.8020	0.8614	0.8614	0.7686	0.8219	0.8713	0.7841	0.8094	0.8476
Sat	0.8977	0.8920	0.9080	0.8644	0.6831	0.6850	0.8570	0.7093	0.7471

方法	Homogeneity			Completeness			V-Measure		
	CLIQUE	联邦-固定阈值	联邦-阈值衰减	CLIQUE	联邦-固定阈值	联邦-阈值衰减	CLIQUE	联邦-固定阈值	联邦-阈值衰减
Wine	0.7096	0.7326	0.8687	0.5594	0.7255	0.8636	0.6256	0.7290	0.8662
Iris	0.7458	0.7336	0.8187	0.5950	0.7348	0.8196	0.6620	0.7342	0.8192
Seeds	0.8866	0.6658	0.7523	0.8883	0.6710	0.7525	0.8875	0.6684	0.7524
Breast	0.5590	0.6745	0.6857	0.5913	0.5099	0.7165	0.5747	0.5808	0.7008
Waveform	0.4277	1	0.9956	0.4531	1	0.9956	0.4400	1	0.9956
Dermatology	0.8219	0.4791	0.7868	0.7369	0.5450	0.8998	0.7771	0.5099	0.8395
Zoo	0.7643	0.8327	0.9099	0.7729	0.8113	0.8358	0.7686	0.8219	0.8713
Sat	0.9016	0.6791	0.6843	0.8302	0.6871	0.6858	0.8644	0.6831	0.6850

联邦-阈值衰减策略在绝大多数数据集和评估指标上均显著优于单机基线方法和联邦固定阈值方法。特别是在ACC、NMI和ARI这三个指标上,在纵向联邦学习下有阈值衰减策略的指标值展现出较大优势。在Wine数据集上,联邦-阈值衰减策略下的ACC达到了0.9663,相比CLIQUE聚类0.7135和联邦-固定阈值策略的0.9101有显著提升。类似地,在Breast和Waveform数据集上,联邦-阈值衰减策略将ACC分别提升至0.9438和0.9993。这表明,通过联邦学习整合多客户端特征信息,并结合阈值衰减策略,能够有效挖掘数据中隐藏的聚类结构,获得更准确的聚类划分。

NMI和ARI指标进一步验证了联邦-阈值衰减在聚类质量和一致性方面的优越性。在Seeds数据集上,联邦-阈值衰减策略的ARI达到了0.7415,远高于CLIQUE聚类和联邦-固定阈值方法,表明该方法能更好地处理不同规模与形状的簇,并减少随机分配的影响。同样,在Dermatology数据集上,联邦-阈值衰减策略在NMI和ARI上分别达到了0.8395和0.7992,显著优于其他两种方法,表明其在复杂高维数据上仍能保持良好的聚类一致性。在Wine数据集上,阈值衰减策略的Homogeneity和Completeness分别为0.8687和0.8636,其综合指标V-Measure也相应达到最高0.8662,说明联邦-阈值衰减方法不仅能保证每个簇的纯度,也能确保同一类样本被完整地划分到同一簇中。值得注意的是,在Dermatology数据集上,联邦-固定阈值方法的Homogeneity和Completeness严重失衡,导致V-Measure偏低;而联邦-阈值衰减策略的结果两者提升至0.7868和0.8998,实现了更优的平衡,体现阈值衰减策略在调节聚类粒度方面的有效性。Waveform数据集在阈值衰减策略下几乎在所有指标上都接近于1,说明其具有

良好的泛化能力,无需依赖繁琐的参数调优即可达到最佳或接近最佳的性能。

4.3.2 裁剪阈值参数分析

在PP-VFCLIQUE算法中,阈值参数 τ 是用于判断单元格是否为稠密单元格的关键控制量,其本质上反映了对局部高密度区域划分的敏感程度。 τ 的取值直接影响稠密单元格的数量、单元间连通结构的形态,从而决定最终聚类结果的精细度与稳定性。为了系统分析 τ 的作用,实验在8个数据集上进行了 $\tau \in [0.01, 0.20]$ 的增量测试,实验结果如图2所示。

在本文所选的多个数据集上,裁剪阈值参数 τ 对聚类性能的影响




图2 τ 值对PP-VFCLIQUE结果的影响

Fig. 2 Effect of τ value on PP-VFCLIQUE results

呈现出相似的变化趋势:较小 τ 值通常带来较高的稠密单元格数量,使得算法能够捕捉较为细粒度的局部结构,因此ACC大多保持稳定;而随着 τ 增大,稠密单元格逐渐减少,聚类结构趋于粗糙,ACC出现下降甚至波动。这种趋势反映了CLIQUE聚类算法在纵向联邦场景下对 τ 的自然敏感性,即 τ 决定了聚类模型的“过分细化”与“过度稀疏”之间的平衡。

从具体数据来看,Wine、Iris、Dermatology与Seeds等数据集在 $\tau \in [0.01, 0.10]$ 区间表现出高度稳定性,ACC波动范围小,均维持在较高水平,Wine数据集在 $\tau=0.11$ 达到0.9213;Seeds数据集在 $\tau=0.13$ 至0.15达到0.9190。这说明在这些中低维、类别边界较清晰的数据集上,小至中等 τ 值能保留局部密度结构,提升聚类可分性。相比之下,Breast、Sat与Waveform三个数据集表现出明显的“峰值敏感性”。Breast数据集在 $\tau=0.07$ 至0.11附近ACC值达到0.91~0.93的较优区间,但在 $\tau \geq 0.15$ 时出现显著下降,说明高 τ 会破坏其局部高密度聚类结构;Sat在 $\tau=0.13$ 达到峰值0.9145,但当 τ 继续增大时ACC快速下降,表明其多类复杂结构对 τ 极其敏感;Waveform在 $\tau=0.09$ 至0.15之间ACC接近1.0,为所有数据集中最稳定的高性能区,但 $\tau > 0.16$ 后ACC急剧下滑至0.33,说明当稠密单元格过少时模型失去判别能力。这类典型多峰趋势说明对于高维、类别形状复杂或本身分布重叠的数据集, τ 在一定范围内能够帮助算法准确刻画潜在子空间结构,但超过临界点后,稠密单元格断裂导致聚类性能迅速恶化。这种结果也印证了CLIQUE算法依赖多维稠密单元格连通性这一本质特征。

4.3.3 隐私预算实验评估

考虑到不同数据集的特征维度差异较大,导致算法的迭代轮数并不固定。若采用固定总预算的分配方式,会导致高维数据在单轮迭代中分配到的预算过低,引入过大的噪声,因此,本实验给每轮设置不同的隐私预算分别进行聚类效果评估,每个隐私预算设置下,分别在每个数据集上运行算法10次,计算平均值与标准差,以全面评估算法在随机噪声影响下的表现。实验结果如图3所示。

实验结果表明,随着隐私预算 ϵ 的增大,本文方法在所有数据集

和评价指标上均呈现显著且稳定的性能提升趋势。ACC指标中,大部分数据集表现出连续增长,当噪声强度降低后,稠密单元格的识别更加准确,聚类结构更加清晰。Seeds数据集ACC从 0.8114 ± 0.1012 提升至 0.9190 ± 0.0292 ,均值提升超过13%,标准差下降约70%,说明算法在高噪声条件下仍保持较强的可用性。Iris数据集上的ACC同样从 0.7600 ± 0.0959 提升至 0.9027 ± 0.0483 ,其波动范围明显收窄,表明隐私噪声对判别边界的干扰减少后,整体聚类精度进一步提升。高维数据集Waveform在 $\epsilon \geq 0.8$ 时ACC达到 0.9636 ± 0.1051 ,接近完美聚类,体现出算法在处理复杂高维模式时的有效性。

从NMI、ARI与V-Measure等结构性指标来看,随着 ϵ 的增大,算法在所有数据集上的聚类质量和结果一致性也均保持稳步提升。Dermatology数据集上的NMI值从 0.7995 ± 0.0215 提升至 0.8395 ± 0.0001 ,标准差几乎为零,表明PP-VFCLIQUE在高维稀疏环境下具有极强的鲁棒性。Waveform数据集在 $\epsilon=1.0$ 时NMI达到 0.9599 ± 0.0823 ,接近理想聚类水平,进一步证明了算法在复杂数据空间中刻画真实子空间结构的能力。ARI指标同样呈现明确增长趋势,Dermatology的ARI从 0.6799 ± 0.0639 升至 0.7992 ± 0.0012 ,几乎不损失精度即可实现隐私保护。Waveform在 $\epsilon \geq 0.8$ 时ARI达到 0.9431 ± 0.1331 ,证明算法的有效性。

总体而言,PP-VFCLIQUE在不同隐私预算下均能保持较高的聚类性能,并随着隐私约束的放宽持续接近无隐私保护的最优效果。更重要的是,随着 ϵ 的增大,各评价指标的标准差均明显下降,表明算法对随机噪声具有较强抑制能力,输出结果更加稳定一致。在中等隐私预算下,多个数据集能达到较高的效果,说明该算法在实际应用场景中可以同时满足隐私保护需求与聚类精度要求。整体结果充分验证了PP-VFCLIQUE在纵向联邦场景下对高维数据、稀疏数据和多类别数据均具有良好的适应性。

4.4 对比实验结果分析

为进一步验证PP-VFCLIQUE在纵向联邦聚类场景下的有效性,本文选取近年来提出的四种代表性联邦聚类方法进行对比实验。实




图3 各评估指标在隐私预算0.1~1.0下的结果

Fig.3 Results of various evaluation metrics under a privacy budget of 0.1 to 1.0

验在5个公开数据集上评估各方法的聚类准确率,实验结果如表4所示。

表4 联邦聚类算法的ACC性能对比

Tab. 4 Comparison of ACC Performance of Federated Clustering Algorithms

数据集	VFDPC ^[21]	FKDC ^[15]	AFCL ^[35]	FedSC ^[36]	PP-VFCLIQUE
Wine	0.9551	0.6629	0.7711	0.7022	0.9337
Iris	0.9667	0.9000	0.8400	0.8933	0.9027
Seeds	0.9143	0.8524	0.7548	0.8952	0.9190
Ecoli	0.7066	0.7827	0.6091	0.5982	0.8214
Pima	0.6966	0.7122	0.6758	0.2513	0.7201

从表4可以看出,PP-VFCLIQUE在5个数据集上均取得最优或次优的聚类准确率。VFDPC^[21]通过混合加密保护距离矩阵,在低维数据集上表现优异,但依赖全局距离矩阵构建,在高维或类别不平衡数据集上性能下降明显;FKDC^[15]采用一次性联邦框架,通信效率高,但该方法面向纵向联邦场景设计,在纵向特征割裂场景下难以捕捉跨客户端的子空间结构;AFCL^[35]通过种子点协同机制自动确定聚类数,对客户异步性有较好鲁棒性,但未针对纵向场景优化,难以充分融合跨维度信息;FedSC^[36]通过核化矩阵分解重构相似性矩阵,适用于高维含噪声数据,但在特征分布复杂的数据上稳定性不足。相比之下,PP-VFCLIQUE有效恢复了跨客户端的子空间结构,在多个数据集上均表现出稳定的性能优势。

4.5 通信开销分析

为评估PP-VFCLIQUE在实际纵向联邦场景下的通信效率,本文统计了算法在5个数据集上的通信开销,包括平均每轮通信量、总通信量、通信轮数及运行时间,结果如表5所示。

表5 通信开销统计

Tab. 5 Communication overhead statistics

数据集	平均每轮通信量/KB	总通信量/KB	通信轮数	时间/s
Wine	25 068.94	125 344.69	5	2 155.49
Iris	3 174.64	19 047.81	6	330.73
Seeds	2 639.61	15 837.68	6	267.93
Ecoli	76 548.99	459 293.95	6	5.20
Pima	1 776.39	10 658.36	6	23.08

从算法复杂度来看,通信开销与候选子空间规模近似呈正相关,即约为 $O(U_{k+1}^{cand})$ 。从表5可以看出,本文提出的PP-VFCLIQUE在不同数据集上的通信开销呈现出一定差异,但整体具有良好的可控性。

具体而言,Wine数据集由于特征维度较高,候选子空间数量较多,其平均每轮通信量与总通信量显著高于Iris与Seeds数据集,对应的通信时间也相对较长。这主要是由于在纵向联邦子空间扩展过程中,高维候选单元的生成与验证会引入更多的加密掩码与噪声传输,从而增加通信负担。相比之下,Iris和Seeds数据集由于维度较低、候选单元规模较小,其通信轮数虽略高(6轮),但单轮通信量显著降低,总体通信开销保持在较低水平,体现了算法在低维场景下的高效性,Pima数据集的通信量相较于其他数据集较低,源于Pima数据集稠密结构较为紧凑,高维扩展时大量候选单元因密度不足而被快速剪枝,因此通信开销得以有效控制。相比之下,Ecoli数据集的数据分布导致在子空间扩展过程中保留了更多的稠密单元格,因此总通信量较高,其运行时间较短,主要源于同态加密计算负载的差异,密文运算连续密集,使得加密库的固定开销被摊薄,单位运算时间短。此外,通信轮数均保持在较小范围(5-6轮),说明算法在较少迭代次数内即可完成稠密单元筛选与聚类构建,具有较好的收敛性。

总体来看,PP-VFCLIQUE的通信开销主要受数据维度与候选子空间规模影响,但其通信轮数稳定、增长可控,在保证隐私保护的前提下,实现了通信效率与聚类性能之间的有效权衡,验证了方法在联邦环境中的可行性。

5 结论

本文提出一种满足差分隐私的纵向联邦聚类算法PP-VFCLIQUE。有效解决了纵向联邦学习中的隐私保护与子空间聚类问题。通过基于分位点的全局网格划分策略,确保了各参与方特征空间划分的一致性;设计的局部稠密识别-全局候选合并-支持度掩码验证流程,实现了通过分布式加噪以及加密掩码信息完成稠密单元格挖掘;引入的阈值衰减策略显著提升了高维数据下的聚类稳定性。在10个数据集上的实验表明,PP-VFCLIQUE在多项关键评估指标上均表现出优越性能。与现有联邦聚类方法的对比分析进一步验证了本算法在纵向联邦场景下的综合优势与泛化能力。然而,算法性能仍受网格划分参数影响,未来将重点研究参数自适应优化策略,进一步提升算法的实用性与鲁棒性。

参考文献 (References)

- [1] AGRAWAL R, GEHRKE J, GUNOPULOS D, et al. Automatic subspace clustering of high dimensional data for data mining applications [C]//Proceedings of the 1998 ACM SIGMOD International Conference on Management of Data. New York: ACM, 1998: 94-105.
- [2] YE J, SHI L, XU H, et al. A client detection and parameter correction algorithm for clustering defense in clustered federated learning [C]//Proceedings of the 30th Annual International Conference on Mobile Computing and Networking. New York: ACM, 2024: 2383-2388.
- [3] KONEČNÝ J, MCMAHAN H B, YU F X, et al. Federated learning: strategies for improving communication efficiency [EB/OL]. (2016-10-18) [2026-04-01]. <https://arxiv.org/abs/1610.05492>.
- [4] WOODRUFF D P. Computational advertising: techniques for targeting relevant ads [J]. Foundations and Trends in Theoretical Computer Science, 2014, 10(1-2): 1-157.
- [5] LIU Y, KANG Y, ZOU T, et al. Vertical federated learning: Concepts, advances, and challenges [J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(7): 3615-3634.
- [6] KIM H, KIM H, DE VECIANA G. Clustered federated learning via gradient-based partitioning [C]//Proceedings of the 41st International Conference on Machine Learning. Vienna: ML Research Press, 2024: 24137-24193.
- [7] BRIGGS C, FAN Z, ANDRAS P. Federated learning with hierarchical clustering of local updates to improve training on non-IID data [C]//Proceedings of the 2020 International Joint Conference on Neural Networks. Piscataway: IEEE, 2020: 1-9.
- [8] DE SOUZA L A C, CAMILO G F, CAMPISTA M E M, et al. Increasing the accuracy of federated learning on non-IID scenarios using client clustering [C]//Proceedings of the 2024 IEEE Latin-American Conference on Communications. Piscataway: IEEE, 2024: 196-201.
- [9] MORAFAH M, VAHIDIAN S, WANG W, et al. FLIS: Clustered federated learning via inference similarity for non-IID data distribution [J]. IEEE Open Journal of the Computer Society, 2023, 4: 109-120.
- [10] 鲁晨阳, 邓苏, 马武彬, 等. 基于DBSCAN聚类的集群联邦学习方法 [J]. 计算机科学, 2022, 49(增刊1): 232-237. (Lu Chenyang, Deng Su, Ma Wubin, et al. A cluster federated learning method based on DBSCAN clustering [J]. Computer Science, 2022, 49(S1): 232-237.)
- [11] MIAO J, WANG Y, CHENG X, et al. Parameter optimization clustering federated learning algorithm based on data heterogeneity [C]//Proceedings of the 2023 4th International Symposium on Computer Engineering and Intelligent Communications.

- Piscataway: IEEE, 2023: 149-154.
- [12] ZHANG Y, CHEN H, LIN Z, et al. FedAC: an adaptive clustered federated learning framework for heterogeneous data[EB/OL]. (2024-03-25) [2026-04-01]. <https://arxiv.org/abs/2403.16460>.
- [13] Du R, Xu S, Zhang R, et al. A dynamic adaptive iterative clustered federated learning scheme [J]. Knowledge-Based Systems, 2023, 276: 110741.
- [14] 申旭弘, 于海宁, 王孝余. 基于多方安全计算的联邦密度聚类算法研究[J]. 信息安全学报, 2025, 10(3): 18-34. (SHEN Xuhong, YU Haining, WANG Xiaoyu. Research on Federated Density-Based Clustering Based on Secure Multi-Party Computation [J]. Journal of Cyber Security, 2025, 10(3): 18-34.)
- [15] WANG Y, PANG W, WANG D, et al. One-shot secure federated K-means clustering based on density cores[J]. IEEE Transactions on Neural Networks and Learning Systems, 2025, 36(8): 14131-14143.
- [16] STALLMANN M, WILBIK A. Towards federated clustering: a federated fuzzy c-means algorithm (FFCM)[EB/OL]. (2022-01-18)[2026-04-01]. <https://arxiv.org/abs/2201.07316>.
- [17] ALFAWAZ O, EL-MOURSAY A A, SAAD M, et al. VFCKM: a federated clustering framework based on k-means algorithm for vertically partitioned data with shared attributes[J]. The Journal of Supercomputing, 2025, 81(7): Article 855.
- [18] 徐雪冉, 杨庚, 黄喻先. 横向联邦学习中差分隐私聚类算法[J]. 计算机应用, 2024, 44(1): 217-222. (Xu Xueran, Yang Geng, Huang Yuxian. Differential privacy clustering algorithm in horizontal federated learning [J]. Journal of Computer Applications, 2024, 44(1): 217-222.)
- [19] BALKUS S V, FANG H, WANG H. Federated fuzzy clustering for longitudinal health data [C]//Proceedings of the 2022 IEEE/ACM Conference on Connected Health: Applications, Systems and Engineering Technologies. Washington, DC: IEEE Computer Society, 2022: 128-132.
- [20] DING S, LI C, XU X, et al. Horizontal federated density peaks clustering [J]. IEEE Transactions on Neural Networks and Learning Systems, 2025, 36(1): 820-829.
- [21] LI C, DING S, XU X, et al. Vertical federated density peaks clustering under nonlinear mapping [J]. IEEE Transactions on Knowledge and Data Engineering, 2025, 37(2): 1004-1017.
- [22] BOZDEMIR B, CANARD S, ERMIS O, et al. Privacy-preserving density-based clustering [C]//Proceedings of the 2021 ACM Asia Conference on Computer and Communications Security. New York: ACM, 2021: 658-671.
- [23] HE Z, WANG L, CAI Z. Clustered federated learning with adaptive local differential privacy on heterogeneous IoT data [J]. IEEE Internet of Things Journal, 2024, 11(1): 137-146.
- [24] LUO G, CHEN N, HE J, et al. Privacy-preserving clustering federated learning for non-IID data [J]. Future Generation Computer Systems, 2024, 154: 384-395.
- [25] YANG Q, LIU Y, CHEN T, et al. Federated machine learning: Concept and applications [J]. ACM Transactions on Intelligent Systems and Technology, 2019, 10(2): 1-19.
- [26] DWORK C, ROTH A. The algorithmic foundations of differential privacy [J]. Foundations and Trends in Theoretical Computer Science, 2014, 9(3/4): 211-407.
- [27] FAN Z, XU X. Apdpk-means: A new differential privacy clustering algorithm based on arithmetic progression privacy budget allocation [C]// Proceedings of the 2019 IEEE 21st International Conference on High Performance Computing and Communications, IEEE 17th International Conference on Smart City, and IEEE 5th International Conference on Data Science and Systems. Piscataway: IEEE, 2019: 1737-1742.
- [28] YANG M, GUO T, ZHU T, et al. Local differential privacy and its applications: A comprehensive survey [J]. Computer Standards & Interfaces, 2024, 89: 103827.
- [29] DWORK C. Differential privacy [C]// Proceedings of the 33rd International Colloquium on Automata, Languages and Programming. Cham: Springer, 2006: 1-12.
- [30] HE X, XU Y, ZHANG S, et al. Enhance membership inference attacks in federated learning [J]. Computers & Security, 2024, 136: 103535.
- [31] YE P, JIANG Z, WANG W, et al. Feature reconstruction attacks and countermeasures of DNN training in vertical federated learning [J]. IEEE Transactions on Dependable and Secure Computing, 2025, 22(3): 2659-2669.
- [32] ACAR A, AKSU H, ULUAGAC A S, et al. A survey on homomorphic encryption schemes: Theory and implementation [J]. ACM Computing Surveys, 2018, 51(4): 1-35.
- [33] LI Y, HU P, LIU Z, et al. Contrastive clustering [C]// Proceedings of the Thirty-Fifth AAAI Conference on Artificial Intelligence. Menlo Park, CA: AAAI, 2021: 8547-8555.
- [34] MISHRA B K, MOHANTY S N, BAIDYANATH R R, et al. An efficient framework for obtaining the initial cluster centers [J]. Scientific Reports, 2023, 13(1): 20821.
- [35] ZHANG Y, ZHANG Y, LU Y, et al. Asynchronous federated clustering with unknown number of clusters [C]//Proceedings of the Thirty-Ninth AAAI Conference on Artificial Intelligence. Menlo Park, CA: AAAI, 2025: 22695-22703.
- [36] QIAO D, DING C, FAN J. Federated spectral clustering via secure similarity reconstruction [C]// Proceedings of the 37th Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates, Inc., 2023: 58520-58555.

This work is partially supported by the National Science Foundation of Hebei Province (No. F2025207001), the Central Government Fund for Guiding Local Science and Technology Development Project in Hebei Province (No. 246Z0703G).

ZHANG Jiayi, born in 2001, M. S. candidate. His research interests include federated clustering, privacy-preserving techniques.

Huo Zheng, born in 1982, Ph. D., professor. Her research interests include privacy-preserving techniques and federated learning.

WANG Suzhen, born in 1964, Ph. D., professor. Her research interests include machine learning and mobile cloud computing.