



电网技术
Power System Technology
ISSN 1000-3673, CN 11-2410/TM

《电网技术》网络首发论文

题目：基于联邦学习的非侵入式负荷监测模型自适应迁移方法
作者：张睿祺，栾文鹏，刘博
收稿日期：2025-04-24
网络首发日期：2026-04-10
引用格式：张睿祺，栾文鹏，刘博. 基于联邦学习的非侵入式负荷监测模型自适应迁移方法[J/OL]. 电网技术. <https://link.cnki.net/urlid/11.2410.TM.20260409.1921.009>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于联邦学习的非侵入式负荷监测模型 自适应迁移方法

张睿祺, 栾文鹏, 刘博*

(智能电网教育部重点实验室(天津大学), 天津市 南开区 300072)

An Adaptive Transfer Method for NILM Model Based on Federated Learning

ZHANG Ruiqi, LUAN Wenpeng, LIU Bo*

(Key Laboratory of the Ministry of Education on Smart Power Grids (Tianjin University), Nankai District, Tianjin 300072, China)

ABSTRACT: Non-intrusive load monitoring (NILM) technology infers the operational status of individual appliances within a household by analyzing aggregate load data. It is of great significance in supporting for energy consumption monitoring and demand response. Although the rapid development of artificial intelligence technology has promoted the application of deep learning algorithms in the field of NILM, this technology requires substantial storage space, computational power, and communication resources for practical applications, facing challenges such as high deployment difficulty, poor generalization capability, and weak privacy protection. To address these issues, this paper proposes an adaptive transfer mechanism for NILM models based on federated learning. Firstly, a global NILM model is constructed on the cloud server, and then lightweight NILM models are created using model pruning techniques and distributed to edge devices. Then, domain adaptation methods are adopted on these edge devices to enhance the adaptability of the local NILM models. Finally, based on the federated learning mechanism, local NILM model updates from multiple target domain users are aggregated to update the global NILM model, ensuring the security of user load data and privacy through the interaction of model parameters. By continuously repeating the above process of interaction between cloud and edge, effective migration of NILM models from cloud source domains to edge target domain users are achieved. Experimental results show that the proposed method not only enhances the generalization capability of the cloud-based global model but also achieves optimal disaggregation performance with local NILM models at the edge.

KEY WORDS: federated learning; non-intrusive load monitoring; adaptive transfer; model pruning

摘要: 非侵入式负荷监测 (non-intrusive load monitoring, NILM) 技术通过分析用户的总负荷数据推断内部各电器的运行情况, 对于能耗监测和需求响应具有重要的指导价值。虽然人工智能技术的快速发展推动了深度学习算法在 NILM 领域的应用, 但这项技术在实际应用中需要大量的存储空间、计算能力以及通信资源, 面临部署难度高、泛化能力差、隐私保护弱等多项挑战。为了解决上述问题, 本文提出了一种基于联邦学习的 NILM 模型自适应迁移方法。首先, 在云端服务器构建全局 NILM 模型, 通过模型剪枝技术构建轻量化的 NILM 模型并下发至边缘设备。然后, 在边缘设备采用领域自适应方法增强本地 NILM 模型的适应性。最后, 基于联邦学习机制聚合多个目标域用户的本地 NILM 模型更新全局 NILM 模型, 通过模型参数的交互来确保用户负荷的数据和隐私安全。不断重复上述云边交互过程, 实现 NILM 模型从云端源域至边缘端目标域用户的有效迁移与性能提升。根据 UK-DALE 和 REFIT 公开数据集的实验结果, 所提方法不仅能够提高云端全局 NILM 模型的泛化能力, 而且可以使边缘端本地 NILM 模型实现最优的分解性能。

关键词: 联邦学习; 非侵入式负荷监测; 自适应迁移; 模型剪枝

0 引言

电力工业是推动国家经济发展的关键基础产业。随着我国经济的持续高速发展和社会生活的日益现代化, 电力消费总量呈现出迅猛的增长态势, 为我国的能源供应带来了严峻挑战。面对这一形势, 我国积极构建以新能源为主体的新型电力系统, 推进需求侧精细化用能管理的应用, 挖掘需求

基金项目: 智能电网国家科技重大专项 2024ZD0802100 资助。

Supported by Smart Grid National Science and Technology Major Project 2024ZD0802100.

侧资源的灵活调度潜力,缓解电力供需矛盾并实现清洁能源的高效利用^{[1]-[2]}。

负荷监测是精细化用能管理的关键技术,其根据是否在用户内部安装传感器分为侵入式负荷监测(intrusive load monitoring, ILM)和非侵入式负荷监测(non-intrusive load monitoring, NILM),其中, NILM 因为具有维护成本低、实施难度小等优势,因此成为负荷监测的研究重点。NILM 技术最早由 MIT 的学者 Hart 于 20 世纪 80 年代提出^[3],旨在在不侵入用户内部的情况下,仅通过分析电力入口处获取的总功率信号就推断出场景中各个电器设备的工作状态及能耗功率。目前该领域的技术方案以数据驱动为主^[4],传统的 NILM 算法包括字典学习^[5]、隐马尔科夫模型^[6]、图信号处理^[7]等。尽管上述方案在负荷监测方面具有一定成效,但因模型的泛化能力有限,导致分解准确率下降的问题仍未得到有效解决。

近年来,得益于人工智能技术的迅猛发展,国内外学术界提出了多种多样的深度学习模型来解决 NILM 问题。Kelly 等^[8]率先于 2015 年将循环神经网络(recurrent neural network, RNN)和降噪自编码器(denoising autoencoder, DAE)应用于此,取得了优于传统方法的分解效果。随后, Zhang^[9]、Kaseliimi^[10]和 Lin^[11]相继探索并应用了卷积神经网络(convolutional neural network, CNN)、生成对抗网络(generative adversarial network, GAN)以及长短期记忆网络(long short-term memory, LSTM),显著增强了 NILM 模型的特征提取能力。考虑到上述模型均是单一任务模型,忽略了电器设备状态检测和功率估计任务之间的共性, Shin^[12]和 Chen^[13]提出了子任务门控网络(subtask gating network, SGN),设计两个 CNN 子网络分别推断设备的运行状态和耗电功率,整合两者输出得到比单任务模型更为精确的分解结果。针对居民用户,将上述 NILM 模型应用于实际系统中面临诸多挑战,主要归因于以下三个方面^[14]:首先,使用深度学习方法解决 NILM 问题的思路是为用户内部的每一个电器设备训练一个神经网络模型,鉴于居民用户内部通常拥有数十个电器设备,模型训练需要的内存和计算资源只有云端设备可以满足,因此导致模型在边缘设备的部署实施难度显著增加;其次,模型训练所需的大量数据依赖于云端和边缘设备的交互传输,这一过程不仅带来显著增加的通信成本,而且对用户的隐私安全构成潜在风险;最后,训练后的模型可能因用户电器设备的种类及数量

变化导致其性能逐渐下降,因此必须对模型进行自适应迁移以适应不同的家庭用电环境。

为此,多种轻量化方法如剪枝^{[15]-[16]}、张量分解^[16]、知识蒸馏^[17]、深度可分离卷积^{[18]-[19]}、神经架构搜索^[20]应用于 NILM 模型,极大地减少模型的参数量和计算量以实现模型在边缘设备的部署。联邦学习方法逐渐应用于 NILM 领域以确保用户的隐私和数据安全^{[21]-[25]},其主要利用边缘设备的标注数据训练本地模型,再上传参数到云端更新全局模型。此类方法的缺点主要有两个:一是边缘设备的标注数据难以获取,二是更新完成的全局模型不适用于跨域迁移。虽然迁移学习方法能够提升 NILM 模型对于特定场景的适应性^{[26]-[30]},但是在模型跨域迁移方面尚未有相关研究。截至目前,虽然上述部分方法成功运用轻量化神经网络模型完成 NILM 任务,但这些方法尚未针对 NILM 模型的功能特性,设计出更加适用于跨域迁移的联邦学习机制。此外,为了适应跨区域不同用户的家庭用电场景,部署于边缘设备的轻量化 NILM 模型通过领域自适应方法进行知识迁移的机制也需要进一步研究。

针对以上问题,本文提出了一种基于联邦学习的 NILM 模型自适应迁移方法,主要围绕文献[14]所提的 NILM 模型进行相关处理操作,主要贡献有以下三个方面:

1) 基于模型剪枝技术构建可部署于边缘设备的轻量化 NILM 模型,采用滤波器剪枝和神经元剪枝方法分别处理云端全局 NILM 模型的卷积层和全连接层,极大程度减少模型的参数规模和计算复杂度,提高云端和边缘端的传输效率。

2) 基于领域自适应方法将剪枝后的轻量化 NILM 模型部署至不同的边缘端用户,通过优化全连接层增强本地 NILM 模型在不同用户场景下的适应性。

3) 基于联邦学习机制聚合多个目标域用户的本地 NILM 模型更新全局 NILM 模型,通过模型参数的交互来确保用户负荷的数据和隐私安全,实现 NILM 模型从云端源域至边缘端目标域用户的有效迁移与性能提升。

本文组织如下:第 1 节概述了所提方法相关技术的基本原理;第 2 节提出了基于联邦学习的 NILM 模型自适应迁移方法,概述了云端全局 NILM 模型和边缘端本地 NILM 模型迭代更新机制;第 3 节对所提方法的有效性进行了实验验证;第 4 节总结本文工作并提出未来展望。

1 理论分析

1.1 NILM 技术

NILM 技术是一项用于细粒度监控电力能耗的技术,旨在通过分析建筑物入口处的电流和电压等数据来识别和分解各个电器设备的能耗,而无需为每个电器单独安装传感器或测量设备。假设一个建筑物内部有 n 个电器设备,在 t 时刻该建筑物的耗电总功率为 $P(t)$,各个电器设备的耗电功率为 $p_i(t)$ ($i=1,2,\dots,n$),则电力用户总耗电功率和各电器设备耗电功率的关系如 (1) 所示:

$$P(t) = \sum_{i=1}^n p_i(t) + e(t) \quad (1)$$

式中, $e(t)$ 表示电器设备的系统噪声和测量误差之和。由此可知, NILM 的主要任务是通过分解总功率 $P(t)$ 得到各个电器设备的功率 $p_i(t)$ 。

1.2 联邦学习

联邦学习是一项分布式机器学习技术,它允许多个参与方(例如用户设备)共同训练一个机器学习模型,而无需将本地数据上传到中央服务器。这项技术的核心在于能够在保护用户隐私和数据安全的前提下,利用分散的数据资源来提升模型性能。根据参与各方数据特征空间、样本空间的重叠关系,联邦学习可以分为三类:横向联邦学习、纵向联邦学习和联邦迁移学习。鉴于本文的研究目标是居民用户,这类用户呈现出相似的数据特征,但各用户之间的数据来源相对独立且重叠较少,因此本文的联邦学习方法具体指的是横向联邦学习方法。




图 1 联邦学习框架

Fig. 1 Framework of federated learning

经典联邦学习框架的训练过程如图 1 所示,具体可以概括为三个步骤:首先云端服务器基于预先存储的数据资源训练一个初始的全局模型,并将此全局模型参数传输至所有边缘端用户,然后各个边缘端用户利用本地数据训练一个本地模型,并将此本地模型参数回传至云端服务器,最后云端服务器聚合各边缘端用户的本地模型,从而构建泛化能力

更强的全局模型,整体提升模型性能和效果。

在联邦学习框架下,整个设计流程确保不触及用户隐私数据的传输。与传统数据传输相比,联邦学习允许模型在本地设备上训练,仅共享模型参数而非原始数据,从而减少了数据泄露的风险。在联邦学习中引入差分隐私可以通过向模型更新过程中添加噪声来实现,这样虽然可以有效保护隐私,但在一定程度上影响模型的准确性。因此,在实际应用中需要根据具体需求找到隐私保护与模型性能之间的最佳平衡点。理想状况下,该方法能够使模型的性能逼近甚至达到如同所有用户数据被集中用于训练时的效果。因此,它特别适合于 NILM 技术在电力系统的普及应用,既能保障数据安全与用户隐私,又可实现高效的能源管理和分析。

1.3 模型剪枝

模型剪枝是一种用于减少神经网络模型参数数量和计算量的技术,专为打造轻量级网络模型而设计^[31]。该技术通过识别和去除在训练过程中对模型性能影响较小的权重、连接或神经元来实现,具体分为针对卷积层的滤波器剪枝和全连接层的神经元剪枝。两种操作的结合可以显著减少模型的参数数量和计算量,提升模型在资源受限环境下的运行效率与性能。在执行过程中,模型剪枝主要包括以下四步: i) 训练模型至收敛; ii) 根据某项标准对模型参数的重要性进行评分; iii) 根据评分移除不重要的模型参数; iv) 对剪枝后的模型进行微调。由于剪枝可能导致模型性能下降,因此剪枝后的模型通常需要微调来恢复其性能。




图 2 模型剪枝原理描述

Fig. 2 Illustrative diagram of model pruning

一维卷积层采用单通道卷积操作，每个滤波器仅包含一个卷积核，因此可以表示为一个三维张量 (O, I, W) ，其中 O 和 I 分别代表输出和输入通道的数量，而 W 代表滤波器的尺寸。在已经训练好的模型中，不同的卷积滤波器对最终结果的重要性各不相同。基于此特性，移除重要性较低的滤波器可以优化模型结构，实现减少内存占用及加速计算的目的。卷积滤波器的重要性可以根据多种标准进行量化，例如矩阵的 $L_{2,1}$ 范数、 $L_{2,2}$ 范数等。在滤波器剪

枝中，若从第 l 层卷积层移除某个滤波器，则在后续的第 $l+1$ 层也要移除与之对应的输入通道，具体过程如图 2 (a) 所示。在移除最后一个卷积层中的滤波器后，展平处理的输出神经元数量将会改变，因此需要移除模型第一个全连接层内与被移除滤波器相关的权重参数。

在一维卷积神经网络模型中，全连接层的参数规模与输入序列的长度密切相关。随着输入序列长度的增加，全连接层中的参数量显著增加，占据了模型总参数量的较大比例。针对这一问题，神经元剪枝可以作为有效的解决方案来减少参数规模。与滤波器剪枝不同的是，神经元的重要性通常使用 L_1 范数或者 L_2 范数来量化评估。当从第 l 层全连接层移除一个神经元时，后续的全连接层则需要移除与之对应的权重，以确保网络结构的一致性和连贯性，具体过程如图 2 (b) 所示。这一过程不仅有助于减少网络参数数量，还能缩短推理时间，从而提升模型的整体效率。

1.4 领域自适应

领域自适应是一项特殊的迁移学习技术，旨在解决当训练数据（源领域）和测试数据（目标领域）来自不同分布时的模型泛化问题。具体来说，领域自适应技术试图通过利用源领域的标注数据和可能未标注的目标领域数据来调整或重新训练模型，使其更好地适应目标领域，特别适用于目标领域的带标签数据难以获取或者数量有限的情况。根据目标领域中标签数据的可用性，领域自适应可以细分为四类：1) 无监督领域自适应：只有源领域的带标签数据可用，而目标领域仅有未标记的数据；2) 有监督领域自适应：源领域和目标领域都有带标签的数据可用；3) 半监督领域自适应：源领域有带标签的数据，目标领域既有少量带标签的数据也有大量未标记的数据；4) 多源领域自适应：学习多个

带标签数据的源领域以适应目标领域。

除此之外，领域自适应还采用了多种不同的学习策略，包括特征对齐、实例加权、对抗性训练以及迁移学习等方法。考虑到 NILM 模型在边缘端部署过程中遇到的用户隐私安全、数据采集困难以及模型结构复杂等问题，本文采用无监督领域自适应方法，通过特征对齐的方式降低领域间的分布差异，提高模型在目标领域的适应性。

2 基于联邦学习的 NILM 模型自适应迁移方法

本节首先介绍了基于联邦学习的 NILM 模型自适应迁移方法的总体设计思路，然后分析了云端全局 NILM 模型轻量化及聚合机制，最后展示了边缘端本地 NILM 模型自适应迁移的过程。

2.1 总体思路

针对 NILM 任务，尽管学术界已经开发出多种深度神经网络模型，但这些模型尚未实现大规模的应用推广。阻碍其广泛应用的主要因素包括：隐私和安全问题导致了用户的担忧，模型本身的复杂性增加了实际部署的难度，以及有限的泛化能力影响了模型在不同场景中的一致性和可靠性。为了克服以上挑战，本文提出了一种基于联邦学习的 NILM 模型自适应迁移方法。

如图 3 所示，其主体主要由两部分构成：一个云端服务器和多个边缘设备。在该框架中，云端服务器扮演着协调者的角色，不仅将全局 NILM 模型进行剪枝处理部署至边缘设备，而且聚合多个用户的本地 NILM 模型参数更新优化全局 NILM 模型，通过不断交互实现全局 NILM 模型从云端源域至边缘端目标域用户的基础迁移。边缘设备则接收来自云端服务器的轻量化模型参数，在本地环境中结合存储的负荷数据进行自适应训练，更新本地 NILM 模型参数并上传至云端服务器。这一过程反复迭代直至训练结束，边缘设备采用最后一轮训练更新的本地模型完成 NILM 任务。该框架的关键优势在于，所有参与联邦学习的边缘设备能够在不上传自身负荷数据至云端服务器的前提下，借助云端服务器与边缘设备之间的协作机制，实现 NILM 模型的更新优化，确保了数据隐私的同时提升了模型性能。具体来说，基于联邦学习的 NILM 模型自适应迁移方法通过以下步骤实现 NILM 模型的协同训练：

步骤 1：云端服务器向边缘设备发送模型训练请求，得到用户的同意后创建由待训练用户构成的用户集合。

步骤 2: 云端服务器构建全局 NILM 模型并进行模型初始化, 基于预先存储的数据集训练并剪枝全局 NILM 模型得到轻量化 NILM 模型, 将该模型下发至用户集合中的所有边缘设备。

步骤 3: 云端服务器从预先存储的数据集中选择部分标注数据下发到用户集合中的所有边缘设备。

步骤 4: 边缘设备接收本地 NILM 模型, 利用下发的标注数据和本地存储的无标注数据进行本地 NILM 模型自适应迁移训练, 将训练完成的本地 NILM 模型上传至云端服务器。

步骤 5: 云端服务器接收各边缘设备上传的本地 NILM 模型, 利用联邦聚合算法更新全局 NILM 模型, 将其剪枝后再次下发至用户集合中的所有边缘设备。

步骤 6: 不断重复上述步骤 4 和步骤 5, 根据全局 NILM 模型测试效果判断模型聚合是否结束, 边缘设备接收最后一次剪枝完成的本地 NILM 模型, 自适应迁移得到最终的边缘端本地 NILM 模型。

由上述步骤可知, 联邦学习用于 NILM 模型训练的计算复杂度与模型的复杂性和参与训练的边缘设备数量有关, 通信开销通常由模型参数的数量、训练轮次、以及每轮参与更新的边缘设备数量决定, 收敛性则与模型的结构和用户数据的分布差异相关。




图 3 基于联邦学习的 NILM 模型自适应迁移框架

Fig. 3 Adaptive transfer framework for NILM model based on federated learning

在上述联邦学习过程中, 有两个细节需要进行详细说明。在步骤 2 中, 云端服务器需要从预先存储的数据集中筛选部分标注数据下发至边缘设备,

其目的是为各边缘设备提供自适应迁移所需的标签数据。根据 Kelly 等^[8]的研究, 云端服务器在数据集中随机选择 50% 的目标电器工作序列和未工作序列, 这样可以充分利用数据集的用户多样性, 有效提升模型的分解性能。

在 CNN 模型架构中, 卷积层可以提取到不同领域的通用特征, 而领域偏移主要反映在全连接层的特征表示中^[32]。这表明, 尽管输入数据的领域可能有所变化, 卷积层学到的特征具有广泛的适用性, 而全连接层的参数需要针对特定领域进行调整以优化性能。通常情况下, 云端服务器能够访问并下载已经标注的数据集, 这些数据源自匿名处理的用户信息。出于对用户隐私安全的考虑, 边缘设备仅被授权收集无标签的总负荷数据。因此本文所提出的模型架构中, 卷积层的训练过程专为云端服务器设计, 以充分利用其强大的计算能力和丰富的标签数据资源; 而全连接层的微调则在边缘设备上执行, 旨在适应本地数据特性的同时, 保护用户数据隐私。在步骤 3 中, 传输的模型参数包括卷积层和全连接层, 而在步骤 4-5 中, 传输的模型参数仅限于全连接层。

2.2 云端全局 NILM 模型轻量化及聚合方法

通常情况下, 采用深度学习解决 NILM 问题的方法是针对用户内部的每一个电器设备单独训练一个模型, 这意味着每个用户的边缘设备至少需要部署数十个 NILM 模型。鉴于传统的 NILM 模型参数量庞大且计算复杂度较高, 直接将模型部署到资源受限的边缘设备上是不切实际的。为了缓解由此带来的存储和计算压力, 模型轻量化成为必要之举, 即通过优化或压缩技术减少模型的资源消耗, 以适应边缘计算环境的需求。考虑到全局模型是联邦学习框架下轻量化模型的基础, 且云端服务器具备充足的计算能力和数据存储资源, 因此利用云端服务器来剪枝和聚合全局模型尤为适宜。




图 4 全局 NILM 模型结构

Fig. 4 Architecture of global NILM model

为验证所提方法的有效性, 本文采用了文献[14]所提的 NILM 模型, 其结构如图 4 所示。虽然该模型仅由两层特征提取卷积层和一层功率回归全连接层构成, 但其采用的序列到序列学习架构增加了模型的复杂性, 导致参数量和计算需求上升, 进而带来了较大的内存占用和较长的计算时间。为了改进这一状况, 本文针对该基础模型进行了两项剪枝措施, 以构建最终的轻量化 NILM 模型。首先是利用滤波器剪枝来精简模型的卷积层架构, 其次是采用神经元剪枝以减少全连接层的参数量及计算量。考虑到大幅减少参数量可能会导致模型性能下降, 因此选取合适的模型剪枝比例是剪枝方法构建轻量化模型的关键步骤。本文以文献[14]的算例为基础, 设置多个不同的模型剪枝比例, 测试并评估了模型的分解效果。

表 1 不同模型剪枝比例的模型大小与性能比较
Tab.1 Comparison of model size and performance with Different model pruning ratios

模型剪枝比例(%)	内存占用(MB)	浮点运算量(MFLOPs)	MAE(W)
0	2.47	1.12	14.9±4.8
10	2.23	1.02	15.0±5.2
30	1.74	0.79	15.1±5.7
50	1.24	0.57	15.3±6.2
70	0.74	0.34	15.6±6.5
90	0.25	0.12	16.3±7.8

如表 1 所示, 该算例设定平均绝对误差 (mean absolute error, MAE) 为衡量模型性能的关键指标, 内存占用反映参数数量的规模, 而浮点运算量则用以评估计算复杂度。当模型剪枝比例线性增加至 70% 时, 模型的参数数量和计算复杂度也随之近似线性减少, 但模型性能下降幅度较小, 然而当模型剪枝比例增加至 90% 时, 模型性能将大幅下降。因此本文将 NILM 模型的模型剪枝比例设定为 70%, 可以在确保模型性能仅有轻微下降的前提下, 显著减小模型的规模和复杂度。由上述结果可知, 基于模型剪枝的轻量化 NILM 模型不仅能够完成 NILM 任务, 同时还能满足边缘设备对 NILM 模型的轻量化要求。

本文的联邦聚合算法采用联邦平均 (federated averaging, FedAvg) 算法, 在各个边缘端用户将训练完成的模型参数上传至云端服务器后, 直接对模型同一位置的所有参数求平均值, 对聚合更新的全局模型进行剪枝后再下发至各个边缘端用户。假设用户集合中包含 M 个待训练用户, 用户 m 在边缘设备执行第 t 轮迭代后的参数为 ω_{t+1}^m , 服务器聚合的

参数则可以表示为:

$$\omega_{t+1} = \frac{1}{M} \sum_{m=1}^M \omega_{t+1}^m \quad (2)$$

式中, ω_{t+1} 表示聚合更新的全局模型参数。经过多轮迭代更新, FedAvg 算法充分利用了各用户领域的本地数据, 从而增强了全局模型的泛化能力。

2.3 边缘端本地 NILM 模型自适应迁移方法

领域偏移是指在机器学习中当训练数据 (源域) 和测试数据 (目标域) 的分布不一致时, 从源域训练得到的模型在应用到目标域时出现性能下降的现象。这种现象在 NILM 领域较为常见, 主要原因是不同用户在电器种类和使用习惯上存在显著的差异性。以剪枝后的轻量化模型为例, 尽管该模型在云端服务器的数据集上展现了优异的分解准确性, 但在部署至边缘设备后, 可能无法维持相同的性能水平。为了解决这一问题, 云端服务器将剪枝后的本地 NILM 模型传输至边缘设备后, 利用随机选择的有标签数据和用户本地的无标签数据对该模型进行无监督自适应迁移, 通过特征对齐的方式最小化源域和目标域之间的分布差异, 从而增强本地 NILM 模型在目标领域的适应性和准确性。

相关性对齐 (correlation alignment, CORAL) 是领域自适应技术中的一种关键方法, 旨在通过调整源域与目标域样本特征分布的相似性来缓解领域偏移现象^[33]。CORAL 方法的核心在于学习一个映射, 该映射不仅能够捕捉源域和目标域间的非线性关系, 而且能够在这一转换过程中构建出一个可微分的协方差矩阵对齐损失函数, 从而有效减小两个领域特征空间之间的统计差异。具体来说, CORAL 方法强调最小化源域和目标域层特征的二阶协方差之间的 Frobenius 范数距离, 确保经过非线性变换的特征在不同领域间的二阶统计特性具有更高的一致性。

通常情况下, 不同的用户可以视为不同的领域, 云端服务器上有标签数据集可以视作源域, 而各个边缘端用户的无标签数据集则构成独立的目标域。考虑到领域偏移主要反映于模型的全连接层, 所以特征对齐的目标是 NILM 模型的功率回归网络。当剪枝完成的本地模型被部署到边缘设备后, 本文采用 CORAL 方法实施本地 NILM 模型的自适应迁移过程, 其过程如图 5 所示。

假设源域和目标域的数据集分别表示为 $\mathcal{D}_S$ 和 $\mathcal{D}_T$, 功率回归网络的特征输出分别是 $\mathcal{F}_S$ 和 $\mathcal{F}_T$, 根据特征输出得到的协方差矩阵分别是 $\mathcal{C}_S$ 和 $\mathcal{C}_T$, CORAL 损失则被定义为源域特征和目标域特征的




图5 边缘端本地模型自适应迁移过程

Fig. 5 Adaptive transfer process of NILM model at the edge
二阶协方差距离，具体如下式所示：

$$\mathcal{L}_{\text{CORAL}} = \frac{1}{4\sigma^2} \|\mathcal{C}_S - \mathcal{C}_T\|_F^2 \quad (3)$$

式中， σ 表示特征的维度， $\|\cdot\|_F^2$ 表示矩阵 Frobenius 范数的平方。在固定卷积层后，将 CORAL 损失和功率回归损失按照一定比例组成总损失函数，微调全连接层即可完成本地模型的自适应迁移。假设 λ 为新损失的比例系数， $\mathcal{L}_R$ 为基于 L_2 范数的功率回归损失，总损失函数的公式如下所示：

$$\mathcal{L}_{\text{all}} = (1-\lambda)\mathcal{L}_R + \lambda \cdot \mathcal{L}_{\text{CORAL}} \quad (4)$$

上述损失作为约束条件，在微调过程中有效控制了源域和目标域之间的差异。通过联合优化功率回归损失和 CORAL 损失，本地 NILM 模型不仅能够提取目标电器设备的通用特征，而且通过自适应迁移显著提升了模型在目标域的分解性能。

3 实验分析

本节首先概述了仿真实验的相关设置，然后评估了联邦学习优化后的全局模型在负荷分解任务中的表现，最后验证了自适应迁移机制对本地模型负荷分解效果的提升。

3.1 实验设置

1) 软硬件环境：本文的硬件环境为 Intel(R) Core(TM) i5-10400F CPU @2.90GHz, 16GB DDR4 内存及 GeForce GTX 1650S(6GB 显存)的 64 位计算机；软件平台为 Windows-10 中文版操作系统，编辑语言环境基于 Python3.6.8(64 位)，云端和边缘端的深度学习框架分别是 TensorFlow 2.10 和 TensorFlow Lite 2.1，其中云端在预训练全局模型的过程中使用 GPU 进行硬件加速。

2) 数据集设置：本文选用公开的 UKDALE^[34] 和 REFIT^[35] 数据集来验证所提方法，聚焦于电热水壶、微波炉、电冰箱、洗碗机和洗衣机这五种常见的家用电器，数据的采样间隔为 8 秒。云端预先存储 UKDALE 数据集中 1 号和 2 号建筑物的所有数据作为训练数据，REFIT 数据集中 3 号和 5 号建筑物的所有数据作为测试数据，样本的时间跨度为数个月到数年不等。此外，边缘端用户选择 REFIT 数据集内的 9 号、15 号和 20 号建筑物作为研究对象。

3) 评价指标：由于本文的负荷分解结果是电器设备的功率，不涉及电器运行状态的辨识，因此选取 MAE 和信号总误差(signal aggregate error, SAE)作为模型性能的评价指标，其中 MAE 表示负荷功率估计值与实际值之间差异的平均绝对值，是衡量功率估计精度的一个直观标准，而 SAE 则量化了一定时间内功率估计累积误差的总量，用于评估电量估算的准确性。较小的 MAE 和 SAE 数值表明模型在分解任务中具有较高的精确度。为了充分展示所提方法在负荷分解方面的提升效果，本实验着重以评价指标的变化体现分解准确率的动态提升。

4) 参数设置：根据文献[14]中算例实验的设定，全局模型在预训练过程中的批量大小、学习率和迭代次数分别是 1024、0.001 和 50，本地模型的批量大小、学习率和迭代次数分别是 64、0.0005 和 10，两者均采用 ADAM 优化器来执行参数更新。为了避免过拟合现象，两者均引入提前停止策略作为正则化手段。具体来说，一旦验证性能不再提升，全局模型允许的最大等待次数为 5，本地模型为 3。其中，联邦学习的聚合频率是所有的本地模型训练后进行一次全局聚合，收敛条件的依据是全局模型前后参数的欧几里得距离，阈值为 0.005。此外，本地模型损失函数中的比例系数 λ 是影响模型性能的关键参数，可以通过云端的额外实验确定数值。具体实验过程如下：分别选择 UKDALE 数据集的 1 号和 2 号建筑物的数据作为源域数据，REFIT 数据集的 3 号和 5 号建筑物的数据作为目标域数据，洗衣机作为目标电器。经过四次交叉实验的测试得知，3 号建筑物的 MAE 达到最小值时对应的系数分别是 0.12 和 0.13，而 5 号建筑物的 MAE 达到最小值时对应的系数分别是 0.11 和 0.12，因此最终选取了四次实验的平均值 0.12 作为本地模型自适应损失函数的最佳比例系数。以 1 号和 3 号建筑物为例，不同比例系数下的 MAE 结果如图 A1 所示。

3.2 全局 NILM 模型监测结果与分析

为了验证所提算法在跨区域用户负荷分解方面的性能改进效果，本文设计并进行了对比实验、消融实验以及集中实验。在对比实验中，本文选用了三种基准方法与经过联邦学习后的最终全局模型进行对比分析，分别为 DAE^[8]，Seq2point^[9]以及多源领域自适应（multisource domain adaptation，MDA）^[36]方法。其中 DAE 和 Seq2point 模型是最常用的深度学习模型，对于不同用户均有稳定的分解准确率，而 MDA 方法是基于多源领域自适应机制对模型进行迁移的方法，在分解准确率和适应性具有更大优势。针对消融实验，本文则通过分别移除模型剪枝和联邦学习两个步骤，来考察这两个因素对全局 NILM 模型分解效能的影响。当取消模型剪枝（称为“无模型剪枝”）时，本地 NILM 模型将基于全局模型结构进行单一的自适应迁移；而当联邦学习环节被取消（称为“无联邦学习”）后，全局 NILM 模型则采用预训练后的初始模型。除上述方法外，为了深入挖掘联邦学习在提升模型性能方面的最大潜能，本文额外引入了来自边缘端的 9 号、15 号和 20 号三个用户的标注数据，连同 UK-DALE 数据集的 1 号和 2 号用户的标注数据对全局模型进行集中实验，并对其分解性能进行评估。所有方法均采用 MAE 和 SAE 两种评价指标，以衡量五种家用电器以及总体平均的分解精度。

经过测试，全局模型经过两轮迭代后就停止更新，并将剪枝后的轻量化模型下发到各边缘设备中。如表 2 所示，在对比实验中，最终全局模型在分解性能上超越了 Seq2point 和 DAE 方法，虽稍弱于 MDA 方法，但其 MAE 和 SAE 仅分别下降了 0.6%和 1.2%，这表明本章提出的算法在负荷分解方面的表现几乎达到了与最先进的 MDA 方法相同的水平。消融实验进一步显示，相较于 Seq2point 模型，无联邦学习方法的初始模型分解性能有轻微下降，MAE 和 SAE 分别下降了 0.6%和 0.9%。然而，联邦学习算法的应用显著提升了全局模型的性能，与初始全局模型相比，最终全局模型的分解性能大幅提升，MAE 和 SAE 分别提高 4.7%和 5.2%，甚至优于 Seq2point 模型，MAE 和 SAE 增幅分别是 4.1%和 4.3%。这一改进主要归功于联邦学习算法的有效性，它不仅能够利用来自 1 号和 2 号居民用户的标注数据来提取目标电器的特征，还能通过

表 2 不同模型的分解性能比较
Tab.2 Comparison of disaggregation performance across different models

电器	实验方法	MAE(W)	SAE(%)
电热 水壶	DAE	15.8	59.4
	Seq2point	14.7	55.6
	MDA	14.2	51.1
	最终全局模型	14.3	51.3
	无联邦学习	15.8	57.4
	无模型剪枝	14.0	50.2
	集中训练模型	14.1	50.8
微波 炉	DAE	14.0	53.8
	Seq2point	12.9	49.3
	MDA	12.4	48.3
	最终全局模型	12.5	49.2
	无联邦学习	13.8	53.5
	无模型剪枝	12.3	48.0
	集中训练模型	12.5	49.2
电冰 箱	DAE	33.5	27.9
	Seq2point	31.5	19.9
	MDA	30.8	19.4
	最终全局模型	30.9	19.8
	无联邦学习	30.7	19.6
	无模型剪枝	30.5	18.9
	集中训练模型	30.6	19.2
洗碗 机	DAE	15.4	24.4
	Seq2point	13.2	19.9
	MDA	11.8	19.3
	最终全局模型	11.9	19.7
	无联邦学习	12.8	19.2
	无模型剪枝	11.3	18.7
	集中训练模型	11.6	19.1
洗衣 机	DAE	13.6	32.1
	Seq2point	12.3	27.6
	MDA	11.2	24.7
	最终全局模型	11.2	25.2
	无联邦学习	11.8	24.4
	无模型剪枝	11.1	24.3
	集中训练模型	11.0	24.2
总体	DAE	18.5±8.5	39.5±16.0
	Seq2point	16.9±8.2	34.5±16.9
	MDA	16.1±8.3	32.6±15.8
	最终全局模型	16.2±8.3	33.0±15.9
	无联邦学习	17.0±7.8	34.8±19.0
	无模型剪枝	15.8±8.3	32.0±15.8
	集中训练模型	15.9±8.3	32.2±15.7

9 号、15 号和 20 号居民用户的未标注数据进行本地模型的自适应迁移,从而在云端服务器与边缘设备之间实现全局模型的持续迭代优化。尽管其性能尚未完全达到集中训练模型的水准,但已极为接近,证明了联邦学习可以使模型性能接近使用所有用户数据集中训练的效果。

值得注意的是,电冰箱的分解结果在采用联邦学习后出现了轻微下降,这主要是由于电冰箱频繁启停的工作模式对边缘端本地模型的自适应迁移过程产生了一定干扰。尽管如此,联邦学习的整体优势仍然显著,对于大多数电器而言,其达到的性能表现远超对比方法。除此之外,无模型剪枝情况下获得的全局模型分解结果优于集中训练得到的模型。这表明,取消模型剪枝的方法会更大程度地提升全局 NILM 模型的分解精度。然而,未经过轻量化处理的全局模型对边缘设备的存储资源及通信容量提出了较高要求,从而限制了其在实际部署应用中的可能性。由此可见,模型剪枝和联邦学习均是本文所提算法的关键组成部分,具体而言,模型剪枝不仅有助于实现模型的轻量化,还能促进其在边缘设备上的有效部署,而联邦学习在促进跨区域用户间的知识迁移方面具有不可替代的重要性。

3.3 本地 NILM 模型监测结果与分析

联邦学习利用 FedAvg 算法整合多个边缘设备上的本地模型参数,显著提升了全局模型的综合性能,并增强了其泛化能力。然而,这种方法仅能在平均意义上达到最优泛化性,并不能确保对每个边缘端用户均实现最佳性能。因此,在最终的全局模型经过剪枝处理并部署到边缘设备后,为了满足各个用户场景下的最优表现需求,仍需进行个性化的适配与优化调整。

为了验证本地 NILM 模型自适应迁移方法的有效性,本文针对三个边缘端用户(9 号、15 号和 20 号居民用户)对经过剪枝处理后的最终全局模型和经过自适应迁移后的本地模型进行了性能对比测试,其指标 MAE 和 SAE 的评价结果如图 A2-A4 所示。由此可知,各边缘端用户的本地 NILM 模型经过自适应迁移后,对目标电器的分解效果均有显著提升,其中 9 号居民用户目标电器的 MAE 和 SAE 平均降低 0.8W 和 3.3%,15 号居民用户平均降低 1.3W 和 2.0%,20 号居民用户平均降低 0.8W 和 1.3%。上述结果表明,本文提出的 CORAL 方法有效提升了本地 NILM 模型的分解性能,使得本地 NILM 模型更加适应于边缘端用户。

4 总结与展望

为了促进 NILM 技术的推广应用,本文提出了一种基于联邦学习的 NILM 模型自适应迁移方法,在云端服务器构建全局 NILM 模型并通过剪枝技术实现模型的轻量化,而且在边缘设备自适应迁移本地 NILM 模型,增强其对特定用户的适应性。此外,联邦学习算法的应用实现了全局模型和本地模型之间的动态交互和迭代改进,实现模型跨区迁移的同时确保了用户的隐私和数据安全。

对于本文所提方法,由于云端服务器通过有标签的训练数据不断更新全局模型的特征提取网络,因此在条件允许的情况下需要收集非目标用户或实验室典型场景的目标电器细粒度数据,未来将考虑引入数据增强技术生成大量仿真数据。除此之外,虽然现有的公开数据集为本文研究提供了数据资源,但它们的用户数量有限,可能不足以完全模拟真实的联邦学习环境,未来将引入更多的真实用户以及更多样化的数据源来验证联邦学习的有效性。

参考文献

- [1] 张智刚,康重庆.碳中和目标下构建新型电力系统的挑战与展望[J].中国电机工程学报,2022,42(8):2806-2818.
ZHANG Z, KANG C. Challenges and prospects for constructing the new-type power system towards a carbon neutrality future[J]. Proceedings of the CSEE, 2022, 42(8): 2806-2818(in Chinese).
- [2] 吴林林,陈琛,胡俊杰,等.支撑新能源电力系统灵活性需求的用户侧资源应用与关键技术[J].电网技术,2024,48(4):1435-1444.
WU L, CHEN Can, HU Junjie, et al. User side resource application and key technologies for flexibility demand of renewable energy power system[J]. Power System Technology, 2024, 48(4): 1435-1444(in Chinese).
- [3] HART G W. Nonintrusive appliance load monitoring[J]. Proceedings of the IEEE, 1992, 80(12): 1870-1891.
- [4] 袁博,葛少云,刘洪.压缩感知在非侵入式负荷监测中的应用展望[J].中国电机工程学报,2024,44(16):6416-6431.
YUAN B, GE S, LIU H. Application Prospect of Compressed Sensing in Non-intrusive Load Monitoring[J]. Proceedings of the CSEE, 2024, 44(16): 6416-6431(in Chinese).
- [5] KHODAYAR M, WANG J, WANG Z. Energy disaggregation via deep temporal dictionary learning[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 31(5): 1696-1709.
- [6] PARSON O, GHOSH S, WEAL M, et al. An unsupervised training method for non-intrusive appliance load monitoring[J]. Artificial Intelligence, 2014, 217: 1-19.
- [7] HE K, STANKOVIC L, LIAO J, et al. Non-intrusive load disaggregation using graph signal processing[J]. IEEE Transactions on Smart Grid, 2018, 9(3): 1739-1747.
- [8] KELLY J, KNOTTENBELT W. Neural nilm: Deep neural networks applied to energy disaggregation[C]. Proceedings of the 2nd ACM international conference on embedded systems for energy-efficient built environments, Seoul, South Korea, 2015.

- [9] ZHANG C, ZHONG M, WANG Z, et al. Sequence-to-point learning with neural networks for nonintrusive load monitoring[C]. Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence, LA, USA, 2018.
- [10] KASELIMI M, DOULAMIS N, VOULODIMOS A, et al. EnerGAN++: A Generative Adversarial Gated Recurrent Network for Robust Energy Disaggregation[J]. IEEE Open Journal of Signal Processing, 2021, 2: 1-16.
- [11] 林顺富, 詹银枫, 李毅, 等. 基于 CNN-BiLSTM 与 DTW 的非侵入式住宅负荷监测方法[J]. 电网技术, 2022, 46(5): 1973-1981.
LIN S, ZHAN Y, LI Yi, et al. Non-intrusive residential load monitoring method based on CNN-BiLSTM and DTW[J]. Power System Technology, 2022, 46(5): 1973-1981(in Chinese).
- [12] SHIN C, JOO S, YIM J, et al. Subtask gated networks for non-intrusive load monitoring[C]. Proceedings of the Thirty-Third AAAI Conference on Artificial Intelligence, Honolulu, USA, 2019.
- [13] CHEN K, ZHANG Y, WANG Q, et al. Scale- and context-aware convolutional non-intrusive load monitoring[J]. IEEE Transactions on Power Systems, 2020, 35(3): 2362-2373.
- [14] LUAN W, ZHANG R, LIU B, et al. Leveraging sequence-to-sequence learning for online non-intrusive load monitoring in edge device[J]. International Journal of Electrical Power and Energy Systems, 2023, 148: 1-9.
- [15] BARBER J, CUAYAHUITL H, ZHONG M, et al. Lightweight Non-Intrusive Load Monitoring Employing Pruned Sequence-to-Point Learning[C]. Proceedings of the 5th International Workshop on Non-Intrusive Load Monitoring, Virtual Event Japan, 2020.
- [16] KUKUNURI R, AGLAWA A, CHAUHAN J, et al. EdgeNILM: Towards NILM on Edge devices[C]. Proceedings of the 7th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation, Virtual Event Japan, 2020.
- [17] TANONI G, STANKOVIC L, STANKOVIC V, et al. Knowledge distillation for scalable nonintrusive load monitoring[J]. IEEE Transactions on Industrial Informatics, 2024, 20(3): 4710-4721.
- [18] ZHANG R, LUAN W, LIU B, et al. A lightweight neural network for energy disaggregation employing depthwise separable convolution[C]. 2021 IEEE Sustainable Power and Energy Conference, Nanjing, China, 2021.
- [19] 黎捷. 基于轻量化 CNN 和 kNN 的非侵入式负荷监测方法研究[D]. 南宁: 广西大学, 2023.
LI J. Research on non-intrusive load monitoring method based on lightweight CNN and KNN[D]. Nanning: Guangxi University, 2023.
- [20] LI Y, YAO R, QIN D, et al. Lightweight federated learning for on-device non-intrusive load monitoring[J]. IEEE Transactions on smart grid, 2024, early access.
- [21] 吴钉捷, 李晓露, 陆一鸣. 基于生成对抗网络和联邦学习的非侵入式负荷分解方法[J]. 电测与仪表, 2022, 59(06): 37-45.
WU D, LI X, LU Y. Non-intrusive load disaggregation method based on GAN and federated learning[J]. Electrical Measurement & Instrumentation, 2022, 59(06): 37-45(in Chinese).
- [22] ZHANG Y, TANG G, HUANG Q, et al. FedNILM: Applying Federated Learning to NILM Applications at the Edge[J]. IEEE Transactions on Green Communications and Networking, 2023, 7(2): 857-868.
- [23] Li, Y., Qin, D., Poor, H.V. et al. Introducing edge intelligence to smart meters via federated split learning[J]. Nature Communications 15, 9044 (2024).
- [24] Wang T, Dong Z. Blockchain-Based Clustered Federated Learning for Non-Intrusive Load Monitoring[J]. IEEE Transactions on Smart Grid, 2024, 15(2): 2348-2361.
- [25] Huang G, Zhou Z, Lei S, et al. Federated Unilateral-Mutual Learning for Privacy-Preserving Nonintrusive Load Monitoring[J]. IEEE Transactions on Instrumentation and Measurement, 2025, 74: 1-12.
- [26] INCECCO M D, SQUARTINI S, ZHONG M. Transfer Learning for Non-Intrusive Load Monitoring[J]. IEEE Transactions on Smart Grid, 2020, 11(2): 1419-1429.
- [27] LIN J, MA J, ZHU J, et al. Deep Domain Adaptation for Non-Intrusive Load Monitoring Based on a Knowledge Transfer Learning Network[J]. IEEE Transactions on Smart Grid, 2022, 13(1): 280-292.
- [28] 鲍光海, 黄逸欣. 基于 ResNeXt 网络和迁移学习的非侵入式负荷监测[J]. 电力系统自动化, 2023, 47(13): 110-120.
BAO G, HUANG Y. Non-intrusive Load Monitoring Based on ResNeXt Network and Transfer Learning[J]. Automation of Electric Power Systems, 2023, 47(13): 110-120(in Chinese).
- [29] SUN Y, FENG J, Yuan L, et al. Transfer Learning for Multiappliance-Task Nonintrusive Load Monitoring[J]. IEEE Transactions on Instrumentation and Measurement, 2025, 74: 1-12.
- [30] Li S, Su Z, Chen G, et al. Transferable Nonintrusive Load Monitoring in Smart Grids via Frequency-Division Fusion Scattering Time-Series Transformer[J]. IEEE Transactions on Industrial Informatics, 2025, early access.
- [31] DAVIS B, JOSE J G O, JONATHAN F, et al. What is the State of Neural Network Pruning[C]. Proceedings of Machine Learning and Systems, Austin, USA, 2020.
- [32] YOSINSKI J, CLUNE J, BENGIO Y, et al. How transferable are features in deep neural networks[C]. Proceedings of the 28th International Conference on Neural Information Processing Systems, Montreal, Canada, 2014.
- [33] SUN B, SAENKO K. Deep coral: Correlation alignment for deep domain adaptation[C]. European Conference on Computer Vision, Amsterdam, Netherlands, 2016.
- [34] KELLY J, KNOTTENBELT W. The UK-DALE dataset, domestic appliance-level electricity demand and whole-house demand from five UK homes[J]. Scientific Data, 2015, 2(1): 150007.
- [35] MURRAY D, STANKOVIC L, STANKOVIC V. An electrical load measurements dataset of United Kingdom households from a two-year longitudinal study[J]. Scientific Data, 2017, 4(1): 160122.
- [36] Luan W, Zhang R, Liu B, et al. Multisource Domain Adaptation for Nonintrusive Load Monitoring Through Data Distillation[J]. IEEE Transactions on Instrumentation and Measurement, 2025, 74: 1-11.



张睿祺

收稿日期: 2025-04-24。

作者简介:

张睿祺(1995), 男, 博士, 从事非侵入式负荷监测技术研究, E-mail: zhang_ruiqi@qq.com;

栾文鹏(1964), 男, 教授, 博士生导师, IEEE 高级会员, 从事电力系统规划与分析、电力数据分析、电力负荷监测、智能电网及物联网技术应用等方面研究, E-mail: wenpeng.luan@tju.edu.cn;