



计算机科学

Computer Science

ISSN 1002-137X, CN 50-1075/TP

《计算机科学》网络首发论文

题目：差分隐私结构化数据合成研究综述
作者：方贤进，罗晨悦
网络首发日期：2026-01-09
引用格式：方贤进，罗晨悦. 差分隐私结构化数据合成研究综述[J/OL]. 计算机科学.
<https://link.cnki.net/urlid/50.1075.tp.20260109.1420.006>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

差分隐私结构化数据合成研究综述

方贤进 罗晨悦

安徽理工大学计算机科学与工程学院 安徽 淮南 232001
(cyluo@aust.edu.cn)

摘要 数据开放共享是人工智能与大数据分析的基础需求，但其面临数据安全性与隐私保护问题，生成具有隐私保护的合成数据是该问题的一种路径。差分隐私（Differential Privacy, DP）因具备严格的数学可证明性，成为合成数据生成的研究热点。基于差分隐私的数据合成通过生成与原始数据分布近似且隐私可证的合成数据，成为兼顾数据效用性与安全性的实用性方案。大数据时代数据的多源、异构特点，导致数据合成方案众多，缺乏通用性的数据合成方法。本文系统的总结了结构化数据（表格数据、轨迹数据和图数据）的数据合成研究成果，提出了一种通用的差分隐私结构化数据合成的主流框架，给出了度量合成数据隐私性与效用性的多个维度和评价指标，总结了差分隐私结构化数据合成面临的挑战，并结合 AI 安全与人工智能生成内容（Artificial Intelligence Generated Content, AIGC）的发展背景，探讨了差分隐私数据合成技术在大语言模型训练、联邦学习等方面的应用潜力及未来研究方向。

关键词： 差分隐私；隐私保护；数据安全；数据合成；隐私计算

中图分类号 （TP309.2）

Survey on Differential Privacy Synthesis of Structured Data

Fang Xianjin, Luo Chenyue

School of Computer Science and Engineering, Anhui University of Science and Technology, Huainan Anhui
232001, China

Abstract Data sharing is essential for artificial intelligence and large-scale data analytics but is often constrained by privacy and security concerns. Privacy-preserving synthetic data has emerged as a promising solution, with Differential Privacy (DP) at the forefront due to its rigorous mathematical guarantees. DP-based synthesis generates datasets that closely approximate the original data distribution while providing formal privacy assurances, balancing utility and security. The multi-source and heterogeneous nature of real-world big data has led to numerous synthesis methods, yet a general-purpose approach is still lacking. This paper systematically reviews DP-based synthesis techniques for structured data, including tabular, trajectory, and graph data, and proposes a unified framework for differentially private structured data synthesis. We introduce multidimensional metrics for evaluating privacy and utility, identify key challenges, and highlight potential research directions. In addition, considering emerging AI safety concerns and the rapid rise of Artificial Intelligence Generated Content (AIGC), we discuss the application prospects of DP-based synthetic data in large language model training, federated learning, and related domains.

Keywords Differential privacy, Privacy preserving, Data security, Data synthesis, Privacy computing

1 引言

随着数字化转型加速，数据已成为社会经济发展的核心要素。然而，数据的开放共享与个人隐私保护之间存在着日益显著的张力。近年来，

频繁发生的个人数据泄露事件、AI 模型训练过程中的隐私泄露风险、以及大语言模型（如 GPT 系列）在训练数据记忆与还原方面暴露的安全隐患，都凸显出隐私保护在当代信息系统中的

基金项目：国家自然科学基金面上项目（No. 61572034）

This work was supported by the National Natural Science Foundations of China (No. 61572034).

通信作者：罗晨悦 (cyluo@aust.edu.cn)

极端重要性。《通用数据保护条例》（GDPR）等法律法规的出台，进一步强化了对数据处理的合规要求，使得原始数据的直接共享和使用面临巨大的法律与伦理挑战^[1]。

在此背景下，差分隐私（Differential Privacy, DP）成为了数据发布与合成研究中的主流技术之一^[2]。尤其是在 AI 与大模型安全领域，差分隐私不仅可用于保护训练数据中的个体信息，还能在模型推理阶段防止成员推断等攻击，为构建可信 AI 系统提供关键支持。合成数据技术是从原始数据生成保留其统计特性、不泄露敏感信息且能支撑公共服务并抵御对抗攻击的替代数据的

技术^[3]。在推荐系统中，推荐功能精确与否取决于能否捕捉到用户真实的交互行为，而交互数据的公开存在严重的隐私泄露问题，合成具有差分隐私保护的数据能够在为原始数据提供隐私保障的同时，最大化合成数据在推荐任务中的效用^[4]。医疗数据的共享对疾病预防与治疗极为重要，直接对原始数据进行研究无疑是暴露患者的隐私，生成具有差分隐私保护的合成数据是平衡二者的最佳方案。^[5]因此，差分隐私与合成数据技术的结合构成了当前保护数据隐私的有力手段（见图 1）。




图 1 公共服务中差分隐私数据合成技术的保护框架

Fig.1 The protection framework of differential privacy data synthesis technology in public services

然而，现有差分隐私数据合成方法多针对特定数据类型，通用性与扩展性不足，处理高维多模态结构化数据时存在效用下降及隐私 - 效用权衡难题，限制了其实际应用^[6-8]。因此，本文旨在系统梳理面向表格、轨迹与图数据等结构化数据的差分隐私合成方法，提出统一的处理框架与多维度评估体系，并结合当前 AI 安全与大模型隐私保

护的实际需求，探讨该领域未来的研究方向，为构建更安全、高效、合规的数据流通生态提供理论支撑与实践参考。

2 相关工作

随着数据价值的不断提升和隐私泄露事件的频繁发生，隐私保护技术已成为学术界与工业界共同关注的焦点。当前应对隐私泄露风险的方法

主要可分为传统隐私保护技术与现代密码学或差分隐私结合的两大类方法。

传统隐私保护方法包括数据匿名化（k-匿名^[9]、l-多样性^[10]、t-接近性^[11]等）、假名化、数据扰动和数据泛化等。这类方法在一定程度上可降低重识别风险，但普遍存在两个根本缺陷：一是缺乏严格的数学隐私保证，难以应对背景知识攻击与联结攻击；二是隐私保护强度与数据效用之间的平衡依赖经验设置，缺乏量化标准。例如，Netflix 推荐算法竞赛中的数据去匿名化事件表明，仅依靠传统匿名化无法抵御强背景知识下的身份推断。

近年来，以同态加密（Homomorphic Encryption, HE）^[12]和安全多方计算（Secure Multi-Party Computation, MPC）^[13]为代表的密码学方法在隐私保护中展现出强大潜力。同态加密允许在密文上直接进行计算，适用于云环境中隐私敏感的数据处理；安全多方计算则使得多个参与方能够在不暴露本地数据的前提下完成联合计算。然而，这些方法也存在明显局限：同态加密计算通信开销高、难适大规模高维数据；安全多方计算对网络延迟和参与方一致性要求高、工程复杂，限制了实际应用。这些都使其难以在实际数据发布与开放共享场景中的广泛应用。

相比之下，差分隐私通过随机噪声机制使输出结果对输入数据中任一记录的变化不敏感，从而防范各类背景知识攻击。与密码学方法相比，DP 不依赖特殊硬件或复杂协议，兼容现有统计与机器学习流程，在政府、医疗和互联网公司的数据发布中已有一系列成功实践，如美国人口普查和苹果 iOS 数据收集等^[14]。

在差分隐私的实现中，目前主流路径可分为交互式与非交互式两种。交互式方式通过加噪回答用户查询，但存在隐私预算快速消耗、响应效

率低的问题；而非交互式方式则通过生成与原始数据统计特征高度近似的合成数据，一次发布后可支持任意后续查询与分析，显著提高了数据的可用性和使用效率^[15]。因此，基于差分隐私的数据合成方法逐渐成为研究热点。

合成数据与原始数据记录级不同，但统计分布、关联结构等高度相似，可替代原始数据用于模型训练等（因数据分析多依赖群体模式）^[3]。差分隐私合成正是在此前提下，通过约束噪声大小和合成机制，在满足隐私保护的同时最大限度地维持这些宏观特征，成为当前平衡隐私与效用的可行路径。

综上所述，隐私保护技术向可证明、可量化、实用化发展，差分隐私数据合成技术因严格隐私保障、高效用、非交互式便利，已成为应对数据共享隐私挑战的重要解决方案。

3 差分隐私基础

差分隐私^[16]是 Dwork 等人于 2006 年针对统计数据库隐私泄露问题提出的隐私定义，其核心是对数据集的计算结果对单个记录的增删不敏感，使记录加入数据集的隐私泄露风险可控，攻击者从而无法通过结果获取准确个体信息。

3.1 差分隐私定义

设数据集 D 和 D' 为相邻数据集（即两者对称差集满足 $|D \Delta D'| \leq 1$ ，即最多相差一条记录）。对于隐私保护算法 A ，若其所有可能输出结果 $O \in \text{Range}(A)$ 均满足以下不等式，则称算法 A 满足 ϵ -差分隐私。

$$\Pr[A(D)=O] \leq e^\epsilon \cdot \Pr[A(D')=O] \quad (1)$$

其中， $\Pr[\bullet]$ 表示由算法 A 的随机性所决定的概率，同时反映隐私泄露的风险；隐私预算参数 ϵ 控制隐私保护强度， ϵ 越小，算法对相邻数据集的区分能力越弱，隐私保护程度越高^[2]。

3.2 全局敏感度

设函数 $f: D \rightarrow \mathbb{R}^d$ 表示从数据集 D 映射到

d 维实数空间的查询函数。该函数的全局敏感度 Δf 定义为：对于所有相邻数据集 D 和 D' （即两者仅相差一条记录），函数输出值的最大差异。

具体形式化表示为：

$$\Delta f = \max_{D, D'} \|f(D) - f(D')\|_p \quad (2)$$

其中， p 表示度量差异时采用的 L_p 范数（默认情况下使用 L_1 范数计算距离）。这里， d 代表查询结果的维度， $\mathbb{R}^d$ 为函数映射的目标实数空间 [16]。

3.3 差分隐私扰动机制

差分隐私的核心是随机算法的设计，其实现方法因问题而异。其中，拉普拉斯机制 (Laplace Mechanism) [16] 与指数机制 (Exponential Mechanism) [17] 是两种最基础的差分隐私保护实现机制。拉普拉斯机制适用于对数值型结果的隐私保护，指数机制则适用于非数值型结果。

3.3.1 拉普拉斯机制

设数据集 D 的查询函数为 $f: D \rightarrow \mathbb{R}^d$ ，其全局敏感度为 Δf （即相邻数据集 D 和 D' 上函数输出的最大 L_1 范数差异）。若随机噪声 Y 服从参数为 $b = \Delta f / \epsilon$ 的拉普拉斯分布（即 $Y = \text{Lap}(b)$ ），则随机算法

$$A(D) = f(D) + Y \quad (3)$$

满足 ϵ -差分隐私。

其中， Δf 控制噪声尺度，敏感度越大，所需噪声越强。

3.3.2 指数机制

设数据集 D 的输出为实体对象 $r \in \text{Range}$ ，其中 Range 表示算法可能的输出范围。定义得分函数 $q(D, r)$ 用于衡量输出 r 在数据集 D 上的效用评分，其全局敏感度为 Δq （即相邻数据集 D 和 D' 上函数值差异的最大绝对值）。若随机算法 M 按以下概率分布从 Range 中选择并输出 r ：

$$\Pr[M(D) = r] \propto \exp\left(\frac{\epsilon \cdot q(D, r)}{2\Delta q}\right) \quad (4)$$

则称算法 M 满足 ϵ -差分隐私。

3.4 近似差分隐私

标准的 ϵ -差分隐私（纯差分隐私）隐私保证严格，要求所有相邻数据集的输出概率比受 ϵ 约束，但复杂或高敏感度算法使用时需添加过量噪声，导致数据效用大幅下降甚至不可用。为平衡强隐私保护与算法的实用性，Dwork 等人引入 (ϵ, δ) -差分隐私，允许以极小概率 δ 打破 ϵ 隐私边界 [18]。

设 M 为一随机化算法， D 和 D' 为任意一对相邻数据集。若对于算法 M 的所有可能输出子集 $S \subseteq \text{Range}(M)$ ，都有：

$$\begin{aligned} \Pr[M(D) \in S] \\ \leq e^\epsilon \cdot \Pr[M(D') \in S] + \delta \end{aligned} \quad (5)$$

则称算法 M 满足 (ϵ, δ) -差分隐私。

3.5 其他差分隐私变体

标准差分隐私模型假设存在可信数据中心，负责收集原始数据、执行算法并发布结果，此模型被称为中心化差分隐私，但这一强信任假设在实际中并非总能成立。为适配更广泛复杂的场景，研究者们扩展出本地化差分隐私、集中式差分隐私及其强化版本等多种 DP 变体。

3.5.1 本地差分隐私

在中心化模型中，用户需要将原始数据无条件地信任给数据收集者。为消除对中心的信任依赖，本地差分隐私 (Local Differential Privacy, LDP) 被提出 [19]。在该模型下，用户在本地图扰自身数据后再发送给收集者，收集者仅收到满足差分隐私的噪声数据，无法获取用户的真实信息，大幅降低了隐私泄露风险。因此，LDP 适用于分布式系统、用户敏感度高的场景（如谷歌、苹果的用户行为数据收集）。

设存在 n 个用户，每个用户持有一条数据记录。若随机化算法 M 在所有用户本地端执行，并

且对于任意两条输入记录 x 和 x' （属于任意用户），以及所有可能的输出子集 $S \subseteq \text{Range}(M)$ ，均满足：

$$\Pr[M(x) \in S] \leq e^\epsilon \cdot \Pr[M(x') \in S] \quad (6)$$

则称算法 M 满足 ϵ -本地差分隐私。

3.5.2 集中式差分隐私

标准 (ϵ, δ) -DP 允许以小概率 δ 发生隐私保护“失败”，此概率可能被攻击者利用。为提供更严谨的、可量化的隐私损失上限，Dwork 和 Rothblum 提出了集中式差分隐私（Concentrated Differential Privacy, CDP）的概念^[20]。Rényi 散度是其主要的数学工具，它可对隐私损失随机变量进行更精细的刻画。

设 M 为一随机化算法， Z 为其隐私损失随机变量。若对于所有相邻数据集 D 和 D' ，该隐私损失随机变量满足以下条件，则称算法 M 满足 (α, ρ) -集中式差分隐私：

$$D_\alpha(M(D) \| M(D')) \leq \rho \quad (7)$$

其中，

$$D_\alpha(P \| Q) = \frac{1}{\alpha - 1} \log E_{x \sim Q} \left[\left(\frac{P(x)}{Q(x)} \right)^\alpha \right] \quad (8)$$

是阶为 α 的 Rényi 散度。 ρ 是衡量隐私损失的预算参数。

3.5.3 零-集中式差分隐私

集中式差分隐私虽然强大，但其隐私损失轮廓（Privacy Loss Profile）在某些极端查询下可能存在“重尾”现象，即存在极低概率发生巨大隐私泄露的风险。零-集中式差分隐私（zero-Concentrated Differential Privacy, zCDP）是 CDP 的一个强化变体，旨在通过约束隐私损失随机变量的均值和中位数均为零，来彻底消除这种重尾风险，提供更严格、更均匀的隐私保障^[20]。

一个随机化算法 M 满足 ρ -零-集中式差分隐私，若其对于所有相邻数据集 D 和 D' ，其隐私损

失随机变量 Z 是次高斯的，且满足：

$$E[Z] = 0 \text{ and } E[e^{\lambda Z}] \leq e^{\lambda^2 \rho / 2}, \forall \lambda \in \mathbb{R} \quad (9)$$

等价地，其矩生成函数被一个均值为零、方差为 ρ 的高斯分布（即 $N(0, \rho)$ ）的矩生成函数所控制。

3.6 不同差分隐私变体的联系与比较

各类差分隐私变体在理论基础上一脉相承，但在隐私度量方式、信任模型及噪声注入位置上存在差异。其关系可总结如下：

（1）信任假设：中心化 DP 依赖可信数据中心，本地 DP 完全去信任化，集中式与零集中式 DP 可视为对中心化 DP 的统计强化；

（2）隐私损失程度：从严格隐私界限的纯 DP 到容忍小概率泄露的近似 DP，再到用户端独立扰动的 LDP 以及分布级约束的 CDP 与 zCDP，隐私度量逐步细化；

（3）应用场景：LDP 更适合分布式数据收集与终端设备；CDP 与 zCDP 常用于深度学习与多次查询场景；纯 DP 仍在数据发布与统计分析中广泛采用。

因此，不同类型的 DP 催生了各异的研究方法与技术路径。中心化 DP 的研究多聚焦于如何在可信服务器上设计高效的合成算法，适合政府统计和集中数据分析。本地化 DP 的研究则侧重于设计低通信开销、高精度的本地扰动机制，适合用户数据采集与联邦学习，以缓解大规模噪声对数据效用的影响。而 CDP 与 zCDP 则更多应用于分析复杂算法（特别是深度学习、频繁组合查询）的累积隐私损失，使得在相同隐私保证下能够注入更少的噪声或在相同噪声下提供更强的隐私保证。理解这些变体的差异与联系，有助于更合理地选择适用于结构化数据合成的隐私保护策略。

为更清晰地展示不同差分隐私变体的特性与适用场景，下表对几种重要的变体进行了对比与

总结。

表 1 差分隐私不同变体比较

Table 1 Comparison of Different Variants of Differential Privacy

差分隐私变体	核心理念	优点	缺点
中心化差分隐私	存在一个可信的数据收集者，在数据汇聚后施加噪声	隐私保证严格，噪声相对较小，数据效用高	依赖对数据收集者的强信任假设，存在单点故障风险
本地差分隐私	用户在本地设备上对个人数据施加扰动后再上传，无需信任数据收集者	除了对数据收集者的信任依赖	为达到同等隐私级别所需噪声更大，数据效用通常低于中心化模型
集中式差分隐私	对隐私损失随机变量进行更严格的约束，要求其是“集中”的（次高斯）	提供了更精细的隐私损失分析，能以更小的总体隐私损失完成相同任务	定义和计算相对复杂，与普通 DP 的转换关系需谨慎处理
零-集中式差分隐私	CDP 的强化变体，要求隐私损失随机变量的均值为零，消除“重尾”风险	结合了 CDP 的紧致性和良好的组合性，隐私保证更鲁棒	与普通 DP 的转换不如 CDP 紧凑，对于某些极端查询的适应性可能稍弱

4 结构化数据的差分隐私合成

4.1 结构化数据及其发布的隐私泄露问题

结构化数据作为大数据时代的主要数据形态，依据其内在组织形式与语义特征，可主要划分为表格数据、轨迹数据与图数据三类。各类数据在应用中扮演不同角色，其隐私泄露后果也各有特点。

4.1.1 表格数据

以行列二维表形式组织，每行代表一个实体或记录，每列对应一个属性或特征，是实际应用中最常见的数据类型。它是金融交易、医疗健康记录、人口普查、教育管理等领域核心数据载体。例如，电子健康记录（EHR）包含患者的诊断、用药及病史信息，用于临床研究、流行病学

分析和保险定价。若此类数据不加保护直接发布，攻击者可通过链接攻击、背景知识推断等手段识别出特定个体，导致个人健康状况、财务状况等敏感信息泄露，引发歧视、诈骗等严重后果。

4.1.2 轨迹数据

记录个体或物体在连续时间戳下的空间位变化，形成时空序列，通常用于分析移动规律[21]。

一个轨迹在二维空间中可以表示为

$$p_0(x_0, y_0, t_0), p_1(x_1, y_1, t_1), \dots, p_n(x_n, y_n, t_n) \quad (10)$$

其中 p_i 表示时空中的一个轨迹点， x_i, y_i 表示点的坐标， t_i 表示当前点的时间， n 表示一条轨迹上点的总数（见图 2）。




图 2 二维空间中的轨迹数据表示

Fig.2 Trajectory data representation in two-dimensional space

轨迹数据常见于智能交通系统、基于位置的服务（LBS）、物流监控、无人机航迹等领域。例

如，网约车平台通过乘客的出行轨迹优化调度和路线规划。若轨迹数据泄露，可暴露个人的生活

习惯、工作地点、社交圈等，对个人安全构成直接威胁，例如物理跟踪、行为分析等。

4.1.3 图数据

由节点（实体）和边（关系）构成，用于表达复杂关联关系，如社交网络、论文引用网络、通信网络、知识图谱等^[22]（见图3）。




图3 数据结构中的图数据表示

Fig.3 Graph data representation in data structures

以社交网络为例，图结构可揭示用户的社区归属、影响力及社交习惯。一旦原始图数据泄露，不仅可能重识别用户身份，还可推断其敏感社会关系，损害个人声誉甚至被用于恶意舆论操控。

综上所述，三类数据均涉及高度敏感的个人及群体信息，其共享与发布必须在严格隐私保护下进行。差分隐私技术通过注入可控噪声，在保证数据可用性的同时，为上述数据发布提供了形式化且可证明的隐私保证。

4.2 差分隐私结构化数据合成框架

当前的差分隐私结构化数据合成方法多针对特定数据类型定制，普适性算法缺乏实际可行性，但大多方法遵循一个统一的三阶段主流框架（见图4），即“选择-压缩表示-合成”。这一框

架以差分隐私噪声注入为核心，通过在不同阶段引入隐私约束，使生成的合成数据在保持统计一致性的同时满足严格隐私保证^[23]。

4.2.1 选择阶段

选择阶段的目标是确定合成任务的统计表示空间，即从原始结构化数据中选择关键属性、依赖关系或查询集合。通过合理选择统计特征，可在保证隐私的前提下显著减少后续处理维度，降低噪声对效用的破坏。该阶段决定了后续噪声添加与预算分配的有效性，是差分隐私数据合成的起点。

4.2.2 压缩表示阶段

压缩表示阶段旨在用低维或聚合的统计结构刻画数据分布特性，并在此基础上施加差分隐私噪声。其核心思想是将高维原始数据转化为可控的统计表示，从而在“压缩”信息的同时控制隐私泄露范围。主要策略包括依据概率分布建模，或对数据进行降维与聚类至低维空间后再添加噪声。因此，压缩表示阶段决定了噪声施加的位置和强度，是平衡隐私与效用的关键环节。

4.2.3 合成阶段

合成阶段在含噪统计特征的基础上，重建与原始数据分布近似的合成数据集。该阶段的重点在于利用随机采样或生成模型恢复数据间的语义与结构一致性，并且可在合成后执行再采样、边缘约束或后验修正，以提高下游任务性能。最终得到的合成数据既保持了与原始数据相似的统计特征，又在形式上满足差分隐私约束，可直接用于后续的分析、建模或共享发布。




图4 差分隐私结构化数据合成的主流框架

Fig.4 Mainstream frameworks for synthetic structured data with differential privacy

因此,该框架中的每个阶段既可独立优化,也可协同设计形成端到端的差分隐私合成系统。其核心在于通过对数据特征的压缩和噪声扰动,在减少噪声影响的同时维持数据的宏观统计特性,实现了隐私与效用的平衡。

4.3 差分隐私表格数据合成

表格数据的差分隐私合成是研究最为广泛的领域,当前差分隐私表格数据的合成方法主要有基于概率图模型、Copula 函数、随机投影和查询这四种方法。

4.3.1 概率图模型

概率图模型 (Probabilistic graphical model, PGM) [24] 属于统计模型的一种类型,分为有向图和无向图两种 (见图 5、图 6),它们借助图形化的表示方式,对一组随机变量的联合概率分布进行操作与处理,其中选择联合分布的过程可以视为主流框架中的压缩表示,现主要包含三类概率图。

(1) 贝叶斯网络[25]: 以有向无环图建模因果关系,适合捕捉强方向性或层次结构的属性关系。通常先择高相关属性构建网络拓扑,再对条件概率表添加噪声得到隐私化联合分布。文献[26]基于指数机制迭代优化拓扑构建并生成合成数据。在文献[26]的基础上,文献[27]又提出了一种通过量化属性对联合分布与其乘积分布之间的差异,来降低敏感度的方法。

贝叶斯网络的优势在于能够较好刻画属性间的条件依赖结构,适用于中等维度的数据。然而,网络结构学习难度随维度上升而急剧增加,即使引入隐私优化策略,也难以在高维任务中保持效率。

(2) 马尔可夫随机场[28]: 此方法通过学习势函数来表示变量之间的相互作用,并以选择少量低阶团结构 (如最大生成树、受限大小的团) 来控制敏感性与噪声规模。文献[29]采样最大生成树

来选择边缘,并制定了一个优化问题来推断最终的数据分布。随后,文献[30]采用迭代算法约束最大团尺寸,通过高噪声节点优先连接避免大团生成来合成数据。

相比于贝叶斯网络,其优势体现在能捕捉更一般的、非方向性的复杂依赖,并且可通过限制团大小或引入正则化提高效率与私密性。

(3) 连接树[31]: 连接树利用了树结构的可分解性,使联合分布可由一阶与二阶边缘分布完全确定。在差分隐私合成数据中,其可以先选择高置信度边缘来构建树,之后在并行框架中对不同子图独立估计并加噪,相比于前两种方法在计算方面更自由。文献[32]在文献[30]的基础上提出了并行 PGM 方法,通过分团训练加速合成,解决了差分隐私数据合成中边缘选择不准确与隐私预算分配不最优的权衡问题,显著提升了合成数据的查询精度与生成效率。

基于连接树的方法兼顾了效率与效用,适用于高维或大规模数据,特别适合工业场景下的快速合成。然而,由于树结构的表达能力有限,其对高阶或全局依赖的刻画能力仍不足。

在提升效率的方法中,文献[33]提出逐渐更新法处理密集交互的大值域图形模型。文献[34]则考虑到现实数据的多表形式及外键约束,通过加入外键限制合成更真实数据。将差分隐私与密码学结合也是近些年的方向之一,文献[35]通过生成低维边缘分布、划分隐私预算实现个性化差分隐私,利用安全点积协议、门限 Paillier 加密及分布式拉普拉斯机制实现了低开销生成高效用多方合成数据集。

因此,基于概率图模型的方法依赖条件概率表、势函数和分布分解对属性显式建模,使合成数据具备满意的效用,是当前差分隐私表格数据合成中理论最成熟、应用最广泛的方向之一,但

其依然面临着对高维数据的结构学习难度大与模型对结构假设的依赖性高等问题。




图5 概率图模型中基于有向图的差分隐私数据合成方法

Fig.5 Differential Privacy Data Synthesis Method Based on Directed Graphs in Probabilistic Graphical Models




图6 概率图模型中基于无向图的差分隐私数据合成方法

Fig.6 Differential Privacy Data Synthesis Method Based on Undirected Graphs in Probabilistic Graphical Models

4.3.2 Copula 函数

在概率论与统计学中, Copula 是描述随机变量间相关性的联合累积分布函数。依据 Sklar 定理^[36], 其与单变量边缘分布结合可确定联合分布, 为合成数据采样提供基础, 并且能够灵活建模多种类型变量之间的相关性, 与概率图模型相比, 在数学结构上更为简洁。核心问题是要根据需求选择合适的函数, 目前主要有 Gaussian Copula^[37]和 vine Copula^[38]两种。

Gaussian Copula 具备封闭的表达式, 可由相关矩阵唯一确定, 并且可将不同类型的变量(连续、离散)转换到统一的 Copula 空间, 运行时间与属性数量成二次方, 但此方法的假设偏线性, 难以捕捉复杂的非线性依赖结构。文献[39]研究了两种方法, 最大似然法和 Kendall 的 τ 系数对相关矩阵进行估计, 接着对估计结果施加噪声扰动, 并在此基础上推导其高斯联结。文献[40]通过二进制转换处理混合属性并消除人工排序, 显著提升了高维数据合成效率与查询精度。文献[41]则是通过增强的傅里叶扰动方法整合差分隐私, 在 Gaussian Copula 的基础上增强了基于非参数 Copula 的合成数据生成模型。

vine Copula 通过将多元分布分解为多个二元 Copula“对”, 并采用自顶向下贪婪算法^[42]选择 Copula 以捕捉复杂依赖结构。其优势体现在可以捕捉非对称性、尾部依赖等复杂分布特性; 但由于结构选择与参数估计成本较高, 在高维场景下需要对结构进行截断或聚类以平衡效用与效率。文献[43]基于 vine Copula 的差分隐私设计了适用于多类型数据并保留数据效用的合成框架。近期, 文献[44]对估计的数据生成分布进行可控近似处理, 避免合成数据在下游预测任务中效用不佳。

与概率图模型类似, Copula 函数也具有较高

的数据效用。其适用于连续变量占比高、相关结构清晰的应用场景, 合成的数据具有较好的整体统计一致性。不过, 基于 Copula 函数的方法其属性数量呈二次方增长, 存在复杂性高的弊端。

4.3.3 随机投影

在基于随机投影的方法中, 表格数据被简化为矩阵模型, 通过对投影后的矩阵加噪实现数据合成, 并且在低维子空间上的投影可以理解为主流框架中的压缩表示形式部分。它体现了差分隐私中的“减少敏感度暴露维度”原则, 是一种“选择-压缩表示-合成”的典型策略。

文献[45]用稀疏 Johnson-Lindenstrauss 变换^[46]将用户表示投影到随机低维空间并添加高斯噪声。文献[47]将高维数据投影到低维空间并加高斯噪声, 有效保持来数据点间的欧氏距离, 提升了高维数据合成实用性。随后, 文献[48]注意到高维数据正交投影近乎服从高斯分布^[49], 于是在含噪投影上应用高斯生成模型获得合成数据。

随机投影的方法将敏感数据映射为低维表示, 大大降低了噪声强度, 适合高维稀疏数据, 如用户行为矩阵。但其难以捕捉原始数据底层结构, 且投影过程中会导致信息丢失, 合成数据效用不足。因此, 随机投影方法更适用于关注整体几何结构而非精细属性语义的场景, 如用户相似度分析、推荐系统等。

4.3.4 查询

基于查询的方法从任务出发, 目标是利用一组高频或高价值的统计查询, 在差分隐私的约束下生成一个能够回答这些查询的合成数据集。其本质是任务驱动的数据发布机制。

文献[50]是该方法的早期代表, 提出了乘法权重指数机制^[51], 结合乘法权重与指数机制提高私有数据集查询准确性以近似数据集分布。随后, 文献[52]将差分隐私查询发布转化为整数规划问题, 利用标准求解器避免传统方法处理指数级状

态的瓶颈。而文献[53]结合工作负载相关性与数据结构迭代选择最优查询、动态分配隐私预算，超越了现有机制性能。

此类方法围绕统计比例查询展开，生成合成数据以可靠响应特定查询，但因其聚焦预定义线性任务且缺乏通用性。并且其合成数据的效用性严重依赖于所设计的查询集，对多任务或复杂结构数据的支持有限。

4.3.5 小结

以上四种方法在实际应用中均面临通用性与特殊性的权衡。随机投影等算法提供量化效用但跨任务能力有限；概率图模型和 Copula 方法虽擅长捕捉复杂关联但依赖经验优化。因此，现有方法多依赖低阶分布，难处理高阶关联及混合属性预处理，亟需设计融合多类型属性特征的预处理策略。差分隐私表格数据合成方法的比较如表 2 所示。

表 2 差分隐私表格数据合成方法比较

Table 2 Comparison of Differential Privacy Methods for Tabular Data Synthesis				
方法类别	方法名称	核心方法/模型	优点	缺点
概率图模型	PrivBayes[26]	贝叶斯网络	开创性工作，能有效捕捉属性间因果关系	高维数据下网络结构学习困难，隐私预算消耗快
	Private-PGM[29]	马尔可夫随机场	通过迭代优化合成数据分布，查询精度高	计算开销大，适用于中低维数据集
	PrivMRF[30]	马尔可夫随机场	通过限制团大小控制敏感度，提升了效率	可能因限制团大小而丢失高阶关联信息
	ABSyn[32]	连接树/并行 PGM	引入并行训练，显著提升合成效率与查询精度	系统实现复杂度高，依赖并行计算环境
	PrivSyn[33]	逐渐更新法	能处理密集交互的大值域数据，通用性强	需更多实际场景验证
	PrivLava[34]	考虑外键的 PGM	首创考虑多表关系与外键约束，合成更真实数据	专注于关系型数据，对单表通用性未强调
Copula 函数	PDP-MVDS[35]	PGM + 密码学	实现多方垂直划分下的隐私保护数据合成	密码学操作引入额外计算与通信开销
	DPCopula[39]	Gaussian Copula	为连续数值型数据提供了一种有效的合成路径	对分类属性处理能力弱，高维时计算复杂
	Gaussian Copula(DP) [40]	Gaussian Copula	有效支持数值型与分类型混合数据，提升了实用性	二进制转换可能引入偏差，高维问题依旧存在
	DPNPC[41]	Gaussian Copula	对于非正态、非线性依赖结构的数据合成效果更好	方法较复杂，计算成本较高
	COPULA-SHIRLEY[43]	vine Copula	能建模非对称、尾部依赖等复杂关系	vine 结构选择与估计过程非常复杂，计算开销大
	TVineSynth[44]	截断 C-vine Copula	解决了完整 Vine Copula 在高维下的计算可行性问题	截断可能忽略一些长程依赖，存在信息损失
随机投影	PrivateProjection [45]	稀疏 Johnson-Lindenstrauss 变换	理论保证强，适用于高维用户数据	合成数据为低维投影，难以直接理解与使用
	DPPro[47]	随机投影	有效处理高维数据，保持点间欧氏距离	投影过程线性，难以捕捉非线性数据结构
	RON-Gauss[48]	正交随机投影	合成数据质量优于直接重构，提供了新思路	生成模型本身可能引入偏差，效用有上限
查询	MWEM[50]	乘法权重更新 + 指数机制	在中等维度和小查询集上表现优异，概念优美	高维数据下收敛慢，计算成本高
	Dual Query[52]	整数规划	能处理具有特定结构的高维数据	依赖于整数规划求解器，问题规模仍受限制
	AIM [53]	自适应迭代机制	显著提升了查询精度和效率	算法实现复杂，需要精心设计查询选择策略

4.4 差分隐私轨迹数据合成

轨迹数据由连续的时空点构成，具有明显的

时空依赖、非均匀性与隐私敏感性，目前的差分隐私轨迹数据合成的研究中主要有基于树和基于分布的两种方法。

4.4.1 树

基于树的方法根据原始数据构建噪声前缀树并合成轨迹数据，前缀树是将相同前缀的轨迹归至同一分支的分层结构，用于对时间序列数据进行编码压缩，其核心优势在于能有效编码轨迹的时序上下文。

文献[54]对原始前缀树进行多级位置泛化并添加拉普拉斯噪声，以噪声计数阈值或预定义树高为终止条件。文献[55]基于 n -gram 模型构建噪声前缀树，利用马尔可夫独立性假设估计位置转移概率，较文献[54]更能捕获时间依赖性且抗噪性更强。针对真实轨迹在地理空间中的非均匀性和多尺度特性，后续研究进行了重要改进，文献[56]则采用分层参考系统（HRS）、差分隐私模型选择、自适应剪枝、方向加权采样及归一化计数控敏感度，缓解了单一参考系统难处理速度变化的真实轨迹，致合成轨迹效用差且可扩展性不足的问题。文献[57]针对现有差分隐私层次分解算法依赖预定义递归深度 h 及部分稀疏向量技术（SVT）隐私保证错误的问题，提出了 PrivTree 算法，通过带衰减因子的有偏计数与拉普拉斯分布分析消除 h 依赖，提升了数据效用。随后，文献[58]针对车联网轨迹数据发布易泄露隐私与隐私预算分配不合理致数据可用性低的问题，提出了 DPTD 算法，引入时间维度划分轨迹平面，以 DBSCAN(Density-Based Spatial Clustering of Applications with Noise，具有噪声的基于密度的聚类方法)聚类与四叉树叶节点结合选质心以缓解稀疏性，平衡了隐私性与可用性。

由此可见，基于树的方法能够细致地建模连续位置间的时间依赖性，且对顺序数据具有普遍

适用性。然而，这类算法主要依赖树结构，通常难以保留轨迹长度等关键属性，且其可扩展性普遍受限，难以同时保持空间连续性与时间变化节奏。因此基于树的方法更适用于短轨迹、结构较规整的时空序列。

4.4.2 分布

基于分布的方法需先推导出原始数据关键属性的概率分布，通过扰动采样后的分布生成合成轨迹数据，该类方法通过利用领域知识，能生成保真度更高的轨迹。其类似于表格数据合成的概率图模型，推导的概率分布属于主流框架中的压缩表示。

文献[59]将强相关属性划分为相交集合并构建对应分布以考虑属性间相互作用。随后，文献[60]将轨迹解构为空间、起止点、转移概率和路线长度四大特征，通过噪声扰动分布采样重建合成数据。在此基础上，文献[61]和[62]沿用文献[59]的框架，前者加确定性约束抵御贝叶斯推断，后者通过贝叶斯优化分配预算最小化误差。而文献[63]提出了 PrivTrace 算法，采用密度敏感两层离散化、依噪声与置信度自适应选一阶/二阶马尔可夫模型和优化估计行程分布，解决了现有差分隐私轨迹合成方法的信息-噪声失衡，及行程分布偏差、空间离散化未用细粒度信息致合成轨迹质量低的问题。近期，文献[64]提出了时空轨迹泛化发布方案 STG-DP，结合 DBSCAN 和 AP 聚类（Affinity Propagation,近邻传播）算法分别生成合成与真实聚类中心以提升数据效用，解决了现有轨迹数据发布方案忽略时空相关性、与数据密度分布、噪声扰动缺乏适应性，导致隐私保护与数据效用难以平衡的问题。针对当前无人机的位置隐私，文献[65]提出了基于差分隐私的位置混淆方案，通过广播混淆位置而非真实位置实现隐私保护，同时将真实位置加密嵌入广播信息以应对违

规场景，对无人机三维位置采用了不同噪声模型独立保护，以降低被还原风险。

虽然基于分布的方法通过利用域中的特定特征生成数据效用较高的轨迹，但需要预定义特征，容易遗漏高阶时空依赖，且在严格隐私设置下存在不足，由于总隐私预算被分割为多份，噪声随预算减少而显著增加，导致各分量误差较大。综合来看，基于分布的方法适用于大样本、

多用户、整体统计结构为主的轨迹发布场景，如交通流量分析。

4.4.3 小结

目前隐私保护的轨迹数据合成方法主要存在两大挑战：一是轨迹数据实时性要求迫切，需构建实时差分隐私轨迹合成算法；二是无人机等设备的普及使轨迹数据从二维扩展至三维空间，数据格式的变化带新的挑战。差分隐私轨迹数据合成方法的比较如表 3 所示。

表 3 差分隐私轨迹数据合成方法比较

Table 3 Comparison of Differential Privacy Methods for Trajectory Data Synthesis				
方法类别	方法名称	核心方法/模型	优点	缺点
树	STM[54]	前缀树 + 位置泛化	结构简单，易于实现	泛化导致信息损失，合成轨迹效用较低
	VL-NGM [55]	前缀树 + n-gram 模型	能建模连续位置间的转移概率	受限于树结构，轨迹长度等属性难保留
	DPT[56]	分层参考系统（HRS）	缓解了单一参考系统对速度变化适应性差的问题	系统复杂，可扩展性仍面临挑战
	PrivTree[57]	自适应层次分解	数据效用高，无需预设树高，自适应能力强	针对静态数据，对实时流式轨迹支持有限
	DPTD[58]	四叉树 + 时空划分	针对车联网轨迹稀疏性问题，平衡了隐私与可用性	专门针对车联网场景，通用性待验证
分布	Sanitization Model[59]	属性相交集合分布	考虑了属性间的相互作用，效用较高	严格隐私设置下，分割预算导致各分量噪声大
	DP-Star[60]	轨迹四特征分解模型	特征划分清晰，合成轨迹覆盖多个关键方面	特征间的关联可能被削弱
	AdaTrace[61]	加约束的分布模型	在保护隐私的同时增强了对抗攻击的鲁棒性	约束设计依赖先验知识
	OptaTrace[62]	分布模型+贝叶斯优化	优化了预算分配，最小化总体误差	优化过程本身有计算开销
	PrivTrace[63]	自适应马尔可夫模型	解决了信息-噪声失衡问题	模型选择策略复杂，参数调优要求高
	STG-DP[64]	时空聚类生成模型	考虑了时空相关性与数据密度分布	聚类算法对参数敏感，影响合成效果

4.5 差分隐私图数据合成

图数据具有整体结构复杂、强关联性、敏感社会关系丰富等特点，目前差分隐私保护图数据合成的方法主要有边-差分隐私与点-差分隐私两种（见图 7），本文主要讨论边-差分隐私方法，因

为点-差分隐私在极端情况下可能因中心节点连接多条边、敏感度较大，扰动时会对合成图的精度和数据效用造成较大影响。




图7 差分隐私图数据保护的两种类型（以社交网络为例）

Fig.7 Two types of differential privacy for graph data protection(taking social networks as an example)

早期的差分隐私图数据合成方法主要包括随机 Kronecker 图模型^[66]、DK-图模型^[67]、指数随机图模型^[68]和层次随机图模型^[69]，但这些方法存在无法捕获真实结构、敏感度大及处理图规模小等问题，且它们仅关注图本身的结构而忽略了节点属性。因此，本节聚焦于当前边-差分隐私下最流行的基于属性图模型（AGM）^[70]的合成方法展开讨论。

4.5.1 属性图模型

属性图模型基于节点属性及相关性对图结构进行条件采样（如社交属性），通过生成模型捕获图的结构属性，对采样分布扰动合成图数据，该过程完全符合主流框架中的选择、压缩表示与合成三个步骤。

文献[71]引入 TriCycLe 结构模型捕捉度分布与聚类系数，通过边缘截断技术处理属性-边相关性的高敏感度问题，实现了图结构与属性关联。之后，文献[72]提出社区保留属性社交图生成模型，在保护边隐私的同时保留原图社区结构、度分布和聚类系数，但存在隐私预算消耗快、计算复杂度高的问题。而文献[73]设计了基于邻接度的隐私衡量算法，结合差分隐私、聚类和随机化等算法，缓解了当前社交网络图谱数据敏感、规模大的问题。文献[74]则针对现有差分隐私图合成方

法引入过多噪声、或图编码时信息丢失严重的问题，创新地提出了 PrivGraph，通过差分隐私的社区划分，生成满足边缘差分隐私且效用高的合成图，解决了小社区无法保留的问题。而文献[75]构建了社交关系指数对链接分层聚类，动态分配隐私预算并利用指数机制并量化了非数值社交关系影响。在最新的研究中，文献[76]提出了敏感感知的个性化边缘差分隐私模型，允许自定义社交连接敏感度，通过动态预算分配和隐私阈值优化，解决传统方法忽视个体隐私偏好差异的问题。对于有向图，文献[77]提出 PrivAGM 框架，通过融合差分隐私、安全多方计算与生成图模型，创新采用选择性 MPC 的邻居列表保护机制、隐式边裁剪技术控制特征敏感度、改进的有向 Chung-Lu 模型^[78]和有向属性图模型（dAGM）捕捉边方向性，实现了差分隐私的有向属性图模型的安全构建。

然而，实际生活中产生的大多数图数据为流式图，即具有时间戳的动态变化图。因此，如何对实时改变的图数据进行保护和合成成为目前主要的研究方向。文献[79]提出了首个考虑时序动态的差分隐私流图合成框架 PSGraph，通过自适应隐私预算分配和跨时间戳信息聚合，解决了现有静

态图方法在流图场景下无法有效利用时间动态特性而导致的隐私预算浪费和合成数据效用低下的问题。随后，文献[80]提出了首个在连续监控场景下发布满足差分隐私的加权图序列的方法 SwgDP，通过节点自适应采样、动态权重优化、基于预测的社区检测和加权图生成等组件，解决了现有静态无权图方法无法有效处理动态加权图发布所面临的隐私预算分配、结构保持和边权重扰动三大挑战。

因此，属性图模型方法的优势在于能够同时保持节点属性与拓扑结构之间的相关性，对社交网络、通信网络等真实图具有良好的适配性，同时模型参数较少、结构清晰，可解释性强。然而，其面临的主要挑战在于图的度分布、社区结

构等统计量通常高度敏感，导致噪声易被放大。总体而言，属性图模型更适用于结构特征明确且较为稳定的图数据场景，例如社交网络或团队协作网络。

4.5.2 小结

综上所述，目前差分隐私图数据合成仍缺乏通用的方案，每种方法有其特定的隐私性和适用场景，但近些年基于属性图模型的方法逐渐成为研究首选。现有研究大多集中于边隐私保护以保护用户关系，但节点级隐私保护研究较少，因选择和拟合图模型难度较大，因此解决该挑战依旧是一个开放问题。差分隐私图数据合成方法的比较如表 4 所示。

表 4 差分隐私图数据合成方法比较

Table 4 Comparison of Differential Privacy Methods for Graph Data Synthesis				
方法类别	方法名称	核心方法/模型	优点	缺点
属性图方法	TriCycLe[71]	标准属性图模型	首次在 AGM 中同时关注图结构与属性关联	对大规模图扩展性有限
	C-AGM[72]	社区保留生成模型	社区结构保持效果好，适用于社交网络分析	隐私预算消耗快，计算复杂度高
	PBCN[73]	邻接度隐私衡量算法	针对社交网络大规模敏感数据，提供了可行方案	方法较复杂，实用性待深入验证
	PrivGraph[74]	差分隐私社区划分	效用高，能有效保留图的社区结构信息	社区划分质量对最终效果影响大
	EPDP[75]	个性化指数机制	考虑个体隐私偏好差异，保护更人性化	非数值关系量化存在主观性
	SPEDP[76]	敏感感知个性化模型	精细化隐私保护，适应不同用户的敏感度需求	需要用户参与设置，可能影响用户体验
	PrivAGM[77]	有向 AGM+选择性 MPC	首个实现差分隐私有向属性图安全构建的框架	密码学操作带来额外开销，系统复杂
	PSGraph[79]	时序动态合成框架	首个考虑时序动态的 DP 流图合成框架，解决静态方法预算浪费问题	对快速变化的流图适应性待提升
	SwgDP[80]	动态加权图生成	首个在连续监控下发布 DP 加权图序列的方法，解决权重扰动挑战	为加权图设计，组件多，系统复杂

当前差分隐私结构化数据合成的方法分类如 表 5 所示。

表 5 差分隐私结构化数据合成方法分类

Table 5 Classification of Differential Privacy Synthetic Data Generation Methods for Structured Data				
数据类型	数据特征	方法/模型	工具	参考文献
表格数据	分类属性	概率图模型	贝叶斯网络	[26] [27]
			马尔可夫场	[29] [30]

		其他	[32] [33] [34] [35]
		查询	/ [50] [52] [53]
数值属性	Copula 函数	Gaussian Copula	[39] [40] [41]
		vine Copula	[43] [44]
	随机投影	/	[45] [47] [48]
轨迹数据	时间序列数据	树	[54] [55] [56] [57] [58]
		分布	[59] [60] [61] [62] [63] [64] [65]
图数据	带属性的图	属性图模型	[71] [72] [73] [74] [75]
			[76] [77]
	流式图		/ [79] [80]

4.6 非结构化数据合成探索

本文重点讨论了结构化数据（表格、轨迹和图）的差分隐私数据合成方法。然而，在大数据与生成式人工智能时代，文本、图像、音频等非结构化数据也蕴藏着巨大的价值。因此，对其隐私保护的数据合成需求日益增长。尽管非结构化数据的合成面临着极高维度和复杂语义特征等挑战，但研究人员目前已经开始探索将差分隐私与深度生成模型结合，证明了这种方法的可行性。

4.6.1 文本数据合成

文本数据由离散符号序列构成，其高维度和语义敏感性给差分隐私数据合成带来了巨大挑战。随着自然语言处理技术的发展，使用差分隐私随机梯度下降法（DP-SGD）^[81]训练递归神经网络（RNN）或 Transformer 模型已成为主流。文献[82]使用 DP-SGD 训练模型来生成满足差分隐私的文本。这种方法可以生成更连贯的句子，但在严格的隐私预算下，模型性能显著下降，难以保证生成文本的质量和多样性。随后，一些研究转向在文本嵌入空间中应用差分隐私扰动。文献[83]提出首先在嵌入空间中保证差分隐私，然后基于扰动嵌入生成文本。最近，针对大型语言模型（LLMs）的隐私保护微调和合成数据生成也成为热门话题^[84]，旨在利用 LLMs 强大的生成能

力，同时通过 DP-SGD 等技术防止其从原始训练数据中记忆和泄露敏感信息。

4.6.2 图像数据合成

图像数据中像素之间的相关性是复杂的，人类视觉系统对图像质量的变化非常敏感。差分隐私图像合成的核心是在尽可能保持图像视觉可用性的同时，通过添加噪声来保护个人隐私。文献[85]通过训练生成对抗网络（GANs）生成人脸图像，获得了视觉上可识别的人脸图像，既能用于模型训练，同时保护训练集中个体的隐私。另一方面，文献[86]探讨了基于差分隐私的扩散模型，展示了它们在复杂图像数据集上合成高质量图像的潜力。

4.6.3 小结

综上所述，基于差分隐私的非结构化数据合成已经成为一个充满活力和快速发展的研究领域。它结合了差分隐私的严格保证和生成式人工智能的强大功能，为安全共享非结构化数据提供了新的可能性。然而，隐私和效用之间的权衡，高计算成本，以及缺乏评估生成数据质量的标准指标等，都需要在未来的研究中取得突破。因此，差分隐私结构化数据合成与非结构化数据合成的比较如表 6 所示。

表 6 差分隐私结构化数据合成与非结构化数据合成比较

Table 6 Comparison of Differential Privacy in Structured Data Synthesis and Unstructured Data Synthesis

维度	结构化数据合成（表格/轨迹/图）	非结构化数据合成（文本/图像/音频）
数据特征	低维到中高维、多属性字段、明确的行/列或节点/边结构；常含混合类型	超高维、连续或离散符号序列、复杂语义与空间关联
常用建模方法	概率图模型、Copula、随机投影、查询、前缀树、属性图模型等	深度生成模型（GAN/VAEs/扩散）
差分隐私嵌入点	统计量/边缘分布或模型参数处直接加噪；结构学习阶段（指数机制）或参数层（拉普拉斯/高斯）	训练阶段（DP-SGD）嵌入或隐空间加噪；输出后处理
主要挑战	高维/混合属性下噪声放大、高价依赖难以保留、流式/动态数据的预算分配	在保持语义一致性同时满足 DP 极难；DP-SGD 下模型能力大幅下降
主要应用场景	人口普查数据发布、医疗数据共享、轨迹分析、社交关系分析	大语言模型训练、多模态数据处理
二者的联系	1、两者核心都是在严格的隐私预算(ϵ)约束下，通过优化算法和噪声机制，尽可能维持数据的可用性 2、本文的主流框架同样适用于非结构化数据，例如在文本合成中“选择”关键词义特征，“压缩表示”为嵌入向量，最后“合成”新文本 3、核心目的都是让合成数据的统计分布与下游任务的结果与原始数据相似	

5 合成数据的隐私性与效用性评估

合成数据的生成旨在提供一种既保护隐私又保持数据实用性的替代方案。对其质量的评估需从隐私性与效用性两个维度展开，并深入理解二者之间的内在权衡关系。

5.1 合成数据的隐私性度量

合成数据通过差分隐私机制对原始数据处理后生成，其隐私性根植于差分隐私严格的数学定义。评估其隐私性，即评估其抵御各种隐私攻击的能力，确保攻击者无法从发布的数据中推断出特定个体的敏感信息。

5.1.1 隐私预算

差分隐私通过隐私预算参数 ϵ 量化隐私保护程度。 ϵ 值越小，代表提供的隐私保护越强。合成数据的隐私性首先可通过其满足的差分隐私定义及所采用的隐私预算大小进行直接度量。这是其隐私性的形式化保证基础。关于隐私预算的分配问题，近些年的研究提出许多个性化差分隐私机制以避免预算浪费并最大化数据效用。文献[87]通过基于查询函数、数据分布和隐私设置自适应选择噪声生成算法及参数，设计了多轮效用感知采样机制重用浪费的预算，在严格隐私保护下显著提

升了数据效用。若将不同阶段预算组合视为优化问题，进化计算是一种有效的优化手段，文献[88]将差分隐私 k-means 算法的预算分配转化为组合优化问题，通过遗传算法优化多轮迭代预算序列并确保算法收敛，提升了聚类结果可用性，但遗传算法需针对不同任务和场景设计不同适应度函数。

除了形式化定义，在实际评估中，研究者还采用多种指标来量化隐私保护强度。

5.1.2 后验概率

基于后验概率的隐私度量通过数据合成前后攻击者对特定知识的确信概率变化量化隐私保护程度，攻击者确信概率变化越小则隐私性越强[89]。其核心是衡量攻击者在观察到合成数据后，对某条原始记录属于特定个体的确信程度的变化。该度量基于贝叶斯推断，后验概率计算公式为：

$$P(\text{个体} = i | \text{合成数据}) = \frac{P(\text{个体} = i | \text{合成数据}) \cdot P(\text{个体} = i)}{P(\text{合成数据})} \quad (11)$$

隐私保护强度可通过比较先验概率 $P(\text{个体} = i)$ 与后验概率的差异来评估。文献[90]通过构建隐私与效用权衡模型，揭示 ϵ 与隐私损

失、数据可用性的数学关系，给出了不同场景下选择最优 ε 的方法，但该方法依赖数据分布，实际场景中可能因数据不满足假设分布而影响度量效果。

5.1.3 区间估算

基于区间估算的方法通过度量真实值与扰动值的距离衡量隐私保护强度。该方法通过构造真实值与扰动后值之间的置信区间来评估隐私保护强度。区间越宽，隐私保护越强。以扰动后的均值 $\hat{\mu}$ 为例，其 $1-\alpha$ 置信区间可表示为：

$$CI = \left[\hat{\mu} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \hat{\mu} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right] \quad (12)$$

其中 σ 是噪声的标准差， $z_{\alpha/2}$ 是标准正态分布的上 $\alpha/2$ 分位数。文献[91]提出用置信区间宽度与置信水平替代传统单一的 ε 参数量化隐私，通过区间估计理论建立隐私与数据效用的权衡模型，但其参数设置仍需主观判断。

5.1.4 信息熵

基于熵的隐私度量利用信息熵理论量化隐私保护程度与泄露风险，核心是结合隐私信息不确

定性与信息熵特性实现量化分析。信息熵用于衡量系统中不确定性的。熵值越高，表示攻击者推断出真实信息的难度越大，隐私保护越强。

其基本形式（Shannon 熵）为：

$$H(X) = -\sum_{x \in \mathcal{X}} P(x) \log P(x) \quad (13)$$

对于轨迹数据等特定类型，可使用位置熵

（Location Entropy）

$$H(L) = -\sum P(l) \log P(l) \quad (14)$$

来衡量位置的不确定性，其中 $P(l)$ 是位置 l 出现的概率^[92]。文献[93]基于 Shannon 通信框架，将隐私保护系统类比为信源-信道-信宿模型，引入信息熵、互信息、条件熵等量化隐私保护强度与泄露风险。

这些度量方法从不同角度对合成数据的隐私性进行了补充和验证，与形式化的隐私预算共同构成了隐私性的评估体系。

当前合成数据的隐私性的主要度量指标如表 7 所示。

表 7 合成数据隐私性度量指标分类

Table 7 Classification of Privacy Measurement Metrics for Synthetic Data

度量指标	具体指标/方法	适用数据类型/场景
隐私预算	ε	所有类型
后验概率	贝叶斯推断	所有类型（主要针对个体识别风险）
区间估计	置信区间宽度	数值型数据
信息熵	Shannon 熵 / 位置熵	所有类型

5.2 合成数据的效用性评价

合成数据的根本目的是替代原始数据用于下游任务，其效用性体现在合成数据支持特定分析任务的能力上。效用评估通过比较合成与真实数据性能，评估合成数据对特定任务的有用程度，确保其有效用于统计分析或机器学习等任务。本节将从数据类型和下游任务论述合成数据的评价指标。

5.2.1 不同类型数据的评价指标

（1）表格数据：获得边缘分布与联合分布是

合成数据主流框架的关键环节，基于分布的评价是考量合成数据与真实数据统计特性一致性的核心。 k -way 边缘分布用于评估多属性联合分布的统计一致性，随着 k 的增加可测量高阶属性相关性^[6]。文献[50]提出用 KL 散度（Kullback-Leibler Divergence）

$$D_{KL}(P \parallel Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)} \quad (15)$$

测量真实分布 P 与合成分布 Q 之间的熵差。总变分距离^[94]（Total Variation Distance）

$$\delta(P, Q) = \frac{1}{2} \sum_x |P(x) - Q(x)| \quad (16)$$

则是通过两概率分布的最大差值评价合成数据，而维度概率分析^[95]是对二元变量计算各维度的伯努利成功概率，来比较合成前后结果发生可能性的相似性。

相关性对于保持数据的结构完整性也至关重要，其反映了特征或属性之间的依赖关系。研究人员通过对比相关系数评估合成与真实数据中变量成对关系的相似性，常用相关度量包括肯德尔相关系数^[96]、皮尔逊相关系数^[97]和斯皮尔曼相关系数^[98]。

统计查询是评估合成数据效用的常用方法，核心是考察合成数据响应特定查询时能否保留真实数据的统计特性、满足下游任务的需求，常见查询包括范围、线性和聚合查询等。

表格数据的效用评价指标普遍适用于合成数据评价，但轨迹数据与图数据因类型和应用场景的特殊性，需特定的评价指标。

(2) 轨迹数据：“地理不可区分性”^[99]将差分隐私扩展至欧几里得空间，通过平面拉普拉斯噪声机制实现位置扰动，衡量轨迹中真实与合成位置的不可区分程度。其要求对于任意两个真实位置 x 和 y ，以及任何发布的位置 l ，满足：

$$\frac{P(\text{发布位置}=l | \text{真实位置}=x)}{P(\text{发布位置}=l | \text{真实位置}=y)} \leq e^{\epsilon \cdot d(x,y)} \quad (17)$$

其中 $d(x, y)$ 是两位置间的欧氏距离。文献^[100]提出的“轨迹覆盖范围”则用于评估合成轨迹在地理空间覆盖范围与原始数据的一致性。

(3) 图数据：图数据的特定评价指标分为可用性和应用两类^[89]：可用性聚焦图结构信息，包括结点度中心性、密度、聚类系数（Clustering Coefficient，节点 i 的聚类系数

$$C_i = \frac{2 \cdot \text{邻居间实际边数}}{k_i(k_i - 1)} \quad (18)$$

其中 k_i 是节点 i 的度）、模块度（Modularity，

$$Q = \frac{1}{2m} \sum_{ij} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j) \quad (19)$$

其中 m 是总边数， A_{ij} 是邻接矩阵元素， c_i 是节点 i 的社区）、度分布、路径长度和相对直径等；面向应用的指标主要用于现实场景的统计分析或机器学习，涵盖社区检测、子图计数和结点属性分类等。

5.2.2 面向任务的评价指标

合成数据的最终价值体现在其支持下游分析任务的效果上，因此面向特定任务的效用指标更具实际意义。此类评估通过模拟真实应用场景，直接检验合成数据能否替代原始数据完成既定目标。

(1) 机器学习：基于机器学习的评估指通过机器学习模型执行预测或分类等任务，比较模型在真实与合成数据上的表现以评估合成数据效用。该评估范式将合成数据置于机器学习 Pipeline 中，通过比较模型性能来量化其效用。其标准流程如下：首先，将原始数据集划分为训练集与测试集；随后，使用由原始训练集生成的合成数据训练特定机器学习模型，同时使用原始训练集本身训练一个相同的模型作为性能基线；最后，在未参与合成过程的原始测试集上评估两个模型的性能。两者性能差距越小，则表明合成数据在保留原始数据判别特征与预测模式方面的效用越高，越具备替代原始数据用于模型训练的价值^[3]。通常的任务包括分类、回归及维度预测等^[95]。常用的性能评估指标根据机器学习任务类型而定：

分类任务广泛采用准确率（Accuracy）、

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (20)$$

精确率（Precision）、召回率（Recall）、F1-

Score(

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (21)$$

)以及受试者工作特征曲线下面积 (Area Under the ROC Curve, AUC) 等指标进行综合评估。例如, 文献[101]在关于医疗健康领域合成数据的综述中指出, 比较在真实与合成数据上训练的预测模型的 AUC 是衡量其临床实用性的关键方法。

回归任务通常采用均方误差 (Mean Squared Error, MSE)、

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (22)$$

平均绝对误差 (Mean Absolute Error, MAE),

$$MAE = \frac{1}{m} \sum_{j=1}^m |f_j(D) - f_j(\hat{D})| \quad (23)$$

或决定系数 (R^2) 来衡量模型预测值与真实值之间的偏差。

聚类任务可采用调整兰德指数 (Adjusted Rand Index, ARI)、归一化互信息 (Normalized Mutual Information, NMI) 等指标, 评估基于合成数据与基于原始数据所得的聚类结果之间的一致性程度。

为确保证据的充分性与结论的稳健性, 该评估应在多种机器学习模型、不同的差分隐私合成

算法及多个隐私预算 ϵ 水平下进行重复实验与交叉验证^[102]。

(2) 统计查询精度: 该指标旨在评估合成数据回答各类统计查询的准确性, 是其作为“统计数据库替代品”的核心效用体现。评估方法为: 设计一个具有代表性的查询工作负载 (Workload) Q , 其中包含 m 个查询, 分别计算每个查询 $q_i \in Q$ 在原始数据集 D 和合成数据集 D' 上的答案, 并度量两个答案之间的误差。误差值越小, 表明合成数据对原始数据总体统计特征的保持能力越强, 越能提供可靠的数据洞察。这一指标在实践中极具重要性, 例如美国人口普查局在其采用差分隐私的 2020 年人口数据发布系统中, 核心的效用评估即依赖于对大量历史统计查询的误差分析^[103]。诸多先进的差分隐私合成算法 (如文献[50]和文献[53]) 其优化目标直接就是最小化特定工作负载上的统计查询误差。

当前合成数据效用性的主要度量指标如表 8 所示。

表 8 合成数据效用性度量指标分类

Table 8 Classification of Utility Measurement Metrics for Synthetic Data

度量对象	度量对象类型	具体指标	适用任务
数据	表格数据	k-way 边缘分布	分布一致性
		KL 散度	分布相似性
		总变分距离	分布差异
		相关系数	属性间依赖关系
	轨迹数据	地理不可区分性	位置隐私
		轨迹覆盖范围	轨迹分析
任务	图数据	结节点中心性、聚类系数	图结构保持
		模块度	社区结构保持
		路径长度、相对直径	图连通性
	机器学习	分类: 准确率、F1 分数、特征曲线下面积	分类模型训练
		回归: 均方误差、平均绝对误差、决定系数	回归模型训练
		聚类: 调整兰德指数、归一化互信息	聚类分析
	统计查询精度	查询误差	统计分析、数据发布

6 差分隐私合成数据的应用场景与未来方向

差分隐私合成数据已在多个实际场景中发挥重要作用, 尤其是在当今数据开放共享与隐私保

护需求并存的时代。结构化数据更是无时无刻充斥于日常应用之中, 但其同样也面临着更加严峻的挑战。

6.1 合成数据的应用场景

6.1.1 表格数据的应用场景

表格数据作为实际生活中最常见的数据存储方式，在大数据时代应用广泛，是统计分析和机器学习的基础。2020 年美国人口普查将差分隐私作为防止通过汇总数据反推个体信息的优先选择^[104]，医疗领域文献^[105]指出通过共享差分隐私保护的患者数据用于流行病学研究至关重要，金融机构也用差分隐私生成合成交易数据供第三方分析^[106]。因此，表格数据仍是未来研究者的重点保护对象。

6.1.2 轨迹数据的应用场景

万物互联时代，终端设备及智能网联汽车的普及使定位与导航数据激增，轨迹保护成为保护隐私和人身安全关键。文献^[107]指出轨迹数据在 LBS 服务中的广泛应用带来隐私风险，尤其多用户场景下存在保护不足且数据可用性低的问题，高效轨迹合成方案需在保护隐私的同时确保数据可用于智能交通规划、路况分析等场景。因此，当前轨迹数据的保护面临高维数据、多样查询任务及车辆间数据相关性等挑战^[108]。

6.1.3 图数据的应用场景

随着社交网络分析与知识图谱研究的深入，图数据的差分隐私保护成为研究焦点。现有图数据保护方法多基于边扰动，但过多虚拟边的引入易降低合成图效用，近年的研究转向对结点度序列添加噪声以保存原始结构^[74]。但传统社交网络分析多针对无权无向图，而随着推荐系统的普及使有向有权图的隐私保护需求凸显。现有推荐系统多基于单用户数据集，存在规模受限和本地开销大的问题，因此，亟需开展多用户及跨域推荐系统研究^[109]，文献^[110]指出可借助本地差分隐私技术解决数据集中于中心服务器的弊端。

6.2 合成数据面临的主要挑战

虽然当前的差分隐私数据合成技术取得了显著进展，但在理论研究和实际应用方面仍面临一系列严峻挑战，限制了其进一步的推广与深化。

（1）隐私性与效用性之间的权衡：差分隐私通过向数据引入噪声提供保护，但添加噪声不可避免地会损害数据效用。在涉及高维数据、复杂关联结构或小隐私预算的场景下，如何精确控制噪声注入并设计更优的合成机制以在强隐私保护下维持足够的数据效用，仍是一个根本性问题。

（2）高维与动态数据合成的挑战：现有方法在处理高维数据时，常因“维度灾难”导致数据效用急剧下降。同时，对于流式图数据、实时轨迹等动态数据，目前的研究多为静态场景设计，缺乏高效的增量更新机制与动态隐私预算分配策略，难以满足对实时更新数据的隐私保护要求。

（3）复杂关联与异构数据建模的困难：现实世界的的数据往往包含复杂的关联关系（如图数据中的社区结构、轨迹数据中的时空相关性）以及混合型或多模态属性。现有的合成模型难以全面、准确地捕获这些数据的复杂特征，导致合成数据在保留高阶统计特性或支持复杂下游任务等方面表现不佳。

（4）个性化隐私保护与隐私预算分配的优化：不同的用户或数据可能具有不同级别的隐私敏感度和保护优先级。现有的个性化差分隐私机制尚不成熟，如何根据数据特征或用户偏好设计自适应、精细化地隐私预算分配策略，避免“一刀切”或隐私过度保护带来的效用损失，仍是一个亟待解决的问题。

6.3 合成数据的未来方向

针对上述挑战，本文提炼出以下五个关键开放问题与未来方向，以推动差分隐私数据合成技术的进一步发展。

(1) 面向高维与动态数据的高效合成机制：探索更强大的降维技术（如基于深度学习的表示学习）与差分隐私的结合，以缓解高维问题。对于动态数据，需设计支持处理流式数据的合成算法，开发跨时间戳的隐私预算优化策略和增量式数据生成模型，以有效的对动态数据进行跟踪与合成^[111]。

(2) 结合深度生成模型与差分隐私：生成对抗网络（GANs）、扩散模型（Diffusion Models）和变分自编码器（VAEs）等深度生成模型在捕获复杂数据分布方面表现出强大能力。如何以更安全、更高效的方式将这些模型与差分隐私训练或输出扰动机制相结合，在保证严格差分隐私的同时，生成更真实、效用更高的合成数据，是未来研究的重点^[112]。

(3) 跨模态与异构数据的合成框架：现实应用中的数据日益多元化。研究能够处理结构化数据之外的文本、图像等多模态数据的差分隐私合成框架至关重要^[113]。这需要探索跨模态的特征对齐、联合分布建模以及统一的隐私保护机制。

(4) 隐私-效用权衡的自适应优化：可利用元学习、强化学习或进化计算等自动化机器学习技术，自适应地优化合成过程中的关键参数，例如在不同合成阶段或数据子集上隐私预算的分配与噪声机制的选择等。目标是构建智能化的合成系统，能够根据数据特性与特定任务寻找最优的解决方案。

(5) 面向大语言模型的安全供给：特别是在如今 AI 安全与生成式人工智能（AIGC）兴起的背景下，差分隐私合成数据不仅展现出重要价值，也面临新的挑战：一方面，它能够为大语言模型（如 GPT 系列）提供合规训练数据，避免原始敏感样本被记忆与还原^[114]，同时支持模型鲁棒性测试与对抗攻击评估，减少使用真实数据带来

的泄露风险，并在本地差分隐私框架下增强联邦学习，实现跨域联合建模而不暴露原始数据；另一方面，合成数据在 AIGC 中的应用也引发新的问题，包括攻击者通过逆向工程推断原始数据分布的再泄露风险、差分隐私与生成模型（如扩散模型和 GAN）结合时如何在保证生成质量的同时满足严格隐私保证，以及合成数据广泛使用后所带来的检测与认证等监管与技术挑战。

结束语

在数据成为核心驱动要素、生成式人工智能技术迅猛崛起并深度融合于产业变革的时代背景下，数据开放与隐私安全的张力日益凸显。差分隐私凭借其严格的数学可证明性，已成为平衡数据效用与隐私保护的核心技术手段，为结构化数据的合规发布与安全共享提供了坚实基础。本文通过系统地总结了差分隐私在结构化数据合成中的关键技术、框架与评估体系，表明“选择-压缩表示-合成”框架已成为主流范式，能够在保护个体隐私的同时保持数据的宏观统计特性。但当前方法仍面临高维数据处理、动态数据合成及隐私预算优化等挑战，尤其在应对复杂关联和实时生成场景时效能受限。随着 AI 与 AIGC 的快速发展，差分隐私合成数据在支持大模型训练、联邦学习等方面的作用愈发关键，其与生成模型的深度融合、合成数据的安全认证与监管等问题仍需突破。未来研究应聚焦于跨模态数据合成、自适应隐私分配、个性化保护及与新一代 AI 技术的协同创新，以推动差分隐私合成数据在保障安全的前提下，更好地服务于开放数据生态和可信 AI 建设。

参考文献

- [1] Voigt, P., A.v.d. Bussche. The EU General Data Protection Regulation (GDPR). 2017.

-
- [2] Dwork, C. Differential Privacy. in Automata, Languages and Programming. 2006. Berlin, Heidelberg: Springer Berlin Heidelberg.
- [3] Jordon, J., L. Szpruch, F. Houssiau, et al., Synthetic Data--what, why and how? arXiv preprint arXiv:2205.03257, 2022.
- [4] Liu, F., Z. Cheng, H. Chen, et al., Privacy-Preserving Synthetic Data Generation for Recommendation Systems, in Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2022, Association for Computing Machinery: Madrid, Spain. p. 1379–1389.
- [5] Su, B., Y. Wang, D. Schiavazzi, et al., Privacy-Preserving Data Synthesis via Differentially Private Normalizing Flows with Application to Electronic Health Records Data. Proceedings of the AAAI Symposium Series, 2023. 1(1): p. 161-167.
- [6] Yang, M., C.-H. Chi, K.-Y. Lam, et al. Tabular Data Synthesis with Differential Privacy: A Survey. 2024. arXiv:2411.03351 DOI: 10.48550/arXiv.2411.03351.
- [7] Miranda-Pascual, À., P. Guerra-Balboa, J. Parra-Arnau, et al., SoK: Differentially Private Publication of Trajectory Data. Proceedings on Privacy Enhancing Technologies, 2023. 2023: p. 496-516.
- [8] Jiang, H., J. Pei, D. Yu, et al., Applications of Differential Privacy in Social Network Analysis: A Survey. Ieee Transactions on Knowledge and Data Engineering, 2023. 35(1): p. 108-127.
- [9] Sweeney, L., k-anonymity: a model for protecting privacy. Int. J. Uncertain. Fuzziness Knowl.-Based Syst., 2002. 10(5): p. 557–570.
- [10] Machanavajjhala, A., J. Gehrke, D. Kifer, et al. L-diversity: privacy beyond k-anonymity. in 22nd International Conference on Data Engineering (ICDE'06). 2006.
- [11] Li, N., T. Li, S. Venkatasubramanian. t-Closeness: Privacy Beyond k-Anonymity and l-Diversity. in 2007 IEEE 23rd International Conference on Data Engineering. 2007.
- [12] Rivest, R.L., M.L. Dertouzos. ON DATA BANKS AND PRIVACY HOMOMORPHISMS. 1978.
- [13] Henecka, W., S.K. ögl, A.-R. Sadeghi, et al., TASTY: tool for automating secure two-party computations, in Proceedings of the 17th ACM conference on Computer and communications security. 2010, Association for Computing Machinery: Chicago, Illinois, USA. p. 451–462.
- [14] Cormode, G., S. Jha, T. Kulkarni, et al., Privacy at Scale: Local Differential Privacy in Practice, in Proceedings of the 2018 International Conference on Management of Data. 2018, Association for Computing Machinery: Houston, TX, USA. p. 1655–1658.
- [15] Zhu, T., G. Li, W. Zhou, et al., Differentially Private Data Publishing and Analysis: A Survey. IEEE Transactions on Knowledge and Data Engineering, 2017. 29(8): p. 1619-1638.
- [16] Dwork C, M.F., Nissim K, Smith A, Calibrating Noise to Sensitivity in Private Data Analysis, in the 3rd Conference on Theory of Cryptography, R.T. Halevi S, Editor. 2006, Springer: New York, USA. p. 265-284.
- [17] McSherry F, T.K., Mechanism Design via Differential Privacy, in 48th annual IEEE Symposium on Foundations of Computer Science. 2007: Providence, Rhode island, USA. p. 94-103.
- [18] Dwork, C., K. Kenthapadi, F. McSherry, et al. Our Data, Ourselves: Privacy Via Distributed Noise Generation. in Advances in Cryptology - EUROCRYPT 2006. 2006. Berlin, Heidelberg: Springer Berlin Heidelberg.
- [19] YE Q Q, MENG X F, ZHU M J, et al.. Survey on local differential privacy. Ruan Jian Xue Bao/Journal of Software, 2018, 29(7): 1981-2005 (in Chinese). <http://www.jos.org.cn/1000-9825/5364.htm>
- 叶青青, 孟小峰, 朱敏杰, et al., 本地化差分隐私研究综述. 软件学报, 2018. 29(07): p. 1981-2005.
- [20] Dwork, C., G.N. Rothblum, Concentrated differential privacy. arXiv preprint arXiv:1603.01887, 2016.
- [21] Kong, X., M. Li, K. Ma, et al., Big Trajectory Data: A Survey of Applications and Services. IEEE Access, 2018. 6: p. 58295-58306.
- [22] Strogatz, S.H., Exploring complex networks. nature, 2001. 410(6825): p. 268-276.
- [23] Hu, Y., F. Wu, Q. Li, et al. SoK: Privacy-Preserving Data Synthesis. in 2024 IEEE Symposium on Security and Privacy (SP). 2024.
- [24] Sucar, L.E., Probabilistic graphical models. 2021: Springer.
- [25] Stephenson, T., An Introduction to Bayesian Network Theory and Usage. 2000.
- [26] Zhang, J., G. Cormode, C.M. Procopiuc, et al., PrivBayes: Private Data Release via Bayesian Networks. ACM Trans. Database Syst., 2017. 42(4): p. Article 25.
- [27] Bao, E., X. Xiao, J. Zhao, et al., Synthetic Data Generation with Differential Privacy via Bayesian Networks. Journal of Privacy and Confidentiality, 2021. 11(3).
- [28] Metzler, D., W.B. Croft, A Markov random field model for term dependencies, in Proceedings of the 28th annual international ACM SIGIR conference on

Research and development in information retrieval. 2005, Association for Computing Machinery: Salvador, Brazil. p. 472–479.

[29] McKenna, R., G. Miklau, D. Sheldon, Winning the NIST Contest: A scalable and general approach to differentially private synthetic data. *Journal of Privacy and Confidentiality*, 2021. 11(3).

[30] Cai, K., X. Lei, J. Wei, et al., Data synthesis via differentially private markov random fields. *Proc. VLDB Endow.*, 2021. 14(11): p. 2190–2202.

[31] The junction tree algorithm, in *Bayesian Reasoning and Machine Learning*, D. Barber, Editor. 2012, Cambridge University Press: Cambridge. p. 102-126.

[32] Jia, J., X. Li, T. Li, et al., ABSyn: An Accurate Differentially Private Data Synthesis Scheme With Adaptive Selection and Batch Processes. *IEEE Transactions on Information Forensics and Security*, 2024. 19: p. 8338-8352.

[33] Zhang, Z., T. Wang, N. Li, et al., PrivSyn: Differentially Private Data Synthesis, in 30th USENIX Security Symposium (USENIX Security 21). 2021, USENIX Association. p. 929-946.

[34] Cai, K., X. Xiao, G. Cormode, PrivLava: Synthesizing Relational Data with Foreign Keys under Differential Privacy. *Proc. ACM Manag. Data*, 2023. 1(2): p. Article 142.

[35] ZHU Y W, WANG K, ZHOU Y Q. A Multi-party Vertically Partitioned Data Synthesis Mechanism with Personalized Differential Privacy[J]. *Journal of Electronics & Information Technology*, 2024, 46(05): 2159-2176

朱友文, 王珂, 周玉倩, 一种满足个性化差分隐私的多方垂直划分数据合成机制. *电子与信息学报*, 2024. 46(05): p. 2159-2176.

[36] Sklar, M.J. Fonctions de repartition a n dimensions et leurs marges. 1959.

[37] Bouyé E., V. Durrleman, A. Nikeghbali, et al., Copulas for Finance - A Reading Guide and Some Applications. *Risk Management*, 2000.

[38] Bedford, T., R.M. Cooke, Probability Density Decomposition for Conditionally Dependent Random Variables Modeled by Vines. *Annals of Mathematics and Artificial Intelligence*, 2001. 32(1): p. 245-268.

[39] Li, H., L. Xiong, X. Jiang, Differentially Private Synthesization of Multi-Dimensional Data using Copula Functions. *Advances in database technology : proceedings. International Conference on Extending Database Technology*, 2014. 2014: p. 475-486.

[40] Asghar, H.J., M. Ding, T. Rakotoarivelo, et al., Differentially Private Release of Datasets using Gaussian Copula. *Journal of Privacy and Confidentiality*, 2021. 10(2).

[41] Osorio-Marulanda, P.A., J.E.C. Ramirez, M.H. Jiménez, et al., Differentially Private Non Parametric Copulas: Generating synthetic data with non parametric copulas under privacy guarantees. *arXiv preprint arXiv:2409.18611*, 2024.

[42] Dißmann, J., E.C. Brechmann, C. Czado, et al., Selecting and estimating regular vine copulae and application to financial returns. *Computational Statistics & Data Analysis*, 2013. 59: p. 52-69.

[43] Gambs, S., F. Ladouceur, A. Laurent, et al., Growing synthetic data through differentially-private vine copulas. *Proceedings on Privacy Enhancing Technologies*, 2021. 2021: p. 122-141.

[44] Griesbauer, E., C. Czado, A. Frigessi, et al., TVineSynth: A Truncated C-Vine Copula Generator of Synthetic Tabular Data to Balance Privacy and Utility. *arXiv preprint arXiv:2503.15972*, 2025.

[45] Kenthapadi, K., A. Korolova, I. Mironov, et al., Privacy via the Johnson-Lindenstrauss Transform. *Journal of Privacy and Confidentiality*, 2013. 5(1).

[46] Johnson, W., J. Lindenstrauss, Extensions of Lipschitz maps into a Hilbert space. *Contemporary Mathematics*, 1984. 26: p. 189-206.

[47] Xu, C., J. Ren, Y. Zhang, et al., DPPro: Differentially Private High-Dimensional Data Release via Random Projection. *IEEE Transactions on Information Forensics and Security*, 2017. 12(12): p. 3081-3093.

[48] Chanyaswad, T., C. Liu, P. Mittal, RON-Gauss: Enhancing Utility in Non-Interactive Private Data Release. *Proceedings on Privacy Enhancing Technologies*, 2019. 2019: p. 26-46.

[49] Meckes, E., Projections of Probability Distributions: A Measure-Theoretic Dvoretzky Theorem, in *Geometric Aspects of Functional Analysis: Israel Seminar 2006–2010*, B.a. Klartag, S. Mendelson, and V.D. Milman, Editors. 2012, Springer Berlin Heidelberg: Berlin, Heidelberg. p. 317-326.

[50] Hardt, M., K. Ligett, F. McSherry, A simple and practical algorithm for differentially private data release, in *Proceedings of the 26th International Conference on Neural Information Processing Systems - Volume 2*. 2012, Curran Associates Inc.: Lake Tahoe, Nevada. p. 2339–2347.

[51] Hardt, M., G.N. Rothblum, A Multiplicative Weights Mechanism for Privacy-Preserving Data Analysis. in *2010 IEEE 51st Annual Symposium on Foundations of Computer Science*. 2010.

[52] Gaboardi, M., E.J.G. Arias, J. Hsu, et al., Dual Query: Practical Private Query Release for High Dimensional Data, in *Proceedings of the 31st International Conference on Machine Learning*, P.X. Eric and J. Tony, Editors. 2014, PMLR: Proceedings of Machine Learning Research. p. 1170--1178.

- [53] McKenna, R., B. Mullins, D. Sheldon, et al., AIM: an adaptive and iterative mechanism for differentially private synthetic data. *Proc. VLDB Endow.*, 2022. 15(11): p. 2599–2612.
- [54] Chen, R., B.C.M. Fung, B.C. Desai, et al., Differentially private transit data publication: a case study on the montreal transportation system, in *Proceedings of the 18th ACM SIGKDD international conference on Knowledge discovery and data mining*. 2012, Association for Computing Machinery: Beijing, China. p. 213–221.
- [55] Chen, R., G. Acs, C. Castelluccia, Differentially private sequential data publication via variable-length n-grams, in *Proceedings of the 2012 ACM conference on Computer and communications security*. 2012, Association for Computing Machinery: Raleigh, North Carolina, USA. p. 638–649.
- [56] He, X., G. Cormode, A. Machanavajjhala, et al., DPT: differentially private trajectory synthesis using hierarchical reference systems. *Proc. VLDB Endow.*, 2015. 8(11): p. 1154–1165.
- [57] Zhang, J., X. Xiao, X. Xie, PrivTree: A Differentially Private Algorithm for Hierarchical Decompositions, in *Proceedings of the 2016 International Conference on Management of Data*. 2016, Association for Computing Machinery: San Francisco, California, USA. p. 155–170.
- [58] Cai, S., X. Lyu, X. Li, et al., A Trajectory Released Scheme for the Internet of Vehicles Based on Differential Privacy. *IEEE Transactions on Intelligent Transportation Systems*, 2022. 23(9): p. 16534–16547.
- [59] Roy, H., M. Kantarcioglu, L. Sweeney. Practical Differentially Private Modeling of Human Movement Data. in *Data and Applications Security and Privacy XXX*. 2016. Cham: Springer International Publishing.
- [60] Gursoy, M.E., L. Liu, S. Truex, et al., Differentially Private and Utility Preserving Publication of Trajectory Data. *IEEE Transactions on Mobile Computing*, 2019. 18(10): p. 2315–2329.
- [61] Gursoy, M.E., L. Liu, S. Truex, et al., Utility-Aware Synthesis of Differentially Private and Attack-Resilient Location Traces, in *Proceedings of the 2018 ACM SIGSAC Conference on Computer and Communications Security*. 2018, Association for Computing Machinery: Toronto, Canada. p. 196–211.
- [62] Gursoy, M.E., V. Rajasekar, L. Liu. Utility-Optimized Synthesis of Differentially Private Location Traces. in *2020 Second IEEE International Conference on Trust, Privacy and Security in Intelligent Systems and Applications (TPS-ISA)*. 2020.
- [63] Wang, H., Z. Zhang, T. Wang, et al., PrivTrace: differentially private trajectory synthesis by adaptive Markov models, in *Proceedings of the 32nd USENIX Conference on Security Symposium*. 2023, USENIX Association: Anaheim, CA, USA. p. Article 93.
- [64] Niu, Y., J. Zhang, Z. Tang, et al., Privacy-preserving spatiotemporal trajectory generalization publishing scheme with differential privacy. *Computers & Security*, 2025. 156: p. 104514.
- [65] JIN Y G, YE F W, WU Q H. Location privacy protection mechanisms for UAVs with Remote ID [J] . *Acta Aeronautica et Astronautica Sinica*, 2025, 46 (11) : 531341 (in Chinese) . doi: 10.7527/S1000-6893. 2025. 31341
- 金永光, 叶方伟, 吴启晖, 面向无人机远程识别的位置隐私保护方法. *航空学报*, : p. 1-11.
- [66] Leskovec, J., C. Faloutsos, Scalable modeling of real graphs using Kronecker multiplication, in *Proceedings of the 24th international conference on Machine learning*. 2007, Association for Computing Machinery: Corvallis, Oregon, USA. p. 497–504.
- [67] Mahadevan, P., D. Krioukov, K. Fall, et al., Systematic topology analysis and generation using degree correlations. *SIGCOMM Comput. Commun. Rev.*, 2006. 36(4): p. 135–146.
- [68] Snijders, T.A.B., P.E. Pattison, G.L. Robins, et al., NEW SPECIFICATIONS FOR EXPONENTIAL RANDOM GRAPH MODELS. *Sociological Methodology*, 2006. 36(1): p. 99–153.
- [69] Clauset, A., C. Moore, M.E.J. Newman, Hierarchical structure and the prediction of missing links in networks. *Nature*, 2008. 453(7191): p. 98–101.
- [70] Pfeiffer, J.J., S. Moreno, T.L. Fond, et al., Attributed graph models: modeling network structure with correlated attributes, in *Proceedings of the 23rd international conference on World wide web*. 2014, Association for Computing Machinery: Seoul, Korea. p. 831–842.
- [71] Jorgensen, Z., T. Yu, G. Cormode, Publishing Attributed Social Graphs with Formal Privacy Guarantees, in *Proceedings of the 2016 International Conference on Management of Data*. 2016, Association for Computing Machinery: San Francisco, California, USA. p. 107–122.
- [72] Chen, X., S. Mauw, Y. Ramírez-Cruz, Publishing Community-Preserving Attributed Social Graphs with a Differential Privacy Guarantee. *Proceedings on Privacy Enhancing Technologies*, 2020. 2020: p. 131–152.
- [73] Huang, H., D. Zhang, F. Xiao, et al., Privacy-Preserving Approach PBCN in Social Network With Differential Privacy. *IEEE Transactions on Network and Service Management*, 2020. 17(2): p. 931–945.
- [74] Yuan, Q., Z. Zhang, L. Du, et al., PrivGraph: differentially private graph data publication by exploiting community information, in *Proceedings of the 32nd USENIX Conference on Security Symposium*. 2023, USENIX Association: Anaheim, CA, USA. p. Article 182.

- [75] Shen, J., J. Tian, Z. Wang, et al., Preserving Social Relationship Privacy via the Exponential Mechanism of Personalized Differential Privacy. *IEEE Transactions on Computational Social Systems*, 2024: p. 1-17.
- [76] Chen, J., C. Hu, W. Sheng, et al., Sensitivity-Aware Personalized Differential Privacy Guarantees for Online Social Networks. *IEEE Transactions on Information Forensics and Security*, 2025. 20: p. 3116-3130.
- [77] Zhang, S., H. Hu, Q. Ye, et al., PrivDPR: Synthetic Graph Publishing with Deep PageRank under Differential Privacy, in *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.1*. 2025, Association for Computing Machinery: Toronto ON, Canada. p. 1936-1947.
- [78] Aiello, W., F. Chung, L. Lu, A random graph model for massive graphs, in *Proceedings of the thirty-second annual ACM symposium on Theory of computing*. 2000, Association for Computing Machinery: Portland, Oregon, USA. p. 171-180.
- [79] Yuan, Q., Z. Zhang, L. Du, et al., PSGraph: Differentially Private Streaming Graph Synthesis by Considering Temporal Dynamics. *arXiv preprint arXiv:2412.11369*, 2024.
- [80] Xu, W., Z. Li, H. Liu, et al., Differentially Private Weighted Graphs Publication Under Continuous Monitoring. *IEEE Transactions on Mobile Computing*, 2025. 24(5): p. 3735-3749.
- [81] Abadi, M., A. Chu, I. Goodfellow, et al., Deep Learning with Differential Privacy, in *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security*. 2016, Association for Computing Machinery: Vienna, Austria. p. 308-318.
- [82] Fletcher, S., A. Roegiest, A.K. Hudek. Towards Protecting Sensitive Text with Differential Privacy, in *2021 IEEE 20th International Conference on Trust, Security and Privacy in Computing and Communications (TrustCom)*. 2021.
- [83] Yue, X., M. Du, T. Wang, et al. Differential Privacy for Text Analytics via Natural Text Sanitization. 2021. Online: Association for Computational Linguistics.
- [84] Yu, D., S. Naik, A. Backurs, et al., Differentially Private Fine-tuning of Language Models. *Journal of Privacy and Confidentiality*, 2024. 14(2).
- [85] Torkzadehmahani, R., P. Kairouz, B. Paten. DP-CGAN: Differentially Private Synthetic Data and Label Generation, in *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. 2019.
- [86] Wang, H., S. Pang, Z. Lu, et al., dp-promise: differentially private diffusion probabilistic models for image synthesis, in *Proceedings of the 33rd USENIX Conference on Security Symposium*. 2024, USENIX Association: Philadelphia, PA, USA. p. Article 60.
- [87] Niu, B., Y. Chen, B. Wang, et al. AdaPDP: Adaptive Personalized Differential Privacy. in *IEEE INFOCOM 2021 - IEEE Conference on Computer Communications*. 2021.
- [88] Li, Y., X. Song, Y. Tu, et al., GAPBAS: Genetic algorithm-based privacy budget allocation strategy in differential privacy K-means clustering algorithm. *Computers & Security*, 2024. 139: p. 103697.
- [89] LIU Y H, CEHN H, LIU Y X, et al. State-of-the-Art Privacy Attacks and Defenses on Graphs[J]. *CHINESE JOURNAL OF COMPUTERS*, 2022, 45(04): 702-734
- 刘宇涵, 陈红, 刘艺璇, et al., 图数据上的隐私攻击与防御技术. *计算机学报*, 2022. 45(04): p. 702-734.
- [90] Lee, J., C. Clifton. How Much Is Enough? Choosing ϵ for Differential Privacy. in *Information Security*. 2011. Berlin, Heidelberg: Springer Berlin Heidelberg.
- [91] Naldi, M., G. D'Acquisto Differential Privacy: An Estimation Theory-Based Method for Choosing Epsilon. 2015. *arXiv:1510.00917* DOI: 10.48550/arXiv.1510.00917.
- [92] WAN S, LI F H, NIU B, SUN Z, et al. Research progress on location privacy-preserving techniques[J]. *Journal on Communications*, 2016, 37(12): 124-141
- 万盛, 李风华, 牛犇, et al., 位置隐私保护技术研究进展. *通信学报*, 2016. 37(12): p. 124-141.
- [93] PENG C G, DING H F, ZHU Y J, et al. Information entropy models and privacy metrics methods for privacy protection. *Ruan Jian Xue Bao/Journal of Software*, 2016, 27(8): 1891-1903 (in Chinese). <http://www.jos.org.cn/1000-9825/5096.htm>
- 彭长根, 丁红发, 朱义杰, et al., 隐私保护的信息熵模型及其度量方法. *软件学报*, 2016. 27(08): p. 1891-1903.
- [94] Kotelnikov, A., D. Baranchuk, I. Rubachev, et al., TabDDPM: modelling tabular data with diffusion models, in *Proceedings of the 40th International Conference on Machine Learning*. 2023, JMLR.org: Honolulu, Hawaii, USA. p. Article 725.
- [95] Choi, E., S. Biswal, B. Malin, et al., Generating Multi-label Discrete Patient Records using Generative Adversarial Networks, in *Proceedings of the 2nd Machine Learning for Healthcare Conference, D.-V. Finale, et al., Editors*. 2017, PMLR: Proceedings of Machine Learning Research. p. 286-305.
- [96] Abdi, H., The Kendall rank correlation coefficient. *Encyclopedia of measurement and statistics*, 2007. 2: p. 508-510.
- [97] Zhang, H., J. Zhang, B. Srinivasan, et al. Mixed-Type Tabular Data Synthesis with Score-based

Diffusion in Latent Space. 2023. arXiv:2310.09656
DOI: 10.48550/arXiv.2310.09656.

[98] De Winter, J.C., S.D. Gosling, J. Potter, Comparing the Pearson and Spearman correlation coefficients across distributions and sample sizes: A tutorial using simulations and empirical data. *Psychological methods*, 2016. 21(3): p. 273.

[99] Andr  s, M.E., N.E. Bordenabe, K. Chatzikokolakis, et al., Geo-indistinguishability: differential privacy for location-based systems, in *Proceedings of the 2013 ACM SIGSAC conference on Computer & communications security*. 2013, Association for Computing Machinery: Berlin, Germany. p. 901-914.

[100] Wang, L., G. Qin, D. Yang, et al., Geographic differential privacy for mobile crowd coverage maximization, in *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence and Thirtieth Innovative Applications of Artificial Intelligence Conference and Eighth AAAI Symposium on Educational Advances in Artificial Intelligence*. 2018, AAAI Press: New Orleans, Louisiana, USA. p. Article 25.

[101] Yale, A., S. Dash, R. Dutta, et al., Generation and evaluation of privacy preserving synthetic health data. *Neurocomputing*, 2020. 416: p. 244-255.

[102] Liu, Y., U.R. Acharya, J.H. Tan, Preserving privacy in healthcare: A systematic review of deep learning approaches for synthetic data generation. *Computer Methods and Programs in Biomedicine*, 2025. 260: p. 108571.

[103] Abowd, J.M., The U.S. Census Bureau Adopts Differential Privacy, in *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 2018, Association for Computing Machinery: London, United Kingdom. p. 2867.

[104] Dwork, C., Differential Privacy and the US Census, in *Proceedings of the 38th ACM SIGMOD-SIGACT-SIGAI Symposium on Principles of Database Systems*. 2019, Association for Computing Machinery: Amsterdam, Netherlands. p. 1.

[105] Ficek, J., W. Wang, H. Chen, et al., Differential privacy in health research: A scoping review. *Journal of the American Medical Informatics Association*, 2021. 28(10): p. 2269-2276.

[106] Chen, J.-H., Y.-J. Wang, Y.-C. Tsai, et al. Financial Vision Based Differential Privacy Applications. 2021. arXiv:2112.14075 DOI: 10.48550/arXiv.2112.14075.

[107] Wu, L., C. Qin, Z. Xu, et al., TCPP: Achieving Privacy-Preserving Trajectory Correlation With Differential Privacy. *IEEE Transactions on Information Forensics and Security*, 2023. 18: p. 4006-4020.

[108] ZHAO Y Q, YANG M. Review of Differential Privacy Research[J]. *Computer Science*, 2023, 50(04): 265-276.

赵禹齐, 杨敏, 差分隐私研究进展综述. *计算机科学*, 2023. 50(04): p. 265-276.

[109] WANG M Y, ZHANG X, LI W J, et al. Review of Research on Privacy Protection Technology for Data Publication[J]. *Journal of Chinese Computer Systems*, 2020, 41(12): 2657-2667

王明月, 张兴, 李万杰, et al., 面向数据发布的隐私保护技术研究综述. *小型微型计算机系统*, 2020. 41(12): p. 2657-2667.

[110] WANG Y, LUO C H, DENG J Z, et al. Matrix Factorization Recommendation Algorithm Based on Local Differential Privacy with Objective Perturbation[J]. *CHINESE JOURNAL OF COMPUTERS*, 2025, 48(02): 451-462.

王永, 罗陈红, 邓江洲, et al., 基于目标扰动的本地化差分隐私矩阵分解推荐算法. *计算机学报*, 2025. 48(02): p. 451-462.

[111] Mao, Y., Q. Ye, Q. Wang, et al., Differential Privacy for Time Series: A Survey. *IEEE Data Eng. Bull.*, 2024. 48: p. 67-92.

[112] Demelius, L., R. Kern, A. Tr  gler, Recent Advances of Differential Privacy in Centralized Deep Learning: A Systematic Survey. *ACM Comput. Surv.*, 2025. 57(6): p. Article 158.

[113] Zhou, X., Y. Hu, Q. Jia, et al., LLM-Enabled Multi-Modal Data Synthesis via Cross-Domain Collaboration. *IEEE Communications Magazine*, 2025. 63(10): p. 86-93.

[114] Lee, P., Synthetic Data and the Future of AI. *Cornell L. Rev.*, 2025. 110: p. 1.

方贤进, 出生于 1970 年, 博士, 教授, 博士生导师, CCF 杰出会员 (No.38710D), 主要研究方向: 网络与信息安全、智能计算。

罗晨悦, 出生于 2001 年, 硕士, CCF 学生会会员 (No.X8948G), 主要研究方向: 数据安全与隐私保护。



Fang Xianjin, born in 1970, Ph.D., professor, Ph.D supervisor, is a member of CCF Distinguished Member (No. 38710D). His main research areas are network and information security and intelligent computing.



Luo Chenyue, born in 2001, postgraduate and is a CCF student member (No. X8948G). His main research direction is data security and privacy protection.

