



无线电通信技术
Radio Communications Technology
ISSN 1003-3114, CN 13-1099/TN

《无线电通信技术》网络首发论文

题目：融合时空动态感知与联邦图学习的推荐-缓存协同机制
作者：江帆，刘喜宁，刘磊，张雪薇，王朝炜
网络首发日期：2026-03-14
引用格式：江帆，刘喜宁，刘磊，张雪薇，王朝炜. 融合时空动态感知与联邦图学习的推荐-缓存协同机制[J/OL]. 无线电通信技术.
<https://link.cnki.net/urlid/13.1099.tn.20260312.2213.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

融合时空动态感知与联邦图学习的推荐-缓存协同机制

江帆^{1,2}, 刘喜宁^{1,2}, 刘磊^{1,2}, 张雪薇^{1,2}, 王朝炜^{2,3}

(1. 西安邮电大学通信与信息学院, 陕西 西安, 710121;

2. 陕西省信息通信网络及安全重点实验室, 陕西 西安, 710121;

3. 北京邮电大学电子工程学院, 北京 100876)

摘要: 针对移动边缘缓存网络中用户偏好动态性强、异质性高的问题, 提出了一种融合时空感知与联邦图学习的推荐与缓存优化策略。为有效捕获移动轨迹的时序依赖和上下文关联, 利用双向长短期记忆模型 (Bidirectional Long Short-Term Memory, Bi-LSTM) 对用户未来位置进行预测; 基于联邦图学习构建用户-内容时空交互图, 在本地融合用户行为与位置信息, 并通过差分隐私保护机制实现用户偏好分布的个性化建模与隐私保护共存; 引入贝叶斯个性化排序 (Bayesian Personalized Ranking, BPR) 模型对内容进行隐式反馈建模, 生成个性化内容动态推荐列表; 为进一步提升推荐-缓存协同效率, 以最小化用户内容获取时延为目标, 构建联合优化框架, 并设计匹配算法与贪婪缓存算法, 通过交替迭代实现推荐与缓存决策的协同收敛。仿真结果表明, 所提方法可提高推荐准确性与缓存命中率, 同时有效降低用户内容获取总时延。

关键词: 联邦图学习; 个性化推荐; 边缘缓存; 内容获取时延

中图分类号: TN929.5

文献标识码: A

开放科学 (资源服务) 标识码 (OSID):



Spatiotemporal Dynamic Recommendation and Edge Caching Collaboration Mechanism Based on Federated Graph Learning

JIANG Fan^{1,2}, LIU Xining^{1,2}, LIU Lei^{1,2}, ZHANG Xuewei^{1,2}, WANG Chaowei^{2,3}

1. School of Communication and Information Engineering, Xi'an University of Posts and Telecommunications, Xi'an 710121, China;

2. Shanxi Key Laboratory of Information Communication Network and Security, Xi'an 710121, China;

3. Beijing University of Posts and Telecommunications, Beijing 100876, China

Abstract: To address the dynamic heterogeneity of user preferences in mobile edge caching networks, this paper proposes a spatiotemporal-aware federated graph learning strategy for personalized recommendation and caching optimization. First, user mobility is predicted via a Bidirectional LSTM network to dynamically model spatiotemporal contexts. Then, federated graph learning is adopted to construct local user preference models in a privacy-preserving manner, capturing diverse interests and predicting content preference probabilities. A Bayesian model ranks content items to generate personalized recommendation lists. Subsequently, to minimize total content acquisition latency, recommendation and caching strategies are respectively optimized using a one-to-one matching algorithm and a greedy algorithm, which are iteratively coordinated via alternating optimization. Simulation results show that the proposed strategy significantly improves recommendation accuracy, reduces content access latency, and enhances caching performance.

Keywords: Federated graph learning, spatiotemporal dynamic recommendation, edge caching, content acquisition latency

基金项目: 国家科技部国家重点研发计划 (2023YFC3806003), 国家自然科学基金 (62201456), 西安邮电大学研究生创新基金 (CXJJYL2024006)

Foundation Items: The National Key Research and Development Program of the Ministry of Science and Technology of China (2023YFC3806003) The National Natural Science Foundation of China (62201456), The Graduate Student Innovation Foundation Project of Xi'an University of Posts and Telecommunications (CXJJYL2024006)

0 引言

随着无线通信技术的快速演进以及智能终端与多媒体应用的普及,移动数据流量呈现出爆炸式增长^[1]。此外,用户在时间和空间上的动态行为特性(如通勤过程中的频繁通信切换)进一步加重了传统网络架构在数据传输与处理方面的负载。现有以中心化内容分发为核心的网络严重依赖回传链路传输,高峰期易导致链路拥塞,甚至引发服务中断。为应对上述挑战,移动边缘缓存技术应运而生。其基本思想是在靠近用户的边缘节点预先缓存内容,并借助设备间通信(device-to-device, D2D)或边缘节点的下行链路实现内容的快速分发,从而有效降低回传链路压力并减少内容获取时延^[2]。

然而,由于边缘节点缓存容量普遍受限,如何设计高效、智能的内容缓存策略成为亟需解决的关键问题。文献[3]结合因子分解(factorization machine, FM)与多层感知器模型挖掘用户群体兴趣,从而设计了群体缓存策略,但并未细致刻画用户个性化偏好差异。文献[4]采用期望最大化(expectation-maximization, EM)算法对用户兴趣进行主题建模,并提出分布式缓存机制,但忽略了用户偏好随时间与空间变化的动态性。文献[5]基于联盟博弈理论构建虚拟社区以提升视频分发效率,然而其算法依赖静态偏好假设,难以适应实际场景中用户动态变化的内容需求。文献[6]首次将图神经网络引入缓存决策,通过建模用户与内容间的高阶交互以捕获隐式偏好。为进一步提升缓存性能,部分研究尝试将推荐系统与缓存策略协同优化,通过主动推荐机制影响用户请求分布。文献[7]基于用户历史请求与内容流行度的时空相关性,设计了联合推荐-缓存机制,有效提升了蜂窝网络中的缓存命中率。文献[8]构建了推荐-缓存协同框架,将用户请求概率建模为原生偏好与推荐强度的非线性交互

关系,以实现缓存性能最大化。文献[9]则在密集异构网络场景中分析了用户推荐敏感度与缓存命中率之间的内在耦合关系。文献[10]提出一种基于深度强化学习的序列化推荐-缓存联合决策框架,通过端到端训练直接优化长期缓存命中率,但其模型训练需集中收集用户连续行为序列,存在显著的隐私泄露风险,且未考虑用户移动带来的时空上下文变化。

总体而言,现有研究通过引入智能化方法刻画用户偏好,并结合缓存策略以提升边缘网络内容分发效率,在提升缓存命中率与降低传输时延方面展现出一定潜力^[11]。然而,现有工作仍存在明显不足:一方面,基于静态或群体偏好假设的模型难以捕捉用户偏好随时间、位置与情境演化的动态特征;另一方面,即使引入推荐机制,现有研究在刻画用户偏好内部的异质结构及其动态演化规律方面仍显不足,难以持续实现高精度、个性化的内容分发。因此,在动态环境下实现对用户偏好的细粒度、适应性建模,仍是边缘内容分发中的关键挑战。

基于上述问题,本文提出一种融合时空感知与隐私保护的边缘缓存-推荐协同优化方法。首先,为突破现有工作对时空上下文建模不足的限制,本文引入基于Bi-LSTM的用户位置预测模型,通过捕获时序依赖关系实现对用户位置的精准预测,提升了推荐与缓存决策的实时适配能力。其次,考虑用户偏好的动态异质性与隐私风险,本文构建了基于本地差分隐私的联邦图学习(federated graph learning, FGL)框架,在分布式环境下融合地理上下文进行安全聚合与表征学习,有效避免集中式建模中数据隐私泄露的问题,同时增强对个体差异的刻画能力。最后,针对现有推荐与缓存独立优化导致的决策割裂问题,本文构建了以最小化访问时延为目标的联合优化模型,并通过交替优化策略实现推荐与缓存决策的协同闭环,从而在保障隐私与个性化的同时,

系统性地提升内容分发效率。

1 系统模型

系统模型如图 1 所示，本文考虑的移动边缘网络架构由云服务器(CS, cloud server)、宏基站(MBS, macro base station)、小基站(SBS, small base station)以及用户设备(UE, user equipment)构成。在 MBS 覆盖范围内部署有 J 个 SBS，其集合表示为 $\mathcal{J} = \{1, 2, \dots, j, \dots, J\}$ 。每个 SBS 具有有限缓存容量，记为 $\{C_j, j \in \mathcal{J}\}$ 。用户设备集合记为 $\mathcal{U} = \{1, 2, \dots, u, \dots, U\}$ ，表示网络中发起内容请求的所有用户设备，假设用户设备在各 SBS 的服务范围内随机分布。MBS 作为核心网络的接入节点，通过有限带宽的无线链路与各 SBS 连接，并借助高速光纤链路与 CS 实现数据交换，从而满足边缘节点与中心云节点之间的通信需求。

考虑到用户的移动性及 SBS 实际部署，将网络划分为 J 个地理位置区域，每个区域部署一个 SBS，负责处理该区域内的用户的内容请求，并与相邻的 SBS 共享用户位置信息。将时间轴划分为 T 个离散时间段，记为集合 $\mathcal{T} = \{1, 2, \dots, t, \dots, T\}$ 。假设用户在任一时间段内可在不同位置区域间随机移动，并在不同位置随机发起内容请求。在任意时间段 t ，将用户 u 所处的位置区域表示为 $j_{u,t}$ ，假设用户 $u \in \mathcal{U}$ 对内容 $f \in \mathcal{F}$ 的原始请求概率记为 $p_{u,f}$ ， $p_{u,f} \in [0, 1]$ 。鉴于推荐机制能重塑用户请求进而显著影响边缘缓存策略，本文在 SBS 侧设计了联合推荐与缓存的协同优化框架，假设用户请求的内容已提前存储于其接入的 SBS 本地缓存，则视为缓存命中，可直接分发给内容请求用户；若请求内容未在本地缓存，则视为缓存未命中，需由 MBS 或 CS 调度传输所请求内容。




图 1 系统模型
Fig.1 System model

2 用户位置与偏好特征的联合推荐机制

为提升内容分发在动态环境下的响应效率与个性化推荐能力，提出一种融合用户位置与偏好特征的联合内容推荐机制。如图 1 所示，SBS 首先基于用户位置信息，利用位置预测模型预测其在下一时段可能出现的地理区域。在此基础上，结合位置预测结果与用户历史行为数据，SBS 在本地训练个性化的用户偏好预测模型，并将模型参数上传至 MBS 进行集中聚合。MBS 完成模型参数的聚合后，生成全局用户偏好模型，并下发至各个 SBS。各 SBS 基于全局偏好模型为用户计算不同内容的偏好评分，从而生成用户个性化内容推荐列表。

2.1 用户位置预测

为实现高精度的位置预测，采用一种融合在线与离线特征建模的双向长短期记忆网络 (Bi-LSTM) 方法^[12]。该模型由两个相互独立的 LSTM 分支构成：前向分支自时间序列起点对用户历史位置轨迹进行建模，刻画其随时间演化的移动行为特征；后向分支则从序列终点反向建模，补充挖掘位置序列中的反向时序关联信息，从而实现对用户移动轨迹中双向时序依赖特性的有效刻画。基于用户历史位置轨迹对 Bi-LSTM 神经网络进行训练后，所得模型可用于预测用户未来可能出现的位置分布，为后续个性

化内容推荐与缓存调度决策提供关键位置先验信息支撑。

本文设计的基于Bi-LSTM的用户位置预测模型由输入层、隐藏层（包括前向 LSTM 单元和反向 LSTM 单元）、输出层及 SoftMax 层构成。其中，隐藏层包含前向 LSTM 单元与反向 LSTM 单元，分别用于对用户历史位置序列的正向与反向时序特征进行建模。该模型旨在有效刻画用户历史位置信息中蕴含的双向时序依赖关系，从而实现对用户未来位置的精确建模与预测。在模型输入阶段，用户的历史位置信息序列以矩阵形式作为模型输入。设输入矩阵的行数表示历史位置点的数量，列数对应每个位置点的特征维度，即输入层的维度。该输入矩阵可以表示为：

$$X_{u,t} = \begin{bmatrix} x_{u,t}^{(1)} & x_{u,t}^{(1)} & \cdots & x_{u,t}^{(1)} \\ x_{u,t-1}^{(1)} & x_{u,t-1}^{(1)} & \cdots & x_{u,t-1}^{(1)} \\ \vdots & \vdots & \ddots & \vdots \\ x_{u,t-N_t+1}^{(1)} & x_{u,t-N_t+1}^{(1)} & \cdots & x_{u,t-N_t+1}^{(1)} \end{bmatrix} \quad (1)$$

其中， $X_{u,t}$ 代表用户 u 在时间 t 的输入矩阵， N_t 为历史位置的数量， N 为输入特征的维度。将该输入矩阵输入到 Bi-LSTM 模型中，通过正向和反向 LSTM 层的处理，最终通过 SoftMax 层对于输出进行归一化处理，从而实现对用户在下一个时间点位置的预测。由于位置预测属于多分类问题，本文选用交叉熵损失函数作为损失函数，其表达式如下：

$$Loss = -\sum_{l=1}^S y_l \ln(\hat{y}_l) \quad (2)$$

其中， y_l 和 $\hat{y}_l$ 分别表示真实位置和预测位置的概率分布。为了提升位置预测的准确性，所提出的模型以最小化损失函数为优化目标，通过迭代更新网络参数，直至训练完成并获得精度收敛的预测模型。

训练完成后，MBS 将训练好的模型发送至各边缘 SBS，以支持分布式的位置预测与缓存调度。在

每个时间周期 t ，每个 SBS 根据用户历史位置信息构建输入矩阵，并利用位置预测模型预测用户在 $t+1$ 时段的潜在位置。通过这种方式，SBS 能够实时获得用户的动态位置。此外，为进一步提升区域内用户感知的完整性与预测覆盖率，SBS 之间共享区域内预测的位置信息，以便获取 $t+1$ 时段覆盖区域内可能接入的用户集合。

2.2 位置修正的用户偏好预测

在位置预测模型的基础上，进一步引入联邦图学习（FGL, federated graph learning）方法，在保障用户数据隐私的前提下，实现对用户之间潜在关联关系与内容偏好特征的建模。FGL 融合了联邦学习（federated learning, FL）与图学习（graph learning, GL）的优势^[13]，通过在本地设备或边缘节点上完成对用户偏好模型训练，仅上传模型参数或中间表示进行协同优化，从而有效降低数据集中化所带来的隐私泄露风险。

所考虑的 FGL 网络结构如图 2 所示，FGL 在边缘智能系统中的部署架构与训练流程包括局部图构建、特征初始化、图神经网络训练以及联邦聚合等多个阶段。首先，系统构建用户-内容交互图（即局部子图），将每个用户 $u \in \mathcal{U}$ 和内容 $f \in \mathcal{F}$ 视为图中的独立节点。在局部图构建过程中，用户 u 的特征向量 $h_u^{(0)}$ 基于其历史行为数据生成，同时引入用户的位置信息作为补充特征输入，以增强模型对用户行为的空间感知能力。图结构中边的权重由用户对内容的评分或交互频次表示。借助图卷积网络的传播机制，模型能够在图结构中进行多层次的邻接特征聚合，挖掘用户与内容之间的深层偏好关系，从而实现个性化的内容推荐。在此基础上，FGL 通过构建用户间的图结构关系，结合用户的交互历史与社交信息，挖掘用户群体中的协同特性与潜在偏好，并在联邦学习框架下进行多轮本地训练与全局

为三元组 (u, i, f) ，其中 i 为用户点击或观看过的内容(正样本)， f 为用户未产生过任何交互的内容(负样本)。BPR 的优化目标是通过优化模型参数，最大化用户在正负样本上的排序差距，其目标函数定义为：

$$L_{BPR} = - \sum_{(u, i, f) \in D} \ln \sigma(\hat{y}_{u, i} - \hat{y}_{u, f}) - \lambda \|\theta\|^2 \quad (6)$$

其中， σ 为 sigmoid 函数， $\hat{y}_{u, f}$ 为用户 u 对内容 f 的偏好概率， λ 为正则化系数， θ 为模型参数。

完成 BPR 优化后，每个 SBS 根据用户当前位置和联合偏好模型的预测结果，利用学习到的模型参数 θ 计算各候选内容的偏好分数，并生成排序后的个性化推荐列表，将该推荐列表传输至用户下一时段所处的目标 SBS，作为进一步优化推荐-缓存策略的依据。

3 缓存与推荐联合优化模型

在获得每个用户的个性化推荐列表后，鉴于推荐机制能够重塑用户的请求行为^[15]，从而对边缘缓存策略的有效性产生显著影响，在 SBS 侧构建联合推荐与缓存的协同优化框架。具体而言，SBS 在获取个性化推荐列表后，在满足本地缓存容量约束的前提下，采用交替优化推荐与缓存策略，优先在用户未来可能接入的 SBS 节点进行缓存部署，将用户偏好度高且内容流行度较高的内容缓存于边缘侧。对于其他未被缓存的内容，则由 MBS 或 CS 集中调度与内容传输，以保障服务的连续性与系统整体性能。

3.1 用户内容推荐与缓存

(1) 推荐策略

首先，考虑用户偏好的动态变化特性。定义用户 u 对内容 f 的偏好为 $p_{u, f} \in [0, 1]$ ，即表示用户 u

在无推荐机制下请求内容 f 的概率。考虑到用户地理位置会显著影响其偏好分布，进一步引入位置依赖性建模。设用户 u 当前位置为 loc_u ，修正后的用户偏好概率表示为：

$$a_{u, f}^{loc} = p_{u, f} \cdot w_{loc, u, f} \quad (7)$$

其中， $w_{loc, u, f}$ 表示位置影响因子，用户偏好概率满足归一性约束 $\sum_{f \in \mathcal{F}} a_{u, f}^{loc} = 1, \forall u \in \mathcal{U}$ 。

引入推荐机制后，用户请求内容的概率分布受到原始偏好与推荐列表的共同影响。定义推荐变量 $r_{u, f} \in \{0, 1\}$ ，若 $r_{u, f} = 1$ ，表示内容 f 被推荐给用户 u ，否则表示未被推荐。全局推荐策略表示为 $r = \{r_{u, f} \mid f \in \mathcal{F}, u \in \mathcal{U}\}$ 。为控制推荐内容的数量，设为每个用户最多推荐 R_u 个内容，相应的约束条件为：

$$\sum_{f \in \mathcal{F}} r_{u, f} = R_u, \forall u \in \mathcal{U} \quad (8)$$

结合用户偏好与推荐行为，定义用户 u 从推荐列表中请求内容 f 的请求概率为：

$$\hat{a}_{u, f}^{loc} = \frac{r_{u, f} \cdot a_{u, f}^{loc}}{\sum_{f \in R_u} r_{u, f} \cdot a_{u, f}^{loc}} \quad (9)$$

类似地，用户 u 从推荐列表外请求内容 f 的请求概率为：

$$\hat{a}_{u, f}^{loc} = \frac{(1 - r_{u, f}) \cdot a_{u, f}^{loc}}{\sum_{f \in \mathcal{F} \setminus R_u} (1 - r_{u, f}) \cdot a_{u, f}^{loc}} \quad (10)$$

综上，用户 u 对内容 f 的综合请求概率表示为：

$$a_{u, f}^{req} = \Delta_u \hat{a}_{u, f}^{loc} + (1 - \Delta_u) \hat{a}_{u, \bar{f}}^{loc} \quad (11)$$

其中 Δ_u^{loc} 表示用户 u 接受推荐内容的概率。

(2) 缓存策略

考虑 SBS 缓存容量受限，设 SBS j 的最大缓存

容量为 C_j ，则缓存容量约束为：

$$\sum_{f \in F} c_{fj} L_f \leq C_j, \forall j \in J \quad (12)$$

L_f 表示内容 f 的大小， $c_{fj} \in \{0,1\}$ 为缓存变量，当 $c_{fj}=1$ 时，则表示内容 f 被缓存于 SBS j 中；否则，该内容未被缓存。

3.2 问题建模

为了提升用户体验和系统效率，本文旨在通过联合优化推荐与缓存策略，最小化用户获取内容的时延。考虑用户 u 连接至 SBS j 并请求内容 f 时，其可能通过以下三种方式获取请求内容：

情况 1：本地缓存命中。若 SBS j 缓存了请求的内容 f ，则用户可直接下载，获取时延为：

$$T_1 = \frac{L_f}{v_{uj}} \quad (13)$$

其中， v_{uj} 是用户 u 与 SBS j 之间的传输速率。

情况 2：MBS 缓存命中。若 SBS j 未缓存内容 f ，但 MBS 中缓存了该内容，内容先由 MBS 传输至 SBS，再传输至用户，总时延为：

$$T_2 = \frac{L_f}{v_{uj}} + \frac{L_f}{v_s} \quad (14)$$

其中， v_s 代表 SBS j 与 MBS 之间的传输速率。

情况 3：用户从云端获取内容。若 SBS 和 MBS 均未缓存该内容，用户通过 MBS 请求内容，MBS 需先从核心网或云服务器中下载内容，时延表示为：

$$T_3 = \frac{L_f}{v_{uj}} + \frac{L_f}{v_s} + \frac{L_f}{v_c} \quad (15)$$

其中， v_c 是 MBS 从云端下载内容的速率。

综合以上三种情况，内容获取时延可以建模为：

$$T_{uf}^j = u(c_{fj}) \cdot T_1 + u(1-c_{fj}) \cdot u(c_{f0}) \cdot T_2 + u(1-c_{fj}) \cdot u(1-c_{f0}) \cdot T_3 \quad (16)$$

其中， c_{fj} 是缓存变量， $u(x)$ 是阶跃函数，用于计算

不同情况下的时延。

本文的优化目标是通过联合优化推荐策略和缓存策略，实现用户内容获取过程中的系统总时延最小化，优化模型可表示为：

$$\begin{aligned} \min_{r,c} \quad & \sum_{u \in U} \sum_{f \in F} \sum_{j \in J} a_{u,f}^{req} T_{uf}^j \\ \text{s.t.} \quad & C_1: \sum_{f \in F} L_f c_{fj} \leq C_j, \forall j \in J \\ & C_2: \sum_{j \in J} c_{fj} \leq 1, \forall f \in F \\ & C_3: \sum_{f \in F} r_{uf} \leq R_u, \forall u \in U \\ & C_4: r_{uf} \in \{0,1\}, \forall u \in U, f \in F \\ & C_5: c_{fj} \in \{0,1\}, \forall j \in J, f \in F \end{aligned} \quad (17)$$

其中，条件 C_1 限制了 SBS 缓存内容大小总和不超过最大缓存容量； C_2 限制了每个内容最多缓存于一个 SBS； C_3 对每个用户的推荐列表大小进行约束；而 C_4 和 C_5 则分别表示推荐和缓存变量均为 0-1 变量。

3.3 问题求解

由于推荐-缓存优化问题为 NP-hard 问题，为降低求解复杂度，本文采用交替优化将该问题解耦为推荐优化和缓存优化^[16]两个子问题，并通过迭代逐步逼近最优解。整体求解流程如下：

(1) 优化推荐策略：在缓存策略固定的前提下，系统根据用户偏好分布及地理位置信息估算每个内容的请求概率。然后，利用一对一交换算法优化每个用户的推荐列表，以提高推荐命中率和系统效率。每次推荐内容交换操作的时间复杂度为 $O(M)$ ，其中 M 为推荐列表大小；对所有 U 个用户进行优化，总时间复杂度为 $O(U \times M)$ 。

(2) 优化缓存策略：在推荐策略确定的情况下，系统依据用户请求概率与内容访问路径计算单位缓存空间带来的边际收益，采用贪婪策略优先缓存请求概率较高内容，直到整体收益无法继续增加。可知每个基站的缓存优化复杂度为 $O(J \times L \times \log(L))$ ，其

中 J 为基站数量, L 为内容数目。

(3) 联合优化流程: 推荐与缓存策略在交替优化框架下不断迭代, 两者相互作用, 推荐策略根据用户偏好和缓存命中情况调整请求概率; 缓存策略反向影响推荐列表选择, 系统在若干轮迭代后收敛至一个在推荐准确性与内容时延之间权衡优化的解, 最终达到全局最优或局部最优。联合优化算法的伪代码如算法 1 所示。

3.4 收敛性与复杂度分析

为增强联合推荐-缓存交替优化算法的理论严谨性, 本节对算法的收敛性与计算复杂度进行分析。设式(17)的目标函数为 $F(R, C)$, 其中 R 与 C 分别表示推荐与缓存的 0-1 决策变量。为保证目标函数单调下降, 本文在两阶段更新中采用严格改进接受准则: 仅当候选更新使 F 降低时才接受, 否则保持上一轮解不变。因此, 在推荐阶段与缓存阶段分别有: $F(R(n), C(n-1)) \leq F(R(n-1), C(n-1))$ 和 $F(R(n), C(n)) \leq F(R(n), C(n-1))$ 。将两式合并可得式(18)的非单调增长目标序列:

$$F(R(n), C(n)) \leq F(R(n-1), C(n-1)), \forall n \quad (18)$$

由于 $F(R, C)$ 表示系统总时延, 显然有下界 $F(R, C) \geq 0$, 因此序列 $\{F(R(n), C(n))\}$ 一定收敛于某个有限值。进一步地, 内容条目有限且 R, C 均为 0~1 离散并受缓存容量与推荐长度等约束, 可行解空间为有限集合。在严格改进接受准则下, 只要发生被接受的更新, 目标值就会严格下降, 而严格下降在有限集合上不可能无限次发生; 因此当不存在可接受更新时算法将在有限步内达到稳定解 (R^*, C^*) 。在仿真实验时, 设置最大迭代次数 N 作为上界, 算法将在 $\min\{N, N^*\}$ 轮内停止, 其中 N^* 为达到稳定解所需的迭代次数, 且该稳定解满足局部最优性质。

计算复杂度方面: 假设第 n 轮迭代中, 推荐优化阶段采用一对一交换策略对每个用户的推荐列表

进行更新, 若推荐列表长度为 M 、用户数为 U , 则该阶段复杂度为 $O(U \times M)$ 。缓存优化阶段对每个 SBS 在 L 个候选内容上计算边际收益并按收益排序, 单个 SBS 复杂度记为 $O(L \times \log(L))$, 网络中 J 个 SBS 的复杂度为 $O(J \times L \times \log(L))$ 。因此, 交替优化在最多 N 轮迭代下的总体复杂度为 $O(N \times (U \times M + J \times L \times \log(L)))$, 空间复杂度主要由请求概率、收益与决策变量存储构成, 为 $O(U \times L + J \times L)$ 。

算法 1 基于位置预测与用户偏好预测的联合优化算法

输入: 用户历史请求数据, 位置数据, 所有用户与文件的特征, 全局用户与基站的状态信息, 迭代次数 N

输出: 推荐策略 r , 缓存策略 c

1. 根据位置信息进行预测, 并将用户历史请求数据、用户特征和物品特征进行预处理后一并输入联邦 GCN 模型进行训练, 预测得到系统内所有用户对所有内容的偏好
2. 初始化用户推荐决策 $r(0)$, 每个用户的推荐列表为该用户偏好最高的 R 个内容
3. 初始化基站缓存决策 $c(0)$, 每个 SBS 缓存所有接入用户中流行度最高的内容
4. 令 $n=1$
5. while $n \leq N$ do
6. 将 $c(n-1)$ 输入一对一交换算法, 得到全局推荐决策 $r(n)$
7. 将 $r(n)$ 输入贪婪算法, 得到全局缓存决策 $c(n)$
8. $n=n+1$
9. end

4 仿真与性能分析

本文的仿真环境基于 Python 3.8。为全面评估所提算法的有效性, 本文构建了由多源真实数据驱动的仿真平台, 并采用以下数据集及参数配置。首先, 采用斯坦福大学的 SUMATRA 移动活动数据集作为用户移动模式的训练数据, 并结合来自旧金山湾区 BALI-2 实时位置数据集, 用于位置预测模型的训练与仿真验证^[17]。此外, 为客观评估用户偏好建模的准确性, 引入 Yelp 数据集作为用户内容偏好数据源

[18]。具体而言，从 BALI-2 数据集中提取 102 名用户在 90 个位置区域的活动记录，并与用户的内容访问与评价信息进行匿名关联匹配，构建用于偏好预测的联合数据集。其他仿真参数见表 1 所示。

表 1 仿真参数取值
Tab.1 Parameter Settings

参数	值
宏基站数	1
小基站数	4
用户数	20
工作频率 f (GHz)	2GHz
基站带宽 B (MHz)	5
小基站功率 (dBm)	24
每个小基站缓存容量 C_j (MB)	600
推荐内容个数	5
文件大小范围 (KB)	[1000, 2000]

图 3 对比了 Transformer 与 Bi-LSTM 在用户位置预测任务中的准确率表现。实验结果表明，Bi-LSTM 的表现优于 Transformer，这是由于其双向结构能够同时捕捉过去和未来的位置信息，增强对用户短期轨迹变化的建模能力，进而有效挖掘时间序列中的局部时间依赖关系。Transformer 虽具备处理长序列的全局建模能力，但在处理短时序数据时，计算复杂度较高，尤其在数据规模较小的场景中，其优势不明显，导致用户位置预测准确率较低。




图 3 Bi-LSTM 和 Transformer 准确率对比图
Fig.3 Comparison of Accuracy: Bi-LSTM vs Transformer
图 4 展示了不同推荐算法在 RMSE (均方根误差) 和 F1 分数两个指标下的性能对比。实验结果表明，联邦 GCN 在两个指标上均表现最优，主要得益于其融合了图卷积网络对用户偏好的建模优势，并引入联邦学习框架实现了数据分布式训练，在保障用户隐私的同时提高了模型的泛化能力。传统 GCN 虽能利用图结构信息实现用户行为与内容建模，但未考虑隐私保护机制；NeuralCF^[19]借助 MLP 捕捉非线性交互关系，但对于稀疏数据的适应能力较弱；传统协同过滤 (CF)^[20]方法面临冷启动和数据稀疏性问题，且未能深入挖掘非线性特征交互；联邦 GAT 引入注意力机制对图中邻节点进行加权建模，但其计算复杂度较高，在系统资源受限的场景中，整体性能差于所提联邦 GCN。

图 4 对比了 Transformer 与 Bi-LSTM 在用户位置预测任务中的准确率表现。实验结果表明，Bi-LSTM 的表现优于 Transformer，这是由于其双向结构能够同时捕捉过去和未来的位置信息，增强对用户短期轨迹变化的建模能力，进而有效挖掘时间序列中的局部时间依赖关系。Transformer 虽具备处理长序列的全局建模能力，但在处理短时序数据时，计算复杂度较高，尤其在数据规模较小的场景中，其优势不明显，导致用户位置预测准确率较低。




图 4 不同推荐模型性能对比图
Fig.4 Performance Comparison of Different Recommendation Models

为了评估所提优化方案的有效性，本文设计了消融实验。分别移除推荐机制（算法 1）、移除推荐与缓存联合优化模块（算法 2）以及移除位置预测模块（算法 3），并与本文所提算法进行对比分析，系统评估各模块的性能贡献。此外，本文还引入 LRU (Least Recently Used) 与 LFU (Least Frequently Used) 作为传统缓存基线算法进行对比。图 5 展示了系统总时延随用户数量变化趋势。仿真结果表明，随着用户数量的增加，系统总时延整体上升，本文

提出的优化方案始终保持最低的时延水平，表现出良好的扩展性与鲁棒性。对比算法 1 由于缺乏个性化推荐机制支持，无法提升缓存命中率，导致时延显著增加；算法 2 虽具备用户偏好建模能力，但因未进行推荐和缓存的联合优化，导致推荐精度不足，缓存效率降低；算法 3 则因无法适应用户位置信息的动态变化，造成内容分发路径非最优，因而时延高于所提方案，进一步验证了位置预测的重要性。LRU 算法在不同用户规模下整体时延最高，主要原因在于其仅依据“最近访问”进行被动替换，难以稳定捕捉长期偏好与跨用户共性需求，在负载上升时更容易出现缓存内容与真实请求分布不匹配，从而导致更多回源传输；LFU 相比 LRU 略有优势，说明“按访问频次”能够在一定程度上保留热门内容并提升命中率，但仍无法处理个性化需求和时空动态，整体性能落后于本文方案。

图 6 展示了系统缓存命中率随缓存容量变化的趋势。仿真结果表明，随着缓存容量的增加，系统整体缓存命中率显著提升，且不同算法间的性能差异逐渐扩大。由于本文提出的优化方案融合了推荐机制、BPR 排序算法、位置预测模型以及基于 GCN 的用户偏好建模，随着 SBS 缓存容量的增加，内容与用户需求的匹配精度提升，实现缓存命中率的最大化。而对比算法 1 由于缺乏智能推荐功能，在各容量场景下的命中率始终最低；算法 2 虽引入了推荐机制和位置预测，但由于推荐精度受限，缓存命中率低于所提优化方案；算法 3 因无法实时捕捉用户空间行为特征，导致缓存内容与动态需求的匹配度下降，其命中率也低于所提出策略。LFU 的命中率整体高于 LRU，表明频次驱动策略在静态热门内容存在时更能保持缓存有效性，但两者均缺乏对用户个性化偏好、推荐反馈以及空间迁移行为的刻画，因此命中率仍明显低于本文算法。




图 5 不同用户数下的系统总时延
Fig.5 Total System Delay under Different Numbers of Users




图 6 SBS 缓存容量变化下的缓存命中率
Fig.6 Impact of SBS Cache Size on the Cache Hit Ratio

5 结束语

本文提出了一种融合 Bi-LSTM 和联邦图学习的动态推荐与缓存优化策略。通过引入 Bi-LSTM 模型进行用户位置预测，实现了对用户动态服务需求的精细刻画；同时，基于联邦图神经网络对用户偏好建模，并结合 BPR 排序模型生成个性化推荐列表，在提升推荐性能的同时兼顾用户数据隐私保护。仿真结果表明，所提出的推荐与缓存联合优化策略在降低系统总时延、提升缓存命中率和优化资源利用效率方面较现有方法具有明显的性能提升。未来研究将面向更复杂的用户行为模式和高度动态的网络环境，探索多模态数据融合在个性化推荐与边缘缓存策略中的应用潜力及优化机制。

参考文献:

- [1] ZHAO L, YANG J, LIU H, et al. Active caching in cloud radio access networks[J]. IEEE Transactions on Network and Service Management, 2021, 17(3): 2452-2464.
- [2] 张双玲,杨守义,李富康.信任环境下 D2D 辅助边缘计算的缓存卸载优化[J]. 无线电通信技术,2025,51(3):564-575. DOI:10.3969/j.issn.1003-3114.2025.03.016.
- [3] SHI S, ZHANG X, ZHAO L, et al. A distributed caching strategy based on user preference and content popularity[J]. IEEE Transactions on Communications, 2021, 67(5): 4238-4251.
- [4] ZHANG X, ZHAO L, SARWAR B M, et al. Video content delivery with cooperative caching using game theory[J]. IEEE Transactions on Multimedia, 2022, 24: 1515-1526.
- [5] ZHAO L, YANG J, LIU H, et al. Active caching in cloud radio access networks[J]. IEEE Transactions on Network and Service Management, 2021, 17(3): 2452-2464.
- [6] LI X, SUN Y, CHEN M, et al. Personalized caching in MEC: Deep reinforcement learning meets user heterogeneity[J]. IEEE Internet of Things Journal, 2024, 11(2): 1453-1465.
- [7] WANG M, YANG J, LIU H, et al. Recommendation-aware caching in edge networks[J]. IEEE Transactions on Network and Service Management, 2020, 18(6): 1142-1154.
- [8] YANG J, LIU H, ZHANG Y, et al. Small cell networks with cache-aware recommendation mechanism[J]. IEEE Wireless Communications Letters, 2022, 8(3): 852-855.
- [9] LIU H, CHEN Y, ZHANG H, et al. Optimization of cache efficiency using recommendation mechanism[J]. IEEE Transactions on Wireless Communications, 2021, 18(4): 1867-1881.
- [10] CHEN Y, ZHANG Y, SARWAR B M, et al. Bundling recommendations and caching for revenue maximization[J]. IEEE Transactions on Signal Processing, 2020, 69: 3354-3367.
- [11] 王朝炜, 杜嘉楠, 王程, 等. 软件定义卫星网络中基于业务调度的混合路由算法[J]. 电子学报, 2024,52(5): 1506-1515.
- [12] 江帆, 梁晓, 孙长印, 等. 雾无线接入网中基于内容流行度和信息新鲜度的缓存更新策略[J]. 电子与信息学报, 2022, 44(09): 3108-3116.
- [13] ZHANG H, LI T, SHI S, et al. Federated graph learning for privacy-preserving content recommendation and caching[J]. IEEE Transactions on Communications, 2023, 71(9): 6884-6897.
- [14] DWORK C, ROTH A. The algorithmic foundations of differential privacy[J]. Foundations and Trends® in Theoretical Computer Science, 2014, 9(3-4): 211-407.
- [15] 王汝言, 蒋昊, 唐桐, 等. 用户请求感知的边端缓存与用户推荐联合优化策略[J]. 电子与信息学报, 2024, 46(07): 2850-2859.
- [16] 朱琦, 陈晓奇. 一种基于多基站协作的推荐和缓存联合优化方法 [J]. 中国专利, 2022, 专利号: CN202210305642.7.
- [17] Stanford University, "Stanford University Mobile Activity TRAcEs (SUMATRA)," 2022.
- [18] Yelp Inc. (2023). Yelp Dataset (Version 2023.06) [Dataset]. Yelp. <https://www.yelp.com/dataset>.
- [19] KHAN A, ALJUMAILY H, ALSAKRAN J, et al. Evaluating the effectiveness of collaborative filtering similarity measures: A comprehensive review[J]. Procedia Computer Science, 2024, 235: 2641-2650.
- [20] SARWAR B, KARYPIS G, KONSTAN J, et al. A survey of collaborative filtering techniques[J]. ACM Computing Surveys (CSUR), 2020, 52(6): 1-30.

作者简介:

江帆, 女, (1982-), 博士, 教授, 主要研究方向为 D2D 通信、雾计算、边缘计算及内容缓存等。

刘喜宁, 女, (2001-), 硕士生, 主要研究方向为 D2D 通信、雾计算、边缘计算及内容缓存。

刘磊, 男, (1989-), 博士, 讲师, 主要研究方向为信息时效性建模及优化、非正交多址接入等。

张雪薇, 女, (1993-), 博士, 副教授, 主要研究方向为宽带无线通信、无线边缘缓存及计算、无线资源规划及分配等。

王朝炜, 男, (1982-), 博士, 北京邮电大学副教授、博士生导师, 主要研究方向为 AI 赋能空天地一体化网络、语义通信和多址接入技术等。