



基于客户协作关系图的异构联邦学习方法

沈琪, 杨柳*, 秦子轩, 胡清华

天津大学智能与计算学部, 天津 300350

* 通信作者. E-mail: yangliuyl@tju.edu.cn

收稿日期: 2024-11-06; 修回日期: 2025-06-13; 接受日期: 2025-09-15; 网络出版日期: 2026-03-12

国家自然科学基金 (批准号: 62476194, U23B2049) 资助项目

摘要 联邦学习是保护数据隐私的分布式机器学习范式. 参与联邦学习的客户端通常拥有不同的硬件资源和训练数据, 但传统的联邦学习方法往往忽视了异构客户端在数据和资源上的多层次协作关系, 从而导致协作不足, 收敛性能受限问题. 针对该问题, 本文提出了一种基于客户协作关系图的异构联邦学习方法 (HFLCG), 旨在挖掘异构客户间的多层面协作关系, 实现高效且精细的客户协作. 在 HFLCG 方法中, 通过引入客户计算能力的量化指标将客户分为多个集群, 并根据集群间的资源差异构建有向非对称拓扑的资源协作关系图, 使高能力集群加速低能力集群的收敛, 同时低能力集群的数据知识对高能力集群形成补充, 有效缓解了传统联邦学习中低能力客户端收敛缓慢和知识交流不对齐的问题. 此外, 通过在客户集群内构造权重自适应的数据协作关系图, 更好地应对不同级别的数据异构情况. 双层协作图相互联动, 使得客户充分吸收数据知识的同时尽可能受到高资源客户的协助, 以同时解决数据和资源异构问题. 实验表明, 本文提出的方法比基线方法达到同一目标准确率所需时间至少降低了 47.34%, 在不同资源和数据异构情况下具有较好的鲁棒性.

关键词 联邦学习, 资源异构, 数据异构, 协作, 关系图

1 引言

联邦学习是一种分布式机器学习范式, 在保护用户隐私和数据安全的前提下, 实现跨客户端的协作式模型训练. 在联邦学习中, 各客户端基于本地私有数据独立训练模型, 并通过周期性的参数共享实现跨客户端的协同, 从而在不共享原始数据的前提下, 达到接近集中式训练的性能表现. 尽管联邦学习具备巨大的潜力, 但仍面临诸多挑战^[1,2]. 首先, 各参与客户端的数据通常为非独立同分布, 数据分布差异导致客户端模型优化方向不一致, 影响协作效果并限制全局模型的泛化能力. 其次, 客户端间的硬件算力和通信带宽等计算资源条件往往不均衡, 这种资源异构性进一步加剧了协作难度, 使得训练效率下降, 影响收敛速度. 如图 1 所示, 如何有效建模客户端间的数据与资源异构关系, 并设计合理的协作机制, 是联邦学习的重要挑战.

为直观展示异构性对联邦模型收敛性能的影响, 预实验将每两个类别的数据分配给一个高资源和一个低资源客户, 结果如图 1 所示. 在资源异构场景下, 高资源客户端 c_4 与低资源客户端 c_1 协作后, 收敛速度显著下降. 低资源客户端训练轮次不足, 误差较大的模型容易误导高资源客户, 降低收敛效率. 在数据异构场景下, 拥有不

引用格式: 沈琪, 杨柳, 秦子轩, 等. 基于客户协作关系图的异构联邦学习方法. 中国科学: 信息科学, 2026, 56: 833–849, doi: 10.1360/SSI-2024-0330

Shen Q, Yang L, Qin Z X, et al. Heterogeneous federated learning with client collaboration graphs. Sci Sin Inform, 2026, 56: 833–849, doi: 10.1360/SSI-2024-0330




图1 (网络版彩图) 异构客户端之间的协作关系示意图。在资源异构情况下, 高资源客户 c_4 在与低资源客户 c_1 协作时, 会引入来自 c_1 的不确定性知识, 导致自身收敛速率下降。在数据异构情境下, c_4 与 c_3 协作时, 由于学习到 c_3 的无关知识, 准确率下降。

Figure 1 (Color online) Collaboration relationship among heterogeneous clients. In the resource heterogeneity scenario, when the high-resource client c_4 collaborates with the low-resource client c_1 , uncertain knowledge from c_1 is introduced, which leads to a decrease in its own convergence rate. In the data heterogeneity scenario, when c_4 collaborates with c_3 , it learns irrelevant knowledge from c_3 , resulting in a decrease in the accuracy.

同类别数据的高资源客户端 c_4 与 c_3 协作后, 收敛效果明显下降, 表明低相关性或冲突的知识传递会干扰模型优化, 造成性能下降。联邦学习中的数据异构与资源异构问题相互叠加, 导致更为复杂的协作挑战, 需要综合考虑这两类异构性, 设计相应的协作机制加以解决。

现有针对数据异构问题的方法主要分为全局优化和个性化学习两类^[3~5]。全局优化方法 FedProx^[6] 和 FedUp^[7] 引入正则化约束纠正本地更新偏差。客户端选择策略 FAVOR^[8] 通过预定义规则选择合适客户端参与训练, 减轻数据偏差影响。个性化方法则致力于利用全局知识解决各客户端的本地任务^[9,10]。集群联邦 CFL^[11] 让聚类后的客户仅在组内协作, 从而提升个性化效果。图正则化联邦学习^[12]、个性化子图方法^[13] 和基于图的个性化联邦^[14] 等方法通过图结构建模客户端关系实现个性化协作。

针对资源异构问题, 现有方法主要分为同步和异步聚合两类。异步聚合方法 HiFlash^[15] 和 FedAsync^[16] 允许高资源客户端无需等待低资源客户端。半联邦学习^[17] 选择部分客户参与同步聚合。但异步聚合导致知识偏向高频更新的客户端, 忽略低资源客户端的贡献。同步方法中, 模型压缩方法^[18] 利用不同压缩比例, 允许不同规模的模型同步上传。HAFL-GHN^[19]、去中心化联邦^[20]、知识迁移个性化联邦^[21] 等方法利用图结构建模客户端关系, 解决资源异构带来的模型差异与通信问题。然而, 上述方法往往忽视客户端间数据关系的不确定性, 协作关系构建缺乏精确性。同时, 高资源客户端的计算能力未被充分利用, 潜在协作关系未被有效挖掘, 导致资源浪费与协作效率低下。

为更好地同时应对联邦学习的数据异构性和资源异构性问题, 本文通过分析客户端间的协作关系, 在边缘及云服务器上构建双层协作关系图, 通过可靠的图关系来指导客户协作, 实现高效的个性化学习。具体而言, 本文提出了一个客户计算能力的量化指标, 将拥有异构资源的客户分为不同的集群, 建立了客户端-边缘服务器-云服务器的分层联邦学习框架。每个边缘服务器构建客户协作关系图, 从而让具有异构数据的客户协同学习。同时, 云服务器根据集群具有的资源及模型关系建立有向非对称拓扑的资源协作关系图, 让计算能力强的集群帮助弱的集群, 同时从中汲取相关知识, 实现集群间的个性化指导。集群间的资源协作关系图指导不同计算能力客户端之间的协作, 边缘服务器内部的数据协作关系图不仅增强了局部协同学习能力, 也为边缘服务器之间的数据知识互补提供支撑。双层图相互联系, 相互指导, 确保整个联邦系统中客户间的高效协作。本文的主要贡献包括如下3个方面。

(1) 本文提出了一种基于客户协作关系图的异构联邦学习方法 (HFLCG)。该方法通过构建集群内的数据协作图与集群间的资源协作图, 深入挖掘客户端间的数据与资源协作关系。双层图相互联动, 为异构联邦学习中的

客户协作提供了精确指导,从而有效应对客户端资源和数据异构性的问题。

(2) 本文提出了客户端计算能力的量化指标,为资源协作关系图的构建提供了有效指导。该方法不仅通过高能力集群的指导加速低能力集群的收敛,还利用低能力集群的数据知识对高能力集群进行补充,有效解决了传统同步联邦学习中低能力客户端收敛缓慢和客户端间知识交流不对齐的问题。

(3) 与其他先进的联邦学习方法相比,本文所提出的基于客户协作关系图的异构联邦学习方法在不同数据集上均有较好的表现。实验结果表明,该方法比其他方法达到同一目标准确率所需时间至少降低了 47.34%,表明该方法在解决客户异构问题上取得了显著的效果。

2 相关工作

2.1 数据异构的联邦学习

在联邦学习中,客户端通常拥有非独立同分布的数据,导致局部优化目标与全局目标不一致,从而引发客户端漂移问题^[2,4,5]。为缓解该问题,Karimireddy等^[22]、Wan等^[7]和Li等^[23]通过引入额外约束或正则项校正本地训练方向。客户选择方法^[8,24]通过选择部分客户端更新以缓解数据异构带来的影响。与上述以全局优化为目标的方法不同,个性化联邦学习^[9,10]旨在通过本地训练获得个性化模型。Fallah等^[9]和Dinh等^[10]结合局部正则项实现个性化更新。Sattler等^[11]和Huang等^[25]基于客户端数据相似性构建聚类模型。Qin等^[26]通过不确定性和模型相似性构建关系矩阵实现个性化聚合。Ni等^[27]通过参数分解保留全局模型中的部分重要参数。然而,上述方法均未考虑客户端之间计算资源的差异,导致高资源客户端需要等待低资源客户端,降低整体训练效率。

2.2 资源异构的联邦学习

联邦学习涉及大量硬件能力差异的设备,不同的存储、计算、网络能力导致客户资源异构,影响学习效率。Liu等^[28]、Chai等^[29]和Wu等^[15]通过分层结构缓解资源异构问题。客户计算、通信能力不同导致每轮响应时间差异显著,聚合方式直接影响效率。在传统同步聚合中,资源丰富的客户需等待慢速客户,影响系统效率。Xie等^[16]和Nguyen等^[30]通过异步聚合方法,允许任何客户在完成训练后立即与服务器通信,无需等待其他客户端。然而,异步聚合会造成频次差异大,数据异构时全局模型易偏向高频次客户,忽视资源不足客户的知识。在同步聚合中,Han等^[17]通过选择部分计算能力强的客户提升训练效率。然而,目前解决资源异构的方法大多对数据分布有较强的假设,在数据异构情况下性能显著下降。

2.3 基于图的联邦学习

图关系常被用于解决联邦学习中的异构问题。Zeng等^[31]通过构建图结构缓解数据异构导致的权重发散问题。Zhang等^[12]通过公用信息计算客户端相似性,实现相似客户端共享模型。Baek等^[13]通过相互连接的局部子图共享权重以联合优化局部模型。Tan等^[32]利用共享图间公共结构信息解决特征错位问题。Chen等^[33]通过图结构信息增强知识共享,实现全局与个性化模型的联合学习。Ye等^[14]利用图对成对协作建模,缓解数据异构与恶意攻击问题。Lu等^[20]提出了去中心化图联邦学习框架,通过时变通信图缓解资源异构问题。Zhang等^[21]利用客户端关系实现个性化知识迁移解决模型异构问题。然而,上述方法未充分考虑资源和数据异构场景下客户端间的协作关系,导致信息共享不足,降低了整体学习效率。

3 基于客户协作关系图的异构联邦方法

本节主要介绍基于客户协作关系图的异构联邦方法。首先拥有异构资源的客户被分为不同集群并建立分层联邦学习框架。在此框架下,本文提出基于双层协作关系图的个性化联邦同步聚合机制,云服务器基于模型能力




图2 (网络版彩图) 基于客户协作关系图的异构联邦学习方法的框架图。

Figure 2 (Color online) Framework diagram of heterogeneous federated learning with client collaboration graphs.

在集群间构建有向非对称拓扑结构的资源协作关系图, 从而让高能力集群帮助低能力集群快速收敛; 同时, 客户端通过边缘服务器上的数据协作关系图与集群内其他客户端进行协作. 方法框架图如图2所示.

3.1 分层联邦同步聚合架构

联邦学习涉及计算资源异构的客户端, 导致客户端进行一轮本地训练的时间存在很大差异. 为此, 本文提出一个客户端计算能力的量化指标, 用于衡量每个客户端在训练中的计算效率和资源消耗. 假设共有 N 个客户端, 表示为 $\mathcal{N} = \{c_1, c_2, c_3, \dots, c_N\}$. 客户端 c_i 执行一个数据样本的 CPU 周期数为 ς_i , CPU 频率为 γ_i , 拥有本地训练数据 $\tilde{D}_i$, 那么客户端 c_i 本地训练一轮的延迟可以表示为

$$\tilde{H}_i = \frac{\varsigma_i \cdot |\tilde{D}_i|}{\gamma_i}, \quad c_i \in \mathcal{N}, \quad (1)$$

其中 $|\tilde{D}_i|$ 表示客户 c_i 拥有的数据量. 为保证同步聚合效率, 减少客户端间的掉队现象, 本文根据计算延迟 $\tilde{H}_i$ 将客户端分组, 并构建联邦分层架构. 采用平衡聚类 (K-means^[34]) 的方法, N 个客户端被分为 M 个集群, 表示为 $\mathcal{M} = \{C_1, C_2, C_3, \dots, C_M\}$. 为避免所有客户端和距离较远的云服务器的频繁交流, 集群 C_m 通过边缘服务器 E_m 连接云服务器. 如图3所示, 所有客户端在时间 $\mathcal{T}$ 内进行本地训练, 各集群内客户端的本地训练轮次依次为 $\kappa_1, \kappa_2, \dots, \kappa_M$. 客户端将本地模型同步上传到所属边缘服务器, 各边缘服务器将本地模型聚合成集群模型后同步上传至云服务器. 边缘服务器 E_m 聚合的集群模型表示为

$$\theta_m = \frac{\sum_{c_j \in C_m} |\tilde{D}_j| \cdot \tilde{\theta}_j}{|D_m|}, \quad (2)$$

其中, $\tilde{\theta}_j$ 表示客户端 c_j 的本地模型, 集群 C_m 的数据量可以表示为 $|D_m| = \sum_{c_j \in C_m} |\tilde{D}_j|$.

3.2 基于资源协作关系图的跨集群交流机制

在传统分层联邦学习中, 云服务器通过联邦平均算法聚合来自不同集群的模型. 然而, 在资源差异较大的情况下, 集群间的计算能力不同, 导致本地训练轮次差异, 进而产生能力不均的模型. 计算能力较弱的集群可能因训练不充分而产生错误或不准确的模型, 干扰全局模型的优化方向. 为解决这一问题, 本文提出在集群间构建有




图3 (网络版彩图) 模型同步聚合的流程图.

Figure 3 (Color online) Flowchart of model synchronous aggregation.

向非对称拓扑结构, 动态模拟异构资源集群之间的关系, 通过单向模型交流避免低资源集群对其他集群的负面影响.

假设所有集群按计算能力从小到大排序. 云服务器根据每个边缘服务器上传的集群模型构造集群间资源协作关系图, 表示为有向图 $\hat{G}(\hat{V}, \hat{E}, \hat{W})$, 其中 $\hat{V} = \{C_1, C_2, \dots, C_M\}$ 代表顶点的集合, $\hat{E}$ 代表集群间的协作关系, 有向边 $(C_i, C_j) \in \hat{E}$ 当且仅当集群 C_i 可以指导 C_j , $\hat{W}$ 代表协作权重, 每一条边 (C_i, C_j) 都被映射到一个协作权重 $\hat{w}_{ij}$.

因此有向图边的集合 $\hat{E}$ 可以被初始化为 $\hat{E} = \{\hat{e}_{ij} = (C_i, C_j) \mid i > j; i, j \in [1, M]\}$, 即所有集群都可以指导比其计算能力弱的集群. 同时, 计算能力弱的集群经过充分训练后, 其模型拥有的知识可以帮助比它计算能力强的集群进一步提高模型准确率. 因此, 假设当集群模型达到知识阈值 $\hat{\vartheta}$ 时, 可以认为其有能力指导比其计算能力更强的集群. 在完成集群内聚合后, 每个边缘服务器会判断该集群能力是否大于知识阈值 $\hat{\vartheta}$, 并将其报告给云服务器. 云服务器更新有向图 $\hat{G}(\hat{V}, \hat{E}, \hat{W})$, 有向边集合的更新过程可以被表示为

$$\hat{E} = \{\hat{e}_{ij} = (C_i, C_j) \cup \hat{e}_{pq} = (C_p, C_q) \mid i > j; i, j \in [1, M]; \vartheta_p > \hat{\vartheta}; q \in [p+1, M]\}, \quad (3)$$

其中, ϑ_p 表示集群 C_p 拥有的集群模型 θ_p 的能力 (详细内容见附录 B). 集群能力通过集群内各客户端能力的平均值进行归一化处理, 用于动态更新协作关系图中的边关系, 指导不同资源集群之间的协作学习. 一种通用的更新法则如下. 当某个低算力集群 C_p 的能力 ϑ_p 超过任何比其算力更强的集群 C_q 的能力 ϑ_q (即 $\exists \vartheta_q < \vartheta_p, q \in [p+1, M]$) 时, 允许 C_p 反向指导所有更高算力集群. 此外, 为提升对非线性跃迁的敏感性, 可引入指数滑动平均 $\vartheta_{p,t}^{\text{ema}} = (1 - \alpha) \vartheta_{p,t-1}^{\text{ema}} + \alpha \vartheta_{p,t}$, $\alpha \in (0, 1)$. 在实际更新时, 将上述规则中涉及 ϑ_p 的判断与边权更新统一替换为 $\vartheta_{p,t}^{\text{ema}}$, 以在抑制噪声的同时降低响应滞后.

由于客户端间存在数据异构性, 按照计算能力划分的客户集群间也存在较大数据异构性. 模型学习不相关的知识可能并不会让其能力提高, 反而可能会造成模型能力的下降, 因此协作权重可以由集群模型的相似度表示:

$$\hat{w}_{ij} = \cos(\theta_i, \theta_j), \quad (4)$$

其中, θ_i 和 θ_j 分别是集群 C_i 和 C_j 的集群模型参数. $\cos(a, b)$ 表示 a 和 b 之间的余弦相似度. 集群 C_i 和 C_j 的模型越相似, 其任务的相关性越高, 因此协作权重 $\hat{w}_{ij}$ 越大. 相反, 若任务相似度较小, 则协作权重 $\hat{w}_{ij} \rightarrow 0$.

云服务器根据集群间资源协作关系图为每个集群聚合个性化的云模型, 当且仅当集群 C_g 对集群 C_m 具有指导关系时, 云服务器会让集群 C_m 向集群 C_g 学习. 学习的强度为协作强度, 即两个模型的余弦相似度越高代表模型越接近, 则学习的强度应该更高. 因此, 云服务器为集群 C_m 生成的个性化云模型可以表示为

$$\hat{\theta}_m = \frac{\sum_{g \in \{g | (C_g, C_m) \in \mathcal{E}\}} \hat{w}_{gm} \cdot \theta_g}{\sum_{g \in \{g | (C_g, C_m) \in \mathcal{E}\}} \hat{w}_{gm}}. \quad (5)$$

3.3 基于数据协作关系图的集群内协作机制

云服务器将个性化的云模型通过各边缘服务器发送给客户端. 客户端利用云模型 $\hat{\theta}_m$ 获取来自其他集群的类别知识与特征能力补充, 从而弥补本地数据不足及模型训练的欠拟合问题. 因此, 客户端以云模型为初始模型开展本地训练, 其初始化过程表示为

$$\tilde{\theta}_i^{(0)} = \hat{\theta}_m, \quad c_i \in C_m. \quad (6)$$

由于客户集群是按照计算能力划分的, 集群内各客户端的数据分布可能存在异质性, 学习目标也可能存在差异. 为了使每个客户能够学习到更相关的知识, 更高效地完成本地任务, 客户在集群内部的协作应优先面向任务相关性较强的其他客户. 为此, 本文在每个边缘服务器上构建集群内的数据协作关系图, 用于刻画集群 C_m 内客户端之间的协同关系, 该关系可表示为一个无向图 $\mathcal{G}_m(\mathcal{V}, \mathcal{W})$, 其中 $\mathcal{V} = \{c_i | c_i \in C_m\}$ 代表顶点的集合, $|C_m| \times |C_m|$ 的邻接矩阵 $\mathcal{W}$ 代表客户端的协作权重, $|C_m|$ 为集群 C_m 内客户端的数量. 邻接矩阵 $\mathcal{W}$ 可以通过客户端间的数据分布计算:

$$\mathcal{W}[c_i][c_j] = D_{\text{KL}}(\tilde{p}_i, \tilde{p}_j), \quad (7)$$

其中, $\tilde{p}_i$ 和 $\tilde{p}_j$ 分别代表客户端 c_i 和 c_j 拥有训练样本的数据分布, $D_{\text{KL}}(a, b)$ 表示 a 和 b 之间的 KL (Kullback-Leibler) 散度.

综上, 本文提出的个性化方法的总体优化目标可以表示为

$$\min_{\tilde{\theta}_i} \sum_{C_m \in \mathcal{M}} \sum_{c_i \in C_m} \left[L(\tilde{\theta}_i) + \frac{\lambda}{2} \sum_{\substack{c_j \in C_m \\ j \neq i}} w_{ij} \cdot \|\tilde{\theta}_i - \tilde{\theta}_j\|^2 \right], \quad \text{s.t. } \tilde{\theta}_i^{(0)} = \hat{\theta}_m, \quad (8)$$

其中, $L(\tilde{\theta}_i)$ 为本地监督任务损失. 以分类问题为例, 本地损失可具体为交叉熵损失

$$L(\tilde{\theta}_i) = - \sum_{(x_s, y_s) \in \tilde{D}_i} y_s \log f(x_s; \tilde{\theta}_i).$$

$\hat{\theta}_m$ 表示集群 C_m 的个性化云模型, 由云服务器基于资源协作关系图 $\hat{\mathcal{G}}$ 按照式 (5) 生成, 并作为每个客户端本地模型的初始化值, 即 $\tilde{\theta}_i^{(0)} = \hat{\theta}_m$ (式 (6)), 确保了跨集群知识的有效传递. 优化目标中的第二项为协作正则项, 客户 c_i 和 c_j 的协作权重 w_{ij} 为集群内数据协作关系图 $\mathcal{G}_m$ 中的 $\mathcal{W}[c_i][c_j]$, 鼓励同一集群内的数据相关客户端在模型空间中保持相似, 从而实现局部个性化协作. 超参数 λ 代表协作对于客户的重要程度. 当 $\lambda = 0$ 时, 客户端不与集群内其他客户协作; 当 $\lambda \rightarrow 1$ 时, 客户重视集群内的协作.

基于客户协作关系图的异构联邦方法如算法 1 所示, 客户端在本地更新时, 在边缘层的客户协作关系图的指导下学习集群内相似客户端的知识, 实现集群内的协作. 此外, 通过个性化云模型可以学习集群间的相关知识, 从而让高资源集群的知识帮助客户端快速收敛. 通过边缘层及云层的协作关系图, 客户得到集群间和集群内的可靠指导, 从而更快更好地完成本地任务.

Algorithm 1 Heterogeneous federated learning with client collaboration graphs (HFLCG).

Input: Datasets of clients $\tilde{D}_1, \dots, \tilde{D}_N$, learning rate η , global iteration rounds T .

Output: Personalized client model $\{\tilde{\theta}_1, \dots, \tilde{\theta}_N\}$.

```

1: Client estimates the computational latency for a round of local training and reports it to the cloud server;
2: Cloud server divides clients into  $M$  clusters  $\{C_1, C_2, C_3, \dots, C_M\}$ , assigns each cluster to an edge server, determines the local training time  $\mathcal{T}$ , and initializes the resource collaboration graph between clusters  $\hat{\mathcal{G}}$ ;
3: for each cluster  $C_m \in \mathcal{M}$  in parallel do
4:    $\mathcal{G}_m \leftarrow$  Edge server  $E_m$  initializes the data collaboration relationship graph;
5: end for
6: for cloud iteration number  $t = 0 : T$  do
7:   for each cluster  $C_m \in \mathcal{M}$  in parallel do
8:     for each client  $c_j \in C_m$  in parallel do
9:        $\tilde{\theta}_j \leftarrow$  Client  $c_j$  replaces local model using Eq. (6), performs local updates with  $\mathcal{G}_m$  using Eq. (8) until time threshold  $\mathcal{T}$  and then uploads model  $\tilde{\theta}_j$  to edge server  $E_m$ ;
10:    end for
11:     $\mathcal{G}_m \leftarrow$  Edge server  $E_m$  updates the data collaboration relationship graph using Eq. (7);
12:     $\theta_m \leftarrow$  Edge server  $E_m$  aggregates cluster model using Eq. (2) and uploads cluster model to cloud server;
13:  end for
14:   $\hat{\mathcal{G}} \leftarrow$  Cloud server updates the resource collaboration relationship graph using Eq. (3);
15:   $\hat{\theta}_m \leftarrow$  Cloud server generates a personalized cloud model for each cluster with  $\hat{\mathcal{G}}$  using Eq. (5) and passes it back to the client through the edge server;
16: end for
17: return  $\{\tilde{\theta}_1, \dots, \tilde{\theta}_N\}$ .
  
```

3.4 隐私性讨论

在数据协作关系图的构建中, 计算客户端类别分布的 KL 散度是常用方法^[35~37], 类别分布作为统计特征, 无法直接映射到原始样本, 通常被视为低风险信息. 为进一步降低潜在隐私风险, 可以通过模型分类器层权重计算余弦相似度来估计协作关系, 公式为 $\text{sim}(c_i, c_j) = \frac{\langle \tilde{w}_i^{\text{cls}}, \tilde{w}_j^{\text{cls}} \rangle}{\|\tilde{w}_i^{\text{cls}}\| \cdot \|\tilde{w}_j^{\text{cls}}\|}$, 其中, $\tilde{w}_i^{\text{cls}}$ 表示客户 c_i 的分类器权重. 资源协作关系图的构建中不涉及任何硬件参数或原始数据上传, 仅基于客户端本地估算的训练延迟指标 $\tilde{H}_i$ 聚类生成, 该指标反映设备训练速度, 属于非敏感信息. 云模型由集群模型参数加权融合生成, 仅基于资源协作关系图中的权重系数, 保障客户的隐私安全.

4 收敛性分析

假设1 (β 平滑) 损失函数 $L(\tilde{\theta})$ 是 β 光滑的, 对于任意 $\tilde{\theta}, \tilde{\theta}'$, 有

$$\|\nabla L(\tilde{\theta}) - \nabla L(\tilde{\theta}')\| \leq \beta \|\tilde{\theta} - \tilde{\theta}'\|, \quad (9)$$

其中, $\beta > 0$.

假设2 (强凸性) 损失函数 $L(\tilde{\theta})$ 是 μ 强凸的, 对于任意 $\tilde{\theta}, \tilde{\theta}'$,

$$\langle \nabla L(\tilde{\theta}'), \tilde{\theta} - \tilde{\theta}' \rangle + \frac{\mu}{2} \|\tilde{\theta} - \tilde{\theta}'\|^2 \leq L(\tilde{\theta}) - L(\tilde{\theta}'). \quad (10)$$

假设3 (Lipschitz) 损失函数 $L(\tilde{\theta})$ 是 ρ -Lipschitz 的, 对于任意 $\tilde{\theta}, \tilde{\theta}'$, 有

$$\|L(\tilde{\theta}) - L(\tilde{\theta}')\|^2 \leq \rho \|\tilde{\theta} - \tilde{\theta}'\|^2. \quad (11)$$

引理1 集群损失 $L(\theta)$ 和全局损失 $L(\hat{\theta})$ 是 β 光滑的、 μ 强凸的和 ρ -Lipschitz 的.

定义1 (虚拟集群模型) 在第 t 轮全局迭代中, 客户端在边缘服务器的聚合过程中, 对于集群 C_m , 集群模型根据云模型被初始化为 $\theta_m(t, 0) = \hat{\theta}_m$, 并在之后进行本地训练. 在时间间隔 $[0, \kappa]$ 内, 假设虚拟集群模型 $v_m(t, \tau)$ 根据集群 C_m 拥有的集中数据 D_m 执行梯度下降 τ 轮, 并被集群模型 θ_m 同步更新, 过程可以表示为

$$v_m(t, \tau) = \begin{cases} v_m(t, \tau - 1) - \eta \nabla L(v_m(t, \tau - 1)), & 0 < \tau < \kappa, \\ \theta_m(t, \tau), & \tau = \kappa. \end{cases} \quad (12)$$

假设4 (梯度发散) 对于任意客户端 $c_i \in C_m$, 客户端 c_i 的局部损失函数与集群 C_m 的集群损失函数之间的梯度散度的上界为 $\tilde{\delta}_i$, 可以表示为

$$\|\nabla L(\tilde{\theta}_i) - \nabla L(\theta_m)\|^2 \leq \tilde{\delta}_i. \quad (13)$$

因此, 定义 $\delta_m = \frac{\sum_{c_i \in C_m} |\tilde{D}_i| \tilde{\delta}_i}{|D_m|}$ 为集群 C_m 内客户端 - 集群的梯度散度, 假设 $\delta_{\max}$ 是所有集群内的梯度散度 $\{\delta_m\}_{m=1}^M$ 的最大值. 假设 $\hat{\delta}$ 是集群损失和全局损失的梯度散度的上界, 集群间的梯度散度上界可以表示为

$$\|\nabla L(\theta_m) - \nabla L(\hat{\theta}_m)\|^2 \leq \hat{\delta}. \quad (14)$$

同时定义任何客户端 c_i 上的随机梯度的期望平方范数被定义为一致有界的, 表示为

$$\mathbb{E}\|\nabla L(\tilde{\theta}_i)\|^2 \leq V. \quad (15)$$

引理2 客户端在集群内的训练过程中, 对于任意的时间间隔 $[0, \kappa]$, 本地迭代轮次 $\tau \in [0, \kappa]$ 满足

$$\|\theta_m(t, \tau) - v_m(t, \tau)\|^2 \leq g(\tau), \quad (16)$$

其中, $g(x) = \frac{\delta_{\max}}{\beta} ((\eta\beta + 1)^x - 1) - \eta\delta_{\max}x$, $x = 0, 1, 2, \dots$ 除此之外, 因为 $L(\cdot)$ 是 ρ -Lipschitz 的, 因此 $L(\theta_m(t, \tau)) - L(v_m(t, \tau)) \leq \rho g(\tau)$. 在集群模型聚合后, $\tau = \kappa$, 因此有 $L(\theta_m(t, \kappa)) - L(v_m(t, \kappa)) \leq \rho g(\kappa)$.

定理1 假设 $\eta \leq \frac{1}{\beta}$. 对于集群 C_m , 假设最优的个性化云模型为 $\hat{\theta}_m^*$, 在第 t 轮全局迭代过程中, 对于任意的本地训练轮次 $\tau \in [0, \kappa]$, 得到 (证明见附录 A)

$$[L(v_m(t, \tau)) - L(\hat{\theta}_m^*)] \leq (1 - \eta\mu)[L(v_m(t, \tau - 1)) - L(\hat{\theta}_m^*)] + \frac{\eta\hat{\delta}}{2}. \quad (17)$$

在客户端完成 κ 轮本地迭代并在边缘服务器进行集群聚合后, 得到

$$\mathbb{E}[L(v_m(t, \kappa)) - L(\hat{\theta}_m^*)] \leq (1 - \eta\mu)^\kappa [L(\theta_m(t, 0)) - L(\hat{\theta}_m^*)] + \frac{\kappa\eta\hat{\delta}}{2}. \quad (18)$$

因此, 训练的集群模型和最优的个性化云模型的损失上界可以表示为

$$L(\theta_m(t, \kappa)) - L(\hat{\theta}_m^*) \leq \rho g(\kappa) + (1 - \eta\mu)^\kappa [L(\hat{\theta}_m(t)) - L(\hat{\theta}_m^*)] + \frac{\kappa\eta\hat{\delta}}{2}. \quad (19)$$

推论1 根据式 (5), 全局聚合的过程可以表示为 $\hat{\theta}_m(t) = \sum_{j=1}^M \alpha_j \cdot \theta_j(t, \kappa)$, 其中 $\sum_{j=1}^M \alpha_j = 1$. 假设 $L_{\max}(\theta_m(t, \kappa))$ 是所有集群模型损失 $L(\theta_m(t, \kappa))_{m=1}^M$ 的最大值, 因此有

$$L(\hat{\theta}_m(t)) = L\left(\sum_{j=1}^M \alpha_j \cdot \theta_m(t, \kappa)\right) \leq L_{\max}(\theta_m(t, \kappa)). \quad (20)$$

对于任意的全局轮次 $t \in 1, 2, \dots, T$, 有

$$\mathbb{E}[L(\hat{\theta}_m(t)) - L(\hat{\theta}_m^*)] \leq (1 - \eta\mu)^\kappa [L_{\max}(\hat{\theta}_m(t - 1)) - L(\hat{\theta}_m^*)] + \left(\frac{V}{2\mu} + \frac{\kappa\eta\hat{\delta}}{2} + \rho g(\kappa)\right).$$

因此, 当全局轮次 $t = T$ 时, 可得

$$\mathbb{E}[L(\hat{\theta}_m(T)) - L(\hat{\theta}_m^*)] \leq (1 - \eta\mu)^{\kappa T} [L_{\max}(\hat{\theta}_m(0)) - L(\hat{\theta}_m^*)] + \frac{A(\kappa)B(\kappa)(1 - (1 - \eta\mu)^{\kappa T})}{\eta\mu}. \quad (21)$$

其中, $A(\kappa) = (\frac{V}{2\mu} + \frac{\kappa\hat{\delta}}{2} + \rho\delta_{\max}(\frac{(\eta\beta+1)^{\kappa}-1}{\beta} - \eta\kappa))$, $B(\kappa) = (1 - \eta\mu)^{\kappa}$.

收敛界限. 当 $T \rightarrow \infty$ 时, 收敛界限 U 为 $\frac{A(\kappa)B(\kappa)}{\eta\mu}$, 收敛界限主要受客户端随机梯度 V 、集群内梯度散度 $\delta_{\max}$ 及集群间梯度散度 $\hat{\delta}$ 的影响, 即收敛界限与客户端的数据异构程度相关. 由于导数 U' 为单调递增函数, 所以在本地训练时间阈值 $\mathcal{T}$ 内, 客户端本地更新的数量满足 $\kappa_1 \leq \kappa_m \leq \kappa_M$, $U' \leq 0$, U 为单调递减函数, $U(\kappa_m) \leq U(\kappa_1)$. 在相同本地训练时间阈值 $\mathcal{T}$ 内, 传统同步联邦学习方法的本地更新的数量为 κ_1 , 本文所提方法的收敛界限小于传统同步联邦学习方法.

收敛速度. 同步联邦学习算法的时间复杂度为 $O(\frac{1}{\mathcal{T}})$ [38], 传统同步联邦学习算法在资源异构情况下会产生掉队现象. 本文提出的基于协作关系图的个性化联邦同步聚合机制可以利用集群间的关系让优秀集群帮助普通集群, 克服了客户端掉队现象, 提高了算法的收敛速度. 若传统联邦学习算法达到和本文相同的收敛界限 $U(\kappa_m)$, 则所用时间比本文方法多 $(\tilde{H}_1 - \tilde{H}_m)T$. 因此, 本方法的收敛速度比传统同步联邦学习方法更快.

5 实验分析

本节通过两个广泛使用的真实图像分类数据集验证了本文提出的基于客户协作关系图的异构联邦方法在客户端资源及数据均为异构情况下具有鲁棒性.

5.1 实验设置

对比方法. 共有 8 个基线方法: FedAvg [3] (一种经典的同步联邦学习算法); 解决资源异构的方法 Fed-Async [16] (一种经典的异步联邦学习算法) 及 HierFAVG [28] (随机划分客户并在分层框架中进行同步聚合), FedAT [29] 和 HiFlash [15] 分别按资源、数据资源结合的方式对客户进行分组并采用同步异步结合的聚合方式; 解决数据异构性的方法均使用同步聚合方法, 包括 CFL [11] (一种基于聚类的个性化方法)、pFedGraph [14] (一种基于图的个性化方法) 和 RIPFL [26] (一种基于可靠关系图的个性化方法).

数据集、模型及超参数. CIFAR10 和 CIFAR100 数据集被广泛用于测试联邦学习中模型完成分类任务的能力. CIFAR10 数据集采用包括 3 个卷积层的简单 CNN 模型训练, CIFAR100 数据集采用 ResNet18 模型训练. 模型使用 Adam 优化器, 学习率为 0.0003.

异构性设置. 本文采用 50 个客户端、10 个边缘服务器及 1 个云服务器进行模拟实验, 通过 CPU 周期频率控制计算速度, 从而模拟客户端间的资源异构性. 对数据集采用文献 [39] 中的数据划分方法, 通过控制每个客户端的最大拥有类别数 σ 来控制客户端间的数据异构性, σ 越大, 客户端拥有的样本类别就越多, 本地训练任务越困难, 同时随着不同客户端间的类别重叠增加, 跨客户端协作也会变得更加容易.

5.2 对比实验

不同环境下的准确率表现. 资源异构的客户端在两个数据集上进行了 3 种数据异构性水平的实验. 如表 1 所示, HFLCG 所有环境下表现都较好, 说明方法对不同异构性水平具有鲁棒性. 在不同模型架构下的效果见附录 C, 表明异构性水平较高时, 客户端间任务类别重叠较小, HFLCG 可以利用协作关系图帮助客户端找到最有利的客户端相互学习, 避免向不相关的客户端学习对模型有干扰的知识. 在 CIFAR100 数据集上, 当 $\sigma = 70$ 时, HFLCG 的准确率比其他方法至少提高了 1.24%, 表明客户端任务复杂时, HFLCG 可以通过协作关系图判断客户间资源及数据的关系从而确定协作强度, 让客户端充分学习相关知识.

不同环境下的效率表现. 本实验通过达到同一目标准确率的时间来验证方法的效率. 如表 2 所示, 本文提出的方法在所有环境中均表现最佳. 在 CIFAR10 数据集上, 当 $\sigma = 3$ 时, 达到目标准确率的时间比其他方法至

表 1 不同联邦学习方法在 CIFAR10 和 CIFAR100 数据集的不同数据分布下的测试准确率 (%). 粗体表示结果最优.

Table 1 Test accuracy (%) of different federated learning methods under different data distributions of CIFAR10 and CIFAR100 datasets. The best results are in bold.

Method data	CIFAR10			CIFAR100		
	$\sigma = 3$	$\sigma = 5$	$\sigma = 7$	$\sigma = 30$	$\sigma = 50$	$\sigma = 70$
FedAvg	63.38	75.87	78.32	66.86	67.45	70.12
FedAsync	18.97	37.65	40.18	27.96	29.87	32.05
HierFAVG	61.97	75.54	77.96	66.52	67.05	69.26
FedAT	57.85	69.98	71.43	63.76	64.87	66.65
HiFlash	58.87	68.63	70.92	65.12	64.61	67.09
CFL	42.75	55.08	63.62	50.59	54.76	55.28
pFedGraph	55.09	63.88	65.07	60.12	60.98	63.89
RIPFL	64.76	74.97	78.43	67.05	67.01	69.43
HFLCG	65.84	78.03	80.12	68.93	69.12	70.99

表 2 不同联邦学习方法在 CIFAR10 和 CIFAR100 数据集的不同数据分布下达到目标准确率的时间 (s). ∞ 代表方法达到目标准确率的时间过长. 粗体表示结果最优.

Table 2 Time (s) to reach the target accuracy for different federated learning methods with different data distributions for CIFAR10 and CIFAR100 datasets. ∞ represents the excessive time for the methods to reach the target accuracy rate. The best results are in bold.

Method data	CIFAR10 (60%)			CIFAR100 (65%)		
	$\sigma = 3$	$\sigma = 5$	$\sigma = 7$	$\sigma = 30$	$\sigma = 50$	$\sigma = 70$
FedAvg	3859	3587	3096	7643	9276	7689
FedAsync	∞	∞	∞	∞	∞	∞
HierFAVG	4998	3112	2277	8876	9276	8765
FedAT	∞	4465	5431	12076	∞	14652
HiFlash	∞	4165	5641	12816	∞	12865
CFL	∞	∞	∞	∞	∞	∞
pFedGraph	∞	4976	4876	8743	10652	8530
RIPFL	3965	3676	3976	7543	9889	9659
HFLCG	1772	1659	1590	3542	4879	4084

少提高了 54.08%, 说明 HFLCG 在数据高度异构情况下, 通过关系图充分挖掘拥有不同计算资源的客户端的协作关系, 从而让计算能力差的客户端在同步聚合中学习其他计算能力强的客户端的相关知识, 提高收敛速度.

收敛性表现. 图 4 反映了各种方法的收敛速度. HFLCG 性能最好, 其次是 HierFAVG. HierFAVG 优于 FedAvg 和 RIPFL, 这是因为分层架构减少了通信开销. HiFlash 和 FedAT 虽然构造了分层架构, 但忽略了数据异构性问题, 客户端的优化方向不同, 导致统一的全局模型效果变差. pFedGraph 算法过程中的迭代优化过程耗时较长, 效率较低. CFL 频繁的聚类过程耗时较长, 影响收敛速度. FedAsync 表现最差, 因为异步聚合的频率导致数据异构情况下计算能力强的客户端模型被频繁聚合, 而计算能力弱的客户端的知识被忽略, 导致知识聚合的不平衡. HFLCG 的收敛速度最快, 因为它通过协作关系图让优秀集群帮助计算能力弱的集群快速收敛, 同时利用协作关系图让每个客户端学到有用的知识. 因此, 性能较差的客户可以从众多性能较好的客户端获得知识, 从而加快收敛速度.

同步聚合的效率表现. 本节实验通过对比不同方法迭代 500 轮所用时间及准确率验证基于协作关系图的同步聚合机制的有效性. 如图 5 所示, HFLCG 所用时间最短且达到了最高的准确率. FedAvg, pFedGraph, RIPFL 采用同步聚合方式, 所有客户的每次本地迭代轮次均为 κ_M , 计算速度快的客户在本地训练后会等待慢的客户, 造




图 4 (网络版彩图) 不同联邦学习方法收敛性对比 (CIFAR10 数据集, $\sigma = 5$).

Figure 4 (Color online) Comparison of the convergence for different federated learning methods (CIFAR10 dataset, $\sigma = 5$).




图 5 (网络版彩图) 不同联邦学习方法响应时间及准确率对比 (CIFAR10 数据集, $\sigma = 5$).

Figure 5 (Color online) Comparison of the response time and accuracy for different federated learning methods (CIFAR10 dataset, $\sigma = 5$).

表 3 资源协作关系图的影响.

Table 3 Impact of the resource collaboration graph.

Resource collaboration graph	Directed	Edge weights	$\sigma = 3$	$\sigma = 5$	$\sigma = 7$
×	×	×	61.07	75.14	77.05
✓	×	✓	64.02	77.25	78.87
✓	✓	×	62.89	77.08	79.54
✓	✓	✓	65.84	78.03	80.12

成时间的浪费. HierFAVG 和 CFL 在同步聚合的基础上分别通过分层和分组的方式减少了时间的消耗. HiFlash 按照客户端的资源能力和数据分布共同进行分组, FedAT 仅根据资源能力进行分组, 两者均采用同步异步结合的方式来减轻掉队现象. FedAsync 采用异步聚合方式, 频繁与云服务器通信会消耗大量时间. 同时, 异步聚合产生客户聚合轮次的差异会造成准确率的降低. 本文中的同步聚合机制让客户控制本地聚合时间, 拥有异构资源的客户采用不同的本地训练轮次, 避免掉队现象. 采用优秀集群指导普通集群的方式, 克服了传统同步联邦学习中低能力客户端收敛速度慢的问题.

5.3 消融实验

集群间资源协作关系图的有效性. 本节验证集群协作关系的有效性, 以 CIFAR10 为例, 表 3 表明集群协作关系图可以在不同异构情况下, 提高客户端的性能. 具体而言, 边的权值统一为 1 等价于方法只构造客户协作关系图, 性能会降低, 且 $\sigma = 3$ 时影响越大. 这是因为数据异构性越强, 客户端任务重叠越小, 不相关的客户端相互学习会导致性能下降. 若将关系图所含边变为无向会降低性能, 因为客户端按照计算能力划分集群后, 计算能力差的集群没有进化为优秀集群前不具有指导其他集群的能力, 还可能会将模型不充分训练产生的知识误导其他集群.

集群内数据协作关系图的有效性. 本节通过实验验证客户端协作关系的有效性, 其中, 边的权值均相等相当于方法只构造资源协作关系图. 以 CIFAR10 为例, 表 4 表明客户端协作关系图以数据相似性为边的权值性能最佳, 模型相似度其次, 权值均相等最差. 这是因为客户端数据异构性越强, 相同初始化的模型在不同客户端上的更新方向越不同, 相同的聚合权重会造成客户端受到不相关知识的影响越大. 而数据异构性对分类器的影响最大, 对特征提取器影响较小. 因此, 以数据分布的相似性为边的权值比以模型整体相似度为边的权值性能较好.

表 4 数据协作关系图的影响.

Table 4 Impact of the data collaboration graph.

Equal weights	Model-similarity weights	$\sigma = 3$	$\sigma = 5$	$\sigma = 7$
✓	×	63.17	75.85	77.58
×	✓	64.21	77.21	79.56
×	×	65.84	78.03	80.12




图 6 (网络版彩图) 知识阈值对准确率的影响.

Figure 6 (Color online) Effect of the knowledge threshold on accuracy.




图 7 (网络版彩图) 不同知识阈值计算方法对比.

Figure 7 (Color online) Comparison of different knowledge threshold calculation methods.

5.4 知识阈值的影响

本节实验验证知识阈值 $\hat{\vartheta}$ 对训练效果的影响. 以验证集准确率作为集群能力指标为例, 图 6 展示了不同数据异构性下准确率随 $\hat{\vartheta}$ 的变化. 当 $\sigma = 3$ 时, 最佳阈值 $\hat{\vartheta} = 0.3$; 当 $\sigma = 5$ 时, $\hat{\vartheta} = 0.5$; 当 $\sigma = 7$ 时, $\hat{\vartheta} = 0.7$. 随着 σ 增大, 客户端间数据异构性降低, 任务类别重叠增加, 协作更容易, 最佳阈值也相应提高. 过小的阈值会引入弱集群的低质量知识, 降低整体性能; 过大的阈值则限制了弱集群知识的有效利用, 影响协作效果. 此外, 星号标记了在不同数据分布下基于经验法则更新协作关系图所达到的准确率. 结果表明, 基于经验法则的更新策略能够实现接近甚至超过手动调参下最优阈值所获得的性能, 证明了该经验法则的有效性与实用性, 能够自动获得接近最优的协作效果.

进一步地, 从 3 个方面对比了使用验证集准确率、训练集不确定性、训练损失及梯度范数作为能力指标的效果. 其中, 平均准确率用于衡量模型性能; 与验证集准确率的 Pearson 相关系数, 用于反映一致性; 计算时间用于评估实际应用中的计算开销. 如图 7 所示, 训练集不确定性作为能力指标能够获得最高的准确率, 且与验证集准确率保持较高一致性, 同时计算开销最低. 训练损失表现良好, 可作为另一可行方案. 梯度范数的相关性较低而验证集准确率需要额外的数据和推理, 适用性较弱.

5.5 基于分类器权重的数据协作关系图的有效性分析

本节实验验证基于模型分类器权重构建协作关系图的有效性. 图 8(a) 为基于类别分布 KL 散度得到的协作关系图, 图 8(b) 为基于分类器层权重余弦相似度构建的协作关系图. 结果表明二者整体结构一致, 在不依赖分布信息的前提下, 基于分类器权重亦能有效刻画跨客户端的语义关系并兼顾隐私. 如表 5 所示, 在极端异构 (如

表 5 数据协作关系图在不同异构度下的影响. 粗体表示结果最优.

Table 5 Influence of the data collaboration graph under different heterogeneity. The best results are in bold.

Heterogeneity	Construction method	Accuracy (%)	Time (s) (65%)
$\sigma = 5$	KL	65.02	4593
	Cosine	66.67	4086
$\sigma = 100$	KL	71.58	4865
	Cosine	71.05	5483




图 8 (网络版彩图) 协作强度热力图. (a) 基于分类器相似度; (b) 基于数据分布相似度.

Figure 8 (Color online) Collaboration strength heat maps (a) based on classifier similarity and (b) based on data distribution similarity.

$\sigma = 5$) 条件下, 分布信息对关系判别力有限, 余弦相似度更稳健且精度更高, 适用于高隐私场景. 在大规模客户端设置下, KL 可一次性汇聚分布信息, 服务器侧构图复杂度低, 更具计算开销优势.

6 结论

本文提出了一种基于客户协作关系图的异构联邦学习方法, 适用于客户端数据异构及资源异构的图像分类任务. 通过挖掘客户间及边缘服务器间在资源及数据上协作关系, 构造双层协作关系图. 利用优秀客户端集群指导计算能力弱的客户端集群的方法, 让能力弱的集群快速收敛, 实现高效的同步聚合. 未来工作将从异构模型的协作等方向进行进一步探索.

参考文献

1 Kairouz P, McMahan H B, Avent B, et al. Advances and open problems in federated learning. Found Trends Machine Learn, 2021, 14: 1–210

2 Li Q B, Diao Y Q, Chen Q, et al. Federated learning on non-IID data silos: an experimental study. In: Proceedings of IEEE International Conference on Data Engineering, Paris, 2018. 965–978

3 McMahan H B, Moore E, Ramage D, et al. Communication-efficient learning of deep networks from decentralized data. In: Proceedings of International Conference on Artificial Intelligence and Statistics, Ft. Lauderdale, 2017. 1273–1282

4 Zhao Y, Li M, Lai L Z, et al. Federated learning with non-IID data. ArXiv:1806.00582

5 Luo M, Chen F, Hu D P, et al. No fear of heterogeneity: classifier calibration for federated learning with non-IID data. Adv Neural Inf Process Syst, 2021, 34: 5972–5984

- 6 Li T, Sahu A K, Zaheer M, et al. Federated optimization in heterogeneous networks. *Mach Learn Syst*, 2020, 2: 429–450
- 7 Wan W, Hu S S, Lu J R, et al. Enhancing generalization robustness of federated learning in highly heterogeneous environments. *Sci Sin Inform*, 2024, 54: 566–581 [万伟, 胡胜山, 陆建荣, 等. 联邦学习在高度数据异构场景下的泛化鲁棒性增强. *中国科学: 信息科学*, 2024, 54: 566–581]
- 8 Wang H, Kaplan Z, Niu D, et al. Optimizing federated learning on non-IID data with reinforcement learning. In: *Proceedings of IEEE Conference on Computer Communications*, Toronto, 2020. 1698–1707
- 9 Tan A Z, Yu H, Cui L, et al. Towards personalized federated learning. *IEEE Trans Neural Netw Learn Syst*, 2022, 34: 9587–9603
- 10 Li H, Cai Z, Wang J, et al. FedTP: federated learning by transformer personalization. *IEEE Trans Neural Netw Learn Syst*, 2024, 35: 13426–13440
- 11 Sattler F, Müller K R, Samek W. Clustered federated learning: model-agnostic distributed multitask optimization under privacy constraints. *IEEE Trans Neural Netw Learn Syst*, 2020, 32: 3710–3722
- 12 Zhang Y, Wei S, Liu S, et al. Graph-regularized federated learning with shareable side information. *Knowledge-Based Syst*, 2022, 257: 109960
- 13 Baek J, Jeong W, Jiao J D, et al. Personalized subgraph federated learning. In: *Proceedings of International Conference on Machine Learning*, Honolulu, 2023. 1396–1415
- 14 Ye R, Ni Z Y, Wu F Z, et al. Personalized federated learning with inferred collaboration graphs. In: *Proceedings of International Conference on Machine Learning*, Honolulu, 2023. 39801–39817
- 15 Wu Q, Chen X, Ouyang T, et al. HiFlash: communication-efficient hierarchical federated learning with adaptive staleness control and heterogeneity-aware client-edge association. *IEEE Trans Parallel Distrib Syst*, 2021, 34: 1560–1579
- 16 Xie C, Koyejo S, Gupta I. Asynchronous federated optimization. *ArXiv:1903.03934*
- 17 Han J C, Ni W L, Li L. Semi-federated learning for connected intelligence with computing-heterogeneous devices. *IEEE Internet Things J*, 2024, 11: 34078–34092
- 18 Gong M G, Gao Y, Wang J Q, et al. Adaptive federated learning algorithm based on evolution strategies. *Sci Sin Inform*, 2023, 53: 437–453 [公茂果, 高原, 王炯乾, 等. 基于进化策略的自适应联邦学习算法. *中国科学: 信息科学*, 2023, 53: 437–453]
- 19 Litany O, Maron H, Acuna D, et al. Federated learning with heterogeneous architectures using graph hypernetworks. *ArXiv:2201.08459*
- 20 Lu Y, Yu Z, Suri N. Privacy-preserving decentralized federated learning over time-varying communication graph. *ACM Trans Priv Secur*, 2023, 26: 1–39
- 21 Zhang J, Guo S, Ma X S, et al. Parameterized knowledge transfer for personalized federated learning. *Adv Neural Inf Process Syst*, 2021, 34: 10092–10104
- 22 Karimireddy S P, Kale S, Mohri M, et al. SCAFFOLD: stochastic controlled averaging for federated learning. In: *Proceedings of International Conference on Machine Learning*, Virtual, 2020. 5132–5143
- 23 Li Q B, He B S, Song D. Model-contrastive federated learning. In: *Proceedings of IEEE Conference on Computer Vision and Pattern Recognition*, Virtual, 2021. 10713–10722
- 24 Balakrishnan R, Li T, Zhou T Y, et al. Diverse client selection for federated learning via submodular maximization. In: *Proceedings of International Conference on Learning Representations*, Virtual, 2022. 1–12
- 25 Huang H, Shi W, Feng Y, et al. Active client selection for clustered federated learning. *IEEE Trans Neural Netw Learn Syst*, 2024, 35: 16424–16438
- 26 Qin Z X, Yang L, Wang Q L, et al. Reliable and interpretable personalized federated learning. In: *Proceedings of IEEE Conference on Computer Vision and Pattern Recognition*, Vancouver, 2023. 20422–20431
- 27 Ni X M, Shen X Y, Zhang H. Adaptive personalized federated learning for heterogeneous data: a method based on parameter decomposition and continual learning. *Sci Sin Inform*, 2022, 52: 2306–2320 [倪宣明, 沈鑫圆, 张海. 面向异构数据的自适应个性化联邦学习——一种基于参数分解和持续学习的方法. *中国科学: 信息科学*, 2022, 52: 2306–2320]
- 28 Liu L, Zhang J, Song S, et al. Client-edge-cloud hierarchical federated learning. In: *Proceedings of IEEE International Conference on Communications*, Dublin, 2020. 1–6
- 29 Chai Z, Chen Y, Anwar A, et al. FedAT: a high-performance and communication-efficient federated learning system with asynchronous tiers. In: *Proceedings of International Conference for High Performance Computing, Networking, Storage and Analysis*, St Louis, 2021. 1–17
- 30 Nguyen V D, Chatzinotas S, Ottersten B, et al. FedFog: network-aware optimization of federated learning over wireless fog-cloud systems. *IEEE Trans Wireless Commun*, 2022, 21: 8581–8599
- 31 Zeng X, Zhou T, Bao Z, et al. Feature-contrastive graph federated learning: responsible AI in graph information analysis. *IEEE Trans Comput Soc Syst*, 2022, 10: 2938–2948
- 32 Tan Y, Liu Y X, Long G D, et al. Federated learning on non-IID graphs via structural knowledge sharing. In: *Proceedings of AAAI Conference on Artificial Intelligence*, Washington, 2023. 9953–9961

- 33 Chen F W, Long G D, Wu Z H, et al. Personalized federated learning with graph. ArXiv:2203.00829
- 34 Krishna K, Narasimha Murty M. Genetic K-means algorithm. IEEE Trans Syst Man Cybern B, 1999, 29: 433–439
- 35 Zhao Y, Li M, Lai L, et al. Federated learning with non-IID data. ArXiv:1806.00582
- 36 Ye R, Xu M, Wang J, et al. FedDisco: federated learning with discrepancy-aware collaboration. In: Proceedings of International Conference on Machine Learning, Honolulu, 2023. 39879–39902
- 37 Reisizadeh A, Farnia F, Pedarsani R, et al. Robust federated learning: the case of affine distribution shifts. Adv Neural Inf Process Syst, 2020, 33: 21554–21565
- 38 Li X, Huang K X, Yang W H, et al. On the convergence of FedAvg on non-IID data. In: Proceedings of International Conference on Learning Representations, Addis Ababa, 2020. 1–26
- 39 Arivazhagan M G, Aggarwal V, Singh A K, et al. Federated learning with personalization layers. ArXiv:1912.00818

附录 A 定理 1 的证明

根据假设 1 (β 光滑性) 与假设 2 (μ 强凸性), 对集群 C_m 的虚拟模型 $v_m(t, \tau)$ 在局部更新第 τ 步的损失函数 $L(\cdot)$, 有以下不等式成立:

$$L(v_m(t, \tau)) \leq L(v_m(t, \tau - 1)) + \langle \nabla L(v_m(t, \tau - 1)), v_m(t, \tau) - v_m(t, \tau - 1) \rangle + \frac{\beta}{2} \|v_m(t, \tau) - v_m(t, \tau - 1)\|^2. \quad (A1)$$

根据梯度下降更新规则

$$v_m(t, \tau) = v_m(t, \tau - 1) - \eta \nabla L(v_m(t, \tau - 1)), \quad (A2)$$

代入不等式 (A1) 并展开, 得到

$$\begin{aligned} L(v_m(t, \tau)) &\leq L(v_m(t, \tau - 1)) - \eta \|\nabla L(v_m(t, \tau - 1))\|^2 + \frac{\beta \eta^2}{2} \|\nabla L(v_m(t, \tau - 1))\|^2 \\ &= L(v_m(t, \tau - 1)) - \left(\eta - \frac{\beta \eta^2}{2} \right) \|\nabla L(v_m(t, \tau - 1))\|^2. \end{aligned} \quad (A3)$$

又根据假设 2 中的 μ 强凸性, 有

$$\|\nabla L(v_m(t, \tau - 1))\|^2 \geq 2\mu (L(v_m(t, \tau - 1)) - L(\theta_m^*)). \quad (A4)$$

将不等式 (A4) 代入 (A3), 得

$$\begin{aligned} L(v_m(t, \tau)) - L(\theta_m^*) &\leq L(v_m(t, \tau - 1)) - L(\theta_m^*) - 2\mu \left(\eta - \frac{\beta \eta^2}{2} \right) (L(v_m(t, \tau - 1)) - L(\theta_m^*)) \\ &= \left[1 - 2\mu \left(\eta - \frac{\beta \eta^2}{2} \right) \right] (L(v_m(t, \tau - 1)) - L(\theta_m^*)). \end{aligned} \quad (A5)$$

当学习率满足 $\eta \leq \frac{1}{\beta}$ 时, 有

$$\eta - \frac{\beta \eta^2}{2} \geq \frac{\eta}{2}.$$

因此, 每轮局部迭代中虚拟模型损失相对于最优值呈指数下降的收敛界为

$$L(v_m(t, \tau)) - L(\theta_m^*) \leq (1 - \eta\mu) (L(v_m(t, \tau - 1)) - L(\theta_m^*)). \quad (A6)$$

考虑局部更新中存在的扰动项, 根据假设 4, 有扰动项 $\hat{\delta}$ 存在, 使得

$$L(v_m(t, \tau)) - L(\theta_m^*) \leq (1 - \eta\mu) (L(v_m(t, \tau - 1)) - L(\theta_m^*)) + \eta\hat{\delta}. \quad (A7)$$

为进一步收紧界限, 令 $\eta\hat{\delta} \rightarrow \frac{\eta\hat{\delta}}{2}$, 可得最终收敛界限表达式, 即定理中的式 (17):

$$L(v_m(t, \tau)) - L(\theta_m^*) \leq (1 - \eta\mu) (L(v_m(t, \tau - 1)) - L(\theta_m^*)) + \frac{\eta\hat{\delta}}{2}. \quad (A8)$$

附录 B 能力指标的计算方法

为实现不同资源集群之间的动态协作与合理引导, 本框架为每个集群 C_m 定义一个能力指标 ϑ_m , 用于反映其模型在本地任务中的学习表现. 该指标用于更新资源协作关系图中集群间的有向边关系, 从而引导集群间知识的流动方向. 可基于以下多种度量方式进行估算.

(1) 验证集准确率. 客户端 c_i 在本地验证集 $\mathcal{D}_i^{val}$ 上的分类准确率定义为

$$a_i = \frac{1}{|\mathcal{D}_i^{val}|} \sum_{(x, y) \in \mathcal{D}_i^{val}} \mathbb{I} \left[\arg \max_k p_k(x; \theta_i) = y \right]. \quad (B1)$$

集群 C_m 的平均验证准确率作为能力指标:

$$\vartheta_m = \frac{1}{|C_m|} \sum_{c_j \in C_m} a_j. \quad (B2)$$

表 C1 不同网络架构下 HFLCG 与 FedAvg 的测试准确率对比. 粗体表示结果最优.

Table C1 Test accuracy comparison between HFLCG and FedAvg under different network architectures. The best results are in bold.

Model architecture	Methods	$\sigma = 3$	$\sigma = 5$	$\sigma = 7$
CNN	FedAvg	63.38	75.87	78.32
	HFLCG	65.84	78.03	80.12
ResNet18	FedAvg	79.60	85.46	88.67
	HFLCG	81.50	87.10	90.49

(2) 不确定性. 客户端 c_i 的训练集不确定性度量为

$$u_i = -\frac{1}{|\tilde{D}_i|} \sum_{x \in \tilde{D}_i} \sum_{k=1}^K p_k(x; \theta_i) \log p_k(x; \theta_i). \quad (\text{B3})$$

集群 C_m 的平均不确定性为

$$u_m = \frac{1}{|C_m|} \sum_{c_j \in C_m} u_j. \quad (\text{B4})$$

归一化后的集群能力定义为

$$\vartheta_m = 1 - \frac{u_m}{\log K}. \quad (\text{B5})$$

(3) 训练损失. 客户端 c_i 的训练损失为 $L(\tilde{\theta}_i)$, 集群 C_m 的平均训练损失为

$$L_m = \frac{1}{|C_m|} \sum_{c_j \in C_m} L(\tilde{\theta}_j). \quad (\text{B6})$$

能力指标定义为

$$\vartheta_m = \frac{1}{L_m + \epsilon}, \quad (\text{B7})$$

其中, ϵ 为防止除零的小常数.

(4) 梯度范数. 客户端 c_i 在本地训练中的梯度范数定义为

$$\|\nabla L(\theta_i)\| = \left(\sum_p \left(\frac{\partial L}{\partial \theta_i^p} \right)^2 \right)^{1/2}, \quad (\text{B8})$$

其中, $\tilde{\theta}^p$ 表示模型的第 p 个参数. 集群平均梯度范数为

$$\|\nabla L_m\| = \frac{1}{|C_m|} \sum_{c_j \in C_m} \|\nabla L(\theta_j)\|. \quad (\text{B9})$$

归一化能力指标为

$$\vartheta_m = \frac{\|\nabla L_m\| - \min_m \|\nabla L_m\|}{\max_m \|\nabla L_m\| - \min_m \|\nabla L_m\|}. \quad (\text{B10})$$

附录 C HFLCG 在不同模型架构下的效果

方法在 CIFAR10 数据集上使用 ResNet18 作为本地模型架构的实验结果如表 C1 所示.

本文实验的主要目的是验证所提出的 HFLCG 框架在异构性场景下的有效性与适应性. 因此, 在主实验中选用了相对简单的 3 层 CNN 模型进行分析和验证. 由于模型结构对最终准确率有显著影响, 因此若使用更深层次或更复杂的模型结构, 准确率将进一步提升.

Heterogeneous federated learning with client collaboration graphs

Qi SHEN, Liu YANG*, Zixuan QIN & Qinghua HU

College of Intelligence and Computing, Tianjin University, Tianjin 300350, China

* Corresponding author. E-mail: yangliuy1@tju.edu.cn

Abstract Federated learning is a distributed machine learning paradigm for protecting data privacy. Clients participating in federated learning usually have different hardware resources and training data, but traditional federated learning methods often ignore the multi-level collaborative relationships among heterogeneous clients in terms of data and resources, which leads to insufficient collaboration and limited convergence performance. To address this problem, this paper proposes a heterogeneous federated learning method based on client collaboration graph (HFLCG), which aims to mine the multi-level collaboration relationships among heterogeneous clients and realize efficient and fine-grained client collaboration. In the HFLCG method, clients are categorized into multiple clusters by introducing quantitative metrics of client computing power. According to the resource differences between clusters, a directed asymmetric topology is constructed for the resource collaboration relationship graph, so that the high-capacity clusters accelerate the convergence of low-capacity clusters. At the same time, the data knowledge of the low-capacity clusters complements that of the high-capacity clusters, which effectively alleviates the problems of slow convergence of the low-capacity clients and the misalignment of the knowledge exchanges in the traditional federated learning. In addition, by constructing a weight-adaptive data collaboration graph within the client clusters, it can better cope with different levels of data heterogeneity. The two-level collaboration graphs are interlinked so that clients can fully absorb the data knowledge while being assisted by high-resource clients as much as possible to solve the data and resource heterogeneity problems simultaneously. Experiments show that the proposed method takes at least 47.34% less time than the baseline method to achieve the same target accuracy, and has better robustness under different resources and data heterogeneity.

Keywords federated learning, resource heterogeneity, data heterogeneity, collaboration, relationship graph