



计算机应用研究
Application Research of Computers
ISSN 1001-3695, CN 51-1196/TP

《计算机应用研究》网络首发论文

题目：联邦学习的梯度安全鲁棒聚合算法
作者：王斌，陈运，张磊，陈杰，郑兵
DOI：10.19734/j.issn.1001-3695.2025.09.0442
收稿日期：2025-09-15
网络首发日期：2026-03-19
引用格式：王斌，陈运，张磊，陈杰，郑兵. 联邦学习的梯度安全鲁棒聚合算法[J/OL]. 计算机应用研究. <https://doi.org/10.19734/j.issn.1001-3695.2025.09.0442>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

联邦学习的梯度安全鲁棒聚合算法^{*}王 斌^{1,2,3,4}, 陈 运^{1,2,3}, 张 磊^{1,2,3†}, 陈 杰^{1,2,3}, 郑 兵^{1,2,3}

(1. 佳木斯大学 信息电子技术学院, 黑龙江 佳木斯 154007; 2. 佳木斯大学 信息电子技术学院, 黑龙江省自主智能与信息处理重点实验室, 黑龙江 佳木斯 154007; 3. 佳木斯大学 信息电子技术学院, 佳木斯市卫星导航技术与装备工程技术重点实验室, 黑龙江 佳木斯 154007; 4. 佳木斯大学 科技处, 黑龙江 佳木斯 154007.)

摘 要: 针对联邦学习中梯度面临的中毒攻击威胁和隐私泄露风险, 提出一种联邦学习的梯度安全鲁棒聚合算法(Model-Secure and Robust Aggregation Algorithms for Federated Learning, MSRAFL)。该算法可以在保护客户端数据隐私的前提下, 有效防御恶意客户端发起的梯度中毒攻击, 提升全局模型的鲁棒性和安全性。首先, MSRAFL 引入差分隐私机制, 通过梯度裁剪与高斯噪声注入实现隐私保护; 其次, 设计基于历史梯度的引导方向, 结合余弦相似度与动态可信阈值对梯度进行投影约束, 以纠正由噪声和攻击引起的更新方向偏离; 进一步, 依据客户端模型损失变化评估其可信度, 并联合余弦相似度动态分配聚合权重, 从而抑制恶意梯度的影响。在真实数据集上的实验结果显示, 即使存在 30% 的中毒模型, MSRAFL 仍能将模型准确率维持在约 0.8 的水平, 优于现有同类聚合算法。这表明, MSRAFL 算法能够在严格隐私保护条件下, 有效提升联邦学习系统对中毒攻击的防御能力, 兼顾隐私安全与模型鲁棒性。

关键词: 联邦学习; 中毒攻击; 隐私保护; 差分隐私; 鲁棒聚合

中图分类号: TP309 doi: 10.19734/j.issn.1001-3695.2025.09.0442

Model-secure and robust aggregation algorithms for federated learning

Wang Bin^{1,2,3,4}, Chen Yun^{1,2,3}, Zhang Lei^{1,2,3†}, Chen Jie^{1,2,3}, Zheng Bing^{1,2,3}

(1. School of Information and Electronic Technology, Jiamusi University, Jiamusi Heilongjiang 154007, China; 2. Heilongjiang Province Key Laboratory of Autonomous Intelligence and Information Processing, School of Information and Electronic Technology, Jiamusi University, Jiamusi Heilongjiang 154007, China; 3. Jiamusi Key Laboratory of Satellite Navigation Technology and Equipment Engineering Technology, School of Information and Electronic Technology, Jiamusi University, Jiamusi Heilongjiang 154007, China; 4. Dept. of Science and Technology, Jiamusi University 154007, Heilongjiang, China)

Abstract: To address the threats of gradient poisoning attacks and privacy leakage risks in federated learning, this paper proposes a secure and robust gradient aggregation algorithm named MSRAFL (Model-Secure and Robust Aggregation Algorithms for Federated Learning). The algorithm effectively defends against gradient poisoning attacks launched by malicious clients while preserving client data privacy, thereby enhancing the robustness and security of the global model. First, MSRAFL incorporates a differential privacy mechanism by applying gradient clipping and injecting Gaussian noise to ensure privacy protection. Second, it designs a guidance direction based on historical gradients and combines cosine similarity with a dynamic trust threshold to constrain gradient projections, thereby correcting deviations in the update direction caused by noise and attacks. Furthermore, it evaluates client credibility based on changes in model loss and dynamically assigns aggregation weights using cosine similarity to suppress the impact of malicious gradients. Experimental results on real-world datasets demonstrate that even with 30% of poisoned models, MSRAFL maintains model accuracy at around 0.8, outperforming existing aggregation algorithms. This indicates that MSRAFL effectively enhances the defense capability of federated learning systems against poisoning attacks under strict privacy protection, achieving both privacy security and model robustness.

Key words: federated learning; poisoning attacks; privacy preservation; differential privacy; robust aggregation

0 引言

当前, 人工智能技术驱动工业自动化^[1]、精准医疗^[2]和金融科技^[3]等领域发生深刻变革, 由此产生的复杂、高维的数据正以前所未有的速度激增^[4]。对此, 联邦学习(Federated

Learning, FL)依托分布式计算架构^[5], 将数据处理迁移至网络边缘, 使得原始数据无需离开本地设备即可参与模型构建, 提升系统响应速度的同时规避了数据上传过程中的隐私泄露风险^[6]。然而, 由于本地训练的不可控性, 存在训练出错或恶意客户端对模型实施中毒攻击的情况, 这会严重威胁模型的

收稿日期: 2025-09-15; 修回日期: 2025-11-12 基金项目: 黑龙江省高等学校基本科研业务费优秀创新团队建设项目(2023-KYYWF-0639); 佳木斯大学国家基金培育项目(JMSUGPZR2022-014); 黑龙江省省属本科高校优秀青年教师基础研究支持计划(YQJH2024239); 黑龙江省自然科学基金联合基金培育项目(PL2024F002); 佳木斯大学博士专项科研基金启动项目(JMSUBZ2022-12); 黑龙江省教育厅创新团队项目(2024-KYYWF-0611); 佳木斯大学“东极”学术团队项目(DJXSTD202413)

作者简介: 王斌(1979—), 男, 黑龙江安达人, 教授, 硕导, 博士, CCF 专业会员, 主要研究方向为信息安全、隐私保护; 陈运(1999—), 男, 安徽省合肥市, 硕士研究生, 主要研究方向为联邦学习, 隐私保护; 张磊(1982—), 男(通信作者), 黑龙江绥化人, 教授, 博士, CCF 会员, 主要研究方向为信息安全、隐私保护; 陈杰(2003—), 男, 陕西西安人, 硕士研究生, 主要研究方向为隐私保护; 郑兵(1998—), 男, 山东泰安人, 硕士研究生, 主要研究方向为联邦学习, 隐私保护。

正常训练^[7], 另外, 客户端上传的训练模型仍然有可能泄露用户的隐私信息^[8]。因此, 联邦学习系统面临中毒攻击和推理攻击的威胁^[9]。如何提升系统的安全性仍是当前联邦学习研究的重点。

为了保护联邦学习模型的安全训练, 研究学者提出了各种抵御中毒攻击的措施并结合隐私保护方法, 如同态加密^[10], 安全多方计算^[11]以及差分隐私^[12]为联邦学习正常训练提供安全保障。例如, Dong 等人提出了 AegisFL^[13], 通过同态加密和安全多方计算技术, 实现对本地模型更新的安全聚合; 并基于本地模型更新与全局模型的余弦相似度和 L2 范数, 计算客户端的信任评分, 并利用这些评分动态调整聚合策略。Ma 等人提出了一种名为 ShieldFL^[14]的防御策略, 使用双陷阱门同态加密以保护梯度中的数据隐私, 测量两个加密梯度之间的余弦相似性实现模型安全聚合。Cheng 等人提出 FBL-BP 联邦学习框架^[15], 采用差分隐私技术保护客户端的隐私, 基于余弦相似度的异常值去除机制保证了全局模型的鲁棒性。Ying 等人提出了联邦学习框架 PPBR-FL^[16], 使用本地差分隐私机制来实现对客户端的隐私保护, 并提出了一种名为 TPM(剪裁填充均值)的拜占庭鲁棒聚合规则来实现鲁棒性。

相较于需要复杂密码学操作的加密方法和通信较高的安全多方计算, 差分隐私(DP)被视为一种更优的隐私保护方法。参数可以在本地训练中被扰动, 从而使攻击者无法获取真实的参数, 但是噪声的添加也会阻碍恶意模型的识别, 因此保护隐私的同时还需要考虑到对抗中毒攻击的问题。对此, 本文基于恶意检测和本地差分隐私构建了个联邦学习算法。首先, 通过引入本地差分隐私, 以加强对推理攻击的防御。其次, 利用余弦投影校正偏离正常方向的梯度, 最后, 结合模型的损失值变化量和余弦相似性识别潜在的中毒攻击者并赋予相应的聚合权重, 实现模型的安全鲁棒聚合。本文所提出的联邦学习模型能够在安全性和隐私性之间取得平衡, 抵御中毒攻击和推理攻击的威胁。本文主要贡献如下:

- 基于差分隐私机制, 在客户端训练的梯度中添加噪声, 保护客户端数据安全。
- 基于余弦投影, 对客户端训练的梯度进行修正, 集中梯度方向, 减小不正常的更新方向对模型聚合的干扰。
- 结合客户端模型训练前后损失值变化量和梯度相似性对抗恶意模型攻击, 确保模型安全聚合。
- 在真实数据库上对所提方案进行了评估, 实验结果表明, 该方案能够实现对模型参数的保护和抵御中毒攻击, 保证模型安全聚合。

1 预备知识

1.1 联邦学习系统架构

联邦学习系统架构^[17]通常由 N 个客户端构成, 记为 $\{p_1, p_2, \dots, p_N\}$, 每个客户端拥有一个私有数据集 $D_i = \{(x_i, y_i)\}$, 每轮训练中客户端接收服务器下发的全局模型 w_G , 利用全局模型和本地数据训练本地梯度。并将训练出的本地梯度上传至中心服务器, 聚合得出新一轮的全局模型。这个过程迭代进行, 最终完成模型训练。联邦学习系统架构如图 1 所示。

从图 1 中可以看出, 联邦学习通过多轮客户端和服务端协作实现模型训练, 典型算法为联邦平均算法 Fedavg^[18], 在本地训练中客户端 p_i 基于本地数据更新本地模型 w_i^{t+1} 和本地梯度 g_i , 其中 t 表示训练轮次, η 表示学习率, S 表示一个批次的数据, x 表示本地数据中的一个样本, y 表示样本

标签, $L_i(w)$ 表示本地损失函数。

$$w_i^{t+1} = w_G^t - \eta \left(\frac{1}{|S|} \nabla L_i(x, y, w_G^t) \right) \quad (1)$$

$$g_i = w_i^{t+1} - w_G^t \quad (2)$$




图 1 联邦学习系统架构

Fig. 1 Federated learning system architecture

中央服务器得到本地梯度后会评估每个梯度的聚合权重, Fedavg 算法根据客户端拥有数据量的大小设置其权重值 λ_i , 具体如式(3)所示, 其中 $|N_i|$ 表示客户端 p_i 的数据量大小, $|N|$ 表示所有客户端的数据总量。

$$\lambda_i = \frac{|N_i|}{|N|} \quad (3)$$

最后, 服务器根据聚合权重聚合新一轮的全局模型参数。

$$w_G^{t+1} = w_G^t + \sum_{i=1}^N \lambda_i g_i \quad (4)$$

1.2 安全风险

从联邦学习系统架构中可以看出, 即使将数据保留在客户端本地, 仍然无法确保客户端梯度训练的安全, 恶意攻击者能够对部分客户端发起中毒攻击, 这些攻击者可以修改客户端拥有的本地数据或者篡改传输过程中的梯度参数, 从而危害模型的训练。另外, 梯度如果以明文的形式传输仍然存在用户隐私泄露的风险。

1.2.1 中毒攻击

中毒攻击是一种针对分布式机器学习系统的安全威胁, 攻击者通过篡改本地数据或梯度参数, 破坏全局模型的性能或植入恶意功能^[19,20]。常见的有数据中毒攻击和模型中毒攻击, 以下是其主要类型及技术特点的总结:

数据中毒攻击^[21]: 攻击者在本地训练数据中注入恶意样本, 影响模型训练过程, 隐蔽性强, 通常不影响正常数据的预测结果, 仅在触发条件下激活异常行为, 例如标签翻转攻击^[22], 攻击者通过修改本地数据标签以干扰模型学习, 如将“猫”标签改为“狗”, 具体可见式(5), 其中 m 是数据集最大类

别数, $l \in \{0, 1, \dots, m-1\}$ 。

$$(x_l, y_l) \rightarrow (x_l, y_{m-l-1}) \quad (5)$$

模型中毒攻击^[23]: 攻击者直接篡改本地模型参数或梯度更新, 干扰全局模型的聚合过程, 破坏性更强, 可能直接导致模型失效或后门植入, 例如符号反转攻击^[24], 攻击者将梯度符号置反, 通过改变原本的方向来误导模型更新方向, 导致全局模型偏离正常收敛方向, 具体可见式(6)所示, 其中 $R=-1$ 。

$$g_i = Rg_i \quad (6)$$

1.2.2 隐私泄露

本文方案中假设服务器是诚实但好奇的, 即服务器会忠实地执行所需要的功能, 但是会通过推理手段尝试破解客户端提交的梯度中所包含的隐私信息。另外, 客户端和服务端之间的信息传输可能会被攻击者劫持, 以明文形式传输梯度参数可能会泄露客户端数据隐私。

1.3 算法思想

MSRAFL 算法要求客户端提交的参数应该受到保护, 不会被恶意攻击者或好奇的服务器推理出其中的隐私信息。对此, MSRAFL 算法利用差分隐私的高斯机制^[25], 如式(7)实现对客户端梯度的隐私保护。

$$\Pr[M(D) \in S] \leq e^\epsilon \cdot \Pr[M(D') \in S] + \delta \quad (7)$$

其中, S 表示输出事件集合, M 表示一个随机算法(或机制), D 和 D' 表示只有一个样本数据不同的相邻数据集, $\epsilon \geq 0$, 表示隐私预算, 越小表示隐私保护越强, $\delta \geq 0$, 表示以很小的概率可以违背差分隐私。

客户端在梯度中添加满足高斯机制的噪声后上传梯度参数。但是, 梯度中添加的高斯噪声和恶意客户端上传的中毒梯度在更新方向上会偏离正常的全局模型方向, 因此, MSRAFL 算法服务器记录客户端梯度和全局梯度的余弦相似值, 其中 g_i 表示本地梯度, g_G 表示全局梯度。

$$\cos \theta_i = \langle g_i, g_G \rangle \quad (8)$$

然后, 根据其中的良性梯度与全局梯度的余弦相似值设定鲁棒阈值, 对超过阈值的梯度利用余弦投影纠正偏离的方向, 减小梯度方向的偏离程度, 使得梯度的更新方向更加集中。

在模型聚合前还需要对梯度进行模型质量评估, 计算器聚合的权重, 防止其中的中毒梯度对模型聚合的破坏, MSRAFL 算法在本地训练开始前利用全局模型计算本地模型的损失值。

$$L_i = \frac{1}{|N_i|} \sum_{(x_i, y_i) \in D_i} l(x, y, w_G) \quad (9)$$

在训练完成后再一次计算模型的损失值, 客户端提交两次计算的模型损失值, 服务器计算前后两次损失值的变化量, 并结合梯度的余弦相似值计算梯度的聚合权重, 其中, 中毒梯度会被惩罚性的赋予较小的权重, 从而确保模型聚合的安全。

2 MSRAFL 算法

本文算法基于传统联邦学习架构设计, 在客户端本地训练中对梯度进行扰动以保护隐私; 在服务器端设计了一系列安全保护措施抵御中毒攻击, 其中包括设置梯度规范引导, 梯度投影约束, 服务器安全聚合, 以下将对这些操作进行具体描述。

2.1 客户端梯度扰动

为了保护客户端上传到服务器的数据安全, 引入噪声对客户训练模型的梯度数据进行扰动, 考虑到高斯噪声更常用且效果较好, 本文选择高斯噪声。客户端在梯度上添加噪声:

$$\tilde{g}_i = g_i + N(0, \sigma^2 I) \quad (10)$$

其中 σ 为噪声强度, I 是与梯度维度相同的单位矩阵。为避免梯度太大, 导致噪声过大, 在添加噪声之前根据灵敏度设定裁剪阈值 C , 然后对梯度进行裁剪以控制梯度的敏感度。

$$g'_i = g_i / \max(1, \|g_i\|_2 / C) \quad (11)$$

客户端操作的算法过程如下:

算法 1 客户端训练阶段

输入: 全局模型 w_G^t 。

输出: 梯度 $\tilde{g}_i$, 损失值 L_{pre} , L_{post} 。

for $i=1$ to N

$p_i \leftarrow w_G^t$ // 客户端接收全局模型

$L_{pre} = \frac{1}{|N_i|} \sum_{(x_i, y_i) \in D_i} l(x, y, w_G^t)$ // 计算训练前本地损失

$w_i^{t+1} = w_G^t - \eta \left(\frac{1}{|S|} \nabla L_i(x, y, w_G^t) \right)$ // 计算本地模型

$g_i = w_i^{t+1} - w_G^t$ // 计算客户端梯度

$L_{post} = \frac{1}{|N_i|} \sum_{(x_i, y_i) \in D_i} l(x, y, w_i^{t+1})$ // 计算训练后本地损失

$g'_i = \text{clip}(1, C)$ 裁剪梯度

$\tilde{g}_i = g'_i + \text{noise}$ 添加高斯噪声

return $\tilde{g}_i, L_{pre}, L_{post}$

end for

客户端训练阶段的操作流程中每个参与训练的客户端接收全局模型, 为了防止客户端伪造前后两次的模型损失值, MSRAFL 算法随机选取部分客户端利用本地数据计算训练前的模型损失 L_{pre} 并提交给聚合服务器, 然后, 客户端训练本地梯度, 所有客户端利用训练得到的模型计算训练后的模型损失, 另外, 客户端对梯度裁剪并加入噪声, 最后提交梯度和模型损失值。

2.2 梯度规范引导

客户端利用本地数据训练本地梯度的过程中, 因为噪声添加或中毒攻击等情况, 训练得到的梯度会有不同程度的差异, 为了避免这种情况 MSRAFL 算法为客户端训练梯度设置一个参考梯度和动态可信阈值用以约束客户端训练的梯度。具体计算方式如下。

2.2.1 参考梯度

在第 t 轮训练时, 服务器聚合正常客户端的梯度得到全局梯度, 因为服务器端的防御操作, 所得到的全局梯度是安全且正确的, 而且, 相邻训练轮次之间的模型差异较小, 所以可以选择第 t 的全局梯度作为第 $t+1$ 轮客户端训练的参考梯度。

$$g_{ref}^{t+1} = g_G^t \quad (12)$$

为避免梯度幅值对方向约束的干扰, 对参考梯度进行归一化处理, 其中 v 是一个极小值, 防止除零错误。

$$g_{ref}^t = \frac{g_{ref}^t}{\|g_{ref}^t\|_2 + v} \quad (13)$$

2.2.2 动态可信阈值

动态可信阈值需根据客户端更新的分布特性自适应调整, 避免固定阈值导致的过拟合或欠防御。以下是具体策略。

服务器记录过去 t 轮(如 $t=3$)内所有客户端更新与参考梯度的余弦相似值:

$$\cos_i^t = \frac{g_i^t \cdot g_{ref}^t}{\|g_i^t\|_2} \quad (14)$$

因为正常模型的更新是合理且相似的, 所以假设合法更新的余弦相似度服从截断正态分布 $N(\mu, \sigma^2)$, 均值和方差选

取鲁棒统计量, 其中均值 μ 使用中位数而非算术平均, 抵抗异常值干扰。标准差选用中位数绝对偏差 MAD (Median Absolute Deviation), 计算每个余弦值与中位数的绝对差值, 再取这些差值的中位数, 用于衡量数据的离散程度。此外, 将 MAD 乘以 1.4826 (正态分布修正系数, 该系数用于将 MAD 转换为标准差的估计值^[26], 适用于正态分布假设), 转化为近似标准差。

$$MAD = \text{median}(|\cos_i^t - \text{median}(\cos_i^t)|) \quad (15)$$

$$\sigma = 1.4826 \cdot MAD \quad (16)$$

设定阈值的目的是为了保持梯度更新方向的一致性, 根据正态分布特性, 中位数 $-2 \times$ 标准差, 确保覆盖约 95% 的合法客户端。另外, 设置安全下限 (如 $\cos_{\min} = 0.2$), 防止阈值过低导致防御失效。最终阈值角度 θ_{trust}^t 通过反余弦函数计算。

$$\theta_{\text{trust}}^t = \arccos(\max(u - \gamma\sigma, \cos_{\min})) \quad (17)$$

梯度规范引导算法执行过程如算法 2 所示。

算法 2 梯度规范引导

输入: 客户端梯度 $\tilde{g}_i$ 。

输出: 全局梯度 g_G^t , θ_{trust}^t 。

$g_{\text{ref}}^t \leftarrow g_G^{t-1}$ // 设置参考梯度

$g_{\text{ref}}^t = \frac{g_{\text{ref}}^t}{\|g_{\text{ref}}^t\|_2 + \nu}$ // 梯度归一化

for $i=1$ to N

$\cos_i^t = \frac{g_i^t \cdot g_{\text{ref}}^t}{\|g_i^t\|_2 \|g_{\text{ref}}^t\|_2}$ // 计算余弦相似度

end for

// 计算均值 μ 和标准差 σ

$\theta_{\text{trust}}^t = \arccos(\max(u - \gamma\sigma, \cos_{\min}))$ // 计算可信阈值

return g_G^t , θ_{trust}^t

梯度规范引导通过设定标准的参考梯度和可信阈值, 为后面校正不良梯度提供一个标准, 减轻恶意梯度对训练的干扰, 加快模型收敛。

2.3 梯度投影约束

联邦学习中客户端利用本地数据训练自己的梯度, 其中正常的客户端会训练出方向大体一致的梯度参数, 而添加噪声的梯度和恶意客户端中毒攻击的梯度则会在方向上偏离正常的梯度参数。这些梯度在直观上如图 2 所示。




图 2 梯度方向图

Fig. 2 Gradient direction diagram

其中 g_{ref} 表示服务器根据所有客户端梯度计算出的梯度良性方向, g_{ref} 和 g_i 之间的夹角 θ_{trust} 表示梯度更新的可信阈值, 若超过这个角度阈值表示梯度更新的质量较差或为恶意更新, 反之则为正常更新。当发现梯度更新和参考梯度之间的夹角超过阈值时, 根据向量投影原理, 对其进行投影处理, 如图中的梯度 g_i , 其与参考梯度之间的夹角 $\theta_i > \theta_{\text{trust}}$, 调整其垂直分量, 使投影后梯度满足:

$$\|g_i' - \text{proj}_{g_{\text{ref}}}\|_2 \leq \|g_i\|_2 \sin \theta_{\text{trust}} \quad (18)$$

服务器对客户端的梯度更新进行约束的具体过程如下。首先, 服务器计算本地梯度和参考梯度的余弦相似度 $\cos \theta_i$, 根据动态可信阈值 θ_{trust} , 若 $\theta_i > \theta_{\text{trust}}$, 则需对本地梯度进行投影。首先, 对梯度进行方向分解, 将梯度 g_i 分解为两个正交向量: 平行分量和垂直分量。

平行分量: 沿参考梯度方向的分量

$$g_i^{\parallel} = \left(\frac{g_i \cdot g_{\text{ref}}}{\|g_{\text{ref}}\|_2^2} \right) g_{\text{ref}} \quad (19)$$

垂直分量: 与参考梯度正交的分量

$$g_i^{\perp} = g_i - g_i^{\parallel} \quad (20)$$

对余弦相似度超过阈值的梯度, 调整其垂直分量, 使新梯度方向满足夹角约束。动态可信阈值, 可以计算允许的最大垂直分量模长为

$$\|g_i^{\perp}\|_{\max} = \|g_i^{\parallel}\|_2 \tan \theta_{\text{trust}} \quad (21)$$

根据最大垂直分量模长对客户端梯度的垂直分量放缩:

$$g_i'^{\perp} = g_i^{\perp} \cdot \min\left(1, \frac{\|g_i^{\perp}\|_{\max}}{\|g_i^{\perp}\|_2}\right) \quad (22)$$

为维持原始梯度的更新强度, 可保持投影后梯度的模长与原梯度一致:

$$\hat{g}_i = \frac{\hat{g}_i}{\|\hat{g}_i\|_2} \cdot \|g_i\|_2 \quad (23)$$

梯度投影约束算法的执行过程如算法 3 所示。

算法 3 梯度投影约束算法

输入: 客户端梯度 $\tilde{g}_i$ 。

输出: 投影梯度 $\hat{g}_i$ 。

$p_i \leftarrow \cos \theta_i$ // 计算余弦相似度

for $i=1$ to N

If $\theta_i > \theta_{\text{trust}}$ // 若客户端相似度超过阈值

$g_i^{\parallel} \leftarrow \tilde{g}_i$ // 计算梯度垂直和水平分量

$g_i^{\perp} \leftarrow \tilde{g}_i$ // 计算梯度垂直分量

$\|g_i^{\perp}\|_{\max} = \|g_i^{\parallel}\|_2 \tan \theta_{\text{trust}}$ // 约束垂直分量

$\hat{g}_i = \frac{\hat{g}_i}{\|\hat{g}_i\|_2} \cdot \|g_i\|_2$ // 保持原始更新强度得到投影梯度

end If

end for

return $\hat{g}_i$

梯度投影约束通过比较与参考梯度的相似性, 限制角度阈值, 可以校正偏离方向较大的梯度, 使得客户端梯度更新具有一致性, 同时保持原有梯度的更新强度, 保证模型收敛。

2.4 服务器安全聚合

客户端训练结束后提交训练梯度至聚合服务器, 传统的联邦平均算法基于客户端训练样本量赋予其梯度相应的聚合权重, 但是这种方法在面对中毒攻击时往往无法得到正确的训练梯度, 为此 MSRAFL 算法基于客户端自我评估的差别向服务器证明自身更新的可信度。轻量化的计算也能够帮助服务器识别异常客户端, 同时避免额外通信开销或隐私泄露。具体是通过模型在本地数据上的损失变化衡量更新是否合理。

首先在客户端在本地训练开始前, 利用服务器广播的全局模型计算客户端本地数据的损失值 L_{pre} , 因为服务器是根据模型训练前后的损失值的差值来评估客户端的可信度, 因此, 为了避免恶意客户端伪造损失值, 服务器从全体客户端中随机选取数量为 $N/2$ 的部分客户端提供训练前的损失值

L_{pre}^i , 这个损失值是利用服务器下发的全局模型 w_G 计算得到。

$$L_{pre}^i = \frac{1}{|N_i|} \sum_{(x_i, y_i) \in D_i} l(x_i, y_i, w_G), \{i=1, 2, \dots, N/2\} \quad (24)$$

服务器获得这部分训练前的损失值后, 为了避免其中的极端损失值或者恶意客户端上传的恶意损失值对损失差值计算的干扰, MSRAFL 算法利用中位数稳定性的原理计算得出基准损失值。

$$L_{pre} = \text{median}\{L_{pre}^i, i \in [1, N/2]\} \quad (25)$$

当所有客户端利用全局模型 w_G 和本地数据完成本地模型 w_{local} 训练后, 需要在本地数据上利用本地模型计算损失值 L_{post}^i 。然后所有客户端提交训练后的损失值。

$$L_{post}^i = \frac{1}{|N_i|} \sum_{(x_i, y_i) \in D_i} l(x_i, y_i, w_{local}), \{i=1, 2, \dots, N\} \quad (26)$$

服务器获得基准损失值和所有客户端训练后的损失值后, 计算前后两次损失值的变化 $\Delta L_i = L_{post}^i - L_{pre}^i$ 。因为合法更新应使损失下降 ($\Delta L_i < 0$), 而中毒攻击可能导致损失异常上升或震荡。所以可以利用损失值的变化识别恶意客户端, 根据损失之变化设置客户端梯度的可信度分数, 并将其作为梯度聚合权重的参考项。利用式(27)计算梯度的可信度分数。

$$s = e^{(-\alpha \cdot \max(\Delta L_i, 0))} \quad (27)$$

从式(27)中可以看出, 若损失下降(变化量为负), 分数为 1, 表示更新合理。若损失上升(变化量为正), 分数按指数衰减, 聚合权重降低。

MSRAFL 算法采用加权聚合的方法计算全局模型, 具体梯度的聚合权重结合可信度分数和客户端训练梯度和参考梯度的余弦相似度。具体权重计算方法可见式(28)。

$$\lambda_i = s_i \cdot \cos \theta_i \quad (28)$$

对于相似度超过可信阈值的客户端, 在梯度投影约束操作后重新计算其与参考梯度的余弦相似度。除此之外, 为了进一步避免恶意梯度的存在所产生的影响聚合服务器采用截断过滤的方法, 因为经过式(28)的处理后, 恶意梯度的聚合权重会比正常梯度的权重更小, 可以降低恶意客户端对模型聚合的影响。服务器可信聚合过程如算法 4 所示。

算法 4 服务器安全聚合算法

输入: 投影后的客户端梯度 $\hat{g}_i$, 损失值 L_{pre}^i , L_{post}^i 。

输出: 全局模型 w_G^{t+1} 。

```

for  $i=1$  to  $N$ 
     $p_i = \cos \theta_i$  // 计算余弦相似度
     $L_{pre} = \text{median}\{L_{pre}^i, i \in [1, N/2]\}$  // 计算基准损失值
     $\Delta L_i = L_{post}^i - L_{pre}^i$  // 计算前后损失差值
     $s_i = e^{(-\alpha \cdot \max(\Delta L_i, 0))}$  // 计算稳定性分数
     $\lambda_i = s_i \cdot \cos \theta_i$  // 计算聚合权重
end for
 $w_G^{t+1} = w_G^t + \text{Aggr}(\lambda_i \hat{g}_i; i \in [N])$  // 聚合模型
return  $w_G^{t+1}$ 

```

服务器聚合阶段负责初始化全局模型参数, 并根据客户端的训练梯度设置可信阈值, 计算客户端训练后本地模型损失值和训练前全局模型损失值的差值, 用于服务器对客户端训练梯度的判别, 并结合客户端的余弦相似度计算梯度聚合权重, 根据权重大小判别存在的恶意客户端, 保证模型的训练安全, 实现模型的训练目标。

3 性能分析

联邦学习系统需要保证模型训练的安全性和准确性, 本节将从理论分析的角度证明所提出的 MSRAFL 算法可以保

证模型的正常训练, 实现隐私保护和抵抗中毒攻击的目标。

3.1 中毒攻击抗性

MSRAFL 算法通过梯度投影约束和服务器安全聚合实现对恶意梯度的防御, 在梯度投影约束中, 因为相邻训练轮数之间梯度的改变不会太大, 所以可以选择上一轮的全局梯度 g_G 作为参考梯度 g_{ref} , 利用余弦相似性计算客户端训练梯度与 g_{ref} 的相似值 $\{\theta_1, \theta_2, \dots, \theta_i\}$, 根据中位数和中位数绝对偏差 MAD 计算得到可信阈值, 对于超过阈值的客户端梯度, 将其分解为平行分量 $g_i^{\parallel}$ 和垂直分量 $g_i^{\perp}$, 然后利用式(22)对梯度垂直分量放缩: $g_i^{\perp} = g_i^{\perp} \cdot \min\left(1, \frac{\|g_i^{\perp}\|_{\max}}{\|g_i^{\perp}\|_2}\right)$, 减轻梯度方向偏离, 最后恢复梯度原始模长, 保持更新强度。梯度投影约束可以限制梯度更新方向的范围, 避免因噪声添加或恶意投毒导致的梯度方向偏差过大, 更集中的梯度方向更新也更有利于模型收敛。

在服务器安全聚合过程中, 参与训练的客户端接收服务下发的全局模型 w_G , 为了防止损失值造假, 服务器随机选取部分客户端利用其本地数据计算损失值

$$L_{pre}^i = \frac{1}{|N_i|} \sum_{(x_i, y_i) \in D_i} l(x_i, y_i, w_G), \text{ 并从中选取损失值的中位数作为基准损失值 } L_{pre},$$

客户端训练完成后利用本地数据更新本地梯度, 再次利用更新后的本地模型计算损失值 L_{post}^i , 服务器接收到损失值之后计算每个客户端损失值的差值 $\Delta L_i = L_{post}^i - L_{pre}^i$, 理论上正常更新后的模型在数据集上的测试损失值应该是下降的, 因此损失值的差应该是负数, 若梯度是恶意更新则第二次损失值会更大, 损失值的差值也会为正, 由此可以判断出哪些是恶意梯度, 为了对恶意梯度施加惩罚, 本文利用公式 $s_i = e^{(-\alpha \cdot \max(\Delta L_i, 0))}$ 对梯度赋予一个信任分数, 若 $\Delta L_i > 0$, 则 s_i 会被赋予一个很小的值, 将该值和余弦相似度结合 $\lambda_i = s_i \cdot \cos \theta_i$ 计算得到梯度的聚合权重值, 经过惩罚的恶意梯度对模型的聚合影响几乎可以忽略。最后聚合梯度, 更新全局模型, 进行下一轮的模型训练, 直到模型收敛或达到最大训练轮数。

3.2 隐私保护抗性

在 MSRAFL 算法中, 为防止被好奇的服务器或恶意攻击者推理出梯度中的数据信息, 实现对数据的隐私保护, 需要对客户端训练梯度进行裁剪并添加噪声, 噪声的添加需满足式(7), 即 (ϵ, δ) -差分隐私, 对于函数 $f: D \rightarrow R^d$, 其 L_2 敏感度为 $\Delta_2 f$, 则发布 $f(D) + N(0, \sigma^2 I)$ 满足 (ϵ, δ) -差分隐私, 当:

$$\sigma \geq \frac{\Delta_2 f \cdot \sqrt{2 \ln(1.25/\delta)}}{\epsilon} \quad (29)$$

在本文算法中, 每个客户端对梯度进行裁剪, 将梯度 $g' = \text{clip}(g, C)$, 满足 $\|g'\|_2 \leq C$, 然后对裁剪后的梯度添加噪声 $\tilde{g} = g' + N(0, \sigma^2 I)$, 梯度裁剪后, 每个梯度的 L_2 范数不超过 C , 因此敏感度为: $\Delta_2 f = \max_{D, D'} \|\tilde{g}(D) - \tilde{g}(D')\|_2 \leq 2C$, 带入

高斯机制条件: $\sigma \geq \frac{2C \cdot \sqrt{2 \ln(1.25/\delta)}}{\epsilon}$, 若噪声标准差满足这一条件, 则单次梯度发布满足 (ϵ, δ) -差分隐私, 考虑到训练共进行了 T 轮, 根据高斯差分隐私的组合性质, 总隐私预算 ϵ_{total} 满足: $\epsilon_{total} \leq \epsilon \cdot \sqrt{2T \ln(1/\delta)}$, 因此本文算法满足 $(\epsilon_{total}, \delta)$ -差分隐私, 可以实现对客户端数据的隐私保护。

3.3 算法效率

本节从计算复杂度和通信复杂度两个维度对其进行分析。MSRAFL 算法主要包括客户端梯度扰动、服务器端的梯度规

范引导、梯度投影约束和安全聚合四个主要模块。

客户端梯度扰动需进行梯度裁剪和噪声添加, 裁剪操作和噪声添加的时间复杂度都为 $O(d)$, 其中 d 为梯度参数量。因此总时间复杂度为 $O(d)$; 服务器端梯度规范引导需计算每个客户端梯度与参考梯度的余弦相似度, 时间复杂度为 $O(Nd)$, 其中 N 为客户端数量。动态可信阈值的计算涉及历史相似度的中位数和 MAD, 其排序复杂度为 $O(N \log N)$, 总体仍以 $O(Nd)$ 为主; 梯度投影约束对每个疑似异常梯度进行投影校正, 包括向量分解与模长调整, 每个客户端的处理复杂度为 $O(d)$, 总复杂度为 $O(Nd)$; 服务器安全聚合需计算每个客户端的损失变化量、可信度分数和聚合权重, 每个客户端的计算量为常数时间 $O(1)$, 但权重归一化需 $O(N)$, 结合余弦相似度计算, 总复杂度为 $O(Nd)$; 综上, MSRAFL 算法每一轮的总计算复杂度为: $O(Nd) + O(N \log N) \approx O(Nd)$ 。由于在实际联邦学习系统中通常有 $d \gg N$, 因此算法的主要开销来自于与梯度维度相关的操作, 属于可接受范围。

MSRAFL 算法的通信开销与传统联邦学习类似, 每轮训练中客户端需上传梯度向量和损失值(共 $d+2$ 个浮点数), 服务器下发全局模型(d 个浮点数)。因此, 每轮通信总量为: $O(Nd)$ 与 Fedavg 等基准算法一致, 未引入显著额外通信负担。

4 实验验证

为了验证 MSRAFL 算法抵御中毒攻击的有效性, 本节在具体数据集上通过实验进行验证并与相关算法进行了对比分析。

4.1 实验设置

本文实验数据来自公共数据集 MNIST 和 FashionMNIST。使用 CNN 卷积神经网络模型对其进行训练, 这个模型有两个卷积层, 一个平展层和两个全连接层组成, 适合 MNIST 这种类型的小尺寸数据集的图像分类。FashionMNIST 数据集是 MNIST 数据集的一个扩展, 使用增强版的 CNN 卷积神经网络模型对其进行训练, 它由三个卷积层, 一个平展层和三个全连接层组成, 拥有更深的层次结构可以增强特征提取能力。此外, 全局迭代轮数 $epochs=100$, 本地训练轮数 $local_epochs=1$, 批次大小 $batch_size=32$, 客户端数量 $N=10$, 为了训练后期获得稳定的模型, 学习率前 90 轮 $\eta=0.1$, 后 10 轮为 $\eta/2$ 。

为了模仿实际训练种恶意客户端对训练施加模型中毒攻击, 本文设置了数据中毒攻击和模型中毒攻击两种类型的中毒攻击, 并选取了两种典型的攻击方式: 标签翻转攻击和符号反转攻击。为了验证 MSRAFL 算法的有效性, 选取了几种相似的联邦学习鲁棒聚合算法, 具体包括 FBLBP^[16]、PPBR^[17]、CSBR^[27]、ArKrum^[28]、Fedavg。

FBLBP 采用差分隐私技术保护客户端的隐私并基于余弦相似度的异常值去除机制保证了全局模型的鲁棒性。

PPBR 通过结合局部差分隐私机制和修剪填充均值聚合规则, 实现了隐私和鲁棒性的双重目标。

CSBR 通过利用压缩感知(CS)技术对梯度更新进行加密, 以保护数据隐私, 同时使用服务器模型梯度作为信任根, 利用余弦相似性检测恶意梯度。

ArKrum 基于中位数的过滤机制去除极端异常值, 再估计恶意客户端数量, 然后通过平均多个客户端更新来提升模型的稳定性和收敛性。

Fedavg 基于客户端本地数据量大小赋予其相应的聚合权重, 加权聚合客户端训练的本地模型, 可作为基准方法对比所提出的算法。

4.2 对比实验

本文在不同数据集上针对中毒攻击和隐私保护进行了一系列的对比实验, 并以模型训练准确率作为主要评价指标, 分析了 MSRAFL 算法的模型训练准确性, 以及在不同攻击程度下的鲁棒性, 还探究了算法对隐私保护方法的抗干扰性。

在 MNIST 和 FashionMNIST 数据集上测试了无攻击情况下不同算法的训练表现, 从图 3(a)(b)中可以看出, 在 MNIST 和 FashionMNIST 数据集上 MSRAFL 算法的最终测试准确率与传统的 Fedavg 算法以及另外四种相关算法一致, 说明 MSRAFL 算法可以完成模型的正常训练, 另外, 从几种算法的收敛速度可以看出: MSRAFL 算法在训练的前期阶段准确率迅速增长, 直至达到最高准确率, 然后保持平稳, 而其他算法的收敛速度较慢, 在模型训练后期才能达到最好的训练效果, 这种情况的原因是因为 MSRAFL 算法的梯度投影约束操作使得梯度方向更加集中, 规避了偏差方向较大梯度对正常模型训练方向的误导, 所以模型收敛更快, 而其余算法并没有去除错误方向的干扰, 故 MSRAFL 算法能够快速收敛, 减少训练时间, 模型训练效率更高。




图 3 无攻击时模型测试准确率

Fig. 3 Test accuracy of the model without attack

为了测试模型在隐私保护环境下的模型聚合效果, 本文设置不同算法在有隐私保护和无隐私保护下进行模型训练, 观察其模型测试准确率的区别, 其中隐私预算为 $\epsilon=5$ 。实验结果如表 1 所示, 从中可以看出在两种不同的数据集上添加噪声前后 MSRAFL 算法准确率降低了 0.4 至 0.7 个百分点, 属于可接受范围, Fedavg 添加噪声后降低 7.1 与 5.4 个百分点, 受扰动最大。其余算法的下降幅度介于前两者之间。噪声的添加在某种形式上也算是错误的梯度信息, 而 MSRAFL 算法利用梯度投影约束操作校正了不正确的梯度

方向，削弱了噪声的干扰，一定程度上避免了噪声对模型训练的影响。

表 1 模型测试准确率
Tab. 1 Test accuracy of the model

Algorithm	MNIST		FashionMNIST	
	no noise	noise	no noise	noise
MSRAFL	0.942	0.938	0.822	0.815
Fedavg	0.93	0.859	0.81	0.756
FBLBP	0.921	0.905	0.795	0.787
PPBR	0.91	0.870	0.80	0.764
CSBR	0.93	0.885	0.81	0.771
ArKrum	0.915	0.88	0.805	0.772

为了测试 MSRAFL 算法的抗中毒性,本文选择不同比例的客户端作为恶意攻击者,测试了不同算法在隐私保护环境下抵抗中毒攻击的承受能力,MSRAFL 算法与其他算法的对比如表 2 和表 3 所示。

从表 2 中可以看出,在符号反转攻击下,MNIST 数据集上 MSRAFL 算法测试准确率虽略有下降,但始终保持在 0.914 至 0.933 之间,仅下降了 1.9 个百分点,而 PPBR 算法准确率下降明显,从 0.867 下降至 0.710,下降了 15.7 个百分点,其他算法的向量幅度也明显大于 MSRAFL 算法,在表 3 的 FashionMNIST 数据集上 MSRAFL 准确率保持在 0.794 至 0.812 之间,只下降 1.8 个百分点,而 ArKrum、FBLBP 和 CSBR 算法的准确率在 0.7 至 0.8 之间,PPRB 算法从 0.762 降低至 0.623,准确率波动比较明显,另外,在标签翻转攻击下,MSRAFL 算法在 MNIST 数据集上的准确率维持在 0.905 至 0.936 之间,下降了 3.1 个百分点。在 FashionMNIST 数据集上同样维持在 0.785 至 0.814 之间,下降了 2.9 个百分点,

在较高恶意攻击者占比下测试准确率仍能保持较高水准,而 FBLBP 和 PPBR 等算法的准确率在 0.6 至 0.7 左右,准确率下降幅度都在 10 个百分点左右,说明其在较高攻击者占比下抗中毒攻击的能力较差。

符号反转攻击的本质是改变梯度的更新方向,而 MSRAFL 算法通过梯度投影约束,修正中毒梯度的垂直方向分量,使其向良性方向靠拢,抵消了方向攻击的破坏力,确保了全局模型更新方向的总体正确性,而标签翻转攻击在梯度方向上可能具有一定欺骗性,但必然导致模型在本地真实数据上的性能下降。MSRAFL 算法基于损失值变化的可信度评估机制,通过比较客户端训练前后的损失变化,能够识别出未能有效优化本地模型的客户端,结合余弦相似性,构成了双重恶意更新识别屏障,从而能有效过滤掉标签翻转攻击产生的不良更新。

另外,与固定阈值方法不同,MSRAFL 基于历史余弦相似度的中位数和 MAD 动态计算阈值。这使得算法能够自适应不同训练阶段、不同数据分布下梯度更新的正常波动范围。因此在攻击比例升高时,MSRAFL 的鲁棒性优势愈发显著。尤其在攻击比例较高(≥ 0.3)时,其性能优势更加明显,相比之下,FBLBP 和 CSBR 等算法主要依赖余弦相似度或简单的统计过滤,缺乏对梯度方向的主动校正能力和对客户端本地训练效用的深入评估,因此在攻击比例升高时防御能力迅速下降。而传统的 Fedavg 聚合算法因为并没有抵抗中毒攻击的能力,所以存在少量恶意客户端时就已经无法正常模型训练,在后期准确率降到 0.1 以下。PPBR 和 ArKrum 虽然具备一定的鲁棒性,但其防御机制在应对方向性攻击和复杂的数据中毒攻击时,不如 MSRAFL 的多层次、多角度防御体系全面和有效。

表 2 MNIST 数据集上的实验结果
Tab. 2 Experimental results on the MNIST dataset

攻击比例	MSRAFL		FBLBP		PPBR		Fedavg		CSBR		ArKrum	
	符号反 转攻击	标签翻 转攻击	符号反 转攻击	标签翻 转攻击	符号反 转攻击	标签翻 转攻击	符号反 转攻击	标签翻 转攻击	符号反 转攻击	标签翻 转攻击	符号反 转攻击	标签翻 转攻击
0.1	0.933	0.936	0.902	0.903	0.867	0.868	0.521	0.553	0.880	0.883	0.876	0.878
0.2	0.930	0.931	0.894	0.891	0.810	0.853	0.242	0.321	0.872	0.876	0.869	0.873
0.3	0.923	0.922	0.853	0.886	0.756	0.784	0.098	0.098	0.835	0.866	0.864	0.847
0.4	0.914	0.905	0.837	0.853	0.710	0.706	0.098	0.098	0.812	0.845	0.845	0.833

表 3 FashionMNIST 数据集上的实验结果
Tab. 3 Experimental results on the fashionmnist dataset

攻击比例	MSRAFL		FBLBP		PPBR		Fedavg		CSBR		ArKrum	
	符号反 转攻击	标签翻 转攻击	符号反 转攻击	标签翻 转攻击	符号反 转攻击	标签翻 转攻击	符号反 转攻击	标签翻 转攻击	符号反 转攻击	标签翻 转攻击	符号反 转攻击	标签翻 转攻击
0.1	0.812	0.814	0.785	0.786	0.762	0.763	0.451	0.438	0.768	0.769	0.770	0.771
0.2	0.807	0.811	0.783	0.782	0.738	0.743	0.261	0.331	0.755	0.758	0.766	0.767
0.3	0.805	0.801	0.765	0.771	0.669	0.682	0.098	0.098	0.746	0.756	0.757	0.759
0.4	0.794	0.785	0.746	0.747	0.623	0.601	0.098	0.098	0.725	0.732	0.726	0.734

4.3 消融实验

为了验证梯度投影约束操作对模型优化改进的效果,本文设置了消融实验,测试了模型在有梯度投影和无梯度投影的模型的测试准确率,实验设置在两种数据集上,客户端对训练后的梯度添加噪声,恶意攻击者占比为 0.2 时,其他条件相同,模型的最终测试结果如图 4 和图 5 所示。

从图 4 中可以观察到,利用梯度投影约束操作后的算法

训练得到的模型在测试数据集上的测试结果快速增长,且模型测试结果稳定,没有太大的波动,训练轮数达到一半时模型测试准确率趋于平稳,最终达到 0.9 以上,而未经过梯度投影约束操作的算法训练得到的模型在两种攻击情况下收敛速度均低于前者,而且模型出现较多波动,说明模型的稳定性较低,容易被异常模型或添加的噪声干扰,模型最终的测试准确率也略低于增添了梯度投影操作的算法。




图 4 MNIST 数据集模型测试结果

Fig. 4 MNIST dataset model test results

图 5 中的模型在 FashionMNIST 数据集上表现与 MNIST 数据集上的表现类似, 添加了梯度投影操作后的模型测试结果在稳定性和收敛速率上均优于未添加的算法, 这种稳定性的提升直接源于梯度投影约束对异常更新方向的即时纠正。在没有该模块时, 某些轮次中出现的、因强噪声或精巧攻击而产生的严重偏离方向的梯度, 会直接参与聚合, 将全局模型参数“拉偏”, 导致准确率骤降, 形成曲线上的“波谷”。

而梯度投影约束作为一个实时在线的方向滤波器, 能够在这些异常梯度影响全局模型之前就对其进行修正, 从而平滑了整体的训练动态, 增强了训练过程的抗干扰能力。同时, 梯度投影约束在修正恶意梯度的同时, 无意中部分校正了因隐私噪声而偏离方向的良性梯度。这使得 MSRAFL 算法在实现隐私保护的同时, 能够部分抵消噪声对模型收敛的负面影响, 实现了隐私与效用之间更好的平衡。




图 5 FashionMNIST 数据集模型测试结果

Fig. 5 Fashionmnist dataset model test results

5 结束语

本文针对联邦学习中的中毒攻击威胁与隐私泄露风险, 提出了一种抗中毒攻击的隐私保护联邦学习算法(MSRAFL)。该算法通过双阶段防御机制实现安全协同训练: 在客户端侧, 引入差分隐私技术对梯度进行裁剪并添加高斯噪声扰动, 在保护本地数据隐私的同时控制噪声对模型性能的影响; 在服务器侧, 创新性地设计了梯度投影约束机制, 基于历史梯度建立参考方向, 结合动态可信阈值对异常梯度进行方向校正, 有效抑制恶意更新。同时提出客户端可信评估策略, 利用训练前后本地损失值变化量化更新合理性, 结合梯度方向一致性生成聚合权重, 并通过截断过滤低权重客户端进一步提升鲁棒性。实验结果表明, MSRAFL 在隐私保护强度、抗中毒攻击能力及模型性能间实现了更优平衡。未来工作将进一步探索非独立同分布(Non-IID)场景下的防御适应性, 并优化动态阈值机制以降低计算开销。

参考文献:

- [1] Yuyi M, Changsheng Y, Jun Z, *et al.* A Survey on Mobile Edge Computing: the Communication Perspective [J], IEEE Communications Surveys and Tutorials, 2017, 19 (4): 2322-2358.
- [2] 王斌, 王畅, 吕灵慧, 等. 推荐系统中的隐私保护: 技术演进、评估框架与隐私效用协同发展 [J/OL]. 计算机应用研究, 1-15 [2025-09-07]. <https://doi.org/10.19734/j.issn.1001-3695.2025.04.0135>. (Wang Bin, Wang Chang, Lyu Linghui, *et al.* Privacy Preservation in Recommendation Systems: Technological Evolution, Evaluation Frameworks, and Privacy-Utility Synergy [J/OL]. Application Research of Computers, 1-15 [2025-09-07]. <https://doi.org/10.19734/j.issn.1001-3695.2025.04.0135>.)
- [3] Das B C, Amini M H, Wu Y. Security and privacy challenges of large language models: A survey [J]. ACM Computing Surveys, 2025, 57 (6): 1-39.

- [4] Chen Z, Yu X, Hang B, *et al.* A Survey on Federated Learning. [J], Knowledge-based systems, 2021, 216: 106775-106775.
- [5] Pushpa S, Murari K S, Rajnesh S, *et al.* Federated Learning: Challenges, Methods, and Future Directions [J], Federated Learning for IoT Applications EAI: Springer Innovations in Communication and Computing, 2022: 199-214.
- [6] 赵金叶, 李晓会, 贾旭. 基于局部差分隐私的动态聚类个性化联邦学习 [J/OL]. 计算机应用研究, 1-8 [2025-09-07]. <https://doi.org/10.19734/j.issn.1001-3695.2025.02.0050>. (Zhao Jinye, Li Xiaohui, Jia Xu. Personalized Federated Learning with Dynamic Clustering Based on Local Differential Privacy [J/OL]. Application Research of Computers, 1-8 [2025-09-07]. <https://doi.org/10.19734/j.issn.1001-3695.2025.02.0050>.)
- [7] Gan S, Yang C, Jiahua D, *et al.* Data Poisoning Attacks on Federated Machine Learning [J], IEEE internet of things journal, 2022, 9 (13): 11365-11375.
- [8] 刘金全, 张铮, 陈自东, 等. 一种基于联邦学习参与方的投毒攻击防御方法 [J]. 计算机应用研究, 2024, 41 (04): 1171-1176. DOI: 10.19734/j.issn.1001-3695.2023.07.0340. (Liu Jinquan, Zhang Zheng, Chen Zidong, *et al.* A Poisoning Attack Defense Method Based on Federated Learning Participants [J]. Application Research of Computers, 2024, 41 (04): 1171-1176. DOI: 10.19734/j.issn.1001-3695.2023.07.0340.)
- [9] Daquan F, Guanxin H, Chenyuan F, *et al.* EAPS: Edge-Assisted Privacy-Preserving Federated Prediction Systems. [J], 2023 IEEE Wireless Communications and Networking Conference: WCNC, 2023.
- [10] Yichang Luo, Juan Wang, Yimin Zhou. Federated Learning Privacy Protection Scheme Based on Homomorphic Encryption [J], 2024 International Symposium on Internet of Things and Smart Cities (ISITSC), 2024: 67-70.
- [11] Bin Liu, Eric B. Blancaflor. Research on Federal Learning Privacy Protection Based on Secure Multi-Party Computing [J], Proceedings of 2024 3RD International Conference on Cyber Security: Artificial Intelligence and Digital Economy, Csaide 2024, 2024: 142-147.
- [12] Zhiyan Chen, Hong Zheng. SPM-FL: A Federated Learning Privacy Protection Mechanism Based on Local Differential Privacy [J], Electronics, 2024, 13 (20).
- [13] Dong Chen, Hongyuan Qu, Guangwu Xu. AegisFL: Efficient and Flexible Privacy-Preserving Byzantine-Robust Cross-silo Federated Learning [C], International Conference on Machine Learning, 2024.
- [14] Zhuoran M, Jianfeng M, Yinbin M, *et al.* ShieldFL: Mitigating Model Poisoning Attacks in Privacy-Preserving Federated Learning [J], IEEE Trans on Information Forensics and Security, 2022, 17: 1639-1654.
- [15] Siyao Cheng, Chang-E. Ren. FBL-BP: Byzantine-Resilient and Privacy-Preserving Federated Broad Learning [J], 2023 IEEE International Conference on Systems, Man, and Cybernetics (SMC), 2023.
- [16] Ying L, Shengfu N, Jianpeng H, *et al.* PPBR-FL: A Privacy-Preserving and Byzantine-Robust Federated Learning System. [C], Knowledge Science, Engineering and Management, 2022, 13370: 39-50.
- [17] Mingzhe C, Nir S, H. V P, *et al.* Communication-efficient Federated Learning [J], Proceedings of the National Academy of Sciences of the United States of America, 2021, 118 (17)
- [18] McMahan B, Moore E, Ramage D, *et al.* Communication-efficient learning of deep networks from decentralized data [C]// Artificial intelligence and statistics. PMLR, 2017: 1273-1282.
- [19] Jiale Z, Bing C, Xiang C, *et al.* PoisonGAN: Generative Poisoning Attacks Against Federated Learning in Edge Computing Systems [J], IEEE internet of things journal, 2020, 8 (5): 3310-3322.
- [20] Geming X, Jian C, Chaodong Y, *et al.* Poisoning Attacks in Federated Learning: A Survey [J], IEEE Access, 2023, 11: 10708-10722.
- [21] Tengzeng Z, Zehua G, Chao Y, *et al.* Byzantine-robust Federated Learning Via Cosine Similarity Aggregation [J], Computer Networks, 2024, 254.
- [22] Xiaosong Liu, Chungun Xu, Pan Zhang. Byzantine-Robust Federated Learning Based on Multi-center Secure Clustering. [J], CECCT, 2023: 203-207.
- [23] Abbas Y, Ali D, Hadis K, *et al.* A Robust Privacy-Preserving Federated Learning Model Against Model Poisoning Attacks [J], IEEE Trans on Information Forensics and Security, 2024, 19: 6693-6708.
- [24] Lingchen Z, Jianlin J, Bo F, *et al.* SEAR: Secure and Efficient Aggregation for Byzantine-Robust Federated Learning [J], IEEE Trans on Dependable and Secure Computing, 2021, 19 (5): 3329-334.
- [25] Shahrzad K, Nupur K, Adam D, *et al.* Differentially Private Federated Learning with Time-Adaptive Privacy Spending [J], ICLR 2025, 2025.
- [26] Li-Pang Chen. Practical Statistics for Data Scientists: 50+essential Concepts Using R and Python [J], Technometrics, 2021, 63 (2): 272-273.
- [27] Guiqiang H, Hongwei L, Wenshu F, Yushu Z, *et al.* Efficient Byzantine-Robust and Privacy-Preserving Federated Learning on Compressive Domain [J], IEEE internet of things journal, 2024, 11 (4): 7116-7127.
- [28] Kun Yang, Neena Imam. Secure and Private Federated Learning: Achieving Adversarial Resilience Through Robust Aggregation [J], arXiv, 2025.