



计算机工程

Computer Engineering

ISSN 1000-3428,CN 31-1289/TP

《计算机工程》网络首发论文

题目：融合参数个性化的自适应差分隐私联邦学习
作者：王炯炯，张淑芬，代家佳，张晗瑞，张益
DOI：10.19678/j.issn.1000-3428.0253490
网络首发日期：2026-04-20
引用格式：王炯炯，张淑芬，代家佳，张晗瑞，张益. 融合参数个性化的自适应差分隐私联邦学习[J/OL]. 计算机工程.
<https://doi.org/10.19678/j.issn.1000-3428.0253490>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

融合参数个性化的自适应差分隐私联邦学习

王炯炯^{1, 2, 3}, 张淑芬^{1, 2, 3*}, 代家佳⁴, 张晗瑞^{1, 2, 3}, 张益^{1, 2, 3}

(1.华北理工大学理学院, 河北 唐山 063210; 2.河北省数据科学与应用重点实验室(华北理工大学), 河北 唐山 063210; 3.唐山市数据科学重点实验室(华北理工大学), 河北 唐山 063210; 4.玉溪市电子政务内网信息技术中心, 云南 玉溪 653100)

摘 要: 个性化联邦学习通过共享训练参数而非数据进行模型训练, 但仍易受推理攻击, 因此广泛应用差分隐私技术进行防护。针对传统差分隐私个性化联邦学习(Differentially Private Personalized Federated Learning, DP-PFL)中静态模型划分和统一噪声的局限, 本文提出了一种融合参数个性化的自适应差分隐私联邦学习框架 DP-FedADC。首先, 该框架利用设计的参数自适应划分(Adaptive Parameter Partitioning, APP)实现模型参数的动态分析, 并自适应划分个性化参数与共享参数。在此基础上, 设计差异化更新策略(Differentiated Parameter Update, DPU), 通过对不同类型参数施加差异化正则约束, 稳定关键参数更新并缓解梯度裁剪对优化方向的影响。其次, 提出客户端级自适应隐私预算分配策略(Client-level Adaptive Privacy Budget Allocation, CAPBA), 根据客户端个性化参数比例动态调整隐私预算, 使高敏感度客户端获得更严格的隐私保护, 同时避免对全局收敛起主导作用的参数施加过度噪声扰动, 从而抑制隐私噪声在训练后期的累积效应。在 MNIST、CIFAR-10、Fashion-Mnist 数据集上的实验表明, 在严格差分隐私约束下, DP-FedADC 显著提升了分类准确率和领域泛化性能, 其测试准确率相较基线方法最高提升约 2%-4%, 且损失值收敛至更低区间。实验结果验证了所提出框架在差分隐私联邦学习场景下的有效性与鲁棒性。

关键词: 联邦学习; 差分隐私; 数据异构; 个性化联邦学习; 自适应隐私预算

中图分类号: TP309

文献标志码: A

DOI: 10.19678/j.issn.1000-3428.0253490

Adaptive Differential Privacy Federated Learning with Integrated Parameter Personalization

WANG Jiongjiong^{1, 2, 3}, ZHANG Shufen^{1, 2, 3*}, DAI Jiajia⁴, ZHANG Hanrui^{1, 2, 3}, ZHANG Yi^{1, 2, 3}

(1. College of Science, North China University of Science and Technology, Tangshan 063210, Hebei, China; 2. Hebei Province Key Laboratory of Data Science and Application (North China University of Science and Technology), Tangshan 063210, Hebei, China; 3. Tangshan Key Laboratory of Data Science (North China University of Science and Technology), Tangshan 063210, Hebei, China; 4. Yuxi City E-Government Intranet Information Technology Center, Yuxi 653100, Yunnan, China;)

[Abstract] Federated learning trains models by sharing model parameters rather than raw data, but it remains vulnerable to inference attacks, which motivates the integration of differential privacy techniques. To address the limitations of static parameter partitioning and uniform noise injection in conventional Differentially Private Federated Learning (DP-FL), this paper proposes an adaptive differentially private federated learning framework with parameter personalization, termed DP-FedADC. The framework introduces Adaptive Parameter Partitioning (APP) to dynamically analyze model parameters and to separate personalized parameters from shared parameters according to their importance. Based on this partitioning, a Differentiated Parameter Update (DPU) strategy is designed to apply distinct regularization constraints to different parameter types, which stabilizes critical parameter updates and mitigates the distortion of optimization directions caused by gradient clipping. In addition, a Client-level Adaptive Privacy Budget Allocation (CAPBA) strategy is proposed to dynamically adjust privacy budgets according to the proportion of personalized parameters at each client, enabling stronger protection for high-sensitivity clients while avoiding excessive noise perturbation on parameters that dominate global convergence. Experiments conducted on MNIST, CIFAR-10, and Fashion-MNIST demonstrate that under strict differential privacy constraints, DP-FedADC consistently improves classification accuracy, convergence speed, and training stability. Compared with existing baselines, the proposed method achieves up to a 2%-4% improvement in test accuracy and converges to a lower loss range, validating its effectiveness and robustness in differentially private federated learning scenarios.

[Key words] federated learning; differential privacy; data heterogeneity; personalized federated learning; adaptive privacy budget

0 引言

随着人工智能的普及和数据安全意识的增强, 如何在保障用户隐私的前提下实现高效的协同建模, 已成为

当前学术界与工业界的研究热点^[1]。传统的集中式训练方式要求将各方数据汇聚到中央服务器进行统一建模, 这在医疗、金融等涉及敏感信息的领域中存在严重的隐私与合规风险。联邦学习(Federated Learning, FL)为此

基金项目: 国家自然科学基金资助项目 (U20A20179)。

通信作者 E-mail: zhsf@ncst.edu.cn

提供了一种分布式解决方案,使得多个客户端能够在本地完成模型更新,仅上传模型参数供服务器聚合,即可在不直接暴露数据的情况下实现全局模型训练^[2]。然而,尽管联邦学习提升了数据利用率,但攻击者仍可能利用上传的梯度或参数更新进行推理攻击,从而导致用户隐私泄露^[3]。

为防御信息泄露,差分隐私(DP)被广泛引入FL^[4]。传统DP-FL方法^[5-7]多采用固定预算或统一噪声的“静态机制”,在实际应用中面临两难平衡:一方面,不同客户端或参数间的敏感性存在显著差异,统一噪声在强隐私约束下易导致关键参数受损,影响收敛稳定性与最终精度;另一方面,过大的噪声虽保障了隐私,却可能淹没核心特征,难以兼顾训练效用与隐私强度^[8]。近期虽有动态调整隐私预算的研究^[9-11],但多侧重于宏观性能或时间维度,忽略了神经网络内部参数重要性的差异^[12],缺乏细粒度的隐私感知。若能根据参数层面对客户端进行更细粒度的隐私控制,将有助于提升模型在复杂分布下的学习效率。此外,真实场景中数据呈现显著的非独立同分布(Non-IID)特征,导致全局模型泛化受限。个性化联邦学习(PFL)通过个性化模块或参数分离策略提升了模型的本地适应性^[13]。但现有方法^[14-16]多依赖静态或先验的参数划分,难以适应训练过程中参数敏感度的动态演化。同时,对个性化与共享参数采取无差别的更新策略,易导致本地特有知识在聚合中流失,进而影响模型在异质场景下的收敛性能。

鉴于此,本文提出了一种融合参数个性化与自适应差分隐私的联邦学习框架(DP-FedADC)。该框架首先利用模型参数的动态评估机制,自适应地划分个性化与共享参数,并实施差异化的更新策略;其次,引入客户端级的自适应隐私预算分配机制,实现了训练过程中模型参数与噪声强度的协同调节。实验结果表明,DP-FedADC在严格保障数据隐私安全的同时,显著提升了分类模型的性能。

本文的主要贡献包括:

提出了一种参数自适应划分的个性化联邦学习机制。该机制核心在于利用Fisher信息矩阵对模型参数进行动态评估,从而在训练过程中实现个性化参数与共享参数的自适应划分。通过结合差异化更新策略,该机制有效地实现了局部特征与全局知识的协同平衡,极大地增强了模型的泛化能力和个性化表现。

提出了一个客户端级自适应隐私预算分配策略,通过衡量不同客户端的个性化参数比例自适应分配隐私预算,个性化程度高的客户端获得更强隐私保护,个性化

程度低的客户端获得较弱保护,缓解统一噪声机制对全局收敛的负面影响,实现对噪声影响的结构化控制。

在实验部分,我们采用广泛的数据集(CIFAR-10、MNIST、Fashion-Mnist)在不同隐私保护级别中全面验证了所提模型的有效性。实验结果表明,DP-FedADC在领域泛化任务上显著优于现有的DP-FL方法,尤其在强隐私保护设置下,其性能优势更为突出。

1 相关工作

结合差分隐私的个性化联邦学习(DP-PFL)旨在保障客户端数据隐私的前提下,通过定制化模型优化策略实现全局协同与本地适应的平衡,以应对现实场景中数据非独立同分布(Non-IID)的挑战。

面对显著的数据异质性,个性化联邦学习(PFL)的核心思路是引入个性化模块或参数分离机制,提升模型对本地数据的表征能力。例如,FedPer^[17]采用参数分离架构,将底层卷积特征提取作为共享参数,保留高层分类头作为客户端专属参数,以缓解异质数据导致的性能退化;FedRep^[18]进一步明确了“共享表示层”与“个性化预测头”的划分,允许客户端根据本地分布独立调整分类头,提升了跨领域适配能力。FedCoSR/FedCRL^[19]结合浅层共享表示与对比学习机制处理标签分布偏斜(Label Skew),并为数据稀疏客户端引入自适应本地聚合。FedBN^[20]通过本地化批归一化(Batch Norm)参数,使模型统计特性与本地分布匹配,有效解决了跨域异质问题。FedALA^[21]则引入轻量级参数适配器,将全局主干网络的知识迁移至本地,避免了全模型重训并增强了Non-IID场景下的迁移能力。然而,上述方法普遍依赖静态或先验设定的参数划分策略,即在训练前固定共享与个性化参数的范围。此类策略缺乏对参数敏感度在训练过程中动态演化的感知能力,难以根据模型收敛状态实时调整贡献度,易导致关键信息共享不足或非关键参数过度个性化,限制了模型在复杂场景下的性能上限。为抵御模型更新被用于推理或重构隐私数据的风险,研究者将差分隐私(DP)引入PFL框架,通过在上传的更新中注入噪声提供理论安全保障。早期工作如PFL-DP^[22]采用“本地裁剪+上传前注噪”机制保护共享更新,在隐私预算受限时通过保留本地个性化部分来维系性能;PrivateFL^[23]则在通信阶段对共享向量进行差分隐私处理,利用带噪梯度学习有利于个性化的本地变换。尽管如此,此类DP-PFL方法多采用统一噪声强度或固定预算策略,忽略了不同客户端及模型参数对更新敏感度的差异。这种“静态噪声”机制易导致关键参数被过度扰动,

在满足隐私强度的同时往往显著削弱了模型的收敛性能。针对隐私与效用的权衡难题，近期研究开始探索动态分配隐私预算策略。Adap DP-FL^[24]通过自动估计梯度敏感度并动态调整裁剪阈值，使模型在训练后期获得更高的优化精度；DPPMOA^[25]利用历史梯度与损失变化估计实时敏感度，使噪声随模型性能改善而逐渐减弱，增强了训练稳定性；cosAFed^[26]则设计了基于模型相似度、训练轮次及准确率等多因素的评分机制，为不同阶段的更新分配差异化预算。然而，这些动态方法主要关注整体噪声尺度的宏观调整，未能触及客户端内部模型结构的细粒度维度，且缺乏与参数个性化机制的深度协同。

综上所述，现有 DP-PFL 研究在缓解性能退化与隐私防护方面虽取得一定进展，但仍存在两大核心局限：首先，普遍依赖的静态参数划分策略缺乏对参数敏感度动态演化的适应性；其次，现有动态预算分配多局限于宏观层面，未能针对不同客户端及参数特性实现细粒度区分。因此，如何在严苛的差分隐私约束下，实现参数个性化机制与隐私保护机制的协同自适应调节，兼顾自适应保护、个性化学习能力与全局模型效能，具有重要的研究意义与学术价值。

2 基础研究

2.1 Fisher 信息矩阵

在统计学习中，Fisher 信息矩阵 (Fisher Information Matrix, FIM) 是衡量模型参数可辨识性与稳定性的重要工具。其核心思想是通过度量参数对观测数据分布的敏感程度，反映模型对参数变化的响应能力。具体而言，FIM 通常由对数似然函数关于模型参数的一阶导数的平方期望构成，用以刻画损失函数曲率在参数空间中的变化趋势。直观而言，Fisher 信息越大，说明该参数方向上模型对输入数据的响应越敏感，即该参数对模型输出的贡献度更高、携带的信息量更丰富。

在本文中，我们利用 Fisher 信息矩阵对模型参数进行细粒度的重要性评估，通过计算每个参数的 Fisher 信息值来刻画其对模型性能的影响程度。随后结合掩码机制，根据 Fisher 值的大小动态决定参数的更新策略：Fisher 值较大的参数被判定为“关键信息参数”，优先进行个性化保留；而 Fisher 值较小的参数则由共享参数替换，从而在保证个性化表达能力的同时，维持跨客户端模型的协同优化。

为验证 Fisher 信息矩阵能够有效量化参数的重要性，我们设计了对比实验，其结果如图 1 所示。当替换掉 FIM 值排名前 5% 的参数时，模型的分类准确率显著下降；相较之下，若随机替换相同比例参数，仅对准确

率造成轻微影响。该结果表明，FIM 所提供的参数重要性评估能够准确反映参数对模型性能的贡献度，验证了其在参数选择与个性化建模中的有效性。




图 1 基于 Fisher 信息矩阵的参数重要性量化验证

Fig.1 Validation of Parameter Importance Quantification Based on Fisher Information Matrix

2.2 个性化联邦学习

个性化联邦学习 (Personalized Federated Learning, PFL) 作为联邦学习的一个重要分支，致力于解决客户端数据非独立同分布带来的模型泛化能力下降问题。与传统联邦学习追求单一全局模型不同，PFL 允许每个客户端在协作学习的过程中发展出更适合自身数据分布的个性化模型。

假设系统中共有 M 个客户端，每个客户端 i 拥有一个私有数据集 $D_i = \{(x_j, y_j)\}_{j=1}^{N_i}$ ， N_i 表示该数据集的大小。PFL 方法通常将模型参数 W 划分为两部分：个性化参数 ω_i 和共享参数 θ ，即 $W_i = (\omega_i, \theta)$ 。此类“共享主干+个性化头部”的设计是目前主流 PFL 方法的基础架构。PFL 的优化目标可表述为：

$$\min_{\theta, \omega_{1:M}} \left\{ F(\omega_{1:M}, \theta) := \frac{1}{M} \sum_{i=1}^M L_i(\omega_i, \theta) \right\} \quad (1)$$

$$L_i(\omega_i, \theta) = E_{(x,y) \sim D_i} [f(\omega_i, \theta; x, y)] \quad (2)$$

为实现该目标，PFL 通常采用客户端本地训练、服务器端协同聚合两阶段交替迭代流程。每一轮训练中，客户端从服务器接收全局参数 θ^t ，并将其与本地个性化参数 ω_i^t 组合成初始模型 $W_i^t = (\omega_i^t, \theta^t)$ 。接着，进行 E_{local} 轮本地更新，得到更新后的参数：

$$W_i^{t+1} = (\omega_i^{t+1}, \theta^{t+1}) \quad (3)$$

服务器收集各客户端发送的全局参数更新量 $\{\Delta \theta_i\}_{i=1}^M$ ，通过加权平均得到新一轮的全局参数 θ^{t+1} 并将其分发给各客户端，以开启下一轮训练。

$$\theta^{t+1} = \theta^t + \frac{1}{M} \sum_{i=1}^M \Delta \theta_i \quad (4)$$

2.3 差分隐私

差分隐私 (Differential Privacy, DP) 是一种严格的隐私保护框架, 通过在算法中引入随机化机制, 使输出几乎不依赖于单个个体数据的存在与否, 从而在保证模型可用性的同时有效防止敏感信息泄露。

形式化定义为: 随机化算法 M 满足 (ϵ, δ) -差分隐私, 如果对于任意相邻数据集 D, D' (仅相差一个样本) 和任意可测集合 S , 都有:

$$P_r[M(D) \in S] \leq e^\epsilon P_r[M(D') \in S] + \delta \quad (5)$$

其中: ϵ 表示隐私泄露的程度, 越小表示保护越强; δ 表示以极小概率放宽隐私约束。为了实现差分隐私, 需要引入全局敏感度 (Global Sensitivity) 的概念。对于函数 $f: D \rightarrow \mathbb{R}^k$, 其 ℓ_1 敏感度定义为:

$$\Delta f = \max_{D, D'} \|f(D) - f(D')\|_1 \quad (6)$$

在此基础上, 可以通过高斯机制 (Gaussian Mechanism) 向函数输出加入噪声来实现差分隐私:

$$M(D) = f(D) + N(0, \sigma^2 I) \quad (7)$$

$$\sigma \geq \frac{\Delta f \sqrt{2 \ln(1.25/\delta)}}{\epsilon} \quad (8)$$

3 系统流程

3.1 方案概述

针对融合参数个性化与自适应差分隐私的联邦学习框架, 本文设计了以下两个步骤, 如图 2 所示。

步骤 1 参数自适应划分与差异化更新。客户端首先通过 Fisher 信息估计模型参数的信息量, 并将其划分为个性化参数与共享参数两部分。随后对两类参数采用差异化本地训练更新策略: 对个性化参数施加强约束以保持关键知识稳定, 对共享参数施加松弛正则项, 减少裁剪操作对其更新方向的破坏。该步骤将参数自适应划分与差异化更新结合, 实现了细粒度、隐私感知的个性化优化过程。

步骤 2 自适应差分隐私扰动与服务器聚合。根据每个客户端的个性化参数占比动态分配隐私预算, 占比越高的客户端分配的隐私预算越小, 添加噪声越强。客户端对裁剪后的更新向量注入对应规模的高斯噪声, 服务器基于客户端数据量进行加权聚合, 实现个性化隐私保护与性能提升。




图 2 DP-FedADC 模型架构

Fig. 2 DP-FedADC Model Framework

3.2 参数自适应划分与差异化更新

为了应对训练过程中客户端数据分布与参数敏感度的动态变化, 本文设计了参数自适应划分 (APP) 与差异化更新策略 (DPU)。具体为: 在每一轮本地训练开

始前, 客户端 i 会接收来自服务器的全局参数 $W^{(global)}$, 随后, 客户端 i 基于本地数据集 D_i , 结合上轮保存的模型参数 $W_i^{(local)}$, 对每个索引为 j 的参数分量 $W_{i,j}^{(local)}$ 通

过采用基于一阶梯度的经验 Fisher 信息计算各参数分量的 Fisher 值。

$$F(W_{i,j}^{(local)}) = \left(\frac{\partial \log L(W_i^{(local)}; D_i)}{\partial W_{i,j}^{(local)}} \right)^2 \quad (9)$$

$L(W_i^{(local)}; D_i)$ 为客户端 i 在参数 $W_i^{(local)}$ 和本地

数据集 D_i 上定义的对数似然函数, $\frac{\partial}{\partial W_{i,j}^{(local)}}$ 表示对参数索引 j 的偏导数。通过对本地数据样本计算损失函数关于模型参数的梯度, 并对梯度平方进行统计平均, 从而得到各参数的 Fisher 估计值。该方法不涉及 Hessian 矩阵或二阶导数计算, 其计算复杂度与一次标准反向传播处于同一数量级, 适合在资源受限的客户端环境中部署。直观上, 若某参数在对数似然上对应的梯度较大, 则该参数的变化对模型输出影响更显著, 因而 Fisher 值更高。为了消除不同参数间的尺度差异, 需要对 Fisher 值进行归一化处理。设第 k 层参数对应的 Fisher 集合为 $\{F_{k,j}\}$, 则索引为 j 的参数的归一化 Fisher 值可表示为:

$$F_{k,j}^{(l)} = \frac{F_{k,j} - \min_j \{F_{k,j}\}}{\max_j \{F_{k,j}\} - \min_j \{F_{k,j}\}} \quad (10)$$

该归一化过程将 Fisher 值缩放至区间[0,1], 使得层内不同参数的差异具备可比性。在此基础上, 我们为每个客户端构造动态个性化掩码。具体流程如下: 系统为每个客户端重置参数 $R_i = 0; m_1 = 0; m_2 = 0$ 。若某 Fisher 值高于阈值 μ , 则该参数被标记为个性化参数, 保留上一轮的参数值; 否则, 该参数被标记为共享参数, 其参数由中心服务器分发的全局参数替换。形式化地:

$$(m_{k,j}^{(l)} = 1, m_1 + 1) \leftarrow \text{if } (F_{k,j}^{(l)} \geq \mu) \quad (11)$$

$$(m_{k,j}^{(l)} = 0, m_2 + 1) \leftarrow \text{else}$$

$$R_i = \frac{m_1}{m_1 + m_2} \quad (12)$$

$$W_i^{t-1} = (\omega_i^{t-1}, \theta_i^{t-1}) = m_{k,j}^{(l)} \square W_i^{(local)} + (1 - m_{k,j}^{(l)}) \square W^{(global)} \quad (13)$$

其中 $\square$ 表示表示哈达玛积。 $m_{k,j}^{(l)}$ 表示客户端 i 在第 k 层索引为 j 的参数的掩码值。 W_i 为初始化完成的本地训练所用的模型参数。 R_i 统计每个客户端个性化参数所占比例。在得到客户端个性化参数所占比例 R_i 后, 将其上传至中心服务器。由于该比例仅为表征参数特性的标量统计值, 完全剥离了任何具体的模型权重或梯度信息, 因此其上传过程不会引入隐私泄露风险。

需要说明的是, DP-FedADC 并未将个性化参数简单视为完全不参与联邦优化的本地私有参数, 也未将其等同于全局共享参数。在本文框架中, 个性化参数更新信息在训练过程中参与噪声注入与裁剪操作并被上传, 从而产生实际的隐私消耗, 但在全局聚合与优化阶段, 其对模型更新的影响受到显式抑制。引入 Fisher 信息矩阵对参数进行动态评估的目的, 并非决定参数是否参与聚合, 而是刻画参数更新对客户端本地数据的依赖程度。具有较高 Fisher 信息的参数通常携带更多客户端特有信息, 参数更新高度依赖客户端本地样本, 该依赖关系在多轮训练中持续存在, 参数变化更容易暴露客户端数据特征, 其梯度更新在上传过程中具有更高的隐私泄露风险。因此, 对个性化参数进行 Fisher 评估主要用于隐私风险识别, 为差异化更新与隐私预算分配提供依据。

对于承载客户端独特知识的个性化参数, 我们的目标是在保证隐私约束的前提下尽可能保留这些本地模式。为此, 本文在本地更新过程中引入差异化更新策略 (DPU), 对个性化参数与共享参数分别施加不同的约束。

对于包含高度个性化信息的参数, 我们设计了损失函数 L_{lal} , 通过引入基于 L2 范数的正则化项, 限制其局部更新幅度, 使这些敏感参数在优化时保持接近其初始方向。该约束有效避免了个性化参数在训练中被过度扰动, 从而最大程度地维持客户端的独特知识结构。个性化参数的更新公式为:

$$\Delta \omega_i^t = \nabla L_{lal}(W_i^{t-1}; D_i) \quad (14)$$

$$\omega_i^t = \omega_i^{t-1} + (-\eta) \square \Delta \omega_i^t \quad (15)$$

ω_i^t 为客户端 i 在第 t 轮更新后的个性化参数; η 为学习率; ∇L_{lal} 为损失函数 L_{lal} 关于个性化参数的梯度; D_i 为客户端 i 的本地数据集。 $(-\eta)$ 是一个基于负梯度下降的过程。个性化参数的损失函数 L_{lal} 为:

$$L_{lal} = CE(\hat{y}_j, y_j) + \frac{\lambda_1}{2} \|\omega_i - \omega_i^{t-1}\|_2 \quad (16)$$

y_j 第 j 个样本的真实标签化参数; $\hat{y}_j$ 为模型对第 j 个样本的预测概率。 CE 为标准的交叉熵损失, 保证分类性能。 λ_1 为个性化参数的正则化强度。 $\|\omega_i - \omega_i^{t-1}\|_2$ 为 L2 正则化项, 该正则化项通过约束个性化参数的更新幅度, 使其在梯度下降过程中尽量保持与上一轮参数的一致性, 从而间接减轻差分隐私噪声对本地独特知识的干扰, 保证个性化参数能够稳健地保留客户端特有信息, 同时不影响模型的分类性能。

对于共享参数, 我们设计了损失函数 L_{gal} , 通过引

入松弛正则项,使其更新的整体 L2 范数保持接近梯度裁剪边界。由于共享参数承担跨客户端的知识整合任务,这一约束能够减少裁剪操作对其更新方向的破坏,避免裁剪造成的梯度形变,并提高模型在强隐私约束下的性能与鲁棒性。

共享参数的更新公式为:

$$\Delta \theta_i^t = \nabla L_{gal}(W_i^{t-1}; D_i) \quad (17)$$

$$\theta_i^t = \theta_i^{t-1} + (-\eta) \Delta \theta_i^t \quad (18)$$

∇L_{gal} 为损失函数 L_{gal} 关于共享参数的梯度。

$$L_{gal} = CE(\hat{y}_j, y_j) + \frac{\lambda_2}{2} \left\| \theta_i - \theta_i^{t-1} \right\|_2 - C \quad (19)$$

本地更新后本地模型参数由更新后的个性化参数 ω_i^t 和更新后的共享参数 θ_i^t 组成:

$$W_i^{(local)} = (\omega_i^t, \theta_i^t) \quad (20)$$

接着计算本地参数更新:

$$\Delta W_i = W_i^{(local)} - W^{(global)} \quad (21)$$

在对计算出的本地参数更新进行自适应差分隐私扰动后上传至中心服务器。算法 1 详细描述了参数自适应划分与差异化更新的具体执行流程。

算法 1: 参数自适应划分与差异化更新

输入 全局参数 $W^{(global)}$, 阈值 μ , 客户端 i 本地数据集 D_i , 客户端 i 模型参数 $W_i^{(local)}$, 正则系数 λ_1, λ_2 , 本地训练轮数 $local - epoch$, 学习率 η

输出 本地参数更新 ΔW , 客户端个性化参数比例 R

参数自适应划分 (APP)

$$1) \quad F(W_{i,j}^{(local)}) = \left(\frac{\partial \log L(W_i^{(local)}; D_i)}{\partial W_{i,j}^{(local)}} \right)^2 \quad // \text{ 计算}$$

客户端索引为 j 的参数 fisher 值

$$2) \quad F_{k,j}^{(l)} = \frac{F_{k,j} - \min_j \{F_{k,j}\}}{\max_j \{F_{k,j}\} - \min_j \{F_{k,j}\}} \quad // \text{归一化}$$

$$3) \quad \text{if } F_{k,j}^{(l)} \geq \mu \quad // \text{构造动态个性化掩码}$$

$$4) \quad m_{k,j}^{(l)} = 1$$

$$5) \quad m_1 + 1$$

$$6) \quad \text{else}$$

$$7) \quad m_{k,j}^{(l)} = 0$$

$$8) \quad m_2 + 1$$

$$9) \quad R_i = \frac{m_1}{m_1 + m_2} \quad // \text{计算个性化参数比例}$$

$$10) \quad W_i^{t-1} = (\omega_i^{t-1}, \theta_i^{t-1}) \quad // \text{实现参数划分 (APP)}$$

差异化更新 (DPU)

$$11) \quad \text{for } e = 1 \text{ to local-epoch do } // \text{个性化参数更新}$$

$$12) \quad \Delta \omega_i^t = \nabla L_{lali}(W_i^{t-1}; D_i)$$

$$13) \quad \omega_i^t = \omega_i^{t-1} + (-\eta) \Delta \omega_i^t$$

$$14) \quad \text{end for}$$

$$15) \quad \text{for } e = 1 \text{ to local-epoch do } // \text{共享参数更新}$$

$$16) \quad \Delta \theta_i^t = \nabla L_{gal}(W_i^{t-1}; D_i)$$

$$17) \quad \theta_i^t = \theta_i^{t-1} + (-\eta) \Delta \theta_i^t$$

$$18) \quad \text{end for}$$

$$19) \quad W_i^{(local)} = (\omega_i^t, \theta_i^t) \quad // \text{本地更新后模型参数}$$

$$20) \quad \Delta W_i = W_i^{(local)} - W^{(global)} \quad // \text{本地参数更新}$$

$$21) \quad \text{return } \Delta W_i, R_i$$

3.3 自适应差分隐私扰动与服务器聚合

为了实现更细粒度的隐私保障并兼顾全局性能,本文提出了客户端级自适应隐私预算分配策略 (CAPBA)。具体而言,该策略沿用第 3.2 节中基于 Fisher 信息量构建的二值掩码 $m_{k,j}^{(l)}$, 将客户端 i 的个性化参数比例 (即高敏感度参数的比例) 定义为 R_i 。该比例刻画了客户端模型中有多少参数主要服务于本地数据分布,比例越高,说明客户端的模型更新越偏向个性化特征,对应的梯度上传中,隐私泄露风险在整体更新中占比越大。基于这一观察,本文将客户端个性化参数在模型中的占比视为衡量其隐私敏感度的重要指标,并据此设计客户端级自适应隐私预算分配策略。采用逆向映射将 R_i 映射到客户端 i 的本地隐私预算 ε_i , 即个性化比例越高的客户端被分配越小的 ε , 从而对应更高尺度的噪声注入,以获得更严格的差分隐私保护,避免对全局收敛起主导作用的参数施加过度噪声扰动,使隐私保护强度能够与潜在隐私风险相匹配。

需要指出的是,尽管在部分应用场景中客户端可能具备明确的隐私偏好,但在大规模或跨域联邦学习系统中,客户端显式声明隐私需求往往难以获取,或存在主观性和不稳定性问题。本文提出的客户端级自适应隐私预算分配策略并非替代客户端隐私意愿,而是从模型结构和参数敏感性角度对潜在隐私泄露风险进行量化建模,从而在无需额外先验假设的情况下,实现自动化且一致的隐私保护分配。这种基于风险感知的隐私预算调整方式在实际联邦学习系统中具有更强的通用性和可扩展性。

具体而言,本文设计了一种线性—温度化映射 (公

式 24), 旨在隐私敏感性与隐私预算之间建立平滑且可控的对应关系。温度参数用于调节隐私预算对个性化参数比例变化的响应强度, 从而避免在客户端异质性较强时出现过度激进的隐私分配; 同时, 通过对隐私预算设置上下界 $[\varepsilon_{\min}, \varepsilon_{\max}]$ 保证映射结果在实际训练过程中的稳定性与可行性。映射得到的 ε_i 再由 Rényi DP 会计器换算为对应噪声尺度 σ_i , 并在每轮梯度裁剪后添加对应的高斯噪声以实现用户级差分隐私。

梯度裁剪: 对客户端计算得到的本地参数更新 ΔW_i , 首先进行 L2 范数裁剪, 确保其不超过预设阈值 C 。

$$\Delta W_i \leftarrow \Delta W_i \cdot \min \left(1, \frac{C}{\|\Delta W_i\|_2} \right) \quad (22)$$

裁剪操作的目的是控制每个客户端更新的敏感度, 从而为后续添加噪声提供界限。在裁剪操作完成后对裁剪后的参数更新加入独立高斯噪声:

$$\Delta \tilde{W}_i \leftarrow \Delta W_i + N(0, \sigma^2 C^2 I) \quad (23)$$

$N(0, \sigma^2 C^2 I)$ 为独立高斯噪声, σ 为噪声强度, 与期望的隐私预算 ε 相关。通过噪声注入, 确保外部观察者难以推断单个客户端的敏感信息, 实现差分隐私保护。为体现“个性化越强, 隐私保护越强 (ε 越小)”的思想, 我们设计了如下映射:

$$\varepsilon_i = \varepsilon_{\max} - (\varepsilon_{\max} - \varepsilon_{\min}) \left(\frac{R_i}{\max_j R_j + \chi} \right)^\beta \quad (24)$$

$\varepsilon_{\max}$ 、 $\varepsilon_{\min}$ 分别为预算下界和上界, χ 为稳定系数, β 用于调节个性化比例对预算分配的敏感度。隐私预算 ε 与噪声强度 σ 的关系可由 RDP 方法进行推导:

$$\sigma = \Delta \min_{\alpha > 1} \sqrt{\frac{\alpha}{2 \left(\varepsilon - \frac{\log(1/\delta)}{\alpha - 1} \right)}} \quad (25)$$

α 为 Rényi 阶数。参数更新加入独立高斯噪声之后客户端将其发送给中心服务器, 中心服务器将各客户端上传的噪声更新按样本量加权平均:

$$p_i = \frac{|D_i|}{\sum_{j=1}^N |D_j|} \quad (26)$$

$$\Delta W^{(global)} = \sum_i p_i \Delta \tilde{W}_i \quad (27)$$

具体执行流程如算法 2 所示。

算法 2: 自适应差分隐私扰动与服务聚合

输入 本地参数更新 ΔW_i , 隐私参数 δ , 隐私预算上下界 $[\varepsilon_{\min}, \varepsilon_{\max}]$, 剪裁边界 C , 客户端数据敏感度 β

输出 噪声添加后的全局更新 $\Delta \tilde{W}_i$

客户端级自适应隐私预算分配 (CAPBA)

客户端

- 1) for i in St do
- 2) 客户端发送个性化参数比例 R_i 至中心服务器
- 3) end for

中心服务器

$$4) \quad \varepsilon_i = \varepsilon_{\max} - (\varepsilon_{\max} - \varepsilon_{\min}) \left(\frac{R_i}{\max_j R_j + \chi} \right)^\beta$$

//中心服务器计算不同客户端的隐私预算并将其发送给客户端

客户端

$$5) \quad \text{for i in St do}$$

$$6) \quad \Delta W_i \leftarrow \Delta W_i \cdot \min \left(1, \frac{C}{\|\Delta W_i\|_2} \right) \quad // \text{裁剪}$$

$$7) \quad \sigma = \Delta \min_{\alpha > 1} \sqrt{\frac{\alpha}{2 \left(\varepsilon - \frac{\log(1/\delta)}{\alpha - 1} \right)}} \quad // \text{计算噪声强度}$$

- 8) $\Delta \tilde{W}_i \leftarrow \Delta W_i + N(0, \sigma^2 C^2 I)$ //加入噪声
- 9) return $\Delta \tilde{W}_i$

3.4 算法流程

算法 3: DP-FedADC 算法

输入 阈值 μ , 本地训练轮数 $local - epoch$, 全局训练轮次 $global - epoch$, 学习率 η , 正则系数 λ_1, λ_2 , 剪裁目标常数 C , 敏感度 β , 隐私预算上下界 $[\varepsilon_{\min}, \varepsilon_{\max}]$

输出 全局模型 $W^{(global)}$

中心服务器

- 1) 初始化全局参数 $W^{(global)}$
- 2) $W^{(local)} = W^{(global)}$ //将所有客户端的初始参数设置为全局参数
- 3) for t = 1 to global-epoch do
- 4) 中心服务器随机选择参与训练的客户端 St
- 5) 发送全局参数 $W^{(global)}$ 到被选中的客户端 St

客户端

- 6) for i in St do
- 7) 参数自适应划分 (APP)
- 8) 差异化更新 (DPU)
- 9) 客户端级自适应隐私预算分配 (CAPBA)
- 10) end for

中心服务器

- 11) $\Delta W^{(global)} = \sum_i p_i \Delta \tilde{W}_i$ //聚合更新
- 12) $W^{(global)} = W^{(global)} + \Delta W^{(global)}$ //参数更新
- 13) end for
- 14) return $W^{(global)}$

第 1)~2) 行初始化全局模型参数,并将该参数作为所有客户端本地模型的初始参数。第 3)~5) 行开始全局训练循环,中心服务器在每轮迭代中随机选择客户端子集参与训练,并将当前的全局参数分发给这些客户端。第 6)~10) 行客户端并行执行关键的自适应机制:首先进行参数自适应划分 (APP) 和差异化更新 (DPU),以实现个性化优化;随后执行客户端级自适应隐私预算分配 (CAPBA),最终生成满足定制化隐私预算的带噪更新。第 11)~13) 行中心服务器收集所有客户端上传的带噪更新,按样本量进行加权平均以完成聚合,并更新全局模型参数。第 14) 行在完成所有全局训练轮次后,返回最终训练好的全局模型。

4 实验结果与分析

4.1 实验设置

所有实验在 Windows11 系统上进行,Python3.10、PyTorch2.0.1、CUDA12.1 环境下进行,使用单张 NVIDIA GeForce RTX4050 进行训练。隐私参数 β 设置为 0.00001,初始学习率为 0.001, batch size 的大小设定为 64。联邦学习系统总共有 100 个客户端,每轮随机选取 30 个客户端参与本地训练,对 MNIST、CIFAR-10、Fashion-Mnist 的全局训练轮次设置为 100、200、100,本地训练轮次设置为 1、4、2。实验中以卷积神经网络 (CNN) 为模型进行验证,模型由三层卷积层和三层全连接层组成,并通过池化和 ReLU 激活完成对图像的特征提取与分类。四个对比算法与 DP-FedADC 进行对比实验时所采用的隐私预算设置为 DP-FedADC 所采用的隐私预算上下界的中间值。

4.1.1 对比算法 (Baseline)

为了全面评估 DP-FedADC 算法的性能,本文选择了五种具有代表性的基线算法进行对比分析,这些算法涵盖了差分隐私联邦学习中从基础理论到前沿优化的不

同维度。

1) DP-FedAvg^[27]作为经典基准,通过对本地更新进行固定阈值裁剪并加高斯噪声来实现隐私保护。其简单而直观的设计使其成为差分隐私联邦学习的经典基线。

2) DP-FedProx^[28]在 DP-FedAvg 的基础上引入 Prox 正则项以限制本地更新的偏离程度,有效缓解了数据异质性带来的模型偏移。

3) ALI-DPFL^[29]通过一种自适应本地迭代次数和噪声尺度的调整机制,以平衡隐私开销与优化过程,实现了隐私开销与训练过程的灵活平衡。

4) DP-Ditto^[30]采用双层优化机制,通过全局与本地模型间的邻近正则化约束,使本地模型在保留客户端独有特征的同时,避免偏离全局收敛方向,在保障隐私的同时增强了模型对 Non-IID 数据的拟合能力。

5) FedCEO^[31]通过利用模型参数在谱空间中的低秩特性,通过灵活截断高频分量来平滑全局语义空间,从而抵消差分隐私噪声在通信迭代过程中的随机干扰。

所有对比算法均在本文实验设置下自行复现并经过精细调优,以确保在各自最优性能下进行公平对比。

4.1.2 实验数据集

实验选取了联邦学习领域广泛使用的三类经典图像数据集,并采用 Dirichlet 分布模拟客户端间的非独立同分布 (Non-IID) 场景。具体包括: 1) MNIST^[32], 包含 70000 张灰度手写数字图像 (分 10 类), 设置异构参数 0.5 以模拟强异构分布; 2) CIFAR-10^[33], 包含 10 类自然物体的 RGB 彩色图像共 60000 张, 异构参数设为 100; 3) Fashion-Mnist^[34], 由 70000 张服饰灰度图像组成, 其数据规模与类别结构同 MNIST 一致, 但视觉特征更具复杂性, 异构参数设为 0.5。所有数据集均严格遵循标准训练/测试集划分, 旨在全面验证算法在不同视觉任务及异构程度下的鲁棒性。

4.2 实验结果及分析

本文实验旨在全面评估 DP-FedADC 框架的性能, 主要从两个维度展开验证: 一是模型准确性验证, 通过在多个标准数据集上对比本算法与基线方法的分类准确率及损失值, 评估其在隐私约束下的有效性与实用性; 二是不同隐私设置下准确率对比, 通过考察不同隐私预算下模型性能的演化, 探索隐私保护强度与模型效用之间的平衡关系, 进而验证框架在不同隐私需求下的鲁棒性与权衡能力。

4.2.1 模型准确性验证

图 3、图 4 和图 5 分别展示了在 MNIST、CIFAR-10 和 Fashion-MNIST 三个数据集上, 在隐私预算设为 5 的

条件下,所提出的 DP-FedADC 框架与多种基线方法的测试准确率和损失值的变化情况。通过对准确率曲线和损失曲线的对比分析可以发现,DP-FedADC 在严格的差分隐私约束下仍能保持较高的分类准确率,并在训练过程中表现出更快的收敛速度和更好的稳定性。

从图 3 可以观察到,在 MNIST 数据集上,DP-FedADC 在准确率、训练稳定性和最终收敛性能方面均优于对比方法。DP-FedAvg 与 DP-FedProx 在训练初期准确率由约 0.25 快速提升至约 0.7,损失在前 40 轮下降至约 1.0,但随后性能提升明显放缓,准确率稳定在 0.82–0.84 区间,损失下降趋于停滞。这表明传统“全参数共享”模式在差分隐私异构环境下存在一定局限。DP-FedAvg 采用统一的梯度裁剪阈值和噪声尺度,忽略不同客户端数据分布带来的梯度差异,容易导致有效特征被过度裁剪或被噪声干扰。DP-FedProx 虽通过引入近端项缓解客户端漂移,但在强隐私约束下,该约束会限制本地模型对私有数据的个性化拟合能力。相比之下,DP-FedADC 在训练后期仍保持稳定提升,准确率在 40 轮后持续增长并最终达到约 0.85,同时损失进一步下降至约 0.8。该方法摒弃了强制所有参数趋同的思路,通过 APP 策略将易产生分歧的个性化参数保留在本地,仅对具备共性的参数进行聚合,从根本上消除了“全局一致性”与“本地异构性”之间的内生矛盾,从而突破了这两类基线算法的性能上限。DP-Ditto 在训练过程中表现出明显的震荡,其最终收敛精度较 DP-FedADC 低约 0.04,损失值高约 0.15。DP-Ditto 通过全局邻近正则项约束个性化模型与全局模型之间的距离,但统一的约束系数在异构数据环境下难以兼顾模型泛化与个性化需求,容易导致非关键参数过拟合或关键参数在差分隐私噪声下丢失重要特征。相比之下,DP-FedADC 通过自适应参数划分实现更细粒度的知识解耦并结合差异化更新策略进行针对性保护,从结构上缓解了差分隐私中梯度裁剪带来的方向畸变。因此,在强隐私约束下,DP-FedADC 能够有效降低训练波动,并获得更优的收敛精度与稳定性。与 DP-FedADC 相比,ALI-DPFL 在训练中波动较大且性能不足,准确率低约 0.02,损失值高出约 0.2。主因是其虽在时间维度优化了迭代效率,但缺乏对客户端异质性隐私敏感度的空间感知,导致高敏感客户端因噪声过大成为性能短板。DP-FedADC 通过

CAPBA 机制,建立隐私预算与参数个性化比例的动态映射,实现资源按需分配:在严密保护高敏感客户端的同时,利用低敏感客户端作为“稳定锚点”,有效抑制了噪声累积效应,从而突破了 ALI-DPFL 的性能瓶颈。与 FedCEO 采用张量低秩近端优化在服务器端进行全局去噪的策略不同,DP-FedADC 选择在客户端源头进行特征的精确甄别与保护。FedCEO 的核心逻辑是通过截断谱空间中的高频分量来恢复被差分隐私噪声破坏的语义信息,这种“全局平滑”操作在处理 Non-IID 数据时存在显著的副作用:它极易将承载客户端独特性的高频个性化特征误判为噪声并予以剔除,导致模型出现“过平滑(Over-smoothing)”现象。体现在准确率曲线上,FedCEO 虽然能通过去噪实现较快的初期收敛且曲线相对平滑,但在训练后期往往过早陷入性能瓶颈,无法进一步提升精度,其收敛精度低于 DP-FedADC 约 0.03。相比之下,DP-FedADC 并非简单地滤除高频信号,而是精准识别出对本地任务高贡献的敏感参数,并通过 APP 将其保留在本地。这种机制避免了 FedCEO 因强制低秩近似而造成的个性化信息丢失,使得 DP-FedADC 的损失值曲线能够突破 FedCEO 的收敛下界,在保留差分隐私保护的同时,最大程度地还原了数据的细粒度特征。

图 4 显示,在特征复杂、类间差异细微的 CIFAR-10 上,DP-FedADC 优势显著。基线算法(如 FedCEO、FedAvg)因强隐私下的统一裁剪或低秩平滑,抹除了关键高频细节,使准确率在 0.48 附近震荡。而本算法通过 APP 模块精准保留高频个性化参数,提升了信噪比与深层语义挖掘能力。图 5 表明,在异构性更强的 Fashion-Mnist 中,DP-FedAvg 和 DP-Ditto 在该数据集上因“客户端漂移”表现出剧烈的波动。DP-FedADC 曲线平滑且 Loss 更低,主要得益于 CAPBA 策略:它通过为不同异构程度的客户端量身定制隐私保护强度,避免了极端异构样本对全局聚合的冲击。实验显示,本算法达到 0.65 精度所需的通信轮数更少,充分验证了自适应保护机制在处理现实异构数据时的鲁棒性。

综上所述,DP-FedADC 在多个基线方法中均展现了明显的优势,尤其是在隐私保护与模型性能的平衡上,DP-FedADC 不仅能有效保证隐私保护,还能提升模型的准确性、收敛速度与稳定性,从而在实际应用中表现出强大的鲁棒性和实用性。




图3 MNIST数据集的平均测试精度及损失值

Fig.3 The average test accuracy and loss values of the MNIST dataset




图4 CIFAR-10数据集的平均测试精度及损失值

Fig. 4 The average test accuracy and loss values of the CIFAR-10 dataset




图5 Fashion-Mnist数据集的平均测试精度及损失值

Fig. 5 The average test accuracy and loss values of the Fashion-Mnist dataset

4.2.2 不同隐私设置下准确率对比

表1、表2和表3分别给出了在MNIST、CIFAR-10和Fashion-Mnist三个数据集上,不同隐私预算设置下所提出的DP-FedADC方法与多种基线方法的测试准确率对比结果。可以观察到,在所有数据集和各类隐私预算条件下,DP-FedADC均取得了最优或具有显著优势的准确率表现,整体性能稳定优于其他基线方法,验证了该方法在差分隐私约束下的有效性和鲁棒性。

在隐私预算极其受限($\epsilon=3$)时,各基线算法均表现出显著的性能衰减。例如,DP-FedAvg和DP-FedProx在CIFAR-10数据集上的准确率分别仅为44.51%和

42.08%。这种低准确率源于其全局统一的静态保护机制。在强噪声下,DP-FedAvg和DP-FedProx的统一裁剪导致梯度方向严重畸变,且噪声淹没了个性化特征。相比之下,DP-FedADC达到了47.99%,领先基线约4-6个百分点。这证明了其CAPBA(自适应预算分配)的核心优势:它不采取“平均主义”,而是通过公式(24)将更多预算向低敏感客户端倾斜,使模型在极高噪声水平下仍能锁定核心语义,突破了传统DP算法在高噪声下的精度瓶颈。DP-Ditto和ALI-DPFL在 $\epsilon=5$ 时分别达到50.81%和51.26%,而DP-FedADC达到了53.26%。DP-Ditto依赖的固定的邻近正则项在处理Non-IID数据时,容易因“拉

取力量”过强导致本地特有知识丢失。数据上的落后反映了其难以平衡全局一致性与本地差异化。

在 MNIST 数据集上,表 1 中的结果表明,DP-FedADC 同样表现出色。随着隐私预算的增大,准确率显著提高。在隐私预算为 3 时,DP-FedADC 的准确率为 83.18,优于 DP-FedAvg(81.02)和 DP-FedProx(79.68)。随着隐私预算值的增加,DP-FedADC 持续领先,证明了该方法在保护隐私的同时还能有效提升性能。表 1 数据表明,当总预算减少时,由于缺乏类似 CAPBA 的自适应分配机制,ALI-DPFL 对噪声的利用率远低于本算法。DP-FedADC 通过差异化更新(DPU)引导梯度自然符合裁剪边界,确保了收敛的高效性。在 Fashion-MNIST 这种类间特征细微的数据集上,随着隐私预算从 3 增加到 11,各算法准确率均有提升,但 FedCEO 始终无法突破 84.45%的准确率天花板,而 DP-FedADC 在时达到了 87.21%。FedCEO 的技术瓶颈在于其服务器端的张量低

秩去噪。虽然低秩近似能平滑噪声,但它在谱空间截断时无差别地剔除了高频分量。在 Fashion-MNIST 这种类间特征细微的数据集上,这些高频分量往往承载了关键的判别信息。与之不同,DP-FedADC 并不依赖“全局过滤”,而是通过 APP(参数自适应划分)在原始空间保留了 Fisher 信息量大的个性化参数。表 3 的数据有力证明了:参数级的精准留存比全模型的后处理去噪更能挖掘出深度特征,从而实现了更高的效用上限。

综上实验数据分析,DP-FedADC 在三大数据集、不同隐私梯度下均实现了全面领先。尤其在低隐私预算的环境下,其准确率较最强基线均有提升。这从实验层面验证了本章提出的 APP、DPU 和 CAPBA 逻辑的科学性:它不仅解决了 DP-FedAvg、DP-FedProx 的“一刀切”弊端,克服了 FedCEO 的“过平滑”效应,更通过 DPU 策略修正了 DP-Ditto 等个性化方法在含噪梯度下的更新偏离。

表 1 MNIST 数据集不同条件下算法的准确率 (%)

Table 1 Accuracy(%) of the algorithm under different conditions on the MNIST dataset

隐私预算	$\epsilon=[1,5]/3$	$\epsilon=[2,8]/5$	$\epsilon=[4,10]/7$	$\epsilon=[6,12]/9$	$\epsilon=[8,14]/11$
DP-FedAvg[27] (2017)	81.02 $\pm$ 0.25	83.60 $\pm$ 0.22	86.16 $\pm$ 0.20	87.82 $\pm$ 0.18	89.63 $\pm$ 0.15
DP-FedProx[28] (2020)	79.68 $\pm$ 0.27	81.69 $\pm$ 0.24	85.47 $\pm$ 0.21	86.66 $\pm$ 0.19	88.80 $\pm$ 0.16
ALI-DPFL[29] (2024)	81.63 $\pm$ 0.24	83.79 $\pm$ 0.21	87.92 $\pm$ 0.19	88.20 $\pm$ 0.18	89.52 $\pm$ 0.15
DP-Ditto[30] (2025)	82.14 $\pm$ 0.38	83.67 $\pm$ 0.33	87.82 $\pm$ 0.32	88.6 $\pm$ 0.27	89.21 $\pm$ 0.26
FedCEO[31] (2025)	82.75 $\pm$ 0.43	83.87 $\pm$ 0.33	88.21 $\pm$ 0.28	87.97 $\pm$ 0.23	89.67 $\pm$ 0.21
DP-FedADC	83.18$\pm$0.20	85.17$\pm$0.18	88.70$\pm$0.16	88.98$\pm$0.15	90.15$\pm$0.14

表 2 CIFAR-10 数据集不同条件下算法的准确率 (%)

Table 2 Accuracy(%) of the algorithm under different conditions on the CIFAR-10 dataset

隐私预算	$\epsilon=[1,5]/3$	$\epsilon=[2,8]/5$	$\epsilon=[4,10]/7$	$\epsilon=[6,12]/9$	$\epsilon=[8,14]/11$
DP-FedAvg[27] (2017)	44.51 $\pm$ 0.52	50.46 $\pm$ 0.48	56.01 $\pm$ 0.45	57.82 $\pm$ 0.43	58.87 $\pm$ 0.41
DP-FedProx[28] (2020)	42.08 $\pm$ 0.55	49.39 $\pm$ 0.50	54.40 $\pm$ 0.46	57.18 $\pm$ 0.44	58.65 $\pm$ 0.42
ALI-DPFL[29] (2024)	44.70 $\pm$ 0.50	51.26 $\pm$ 0.47	57.43 $\pm$ 0.44	58.19 $\pm$ 0.42	59.59 $\pm$ 0.40
DP-Ditto[30] (2025)	44.33 $\pm$ 0.63	50.81 $\pm$ 0.62	57.31 $\pm$ 0.55	58.66 $\pm$ 0.53	59.63 $\pm$ 0.45
FedCEO[31] (2025)	45.67 $\pm$ 0.58	52.89 $\pm$ 0.54	57.88 $\pm$ 0.47	58.79 $\pm$ 0.34	59.79 $\pm$ 0.31
DP-FedADC	47.99$\pm$0.45	53.26$\pm$0.42	58.15$\pm$0.39	59.02$\pm$0.37	60.06$\pm$0.35

表 3 Fashion-Mnist 数据集不同条件下算法的准确率 (%)

Table 3 Accuracy(%) of the algorithm under different conditions on the Fashion-Mnist dataset

隐私预算	$\epsilon=[1,5]/3$	$\epsilon=[2,8]/5$	$\epsilon=[4,10]/7$	$\epsilon=[6,12]/9$	$\epsilon=[8,14]/11$
DP-FedAvg[27] (2017)	55.37 $\pm$ 0.32	64.13 $\pm$ 0.29	69.61 $\pm$ 0.27	72.20 $\pm$ 0.25	74.21 $\pm$ 0.23
DP-FedProx[28] (2020)	54.87 $\pm$ 0.33	64.42 $\pm$ 0.30	68.65 $\pm$ 0.27	71.81 $\pm$ 0.26	73.97 $\pm$ 0.25
ALI-DPFL[29] (2024)	56.71 $\pm$ 0.30	65.04 $\pm$ 0.28	70.62 $\pm$ 0.26	72.88 $\pm$ 0.25	74.56 $\pm$ 0.23
DP-Ditto[30] (2025)	57.31 $\pm$ 0.41	65.87 $\pm$ 0.39	71.51 $\pm$ 0.33	72.73 $\pm$ 0.31	74.33 $\pm$ 0.30
FedCEO[31] (2025)	56.82 $\pm$ 0.57	65.02 $\pm$ 0.34	72.02 $\pm$ 0.31	73.21 $\pm$ 0.24	73.82 $\pm$ 0.21
DP-FedADC	58.63$\pm$0.27	67.21$\pm$0.26	72.51$\pm$0.25	73.30$\pm$0.24	74.89$\pm$0.22

4.3 消融实验

为了量化各模块对整体性能的贡献,本文在特征分布复杂的 CIFAR-10 数据集上进行消融实验,在不同隐

私预算下,逐步叠加 DPU 和 CAPBA 模块,深入剖析其内在作用机制。在基线模型(仅包含 APP)的基础上引入 DPU 后,在 $\epsilon=[1,5]$ 时模型准确率提升了约 0.31%。

在 CIFAR-10 这种高维图像任务中，模型参数对梯度的细微方向极其敏感。传统差分隐私中的硬梯度裁剪往往会强制改变梯度的几何方向，导致“裁剪偏差”。DPU 通过在本地图更新中引入松弛正则项，引导共享参数的范数平滑地接近裁剪阈值，而非被暴力截断。这种机制在不消耗额外隐私预算的前提下，提高了带噪梯度的方向保真度，使得模型能够在噪声环境中捕捉到更精准的下降路径。单独引入 CAPBA 模块后，模型准确率实现了约 1.51% 的增长。CAPBA 建立了个性化参数比例与噪声尺度的动态映射，实现了隐私资源的帕累托优化。它将有限的“信噪比”资源倾斜给对全局收敛贡献更大的关键参数，有效抑制了聚合过程中的噪声累积效应，从而突破了统一噪声下的性能瓶颈。当 DPU 与 CAPBA 同时启用时，模型达到了 53.26% 的最高准确率，该提升幅度

大于两个模块独立提升之和，体现了显著的协同效应。DPU 与 CAPBA 在优化链条中处于互补位置。CAPBA 负责从“量”的维度降低总体噪声干扰，为优化器提供更清洁的信号环境；而 DPU 负责从“质”的维度修正梯度方向，确保在剩余噪声干扰下仍能保持正确的更新轨迹。使得 DP-FedADC 在 CIFAR-10 这样复杂的异构环境下，能够兼顾隐私保护的坚固性与特征提取的深刻性。

综上所述，DP-FedADC 的性能提升并非源于单一技术的叠加，而是源于三大模块的有机协同：APP 解决了“保护对象”的精准识别问题，DPU 解决了“保护过程”中的梯度偏差问题，CAPBA 解决了“保护力度”的资源配置问题。三者共同构建了一个高度自适应的隐私保护体系。

表 4 消融实验结果

Table 4 Ablation experiment result						
DPU	CAPBA	$\epsilon=[1,5]$	$\epsilon=[2,8]$	$\epsilon=[4,10]$	$\epsilon=[6,12]$	$\epsilon=[8,14]$
×	×	44.23	50.3	55.28	57.63	58.7
√	×	44.54	50.6	56.1	58.65	59.33
×	√	45.83	51.92	57.67	58.8	59.76
√	√	47.99	53.26	58.15	59.02	60.06

4.4 相关参数对模型的影响

我们在 CIFAR-10 数据集上（采用 Dirichlet 划分，设置异构参数 100），隐私预算上下界为 $[2,8]$ 、 $[4,10]$ ，验证 DP-FedADC 中超参数的影响。

4.4.1 正则系数

正则系数 λ_1 、 λ_2 分别控制着个性化参数与共享参数在本地图更新时被施加的不同约束。经过测试，如表 5、表 6 所示，当 λ_1 约为 0.05、 λ_2 约为 0.12 时，我们获得了最佳性能。我们将此设置应用于多个不同数据集，结果均展现出稳定优异的性能。

表 5 不同 λ_1 对训练性能的影响 (%)

Table 5 The impact of different values of λ_1					
λ_1	0.01	0.03	0.05	0.07	0.09
[2,8]	51.39	51.56	53.26	51.83	52.59
[4,10]	57.68	57.77	58.15	57.29	57.33

表 6 不同 λ_2 对训练性能的影响 (%)

Table 6 The impact of different values of λ_2					
λ_2	0.07	0.1	0.12	0.15	0.17
[2,8]	51.59	52.73	53.26	51.08	50.97
[4,10]	56.51	58.12	58.15	56.82	57.72

4.4.2 敏感度系数

敏感度系数 β 控制着个性化比例对预算分配的敏感度。经过测试，如表 7 所示，在 CAPBA 中， $\beta=1$ 的线

性映射导致不同敏感度客户端之间的隐私预算差异有限，高敏感客户端保护不足，中低敏感客户端噪声又难以显著降低，自适应效果较弱。相比之下， $\beta=2$ 的平方映射一方面能更突出地区分高敏感与普通客户端，使前者获得更强隐私保护、后者保持较高信噪比和良好收敛；另一方面又不像更大的指数（如 $\beta=3$ ）那样过度放大噪声，因此本文在其余实验中均采用 $\beta=2$ 作为自适应差分隐私噪声分配的默认配置。

表 7 不同 β 对训练性能的影响 (%)

Table 7 The impact of different values of β					
β	1	1.5	2	2.5	3
[2,8]	52.57	52.93	53.26	52.28	51.93
[4,10]	57.33	57.91	58.15	58.11	57.63

4.4.3 Dirichlet 分布

为刻画不同非独立同分布程度对模型性能的影响，本文采用 Dirichlet 分布控制客户端数据划分，经过测试，如表 8 所示，DP-FedADC 在不同非独立同分布程度下均取得了较高的准确率。

表 8 不同 Dirichlet 分布对训练性能的影响 (%)

Table 8 The impact of different Dirichlet distributions performance				
Dirichlet 分布	a=1	a=10	a=50	a=100
[2,8]	41.21	51.37	52.16	53.26
[4,10]	46.35	55.89	57.61	58.15

4.4.4 Fisher 阈值 μ

阈值 μ 控制参数的动态划分。决定哪些参数被视为客户端的个性化参数，哪些参数被全局参数替换，从而实现对本地图知识全局知识结构化分离。经过测试，

如表 9 所示，当 μ 取 0.2 时，我们获得了最佳性能。我们将此设置应用于多个不同数据集，结果均展现出稳定优异的性能。

表 9 不同 μ 对训练性能的影响 (%)Table 9 The impact of different values of μ performance

μ	0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9
[2,8]	38.34	50.31	53.26	52.32	52.3	52.1	51.23	50.37	43.51	25.98

4.4.5 特征空间分布的可视化分析

为了直观探究 DP-FedADC 在特征表示学习层面的优势，我们利用 t-SNE 技术提取了测试集样本在全连接层之前的倒数第二层特征向量，并将其投影至二维平面进行可视化。图 6 对比了基线算法 DP-FedAvg 与本章提出的 DP-FedADC 在 CIFAR-10 上的特征分布情况。如图 6 (b) 所示，在 DP-FedAvg 的特征空间中，不同类别的簇之间存在显著的粘连与重叠（例如类别 2 与类别 6 的边界模糊）。这表明在统一的差分隐私噪声干扰下，模型难以捕捉到细微的判别性特征，且全局平均聚合导致了异构数据的语义混淆。相反，图 6 (a) 中的 DP-FedADC 展现出了极佳的类间分离度，不同颜色的点团形成了界限分明的“岛屿”。这归功于 APP（参数自适应划分）策略，它成功保留了负责精细分类的个性化参数，避免了全局聚合对本地特有语义的“稀释”。进一步观察可见，DP-FedADC 的同类样本点聚集得更为紧密，而 DP-FedAvg 的同类点则呈现松散的弥散状。这种“内聚”特性意味着模型对噪声具有更强的鲁棒性。DPU（差异化更新）与 CAPBA（自适应预算）的协同作用，有效抑制了梯度裁剪带来的方向畸变和非必要噪声的干扰，使得模型能够学习到更加一致且坚固的特征表示，从而在分类决策边界附近保持了更高的置信度。





图 6 t-SNE 特征

Fig. 6 t-SNE Feature

5 结语

本研究针对当前差分隐私个性化联邦学习 (DP-PFL) 框架中，静态模型参数划分和统一噪声注入机制在处理客户端数据非独立同分布时，导致模型效用与隐私保护失衡的问题，提出了一种融合参数个性化与自适应差分隐私的联邦学习框架 DP-FedADC。该框架的核心创新在于模型参数与隐私噪声强度的协同自适应调节。该框架通过参数的自适应划分与差异化更新，有效平衡了客户端的特有知识与全局协同学习。其次，我们提出了客户端级自适应隐私预算分配策略，在确保高敏感度客户端获得更强的隐私保护的同时提升了全局性能。在数据集上的实验验证了 DP-FedADC 方法的有效性。实验结果表明，在严格的差分隐私约束下，DP-FedADC 在分类准确率和领域泛化性能上显著优于现有 DP-FL 基线方法，尤其在强隐私保护下，性能优势更加明显。

尽管表现优越，但本研究仍存在一定局限：首先，参数重要性评估引入了额外的计算开销，在大规模模型上的效率仍需优化；其次，自适应阈值的选取对特定任务具有一定的敏感性。此外，目前验证主要集中于经典图像数据集。未来工作将聚焦于探索低复杂度的重要性估计方法，设计更具鲁棒性的自适应阈值策略，并结合更多实际应用场景验证框架的普适性。



参考文献

- [1] KAIROUZ P, MCMAHAN H B, AVENT B, et al. Advances and open problems in federated learning[J]. Foundations and trends® in machine learning, 2021, 14(1-2) : 1-210.
- [2] LI T, SAHU A K, TALWALWAR A, et al. Federated learning: Challenges, methods, and future directions[J]. IEEE signal processing magazine, 2020, 37(3) : 50-60.
- [3] HITAJ B, ATENIESE G, PEREZ-CRUZ F. Deep models under the GAN: Information leakage from collaborative deep learning[C]//Proceedings of the 2017 ACM SIGSAC conference on computer and communications security. 2017: 603-618.
- [4] DWORK C, MCSHERRY F, NISSIM K, et al. Calibrating noise to sensitivity in private data analysis[C]//Theory of cryptography conference. Berlin, Heidelberg: Springer Berlin Heidelberg, 2006: 265-284.
- [5] CHENG A, WANG P, ZHANG X S, et al. Differentially private federated learning with local regularization and sparsification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10122-10131.
- [6] 李阳,姜毅,陈帅,等. 多层超网络聚合的个性化联邦学习算法 [J/OL]. 计算机工程, 1-11[2025-12-23].<https://doi.org/10.19678/j.issn.1000-3428.0070679>.
LI Y, JIANG Y, CHEN S, et al. Computer Engineering, Personalized federated learning algorithm based on multi-layer hypernetwork model aggregation 1-11[2025-12-23].
<https://doi.org/10.19678/j.issn.1000-3428.0070679>. (in Chinese)
- [7] LIANG Z, WANG B, GU Q, et al. Differentially private federated learning with Laplacian smoothing[J]. Applied and Computational Harmonic Analysis, 2024, 72: 101660.
- [8] ZHU L, LIU X, LI Y, et al. A fine-grained differentially private federated learning against leakage from gradients[J]. IEEE Internet of Things Journal, 2021, 9(13): 11500-11512.
- [9] 曹天涯,张雨静,贾俊杰,等.基于个性化梯度裁剪的联邦学习隐私保护算法 [J/OL]. 计算机工程, 1-12[2025-12-23].<https://doi.org/10.19678/j.issn.1000-3428.0069644>.
CAO T Y, ZHANG Y J, JIA J J, et al. Computer Engineering, Privacy-preserving algorithm for federated learning based on personalized gradient clipping. 1-12[2025-12-23].
<https://doi.org/10.19678/j.issn.1000-3428.0069644>. (in Chinese)
- [10] 郭子贇,田有亮,李梦倩.基于激励机制的自适应隐私保护联邦学习方案 [J/OL]. 计算机工程, 1-16[2025-12-23].<https://doi.org/10.19678/j.issn.1000-3428.0070751>.
GUO Z B, TIAN Y L, LI M Q. Computer Engineering, Adaptive Privacy-Preserving Federated Learning Scheme Based on Incentive Mechanism. 1-16[2025-12-23].
<https://doi.org/10.19678/j.issn.1000-3428.0070751>. (in Chinese)
- [11] SHAN F, LU Y, LI S, et al. Efficient adaptive defense scheme for differential privacy in federated learning[J]. Journal of Information Security and Applications, 2025, 89: 103992.
- [12] LEE S, ZHANG T, AVESTIMEHR A S. Layer-wise adaptive model aggregation for scalable federated learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(7) : 8491-8499.
- [13] TAN A Z, YU H, CUI L, et al. Towards personalized federated learning[J]. IEEE transactions on neural networks and learning systems, 2022, 34(12) : 9587-9603.
- [14] OH J, KIM S, YUN S Y. Fedbabu: Towards enhanced representation for federated image classification[J]. arXiv preprint arXiv:2106.06042, 2021.
- [15] HUANG Y, CHU L, ZHOU Z, et al. Personalized cross-silo federated learning on non-iid data[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(9) : 7865-7873.
- [16] SUN G, MENDIETA M, LUO J, et al. Fedperfix: Towards partial model personalization of vision transformers in federated learning[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 4988-4998.
- [17] ARIVAZHAGAN M G, AGGARWAL V, SINGH A K, et al. Federated learning with personalization layers[J]. arxiv preprint arxiv:1912.00818, 2019.
- [18] COLLINS L, HASSANI H, MOKHTARI A, et al. Exploiting shared representations for personalized federated learning[C]//International conference on machine learning. PMLR, 2021: 2089-2099.
- [19] HUANG C, CHEN X, ZHANG Y, et al. Fedcrl: Personalized federated learning with contrastive shared representations for label heterogeneity in non-iid data[J]. arxiv preprint arxiv:2404.17916, 2024.

- [20] LI X, JIANG M, ZHANG X, et al. Fedbn: Federated learning on non-iid features via local batch normalization[J]. arxiv preprint arxiv:2102.07623, 2021.
- [21] ZHANG J, HUA Y, WANG H, et al. Fedala: Adaptive local aggregation for personalized federated learning[C]//Proceedings of the AAAI conference on artificial intelligence. 2023, 37(9) : 11237-11244.
- [22] WEI K, LI J, MA C, et al. Personalized federated learning with differential privacy and convergence guarantee[J]. IEEE Transactions on Information Forensics and Security, 2023, 18: 4488-4503.
- [23] YANG Y, HUI B, YUAN H, et al. {PrivateFL}: Accurate, differentially private federated learning via personalized data transformation[C]//32nd USENIX Security Symposium (USENIX Security 23) . 2023: 1595-1612.
- [24] FU J, CHEN Z, HAN X. Adap dp-fl: Differentially private federated learning with adaptive noise[C]//2022 IEEE international conference on trust, security and privacy in computing and communications (TrustCom) . IEEE, 2022: 656-663.
- [25] FAN T, CUI Z. Adaptive differential privacy preserving based on multi-objective optimization in deep neural networks[J]. Concurrency and Computation: Practice and Experience, 2021, 33(20) : e6367.
- [26] WANG Z, YU X, HUANG Q, et al. An adaptive differential privacy method based on federated learning[J]. arxiv preprint arxiv:2408.08909, 2024.
- [27] GEYER R C, KLEIN T, NABI M. Differentially private federated learning: A client level perspective[J]. arxiv preprint arxiv:1712.07557, 2017.
- [28] LI T, SAHU A K, ZAHEER M, et al. Federated optimization in heterogeneous networks[J]. Proceedings of Machine learning and systems, 2020, 2: 429-450.
- [29] LING X, FU J, WANG K, et al. Ali-dpfl: Differentially private federated learning with adaptive local iterations[C]//2024 IEEE 25th International Symposium on a World of Wireless, Mobile and Multimedia Networks (WoWMoM) . IEEE, 2024: 349-358.
- [30] Zhao X, Cui Q, Li W, et al. Convergence-privacy-fairness trade-off in personalized federated learning[J]. IEEE Transactions on Machine Learning in Communications and Networking, 2025, 3: 246-262.
- [31] Li Y, FU L, WANG T, et al. Clients collaborate: Flexible differentially private federated learning with guaranteed improvement of utility-privacy trade-off[J]. arXiv preprint arXiv:2402.07002, 2024.
- [32] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 2002, 86(11): 2278-2324.
- [33] KRIZHEVSKY A, HINTON G. Learning multiple layers of features from tiny images.(2009)[EB/OL].(2009-9)
- [34] H. XIAO, K. RASUL, and R. VOLLGRAF, "Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms," arXiv preprint arXiv:1708.07747, 2017.